队伍编号	MCB2100090
赛道	A

基于多模型 Stacking 融合的二手车定价销售策略研究

摘要

随着中国二手车交易体量日趋增长，一个完善合理的二手车资产价值评估体系亟需构建。但由于二手车具有“一车一况”的特殊属性且新车价格的波动会带来联动影响，二手车的价值衡量标准难以准确设定。本文旨在建立一个二手车资产价值评估的普适性模型，为二手车价格估算提供一种辅助解决方案，并探究缩短门店成交周期的有效手段，为缓和二手车市场信息不对称、完善交易评估体系出一份绵薄之力。

针对问题一，第一步(数据清洗)：本文运用**统计指标、K 近邻算法(KNN)**等填充方法，逐个对附件 1、附件 2 进行缺失值、异常值处理。第二步(特征工程)：本文对部分类别特征数据进行**标签编码**和**独热编码**，然后进行**特征构造**并删除重复信息的字段，同时对部分数值特征进行**分箱**处理。第三步(可视化)：利用 **pandas-profiling** 工具生成研究报告，并通过绘制分布图、热力图、三维柱状图、三维散点图等，对特征变量进行统计解释。第四步(模型准备)：本文依据题干信息及统计学理论，建立并采用**评测标准、调整决定系数R^2、平均相对误差、5%误差准确率**这四项指标作为本文的模型评估标准。第五步(模型建立)：本文先建立**神经网络**模型评判数据集预测情况，然后利用 **XGBoost** 算法、**随机森林**、SFS **序列前向选择**筛选得到 **34 个特征**，据此分别建立 3 个线性回归模型及 7 个树模型，并根据上述 11 个模型的评估结果，决定采用测评表现最优的 **XGBoost** 算法、**LightGBM** 算法、**CatBoost** 算法作为本文的预测模型，同时利用**贝叶斯优化调参**对其进行优化。第六步(模型融合)：为进一步提升模型的预测效果，本文采用 **Stacking 法**将上述选择的 3 个模型进行**模型融合**，其结果表明融合后模型波动更小且预测更为稳定。

针对问题二，本文先在特征工程中对附件 4 数据集进行**特征构造**，同时将其与附件 1 数据集进行拼接处理。通过分析数据集，本文构建车辆的总成交周期由总调价周期和最佳成交周期两个阶段组成的模型，并利用 **XGBoost** 算法判断影响二手车总成交周期的关键因素。针对如何采取行之有效的手段加快门店在库车辆的销售速度，本文决定采用问题一预测出的二手车交易价格作为**指导价**，针对上架价格进行定价处理；同时通过减小调价周期、增大降价幅度、增加调价次数对总调价周期进行干预；针对最佳成交周期，本文先抛弃调价因素，再利用 **XGBoost** 算法进行特征重要性排序，以此得到了多个对最佳成交周期产生显著性影响的特征，并利用**数据可视化**和 **K-Means 聚类分析**探究如何利用这些因素来改善最佳成交周期进而缩减总成交周期。

针对问题三，本文从提高利润率，扩宽客户受众，拓展业务广度，增添附加值业务四个方面入手，通过与互联网公司合作**绘制用户画像**，针对不同地区不同的用户偏好，因地制宜进行展销，并且通过布局二手新能源汽车业务，如二手电池产业，充电桩产业以拓展业务广度，并从二手车检测认证，翻新，质保，保险四个方面增添附加值业务。将有限资源，精准投入到重点领域，增强业绩稳定性，实现良性发展。

关键词：特征工程、神经网络、Boosting 算法、Stacking 融合、K-Means 聚类

目录

一．问题重述 1

1.1 研究背景 1
1.2 研究问题 1

二．问题分析 1

2.1 针对问题一的分析 2
2.2 针对问题二的分析 2
2.3 针对问题三的分析 3

三．原始数据集介绍 4

四．问题一 模型的建立和求解 4

4.1 数据清洗 4
4.2 特征工程 7
4.3 可视化分析 8
4.4 模型准备 10
4.5 神经网络 10
4.6 树模型 11
4.7 模型融合——Stacking 法 19

五．问题二 模型的建立与求解 20

5.1 特征工程 20
5.2 挖掘车辆成交周期的关键因素 23
5.3 寻求加快在库车辆销售速度的有效手段 24

六．问题三 模型的建立与求解 30

6.1 提高利润率 30
6.2 扩宽客户受众 30
6.3 拓宽业务广度 31
6.4 增添附加值业务，增厚利润空间 31

七．参考文献 32

一．问题重述

1.1 研究背景

新冠肺炎疫情的不期而至为全球汽车行业带来严峻挑战。但是，除 2020 年受疫情影响下跌 4%外，中国二手车交易量在过去的 18 年中持续增长。根据中国汽车流通协会统计数据显示，2021 年 1 月至 11 月，中国二手车交易量达 1596 万辆，2021 年全年更是突破了 1700 万辆，同比增长 20%。另外，我国“十四五”规划也深刻影响着汽车产业，加速了二手车“内循环”的构建，促进二手车买卖体系的进一步成熟与完善。除此之外，年度政府工作报告提出“取消对二手车交易的不合理限制”，意在顺畅二手车交易的脉络，鼓励竞争，反对垄断。

纵然十几年间年交易量基本居于增长态势，但由于二手车“一车一况”的特殊属性及新车价格的波动会带来联动影响，我国目前尚未出台有关二手车资产价值衡量的相关政策。因此，市场上二手车价值评估往往来源于二手车交易平台或第三方估价平台。此外，线上收集用户信息结合线下门店展示销售的 020 门店模式是当前二手车的主要零售方法，然而尚未完善的资产评估标准体系可能会导致门店的滞销甚至打包批发。

综上，完善二手车资产价值评估体系是打通二手车市场“任督二脉”的关键所在。道阻且长，行则将至。

1.2 研究问题

鉴于以上背景，本文研究解决问题如下：

问题 1：选择估价方法并预测零售价格

依据附件 1“估价训练数据”所提供的训练用二手车交易样本数据及题目文本涉及的其他相关资料，基于机器学习及统计学理论知识，联系结合各特征变量，训练并测试模型，以选择二手车交易的最优估价方法并预测附件 2“估计验证数据”的二手车零售交易价格，最后将预测结果保存在附件 3“估价模型结果”文件中。

问题 2：挖掘车辆成交周期的影响因素并探究加快销售速度的手段

结合附件 4“门店交易训练数据”所提供的车辆销售各阶段的时间数据以及题目文本涉及到的其他相关资料，结合问题一的结论，深入探究挖掘车辆交易周期的影响性因素，并分析加快二手车销售速度的有效方法及其应用前提和预期效果。

问题 3：思考其他研究问题并阐述思路

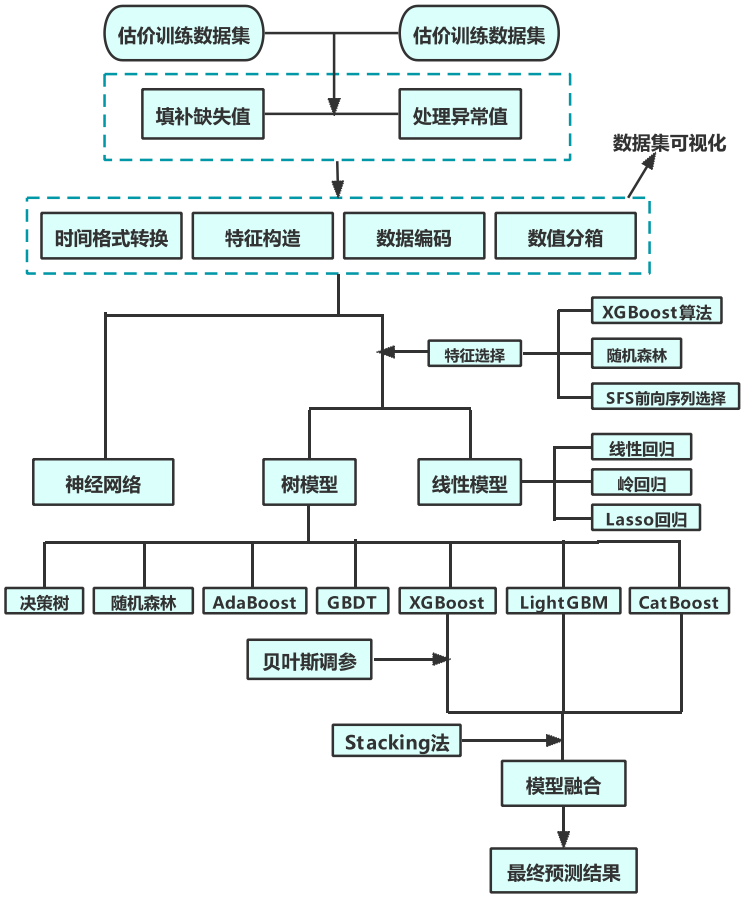
结合题目所提供的数据集及问题一、问题二的研究结果，思考其他值得研究的二手车行业的问题，并阐述相应思路。

二．问题分析

基于重述及附件数据，本文对问题进一步分析如下：

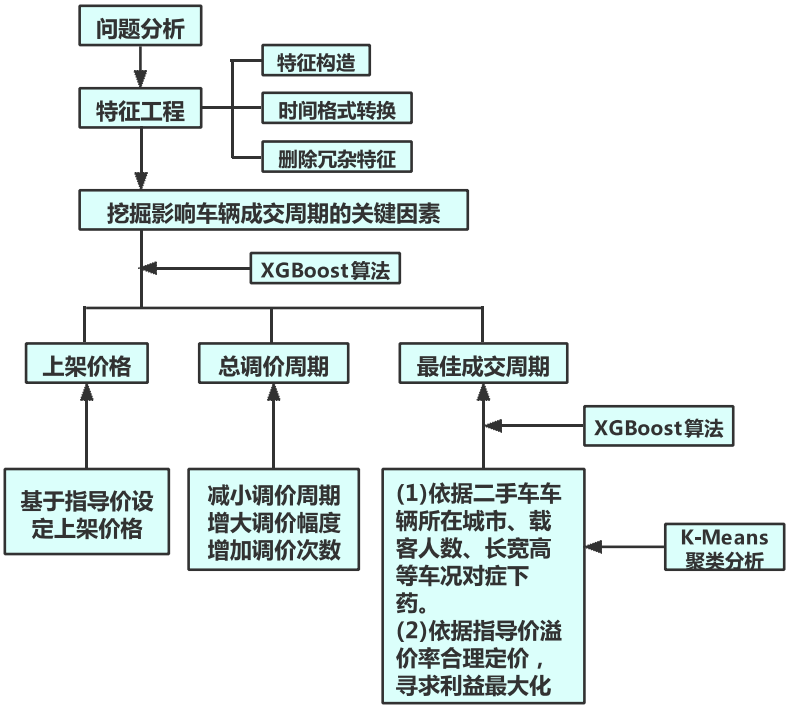
2.1 针对问题一的分析

本文首先对附件 1 与附件 2 的数据集进行预处理，利用统计学手段、K 近邻算法等方法处理原始数据集中的缺失值和异常值，再进行特征工程和数据可视化。此外，本文构建模型的评价指标，以从不同算法中遴选出多个最佳预测模型，并利用 Stacking 法对其进行模型融合，达到进一步稳定预测、减小波动的目的。



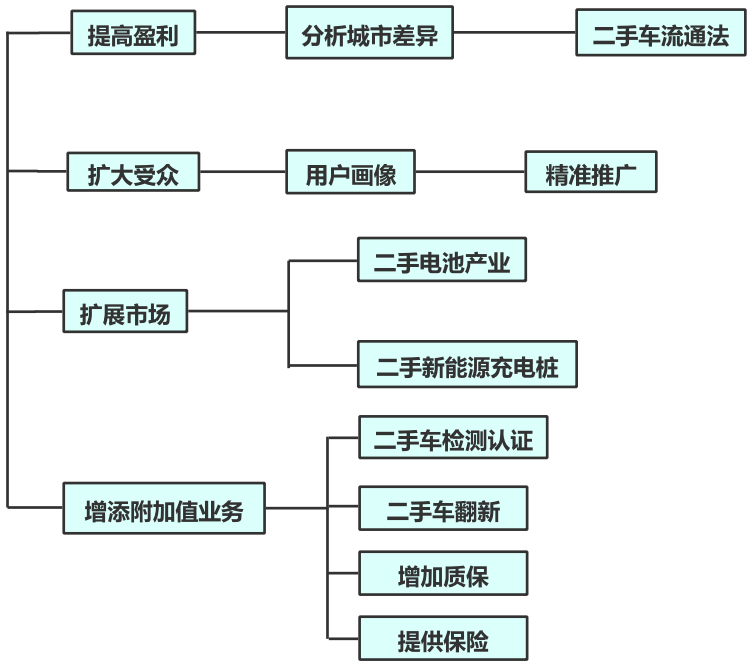
2.2 针对问题二的分析

本文首先对数据集进行特征工程，并利用 XGBoost 算法判断影响二手车总成交周期的关键因素。而针对如何采取行之有效的手段加快门店在库车辆的销售速度，本文以问题一预测得到的二手车交易价格作为指导价，对上架价格进行定价处理；同时通过减小调价周期、增大降价幅度、增加调价次数对总调价周期进行干预；针对最佳成交周期，本文利用 XGBoost 算法进行特征重要性排序，以此获得多个对最佳成交周期产生显著性影响的特征，并利用数据可视化和 K-Means 聚类分析探究如何利用这些因素来改善最佳成交周期进而缩减总成交周期。



2.3 针对问题三的分析

本文从提高利润率，扩宽客户受众，拓展业务广度，增添附加值业务四个方面入手，通过与互联网公司合作绘制用户画像，针对不同地区不同的用户偏好，因地制宜进行展销，并且通过布局二手新能源汽车业务，如二手电池产业，充电桩产业以拓展业务广度，并从二手车检测认证，翻新，质保，保险四个方面增添附加值业务，从而将有限资源，精准投入到重点领域，增强业绩稳定性，实现良性发展。



三．原始数据集介绍

附件 1：原始数据集由 30000 条来源于二手车交易平台的训练用样本数据组成。该数据集中涉及的二手车展销时间跨度长达 19 个月，自 2020 年 1 月 1 日至 2021 年 7 月 31 日。此外，本原始数据集一共包含了 36 个字段，其中 20 列字段主要为二手车车辆基础配置信息、交易时间及价格信息等，15 列字段为匿名特征，另有 1 列字段为本文预测目标——二手车交易价格估值。

附件 2：原始数据集由 5000 条来源于二手车交易平台的验证用样本数据组成。该数据集中涉及的二手车展销时间跨度为 5 个月，自 2021 年 8 月 1 日至 2021 年 12 月 7 日。此外，本原始数据集一共包含了 35 个字段，其中 20 列字段主要为二手车车辆基础配置信息、交易时间及价格信息等，15 列字段为匿名特征。

附件 3：待填充预测值的数据集。

附件 4：原始数据集由 10000 条门店交易数据组成。该数据集一共有 6 个字段，除车型 id 以外，其他字段均与二手车交易过程中各阶段时间及价格有关。

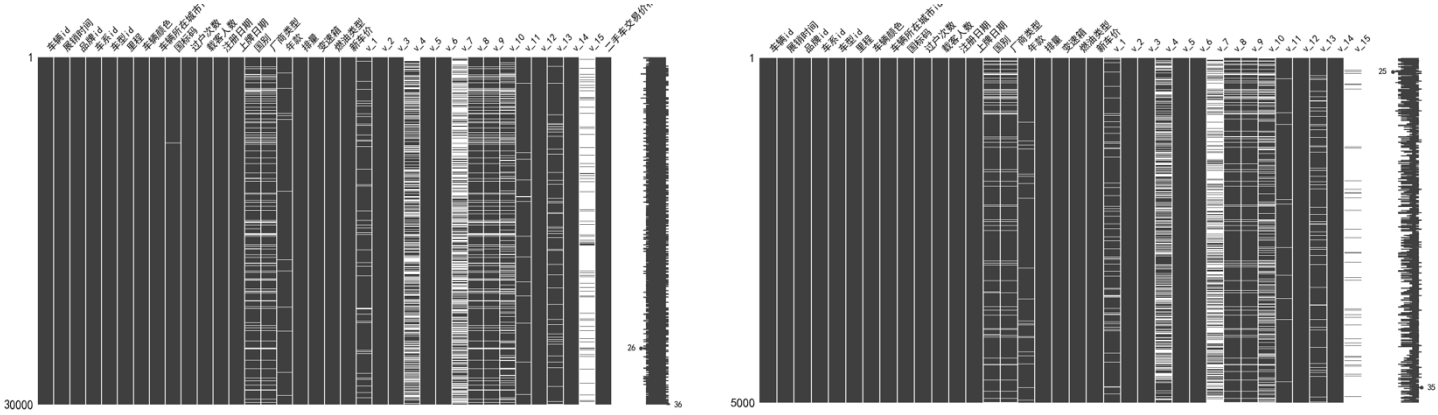
四．问题一 模型的建立和求解

4.1 数据清洗

附件 1、附件 2 原始数据集中，介于时间跨度长、基础配置信息纷繁复杂、车辆品牌型号涉及较广等因素，可能会导致原始数据集出现缺失值、异常值等现象，影响本文数据挖掘及分析的结果，因此本文将先对原始数据集进行初步的数据清洗。

4.1.1 查找缺失值并计算占比

首先，本文先进行缺失值可视化分析，其中，空白值越多代表缺失情况越严重。分别绘制附件 1、附件 2 的缺失值数据密度图如下：



由二图可知，匿名变量 7 及匿名变量 15 空白值明显较多，此外半数的特征变量存在缺失值的情况。为进一步定量处理缺失问题，本文分别查找计算了原始数据集的各字段缺失及其占比情况，如下表所示：

字段名	缺失值数量		缺失值占比	
数据集	训练集	验证集	训练集	验证集

国标码	9	0	0.0300%	0
国别	3757	396	12.5233%	7.92%
厂商类型	3641	375	12.1367%	7.50%
年款	312	106	1.0400%	2.12%
变速箱	1	0	0.0033%	0
匿名变量 1	1582	340	5.2733%	6.80%
匿名变量 4	12108	1863	40.3600%	37.26%
匿名变量 7	18044	3315	60.1467%	66.30%
匿名变量 8	3775	416	12.5833%	8.32%
匿名变量 9	3744	413	12.4800%	8.26%
匿名变量 10	6241	1231	20.8033%	24.62%
匿名变量 11	461	73	1.5367%	1.46%
匿名变量 12	0	1	0	0.02%
匿名变量 13	1619	260	5.3967%	5.20%
匿名变量 15	27580	4719	91.9333%	94.38%

易知，有 15 个字段存在缺失值，其中匿名变量 15 的缺失值占比高于 90.00%，该字段所含缺失值过多而丧失填补价值，因此本文将其剔除并不进行后续数据分析。

4.1.2 处理国标码字段缺失值及异常值

根据国家质量监督检验检疫总局发布的规定，国标码取决于汽车型号、汽车使用燃料及汽车排气污染物排放限值。由此，同一车型 id 对应的载客人数、排量及燃油类型相同，相应的，其国标码也应当相同。所以，在不将 NaN 计入总数的情况下，本文通过分别计算同一车型 id 各国标码所含样本数目，经比较得其众数作为填充值，以对缺失值及异常值进行替换处理。

4.1.3 处理国别字段缺失值及异常值

易知，同一品牌 id 对应同一国别（如，宝马品牌仅对应德国）。本文以品牌 id 为依据进行分组可知，国别字段同时存在缺失值及异常值。对此，在不将 NaN 计入总数的情况下，本文通过分别计算同一品牌 id 各国别所含样本数目，经比较得其众数作为填充值，对缺失值及异常值进行替换处理。

此外，本文分别基于以下两种情况进行特殊填补处理：

1) 当某品牌 id 对应国别均为空值时，则将其填补为所有国别字段的众数，即为 779412。
2) 已知国别区间为 779411-779419 及 779421，而品牌 id 为 37 的字段对应国别均为 0，故将其填补为 779420。

此外，介于国别变量是一个类别特征，而考虑到较大数值对于后续模型的影响，本文利用 Label Encoder 对其进行编码。

4.1.4 处理厂商类型字段缺失值及异常值

检索数据集可知，同一品牌 id 对应厂商类型相同。对此，在不将 NaN 计入总数的情况下，本文通过分别计算同一品牌 id 各厂商类别所含样本数目，经比较得其众数作为填充值，对缺失值及异常值进行替换处理。

特殊的，若某品牌 id 对应厂商类别均为空值，则将其填补为所有厂商类型字段的众数，即为 2。

4.1.5 处理年款字段缺失值

易知，展销时间、注册时间、上牌时间这 3 个字段均为 object 格式，为后续展开比较和计算，本文利用 pandas 库中的方法 dt 对其进行高效操作，将上述 3 个字段转化为 datetime64 格式。

据此检索发现，年款基本居于注册日期与上牌日期附近。因此，本文决定以注册日期的年份填补年款缺失值，而数据集原本的已填年款不做改动。

由于年款变量也是一个类别特征，所以本文同样利用 Label Encoder 对其进行编码处理。

4.1.6 处理变速箱字段缺失值

由于变速箱字段仅存在 1 个缺失值，且该缺失值对应的车系 id 为 459。经检验，车系 id 为 459 的所有记录对应变速箱均为 15，因此本文填补缺失值为 15。

4.1.7 处理匿名变量 7

本文观察数据集易知匿名变量 7 为时间变量，过户次数和匿名变量 7 存在联系，且匿名变量 7 的时间均先于展销时间，据此本文猜测匿名变量 7 为前一次过户时间。通过进一步观察，本文对此归结了以下两种异常情况并作出处理：

1) 当过户次数为 0 时，几乎所有匿名变量 7 为空值。对此，本文将过户次数为 0 的所有记录处理为空值。
2) 当过户次数不为 0 时，仅存在 5 个变量不为空值。对此，本文将这 5 条记录的过户次数处理为 0。

4.1.8 处理匿名变量 11

由于难以判断匿名变量 11 的特征类型，因此本文用该匿名变量的众数对其进行填补。

4.1.9 处理匿名变量 12

易知匿名变量 12 是车辆的长宽高数据，而附件 2 中该特征变量存在 1 个缺失值，其对应的车型 id 为 1866，而附件 1、附件 2 中不存在其他车型 id 为 1866 的记录。因此本文根据该缺失值的车系 id4，选取车系 id4 对应车辆长宽高数据的众数来进行缺失值填充。

4.1.10 处理匿名变量 13

易知，匿名变量 13 的时间基本在注册时间之前，且相差不超过 5 个月，本文猜测该变量为出厂日期。由于该特征的信息解释和注册时间重复性及相关性较高，因此本文仅保留注册时间，对匿名变量 13 进行删除处理。

4.1.11 处理匿名变量 1、4、8、9、10

通过观察数据集，匿名变量 1、4、8、9、10 均为类别变量，因此本文采取 K 近邻(K-NN)算法对样本进行判别归类。K 近邻主要思想为少数服从多数，寻找待分类样本周围最近的 K 个已分类样本，若 K 个已分类样本大多数属于类别 A，则将该待分类样本归为类别 A。本文具体步骤如下：

1) 选取特征

本文选取“品牌 id”、“车系 id”、“车型 id”、“国别”、“厂商类型”、“排量”、“变速箱”及“燃油类型”这 8 个字段作为特征变量。

2) 计算欧式距离

此时本文利用欧式距离公式计算待分类样本点与已分类样本点之间的距离，即不同样本之间的相似程度。

由于存在 8 个特征变量，因此本文假设待分类样本点 A 的坐标为$(A_1, A_2, \cdots, A_8)$，已分类样本点 B 的坐标为$(\mathrm{B}, B_2, \cdots, B_8)$，那么 A、B 两点的欧式距离为：

$$|AB| = \sqrt{(A_1 - B_1)^2 + (A_2 - B_2)^2 + \cdots + (A_8 - B_8)^2}$$

3) 根据 K 值判定类别

计算得到各已分类样本与待分类样本的欧式距离后，即可根据距离远近对已分类样本进行升序排序。通过选取前 K 个已分类样本并核算得到其中的最多类别，从而实现未知样本的归类，完成匿名变量 1、4、8、9、10 的缺失值处理。

4.1.12 处理二手车交易价格异常值

根据本文的模型假设 1，认定实际保值率大于等于 150%为异常值，据此查找计算二手车交易价格的异常值占比大约为 0.033%。例如车辆 id 为 49878 的车辆新车价格为 15.28 万，而其二手车交易价格为 109000 万，明显为异常值，本文猜测是录入时小数点缺失导致。对于一般汽车而言，二手车交易价格往往低于新车价格，因此本文将小数点前移 4 位，修改其价格为 10.90 万元。其他异常值同理。

4.2 特征工程

4.2.1 特征构造

步骤一：构造特征——使用时长、使用年限

本文利用“展销时间”减去“上牌时间”得到新特征“使用时长”，再除以 365 天并调用 Math 库向上取整得到新特征“使用年限”。

步骤二：构造特征——距离上次过户时长

本文利用展销时间减去匿名变量 7 得到新特征“距离上次过户时长”，其中没有过户次数的记录统一填充为 0。

步骤三：构造特征——交易淡旺季

本文根据展销时间择选得到，每年的 2、3 月份及 6、7、8 月份是二手车交易的淡季，而年初、年末及 9 月份为旺季。

结合资料，淡季可能是由于 2、3 月份正值春节或春节刚过，汽车行业适才开业；而 6、7、8 月渐入夏季，炎热的天气导致人们外出频率的降低，且暑假的来临让学生家庭接送孩子的需求也相应下降，可能因此延后购车。而旺季可能是因为年初、年末人们日常薪资与年终奖到位，未来消费预期也比较乐观，且此时正值春运，购入汽车回家便捷；而 9 月学生开学，学生家庭购车需求增强，且气温稍降，人们日常出行频率变高。

步骤四：构造特征——实际保值率、实际折旧率、年实际折旧率、每公里实际折旧率

除此之外，本文仅对附件 1 训练集构造了上述 4 个特征，其计算公式分别如下：

$$\begin{cases} \text{实际保值率} = \dfrac{\text{二手车交易价格}}{\text{新车价}} \\ \text{实际新车价} = \dfrac{\text{新车价} - \text{二手车交易价格}}{\text{新车价}} \\ \text{年实际折旧率} = \dfrac{\text{折旧率}}{\text{使用年限}} \\ \text{每公里实际折旧率} = \dfrac{\text{折旧率}}{\text{里程}} \quad （若 > 1 \text{ 则计作 } 1） \end{cases}$$

步骤五：特征构造——v_11_n

本文将匿名变量 11 进行独热编码，为去除编码后“匿名变量 11”变量名中的“+”，本文对该变量重新命名如下：

原变量	重命名后变量
v_11_1	v_11_1
v_11_1+2	v_11_2
v_11_1+2,4+2	v_11_3

v_11_1,3+2	v_11_4
v_11_3+2	v_11_5
v_11_5	v_11_6

步骤六：特征构造——长、宽、高

观察易知匿名变量 12 是一个三维数据，本文猜测这是车辆的长宽高，因此本文将其拆分为“长”、“宽”、“高”三个特征变量。

步骤七：保存数据集

本文将此时的训练集和验证集分别保存为“估价训练数据整理_可视化.xlsx”和“估价验证数据整理_可视化.xlsx”，用作后续可视化分析使用。

步骤八：删除冗杂特征——展销时间、注册日期、上牌日期、匿名变量 7、12

由于在上述步骤中已充分利用“展销时间”、“注册日期”、“上牌日期”、“匿名变量 7”计算得到了新的时间特征变量，因此为了避免信息的重复解释并对数据集降维，本文对这 4 个特征进行删除处理。

此外，由于“匿名变量 12”被拆分为 3 个新特征，因此该变量也需要进行删除。

步骤九：保存数据集

本文将此时的训练集和验证集分别保存为“估价训练数据整理_NN.xlsx”和“估价验证数据整理_NN.xlsx”，用作后续神经网络模型分析使用。

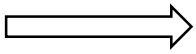
4.2.2 数据转换

步骤一：独热编码(One Hot Encoder)

易知，本数据集中存在多个离散变量，且变量的取值之间不存在大小比较的意义。因此，为了扩充特征作用以解决属性数据的离散值问题，本文对“车辆颜色”、“厂商类型”、“燃油类型”、“交易淡旺季”以及匿名变量 1、2、3、6、8、9、10、14 进行独热编码，将上述 12 种类型的数据存储在垂直空间中。

以“匿名变量 14”的部分样本为例：

车辆 id	匿名变量 14
1	1
2	2
5	2
6	2
7	1
10	1
12	2
……	



车辆 id	匿名变量 14_1	匿名变量 14_2	匿名变量 14_3
1	1	0	0
2	0	1	0
5	0	1	0
6	0	1	0
7	1	0	0
10	1	0	0
12	0	1	0
……			

步骤二：“里程”分箱

本文将“里程”进行降序排列，然后以(0,3]、(3,6]、(6,9]、(9,12]、(12,15]、(15,45]为区间对数据进行分箱处理，再分别对其进行独热编码并命名“里程”标签，结果如下：

里程标签	区间	居于该区间内的样本个数
里程_1	(0,3]	8364
里程_2	(3,6]	7940
里程_3	(6,9]	5135
里程_4	(9,12]	4466
里程_5	(12,15]	2546

里程_6	(15,45]	1549

步骤三：“使用时长”分箱

此外，本文将“使用时长”进行降序排列，然后以(0,1000]、(1000,2000]、(2000,3000]、(3000,4000]、(4000,6000]为区间对数据进行分箱处理，再分别对其进行独热编码并命名“使用时长”标签，结果如下：

使用时长标签	区间	居于该区间内的样本个数
使用时长_1	(0,1000]	6539
使用时长_2	(1000,2000]	10145
使用时长_3	(2000,3000]	7451
使用时长_4	(3000,4000]	4196
使用时长_5	(4000,6000]	1669

步骤四：保存数据集

经上述特征工程，本文构造了 121 个特征变量以供后文中的树模型进行训练，并将此时的训练集和验证集分别保存为“估价训练数据整理_TreeModel.xlsx”和“估价验证数据整理_TreeModel.xlsx”。

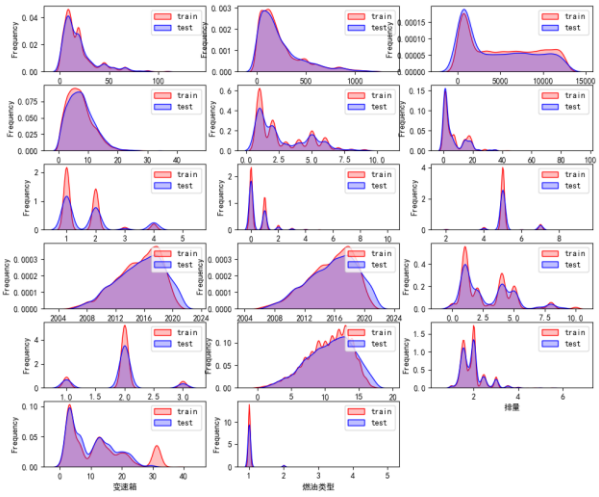
4.3 可视化分析

4.3.1 使用 pandas-profiling 工具生成数据报告(详见“数据报告.html”)

报告显示，经处理后数据集不存在缺失值。对单变量进行分析，里程的频数分布直方图呈正态分布，最大里程数为 44.74 公里；车辆过户次数基本都在 2 次以内；载客人数基本都为 5 人，这意味着小型五人座私家车为二手车交易的主要车型；二手车交易年款以 2016 年款居多，可能是因为 2016 年购入的新车截止到目前为止，里程和使用年限均处于二次交易的理想范围；排量主要分布在 1～2 之间，可能因为国家限制碳排放政策的落实；燃油类型主要为 1 类型，本文猜测 1 类型为汽油，满足绝大部分私家车的燃油需求，2 类型为柴油，主要由客车、货车使用；新车价主要集中在 30 万以内，这是绝大部分家庭所能承受的私家车新车价格；使用年限为 4 年居多，主要分布在 3～5 年之间；车辆的长和宽趋于正态分布；高相对集中在一个明显高峰和一个小高峰，可能是因为绝大部分两厢私家车的高度趋于相同，而一部分高顶车型为一部分人群的受众偏好。

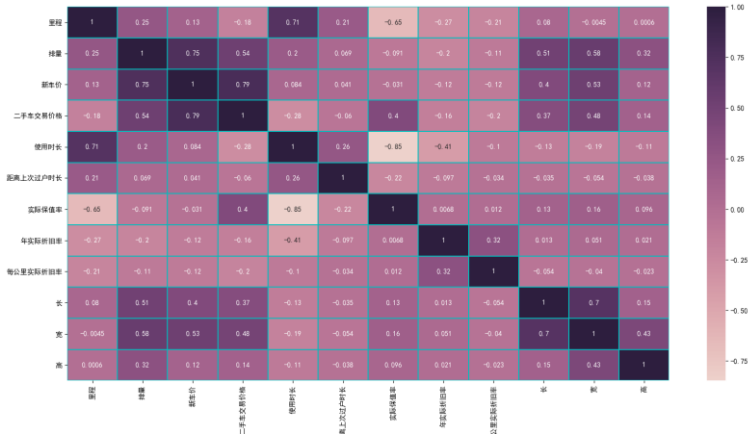
4.3.2 查看数据分布

通过绘制题给训练集与验证集所有特征字段的分布，得出二者分布基本趋于一致，表明后续通过将模型对训练集进行训练并预测验证集是行之有效的策略。



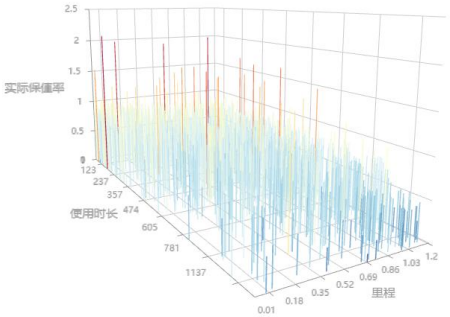
4.3.3 连续数字特征可视化

将二手车的里程、排量、新车价、二手车交易价格、使用时长、距离上次过户时长、实际保值率、年实际折旧率、每公里实际折旧率、长、宽、高这些数字特征绘制热力图如下，同时本文绘制配对网格图见所附文件“配对网格图.png”。

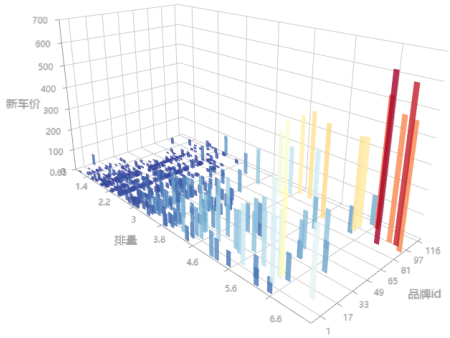


4.3.4 绘制三维柱状图

1) 本文以二手车的使用时长为 X 轴，里程为 Y 轴，实际保值率为 Z 轴绘制了三维柱状图，如右所示。由图可知，随着里程和使用时长的增加，柱体变短，表明二手车的实际保值率相应下降；使用时长和里程接近于 0 的相对较新的二手车，其实际保值率极高。因为实际保值率与二手车资产价值直接挂钩，所以里程和使用时长可能是二手车价格评估的重要因素。

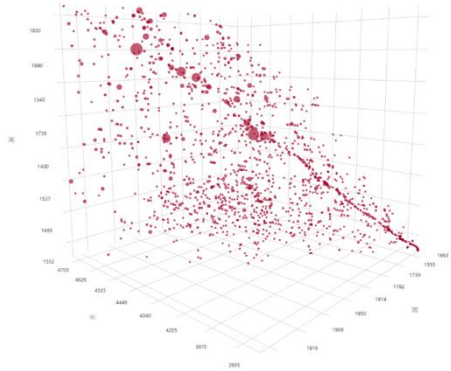


2) 本文以二手车的排量为 X 轴，品牌 id 为 Y 轴，新车价为 Z 轴绘制了三维柱状图，如右所示。由图可知，以同一品牌 id 的车辆为前提，排量越大，代表新车价的柱体越高，故排量与新车价呈正相关，对后续预测二手车价格起到至关重要的作用。



4.3.5 绘制三维散点图

本文以二手车的长为 X 轴，宽为 Y 轴，高为 Z 轴，新车价为散点体积大小，绘制了三维散点图，如右所示。



由图可知，绝大部分二手车的长宽高呈多元线性关系，且新车价较高的样本也基本聚集在该线附近，这意味着二手车体积按相同比例放大或缩小，可能存在一个相对舒适且利用率合理的行车空间。

4.3.6 图片见附件

1) 本文绘制了二手车交易价格预测值的分布情况，将约翰逊分布、正态分布、对数正态分布与预测值进行比对，判断其预测值满足经过约翰变换后服从正态分布概率的随机变量的概率分布。
2) 本文绘制了二手车各特征变量的偏度、峰度图，反映了该统计数据分布的偏斜方向和陡缓程度的度量。

本文将上述图片保存在附件中。

4.4 模型准备

4.4.1 模型评测标准

根据题干，本文建立了模型评测标准如下：

$$0.2 \times (1 - Mape) + 0.8 \times Accuracy_5$$

其中，Ape代表相对误差，公式为：

$$Ape = \frac{|\hat{y} - y|}{y}$$

$Mape$代表相对误差，假设真实值为$y = (y_1, y_2, \cdots, y_m)$, 模型预测值$\hat{y} = (\widehat{y_1}, \widehat{y_2}, \cdots, \widehat{y_m})$，其为公式为：

$$Mape = \frac{\sum_{i=1}^{m} Ape_i}{m}$$

$Accuracy_5$代表 5%误差准确率，其公式为：

$$Accuracy_5 = \frac{count(Ape \leq 0.05)}{count(total)}$$

其中，$count(Ape \leq 0.05)$代表Ape在 5%以内的样本个数，而$count(total)$意味着样本总数量。

4.4.2 调整决定系数R^2

本文运用调整决定系数R^2(Adjusted R-squere)对后文回归模型结果进行评估，其公式如下所示：

$$R^2_{adjusted} = 1 - \frac{(1 - R^2)(n - 1)}{n - p - 1}$$

R为决定系数，其公式为：

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} = \frac{\sum(\hat{y}_i - \bar{y})^2}{\sum(y_i - \bar{y})^2} = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

其中 SSR 为回归平方和，SST 为离差平方和，SSE 为残差平方和。

决定系数往往能够用于描述回归模型的拟合优度，但是当样本体量较大时会存在一定程度上的误差，而调整决定系数能够消除样本体量和特征维度带来的误差影响。由于本题的训练集涉及到 30000 条样本记录，因此本文也选择使用调整决定系数来对后文中回归模型进行拟合优度评估。

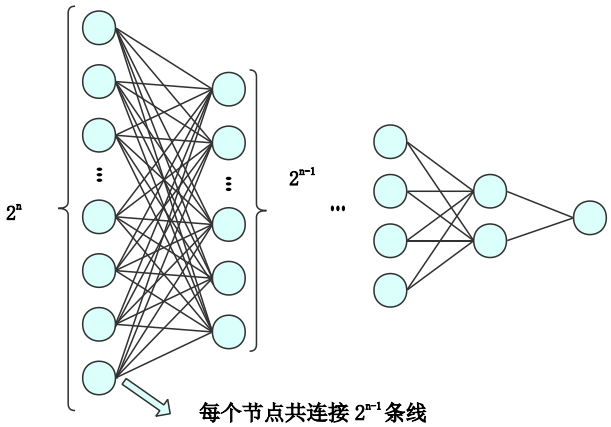
4.5 神经网络

4.5.1 Sequential 模型

神经网络模型的思想来源于模仿人类大脑思考的方式。神经元是神经系统最基本的结构和功能单位，人类大脑在思考时，神经元会接受外部的刺激，当传入的冲动使神经元的电位超过阈值时，神经元就会从抑制转向兴奋，并将信号向下一个神经元传导。神经网络的思想是通过构造人造神经元的方式模拟这一过程。

实际应用中，常常采用多层神经网络，在多层神经网络模型中，输入层和输出层间可以有多层隐藏层，层与层之间互相连接，信号通过线性变换和激活函数的复杂映射，不断地进行传递。

Keras 是一个高层神经网络库。Keras 序列模型可以很容易地拟合回归数据并预测测试数据，Keras 分为两种类型的模型，顺序模型(Sequential)和泛型模型(Model), 我组考虑利用 keras 中的 Sequential 模型对二手车交易价格进行预测。Sequential 通过多个网络层的线性堆叠达到回归目的，具有极好的实用效果。其原理如下图：



4.5.2 模型评价

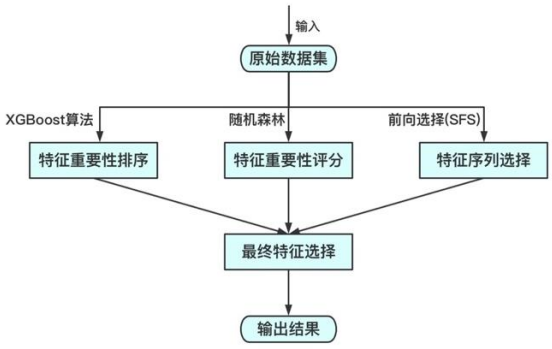
	调整决定系数R^2	平均相对误差	5%误差准确率	评测标准
模型评价	0.93242	0.17508	0.25480	0.36882

由此可知，神经网络平均相对误差高达 15%以上，考虑到二手车交易价格定价的严谨性，本文暂不采纳该神经网络模型。

4.6 树模型

4.6.1 特征选择

为增强模型的泛化能力并减少过拟合，本文将利用包裹式(Wrapper)特征选择法完成对各变量的遴选。相较于过滤式方法(Filter)，包裹式方法能够筛选出规模相对较小的优化特征子集。而机器学习本身具有的特征打分机制，能够被运用到特征选择任务上以达到筛选的目的。本文的特征选择流程如下图所示：



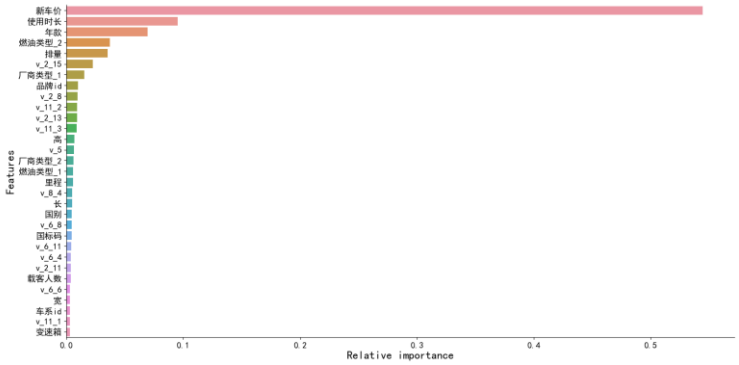
步骤一：特征重要性排序——XGBoost 算法

树模型通常用于机器学习算法自动进行的特征筛选。其获取各个特征重要性分数的核心在于信息增益的计算。信息增益即为某一条件划分下信息不确定性减少的程度，而树模型正是利用信息增益准则来对特征变量进行选择。因此，本文利用树模型中的 XGBoost 算法对特征变量进行遴选，其信息增益公式为：

$$IG(X,Y) = H(Y) - H(Y|X) = \sum_{x,y} p(x) \cdot p(y|x) \cdot logp(y|x) - \sum_{y} p(y) \cdot logp(y)$$

在机器学习中，熵意味着变量不确定的度量。对于上述公式，经验熵$H(Y)$代表数据集Y的不确定性，而经验条件熵$H(Y|X)$代表在特征变量X这一给定条件下数据集Y的不确定性，二者之差即为信息增益，代表特征变量X作用下数据集Y不确定性减少的程度。由于不同特征变量往往能带来不尽相同的信息增益，因此通过计算各特征变量的信息增益并将其排序，即可得到回归能力最优的特征。

本文将特征重要性大于 0.3%的变量绘制成特征重要性分数条形图如下所示：

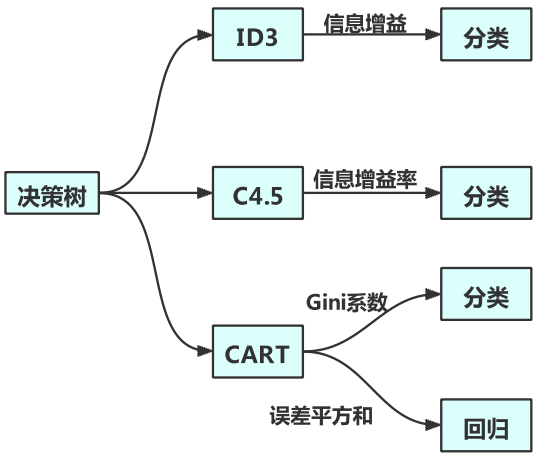


由图可知，新车价是二手车交易价格最重要的特征影响因素，其特征重要性分数高达 54.447%；其次是使用时长，其特征重要性分数为 9.543%，可能是因为除限量车型等特殊情况以外，一般性车辆的硬件设施及行驶品质会随时长增加而下降，其资产价值也相应下滑；年款对二手车零售价格也具有一定影响，其特征重要性分数为 6.963%，可能是因为汽车款式的迭代更新会带来更加新颖和高档的驾驶体验，价格也随之上涨；燃油类型_1 和排量的特征重要性分数分别为 3.735%和 3.523%，这可能与近些年来新能源汽车的市场占有率上涨有所挂钩，且使用汽油的私家车价格差异更为明显（相比较而言，代表柴油的燃油类型_2 特征重要性分数较低，可能是因为使用柴油的客车及货车相较于私家车的社会功能不同导致其二手车价格大同小异），同时，排量对价格的影响可能还来源于政府节能减排政策的落实以及绿色环保节能出行的社会倡议。

步骤二：特征重要性评分——随机森林

随机森林(Random Forest，RF)是一种将多棵互不关联的决策树(Decision Tree)加权集合构成的模型算法，是集成学习中 Bagging 方法的一种，具有随机属性且适用于较高维度的数据集。随机森林的核心在于样本采样和特征采样的随机性，其基本原理是输入待预测的X个原始数据，利用集成的N棵决策树执行判断和分类任务并得到N个分类结果，而随机森林通过集成汇总所有分类结果以最终输出投票次数最多的类别。

而决策树主要分为 ID3、C4.5 以及 CART 三种类型的算法，前两者分别以信息增益和信息增益率解决分类问题，但 CART 算法既能够以基尼系数(Gini Coefficient)为依据应用在分类问题上，也可以用于建立回归树模型。决策树各类型算法如右图所示：



而本文正是基于 CART 算法建立随机森林回归模型，其基本原则为最小均方差(MSE)。CART 回归树是针对连续的目标变量，选取能够最优划分特征变量的值，再通过将数据与该值比较以达到树分裂的目的。其基本思想为：针对随机划分的特征变量A，将其所对应的随机划分点s划分为数据集D_1和D_2，并求出这两个数据集的最小均方差之和的最小值所对应的特征变量及特征值划分点，其表达式为：

$$\underbrace{min}_{A,s}[\underbrace{min}_{c_2}\sum_{x_i\in D_1(A,s)}(y_i-c_1)^2+\underbrace{min}_{c_2}\sum_{x_i\in D_2(A,s)}(y_i-c_2)^2]$$

其中，c_1是数据集D_1的最小均方差，c_2是数据集D_2的最小均方差。

本文利用基于 CART 算法建立的回归随机森林对所有特征变量进行重要的的打分，其步骤如下：

1、使用训练数据训练模型；

2、计算训练数据在随机森林上依据某一特征变量预测结果和实际结果的决定系数 R 方，记作得分，并使用 k 折交叉验证取该特征变量得分的平均值；

3、遍历训练数据集中的每一列特征变量，在原训练数据集的基础上通过对比得分将对应的特征变量进行筛选操作，然后使用模型得到筛选后特征变量。

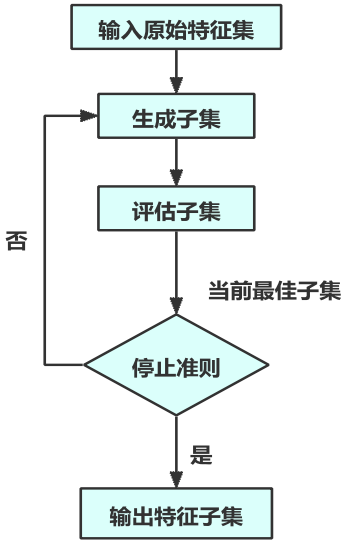
由于篇幅有限，本文选取随机森林打分排名前 10 的特征变量，具体如下表所示：

排名	特征变量名	随机森林打分情况
1	新车价	0.616
2	排量	0.452
3	宽	0.343
4	品牌 id	0.337
5	v_5	0.313
6	变速箱	0.261
7	长	0.248
8	v_11_5	0.166
9	高	0.152
10	国别	0.14

步骤三：特征序列选择——前向选择(SFS)

由于高纬度特征往往存在特征冗余及特征无关的情况，因此当特征维度过高时，通常会导致分类器性能的下降。为了避免上述的“维灾难”，本文将利用特征序列选择（Sequential Feature Selection）来去除冗余特征及地相关性特征的影响，改善精度的同时减少模型训练所需时间。

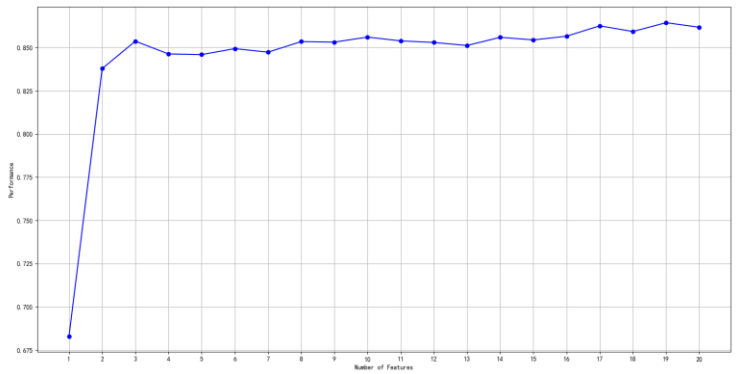
特征序列选择的原理是从初始特征中筛选出高相关性的最优特征以达到降低数据集维度的目的，其基本步骤如右图所示：



此外，特征序列选择主要有以下三种：

特征序列选择种类	具体方法
序列前向选择	向一个空集中逐步添加高相关性最优特征。
序列向后消除	将一个全集中逐步删除低相关性的最差特征。
序列前向选择和后向消除组合	逐步择选高相关性的最优特征的同时，删除剩余特征中低相关性的最差特征。

本文采用了序列前向选择的方法，从 121 个特征变量的原始数据集中遴选出 20 个特征变量，并绘制了特征重要性的边际效应图如下：



步骤四：最终特征选择

本文通过联合比较 XGBoost 算法中特征重要性分数大于 0.3%的变量与随机森林回归模型重要性评分大于 0.03 的变量，取其交集得到二者共同遴选出的特征变量，再将之与步骤三中特征前向选择的结果取并集，并绘制关键词标签云如右图所示，最终筛选得到 34 个特征变量如下：



序号	特征变量名	序号	特征变量名
1	品牌 id	18	车辆颜色_8
2	车系 id	19	厂商类型_1
3	里程	20	燃油类型_1
4	国别	21	v_1_3
5	年款	22	v_2_4
6	排量	23	v_2_8
7	变速箱	24	v_2_11
8	新车价	25	v_2_13
9	v_5	26	v_2_15’
10	使用时长	27	v_3_3
11	使用年限	28	v_3_6
12	交易旺季	29	v_6_7
13	v_11_1	30	v_6_12
14	v_11_3	31	v_8_4

15	长	32	v_10_2
16	宽	33	里程_2
17	高	34	使用时长_3

4.6.2 线性回归模型

步骤一：建立模型

模型 1——线性回归(Linear Regression)

本文采用的线性回归模型是假设目标值与特征变量线性相关的基础上，以误差均方函数为损失函数，并令损失函数最小以确定参数的回归方法。

模型 2——岭回归(Ridge Regression)

岭回归在损失函数中增加了二阶正则项的最小二乘，也叫 L2 范数，具有降维作用的同时，它还以限制模型参数对异常样本的匹配程度，处理相关性高的数据集，进而提高模型面对多数正常样本的拟合精度。我组通过 RidgeCV 针对正则化强度 alpha 进行调参，得出在 alpha 为 14 时可以达到较好的拟合效果。

模型 3——Lasso 回归(Lasso Regression)

Lasso 回归类似于上文提到的岭回归，也通过构造惩罚函数来处理特征变量的共线性问题。但是，相较于岭回归，Lasso 回归可以通过使惩罚项由 L2 范数变为 L1 范数将相对不显著的特征变量系数压缩为 0，达到剔除变量的目的；而岭回归仅仅只在一定程度上压缩特征变量系数且会保留回归模型的全部变量。

步骤二：模型评估

根据上文模型准备中所详细阐述的评测标准和调整决定系数R^2，本文对线性回归模型、岭回归模型、Lasso 回归模型进行评估，其结果如下表所示：

模型	线性回归模型	岭回归模型	Lasso 回归模型
调整决定系数R^2	0.76108	0.76121	0.75069
平均相对误差	0.52198	0.52298	0.53002
5%误差准确率	0.13317	0.13317	0.13317
评测标准	0.20214	0.20194	0.20214

由表可知，三种线性回归模型的调整决定系数R^2均小于 0.8，这意味着模型的拟合优度表现一般；平均相对误差均在 52%左右，表现不佳；而 5%误差准确率基本在 13%左右，相对较高；除此之外，模型的测评标准相对较低，均在 0.2 左右。因为，本文暂不采用线性回归模型。

4.6.3 树模型

步骤一：建立模型

模型 1——决策树模型

决策树已在上文特征选择中有过阐述，当它执行回归任务时，其结构为是否问题的二叉树结构，是从根部节点伊始，通过单一特征变量进行测试，以测试结果为依据将样本划分至子节点。

模型 2——随机森林

随机森林已在上文特征选择中详细阐述。基于 CART 算法建立随机森林回归模型，其基本原则为最小均方差(MSE)。为了保证模型的泛化能力，随机森林在建立每棵树的时候，往往会遵循数据随机、特征随机这两个基本原则。CART 回归树再针对连续的目标变量，选取能够最优划分特征变量的值，并通过将数据与该值比较以达到树分裂的目的。

模型 3——AdaBoost 算法

AdaBoost 算法是一种有效而实用的 Boosting 算法，它以一种高度自适应的方法顺序地训练弱学习器。其算法步骤如下：初始化各个样本点权重$w_i\ (i = 1,2, \dots, N)$，使各权重相等，并根据误差率e_m计算公式构造误差率最小的弱学习器$F_m(x)$：

$$e_m = \sum_{i=1}^{N} w_{mi} I(F_m(x) \neq y_i)$$

在得到误差率之后，调整弱学习器的权重，计算弱学习器$F_m(x)$的系数$\alpha_m = \frac{1}{2} ln\left(\frac{1-e_m}{e_m}\right)$，得到第$m$次迭代的强学习器$f_m(x)$：

$$f_m(x) = \sum_{i=0}^{m} a_i F_i(x)$$

进而，利用弱学习器的权重，更新原来样本点的权重。增大错误分类点的权重，减少正确分类点的权重：

$$w_{m+1,i} = \frac{w_{m,i}}{Z_m} \exp\left(-a_m y_i F_m(x_i)\right)$$

$w_{m+1,i}$是本次更新的样本点权重，$w_{m,i}$是上次的样本点权重，各样本权重之和为1。y_i是样本i的实际值，$F_m(x_i)$是弱学习器$F_m(x)$所预测的样本i的分类，Z_m是一个规范化因子，其公式如下：

$$z_m = \sum_{i=1}^{N} w_{mi} \exp\left(-a_m y_i F_m(x_i)\right)$$

最后，将上面的过程反复迭代，代直到误分类数达到阈值或达到最大迭代次数。M次迭代后得到最终强学习器：

$$sign[f_M(x)] = sign\left[\sum_{i=1}^{M} \alpha_i F_i(x)\right]$$

其中sign(x)是符号函数。同时，在上述过程中为防止 Adaboost 过拟合，可以向模型加入正则化项，即为每个弱学习器的权重缩减系数 v，也即学习率(Learning Rate)。

AdaBoost 充分考虑的每个分类器的权重，很好的利用了弱分类器进行级联，具有很高的精度。

模型 4——GBDT 算法

GBDT 算法是一种由多棵树组成加法模型的梯度提升决策树算法，GBDT 算法则将损失函数的负梯度作为残差的近似值，不断使用残差迭代和拟合回归树生成最终的强学习器。简单来说，AdaBoost 算法是调整权重，而 GBDT 算法则是拟合残差。其中残差计算公式为：

$$r_{mi} = y_i - f_{m-1}(x_i)$$

GBDT 算法每一次的残差计算都增大了分错样本的权重，而分对的权重都趋近于 0，因此泛化性能比较好。并且预测精度高，适合低维数据，可以灵活处理各种类型的数据。

模型 5——XGBoost 算法

XGBoost 回归模型已在上文详细阐述，其核心思想在于计算信息增益，来反映各特征变量减少信息不确定性的程度。它是经过优化的分布式梯度提升库，旨在高

效、灵活且可移植。作为 GBDT 算法的高效实现，XGBoost 算法在如下两个方面做了优化：

1) 算法本身的优化：XGBoost 算法的损失函数，除了本身的损失，还加上了正则化部分，可以防止过拟合，泛化能力更强。XGBoost 算法的损失函数是对误差部分采用二阶泰勒展开，相较于 GBDT 算法的损失函数只对误差部分做一阶泰勒展开，更加准确。
2) 算法运行效率的优化：对每个弱学习器，如决策树建立的过程做并行选择，找到合适的子树节点分裂特征和特征值，从而提升运行效率。

模型 6——LightGBM 算法

LightGBM 模型是一种根据直方图的离散值来遍历数据以寻找最优分割点的决策树算法。和 XGBoost 算法一样是对 GBDT 的高效实现，原理和 XGBoost 类似，都采用损失函数的负梯度作为当前决策树的残差近似值，去拟合新的决策树。

1) 基于 leaf-wise 的决策树生长策略

LightGBM 使用的 leaf-wise 策略，每次在当前叶子节点中，找出分裂增益最大的叶子节点进行分裂，而不是所有节点都进行分裂，以此提高精度。

2) 直方图算法

先对特征值进行装箱处理，把连续的浮点特征值离散化成 k 个整数，形成一个一个的箱体，同时构造一个宽度为 k 的直方图，在遍历数据的时候，根据离散化后的值作为索引在直方图中累积统计量，当遍历一次数据后，直方图累积了需要的统计量，然后根据直方图的离散值，遍历寻找最优的分割点。

3) 并行学习

LightGBM 支持特征并行和数据并行两种。传统的特征并行主要思想是在并行化决策树中寻找最佳切分点，在数据量大时难以加速，同时需要对切分结果进行通信整合。LightGBM 则是使用分散规约，它将直方图合并的任务分给不同的机器，并利用直方图做加速训练，降低通信和计算的开销。

模型 7——CatBoost 算法

CatBoost(Categorical Boosting)是基于完全对称的决策树且能够高效处理类别型特征变量的 GBDT 框架算法，具有较高的准确性和较优的泛化能力。

CatBoost 算法的工作原理是首先对所有样本进行随机排序，然后针对某个类别型特征，每个样本的该特征转为数值型时都是基于排在该样本之前的类别标签取均值，同时加入了优先级和优先级的权重系数，降低了类别特征中低频次特征带来的噪声，从而避免梯度估计的偏差，进而解决预测偏移的问题。其优先级的权重系数公式如下：

$$\frac{\sum_{j=1}^{p-1}\left[x_{\sigma_j}, k = x_{\sigma_p}\right] Y_{\sigma_j} + a \cdot P}{\sum_{j=1}^{p-1}[x_{\sigma_j}, k = x_{\sigma_p,} k] + a}$$

同时，在 CatBoost 算法中，还将浮点型特征、统计值以及 One Hot 编码进行特征二值化并放入向量中，然后在打分过程中利用二值化的特征计算模型的输出。

步骤二：模型评估

根据上文模型准备中所详细阐述的评测标准和调整决定系数R^2，本文对决策树模型、随机森林、AdaBoost 算法、GBDT 算法、XGBoost 算法、LightGBM 算法以及 CatBoost 算法进行评估，其结果如下表所示：

模型	决策树模型	随机森林	AdaBoost 算法	GBDT 算法
调整决定系数R^2	0.59135	0.69540	0.44358	0.94921
平均相对误差	0.47981	0.46154	1.78527	0.09320

5%误差准确率	0.09900	0.11167	0.05300	0.42033
评测标准	0.18324	0.19703	-0.11465	0.51763

模型	XGBoost 算法	LightGBM 算法	CatBoost 算法
调整决定系数R^2	0.95005	0.93953	0.94227
平均相对误差	0.08956	0.09324	0.08918
5%误差准确率	0.46533	0.45467	0.45183
评测标准	0.55435	0.54509	0.54363

易知，XGBoost 算法最优，其调整决定系数R^2达到了 0.95005，为 7 个模型最高，这意味着该模型拟合优度良好；平对相对误差为 8.956%，其评测标准为 0.554333，相对最为理想。除此之外，LightGBM 算法以及 CatBoost 算法稍逊于 XGBoost 算法，二者的调整决定系数R^2均在 0.94 左右，评测标准也在 0.38 上下。因此，本文暂时采用 XGBoost 算法、LightGBM 算法以及 CatBoost 算法为当前阶段的回归模型。

步骤三：模型调参——贝叶斯优化调参方法

网格优化是将一个参数空间内的所有点进行验证以返回最优损失函数的方法，然而该方法往往在计算量与计算时间上有着不可避免的缺陷，因此本文决定采用基于高斯过程建模的贝叶斯优化调参方法（BOA, Bayesian Optimization Algorithm），以争取效率和精准的双赢。

贝叶斯优化调参对给定优化的目标函数，在搜索的每次迭代中,从域空间为每个超参数选择一个样本点，利用机器学习模型计算该超参数组在验证集上的损失，并通过高斯过程不断地添加样本点来更新目标函数的后验分布,直到后验分布基本贴合于真实分布，使目标函数（每组超参数在验证集上的损失）最小。

当我们进行 GridSearch 网格搜索时,是从域空间形成的网格中为每个超参数随机选择样本点;而在贝叶斯优化中,是按照域空间超参数样本点的多元高斯概率分布进行选择，其使用了不断更新的贝叶斯概率模型,通过推断过去的结果来“集中”有希望的样本点。

对于一个 N 维向量 X，其多元高斯概率分布为：

$$p(x_1,\cdots,x_N)=\frac{1}{(2\pi)^{\frac{N}{2}}|\Sigma|^{\frac{1}{2}}}\cdot e^{-\frac{1}{2}[(\vec{X}-\vec{\mu})^{\mathrm{T}}\Sigma^{-1}(\vec{X}-\vec{\mu})]}$$

其中，μ为一个 N 维的均值向量，Σ为一个 N*N 维的协方差矩阵，|Σ|表示其行列式。进一步的，超参数θ的后验分布$p(\theta|X,Y)$为:

$$p(\theta|X,Y)=\frac{L(Y|X,\theta)p(\theta)}{\int L(Y|X,\theta)p(\theta)d\theta}$$

其中$L(Y,X|\theta)=\sum_{i=1}^{N}p(y_i,x_i|\theta)$是基于该超参数生成的机器学习模型中的似然函数，而当$p(y,x|\theta)$是高斯概率分布时，对数似然函数的闭式解存在。

经过贝叶斯调参进行优化，本文采用的三个数模型超参数取值如下：

1) XGBoost 算法超参数含义及其取值：

参数	意义	取值
learning_rate	弱分类器的权重缩减系数	0.05
max_depth	决策树的最大深度	12
n_estimators	弱学习器最大迭代次数	5000

2) LightGBM 算法超参数含义及其取值：

参数	意义	取值

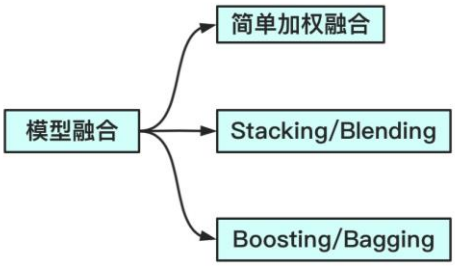
learning_rate	弱分类器的权重缩减系数	0.06
max_depth	决策树的最大深度	11
n_estimators	弱学习器最大迭代次数	5300
num_leaves	最大叶子数量	1000

3) CatBoost 算法超参数含义及其取值：

参数	意义	取值
iterations	决策树的最大树数	5000
learning_rate	弱分类器的权重缩减系数。	0.06
depth	决策树的深度	11
l2_leaf_reg	L2 正则数	3
loss_function	损失函数	MAE
eval_metric	用于过拟合检验和最佳模型选择的损失函数	MAE
random_seed	训练过程的随机种子	35

4.7 模型融合——Stacking 法

模型融合的主要思想是通过训练对多个模型进行组合以改善整体表现，在机器学习中被广泛使用。模型融合主要有以下几种方法：



本文将采用 Stacking 法对树模型进行融合，再利用加权融合法将其与神经网络模型进行融合。

4.7.1 Stacking 法

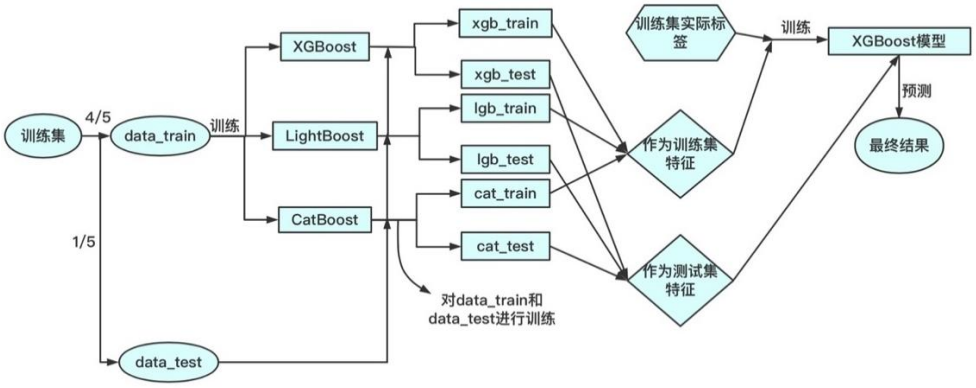
首先，本文采用堆叠法(Stacking)来对上述选择的 3 个树模型进行融合。Stacking 方法旨在减小模型的泛化误差，本质是“堆叠”的分层式结构，优势在于提高预测的准确性。本文运用两阶段 Stacking 方法，具体步骤如下图及下文所示：

第一层：

1) 本文以 4:1 的比例将前文保存的“估价训练数据整理_TreeModel.xlsx”训练集拆分为“data_train”和“data_test”，分别包含了 24000 条数据和 6000 条数据。
2) 利用 XGBoost 算法、LightGBM 算法以及 CatBoost 算法对“data_train”进行训练。
3) 用步骤 2 训练完成的 3 个模型对“估价训练数据整理_TreeModel.xlsx”训练集进行预测，其结果分别保存为“y_xgb”、“ y_lgb”以及“y_cat”。

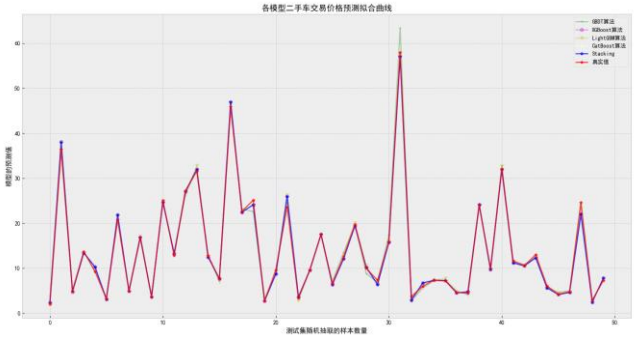
第二层：

1) 将第一层步骤 3 的三个预测结果数据集作为新的训练集特征，与“估价训练数据整理_TreeModel.xlsx”训练集的实际特征一起，选取第一层中单一模型评测标准较高的 XGBoost 算法作为元模型进行次级训练预测。
2) 用训练完成的 XGBoost 算法对“估价验证数据整理_TreeModel.xlsx”验证集进行预测，得到最终结果。



4.7.2 拟合后模型评估

本文作出 Stacking 后的模型及单一模型对随机抽取的 50 辆二手车交易真实价格预测结果的拟合曲线。



由图可知，Stacking 融合后模型的拟合曲线更贴切真实交易价格曲线，模型预测精度更高。在局部预测差异较大的区域，Stacking 融合后模型表现出的波动较小且预测效果更为稳定。在模型评价方面，下表展示了 Stacking 在四种指标下的模型预测效果：

	调整决定系数R^2	平均相对误差	5%误差准确率	评测标准
模型融合后评估	0.94987	0.08952	0.46500	0.55410

与上文单一模型对比，本文发现 Stacking 后的模型平均相对误差略微降低，且评测标准有所提高。

4.7.3 保存数据集

1） 利用 Stacking 融合后的模型对估价训练数据进行预测，将预测值保存为“估价训练数据指导价.xlsx”。

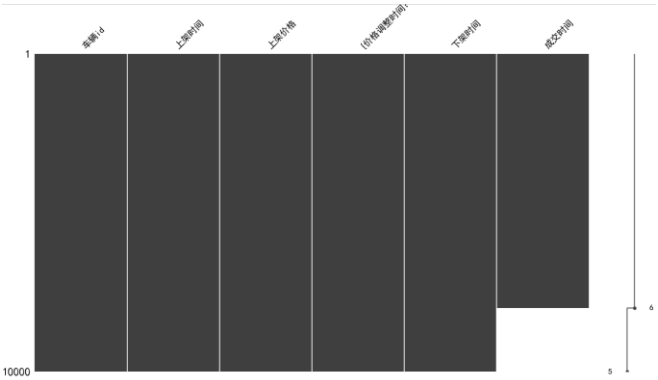
2） 利用 Stacking 融合后的模型对估价验证数据进行预测，将预测值保存至附件 3“估价模型结果.txt”中。

五．问题二 模型的建立与求解

5.1 特征工程

5.1.1 特征构造——是否成交

首先，本文绘制附件 4 数据集的缺失值数据密度图如下：



由图易知，仅“成交时间”这一字段缺失 2000 条数据。结合题干表格，成交车辆下架时间与成交时间相同，这意味着存在 2000 辆二手车未成交就已被下架。因此本文构造新特征变量“是否成交”，其中成交车辆填充为 1，未成交车辆填充为 0。

5.1.2 特征构造——价格调整时间 n、调整后价格 n、调价次数

易知特征“{价格调整时间：调整后价格}”中包含二手车的每一次调价时间和每一次调整价格。为利于后续对该变量所含信息进行深入分析挖掘，本文采用正则表达式，将每一次价格调整时间和每一次调整后价格分离处理，由于最多调整次数为 12 次，因此本文将它们分门别类地存储于 24 个新变量“价格调整时间 1～12”和“调整后价格 1～12”中，并计算价格调整的次数，保存在新字段“调价次数”中，其中未进行调价的时间、价格计作空值。

5.1.3 处理时间格式

检索数据集可知，“上架时间”、“下架时间”、“成交时间”、“价格调整时间 1～12”这 15 个字段均为 object 格式，为后续进一步开展时间特征的数据分析，本文利用 pandas 库中的方法 dt 对其进行高效操作，将上述 15 个字段转化为 datetime64 格式。

5.1.4 特征构造——平均降价幅度、最大降价幅度、最小降价幅度

本文根据价格调整时间 n、调整后价格 n 构造了上述 3 个特征，利用公式分别进行计算填充。

1） 平均降价幅度：

$$\begin{cases} 0, & \text{调价次数} = 0 \\ \dfrac{\text{上架价格} - \text{调整后价格}_1}{\text{上架价格}}, & \text{调整次数} = 1 \\ \dfrac{\dfrac{\text{上架价格} - \text{调整后价格}_1}{\text{上架价格}} + \sum_{i=1}^{n-1} \dfrac{\text{调整后价格}_i - \text{调整后价格}_{i+1}}{\text{调整后价格}_i}}{n}, & \text{调整次数} = n > 1 \end{cases}$$

2） 最大降价幅度：

$$\begin{cases} 0, & \text{调价次数} = 0 \\ \dfrac{\text{上架价格} - \text{调整后价格}_1}{\text{上架价格}}, & \text{调整次数} = 1 \\ \max\{\dfrac{\text{上架价格} - \text{调整后价格}_1}{\text{上架价格}}, \dfrac{\text{调整后价格}_i - \text{调整后价格}_{i+1}}{\text{调整后价格}_i}(i = 1, \cdots, n-1)\}, & \text{调整次数} = n > 1 \end{cases}$$

3） 最小降价幅度：

$$\begin{cases} 0, & \text{调价次数} = 0 \\ \dfrac{\text{上架价格} - \text{调整后价格}_1}{\text{上架价格}}, & \text{调整次数} = 1 \\ \min\{\dfrac{\text{上架价格} - \text{调整后价格}_1}{\text{上架价格}}, \dfrac{\text{调整后价格}_i - \text{调整后价格}_{i+1}}{\text{调整后价格}_i}(i = 1, \cdots, n-1)\}, & \text{调整次数} = n > 1 \end{cases}$$

5.1.5 特征构造——平均调价周期、最大调价周期、最小调价周期

除此之外，本文根据价格调整时间 n、调整后价格 n 构造了上述 3 个特征，利用公式分别进行计算填充。

1） 平均调价周期

$$\begin{cases} 0, & \text{调价次数} = 0 \\ \text{价格调整时间}_1 - \text{上架时间}, & \text{调整次数} = 1 \\ \dfrac{\text{价格调整时间}_1 - \text{上架时间} + \sum_{j=2}^{n-1} \text{价格调整时间}_j - \text{价格调整时间}_{j-1}}{n}, & \text{调整次数} = n > 1 \end{cases}$$

2） 最大调价周期

$$\begin{cases} 0, & \text{调价次数} = 0 \\ \text{价格调整时间}_1 - \text{上架时间}, & \text{调整次数} = 1 \\ \max\{\text{价格调整时间}_1 - \text{上架时间}，\text{价格调整时间}_j - \text{价格调整时间}_{j-1}; (j = 2, \cdots, n)\}, & \text{调整次数} = n > 1 \end{cases}$$

3） 最小调整周期

$$\begin{cases} 0, & \text{调价次数} = 0 \\ \text{价格调整时间}_1 - \text{上架时间}, & \text{调整次数} = 1 \\ min\{\text{价格调整时间}_1 - \text{上架时间}，\text{价格调整时间}_j - \text{价格调整时间}_{j-1}; (j = 2, \cdots, n)\}, & \text{调整次数} = n > 1 \end{cases}$$

5.1.6 特征构造——成交价格

以前文“是否成交”这一特征为依据，对完成成交的二手车构造新特征“成交价格”。该字段的填充方式为：

1） 若该二手车未进行调价，则以“上架价格”中的数据对“成交价格”进行填充。

2） 若该二手车参与调价，则以最后一次“调整后价格”对“成交价格”进行填充。

5.1.7 特征构造——成交周期、下架周期

以前文“是否成交”这一特征为依据，构建新特征如下：

1） 若二手车完成成交，则用“成交时间”减去“上架时间”构造特征“成交周期”。

2） 若二手车未完成成交，则用“下架时间”减去“上架时间”构造特征“下架周期”。

5.1.8 特征构造——最佳降价幅度

以前文“是否成交”这一特征为依据，构建新特征如下：

1） 若二手车完成成交，且进行过调价，则利用如下公式构造特征“最佳降价幅度”：

$$\frac{\text{上架价格} - \text{调整后价格}n}{\text{上架价格}}, n = 1, \cdots, 12$$

2） 若二手车完成成交，但未进行调价，则直接填充为 0。

3） 若二手车未完成成交，则为空值。

5.1.9 特征构造——最佳成交周期

以前文“是否成交”这一特征为依据，构建新特征如下：

1） 若二手车完成成交，且进行过调价，则利用如下公式构造特征“最佳成交周期”。

$$\text{成交时间} - \text{价格调整时间}n\ ,n = 1,\cdots,12$$

2） 若二手车完成成交，但未进行调价，则用“成交时间”减去“上架时间”构造特征“最佳成交周期”。

3） 若二手车未完成成交，则为空值。

5.1.10 删除冗杂特征——上架时间、{价格调整时间：调整后价格}、下架时间、成交时间

由于在上述步骤中已充分利用“上架时间”、“ {价格调整时间：调整后价格}”、“ 下架时间”、“ 成交时间”这 4 个特征，且计算构造了新的时间特征变量，因此为了避免信息的重复解释并对数据集降维，本文对这 4 个特征进行删除处理。

5.1.11 保存数据集

本文将经上述处理的数据集保存为“门店交易训练数据.xlsx”。由于篇幅有限，本文摘取前 5 行数据如下表所示：

车辆 id	上架价格	是否成交	调价次数	平均降价幅度	最大降价幅度	最小降价幅度	平均调价周期
68603	3.98	1	0	0	0	0	0
12312	4.5	1	0	0	0	0	0
57655	23.9	1	1	0.037657	0.037657	0.037657	23
45688	20.5798	1	0	0	0	0	0
52081	12.28	1	1	0.030945	0.030945	0.030945	21

车辆 id	最大调价周期	最小调价周期	成交价格	成交周期	下架周期	最佳降价幅度	最佳成交周期
68603	0	0	3.98	0	空值	0	0
12312	0	0	4.5	31	空值	0	31
57655	23	23	23	26	空值	0.037657	3
45688	0	0	20.5798	3	空值	0	3
52081	21	21	11.9	53	空值	0.030945	32

5.2 挖掘车辆成交周期的关键因素

5.2.1 数据集拼接

由题干可知，车辆本身的性能与价格是否公道是成交的关键性因素，因此本文将问题一中保存的数据集“估价训练数据整理_NN.xlsx”、“ 估价训练数据指导价.xlsx”与问题二特征工程中保存的“门店交易训练数据.xlsx”进行拼接，用于后文进一步探究二手车交易的成交周期。

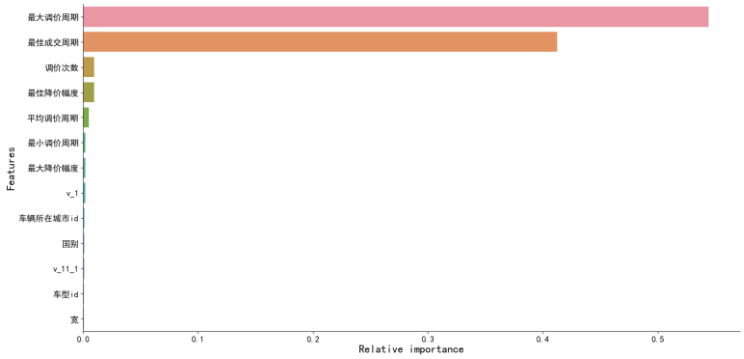
5.2.2 特征构造——指导价调价幅度

本文利用如下公式构造新特征“指导价调价幅度”：

$$\frac{\text{成交价格} - \text{指导价}}{\text{指导价}}$$

5.2.3 特征重要性排序——XGBoost 算法

本文利用上文已阐述的 XGBoost 算法对特征重要性进行排序，重要性前 13 位的特征如下：



根据上文特征构造的具体阐述，易知“成交周期=调价周期+最佳成交周期”，其中，成交周期代表从上架到最后一次调价所用时长，而最佳成交周期代表最后一次调价到成交所用时长，这意味着减短调价周期和最佳成交周期可能是减短成交周期的至关要素所在。据图分析如下

1） **最大调价周期**

最大调价周期对二手车成交周期的影响最为显著，其特征重要性分数为 54.433%。在二手车销售过程中，价格的调整往往是不可或缺的阶段。不可避免地，对于门店而言，更高的销售价格会带来更为可观的利润，但由于消费者通常对二手车购买预备有目标预算或可接受的价格区间，因此门店相应地按照消费者心理预期作出价格调整是难以避免的销售行为。对此，门店销售逐步调整价格，在以成交为最终目的的同时期待更高利润，但倘若能够压缩每一次调价的周期，即可在保证上述要求的同时减短最大调价周期，从而达到减短成交周期的目的。

2） **最优调价周期**

最佳成交周期间不再对价格进行调整，意味着该时间段内二手车价格已符合消费者的心理预期水平。由于门店销售的谈判技巧并非成交的根本因素，因此本文认为最佳成交价格与车辆本身的性能相关，这也是消费者在此期间内尚在考量犹豫的原因所在。

由图，最佳成交周期的特征重要性分数较高，为 41.239%，这意味着最佳成交周期是影响二手车成交的关键性因素。结合上段分析，本文认为最佳成交周期时长背后的根本因素在于二手车性能的好坏，这可以引申为二手车车况对推动其是否迅速成交具有强烈影响。比如，以同等零售价格为前提，二手车本身为普适度强且各功能状况良好的实用性车型，其受众程度更广，且消费者对其最终考量犹豫的时长可能会远远短于相比之下具有特殊分工或车况稍次的二手车。

3） **调价次数和最佳降价幅度**

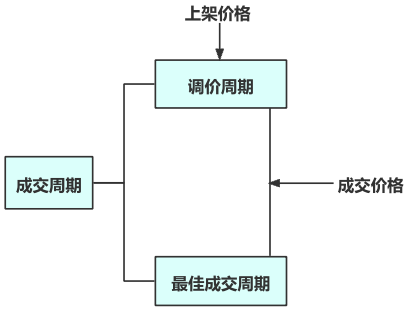
由图可知，调价次数和最佳降价幅度对成交周期具有一定的影响。其二者之间存在一定联系：降价幅度越大，则需要更少的调价次数，即可到达消费者心理预期的价格区间；相应地，调价次数越多，则无须大幅度降价，便可以达到消费者的预期价格。因此，最佳降价幅度增大或调价次数增多，二手车的成交周期都得到压缩。

4） **二手车性能**

由图可以判断，二手车性能对成交周期的影响微乎其微。本文认为，二手车性能直接影响的是二手车销售价格，仅通过前文所提到的最佳调价周期而对成交周期产生间接影响。

5.3 寻求加快在库车辆销售速度的有效手段

5.3.1 模型构建



为了加快门店二手车的销售速度、压缩成交周期，本文进行了以下思考：

1） 针对上架价格

根据问题一中 Stacking 后的模型预测出适宜的成交价格(指导价)，由于问题一中的模型搭建已经考虑到车辆性能、车况、受众环境等多方面因素，故而该指导价与消费者所预期的价格直接挂钩。门店定价师对消费者心理作出一定了解，对二手车适宜的成交价格有所预判后，可以参照指导价对初始上架价格进行设定。在指导价上浮 3%-7%左右设定上架价格，既可在接近消费者心理价位预期的情况下保证超额收益，也可根据短期内是否成交进行后续的调价行为。

2） 针对调价周期

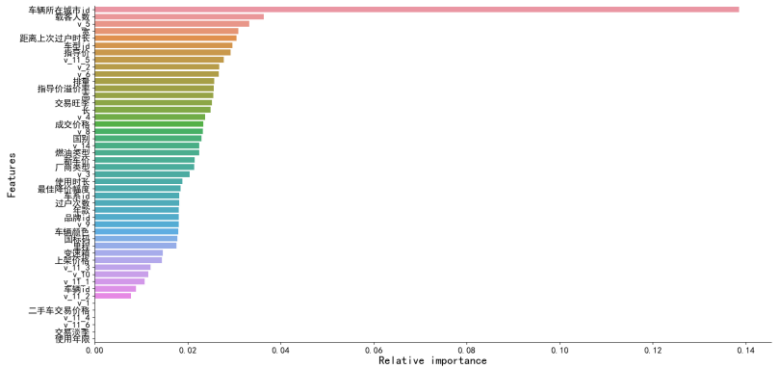
在上架价格无法满足消费者预期时，门店定价师可以通过调价的手段来刺激消费者购买。由 6.2.3 分析出的关键影响因素可知，尽可能地缩短每次调价之间调价周期、增大每次调价的降价幅度，能够使价格在相对较短的时间内达到消费者可接受的价格区间(指导价附近)，以减少从上架到最后一次调价所需要的全部时长(调价周期)，最终达到压缩总的成交周期的目的。

3） 针对最佳成交周期

由 6.2.3 已知最佳成交周期会直接影响到总的成交周期，而如何缩减最佳成交周期，亦是门店定价师需要采取的手段的重中之重，本文将在后续进一步探究缩减最佳成交周期的使用条件和有效手段。

5.3.2 最佳成交周期的特征重要性排序——XGBoost 算法

本文利用 XGBoost 算法对最佳成交周期的特征重要性进行排序如下：

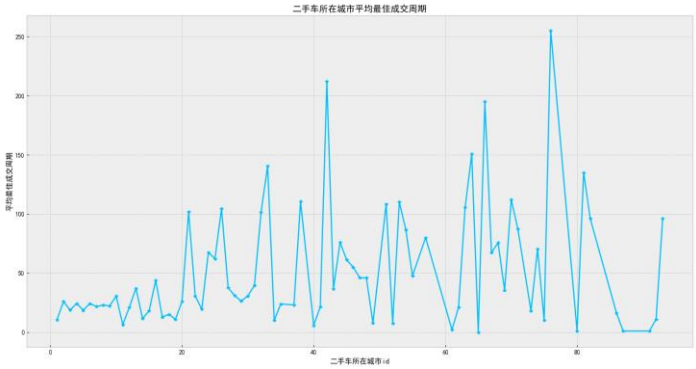


如图，“车辆所在城市 id”、“载客人数”、“匿名变量 5”以及“宽”为最佳成交周期的几个主要影响因素，其特征重要性分数如下表所示：

特征变量	重要性分数
车辆所在城市 id	13.855%
载客人数	3.638%
匿名变量 5	3.321%
宽	3.090%

本文将对二手车车辆所在城市、载客人数、长宽高、指导价溢价率这 6 个特征进行逐一讨论，探究如何利用这些特征采取行之有效的手段以缩减二手车的最佳成交周期。

5.3.3 根据车辆所在城市探究改善最佳成交周期的手段

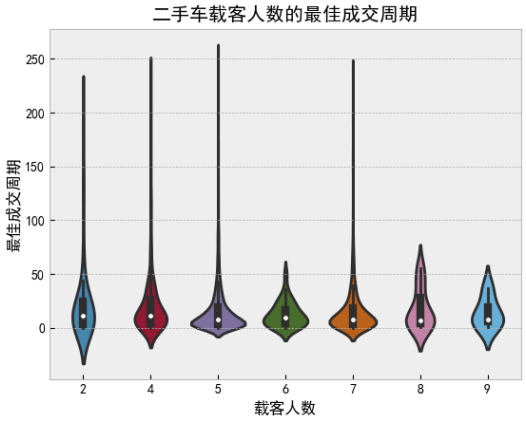


通过计算不同城市的平均车辆最佳成交周期并绘制折线图，发现不同城市的平均最佳成交周期从 10 天到 260 天不等。这可能是因为不同城市之间经济发展水平存在差异，二手车价格相较于收入的比例为人们带来不尽相同的考量；同时，不同地区人均消费水平及消费观念也有所不同，中小城市消费者相对传统的消费行风习惯于用积蓄购买车辆，而大城市消费者乐观的超前消费理念不会考虑过多的因素，达到心理预期价位即可成交；最为重要的是，相较于二三线城市，二手车在一线乃至超一线城市的受众面更广，二手车门店客流量更大，更多的顾客带来更多交易的可能性，故而导致其最佳成交周期更短。

采取手段：

根据第一问由车辆本身性能及车况预测出的指导价，同样的车辆，已降价至指导价附近时，针对大城市，应该给与其消费者更小的时间选择范围，即之后的待成交时间接近该城市平均最佳成交周期时，便可考虑再进行降价微调，因为大城市二手车门店客流量大，在接近平均最佳成交周期的时长内仍未被购买，表明此价格仍未达到消费者心理预期，故可提前降价；而面向中小城市，由于本身受众面较窄、门店客流量较少，故可适当放宽消费者的时间选择范围，例如可以以比该城市平均最佳成交周期更长的时间去等待合适的交易的发生，无需做额外的调价，从而既缩减了最佳成交周期，也保证了二手车交易平台的权益。

5.3.4 根据车辆载客人数探究改善最佳成交周期的手段



通过计算不同载客人数的车辆的最佳成交周期并绘制小提琴图，发现不同载客人数对车辆最佳成交周期存在较大影响，其中载客人数为 5，6，7 人的车辆最佳成交周期分布相对集中，且最佳成交周期的 95%置信区间较小，而其它载客人数的车辆最佳成交周期相对分散，且最佳成交周期的 95%置信区间较大。这可能是由于不同车辆的

受众存在大小差异导致，目前市场上主流的私家车一般都是 5 座的轿车，6，7 座的 SUV 为主，受众较广。而 2 座，3 座的汽车以价格较高的跑车为主，8 座，9 座的车以面包车为主，受众较小，所以最佳成交周期分布更分散，平均最佳成交周期相对更长。

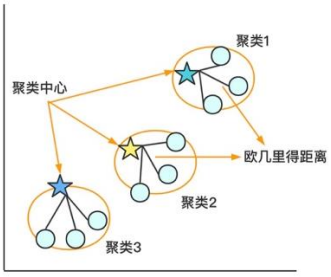
采取手段：

根据第一问由车辆本身性能及车况预测出的指导价，同样的车辆，已降价至指导价附近时，针对载客人数为 5，6，7 人的车辆，由于其受众广，门店定价师在其之后的待成交时间接近平均最佳成交周期时，便可考虑再进行降价微调，因为该类别二手车需求旺盛，在接近平均最佳成交周期的时长内仍未被购买，表明此价格仍未达到消费者心理预期，故可提前降价；针对载客人数为 2，3，8，9 人的车辆，由于其受众较小，门店定价师在其之后的待成交时间超过该载客人数车辆最佳成交周期的 95%置信区间后再降价微调，充分等待潜在客户的挑选。

5.3.5 基于 K-Means 聚类探究改善二手车最佳成交周期的手段

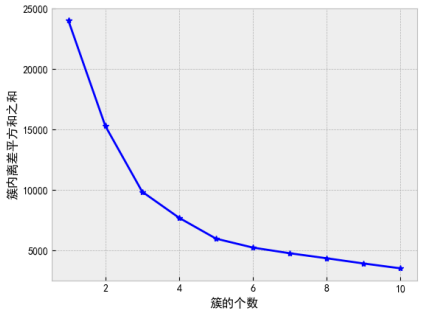
由特征重要性分数可知二手车的长宽高对最佳成交周期亦存在较大影响。

K-Means 算法是一种将数据划分到相应集群的聚类算法，具有高效处理大体量数据的优点，且聚类效果较好。K-Means 算法的基本思想是:先给定一个参数 K，随机选取 K 个质点作为聚类初始质点，计算各个质点到聚类中心的欧几里得距离，并将其分别分配到距离最近的聚类中心所在簇中;然后重新计算各个簇的中心，并再对所有质点进行分配;重复以上步骤，直至相邻两次迭代中聚类中心不再变化或聚类准则函数收敛，而上述往往采用误差平方和作为准则函数。



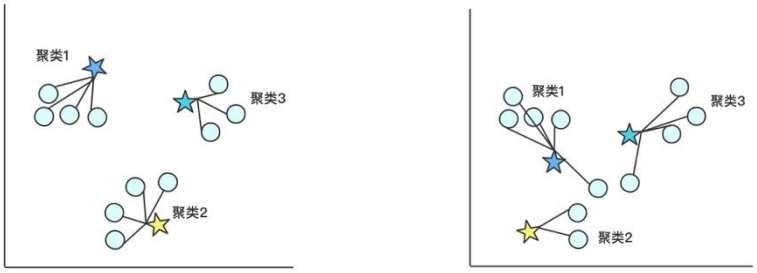
其基本步骤如下：

1) 由于本文所涉及数据集需要对二手车最佳成交周期进行分类，因此我组根据 SSE 簇内离差平方和拐点法，选择折线坡度骤减的点作为最优 K，如下图 K 为 3 时最优，确定将数据集划分为 3 类，并选取 3 个初始聚类中心为 (C_1, C_2, C_3)；



2) 计算样本x_i $(1 \le i \le 8000)$到初始聚类中心的欧几里得距离，并根据最小距离原则确定每个样本的聚类中心C_j $(1 \le j \le 3)$，将分别分配到相应的簇中；

3） 重新计算各簇的聚类中心，并重新分配各样本，取第一、二次分配绘图如下：

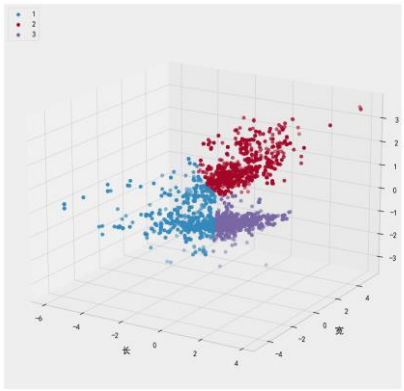


4） 重复上述步骤，迭代计算聚类中心并分配样本，直至聚类中心稳定不变或满足聚类准则函数收敛。其中，聚类准则函数的收敛情况通常以各样本到聚类中心的距离平方和是否最小来进行判断，其公式如下：

$$Var = \sum_{i=1}^{n} [min_{j=1,\cdots k} d(x_i, z_j)^2]$$

其中，若Var值收敛，则终止算法，完成聚类。

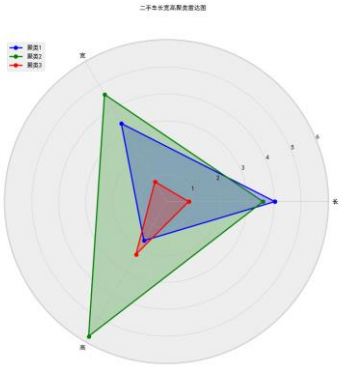
本文将可视化结果绘制成三维着色散点图如下：



该可视化结果以二手车的“长”为 X 轴，“宽”为 Y 轴，“高”为 Z 轴，通过不同的颜色将车辆分为了 3 类，其分别包含的样本数及聚类中心点如下表所示：

类别	所含样本数目	聚类中心点坐标
1	3487	(0.51476, 0.17706, -0.66106)
2	2258	(-1.08819, -1.07229, -0.36899)
3	2255	(0.29364, 0.79992, 1.39170)

此外，本文绘制了依据长宽高这三个显著性特征的聚类雷达图如下：



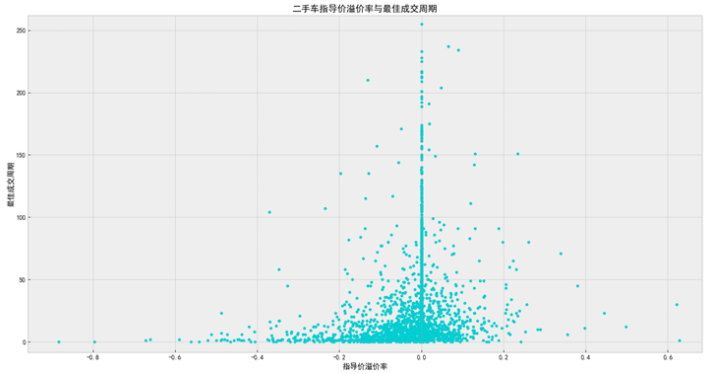
结合散点图、雷达图及表格，并比对数据集可知：

1) 聚类 1 包含样本数目最多，且该类型车辆长宽高趋于中等一致，本文认为聚类 1 可能是受众面较广的轿车。经检索数据集进行比对可知，该类别车辆平均最佳成交周期相对于后两种更短，表明该类别车辆市场需求量大。
2) 聚类 2 明显更趋向于高和宽有明显优势的车型，本文查阅专业文献得出聚类 2 可能是运动型多功能车(SUV)或多用途商务车(MPV，多为两厢式，不追求车长)，该聚类的车辆在涵盖聚类 1 轿车的城市功能基础上，又具有一定的特殊功能，如越野功能、旅行乘务功能或载物功能，但可能由于车型、价格等多方面考量，其与聚类 1 轿车相比，平均最佳成交周期较长，表明市场和需求都有所下降。
3) 聚类 3 明显缩减了车辆的整体空间，本文查阅专业文献得出聚类 3 可能属于跑车或 MINI 类型的单厢车。该类型的车意在追求车身的小巧，但往往仅适用于个人或两人小家庭，且不具备载货或商务功能，故而市场需求不大，因此该类别车辆的平均最佳成交周期较大。

采取手段：

根据第一问由车辆本身性能及车况预测出的指导价，同样的车辆，已降价至指导价附近时，针对聚类 1 车型的二手车，由于其为大众所普遍接受，门店定价师在其之后的待成交时间接近该聚类平均最佳成交周期时，便可考虑再进行降价微调，因为该类别二手车需求旺盛，在接近平均最佳成交周期的时长内仍未被购买，表明此价格仍未达到消费者心理预期，故可提前降价；对于聚类 2 车型的二手车，市场对于其接受程度适中，门店定价师可在其之后的待成交时间等于该聚类平均最佳成交周期时准时调价；而对于聚类 3 车型的二手车，受众面往往较窄，故而可延长时间再进行调价，充分等待合适的顾客进行挑选。

5.3.6 通过二手车指导价溢价率探究改善最佳成交周期的手段



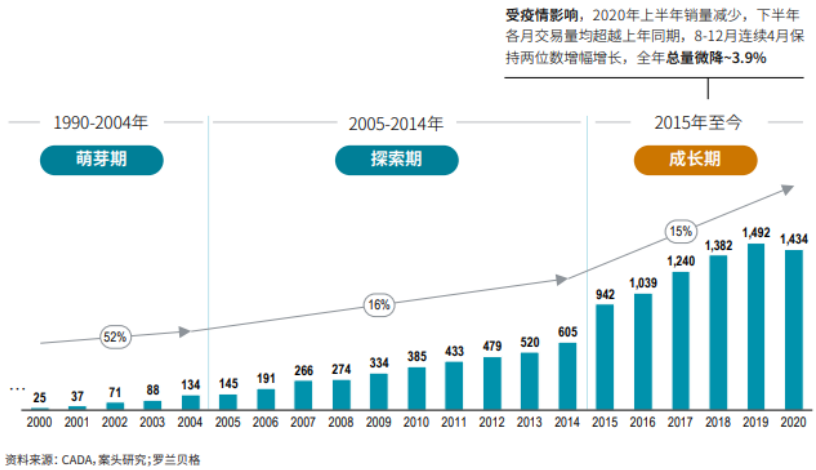
通过分析二手车实际成交价格与第一问预测出的成交价格(指导价)的溢价率，可以很明显的发现，当指导价溢价率为负值时(即以比预测的价格低估卖出)，98.3%的二手车最佳成交周期均小于 30 天，达到了很好的流通效果；而当指导价溢价率为正时，消费者受众的接受意愿相比之前明显下降，尤其是当溢价率超过 10%时，有接近 50%的二手车最佳成交周期超过了 30 天，表明在实际成交价格相对于指导价溢价过多时，消费者虽有购买需求但是其购买意愿并不会那么强，因此导致流通效果变差。

采取手段：

对于探究如何利用指导价溢价率来加快最佳成交周期的手段，门店定价师可结合上述分析的多方位重要因素进行考量。相较受众面较窄的二三线城市，一线乃至超一线城市针对普适型号的二手车可以考虑最终的定价相对于指导价溢价率较高一些；而二三线城市针对受众面较小的商务车、跑车等，可使最终的定价略低于指导价，以次加快门店在库二手车的销售速度。

六．问题三 模型的建立与求解

我国二手车发展历经萌芽期、探索期和成长期三个阶段。随着互联网玩家的快速扩张，以及国家支持性政策法规密集出台，我国二手车交易规模快速上升，行业整合淘汰加速。在过去几年中，中国二手车市场保持着快速增长的态势，2019 年突破交易量 1,492 万台。然而，与成熟市场相比，中国二手车市场仍处于早期发展阶段，整体市场二手车占新车的比率较低。



在供应端和消费端共同利好的影响下，未来二手车市场存在较大的发展潜力。因此，实现可持续性发展便显得尤为重要，本文从提高利润率，扩宽客户受众，拓展业务广度，增添附加值业务四个方面入手，研究如何实现可持续性发展。

6.1 提高利润率

由于 020 门店模式为线下实体门店对外展销和售卖，导致每个线下门店能展销的车辆有限，因此针对不同城市消费水平，客户偏好等差异进行展销尤为必要，可以通过分析历史销售数据，结合问题二中分析得出不同城市对不同类型二手车的最佳成交周期会有所不同，进一步得到不同城市对于不同类型汽车的需求量，从而可以在不同城市之间进行二手车的流通，保证二手车的销售效率，达到利润率最大化。

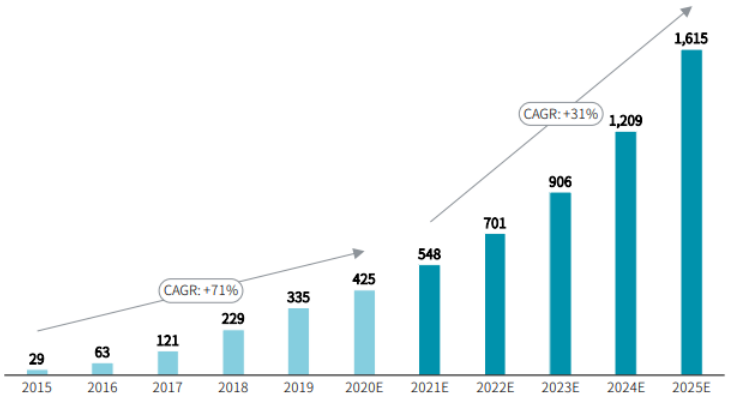
6.2 扩宽客户受众

传统经销商利用自身品牌效应获客，电商平台多利用互联网流量平台。二手车是低频消费，要想稳定客源就需要不断的吸引新客户。目前二手车市场竞争激烈，新车的价格波动也会冲击二手车市场的交易价格，容易造成客户流失，无论是线下传统交易还是二手车电商交易，均需要较高的获客成本。传统的大型经销商集团具有品牌效应，可以通过口碑营销等方式取得低获客成本的引流效果，二手车电商平台通过与互联网巨头的战略合作也有助于其引流。如优信通过与零售巨头淘宝在供应链、交易过程、金融服务以及售后物流等全方位的合作，有助于优信从超级流量平台获取流量资源优势。而中小二手车商既没有品牌效应，也难以接入流量平台引流，获客成本相对较高。由题意可知典型的二手车零售场景一般通过互联网等线上渠道获取用户线索，线下实体门店对外展销和售卖，因此可以通过与主流互联网运营商进行合作，寻找潜

在目标客户，并绘制用户画像，对潜在客户进行精准的二手车辆信息广告投放，从而扩宽客户受众的广度。

6.3 拓宽业务广度

目前汽车市场从增量市场转换为存量市场，因此二手车市场是逐年递增的，如下图所示，新能源汽车的市场占有率逐年提高，新能源车保有量的快速攀升将有效带动新能源二手车产业的蓬勃发展，也为二手车产业链带来全新的挑战。可以见得未来二手新能源汽车市场会不断增长。因此可以针对二手新能源汽车市场提供针对性业务模式，例如新能源汽车车电分离后二手电池产业，包括二手电池残值定价、二手电池交易，三电系统检测与整备修复，以及回收电池的梯次利用等等；以及二手新能源充电桩产业，包括新能源车置换过程中私桩充电桩的交易与回收等等。



资料来源:IEA;罗兰贝格

6.4 增添附加值业务，增厚利润空间

对二手车进行检测认证：与经销商通过以旧换新的收车价格相比，认证二手车的价格可以上升约 40%，远高于未得到认证车辆的价格。二手车认证不仅对二手车相关手续、车型和年款、以及对真实车况的认证，还会通过各交易市场的实际历史成交价格直接给出客观的建议交易价格，保障了消费者的合理权益。

对二手车进行翻新：二手车整备和翻新通常需要经过比较复杂的工序，其中涉及了更换零部件、清洗发动机舱、更换轮胎以及车身抛光等一系列工序。二手车商可以利用翻新工作提高自身对于二手车的定价，同时利用其规模和技术经验优势降低成本，带来较大的利润空间。

增加质保项目：随着二手车拍卖等新型交易的出现，抢占了二手车车源的部分市场份额，导致二手车价格被抬高。二手车商向消费者提供的质量保障方案进一步增强消费者的信心。

为消费者提供保险：为消费者提供保险销售和咨询服务、赚取代理佣金，可成为二手车商重要的盈利点。经销商需要根据用户需求变化趋势和不同用户的需求差异性，调整车险品种推荐方式，从而增加车险服务成交率。通过服务打包、会员制等多种创

新方式，经销商不仅可以完成保险销售，而且带动其他增值服务的开展，长期锁定用户进店消费。

七．参考文献

[1]姚登举, 杨静, 詹晓娟. 基于随机森林的特征选择算法[J]. 吉林大学学报：工学版, 2014(1):5.
[2]胡仁涛. 基于贝叶斯优化调参的双频带天线设计[A]. 中国电子学会.2020 年全国微波毫米波会议论文集（下册）[C].中国电子学会:中国电子学会微波分会,2020:3.DOI:10.26914/c.cnkihy.2020.054779.
[3]彭星光, 高晓光, 魏小丰. 基于贝叶斯优化算法的 UCAV 编队对联合目标的协同攻击研究[J]. 系统仿真学报, 2008, 20(10):4.
[4]赵梦想, 胡敏. 基于 Stacking 融合的电商平台二手车定价研究[J]. 信息与电脑, 2021, 33(19):4.
[5] Chen T, Tong H, Benesty M. xgboost: Extreme Gradient Boosting[J]. 2016.
[6] Zheng H, Yuan J, Chen L. Short-Term Load Forecasting Using EMD-LSTM Neural Networks with a Xgboost Algorithm for Feature Importance Evaluation[J]. Energies, 2017, 10(8):1168.
[7] Wang D, Yang Z, Yi Z. LightGBM: An Effective miRNA Classification Method in Breast Cancer Patients[C]// the 2017 International Conference. 2017.
[8]方匡南, 吴见彬, 朱建平,等. 随机森林方法研究综述[J]. 统计与信息论坛, 2011, 26(3):7.
[8]李欣海. 随机森林模型在分类与回归分析中的应用[J]. 应用昆虫学报, 2013, 50(4):8.
[9]曹正凤. 随机森林算法优化研究[D]. 首都经济贸易大学.
[10]刘波, 秦川, 鞠平,等. 基于 XGBoost 与 Stacking 模型融合的短期母线负荷预测[J]. 电力自动化设备, 2020, 40(3):7.
[11]王星. 一种 stacking 模型融合方法:, CN112163620A[P]. 2021.
[12]于玲, 吴铁军. 集成学习:Boosting 算法综述[J]. 模式识别与人工智能, 2004, 17(1):8.
[13] Jabeur S B, Gharib C, Mefteh-Wali S, et al. CatBoost model and artificial intelligence techniques for corporate failure prediction[J]. Technological Forecasting and Social Change, 2021, 166(8):120658.
[14]黄冠翎. CatBoost 算法在乳腺肿瘤诊断研究中的应用[D]. 上海师范大学, 2019.