队伍编号	MCB2102542
赛道	（B）

信息流智能推荐算法中序列收益评估模型的构建与研究

摘 要

目前互联网信息蓬勃发展，用户面临信息过载，而推荐算法不仅满足用户个性化内容消费需求，而且提升了用户获取有用信息的效率。本文通过建立推荐序列总点击量和总时长收益评估模型，为推荐序列提供预测服务，从而达到更好地进行信息序列的推送和进行信息流整体收益评估。

针对问题一：基于训练集数据，**建立评估推荐序列总点击和总时长收益数学模型**，并进行**优化网格矩阵**计算，得出**不同排列组合的收益值**并计算**时间收益系数**。同时统计分析不同时段的点击量，计算不同时段对收益值的影响。

针对问题二：基于问题一模型，建立各用户的**优先网格矩阵并**获取相关数据，建立**隐语义预测模型**，获得**隐分类用户矩阵**和**隐分类物品矩阵**，得到未浏览得点击量和浏览时长，考虑时间、排序等因素，**预测**请求 ID 对应**推荐序列的点击量和时长**之和，并填入附件 result.csv 中，**预测精准度达到 93%**左右。

针对问题三：根据题目设计如下**剪枝策略**。统计分析每个请求 ID 的训练内容获得序列的最优长度；基于问题一的模型，建立每个 ID 的**优先网格矩阵，曲线拟合**获得不同内容排序带来的收益；通过每条内容的收益值设计每种分类内容的选择概率，再通过**轮盘赌**的方式选择推荐序列。经过检验证明**最优序列精准度达到 90%**左右。

综上所述，本文依据各题所给的条件较全面地分析并解决了信息流智能推荐算法中序列收益评估建模问题。经过分析验证，本文建立的模型合理有效，简便易行，便于推广到日后其他序列收益评估的建模中去，有一定的现实意义。

关键词：推荐算法 推荐序列 优化网格矩阵 隐语义预测模型 曲线拟合 剪枝策略 轮盘赌

目录

1.问题重述 1
1.1. 问题背景 1
1.2. 问题提出 1
1.3. 问题求解流程图 1
2.问题分析 2
2.1. 问题一的分析 2
2.2. 问题二的分析 2
2.3. 问题三的分析 3
3.符号说明 3
4.基本假设 3
5.数据处理 4
6.问题一：推荐序列总点击和总时长收益评估模型 4
6.1. 问题一的建模流程 4
6.2. 模型的建立及求解 5
7.问题二：预测推荐序列的总点击量和总时长 8
7.1. 考虑序列顺序的隐语义模型概述 8
7.1.1 基于用户的协同过滤算法 9
7.2.1 基于物品的协同过滤算法 10
7.3.1 隐语义模型 11
7.2. 考虑序列顺序的隐语义预测模型 13
7.3. 误差分析和结果写入 13
8.问题三：剪枝策略下精确评估最优序列收益 14
8.1. 问题三的建模流程 14
8.2. 模型的建立及求解 15
8.3. 剪枝策略复杂度分析 15
8.4. 剪枝策略的精准度检验 16
9.总结和展望 17
参考文献 18
附录 19

1. 问题重述

1.1. 问题背景

21 世纪是我们所生活的年代，是世界经济发展的时代，是科学力量加强的时代，也是一个信息化的时代，因此生活在这样的一个时代中，用户在使用互联网应用时时常面临着信息过载的问题。推荐算法的出现，满足了用户个性化的内容消费需求，提升了用户获取有用信息的效率，在互联网 APP 里已被广泛应用。

1.2. 问题提出

信息流作为推荐算法的主要应用场景，是用户触及互联网信息的主要入口，已经完全融入了人们的日常生活中，成为了人们了解世界的主要方式。传统推荐算法的核心思想是挖掘被推荐内容与用户兴趣的匹配关系，以及内容本身的优质程度，选择与用户最相关或者最优秀的内容推荐给用户。

但是，经过专家学者研究发现，除了内容本身因素以外，内容之间的排列组合关系，也会影响用户的浏览体验，进而影响推荐收益的大小。例如，相似内容的高度集中，往往会带来较差的结果反馈，即使它们都高度匹配用户兴趣或者具有较高的内容质量。于是，越来越多的研究集中在如何选择最优的内容排列组合上，而不仅仅是最优的内容上。因此本题目要求设计数学模型对给定的候选序列进行序列整体收益的评估。

根据题目提供附件中的训练集 train_data.txt、内容的基础属性 doc_info.txt、测试集 test_data.txt 以及数据格式示例和包括的涉及字段，进行信息流智能推荐算法中的序列评估问题的解决。这需要我们解决如下问题：

问题 1：建立评估推荐序列总点击收益和总时长收益的数学模型，以及如何根据点击收益和时长收益对综合收益进行量化。在序列评估模型设计中，需要详细阐述如何考虑不同排列组合对收益大小的影响。

问题 2：结合问题 1 设计的数学模型，预测测试集中推荐序列的总点击量和总时长（单位为秒），将预测结果写入 result.csv 并提交。

问题 3：假设有 N 条候选内容，从中选择长度为 K（N≥K）的最优推荐序列，需要参与收益评估的序列量为A_N^K。在真实推荐场景中，由于计算性能的考虑，系统无法对所有可能序列进行收益评估，往往需要先采用计算复杂度更低的方式对序列集合进行剪枝，圈定出少量候选序列进行精确收益评估。而剪枝策略的目标是保证候选序列集更大可能包含最优序列。请详细阐述你的建模思路，以及剪枝策略的精准度和时间复杂度。

1.3. 问题求解流程图

综合分析上述四个问题，我们的建模目标是根据提供的近一周时间内用户在信息流产品上的曝光历史、内容的基础属性以及在训练集时间之后的一部分用户推荐序列等信息，构建评估推荐序列总点击收益和总时长收益的数学模型，从而为更好的进行信息的推荐并达到收益最大化提供预测服务。基于此，给出本题的解题流程图如下所示：

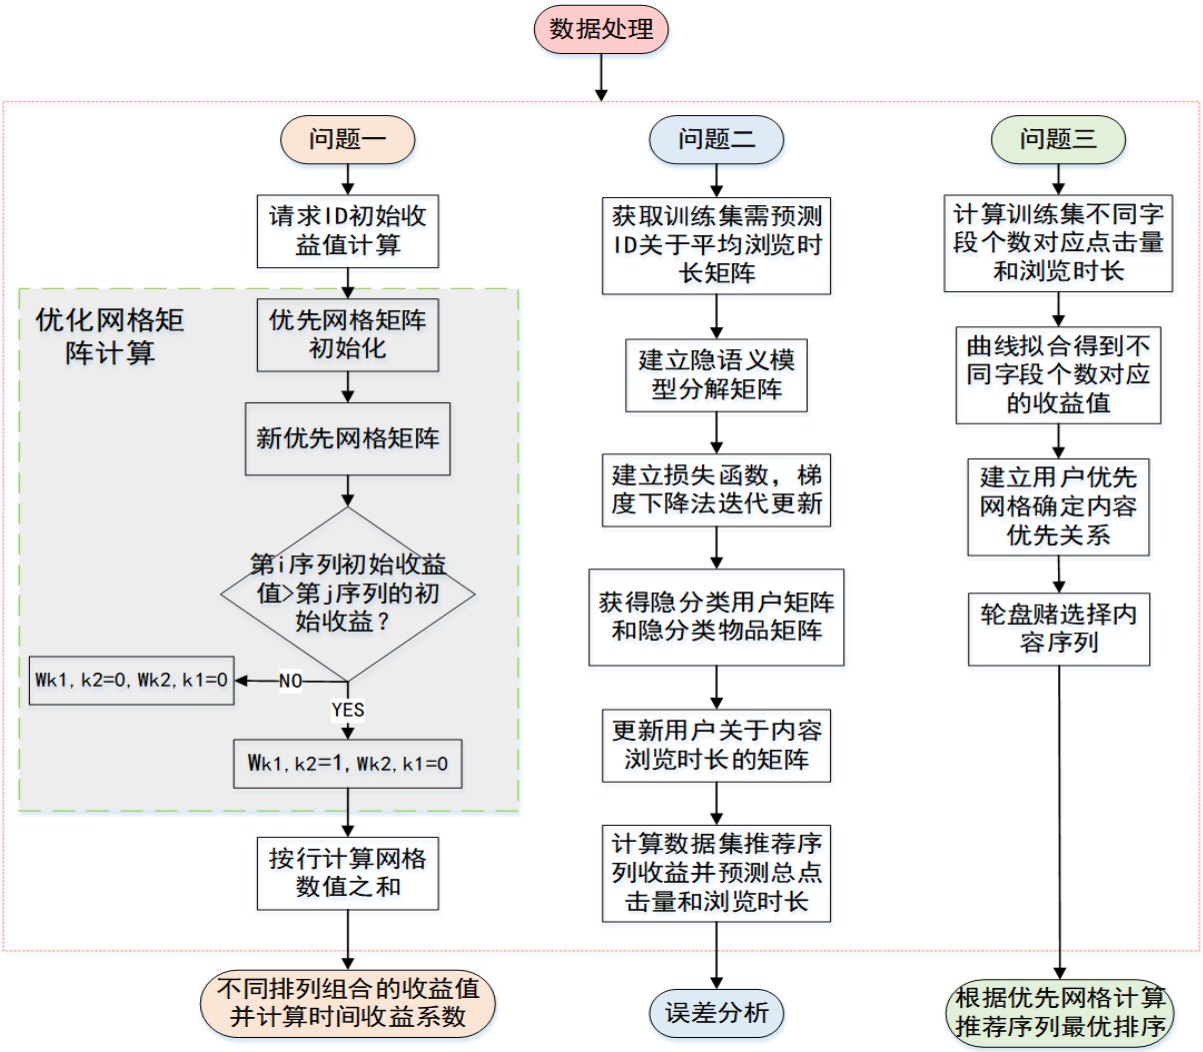


图 1：解题流程图

2. 问题分析

2.1. 问题一的分析

问题一要求建立评估推荐序列总点击收益（序列中单条内容的点击量之和）和总时长收益（序列中单条内容的浏览时长之和）的数学模型，以及如何根据点击收益和时长收益对综合收益进行量化，同时还需要考虑不同排列组合对收益大小的影响。

训练数据中可以得到每个 ID 的每一条推荐序列的点击量和浏览时长，在不考虑排列组合的情况下，每一条序列的初始收益值也是已知的。要确定不同排列组合对收益值的影响，可以考虑根据点击量和浏览时长产生的初始收益值更新推荐内容的排序，确定在已有的序列中，用户对那些推荐内容更加喜欢或者是更加喜欢这个推荐内容放在哪个位置，最终就可以得到不同排序对收益影响的大小。

同时训练数据中也给各个 ID 的推荐序列标准了时间，需要对不同时段的点击量进行统计分析，计算在不同时间对收益值的影响。

2.2. 问题二的分析

问题二要求基于问题一设计的数学模型，预测测试集（test_data.txt）中推荐序列的总点击量和总时长（单位为秒）。题目中训练数据的推荐内容包含了一级分类和二级分类内容，为了提高模型的

准确性，采用二级分类作为对各个内容分类的标签。

首先，按照问题一中的数学模型，建立各个用户的优先网格矩阵，获得各个用户对应的不同推荐内容各自的收益值；其次，根据训练数据获得各个用户每一个推荐内容的平均点击量和平均浏览时长；再者，建立隐语义模型，获得没有浏览记录的点击量和浏览时长；最后，考虑时间、排序等因素，预测每个请求 ID 对应推荐序列的点击量和时长之和，并填入附件 result.csv 中。

2.3. 问题三的分析

问题三中要求设计剪枝策略，目标是在 N 条候选内容中选择长度为 K（N≥K）的推荐序列，同时还需保证候选序列集更大可能包含最优序列，除此以外还需要分析模型的精准度和时间复杂度。若使用穷举法对每一条序列是收益进行评估，精准度会提升，但无疑增加了模型的计算量。因此需要设计一种剪枝策略，在保证精准度的同时，还要减少模型的计算量。

因此，首先需要对每个请求 ID 的训练内容进行统计分析，获得序列的最优长度；其次，根据问题一的模型，建立每个 ID 的优先网格矩阵，获得不同内容排序带来的收益；最后，通过每条内容的收益值设计每种分类内容的选择概率，再通过轮盘赌的方式选择推荐序列。同时，分析模型的时间复杂度，并检验模型的有效性。

3. 符号说明

下表列出了一部分符号和简称并给予了说明，文中出现的其它符号或简称会在出现的相应位置给予解释。

表 1：符号/简称说明

符号/简称	符号说明
CT^{I}	（content type）内容类别一级分类
CT^{II}	内容类别二级分类
N^{I}	一级分类个数
N^{II}	二级分类个数
ID_{ct}	内容 ID
ID_{us}	用户 ID
ID_{ps}	请求 ID
W	优先网格
E_0	只考虑点击次数和观看时长的收益
E_1	考虑推荐序列排序的收益
CN	点击数量
WT	观看时长
CN_{max}	用户序列的最大点击量
WT_{max}	用户序列的最大观看时长
RS	推荐序列
F	字段个数
$F_{P_i}^{k}$	第P_i个推荐序列的第 k 个字段
P	推荐序列个数
P_i	第 i 个推荐序列

4. 基本假设

假设 1：异常值处理后的数据均为准确数据；

假设 2：用户单次请求推荐服务提供的内容观看时长为内容的最大时长；

假设 3：一旦点击内容，观看时长大于 0；没有点击内容，观看时长效应 0；

假设 4：所有用户没有重复浏览相同的内容；

假设 5：每个内容只有一个一二级分类；

假设 6：内容的基础属性第一个位置数据为一级分类。

5. 数据处理

基于题目提供内容的基础属性（doc_info.txt），可以发现数据中存在多个异常数据，为更好的进行问题的解决，需要采取措施进行数据处理。同时，数据异常有几种表现形式，诸如：(1)内容类别没有一级分类和二级分类；(2)内容类别只有一级分类，没有二级分类；(3)单个内容存在多个一二级分类；(4)内容的基础属性存在异常符号。

针对上述异常值情况，对应做如下处理操作：

1、针对异常情况(1)，考虑数据的完整性，将一级和二级内容均设置为其他（处理之后分类为其他/其他）；

2、针对异常情况(2)，将二级分类设置为其他（处理之后分类为***/其他）；

3、针对异常情况(3)，取第一个分类作为单个内容的一二级分类（处理之后分类为：）；

4、存在异常符号的类别，也作为一个单独的分类，并按照异常情况(2)、(3)做数据处理。

按内容的基础属性的基础属性进行分类，二级分类一共 290 个项目（图形）、一级分类一共***个，按照一二级分类建立网络关系，网络关系图如下所示：

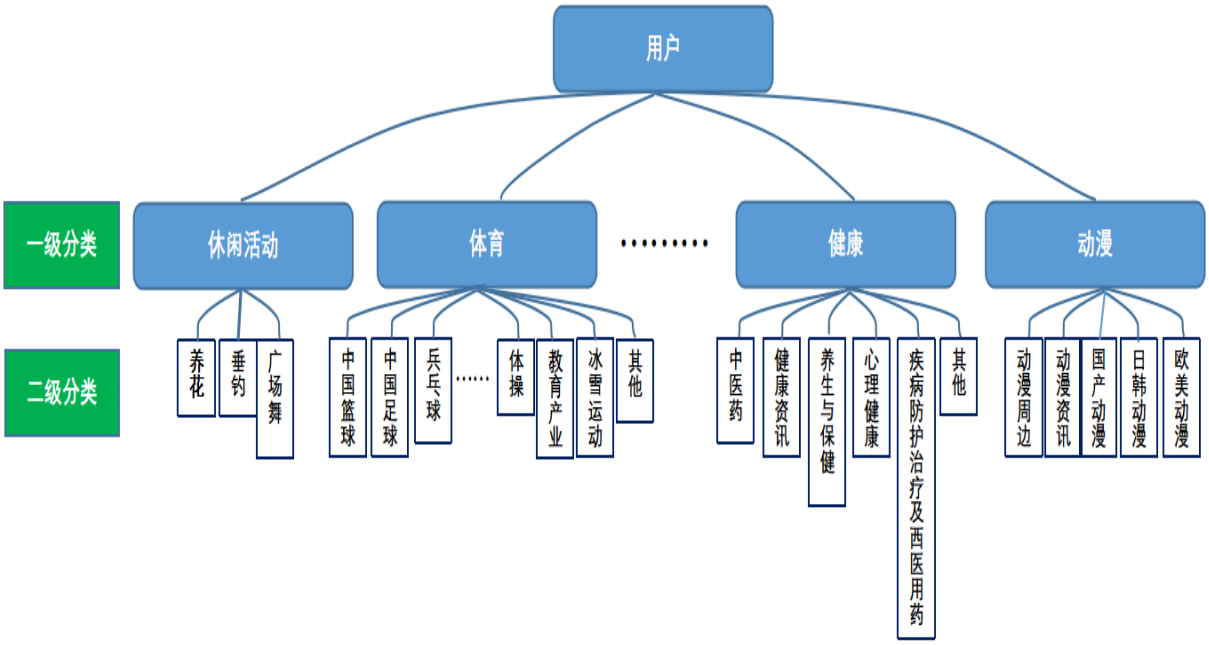


图 2：内容分类网络关系图

6. 问题一：推荐序列总点击和总时长收益评估模型

6.1. 问题一的建模流程

对于单个用户来说，考虑不同排列组合收益的大小，推荐序列总点击收益数学模型的建模流程如下：

表 2：问题建模流程

步骤编号	详细内容
1	按照二级分类将项目分成 290 个项目
2	290*290 的优先网格初始化 W

3	推荐服务返回的内容列表的点击量和观看时长
4	计算推荐序列的累计最大时长和最大点击量
5	将每一条内容列表的点击量和观看时长分别除以最大时长和最大点击量并相加并除以2，获得初始收益值 pi
6	更新优先网格，获得序列的优先关系，步骤如下： 6.1 初始化，用第一条序列更新优先网格，网格的初始收益值为 p1 6.2 如果 pk > pi（k= 1:290、i= 1:290） 6.2.1 获取内容 ID 的项目 6.2.2 根据内容分类优先关系，更新网格 6.3 如果 pk <=pi（k= 1:290、i= 1:290） 6.2.1 获取内容 ID 的项目 6.2.2 根据内容分类优先关系，把不存在优先关系的项目位置更新（W(j1,j2)=W(j2,j1)=0）
7	根据优先网格计算 290 个项目的优先关系
8	计算序列优先顺序得分需要交换才能得到的最优序列次数 N 除以（（n+1）*n/2）
9	上述结果加上初始收益值 pi 再除以 2

6.2. 模型的建立及求解

按二级分类对字段内容进行整理，整理公式如下：

$$N^{\text{II}} = \text{set}（\text{CT}^{\text{II}}）\tag{1}$$

其中，N^{II}表示二级分类个数 ；CT^{II}表示内容类别二级分类；set表示对字段内容进行去重。

经过计算，N^{II}的值为 290，并对内容进行依次编号。

初始化优先网格W如下式所示：

$$\text{W} = \begin{bmatrix} 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & & 0 & 0 \\ \vdots & & \ddots & \vdots & \\ 0 & 0 & & 0 & 0 \\ 0 & 0 & \cdots & 0 & 0 \end{bmatrix}_{290\times290}\tag{2}$$

矩阵的值表示优先关系，矩阵索引表示二级分类的内容，1 表示优先，0 表示不优先，若对称位置$W_{i,j} = W_{j,i} = 0$，表示两个内容之间没有优先关系。

推荐服务返回的内容列表的点击量和观看时长如式 3、4 所示：

$$CN_{P_i} = \sum_{j=1}^{P} CN_{F_{P_j}^k}\tag{3}$$

$$WT_{P_i} = \sum_{j=1}^{P} WT_{F_{P_j}^k}\tag{4}$$

计算推荐序列的累计最大时长和最大点击量如式 5、6 所示：

$$CN_{max} = \max\left(CN_{P_i}\right)\ \ (i = 1、2\cdots P)\tag{5}$$

$$WT_{max} = \max\left(WT_{P_i}\right)\ \ (i = 1、2\cdots P)\tag{6}$$

初始收益计算如下式所示：

$$\mathrm{E}_{0_i}=\frac{CN_{P_i}WT_{max}+WT_{P_i}CN_{max}}{2CN_{max}WT_{max}}\quad(i=1、2\cdots P) \tag{7}$$

更新优先网格，获得序列的优先关系。第P_i个推荐序列的第 k 个字段与内容类别的对应关系为：

$$F_{P_i}^{k}\leftrightarrow \mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k}\ （k=1、2、\cdots、\mathrm{F;i}=1、2、\cdots、\mathrm{P}） \tag{8}$$

其中$\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k}$表示第$P_i$个序列的第 k 个字段对应的优先网格位置，这就可以分为两种情况了。

（1）第一种情况：$\mathrm{E}_{0_{P_i}}>\mathrm{E}_{0_{P_j}}(j=1、2、\cdots、i)$，其中$\mathrm{E}_{0_{P_i}}$表示第 i 个序列的初始收益值；$\mathrm{E}_{0_{P_j}}$表示第 j 个序列的初始收益值。

$$W^{(k1,k2)}_{(\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k1},\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k2})}=1\ (k1=1、2、\cdots、F;k2=1、2、\cdots、k1;) \tag{9}$$

$$W^{(k1,k2)}_{(\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k2},\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k1})}=0 \tag{10}$$

$W^{(k1,k2)}_{(P_i,N)}$表示当字段$F_{P_i}^{k1}$在字段$F_{P_i}^{k2}$前面时，将字段对应内容的优先网格矩阵的位置（$\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k1},\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k2}$)变为 1。

（2）第二种情况：$\mathrm{E}_{0_{P_i}}\le\mathrm{E}_{0_{P_j}}(j=1、2、\cdots、i)$

$$W^{(k1,k2)}_{(\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k1},\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k2})}=1\ (W^{(k1,k2)}_{\left(\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k1},\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k2}\right)}=0\ \&\&\ W^{(k1,k2)}_{\left(\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k2},\mathrm{CT}^{\mathrm{II}}{}_{P_i}^{k1}\right)}=0) \tag{11}$$

根据优先网格计算 290 个项目的优先关系，计算每一行的累计数值，即为优先关系数值大小，再进行排序：

$$\mathrm{score}_i=\sum_{j=1}^{N^{\mathrm{II}}}W_{(\mathrm{i,j})} \tag{12}$$

其中score_i表示第 i 个二级分类内容的优先关系数值，即：$\mathrm{priority}=\mathrm{sort(score)}$，其中priority表示排序之后的二级分类内容编号。

$$E_e=1-\frac{N}{(F-1)^2} \tag{13}$$

$$E_1=\frac{E_1+E_e}{2} \tag{14}$$

其中，N表示序列通过移动编号达到最优排序的移动次数，E_e表示对序列进行交换的收益值；E_1表示序列的收益值。

随机选取 5 个内容，产生不同长度字段，随机取大小不同的初始收益值，作为案例，具体信息如下表：

表 3：案例信息

推荐序列编号	推荐序列(数值表示内容编号)	初始收益值
1	{2、1、3}	0.6
2	{5、3、1、2 、1}	0.8
3	{1、3、5、4}	0.5

其变化过程为$W_0\rightarrow W_1\rightarrow W_2\rightarrow W_3$，$W_0$表示初始化的优先网格矩阵，$W_1$、$W_2$、$W_3$分别表示新的推荐序列对优先网格矩阵的作用关系，则优先关系数值为$\mathrm{score}=[1\ 1\ 3\ 0\ 4]$、则优先关系为{5、3，1、2、4}或{5、3，2、1、4}。具体变化示意图如下：

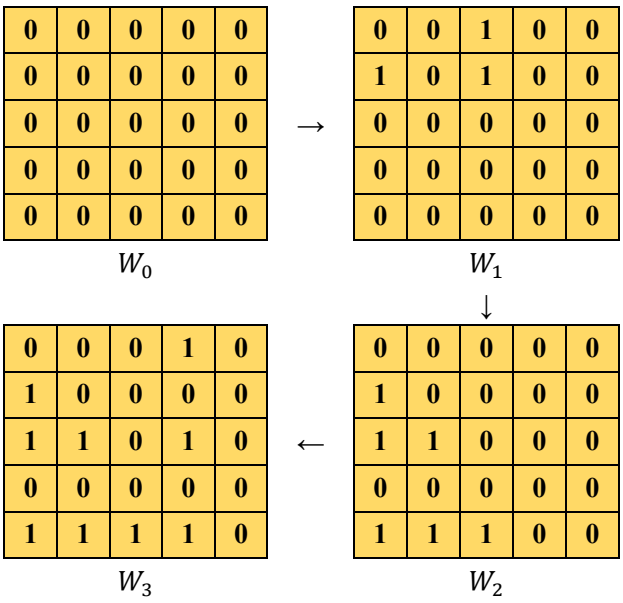


图 3：案例变化示意图

由于内容 1 和内容 2 的优先关系数值相同，故这两种排列组合的收益值是相同的。同时我们可发现$W_{4,2} = W_{2,4} = 0$，从score中我们可以发现，内容 2 是优于内容 4 的，但是差距不大。从推荐序列也可以发现，这是由于关于 4 的内容较少导致，只能由前面的推荐序列得到内容 4 的优先关系。

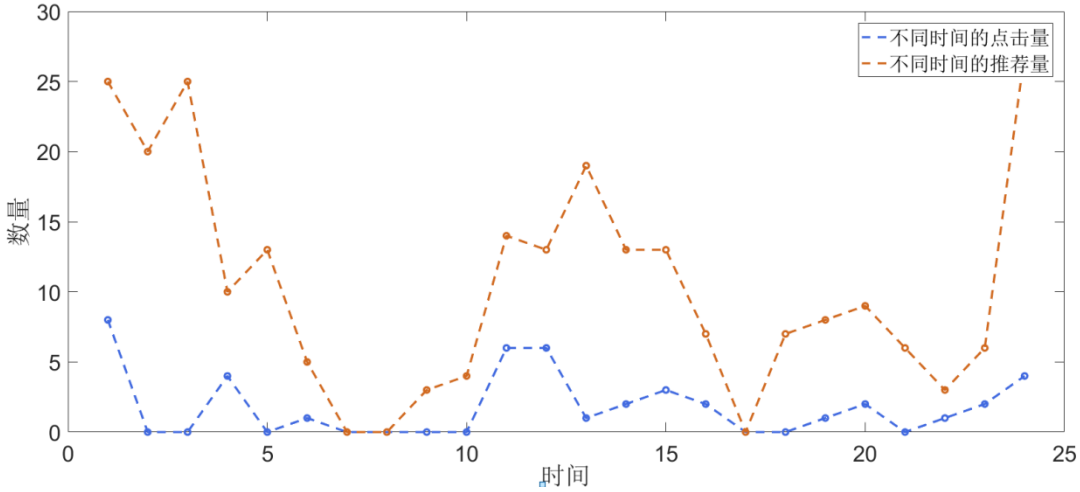


图 4：时间收益分布图

上图为 ID 号为 1385016772 从 0 点到 23 点总的推荐内容数量和总的点击数量，从中我们可以发现，不同时间的点击率是不同的，因此，我们需要设置时间收益τ_d来体现不同时间推送内容带来的收益。

$$P_i^d = \frac{CN_i^d}{RN_i^d}$$
$$\tau_{d_i} = \frac{P_i^d}{\max(P_i^d)} \quad (15)$$

其中，CN_i^d为时间为 i 时总的点击量，RN_i^d为时间为 i 时总的推荐量，P_i^d为对应的点击率，τ_{d_i}为时间为 i 是的收益值。

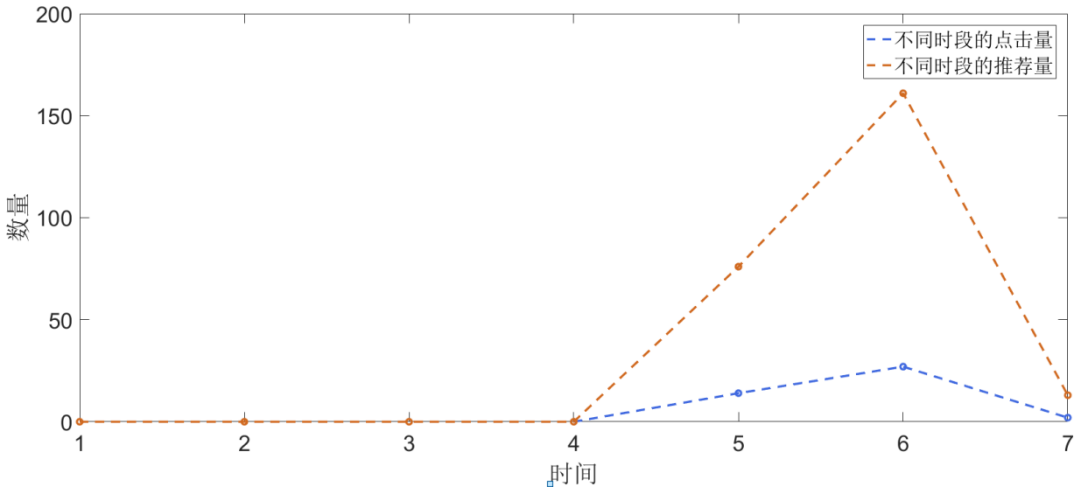


图 5：日期收益分布图

训练数据中为日期为 2021 年 10 月 20 日到 31 日之间的数据，我们把它的转化为以周为单位。以 ID 号为 1385016772 为例，数据如上图所示，其中横坐标编号代表周一至周天，我们可以发现，推荐内容的时间为周五、周六和周日，因此设置日期收益τ_w来体现不同时间推送内容带来的收益。

$$P_i^w = \frac{CN_i^w}{RN_i^w}$$
$$\tau_{w_i} = \frac{P_i^w}{\max(P_i^w)} \quad (16)$$

其中，CN_i^w为时间为周 i 时总的点击量，RN_i^w为时间为周 i 时总的推荐量，P_i^w为对应的点击率，τ_{w_i}为时间为周 i 是的收益值。

7. 问题二：预测推荐序列的总点击量和总时长

7.1. 考虑序列顺序的隐语义模型概述

一个完整的协同过滤推荐系统可以用下面的框架图：

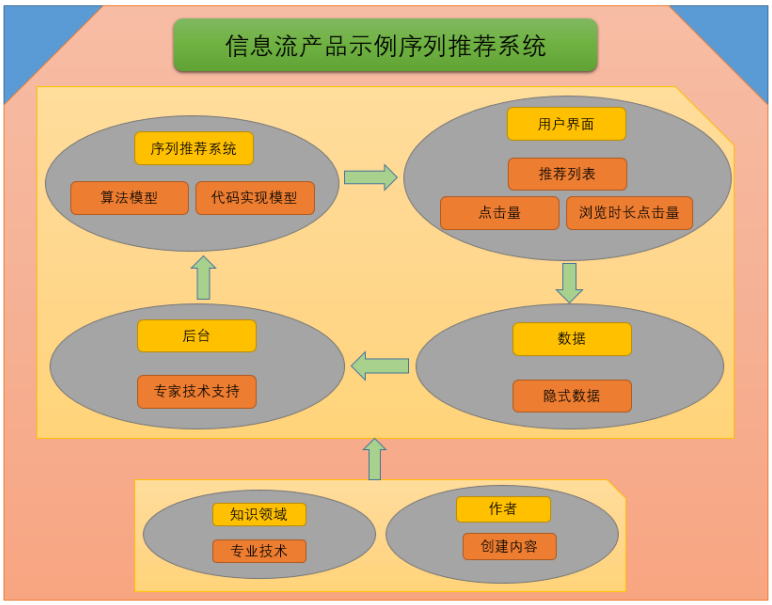


图 6：信息流产品示例序列推荐系统

一般可以根据算法原理把协同过滤算法分为三种，如表 4。可以看到基于用户的协同过滤算法(User-based)和基于物品的协同过滤算法(Item-based)是最经典领域模型算法。矩阵分解模型包括有

SVD、MF、LFM 以及 PMF 等算法。基于图的模型中研究最有代表性的是随机游走算法[15]。

表 4：协同过滤算法分类

模型	代表性算法
基于领域的模型	基于用户的协同过滤 基于物品的协调过滤
矩阵分解模型	奇异值分解 隐语义模型
基于图的模型	随机游走 Tangent、PathFusion

下面将介绍最通用的三种模型算法：基于用户的协同过滤、基于物品的协同过滤、隐语义模型。因此将算法说明中所需要的符号进行设定，表格如下：

表 5：使用到的公式符号

符号	定义
A(a)、B(b)、C(c)、u	表示用户 A(a)、用户 B(b)、C(c)、u
$\vec{a}$，$\vec{b}$	物品空间中的表示用户的用户向量
$R_{a,k}$	表示用户 a 对物品 k 的评分
I_a	表示用户 a 消费或评分的物品集合
I_{ab}	表示用户 a 和用户 b 共同消费或评分的物品集合
$\overrightarrow{R_a}$	表示用户 a 所有物品评分的平均值
i，j	表示物品 i 和物品 j
$\vec{\imath}$，$\vec{\jmath}$	用户空间中的表示物品的物品向量
$\overrightarrow{R_\imath}$	表示物品 i 评分的平均值
U_{ij}	表示物品 i 和物品 j 都已经评价过的用户集合
$Sim(a，b)$	表示用户 a 和 b 的相似度
$Sim(a，b)$	表示物品 i 和 j 的相似度
P，Q	隐语义模型矩阵分解后的 P 和 Q 参数矩阵
r_{ui}	表示用户 u 对 i 的评分
$\widehat{r_{u\imath}}$	表示用户 u 对 i 的与非评分
α	梯度下降法的学习率
λ	正则化参数
F	LFM 的隐因子个数

7.1.1 基于用户的协同过滤算法

基于用户的协同过滤算法(User-based Collaborative filtering)是最早提出的推荐算法之一，一开始应用于邮件过滤系统，后面被 Grouplens 应用于新闻推荐[14]。这种算法是协同过滤算法最直接的体现，作用过程示意图如图 7。



图 7：基于用户的协同过滤算法形象表示

从图中可以直观的看到，用户 A 和用户 C 同时对物品 A 和物品 C 感兴趣，可以将他们看作有着相似偏好的用户，用户 A 没有使用过物品 D，User-CF 推荐系统就会自动将物品 D 可以推荐给用户 A[14]。可以将基于用户的协同过滤算法表述为 3 个步骤：

步骤 1. 计算各用户与活动用户的相似程度；

步骤 2. 根据各用户与活动用户的相似度确定该活动用户的邻居；

步骤 3. 将邻居的得分的加权值作为活动用户的评分。

要找到指定用户的相似用户，需要用算法来衡量用户之间的相似程度。下面介绍 3 种经典的计算方式: 余弦相似性、相关相似性和修正的余弦相似性。

1、余弦相似性：用户 a 和用户 b 之间的余弦相似性为:

$$sim(\mathrm{a},\mathrm{b}) = \cos(\vec{a}\cdot\vec{b}) = \frac{\vec{a}\cdot\vec{b}}{||a||_2\cdot||b||_2} = \sum_k \frac{R_{ak}}{\sqrt{\sum_{l\in I_a} R_{il}^2}}\cdot\frac{R_{bk}}{\sqrt{\sum_{l\in I_a} R_{bl}^2}} \tag{17}$$

式中分母用于归一化，这样打分项目较多的用户在计算式时候不会优先于其他的用户。

2、相关相似性：使用皮尔逊相关系数(Pearson)来度量两个用户之间的相似性:

$$\mathrm{sim}(\mathrm{a},\mathrm{b}) = w_{a,b} = \frac{\sum_{k=1}^{K}(R_{a,k}-\bar{R}_a)(R_{b,k}-\bar{R}_b)}{\sqrt{\sum_{k=1}^{K}(R_{a,k}-\bar{R}_a)^2}\sqrt{\sum_{k=1}^{K}(R_{b,k}-\bar{R}_b)^2}} \tag{18}$$

其中 K 这个变量是用户 a 和用户 b 相同的评分数量。

3．修正的余弦相似性：考虑一种情况，比如一些用户评分比较极端，而另一些用户评分比较温和，如果采用下面公式进行计算，这两种用户的差异会表现的很大，即 使两者的兴趣其实是很相似的。可以用下面的式子进行修正:

$$\mathrm{sim}(\mathrm{a},\mathrm{b}) = w_{i,j} = \frac{\sum_{k\in l_{a,b}}(R_{a,k}-\bar{R}_a)(R_{b,k}-\bar{R}_b)}{\sqrt{\sum_{k\in I_a}(R_{a,k}-\bar{R}_a)^2}\sqrt{\sum_{k\in I_b}(R_{b,k}-\bar{R}_b)^2}} \tag{19}$$

7.2.1 基于物品的协同过滤算法

在用户数目比物品数目少的情况下，基于用户的协同过滤算法运行得不错。但是随着一个在线系统的用户越来越多，基于用户的协同过滤算法在这种情况下时间复杂度非常高，寻找指定用户的邻居花费时间很长。为了解决这个问题，Linden 等人提出了基于物品的协同过滤算法(Item based)[15]。

基于物品的协同过滤算法和基于内容的推荐系统在形式上看起来很像，都是找寻相似的物品，但是两者有着本质上的不同。基于内容的推荐系统是通过物品的内在属性来寻找相似的物品。而基于物品的协同过滤算法是分析用户的行为数据来计算物品之间的相似程度。比如很多用户会同时购买《推荐系统实战》和《数据挖掘导论》两本书籍，那么就可以认为这两本书籍的相似度是很大的，因此可以为只买了《推荐系统实战》的用户推荐《数据挖掘导论》这本书[15]。形象表示如图 8。

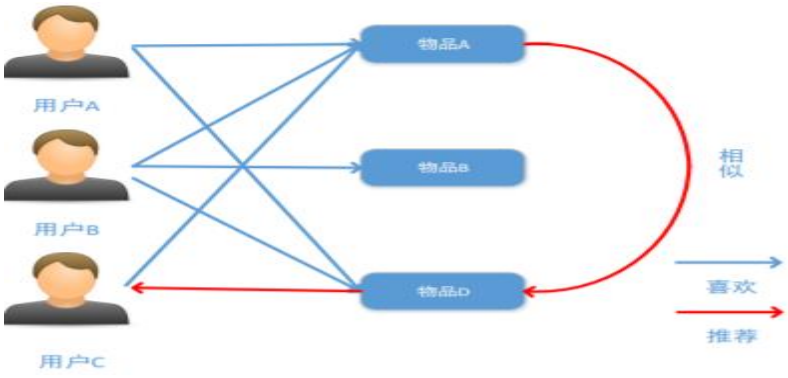


图 8：基于物品的协同过滤算法形象表示

Amazon 研究人员提出基于物品的协同过滤算法主要考虑到了在他们的数据库当中，物品的数量是相对不会有很大变化的，而且总的物品数量相对于不断增加的用户数量是比较少的，因此计算机系统可以使用较小的时间复杂度就可以计算得到物品之间的相似度[13]。而且在用户不断加入的时候，整个推荐系统的扩展性是很强的，因为不需要用大量的时间计算新增加的用户的最近邻居。所以这种算法效率较高，而且准确性也有很大的保证。一经提出，就成为了推荐系统的宠儿[14]。

基于物品的协同过滤系统一般也分为三个步骤：

步骤 1. 通过用户-物品矩阵求出不同物品之间的相似度；

步骤 2. 得到指定物品的相似度最大的 N 个邻居物品；

步骤 3. 为购买了指定物品的用户推荐指定物品的邻居物品，前提是用户没有买过该物品。

如基于用户的算法一样，步骤 1 中的计算不同物品之间的相似度也是基于物品的算法的核心步骤。选择不同的算法计算物品的相似度，会得到不同的推荐结果。计算两个物品的相似度，首先要分离出对这两个物品所有已经评分的用户，然后利用相似性度量算法计算得到两个物品的相似性。同样采用 3 种经典的计算方式进行计算，具体计算公式见下述若干式子。

1、余弦相似性：设有物品 i 和物品 j，他们之间的相似性如式所示:

$$sim(i,\mathrm{j}) = \cos(\vec{\imath}\cdot\vec{j}) = \frac{i\cdot\vec{j}}{||i||_2\cdot||j||_2} \tag{20}$$

2、相关相似性：这种算法一般采用皮尔逊系数作为物品之间的相似系数。

$$sim(i,j) = \frac{\sum_{u\in U}(R_{u,i}-\bar{R}_i)(R_{u,j}-\bar{R}_j)}{\sqrt{\sum_{u\in U}(R_{u,i}-\bar{R}_i)^2}\sqrt{\sum_{u\in U}(R_{u,j}-\bar{R}_j)^2}} \tag{21}$$

3、修正的余弦相似性：各个用户的评分尺度不一样，需要对此进行修正。建议将用 户评分减去该用户所有评分的平均值，经过修正之后，不论用户是极端型的评分还是 温和型的评分，都可以得到使得计算更加准确。具体的计算公式如下所示:

$$sim(i,j) = \frac{\sum_{u\in U}(R_{u,i}-\bar{R}_u)(R_{u,j}-\bar{R}_u)}{\sqrt{\sum_{u\in U}(R_{u,i}-\bar{R}_u)^2}\sqrt{\sum_{u\in U}(R_{u,j}-\bar{R}_u)^2}} \tag{22}$$

在得到物品的相似度之后，最后需要计算的用户 u 对物品 i 的评分的预测值，计算公式如下（21）:

$$S_{u,i} = \frac{\sum_{k\in N_u(i)} sim(k,j)\cdot R_{u,k}}{\sum_{k\in N_u(k)}|sim(k,j)|} \tag{23}$$

公式中$N_u(i)$表示表示与物品 i 相似度最高的 n 个物品的集合。这种方法在评分预测中是最常用的方法，被称为权相加法。

7.3.1 隐语义模型

矩阵分解模型是近年来推荐系统算法研究的热点方向。这个算法的主要思想是采用了矩阵论中的矩阵分解算法。推荐系统算法研究学者一直希望将矩阵奇异值分解(Singular value

decomposition ,SVD)引入到推荐系统中，但是传统的 SVD 有着难以克服的局限性，所以进展一直较慢[13]。

在 Netflix Prize 比赛中，Simon Funk 基于最优化理论对 SVD 算法进行改进，后来这个算法被比赛的冠军 Koren 称为隐语义模型。由于这个新算法在比赛中的优异表现，他也受到越来越多的研究人员的关注[14]。

在隐语义模型之前，SVD 算法一直是矩阵分解领域的研究重点。Sarwar 等人将其应用到了推荐系统中。但是 SVD 算法在大规模矩阵上分解的时间复杂度过高，一般是 $O(N^3)$，当前的商业公司都是千万级别的用户—物品矩阵，这个速度是不能容忍的。另外还需要对大规模稀疏矩阵进行补全，也需要耗费很大的人力资源[15]。这些缺点使得 SVD 算法很难在实际的推荐系统进行商用。

在 Netflix prize 开始后，为了解决上述 SVD 算法的缺陷，在 2006 年，Simon Funk 在提出了一个算法—Funk-SVD 算法，这个算法被后来的 Netflix Prize 冠军 Koren 称作隐语义模型(Latent Factor Model)[16]。

隐语义模型的核心公式是：

$$preference(u,i) = R_{ui} = P_u^T Q_i = \sum_{k=1}^{K} p_{u,k} q_{i,k} \tag{24}$$

这个分解过程可以用图对矩阵的分解进行形象化表示，如图 9 所示：

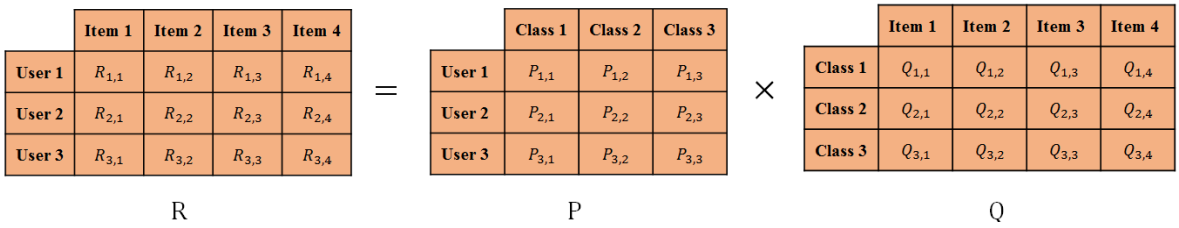


图 9：矩阵分解示意图

其中 R 是用户—物品矩阵，矩阵值 R_{ij} 表示用户 i 对物品 j 的兴趣度。P 矩阵是用户—隐分类矩阵，矩阵值 P_{uk} 表示的是用户 u 对第 k 个隐类的关系。Q 矩阵是隐分类物品矩阵，矩阵值 Q_{ki} 表示的是第 k 个隐类和物品 i 之间的关系。

P 和 Q 矩阵的计算需要通过最优化损失函数理论算法对数据集进行计算得到。

数据预处理完成后，通过计算公式（23）来计算 P 和 Q 参数矩阵，在大多数的研究中，评测指标一般定为均方根误差 RMSE(root mean square error)，然后通过随机梯度下降法使得损失函数最小化。

损失函数的公式为：

$$C = \sum_{(u,i)\in K} (r_{ui} - \hat{r}_{ui})^2 = \sum_{(u,i)\in K} (r_{ui} - \sum_{k=1}^{K} p_{u,k} q_{i,k})^2 + \gamma ||p_u||^2 + \gamma ||q_i||^2 \tag{25}$$

公式（23）中，K 表示用户—物品集合，γ项表示正则化项，用来防止过拟合。γ 值一般是通过实验来进行确定。

接下来采用随机梯度下降法来最小化 RMSE。

首先对 p_{uk} 和 q_{ik} 分别求偏导，公式为：

$$\begin{aligned} \frac{\partial C}{\partial p_{uk}} &= -2q_{ik}e_{ui} + 2\gamma p_{uk} \\ \frac{\partial C}{\partial p_{ik}} &= -2q_{uk}e_{ui} + 2\gamma q_{ik} \end{aligned} \tag{26}$$

随机梯度下降法，将参数随着最快的下降方向进行下降，公式为：

$$\begin{aligned} p_{uk} &= p_{uk} + \alpha(q_{ik}e_{ui} - \gamma p_{uk}) \\ p_{ik} &= p_{ik} + \alpha(q_{uk}e_{ui} - \gamma q_{ik}) \end{aligned} \tag{27}$$

其中，α 这个参数是 SGD 的学习率，这个参数决定了每一步下降的速度，这个参数需要通过多次试验得到。每次迭代都需要将学习率减少，这是梯度下降法要求的，主要是为了使算法尽快收敛。

当求出 P 和 Q 矩阵之后，就可以对一个用户没有使用过的物品进行预测评分。这里生成的评分不单是用来最后的评测，前期的随机梯度下降也用到了这个预测评分公式。

7.2. 考虑序列顺序的隐语义预测模型

根据（train_data.txt）作为训练集计算每个用户对应每个内容的点击次数和浏览时长，通过隐语义模型计算用户没有观看历史的内容的点击次数和浏览时长，得到每一个用户对应每一个内容的点击次数矩阵和浏览时长矩阵，根据优先网格计算推荐序列的收益值，再通过公式（26），则可计算测试集每一个推荐序列的总点击量和点击时长。

$$CN_{p_i}^{S} = \tau_s \tau_w \tau_d \cdot \sum_{i=1}^{F_{p_i}} (\mathrm{CN}_{F_{P_i}^k} \cdot E_{1_{p_i}})$$

$$WT_{p_i}^{S} = \tau_s \tau_w \tau_d \cdot \sum_{i=1}^{F_{p_i}} (\mathrm{WT}_{F_{P_i}^k} \cdot E_{1_{p_i}}) \tag{28}$$

其中$CN_{p_i}^{S}$和$WT_{p_i}^{S}$分别表示第p_i个推荐序列的总点击量和总浏览时长，$\mathrm{CN}_{F_{P_i}^k}$表示第p_i个推荐序列的第 k 个字段的点击量，$WT_{F_{P_i}^k}$表示第p_i个推荐序列的第 k 个字段的浏览时长；τ_s表示序列顺序收益值系数；τ_w表示日期收益系数；τ_d表示时间收益系数。

将预测结果填入 result.csv 中给定位置的总点击量和总时长。

7.3. 误差分析和结果写入

在训练数据集中随机选取了 500 个推荐序列，其中包含了若干个用户，预测结果如图 10 所示。

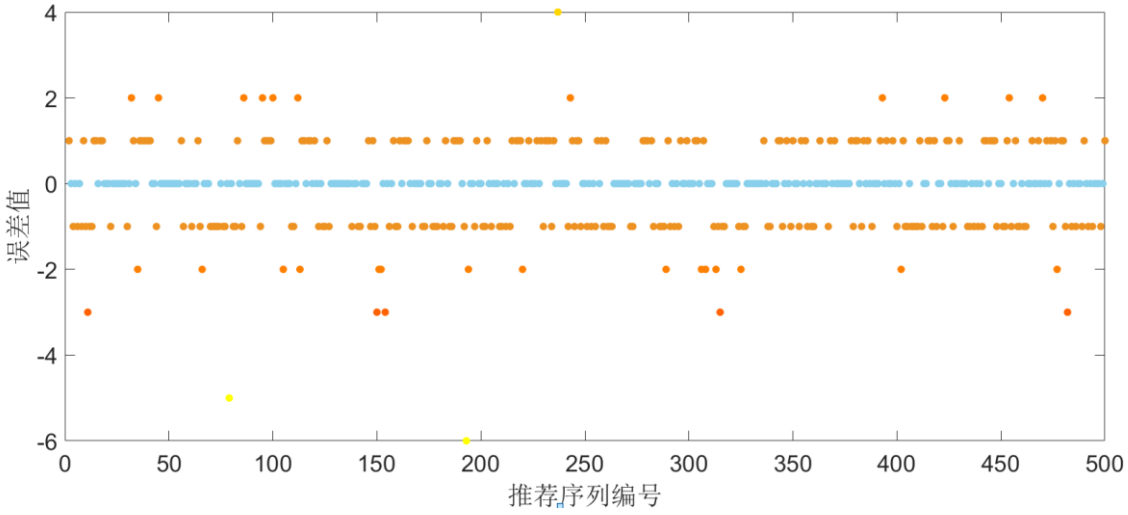


图 10：各推荐序列编号下的误差值

图中的数据为预测的点击量减去实际的点击量，大于 0 表示，预测的点击量多于实际的点击量，小于 0 表示预测的点击量少于实际的点击量，等于 0 表示预测的点击量和实际的点击量相同。从图中我们可以发现：93%的预测点击量与实际的点击量偏差是小于等于 1，误差在可控的范围之内，说明设计的模型具有有效性。

同时我们选取 1679 个数据进行统计分析各个误差值的数量分布，结果如表 6 所示，并用 MATLAB 的正态分布拟合工具对数据进行拟合，结果如图 11 所示。从图中我们也可以发现，大量的数据分布

在[-2,2]这个区间上，验证了我们模型的有效性

表 6：不同点击量的误差值

误差值	数量	误差值	数量	误差值	数量
-6	1	-1	398	4	11
-5	2	0	672	3	38
-4	7	6	2	2	77
-3	32	5	0	1	355
-2	84				

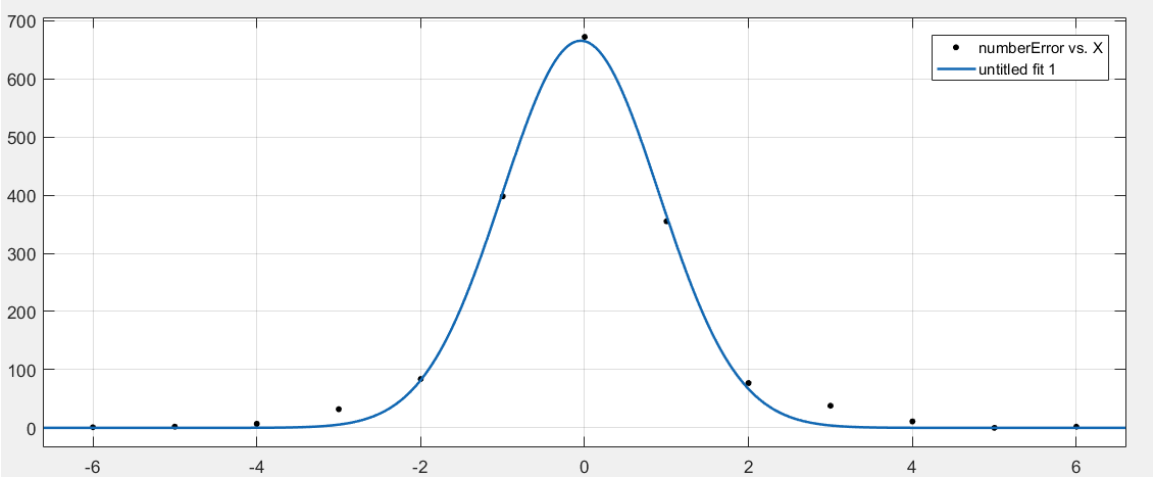


图 11：曲线拟合图

同时，基于问题一设计的数学模型，预测了测试集（test_data.txt） 中推荐序列的总点击量和总时长（单位为秒），并将预测结果写入 result.csv。部分预测数据结果表如下所示：

表 7：部分预测数据结果

请求 ID 编号	总点击量	总浏览时长
719708291_1635480753679_2960	1	339
679978594_1635491281923_1780	0	0
781051348_1635478916952_3923	0	0
1223262997_1635514428746_6191	1	33
1210159908_1635487197871_9372	1	48

8. 问题三：剪枝策略下精确评估最优序列收益

8.1. 问题三的建模流程

针对问题三的求解采用下述求解思路：

步骤 1：根据训练数据计算不同字段个数对应的点击数量和浏览时长；

步骤 2：用正态分布拟合数据；

步骤 3：得到不同字段个数对应的收益值 E2；

步骤 4：建立用户的优先网格确定内容的优先关系；

步骤 5：轮盘赌选择内容序列；

步骤 6：根据优先网格计算推荐序列的最优排序；

8.2. 模型的建立及求解

借助正态分布进行数据拟合需要给出正态分布的函数如式（29）：

$$\mathrm{f(x)}=\frac{1}{\sqrt{2\pi}}e^{-\frac{(x-\mu^2)}{2\sigma^2}} \tag{29}$$

假设数据点{x_i、y_i}（i=1,2,3,...N）符合正态分布曲线，对其进行拟合（曲线拟合不同于分布拟合，需要乘以幅度 A），给出损失函数式（30），对损失函数 J0 求解即可实现参数估计。

$$J_0=\sum_{i=1}^{N}|f(x_i)-y_i|^2=\sum_{i=1}^{N}|\frac{A}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu^2)}{2\sigma^2}}-y_i|^2\mathrm{f(x)}=\frac{1}{\sqrt{2\pi}}e^{-\frac{(x-\mu^2)}{2\sigma^2}} \tag{30}$$

由于求导比较复杂（可以借助 Mathmatica/Maple），因此这里换一个思路：如果$e^x\to y$，则$x\to lny$，则重新定义准则函数：

$$J_1=\sum_{j=1}^{N}\left|ln\frac{A}{\sqrt{2\pi}\sigma}-\frac{(x_i-\mu)^2}{2\sigma^2}-lny_i\right|^2=\sum_{i=1}^{N}\left|-\frac{x_i^2}{2\sigma^2}+\frac{\mu x_i}{\sigma^2}-\left(\frac{\mu^2}{2\sigma^2}-ln\frac{A}{\sqrt{2\pi}\sigma}\right)-lny_i\right|^2 \tag{31}$$

此时，变成了{x_i、$ln\,(y_i)$}的一元二次最小二乘拟合问题。假设拟合结果为：

$$p_1X_i^2+p_2X_i+p_3=lny_i \tag{32}$$

对应的参数估计为：

$$\begin{gathered}\sigma^2=\frac{-1}{2p_1}\\ \mu=\sigma^2p_2\\ \mathrm{A}=e^{\left(\frac{\mu^2}{2\sigma^2}+p_3\right)}\times\sqrt{2\pi\sigma^2}\end{gathered} \tag{33}$$

使用正态分布去拟合不同字段个数的点击数量，计算不同字段个数对应的曲线面积

$$S_k=\int_{k-1}^{k}f(k)\quad（\mathrm{k}=1、2、\cdots、\mathrm{F}） \tag{34}$$

其中S_k表示不同字段个数对应的概率值，k 的值为max (S_k)对应的 k 值。

在确定选取的字段个数之后，就需要选取字段对应的内容。假设有 N 条候选内容，二级分类内容可能有N_1条，优先网格只能确定用户不同二级内容的优先关系，无法确定同一种分类内容的优先关系，因此，这里我们通过轮盘赌的方式进行选取。建立N_1个分类内容的优先网格，确定内容的优先关系，确定 N 条候选内容的排名，记为$\mathrm{V}_i(i=1、2、\cdots N)$.

$$P_i=\left[\frac{\sum_{j=1}^{i-1}(\max(V)-V_j)}{\sum_{j=1}^{N}V_k}\quad\frac{\sum_{j=1}^{i}(\max(V)-V_j)}{\sum_{j=1}^{N}V_k}\right] \tag{35}$$

其中，P_i表示每一条内容的概率分布区间，即：

$$\mathrm{R}_{1\times k}=\left[rand_1()、rand_2()、\cdots rand_k()\right] \tag{36}$$

其中，$\mathrm{R}_{1,i}$对应的值落在P_i所属的区间即为选取的对应的内容。

8.3. 剪枝策略复杂度分析

在计算机科学中，算法的时间复杂度是一个函数，它定性描述该算法的运行时间。这是一个代表算法输入值的字符串的长度的函数。时间复杂度用O表述，不包括这个函数的低阶项和首项系数[5]。使用这种方式时，时间复杂度可被称为是渐近的，亦即考察输入值大小趋近无穷时的情况。在问题三中，我们考虑的是最坏时间复杂度，剪枝策略需要用到的模型如下表所示：

表 8：剪枝策略模型及其时间复杂度

模型	时间复杂度
曲线拟合拟合模型	$O(nlog(n))$
概率求解模型	$O(n)$
优先网格模型	$O(n^2)$
内容选取模型	$O(n)$

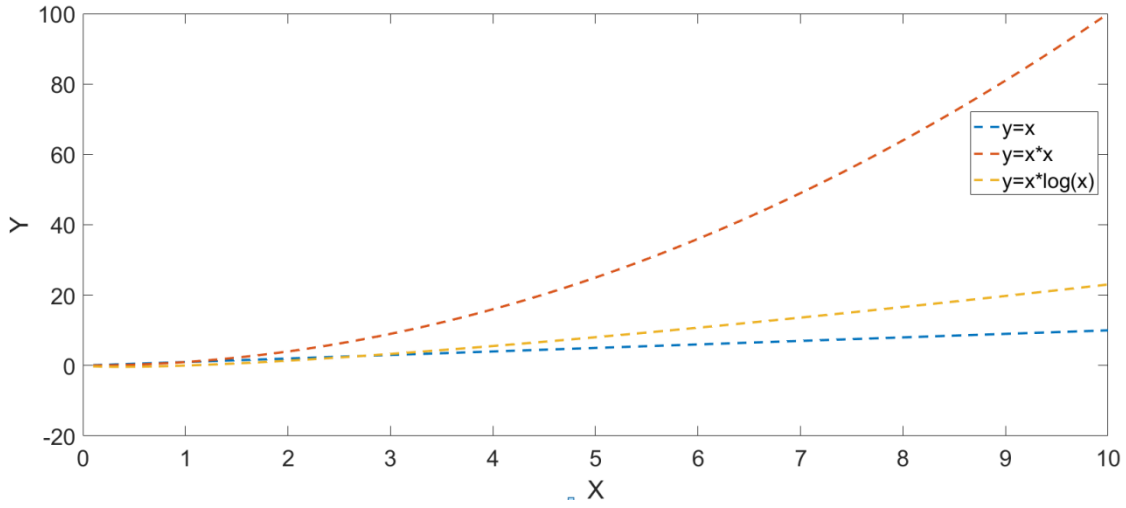


图 12：时间复杂度曲线图

从上图我们可以发现当n取值较大时，$n^2 > nlog(n) > n$，故剪枝策略的时间复杂度为$O(n^2)$。

8.4. 剪枝策略的精准度检验

为了检验剪枝策略的精准度，以 ID 号为 1385016772 为例，从 290 个二级分类的条候选内容中，在训练数据集中寻找收益值最大的序列，作为目标序列 K。

基于剪枝策略计算最优的序列K'以及序列的长度。若通过剪枝策略得到的序列包含序列 K，即$K \in K'$，则记为 0，否则记为 1。

判断结果如图 13 所示，我们可以发现：绿色表示找到了最优序列，红色空心圆圈则表示没有找到最优序列，在产生的 500 个序列中仅有 56 个没有包含给定的最优序列，由此计算出剪枝策略的精准度可以达到 90%左右。

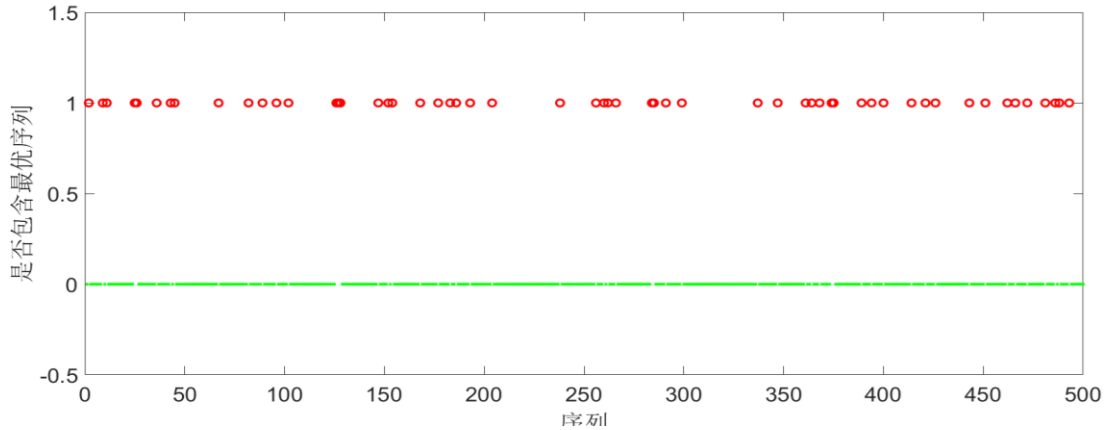


图 13：不同序列是否包含最优序列判断图

9. 总结和展望

近些年，推荐系统在商业应用中已经非常普遍。包括像电子商务公司、内容提供公司都有着自己研制的推荐系统，例如国外的 Amazon、youtube，国内的京东、腾讯视频等等，这些公司都通过自己的推荐系统获得了丰厚的商业回报[16]。因为有着强大的商业驱动力，推荐系统的发展如火如荼。

本文首先介绍了推荐系统的发展现状，并详细阐述了其中比较知名的算法，包括基于邻域的协同过滤算法、矩阵分解模型等。另外还介绍了推荐系统的评价标准以及用户数据获取和表示这两个推荐系统的重要步骤。

优先矩阵模型能够根据用户推荐序列的点击量，实时更新用户推荐序列中的内容的喜爱程度，同时还能分析不同的排列组合对用户的影响。

隐语义模型能够让用户对没有使用过的物品进行预测评分，但隐语义模型在实际使用中有一个困难，那就是它很难实现实时推荐。经典的隐语义模型每次训练时都需要扫描所有的用户行为记录，这样才能计算出用户对于每个隐分类的喜爱程度矩阵 P 和每个物品与每个隐分类的匹配程度矩阵 Q。而且隐语义模型的训练需要在用户行为记录上反复迭代才能获得比较好的性能，因此 LFM 的每次训练都很耗时，一般在实际应用中只能每天训练一次，并且计算出所有用户的推荐结果。从而隐语义模型不能因为用户行为的变化实时地调整推荐结果来满足用户最近的行为。隐语义模型和优先矩阵相结合，就能实时地根据用户的浏览情况，更新不同内容带来的收益，做到实时更新。最后设计剪枝策略，能够在 N 条候选内容中，快速地选择选择长度为 K（N≥K）的最优推荐序列，减小模型的计算时间。

总而言之，文中建立的推荐序列收益评估模型，能够快速地计算不同序列排列组合带来的收益，并且更够实时地更新，并快速地选取最优序列推荐给用户。

参考文献

[1] 温雯,梁方宇.基于用户潜在状态及依赖关系学习的时序行为推荐[J/OL].计算机应用:1-8[2022-01-20].

[2] 余皑欣,冯秀芳,孙静宇.结合物品相似性的社交信任推荐算法[J/OL].计算机科学:1-13[2022-01-20].

[3] 陈壮,邹海涛,郑尚,于化龙,高尚.基于用户覆盖及评分差异的多样性推荐算法[J/OL].计算机科学:1-10[2022-01-20].

[4] 王苑丞,韩林志.模因论视域下抖音平台信息流广告的创作研究[J].中国广告,2022(01):70-74.

[5] 陈靓,钱亚冠,何志强,关晓惠,王滨,王星.深度卷积神经网络的柔性剪枝策略[J/OL].电信科学:1-17[2022-01-20].

[6] 高秋英,王丽丽,王荣忠.最小二乘法曲线拟合及优化算法研究[J].工业控制计算机,2021,34(11):100-101.

[7] 刘欢.基于大数据的信息流营销探讨[J].中国管理信息化,2021,24(22):92-94.

[8] 王伟,蔡文生,邓科.利用最小二乘法拟合水位流量关系曲线探讨[J].陕西水利,2021(11):51-52+58.DOI:10.16747/j.cnki.cn61-1109/tv.2021.11.017.

[9] 郭静宁.深度卷积神经网络模型剪枝方法研究[D].北京交通大学,2020.DOI:10.26944/d.cnki.gbfju.2020.001651.

[10] 张镇. 卷积神经网络通道剪枝算法研究[D].西安电子科技大学,2020.DOI:10.27389/d.cnki.gxadu.2020.000642.

[11] 甘子美. 短视频 App 算法推荐智能化对用户心流体验的影响研究[D].广东外语外贸大学,2020.DOI:10.27032/d.cnki.ggdwu.2020.001056.

[12] 纪煜东. 对采用个性化推荐的移动端视频平台的优化策略[D].江南大学,2019.

[13] 王宁,沈正一,崔德龙,刘晴瑞.结合协同过滤与隐语义模型的视频推荐策略[J].湖南工程学院学报(自然科学版),2021,31(04):40-43.DOI:10.15987/j.cnki.hgbjbz.2021.04.007.

[14] 黄伟建,顾明星,黄远.结合隐语义模型与改进用户信任的协同过滤推荐算法[J].现代电子技术,2021,44(12):141-144.DOI:10.16652/j.issn.1004-373x.2021.12.030.

[15] 张小雷. 基于协同过滤和隐语义模型的图书推荐算法研究与实现[D].阜阳师范大学,2021.DOI:10.27846/d.cnki.gfysf.2021.000168.

[16] 周熙然. 基于隐语义模型的推荐算法研究与应用[D].西安科技大学,2021.DOI:10.27397/d.cnki.gxaku.2021.000884.