队伍编号	MCB2102047
赛道	A

基于多模型融合与灰色关联分析的二手车交易问题研究

摘 要

随着经济的发展，我国的机动车保有量不断上升，二手车市场迅速扩展，二手车交易受到诸多因素的影响。本文就题目所给数据完成对二手车的估价以及分析影响二手车成交周期的关键因素。

对问题一中二手车的估价问题，首先对所给数据进行预处理，在这一阶段，先根据特征的取值离散连续情况标记出类别特征并编码，分别通过众数和平均值分别填充离散和连续特征；其次，剔除数据中的异常值以避免引入误差；最后，变换实际交易价格使其近似呈线性分布，以利于模型的学习；对类别特征采用 one-hot 编码，消除编码带来的类间差异；计算特征之间的相关系数以及建立新的特征等。下一阶段中，先按 7:3 比例分割数据集，采用集成学习 Bagging 与 Boosting 中的随机森林、梯度提升决策树 GBDT、XGBoost 以及 Lightgbm 算法在训练集上训练，实验表明四种算法对该数据集都具有足够的拟合能力，但是由于过拟合均很严重，难以获得很好的精度。为此，在测试集上进行超参数的选取，在保证测试精度的同时减轻过拟合的程度，提升模型的泛化性能，四种算法测试精度分别为 0.526、0.51、0.529、0.534。在本问题的最后，建立多模型融合三层 Stacking 结构，第一层使用上述四个学习器，第二层仅使用 GBDT、XGBoost、Lightgbm，再通过线性回归层输出。实验表明由于 Stacking 利用了多种学习器各自的优势与强项，在保证模型泛化性的前提下，其测试精度分别为 0.572，这表明模型精度得到了进一步的提升，优于任何一种单模型。

对问题二中探究影响二手车成交周期的关键因素，同样首先对所提供数据进行分析，删除未完成成交的二手车数据，并从问题一提供的数据中找到同一辆二手车的其他具体信息。计算各特征之间以及特征与标签之间的相关系数，寻找是否存在显著的线性关系，去除冗余特征。之后将最后一次改价到成交时间之间的天数作为标签值，通过 XGBoost 回归模型在数据集上训练，以基决策树使用每个特征时的信息增益作为特征重要性的依据，得到影响成交周期的关键因素以及各因素之间的定量差距；接着利用灰色关联法探究特征与成交周期之间的相关性，计算并得到其之间的灰色关联度。最后，将两种方法得到的排序结果和定量差距进行融合以输出最后的结果，结果发现车辆所在城市 cityId、载客人数 seatings、国标码 carCode 以及过户次数 transferCount 是影响成交周期的最关键的几个因素。由于前三个为类别特征，本文在接下来的研究中发现有些类别比如编号为 50、67 等城市的成交周期最短，载客人数为 3 的二手车成交周期也相对最短，本文后续也对该结果进行了分析并提供了相关建议。

问题三为开放性问题，考虑到问题二中没有利用到的未成交二手车的数据信息，提出可以将二手车完成成交，也就是是否卖出作为标签信息以及结合给定的车辆其它信息预测卖出情况的二分类问题，从而可以利用该模型来指导二手车交易平台的合理经营。我们考虑使用 BP 神经网络结合 softmax 层作为训练模型，利用交叉熵损失函数完成梯度下降与网络权重的更新，以分类精确度为指标，提升分类器的性能。如若出现了过拟合现象则可以考虑权值衰退或 dropout 策略。

关键词：梯度提升树，随机森林，XGBoost，Lightgbm，多模型融合，灰色关联分析

目录

1. 问题重述 1
   1.1 研究背景 1
   1.2 研究问题 1
2. 问题分析 1
   2.1 问题一分析 1
   2.2 问题二分析 2
   2.3 问题三分析 3
3. 模型假设 3
4. 符号说明 3
5. 问题一 4
   5.1 数据预处理 4
   5.2 基于 Bagging 与 Boosting 的回归模型建立 8
   5.2.1 梯度提升回归树（GBRT） 9
   5.2.2 随机森林 11
   5.2.3 XGBoost 13
   5.2.4 LGBM 14
   5.3 基于多模型融合的回归模型建立 16
6. 问题二 18
   6.1 数据预处理 18
   6.2 基于回归模型和灰色关联分析的关键因素提取 19
7. 问题三 23
8. 模型评价 24
   8.1 优点 24
   8.2 不足 24

参考文献 25

附录 25
   附录 1：问题一代码（由 jupyter notebook 导出） 25
   附录 2：问题二代码（由 jupyter notebook 导出） 36

1. 问题重述

1.1 研究背景

近年来，随着国家经济的飞速发展与人民生活水平的逐步提高，我国机动车保有量不断上升，二手车市场也随之迅速扩展。机动车以“二手车”形式在“收车、拍卖、零售、置换”等流通环节的交易需求越来越大，多种交易形式日渐趋于完善，以满足社会上多方面、各层次的需要[1]。

在二手车交易过程中，最重要与最困难的就是车辆估价问题，而这恰恰也是用户最为关心的问题。因为二手车不同于一般的“电商商品”，存在“一车一况”的复杂特性，其价格不但受到如品牌、车系、动力等车辆本身基础配置的影响，还与如行驶里程、车身受损和维修情况等后期车况有极大关联，甚至会随着新车价格的变化而变化。对此，发达国家的二手车交易市场已相当成熟，不仅拥有完善的法规体系、多样的交易方式，而且能够采用合理的价格评估体系，并保持权威的基价发布机构的信息公开透明[2]。例如，美国的 KBB（Kelly Blue Book）可以通过输入汽车的地区、品牌、里程、交通事故信息及其维修记录计算出二手车的合理价格区间。相比国外，我国目前并没有出台一套评判二手车资产价值的评估制度或统一标准，国内的二手车市场也缺乏被普遍认可的权威的中立机构，一些二手车交易平台和二手车第三方估价平台都从自身的角度出发建立了一系列估价方法用于评估二手车资产的价值，但其中仍存在信息不对称的现象，也没有相对可信的价格评估体系。

因此，寻找更为准确合理的二手车估价方法，建立健全二手车评估体系，成为二手车市场持续健康发展所需要解决的当务之急。当下，互联网在渗透各个产业的过程中，产生了大量的数据，而这些海量的数据具有非常宝贵的经济价值与研究价值，借助不断发展与进步的数据挖掘技术所具备的高效地处理复杂多样变量之间的高度非线性和强耦合关系等问题的能力，人们能够快速地从海量数据中探寻并提取出有价值的信息。在二手车交易的 O2O 门店模式下，如何依据数据分析与合适的估价模型确定二手车的零售交易价格，提高销售效率与服务质量，也是当前研究的重点。

1.2 研究问题

基于上述研究背景，本文需要研究并解决以下问题：

问题 1：基于给定的二手车交易样本数据（附件 1：估价训练数据），选用合适的估价方法，构建模型，对附件 2“估价验证数据”中的二手车交易价格进行预测，并将预测结果保存在附件 3“估价模型结果”文件中。其中，附件 1“估价训练数据”包含车辆基础信息、交易时间信息、价格信息等 36 列变量信息（有 15 列为匿名变量），和附件 2“估价验证数据”只相差最后 1 列数据（二手车交易价格（预测目标））。

问题 2：结合附件 4“门店交易训练数据”对车辆的成交周期（从车辆上架到成交的时间长度，单位：天）进行分析，挖掘影响车辆成交周期的关键因素。假如需要加快门店在库车辆的销售速度，可以结合这些关键因素采取哪些行之有效的手段，并进一步说明这些手段的适用条件和预期效果。

问题 3：依据给出的样本数据集，说明还有哪些问题值得研究以及相应的研究思路。

2. 问题分析

2.1 问题一分析

问题一要求使用给定的二手车交易样本数据自行划分训练集、测试集，构建适合这些数据特征的模型，来预测二手车的零售交易价格。所给数据样本中总共有 35 个不同的特征，包括车辆展销时间、二手车的品牌、车系、里程、年款、变速箱等重要信息，附件 1 估价训练数据中有 30000 个样本，附件 2 估价验证数据中则有 5000 个样本以供最终预测。由于数据不可避免有缺失值、异常值，

在读入数据之后首先应该进行数据处理，剔除异常值，以及按特征逐步填补缺失值；其次，应该对一些明显是类别信息的特征转换数据类型或者进行编码，以利于模型的学习。然后，由于 35 个特征之间可能会存在冗余信息，需要进行特征之间的相关性分析，剔除相关程度过高的特征以减少模型的复杂程度。根据常识，我们可以知道二手车的价格与新车购入价格、使用年限等有着密不可分的关系，我们重点关注这些影响模型构建的特征因素，例如利用特征“tradeTime”与“licenseDate”的差值来创建新特征“使用月数”等，对于一些对模型构建贡献度较小或者缺失值过多的特征，我们予以删除，以避免引入过多误差，同时减少复杂度，增加模型的泛化能力。在特征工程结束之后，我们采用拟合能力强的集成学习 bagging 或者 boosting 模型来进行训练，由于单模型在训练时容易发生欠拟合与过拟合，我们采用多模型融合策略来进一步增强模型的泛化能力与鲁棒性。问题一的思路流程图如图 1 所示。

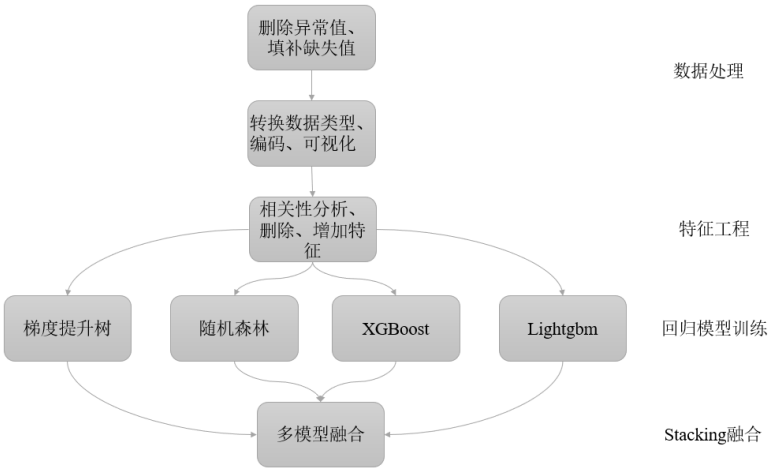


图 1 问题 1 流程图

2.2 问题二分析

问题要求我们结合门店的交易数据分析车辆的成交周期，由于成交周期指的是车辆上架到成交的时间长度，因此我们先删除所给数据中未完成成交的部分数据，利用剩余数据计算每个 carid 对应的成交周期。然后在问题一中的数据中找到对应的车辆补充信息，同问题一一样填补缺失值，剔除异常值。这里我们将二手车价格高于新车价格也作为异常处理，减少冗余信息，之后通过建立回归模型来分析各个特征对建立模型的重要程度以及利用计算特征与车辆成交周期之间的灰色关联度，将两者得到的特征排序进行结合，最终得到影响车辆销售速度的关键因素。之后通过统计分析查看排名靠前的因素对成交周期的具体影响，并给出建议。问题二的思路流程图如图 2 所示。

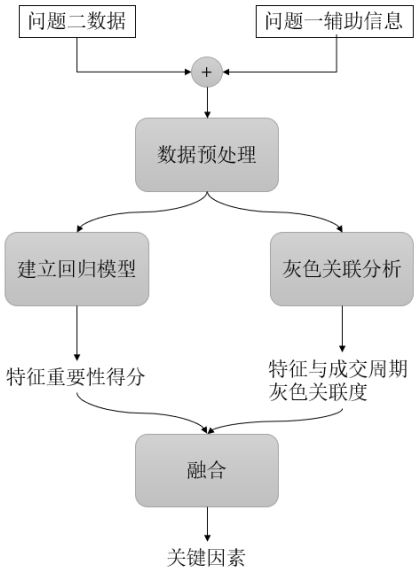


图 2 问题二流程图

2.3 问题三分析

问题三为开放性问题，要求我们依据给出的样本数据集自行提出值得研究的问题并给出思路。我们关注到问题二考虑的是已成交二手车的信息，即把未成交的 2000 个二手车样本剔除。因此在问题三中我们也可以将二手车是否卖出，也就是是否完成交易作为标签信息用于根据车辆给定信息判断卖出情况的二分类问题。我们利用该信息来预测车辆是否能卖出，从而可以指导二手车交易平台更合理地挑选车辆与获得最大收益。在这个二分类问题上，传统的机器学习算法例如逻辑回归、支持向量机或者 BP 神经网络都能比较好地完成。

3. 模型假设

1、 假设样本数据中缺失较多的特征对有效预测二手车交易价格所提供的必要信息少。
2、 假设问题一数据里的匿名特征中取值种类很少的特征为类别特征，包含的是类别信息。
3、 假设二手车的卖出价格一般应低于新车售卖价格。
4、 假设问题二数据里的车辆成交时间特征取值为空值表示该二手车未完成成交即下架。

4. 符号说明

符号	符号说明
p_i	第i个实际交易价格
$\bar{p}_i$	转化后的第i个实际交易价格
μ	均值
σ	方差
f_{ik}	第 i 个样本在第 k 个特征的取值
$grey_corr_k$	第 k 个特征与成交周期的灰色关联度
$score_k$	第 k 个特征的重要性得分
A-O	对应 15 个匿名特征的编号

5. 问题一

5.1 数据预处理

通过 pandas 库读取二手车的估价训练数据与估价测试数据，其中训练集大小为 30000*36，即 30000 个样本，35 个特征以及最终的实际交易价格即标签；测试集大小为 5000*35。在所有的特征中我们先除去对模型训练没有作用的 carid 列，为了判断是否存在异常值，我们先查看样本的统计信息，如下图所示：

	brand	serial	model	mileage	color	...	I	J	M	N	price
count	30000.000000	30000.000000	30000.000000	30000.000000	30000.000000	...	26256.000000	23759.000000	28381.000000	30000.000000	30000.000000
mean	19.228300	237.707733	5312.047767	7.144473	2.786700	...	4.418761	2.507934	201449.680631	1.398133	18.062224
std	18.009168	233.329093	4055.789248	4.383048	2.037599	...	0.614021	0.500200	282.230336	0.496486	629.444049
min	1.000000	1.000000	1.000000	0.010000	1.000000	...	2.000000	1.000000	200606.000000	1.000000	0.050000
25%	8.000000	76.000000	1171.000000	3.907500	1.000000	...	4.000000	2.000000	201211.000000	1.000000	6.100000
50%	13.000000	162.000000	4920.500000	6.540000	2.000000	...	4.000000	3.000000	201504.000000	1.000000	10.479900
75%	23.000000	312.000000	8976.000000	9.540000	5.000000	...	5.000000	3.000000	201702.000000	2.000000	18.000000
max	133.000000	1248.000000	12735.000000	44.740000	10.000000	...	6.000000	3.000000	202105.000000	3.000000	109000.000000

图 3 样本统计信息

观察到训练样本实际交易价格 price 类最大值不合理，根据常识，由于二手车价格与原本新车价格之间存在着正向关系，我们继续画出 price 与特征 newprice 之间的散点图，如图 4 所示：

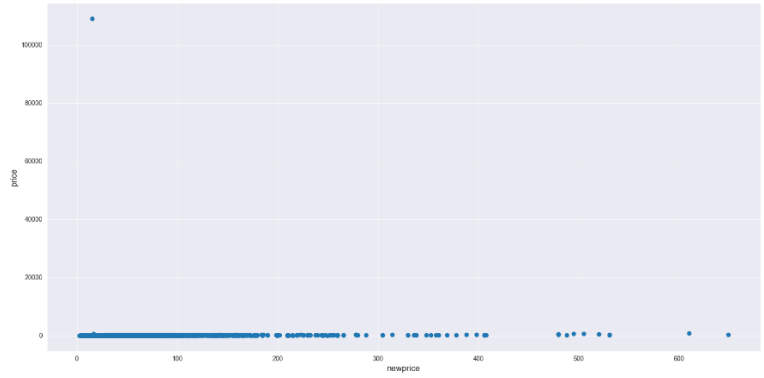


图 4 散点图

很明显看到左上方存在异常值，我们将其所在处的样本删除。此外根据假设我们将二手车实际交易价格除以新车价格并画出相应曲线，如图 5 所示。

$$ratio_i = price_i / newprice_i \tag{1}$$

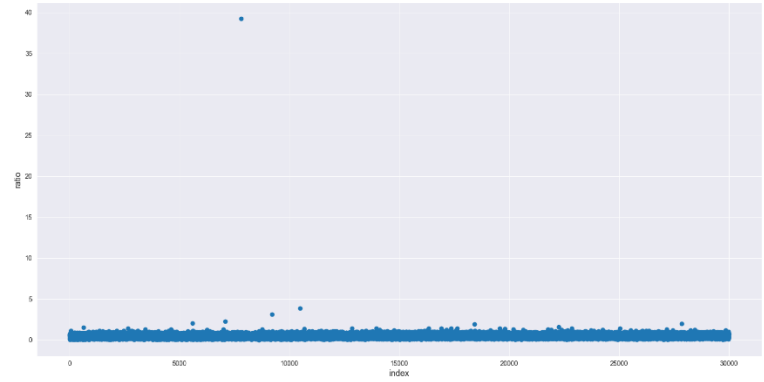


图 5 ratio 分布图

可以看到样本中存在些许二手车售卖价格超过或者远超于对应的新车价格，因为这种情况的可能性很小，而且仅有 193 个，占原始样本数目的 0.6%，所以为了减少给模型带来误差，我们删除二手车价格大于新车价格样本数据。

之后我们对画出实际交易价格 price 的直方图、密度图以及 QQ 图，其中 Q-Q 图主要用于检验数据分布的相似性，如果要利用 Q-Q 图来对数据进行正态分布的检验，则可以令 x 轴为正态分布的分位数，y 轴为样本分位数，如果这两者构成的点分布在一条直线上，就证明样本数据与正态分布存在线性相关性，即服从正态分布。如图 6 所示。

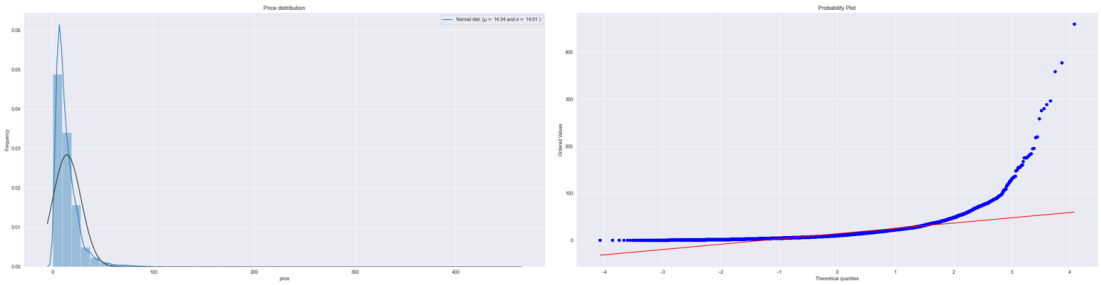


图 6 实际交易价格直方图、密度图与 Q-Q 图

其中均值和方差为：

$$\mu = 14.43, \sigma = 16.47 \tag{2}$$

可以观察到交易价格为非正态分布，于是我们通过式（1）平滑操作转化实际交易价格，使其更加服从高斯分布，利于后续模型的学习与拟合。

$$\overline{p}_i = \ln(1 + p_i) \tag{3}$$

转化后的标签值分布如图 7 所示，可以看到数据已经呈现较好的正态分布，其中变换后的数据的 $\mu = 2.45, \sigma = 0.73$ 。

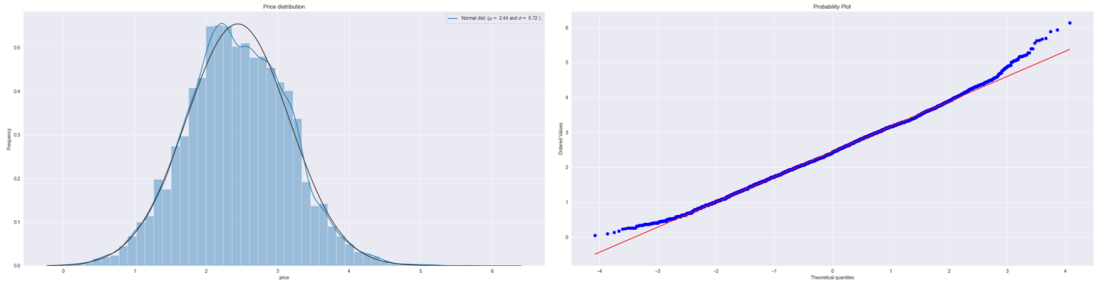


图 7 转换后交易价格直方图、密度图，Q-Q 图

接下来先初步筛选样本特征，去除与标签不太相关或者特征两两之间过分相关的特征，首先计算特征之间取值的相关系数 r，计算式如下：

$$r_{ij} = \frac{\sum_{k=1}^{n}(f_{ik} - \overline{f}_i)(f_{jk} - \overline{f}_j)}{\sqrt{\sum_{k=1}^{n}(f_{ik} - \overline{f}_i)^2}\sqrt{\sum_{k=1}^{n}(f_{jk} - \overline{f}_j)^2}} \tag{4}$$

得到相关系数矩阵后画出对应的热力图如下所示：

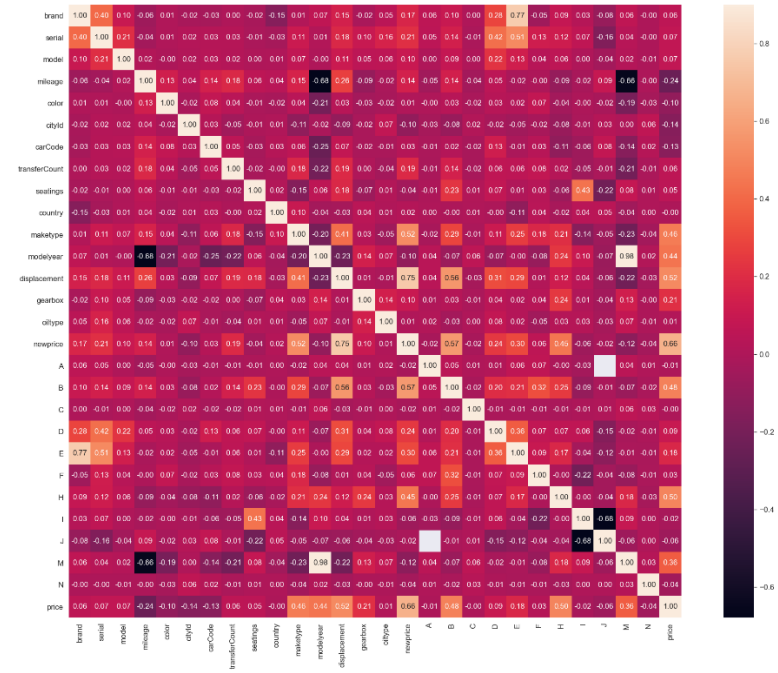


图 8 相关系数矩阵热力图

然后便可以对样本特征数据缺失值进行处理。

首先计算每个特征的缺失数据的数目占所有样本数目的比例，从图 9 可以看出，在除去 carid 特征之后的 34 个剩余特征中，共有 15 个特征：O，G，D，J，H，country，I，maketype，A，M，K，modelyear，carcode，gearbox，L 含有缺失值，其中大写字母 A 到 O 是对 15 个匿名的重新命名。我们先查看每个特征中的取值类别个数，如图 10 所示，可以看到很多特征的取值种类非常稀少，数据呈现离散化，在图 11 我们继续查看这些类别数很少的特征里的具体取值分布情况，以及根据常识，我们将['color', 'carCode', 'seatings', 'cityId', 'model', 'country', 'maketype', 'oiltype', 'brand', 'serial', 'A', 'B', 'C', 'F', 'H', 'I', 'K', 'N', 'gearbox']这些特征作为类别特征，即每个样本在该特征的不同取值对应不同的类别，例如颜色 color，10 中不同取值意味着一共有 10 中类别。

对于特征 O、G、D，这三个特征的缺失值占比分别为 92.28%，60.99%以及 39.9，由于缺失值占比过多，我们舍弃这些特征，直接删除。

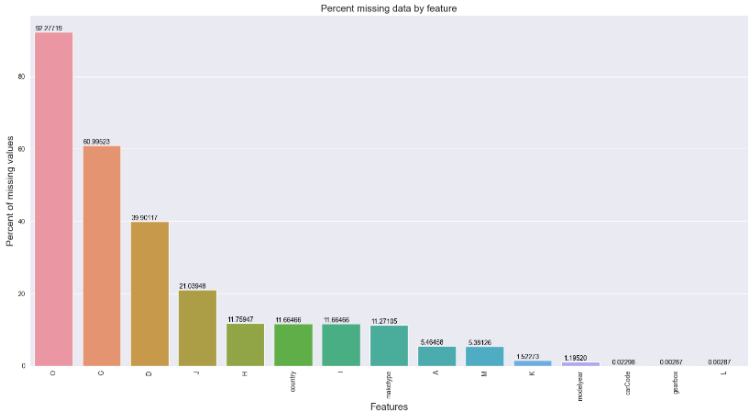


图 9 样本缺失值数目排序图

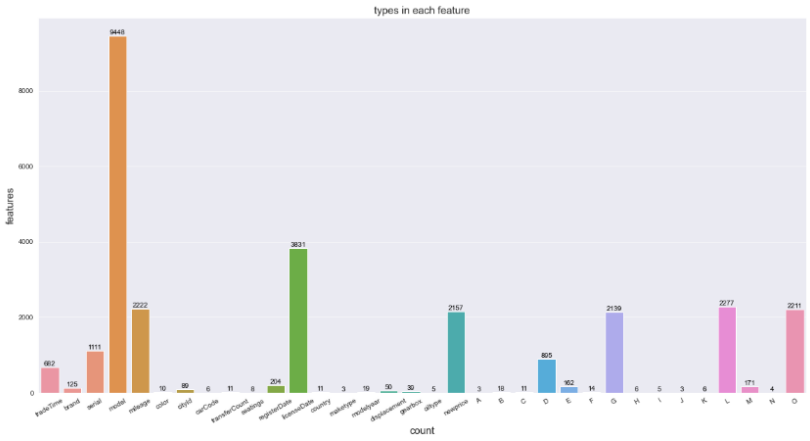


图 10 特征取值情况

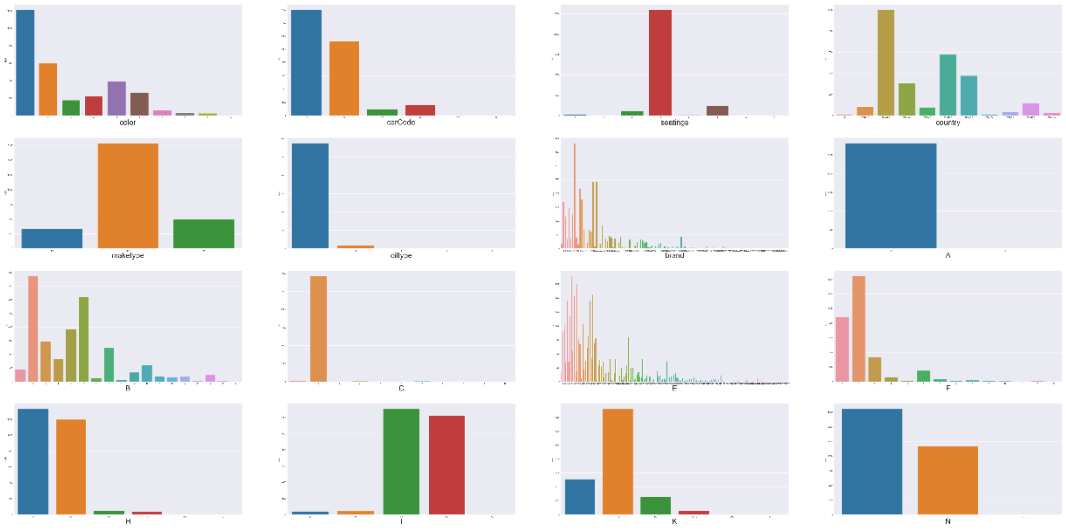


图 11 部分特征取值情况统计图

其次从相关系数矩阵观察得到：M 与 modelyear，J 与 A 之间有很大相关性，又考虑到 J 与 M 的缺失占比远高于 A 与 modelyear，所以对 M 与 J 两列我们同样进行删除处理。

对于特征'carCode', 'maketype', 'country', 'modelyear', 'gearbox', 'A', 'H', 'I', 'J', 'K'，根据前述为类别特征，由于这些特征取值的种类较少，且缺失值占比也很小，所以我们采用众数填充策略填补空值。

对于特征'L'，查看其每一列取值为“4220*1740*1625”格式，很大程度认为其为汽车的三维信息，于是我们将该列取值表达式计算出结果作为新特征来替代该特征，其中存在的一个空值使用新特征的均值进行填补。至此我们已经填充好所有的缺失值。

接下来就是对特征的数据类型进行操作与转换。

首先是三个时间信息特征 tradeTime，registerDate 与 licenseDate，由于具体的年月日格式难以直接拿来训练，所以需要进行转换处理。对于注册时间 registerDate 与上牌时间 licenseDate，我们更加关注从注册到售出之间以及从上牌到售出之间的持续时长，这表征的是新车的使用时间，因此我们将 registerDate 到 tradeTime 之间的天数作为新特征 registerDays，将 licenseDate 到 tradeTime 之间的天数作为新特征 licenseDays 来替代这两个特征，以利于模型的训练与收敛。对于展销时间 tradeTime，我们将该列的每个时间值转化为距离 2000 年 1 月 1 日的天数，这让我们很大程度地保留了时间信息。

对于类别特征，我们先通过小提琴图进行可视化，小提琴图 (Violin Plot) 用于显示数据分布及其概率密度。这种图表结合了箱形图和密度图的特征，主要用来显示数据的分布形状。中间的黑色

粗条表示四分位数范围，从其延伸的细黑线代表数据范围，两端为最大值和最小值，而白点则为中位数。图 12 显示了部分特征。

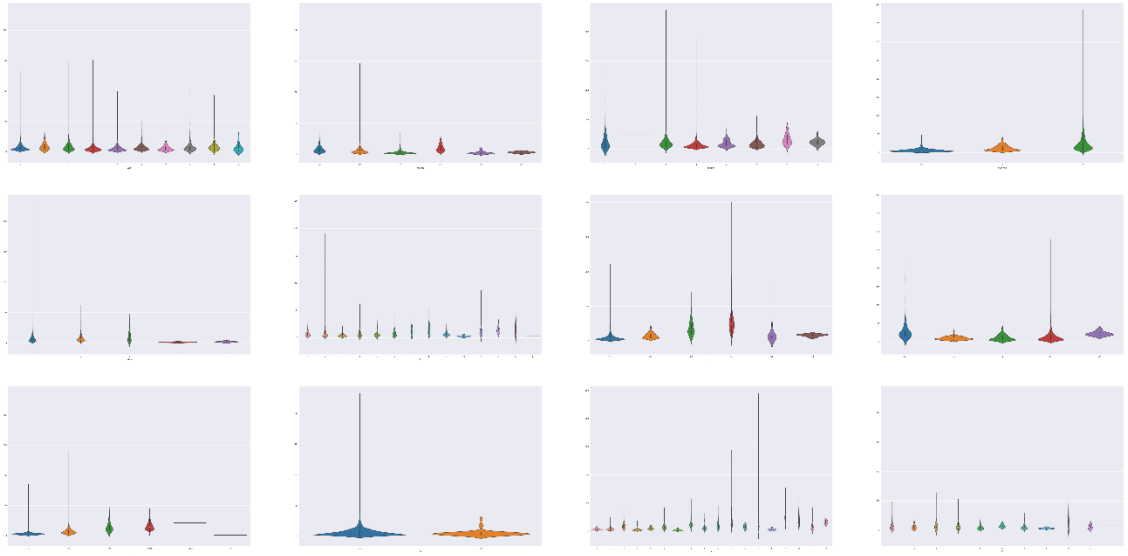


图 12 部分特征关于价格的 Violin plot

由于类别特征中样本具体取多大的值不是我们关注的，因此我们将前述 19 个离散类别特征转化为类别编码，这可以让模型忽略类别特征取值的方差，减少引入不必要的干扰。由于特征 model 与 serial 类别数较多，分别为 9448 与 1111，全部 one-hot 编码后会使模型训练速度大幅减弱，样本特征值过分稀疏，收敛难以保证，因此我们只将除这两个特征之外的 17 个类别特征转化为 one-hot 编码来消除各特征所有类别之间的距离，解决回归模型不好处理属性数据的问题，以及在一定程度上也起到了扩充特征的作用，让距离计算更合理。经过独热编码后特征维度数被扩展到 536。

最后对之前计算得到的 tradeTime，registerDays，licenseDays 以及特征里程 mileage，过户次数 transferCount，年款 modelyear，排量 displacement，新车价 newprice 以及转换之后的匿名特征 L 进行数据标准化，即：

$$f_{ik}^{'} = \frac{f_{ik} - \mu}{\sigma} \tag{5}$$

其中 μ 为该列特征取值的均值，σ 为方差，标准化的目的是将数据变换到均值为 0，标准差为 1 的类正态分布，消除特征的量纲影响，利于模型的学习训练。

5.2 基于 Bagging 与 Boosting 的回归模型建立

集成学习是通过构建并结合多个学习器来完成学习任务，其一般结构是先产生一组“个体学习器”，再用某种策略将它们结合起来，目前三种常见的集成学习策略是 Bagging、Boosting 和 stacking[4]。

Bagging 是 Bootstrap Aggregating 的英文缩写，又称装袋算法，之所以被称为装袋法，是因为它采用了一种有放回的抽样方法来生成训练数据。通过多轮有放回的对初始训练集进行随机采样，多个训练集被并行化生成，对应可训练出多个基学习器（基学习器间不存在强依赖关系），再将这些基学习器结合，构建出强学习器。其本质是引入了样本扰动，通过增加样本随机性，达到降低方差的效果。Bagging 算法可与其他分类、回归算法结合，提高其准确率、稳定性的同时，通过降低结果的方差，避免过拟合的发生。在对预测输出进行结合时，Bagging 通常对分类任务使用简单投票法，对回归任务使用简单平均法。Bagging 的算法如图 13 所示：

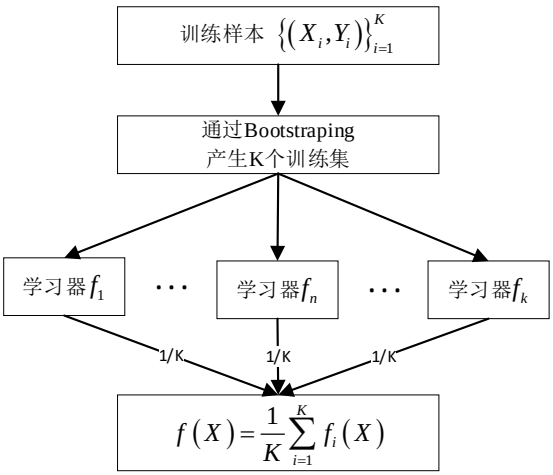


图 13 Bagging 算法示意图

训练一个 Bagging 集成与直接使用基学习算法训练一个学习器的复杂度同阶，这说明 Bagging 是一个很高效的集成学习算法。Bagging 主要关注降低方差，因此它在不剪枝决策树、神经网络等易受样本扰动的学习器上效用更加明显。

而 Boosting 是一族可将弱学习器提升为强学习器的算法。这族算法的工作机制类似：先从初始训练集训练出一个基学习器，再根据基学习器的表现对训练样本分布进行调整，使得先前基学习器做错的训练样本在后续受到更多关注，然后基于调整后的样本分布来训练下一个基学习器；如此重复进行，直至基学习器数目达到事先指定的值 T，最终将这 T 个基学习器进行加权结合。从偏差-方差分解的角度看，Boosting 主要关注降低偏差，因此 Boosting 能基于泛化性能相当弱的学习器构建出很强的集成。

本节将利用前述预处理的数据分为训练集与测试集（严格来说这里的测试集应该是用来调整超参数的验证集，下文不再指出）来探究 Bagging 中的代表性算法随机森林(Random Forest)以及 Boosting 中的梯度提升树 GBRT，XGBoost 以及 Lightgbm 算法的回归性能。

5.2.1 梯度提升回归树（GBRT）

梯度提升回归树（GBRT）是一种 Boosting 集成学习方法[5]。GBRT 利用损失函数的负梯度在当前模型的值作为回归问题提示树算法中的残差近似值。梯度提升树的泛化能力和表达能力都很好，具有较好的可解释性和鲁棒性，能够自动发现特征之间的高阶关系，并且不需要对数据进行归一化等处理。GBRT 的算法流程如图 14 所示，其在初始化时估计使损失函数极小化的常数值，它是只有一个根节点的树，然后计算损失函数的负梯度在当前模型的值，将它作为残差的估计，利用该值来估计回归树叶节点区域，以拟合残差的近似值；再利用线性搜索估计叶节点区域的值，使损失函数极小化，然后再更新回归树，最后将模型融合得到最终的输出模型。GBRT 允许优化任意可微的损失函数。

输入： 训练数据集

$T=\{(x_1,y_1),(x_2,y_2),...,(x_N,y_N)\},x_i\in \mathrm{X}\subseteq R^n,y_i\in Y\subseteq R,i=1,2,...,N$

最大迭代次数M，损失函数$L(y,f(x))$

输出： 回归树

步骤：

1、初始化

$$f_0(x)=\arg\min_c\sum_{i=1}^{N}L(y_i,c)$$

2、对$m=1,2,...,M$

2.1、对$i=1,2,...,N$计算

$$r_{mi}=-\left[\frac{\partial L(y_i,f(x_i))}{\partial f(x_i)}\right]_{f(x)=f_{m-1}(x)}$$

2.2、对r_{mi}拟合回归树，得到第m棵数的叶结点区域$R_{mj},j=1,2,...,J$

2.3、对$j=1,2,...,J$计算

$$c_{mi}=\arg\min_c\sum_{x_i\in R_{mj}}L(y_i,f_{m-1}(x_i)+c)$$

2.4、更新

$$f_m(x)=f_{m-1}(x)+\sum_{j=1}^{J}c_{mj}I(x\in R_{mj})$$

3、得到回归树

$$\hat{f}(x)=f_M(x)=\sum_{m=1}^{M}\sum_{j=1}^{J}c_{mj}I(x\in R_{mj})$$

图 14 GBRT 算法流程图

我们调用 sklearn 库中的相应函数对该前面所处理好的题目一的特征与标签进行训练与测试，其主要参数是迭代次数、学习率，学习率指的是每次更新时对残差的关注程度，学习率通常与迭代次数一同变化，就像神经网络的梯度下降里的迭代与学习率一样。我们在算法中指定 Huber 损失函数来优化，为从算法中我们可以看到由于 GBRT 不断学习残差，因此随着给定最大迭代次数也即回归树的最大数量M的提高，其最终能在训练集上达到很好的精度，因此为观察该算法以及训练得到的模型的泛化性变化，我们以题述给定的计算公式为评价标准，其最高得分为 1，我们先固定学习率，观察算法随回归树数量增多性能在训练集与测试集上的变化，如图 15 所示。

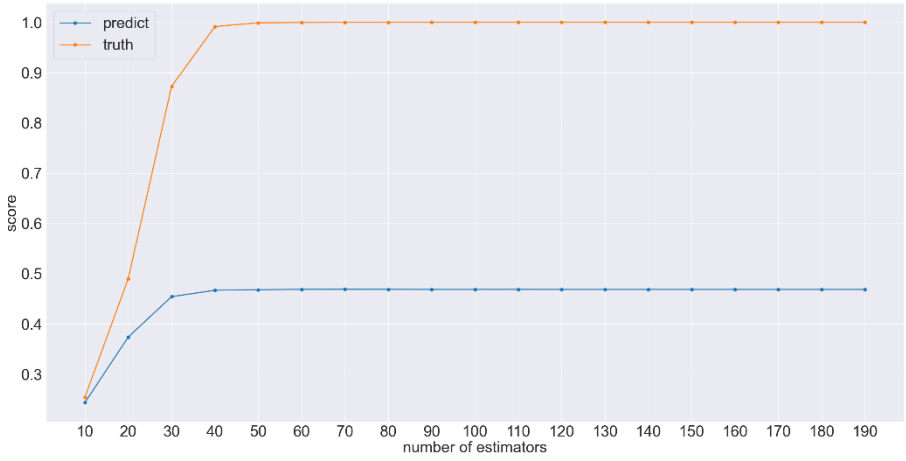


图 15 模型精度与回归树数量变化曲线

可以看到随着子回归器数量的增多，GBRT 模型先同时在训练集与测试集上精度不断上升，但是当超过一定数量时（本次测试为 40），训练精度几乎就已经能完全拟合训练数据集，而测试精度也已达到极限几乎不再提升，且两者有着较大的差异，这表示模型出现了严重的过拟合现象，回归器学习到了训练集上独特的特征，导致模型的泛化性能无法上升，不具有通用性。

为此我们控制 GBRT 模型中单个回归树所允许的最大深度，由于回归树的拟合能力与其复杂程度成正比，树的深度则表明其分支越多，更加具有特性而失去通用性，当限制其最大深度后会很有效的避免过拟合现象，训练与测试精度变化如图 16 所示。

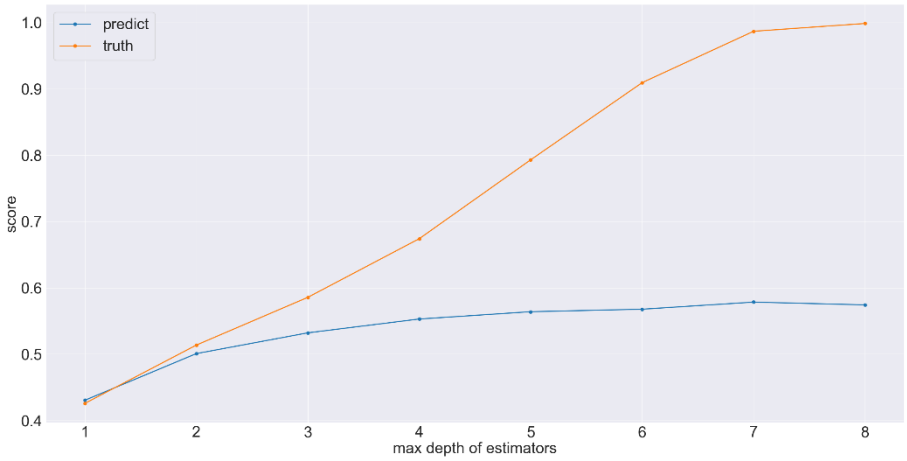


图 16 精度随最大深度变化曲线

可以看到该曲线与刚才的曲线走向相同，在深度较小时训练精度与预测精度相差不大，但增加深度之后出现了很严重的过拟合，由于深度从 4 到 5 时虽然测试精度有些许上升但过拟合程度大幅加深，因此我们将单个回归树最大深度控制在 4，此时模型仍具有不错的测试得分。同样接下来我们控制单个回归树分割一个内部节点所需的最小样本数，以及每个叶结点上所需的最小样本数，该参数表示只有当每个左右分支都有规定的最小训练样本数时，分割才会被进行，因此其可以限制模型的复杂程度，产生平滑模型的效果，减轻过拟合现象。

我们将单个回归树最大深度控制在 5，同时限制单叶结点最小样本数以及最小样本分割数，使用较大的回归树数目以期望在不太减小测试精度的同时保证模型的泛化能力，减少过拟合程度。下图 17 显示了模型在部分样本上预测值与准确值的比较。

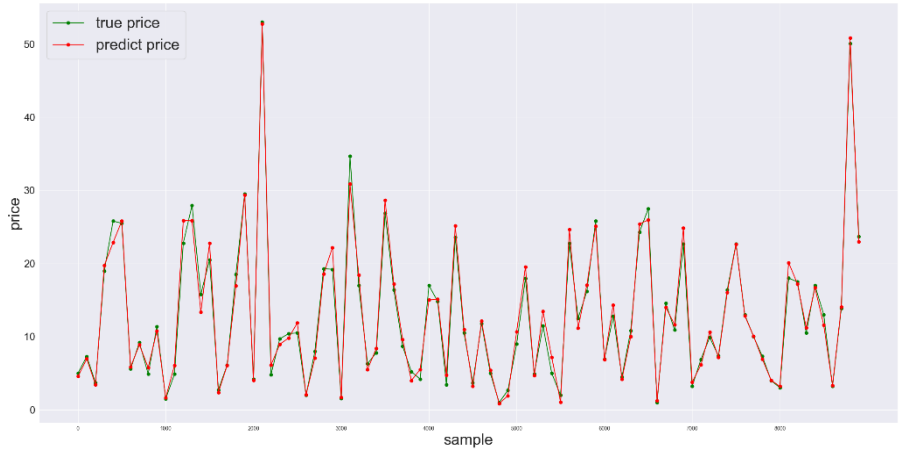


图 17 预测价格与准确价格比较图

可以看到模型具有不错的测试精度，预测价格与真实交易价格平均只差 870 元，具有很好的指导意义；训练与测试得分分别为 0.581 与 0.526，这表示模型的过拟合得到了很好的缓解。

5.2.2 随机森林

随机森林法 (Random forest, RF) 是由美国科学家 Leo Breiman 于 2001 年发表的一种机器学习算法，融合了 Breiman 本人在 1996 年提出的 Bagging 集成学习理论与 Ho 在 1998 年提出的随机子空间方法。其核心思想在于决策树 (Decision tree, DT) 与袋装采样 (Bagging) [6]-[7]。实际上，随机

森林是 Bagging 的一个扩展变体，其在以决策树为基学习器构建 Bagging 集成的基础上，进一步在决策树的训练过程中引入了随机属性选择。决策树的本质是一种树状分类器，而袋装抽样法则是一种常见的用于减少统计学习方法方差的处理手段。在训练过程中，决策树由原始数据集的抽样样本独立构建得出，并使用预测模型子集中的最佳变量对每个节点进行分离。对于分类任务，随机森林的输出是大多数决策树选择的类；对于回归任务，则返回单个决策树的平均值或平均预测值。

随机森林算法可以在分类的基础上进行回归分析，通过对样本分类的结果进行一定的运算，例如计算某一特征变量在内部所有决策树中重要性的平均值，可得到各个特征变量的重要性。特征的重要性反映了其对预测结果的影响程度，如果某一特征的重要性越大，那么该特征对预测结果的影响越大，反之，如果某一特征的重要性越小，那么该特征对预测结果的影响越小。因此我们也能通过特征重要性查看影响二手车售出价格的关键因素。

同样，由于随机森林是由多个子决策树在样本上自助采样训练得到的，每个子决策树并行训练，不存在相关关系，在回归任务中最后输出是每个决策树的输出的均值，因此随机森林的精确性、泛化性取决于单个决策树的大小和拟合能力。图 18 展示了该算法的训练得分与测试得分随子决策树数量的变化。

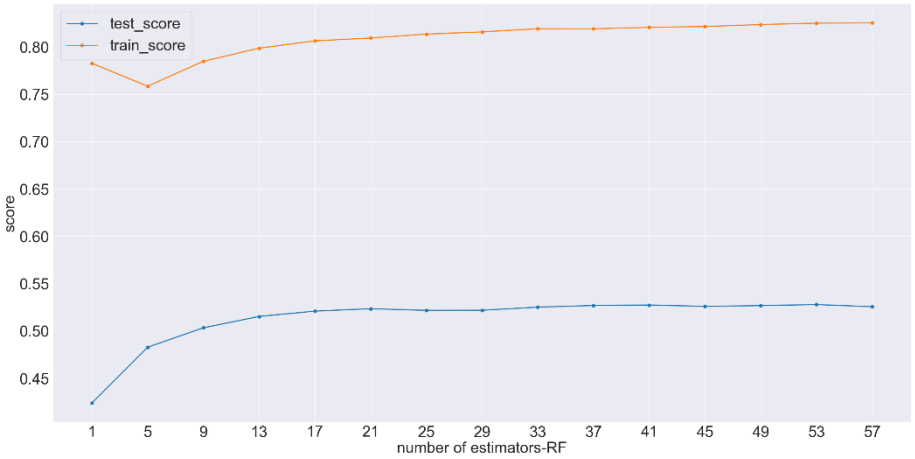


图 18 随机森林模型精度随回归树数量变化曲线

我们发现随着随机森林中基学习器即决策树的数量增多时，从一开始就表现出了很严重的过拟合现象，这意味着单个决策树在不限制最大深度的情况下已经可以对数据一中的训练集进行很大程度上的拟合，即拟合能力过强，而泛化性太差，因此我们继续观察如果限制单个决策树的最大深度会对模型拟合产生的影响，如图 19 所示。

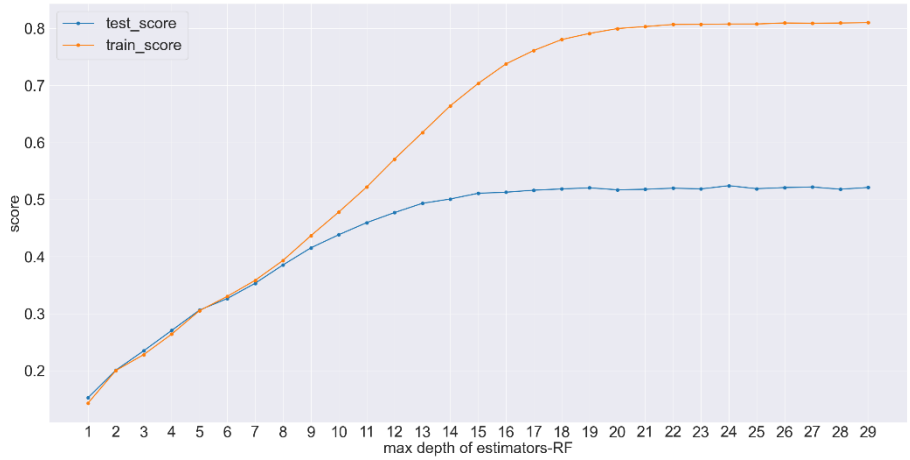


图 19 模型精度随最大深度变化曲线

此外控制每次 bootstrap 选取的样本数量以及寻找最佳分割时要考虑的特征数量也是很有效地控制过拟合的手段，这会给训练引入随机性，避免模型关注很强的特性信息，由于各参数具有很强的

耦合性，考虑到随机森林具有并行性训练较快，于是在上述先验知识下我们调用网格搜索函数在指定的参数范围内进行参数的选择，利用调整的参数训练学习器，从所有参数中找到在验证集上精度最高的参数，一般与 k 折交叉验证共同搭配，来保证选择参数的性能稳定性，首先利用训练集对学习进行训练，再利用测试集来测试得到的模型，以此来作为评价性能的指标。使用交叉验证取得分均值作为模型的评价指标来进行比较，以减少数据分割带来的随机性和偏差，更加展现模型的鲁棒性。

参数范围的选择需要考虑过拟合问题。最终选取基学习器数量为 24，最大深度为 15，在寻找最佳分割时最大考虑 80%的特征，此时训练与测试得分分别为 0.51 与 0.67，可以发现随机森林回归性能不如梯度提升回归树，图 20 显示了模型在部分样本上预测值与准确值之间的差距。

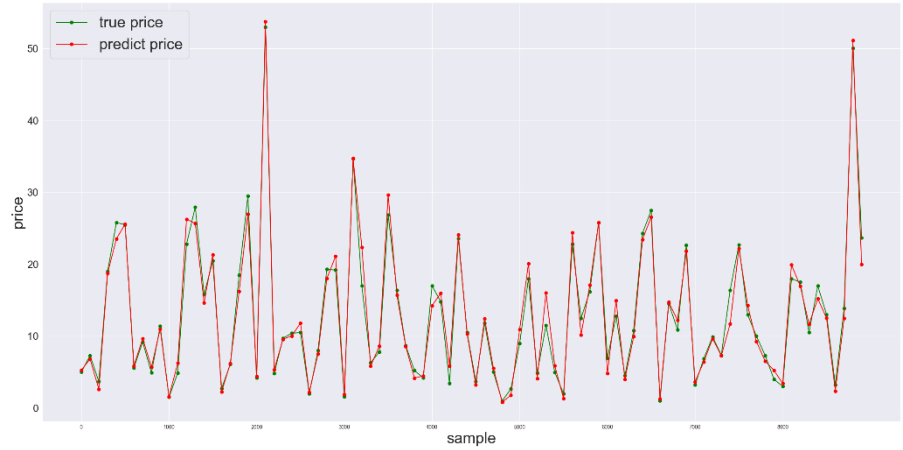


图 20 预测价格与准确价格比较图

5.2.3 XGBoost

XGBoost 是对 GBDT 的改进，适用于分类和回归问题[8]。原始的 GBDT 基于经验损失函数的负梯度来构造新的决策树，只能在决策树构造完后进行后剪枝。而 XGBoost 直接在构建阶段就加入了正则项。此外，GBDT 在梯度下降时使用了代价函数的一阶导数，而 XGboost 对代价函数进行二阶泰勒展开，可以同时使用一阶导数和二阶倒数；GBDT 在每轮迭代时使用全部数据，而 XGBoost 则采用了与随机森林相似的策略，对数据进行采样。此外 GBDT 等算法难以并行，效率很低。

从图 14 GBDT 的算法图中可以知道，其利用的是损失函数的一阶导数用于计算残差完成拟合，而 XGBoost 则利用二阶泰勒公式作为近似值。

作为 Boosting 的一员，我们仍然首先关注 XGBoost 回归模型训练和预测精度与基学习器数量之间的关系，如图 21 所示。

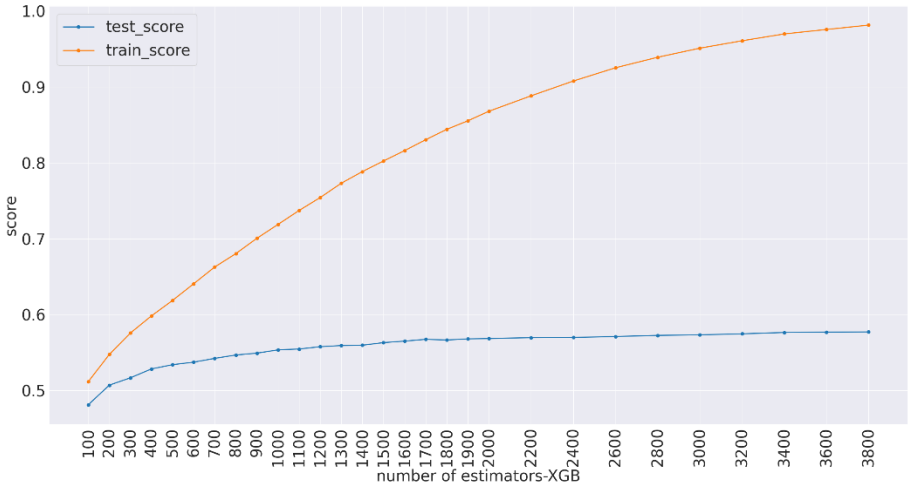


图 21 模型精度随回归树数量变化曲线

在图示的学习器数量范围内，模型的训练与测试精度均在不断上升，不同的只是训练精度上升较快且对训练集拟合得很好，而测试精度则相对上升较为平缓，过拟合程度不断加深，对 XGBoost 来说重要的降低过拟合参数为构建每个树所用的的子样本数和特征数目，这会使每个基学习器的拟合能力降低。其次 L1 与 L2 正则项也是常用限定权重大小的方法，类似于剪枝，降低模型的复杂度，此外当然还有控制树的最大深度，如图 22 所示。

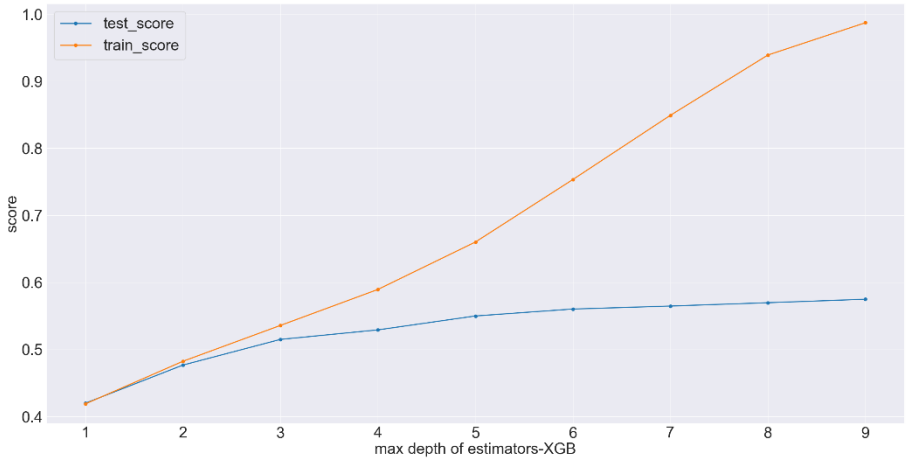


图 22 模型精度随最大深度变化曲线

最大深度在 5 之后时测试精度增加趋于缓和，过拟合变得严重，因此我们将基学习器最大深度设置为 5，下一步我们通过引入两个正则项以及限定构建基学习器时使用的样本数量和特征数量来进一步缓解过拟合现象，最终模型训练与测试得分分别为 0.578 与 0.532，相比之下直接将最大深度设置为 4 的训练与测试得分为 0.589 与 0.529，测试精度和泛化性都有了些许的改善。相应的部分样本上预测价格与真实交易价格对比如图 23 所示。

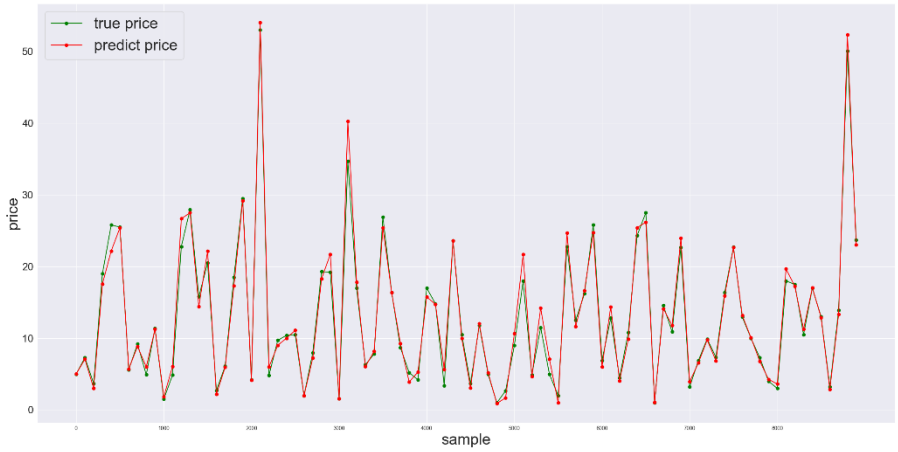


图 23 预测价格与实际价格比较图

5.2.4 LGBM

GBDT 和 XGBoost 作为传统的 boosting 算法，需要对每一个特征都要扫描所有的样本点来选择最好的切分点，非常的耗时。为了解决这种在大样本高纬度数据的环境下耗时的问题，Lightgbm 使用了如下两种解决办法：一是 GOSS（Gradient-based One-Side Sampling, 基于梯度的单边采样），即不是使用所用的样本点来计算梯度，而是对样本进行采样来计算梯度；二是 EFB（Exclusive Feature Bundling，互斥特征捆绑），这里不是使用所有的特征来进行扫描获得最佳的切分点，而是将某些特征进行捆绑在一起来降低特征的维度，使寻找最佳切分点的消耗减少。这样大大的降低的处理

样本的时间复杂度，但在精度上，通过大量的实验证明，在某些数据集上使用 Lightgbm 并不损失精度，甚至有时还会提升精度[9]。

GOSS 与 EFB 算法的伪代码如下图所示，其中 GOSS 在每次迭代时根据样本点的梯度的绝对值对它们进行降序排序，对排序后的结果选取前 a*100%的样本生成一个大梯度样本点的子集，再对剩下的样本集合（1-a）*100%的样本，随机的选取 b*（1-a）*100%个样本点，生成一个小梯度样本点的集合；然后将大梯度样本和采样的小梯度样本合并，其中将小梯度样本乘上一个权重系数$\frac{1-a}{b}$，使用上述的采样的样本，学习一个新的弱学习器，之后就是不断地重复上述步骤直到达到规定的迭代次数或者收敛为止。从描述中可以看出当 a=0 时，GOSS 算法退化为随机采样算法；当 a=1 时，GOSS 算法变为采取整个样本的算法。由于这种的选择，使得 GOSS 算法模型精确度既高于随机采样算法，也将会增加弱学习器的多样性，从而潜在的提升了训练出的模型泛化能力。

Input: I: training data, d: iterations
Input: a: sampling ratio of large gradient data
Input: b: sampling ratio of small gradient data
Input: $loss$: loss function, L: weak learner
models ← {}, fact ← $\frac{1-a}{b}$
topN ← a × len(I) , randN ← b × len(I)
for $i = 1$ ***to*** d **do**
  preds ← models.predict(I)
  g ← $loss$(I, preds), w ← {1,1,...}
  sorted ← GetSortedIndices(abs(g))
  topSet ← sorted[1:topN]
  randSet ← RandomPick(sorted[topN:len(I)], randN)
  usedSet ← topSet + randSet
  w[randSet] × = fact ▷ Assign weight $fact$ to the small gradient data.
  newModel ← L(I[usedSet], − g[usedSet], w[usedSet])
  models.append(newModel)

Input: F: features, K: max conflict count
Construct graph G
searchOrder ← G.sortByDegree()
bundles ← {}, bundlesConflict ← {}
for i ***in*** *searchOrder* **do**
  needNew ← True
  for $j = 1$ ***to*** *len(bundles)* **do**
    cnt ← ConflictCnt(bundles[j],F[i])
    if *cnt + bundlesConflict[i]* $\leq K$ **then**
      bundles[j].add(F[i]), needNew ← False
      break
  if *needNew* **then**
    Add $F[i]$ as a new bundle to *bundles*
Output: *bundles*

图 24 GOSS(左)与 EFB(右)伪代码[参考文献]

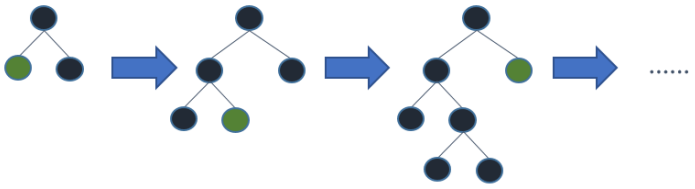


图 25 leaf-wise growth

LightGBM 通过 leaf-wise 策略来生长树。每次从当前所有叶子中，找到分裂增益最大的一个叶子，然后分裂，如此循环。因此同 Level-wise 相比，在分裂次数相同的情况下，Leaf-wise 可以降低更多的误差，得到更好的精度。但是，当样本量较小的时候，leaf-wise 可能会造成过拟合。 所以，LightGBM 可以利用限制树的深度来避免过拟合。

LightGBM 可以通过使用较小的学习率和较大的迭代次数以及使用较大的叶子数目来提高准确率，其模型精度随迭代次数的变化如图 26 所示，如前所述，lgbm 的训练与收敛速度都很快，很容易就能够完全拟合出训练集上的所有数据，但仍然存在着过拟合严重的问题，处理 lgbm 的过拟合问题主要从减少叶子数目、减少每个决策树的最大深度，设置 bagging 频率等相关参数结合 bagging 训练，设置每次训练时使用的子特征数目等。这里我们重点关注叶子节点数对模型的影响，在将迭代次数固定为 1000，此时模型随最大节点数的变化如图 27 所示。

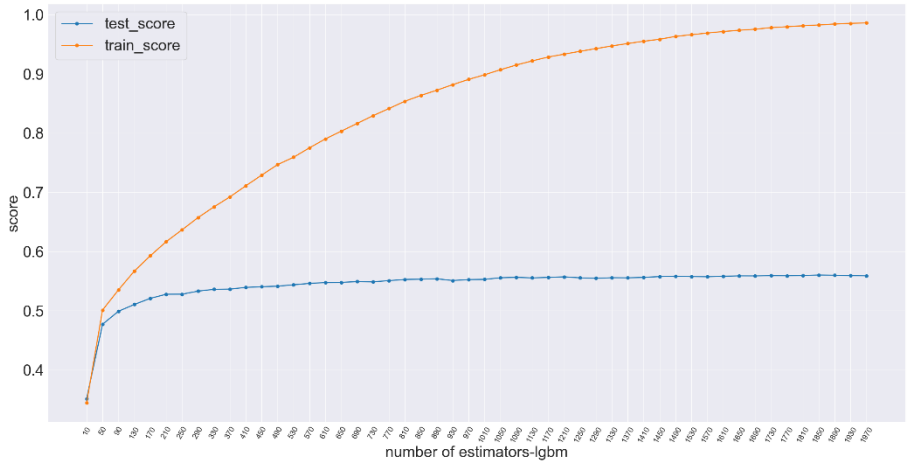


图 26 模型精度随回归树数量变化曲线

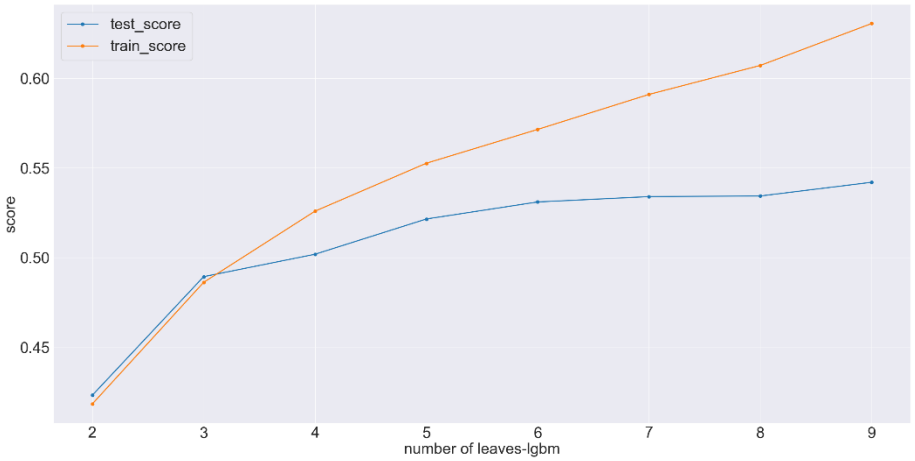


图 27 模型精度随节点数变化曲线

我们可以发现相当于随机森林与 XGBoost 回归模型，lgbm 可以在测试精度还不错的情况下同时保持过拟合程度也很小，我们选择绝对误差作为优化函数，在将叶节点数目设置为 3 的情况下，增大迭代步数，同时引入 bagging 与单次训练选择特征数目比例，最终的预测价格与真实交易价格对比如图 28 所示。

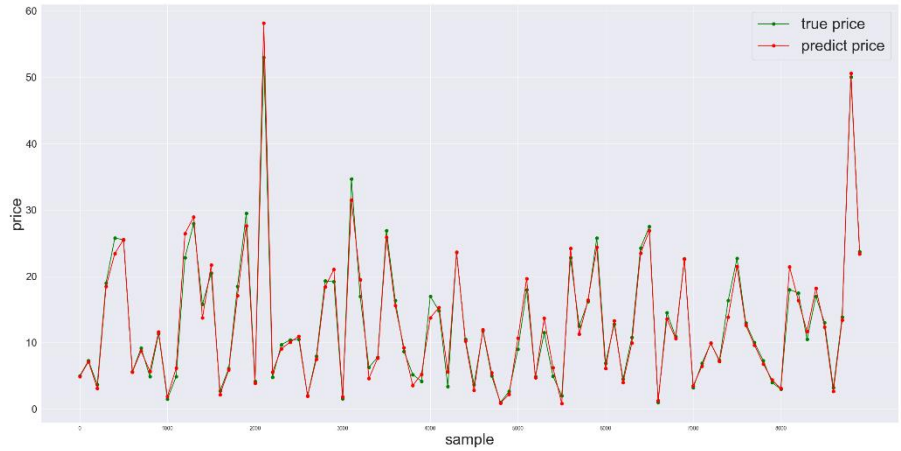


图 28 预测价格与实际价格比较图

5.3 基于多模型融合的回归模型建立

从上述分析可以看到，无论是简单的单个决策树还是集成学习的 Bagging 与 Boosting 中常用算法，都具备很好的拟合训练特征与标签之间的映射的能力，然而无一例外都出现了过拟合现象，通常来说由于数据中不可避免的存在误差，过拟合现象也就无法消除，减少过拟合是提升模型的泛化性能的必然要求，通过限制比如基学习器中的复杂程度，限制学习器个数，利用每次更新迭代时随机选取特征与样本来为模型带来更多的随机性，此外增大数据量也是十分有效的一种手段。本小节就上述得到的几种模型通过集成学习中的 Stacking 多模型融合策略来进一步提升模型预测精度。

Stacking 是一种类似与神经网络的框架结构，首先通过第一层多个在训练样本上独立学习的学习器来进行类似于特征提取的操作，再作为第二层的输入，供第二层学习器的训练以达到融合的效果。Stacking 的主要思想是取长补短，不同的强模型对于相同的数据以及数据分布都是从不同的角度出发的，将不同角度的数据进行汇总和学习，一般来说可以获得更好的结果，至少不会变差。一般来说第一层学习器通常采用学习能力比较强的模型，第二层使用弱学习器以减少过拟合的风险，经过测试我们确定了如图 29 的双层 Stacking 框架。

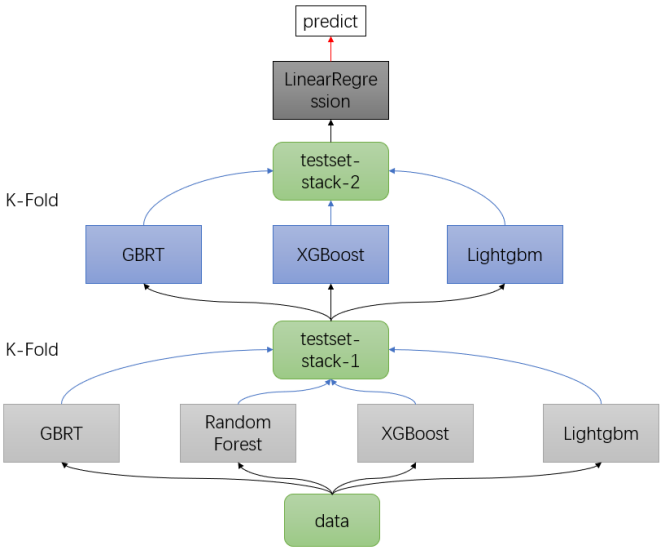


图 29 本节所用 stacking 框架

具体来说，我们第一层的回归器为前述的 GBRT、RF、XGBoost 以及 Lgbm，输入训练集数据，每个模型并行化训练，即分别在训练数据上做 k 折交叉验证，k 折交叉验证是一种常见的验证模型性能的统计分析方法，其基本思想是将输入数据分为 k 组，其中 k-1 组作为训练集，剩下的一组作为测试集。因此每个回归器都会进行 k 次训练，在每次训练完成后都对当前作为测试集的数据进行预测，最后将 k 次的预测值整合成当前模型的输出，也即第二层模型的输入，因此第二层一共有第一层回归器数量 4×k 个输入特征，第二层的三个回归器在此输入数据上进行学习，同样进行了 k 折交叉验证，并将预测结果输入给最后一层的简单线性回归分类器。至此模型训练过程完成，示意流程图可以参考图 30 两层的 Stacking 流程。

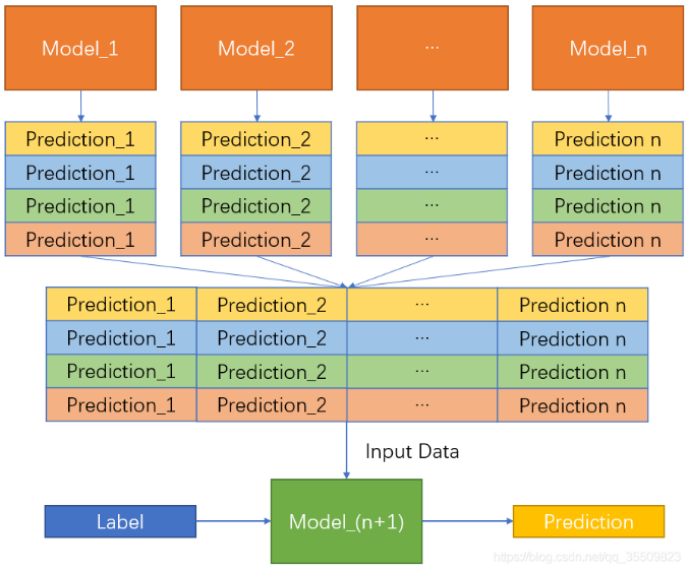


图 30 Stacking 训练流程

为了保证模型的稳定性，我们将第一层的 k 值设为 4，第二层则设置为 3。由于需要训练的模型和交叉验证次数很多，训练较为缓慢，最后模型在训练集和测试集上的得分分别是 0.667 与 0.572，测试精度均高于前述所有方法。图 31 显示了预测价格与真实交易价格之间的差距情况。可以看到我们在保证过拟合程度不太大的情况下提升了模型的预测精度，达到了泛化性和精确性的权衡，因此我们利用此模型对数据三进行预测并输出。

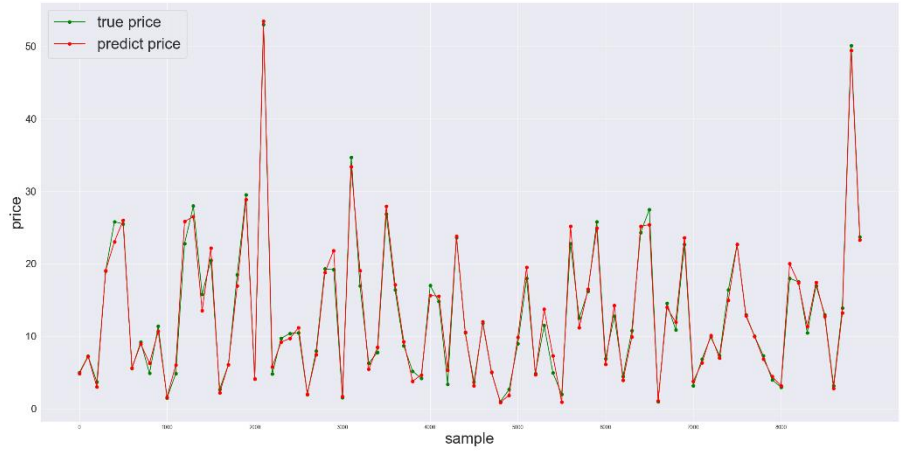


图 31 预测价格与实际价格比较图

6. 问题二

问题二要求我们结合门店的实际交易数据来确定影响车辆从上架到成交的时间长度的关键因素、结合这些关键因素采取哪些有效的手段，以及这些手段的使用条件和预期效果。同问题一一样，我们首先对数据进行异常值检验、缺失值填补、标准化等，然后训练模型来得到影响模型的特征重要性排序，最后再重新在这些特征上做车辆成交周期的回归预测，来探究各个特征的变化对成交周期长短的影响。

6.1 数据预处理

同问题一相同，我们首先仔细查看提供的数据，统计各个特征的缺失情况，如图 32 所示。

```
0   carid                10000 non-null  int64
1   pushDate             10000 non-null  object
2   pushPrice            10000 non-null  float64
3   updatePriceTimeJson  10000 non-null  object
4   pullDate             10000 non-null  object
5   withdrawDate         8000 non-null   object
```

图 32 特征空值信息

可以看到只有第五列特征含有 20%的空值，由于题述成交车辆下架时间和成交时间相同，因此我们根据假设认为成交时间中为空值的数据即表示该二手车未完成售卖。由于我们需要获取二手车的成交周期，且一些二手车在上架之后不久由于定价太高而滞销，之后采取打折降价促销来最终卖出，因此我们将车辆成交时间减去最后一次修改定价时间得到的天数作为标签信息，此外由于题目要求探究影响成交周期的因素，所以我们删除这些未完成售卖的车辆信息。

之后我们通过 carid 在问题一提供的数据里来索引得到该车辆的其他补充信息，用问题一中同样的方法对补充信息数据剔除异常值、对缺失值进行填补，由于本题需要求解特征的重要性，因此在对类别特征做类别编码后不进行独热编码，最后将两个数据拼合在一起。在寻找异常值时，我们发现有 48 个二手车样本的实际售出价格高于对应的新车价格或者是二手车的上架价格高于新车价格，由于样本数较少，我们将这两种情况当作异常值，直接从数据中删除。

经过观察我们发现题目一数据中的特征 tradeTime 与题目二数据中的特征 updatePriceTimeJson 里最后一次修改定价时间相同，而实际交易价格 price 即为 updatePriceTimeJson 最后一次修改的定价，因此我们为了简化分析，删除该特征。此外我们将实际交易价格除以新车价作为新特征。

6.2 基于回归模型和灰色关联分析的关键因素提取

车辆的成交周期是一个错综复杂的问题，其受到各方面因素的影响，比如销售的谈判技巧，车辆本身的好坏，价格是否公道，市场是否景气等因素。对于本题我们仅依靠所提供的数据进行分析。同样我们首先观察各特征之间以及特征与标签之间的相关系数，即公式 4，在统计学中，通常用相关系数描述两个变量之间的相关程度，它是研究变量之间线性相关程度的量，当相关系数为 0 时通常认为两变量之间不存在线性关系，但并不能排除其是否存在其他关系。相关系数矩阵的热力图如图 33 所示。

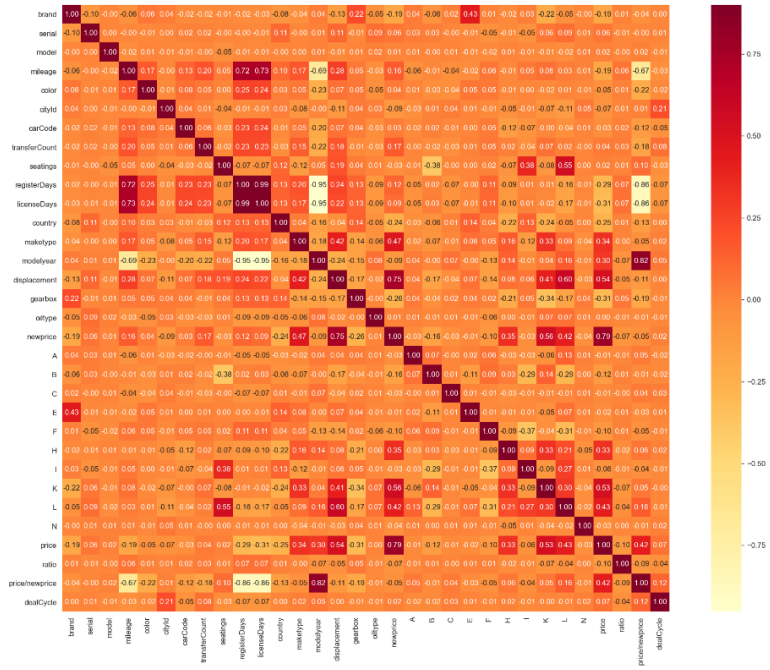


图 33 特征相关系数矩阵

从图中可以看到年款 modelyear、注册总天数 registerDays、上牌总天数 licenseDays 三者之间具有很强的线性关系，这符合逻辑，因为注册和上牌时间常常与车的年款相近，即购买当年的新车型，而注册时间一般和上牌时间很接近，故保留 licenseDays，删除 registerDays、modelyear 特征。此外可以看到售出价格与新车价的比值和 licenseDays、registerDays 以及里程数 mileage 都呈现反比关系，因为如果二手车持有时间长、总行驶路程即里程数多的话，车辆贬值越严重，所以为反比的关系。

重点关注特征与交易周期之间的关系时，我们发现除了城市 cityid 以及售出价格与原价的比值与交易周期有较弱的线性关系之外，其它特征几乎不存在线性关系。

为了探究各特征与成交周期之间的非线性或者隐含关系，我们考虑了将回归模型的特征重要性排序与灰色关联度分析相结合，综合评判各特征的重要性。

1) 回归模型

我们知道在构建诸如上章所述的梯度提升决策树、XGBoost 等集成模型时，模型总是会通过对训练数据的学习不断去优化自己的输出，具体来说，作为基学习器的决策树在损失函数的指导下会自动调整和利用更加利于达到好的拟合效果的特征来进行分支等，因此我们可以通过训练一个强学习器，让其通过这些特征学习到成交周期的非线性关系，尽管可能不具备很好的泛化性，但我们有理由相信对该回归模型的建立起着很大作用的特征本身与成交周期有着密切的关系。所以我们利用处理好的特征数据，以成交周期为标签，建立 XGBoost 回归模型，随着迭代次数的增大，算法在训练集上的均方根误差不断减少，如图 34 所示。

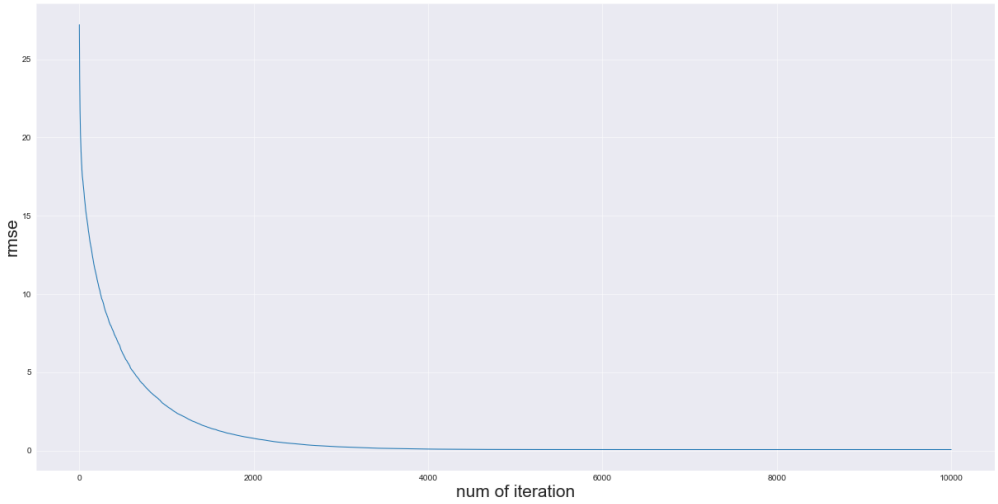


图 34 模型损失函数随迭代的变化

可以看到 XGBoost 回归模型在训练集上取得了不错的拟合效果，我们以基决策树使用该特征时的信息增益作为重要性的依据，所有特征对该模型贡献重要性排序如图 35 所示。

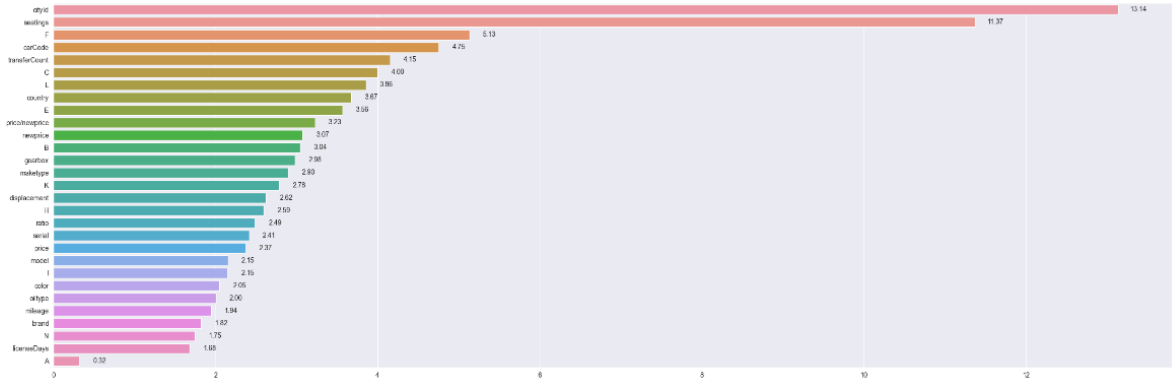


图 35 各特征重要性排序

可以看到排名靠前的有城市 cityId，车辆座位类型 seatings，国标码以及过户次数等。

2) 灰色关联度分析

灰色关联度分析（Grey Relation Analysis，GRA），是一种多因素统计分析的方法[10]，是指对一个系统发展变化态势的定量描述和比较的方法，其基本思想是通过确定参考数据列和若干个比较数据列的几何形状相似程度来判断其联系是否紧密，它反映了曲线间的关联程度。简单来讲，就是在一个灰色系统中，我们想要了解其中某个我们所关注的某个项目受其他的因素影响的相对强弱，也就是说：我们假设已经知道某一个指标可能是与其他的某几个因素相关的，那么我们想知道这个指标与其他哪个因素相对来说更有关系，而哪个因素相对关系弱一点，依次类推，把这些因素排序，得到分析结果，我们就可以知道我们关注的这个指标与因素中的哪些更相关。

常规的灰色关联度的计算如下式：

$$\xi_i(k)=\frac{\min\limits_s\min\limits_t|x_0(t)-x_s(t)|+\rho\max\limits_s\max\limits_t|x_0(t)-x_s(t)|}{|x_0(i)-x_i(i)|+\rho\max\limits_s\max\limits_t|x_0(t)-x_s(t)|} \tag{6}$$

$\xi_i(k)$为比较数列 x_i 对参考数列 x_0 在第 k 个指标上的关联系数，其中 $\rho\in[0,1]$ 为分辨系数，一般而言分辨系数越大，分辨率越大，分辨系数越小，分辨率越小。对该列所有 $\xi_i(k)$ 求和便得到灰色关联度，通过比较灰色关联度的大小便可对各特征进行相关度排序。计算出来的灰色关联度矩阵热力图如图 36 所示。

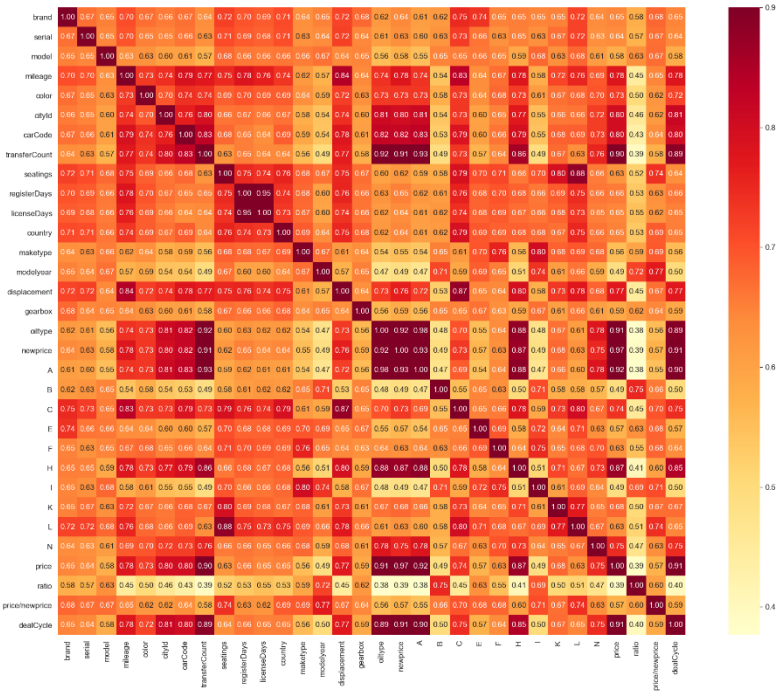


图 36 灰色关联度矩阵热力图

接下来我们对通过回归模型得到的各因素重要性排名及分数以及灰色关联度综合进行分析。为了更大程度地保留各特征之间的差距且考虑到两列值的大小不同，我们将两列指标同时除以指标内的最小值之后的乘积作为最终的评判标准。即

$$criterion_k=\frac{score_k}{\min(score)}*\frac{grey_corr_k}{\min(grey_corr)} \tag{7}$$

各特征表现如图 37 所示。

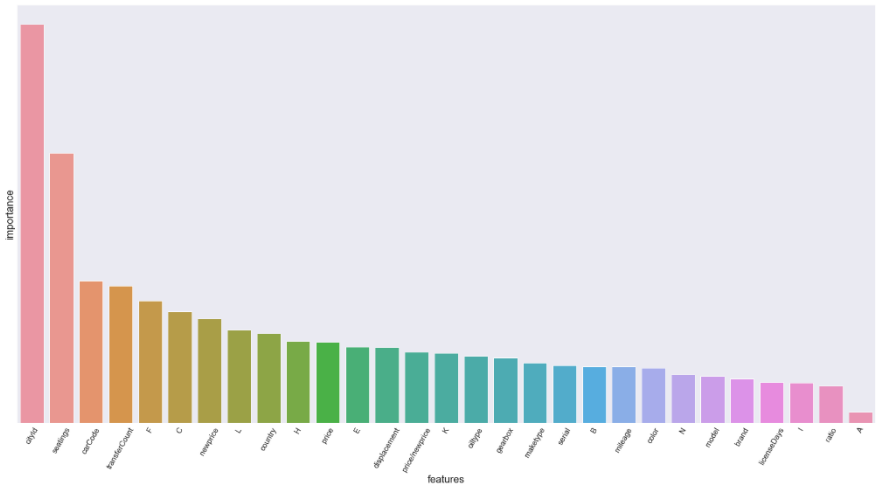


图 37 特征重要性排序

我们可以看到从综合评判来看，当定价处于合适的区间时，对车辆成交周期影响最关键的因素分别是车辆所在城市 Id，车辆的载客人数，国标码以及过户次数等，其后新车价与售卖车价同样有着一些影响。由于前三个因素为类别特征，本文继续深入分析城市和载客人数对成交周期的影响。首先我们查看 cityId、carCode 以及的 seatings 统计条形图。

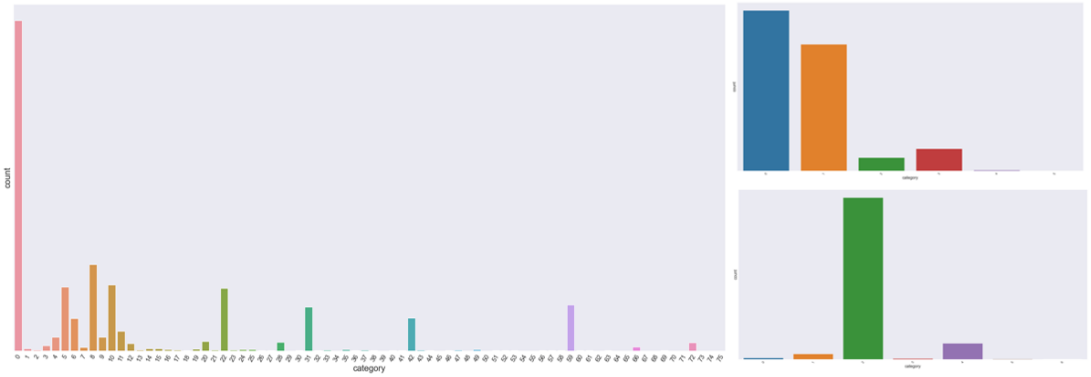


图 38 cityId(左)、carCode(右上)、seatings(右下)

根据分析，我们认为大、中、小城市的贸易流通、市场情况、居民收入水平以及其它一些因素是使得城市成为最影响成交周期的关键。接下来我们统计样本中每个 cityId 内的平均成交周期，由于 cityId 的重要性相对较高，因此具有一定的指导意义，如图 39 所示，可见在比如 cityId 为 50，67，71，73 的城市成交周期相对较短，若在这些地方出售可能会缩短二手车交易的成交周期。因此，二手车线下零售门店应该在落地经营之前就对城市及区域的相关因素进行市场调研分析，做好充分的选址规划。例如，根据城市区域内车主的生活特性、消费习惯等，城市区域内的人口结构，如年龄、性别、职业、文化程度、人口密度、增长速度等，城市区域内家庭户数及构成，城市区域内消费者的消费收入水平和消费水平、消费意识和购买力等，选择车辆保有量不是太高但对具有一定二手车需求和购买力的城市区域，从根本上保证二手车交易客户群体的数量。总之，二手车线下零售门店可以根据车流原则找到聚客点，根据目标市场原则瞄准当地车主人群，选择商圈、社区的密度合适、配套规范成熟的城市区域，将店面努力打造为所在城市的招牌地标之一。

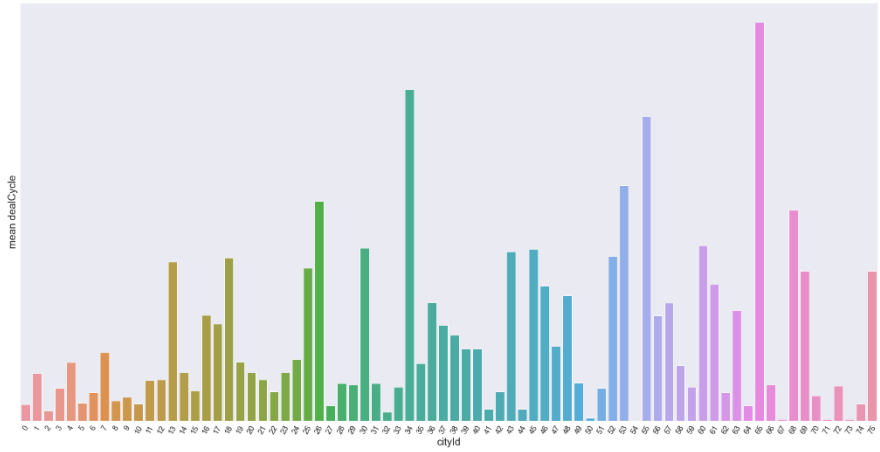


图 39 cityId 内平均成交周期

同样对于车辆的载客数量，从图 40 可以看出载客人数为 3 的二手车成交周期最短，据分析可能是由于大家对作为代步的二手小轿车更加青睐，而像载客人数为 0（如不能载人的货车等）就会有相对较长的成交周期，因此二手车交易平台应当对于具有不同载客数量的车辆更加合理地定价，并根据目标客户的需求个性化地进行推荐与展销，或者适时地采用降价促销等方式，稳定相对易销的小型私家二手车的成交周期，加速相对滞销的门店在库的二手车销售速度。

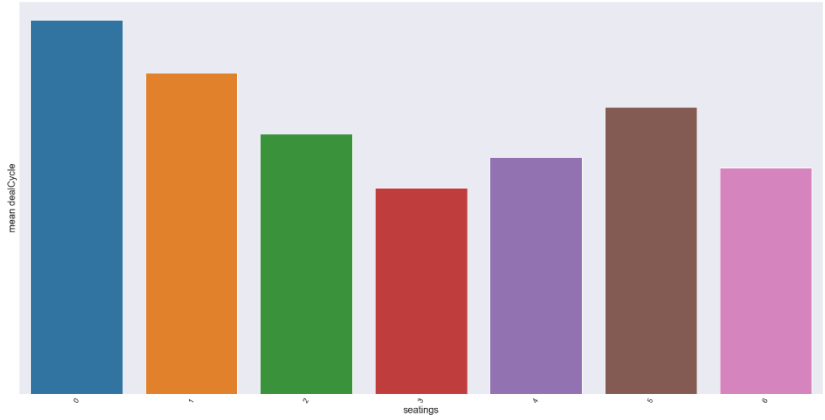


图 40 载客人数平均成交周期

值得注意的是我们观察到特征 ratio

$$ratio = (pushPrice - price) / pushPrice \quad (8)$$

即上架以后到最后售出这两个价格之间的比例，也就是平台的降价幅度似乎对没有起到很重要的影响，我们分析可能原因之一是降价幅度基本上很小，使得车辆的价格仍然在消费者的预期价位之内，没有更多地起到刺激作用，因此可以看出消费者对二手车价位也有一定的了解和知识储备。

7. 问题三

此问为开放问题，我们观察到上述问题二关注的是已成交二手车的信息，即把未成交的 2000 个二手车样本剔除，且由于成交周期的影响因素十分复杂，难以学习到泛化性好的回归模型。因此我们可以利用这些被剔除的信息，将二手车是否卖出，也就是是否完成交易作为标签信息用于根据车辆给定信息判断卖出情况的二分类问题。在这个二分类问题上，我们首先应该把平台最后一次修改后的价格作为车辆的价格特征，重点提取出二手车的使用时长、里程数、过户次数等其它车辆本身信息，以及上述可能对二手车能否卖出有很大影响的外界因素如所在城市等信息。

我们的思路是挑选 BP 神经网络 (Back Propagation Neural Network) 由 Rumelhart 和 McClelland 为首的科学家于 1986 年提出，是一种按照误差逆向传播算法训练的多层前馈神经网络，也是目前神经网络中应用最广泛的模型。BP 神经网络是由大量简单神经元相互连接构成的复杂网络，在单层基础上可以构造多层，典型的三层 BP 神经网络通常由输入层、隐藏层（中间层）与输出层这 3 层组成，如图 41 所示，其中，输入层中神经元的个数与特征数相关，输出层的个数与类别数相同，隐藏层（中间层）的层数与神经元数均可自定义。

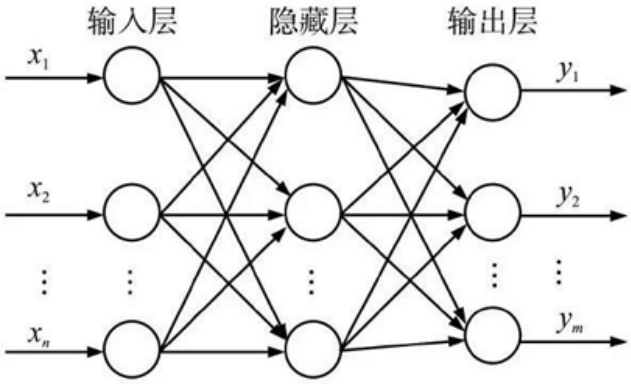


图 41 三层神经网络结构示意图

在搭建 BP 神经网络的过程中，输入层至隐含层的权值与阈值、隐含层至输出层的权值与阈值和隐含层中的神经元数量会对神经网络的计算速度与计算结果产生明显的影响。BP 神经网络模型使用了优化技术中的梯度下降法，将一组输入输出样本的函数问题转变为非线性优化问题，即这个输入到输出的映射是一个高度非线性映射。

我们将处理好的数据利用 BP 神经网络训练，以交叉熵损失函数为指导，基于 mini batch 进行梯度下降、权重更新，小批量使得更新更加平滑，MLP 随着节点数的增多容易出现过拟合现象则可以通过权值衰退和 dropout 等手段来缓解，同样权重初始化也对模型收敛有着很大的影响，可以考虑结合现代寻优算法如遗传算法或者粒子群算法来对权重进行初始化。二分类任务比成交周期的直接回归预测要简单，因此我们可以利用该分类模型来预测车辆是否能够卖出，相应地我们也可以调整一些参数查看对结果的影响，从而可以指导二手车交易平台更合理地挑选车辆与获得最大收益。

8. 模型评价

8.1 优点

本文在问题一中基于集成算法中的 Bagging、Boosting 以及 Stacking 框架分别建立了基于随机森林、梯度提升树、XGBoost 以及 Lightgbm 的回归模型，探究每个模型在数据集上的性能，调整参数保证精度的同时减少过拟合的程度，最后使用四种模型融合双层 Stacking 框架，进一步提升了预测的精度，且也确保了模型的泛化性能，融合效果优于单个模型的预测结果。问题一在数据处理中保留了原始数据的类别信息，采用独热编码减少人为标号带来的类间差异且拓展了特征维度，逐列填补缺失值，使得数据具有很好的完整性，模型也具有较好的鲁棒性。

在问题二中我们建立了基于回归模型与灰色关联度的关键因素提取模型，分别通过使用 XGBoost 回归模型在数据上训练得到各个特征对成交周期的影响因素，以及提取成交周期与各特征的灰色关联信息，相互验证，并将二者结果融合，使关键因素提取更加准确。

8.2 不足

1) 模型一中由于使用了大量的集成学习方法，模型复杂度较高，训练相对较慢。

2) 模型二中没有关注每次降价操作的时间节点信息，可能会漏掉某些待深入挖掘的规律。

3) 二手车交易价格预测以及成交周期分析错综复杂，本题提供的样本数据量较小，导致模型的精度不能继续提高，因此需要有更多的样本量进行模型的训练，进一步发挥多模型融合的长处。

参考文献

[1] 李幽,郑兴旺,薛建国.基于神经网络算法的二手商用车估价模型及应用系统的研究与实现[J].经营与管理,2019(11):63-70.

[2] 陈洞明.基于数学模型的二手车快速估价方法的研究[J].时代汽车,2019(18):144-146.

[3] 闫宏秀.数据挖掘与技术伦理学的内在路径构建[J].哲学动态,2019(08):95-101.

[4] Yuan S, Zhang Y, Tang J, et al. Expert finding in community question answering: a review[J]. Artificial Intelligence Review, 2020, 53(2): 843-874.

[5] Friedman J H. Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 2001, 29(5):1189-1232.

[6] Breiman L. Random forests[J]. Machine learning, 2001, 45(1): 5-32.

[7] Breiman L, Cutler A. Manual-setting up, using, and understanding random forests V4.0.2003[J]. Statistics Department, University of California Berkeley, CA, USA, 2002, 1(58).

[8] Chen T, Guestrin C. Xgboost: A scalable tree boosting system[C]//Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining. 2016: 785-794.

[9] 张旭东,钱仲文,沈思琪,石佳,逄金辉.一种基于 LSTM 与 LGBM 的电力负荷预测算法[J].系统工程,2019,37(01):152-158.

[10] 谭学瑞,邓聚龙.灰色关联分析：多因素统计分析新方法[J].统计研究,1995(03):46-48.