队伍编号	MCB2100868
赛道	A

基于机器学习的二手车价格预测与销售策略研究

摘 要

本文建立二手车估价模型，使得二手车电商进行快速准确地给二手车定价，制定营销补贴政策，提升二手车价值评估效率，分析影响车辆成交周期的关键因素，加快门店在库车辆的销售速度。

针对问题一，本文对“估价训练数据”进行分析，设置训练集和验证集构建模型，对“估价验证数据”进行预测。由于原始训练数据存在不规范性，首先进行**数据清洗**，包括对日期等非数值数据类型进行转换，处理缺失值和异常值，删除与预测目标无关列和重复列；在对原始数据进行清洗后，采用**特征工程**的方法对原始估价训练数据进行处理，包括对 price 和 newprice 进行对数化转换，对数据中的连续值特征归一化，对数据中的分类特征进行特征编码，对原始数据进行特征构造并进行嵌入式特征提取，以便增强模型的表达能力，获取更好的训练数据特征；在对数据清洗，进行特征处理后，得到一份经过处理的样本数据，再分别使用**随机森林**、**LightGBM** 和 **XGBoost** 模型，采取**五折交叉验证法**对样本数据进行拟合，得到各特征与二手车价格的关系，最后采取 **stacking 模型融合**的方法将上述三种模型的预测结果赋予不同权重，结合它们的优点建立最终预测二手车价格的模型。其中，stacking 融合模型根据模型评测标准在训练集的得分为 0.793，在验证集的得分为 0.636。

针对问题二，将门店交易数据根据 carid 索引“估价训练数据”表，将该表和“门店交易数据”合并为一个大表得到更多特征。此外，构造其他对成交周期天数产生影响的特征如**车辆成交季节**，**车辆降价的幅度**等。对原始数据中存在未成交的车辆，将它们的成交周期天数设为已成交车辆最大天数的两倍。采用基于惩罚项的特征选择方法，通过**逻辑回归**、**LASSO 回归**、**SVM 模型**得出影响成交周期的前五个重要性特征；采取基于树模型的特征选择方法，通过**随机森林**、**LightGBM**、**XGBoost 模型**得出影响成交周期的前五个重要性特征。通过**投票机制**选出 6 个模型中票数最多的前五个对成交周期影响的关键因素为 carid、车辆成交季节 transferCount、pushPrice 和车辆降价幅度。将选取的关键因素与成交周期做多元回归分析，得到对应因素调整对成交周期的影响的效果。根据关键因素加快车辆成交周期速度可分为**销售策略**类型的建议以及**对二手车的收购标准**的建议。销售策略有四个方面：将车辆从平均周期较大的城市转移到平均周期较短的城市，缩短的成交天数为城市间成交平均周期的时间差；在车辆出售淡季加大降价力度、提升降价的幅度，预期效果每降低 10% 价格，缩短 3.625 天；降低车辆上架价格，每降低价格 1 个单位，缩短 1.5 天。二手车的收购标准方面为降低收购过户次数较多的车辆比例，每减少过户次数一次，缩短 10.952 天。

针对问题三，需要依据给出的样本数据，提出值得研究的问题并给出思路。本文研究**季节因素**对二手车交易价格的影响，挖掘影响二手车**保值率**的关键因素。对于季节因素对二手车交易价格的影响，本文根据“估价训练数据”和“门店交易数据”获取每一辆二手车的成交时间和成交价格，再按照月份将成交时间划分为春夏秋冬四个季节，分别对四个季节的成交价格统计特征进行分析，得出夏季和秋季的成交总额较多，而夏季的成交额的平均值较少，春季、秋季和冬季成交额的平均值比较接近；对于影响二手车保值率的关键因素，本文分别采用**基于惩罚性的特征选择法**和**树模型的特征选择法**，对重要特征进行提取，再使用投票机制得到最终影响汽车保值率的关键因素，分别为新车价、二手车交易价格、上架价格、品牌 id、车系 id 和厂商类型。

关键词：特征工程、随机森林、LightGBM、XGBoost、stacking 模型融合、投票机制

目录

1 问题重述 1

1.1 问题背景 1
1.2 需要解决的问题 1

2 问题分析 2

2.1 问题 1 分析 2
2.2 问题 2 分析 2
2.3 问题 3 分析 3

3 模型假设 4

4 符号定义与说明 4

5 问题一模型的建立与求解 5

5.1 数据清洗 5
5.1.1 整体数据分析 5
5.1.2 对非数值数据类型进行转换 6
5.1.3 缺失值处理 6
5.1.4 异常值处理 7
5.1.5 删除与目标无关列和重复列 8
5.1.6 去掉可能影响预测的数据 8
5.2 特征工程 9
5.2.1 对 price 和 newprice 对数转换 10
5.2.2 归一化 10
5.2.3 特征编码 11
5.2.4 特征构造 11
5.2.5 嵌入式特征选取 11
5.3 模型的建立与求解 12
5.3.1 随机森林模型的建立 12
5.3.2 随机森林模型的检验 13
5.3.3 随机森林模型的参数调优 13
5.3.4 LightGBM 模型的建立 14
5.3.5 XGBoost 模型的建立 14
5.3.6 模型融合 15

6 问题二模型的建立与求解 16

6.1 数据的预处理 16
6.2 模型的建立 16
6.2.1 逻辑回归模型的建立 17
6.2.2 LASSO 回归模型的建立 17
6.2.3 SVM 模型的建立 17
6.3 模型的求解 17
6.3.1 关键影响因素的选取 17
6.3.2 多元线性回归衡量预期效果 18

6.3.3 建议与预期效果 18
7 问题三研究问题及求解思路 21
7.1 季节因素对二手车交易价格的影响 21
7.1.1 按照月份划分季节 21
7.1.2 统计每个季度二手车交易价格的特征 21
7.1.3 统计特征分析 22
7.2 影响二手车保值率的关键因素 22
7.2.1 二手车保值率计算 22
7.2.2 挖掘影响二手车保值率的因素 22
8 模型评价 24
8.1 模型的优点 24
8.2 模型的缺点及改进方向 24
参考文献 25
附录 26

1 问题重述

1.1 问题背景

随着我国机动车市场的不断发展，人均汽车保有量不断增加，个体消费观念的转变也让购买使用二手车的行为逐步被消费者接受，二手车市场也随之更加繁荣，其流通需求也越来越大。

目前国家并没有出台一个评判二手车资产价值的标准，同时二手车价格难以准确估计和设定，其不但受到车本身基础配置，如品牌、车系、动力等的影响，还受到车况如行驶里程、车身受损和维修情况等的影响，甚至新车价格的变化也会对二手车价格带来作用，因此二手车“一车一况”的特点决定了在实际工作中只能“一人一车”进行价值评估，而不能进行批量评估，这大大降低了评估效率。

在一个典型的二手车零售市场，二手车一般通过互联网等线上渠道获取用户线索，线下实体门店对外展销和售卖，也就是门店通过“买手”从个人或其他渠道收购二手车，然后由门店定价师销售，这同样需要制定合理的价格，使车辆受到消费者青睐。

为了使得二手车电商进行快速准确地给二手车定价，制定营销补贴政策，降低评估过程的人力成本，提升二手车价值评估效率，迫切需要一种科学准确的估价模型，用于评估二手车资产的价值，加快门店在库车辆的销售速度。

1.2 需要解决的问题

问题 1 选用合适的估价方法，构建模型预测二手车的零售交易价格。

该问题需要使用“估价训练数据”，设置训练集和测试集构建模型，并使用训练完成后的模型对“估价验证数据”进行预测，再根据模型评测标准，对预测结果进行评估。

问题 2 挖掘影响车辆成交周期的关键因素，加快门店在库车辆的销售速度。

该问题需要使用“门店交易训练数据”，对车辆的成交周期进行分析，结合“估价训练数据”挖掘影响车辆成交周期的关键因素，再根据这些关键因素采取行之有效的手段，加快门店在库车辆的销售速度，并给出这些手段的适用条件和预期效果。

问题 3 基于样本数据集，给出值得研究的问题及思路。

该问题需要在问题 1 和问题 2 的基础上，依据给出的样本数据集，给出二手车估价领域中值得研究的问题以及思路。

2 问题分析

2.1 问题 1 分析

该问题需要基于给定的二手车交易样本数据构建模型预测二手车的零售价格，数据包括车辆基础信息、交易时间信息、价格信息等 36 列变量信息，其中 15 列为匿名变量。

由于原始数据存在不规范性，因此首先需要进行数据清洗，包括对日期等非数值数据类型进行转换，处理缺失值和异常值，删除与预测目标无关列和重复列。在对原始数据进行清洗后，采用特征工程的方法对原始估价训练数据进行处理，把原始数据转变为模型的训练数据，以便获取更好的训练数据特征，再使用合适的模型对数据进行训练，利用训练完成的模型对验证数据进行预测，并分析模型预测结果的准确度。

在特征工程的处理上，由于大部分模型需要的数据要求符合正态分布，因此需要对某些特征信息进行对数化转换；对于数据中的连续值特征，为了消除不同字段量纲对最终模型的影响，需要对数据进行归一化；对于数据中的分类特征，原始数据的值跨越较大且有多种形式，但是只有数字类型才能进行计算，所以需要对各种特殊的特征值进行相应的编码；为了对数据进行充分利用，增强模型的表达能力，需要对原始的数据进行特征构造，经过构造新特征后会得到较多的特征，因此需要对特征进行提取，防止模型的过拟合。

在对数据进行缺失值处理，异常值处理，特征工程步骤后，得到一份经过处理的样本数据。再分别使用 LightGBM，XGBoost 和随机森林模型，采取五折交叉验证法对样本数据进行拟合，得到各特征与二手车价格的关系，最后采取模型融合的方法将上述三种模型的预测结果赋予不同权重，结合它们的优点建立起最终预测二手车价格的模型。

对于模型的评测标准，需采取如下公式进行计算：

$$0.2 * (1 - Mape) + 0.8 * Accuracy_5$$

其中，Mape 为平均相对误差：

$$Mape = \frac{1}{m}\sum_{i=1}^{m} Ape_i$$

Ape 为相对误差：

$$Ape = \frac{|\hat{y} - y|}{y}$$

真实值 $y = (y_1, y_2, \cdots, y_m)$，模型预测值为 $\hat{y} = (\widehat{y_1}, \widehat{y_2}, \cdots, \widehat{y_m})$；
$Accuracy_5$ 为 5%误差准确率：

$$Accuracy_5 = \frac{count(Ape \le 0.05)}{count(total)}$$

$count(Ape \le 0.05)$ 为相对误差 Ape 在 5%以内的样本数量，$count(total)$ 为样本总数量。

需要根据模型评测的计算标准，采用上述数据清洗、特征工程和模型训练的方法，使得评测标准的计算得分尽可能高。

2.2 问题 2 分析

该问题需要结合“门店交易数据”对车辆的成交周期进行分析，并挖掘影响车辆成交周期的关键因素。因门店交易数据仅给出车辆 id、上架时间、上架价格、{价格调整时间：调整后价格}、下架时间和成交时间等 6 列数据，为挖掘影响二手车成交周期的关键因素，需要根据 carid 索引“估价训练数据”表，将该表和“门店交易数据”合并为一个大表，获取每一个二手车更多的特征信息。

对合并的表的原始数据进行预处理后，从原始数据计算出车辆的成交周期天数。同时原始数据中存在未成交的车辆，将它们的成交周期天数设为已成交车辆最大天数的两倍。此外，挖掘其他可能对成交周期天数产生影响的特征，如车辆成交的季节，车辆降价的次数，车辆降价的幅度等，构造新特征后再通过模型来得到对对车辆的成交周期的关键因素。

采用基于惩罚项的特征选择方法，通过逻辑回归、LASSO 回归、SVM 模型得出影响成交周期的前五个重要性特征；采取基于树模型的特征选择方法，通过随机森林、LightGBM、XGBoost 模型得出影响成交周期的前五个重要性特征。最后通过投票机制选出 6 个模型中票数最多的前五个对成交周期影响较大的因素。对五个重要因素分别和成交周期关系进行可视化，分析提供相应的建议。将选出的五个重要因素与成交周期做多元回归分析，以此来得到对应因素调整对成交周期的影响的效果。

2.3 问题 3 分析

在问题 1 选用合适的估价模型预测二手车交易价格，以及问题 2 挖掘出影响车辆成交周期的关键因素的基础上，依据样本的数据集，列举出需要研究的问题及思路如下。

1. 季节因素会对二手车的交易价格产生哪些影响？

与其它产品一样，二手车的交易市场同样存在淡季和旺季，一年内不同时间的二手车交易价格存在差异，这也导致季节因素会对二手车的交易价格产生影响。

将给出的“估价训练数据”和“门店交易训练数据”两个数据表合并为一个大表，可以获取每一辆二手车的成交时间和成交价格，故按照月份将成交时间划分为春夏秋冬四个季节，即 1-3 月对应春季、4-6 月对应夏季、7-9 月对应秋季，10-12 月对应冬季，计算每个季节二手车交易价格的总和以及平均值，根据计算结果分析季节因素对二手车交易价格产生的影响，从而有利于二手车电商进行快速准确地给二手车定价，制定营销补贴政策。

2. 有哪些关键因素影响二手车的保值率？

二手车保值率一直是衡量二手车价值的关键指标，但也直接受新车价格稳定的影响。在新车交易中，保值率日渐成为消费者购车的决策因素之一，被誉为汽车价值生命的“第二周期”，故探究影响二手车保值率的关键因素，对各大汽车厂商以及二手车电商制定策略销售车辆有重要的作用。

汽车保值率就是就是指某款车型在使用一段时期后，将其卖出的价格与先前购买价格的比值。基于给出的“估价训练数据”和“门店交易训练数据”，将两个数据表合并为一个大表，可以获取每一辆车的新车价、上架价格以及最终成交价格。计算出上架价格与新车价格的比值作为汽车的期望保值率，最终成交价格与新车价格的比值作为汽车的实际保值率，再取期望保值率与实际保值率的平均值作为汽车的保值率，可根据问题 2 寻找影响车辆成交周期的关键因素所使用的模型和方法，挖掘影响车辆保值率的关键因素。

3 模型假设

1. 假设影响二手车价格的因素仅包含题目所给定特征信息；
2. 假设样本数据中缺失过多的变量信息对二手车价格的预测产生的影响较小；
3. 假设预测集采集的 price 数据和训练集采集的 price 分布是一致的；
4. 假设在做出销售策略的阶段不会有黑天鹅事件或重大自然灾害等对门店二手车销售带来影响；
5. 假设异常值和缺失值处理后的数据有效可信，能够反映二手车本身属性与价格的关联性；

4 符号定义与说明

符号	说明	单位
$\hat{y}$	采用策略后的购买概率	%
y	原始购买概率	%
$\widehat{Xi}$	第 i 个指标提高后的结果	1
w	叶子节点的分数	1
k	树的数量	棵
T	叶子节点的个数	个
r_l	二手车上牌时间减去注册时间的值	天
low_price_rate	二手车价格调整幅度	%
low_count	二手车价格调整次数	次
tradeDays	汽车的成交周期	天
u_tradeDays	未成交车辆的成交周期天数	天
last_price	最后一次的降价价格	元

5 问题一模型的建立与求解

5.1 数据清洗

5.1.1 整体数据分析

首先导入题目所给的数据，通过 python 读取数据的整体信息，如下表所示。原始数据共有 20 个显示特征和 15 个匿名特征，共有 30000 万行训练数据和 5000 行预测数据。其中有数值类型、日期类型、对象（字符串）几种数据类型。因为模型训练所需要的数据为数值类型，有几个值需要我们经过处理才能被模型识别，分别是日期类型：tradeTime、registerDate、licenseDate、f7 和 f15。对象类型：f11 和 f12。

表 5.1 原始数据字段与数据类型

字段名	数据类型
carid	int64
tradeTime	datetime64[ns]
brand	int64
serial	int64
model	float64
mileage	int64
color	int64
cityId	int64
carCode	int64
transferCount	int64
seatings	int64
registerDate	datetime64[ns]
licenseDate	datetime64[ns]
country	float64
maketype	float64
modelyear	float64
displacement	float64
gearbox	int64
oiltype	int64
newprice	float64
f1	float64
f2	int64
f3	int64
f4	float64
f5	int64
f6	int64
f7	datetime64[ns]
f8	float64
f9	float64
f10	float64
f11	object

f12	object
f13	float64
f14	int64
f15	datetime64[ns]
price	float64

5.1.2 对非数值数据类型进行转换

对日期类型数据进行转换

首先对日期类型进行转换，通过 python 将几个数据类型为日期的字段年月日分别分割出来成为三个新的字段年，月，日。

其次，python 查看匿名字段 f13 数据如下图所示，它是一个年月的字符串格式，因此将 f13 的年月也分别分割出来生成两个新的字段表示年和月。

```
201709.0
201609.0
     NaN
201608.0
201204.0
```

图 5.2 f13 前 5 个值

对对象类型数据进行转换

通过查看匿名字段 f11 的值，发现其共有以下几种字符串数据：分别是“1+2”，“1”，“3+2”，“1+2”，“5”，“3+2”共有 6 个类别，因此将 f11 这六个字符串替换为编码 0，1，2，3，4，5 表示 6 个类别。

查看 f12 的值，如下图所示，是三个数相乘的形式，根据背景知识可知 f12 可能为车辆的长宽高相乘，因此可以将长，宽，高分离出来，形成三个新的字段，再令长宽高相乘得到车辆的体积为第四个新字段。

```
4220*1740*1625
4630*1775*1480
4515*1725*1445
4500*1834*1707
4315*1783*1606
```

图 5.3 f12 前 5 个值

5.1.3 缺失值处理

原始数据中存在大量缺失值，查看下数据中各字段缺失值的情况，再采取方法处理。通过 python 对缺失值情况可视化分析，如图 5.4 和 5.5 所示，训练集和预测集数据缺失情况大致相同。f7 和 f15 的缺失值较多，数据少于全部数据的一半， f4 缺失值接近一半，而 f1，f8，f9，f10，f11，f13，country 和 maketype 缺失较少。

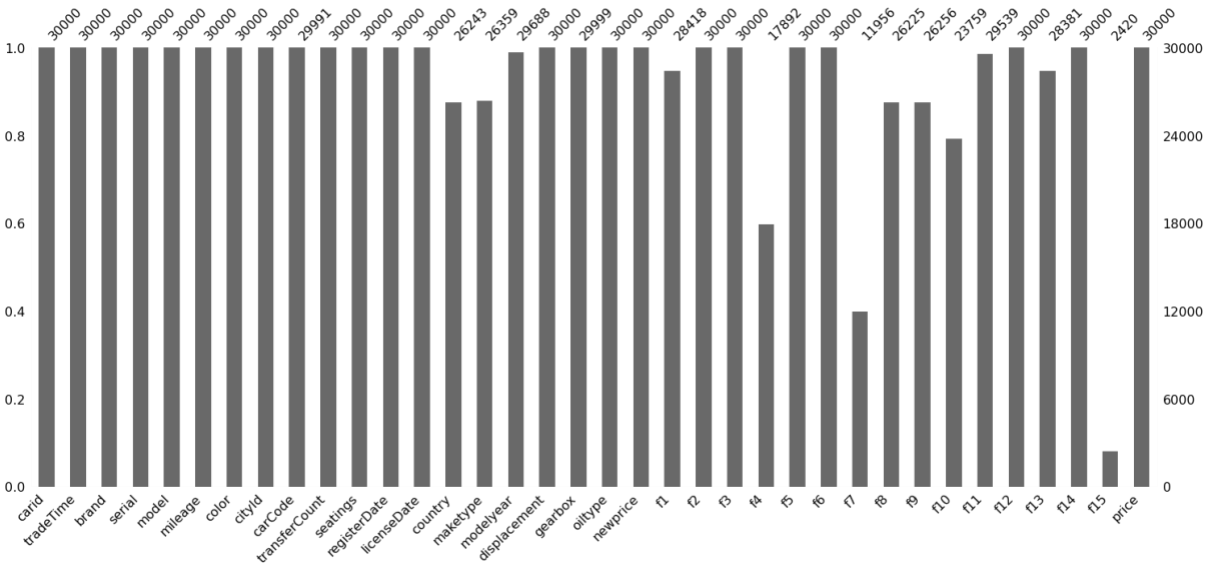


图 5.4 训练集数据缺失值情况

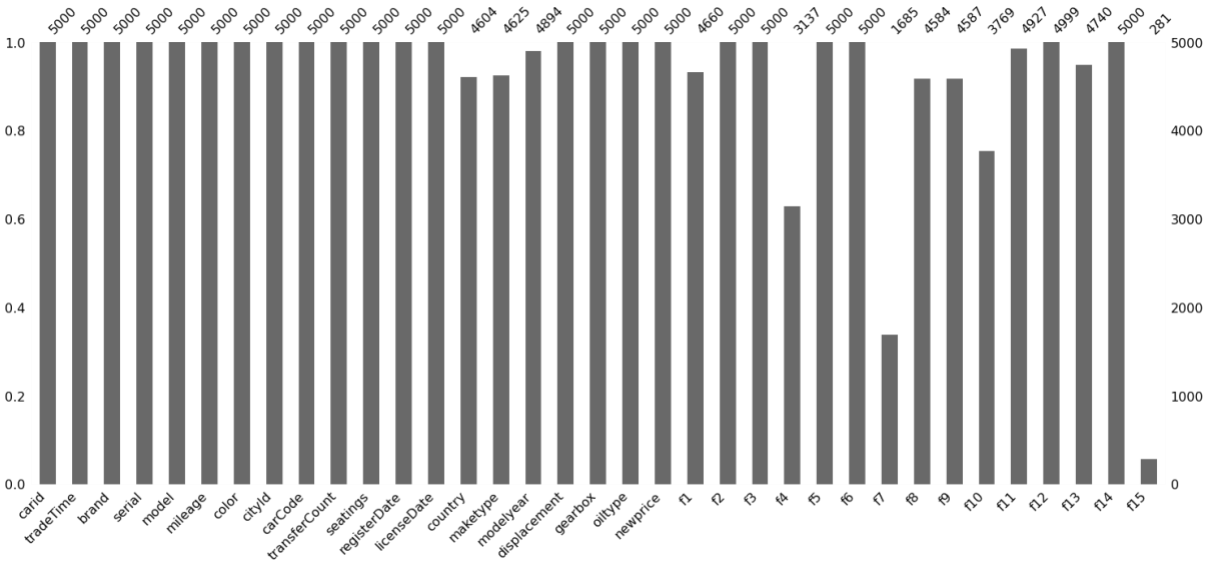


图 5.5 预测集数据缺失值情况

经过以上的分析，对缺失值的处理采取以下步骤：

1. 对于 f7 和 f15 的缺失值较多如若直接填充会产生很大偏差，因此采取直接这两个特征删除的方法。
2. 对于 country 字段发现和 serial 字段一一对应，因此可以通过 serial 字段来填充 country
3. 对于 maketype，f8，f9，f10，f11 都是离散特征的情况，相比直接删除数据会造成大量数据丢失或者填充众数导致数据分布出现偏差，我们采取用-1 填充缺失值，使其成为一个新的种类
4. 对于 f13，因为其含有长宽高的信息，用且缺失数据极少，将长宽高分离出来，直接采取用众数填充。

5.1.4 异常值处理

对 price 字段异常值处理

绘制目标字段 price 的箱形图，发现有一个突出的异常值，达到了十万，因此将该值去除。

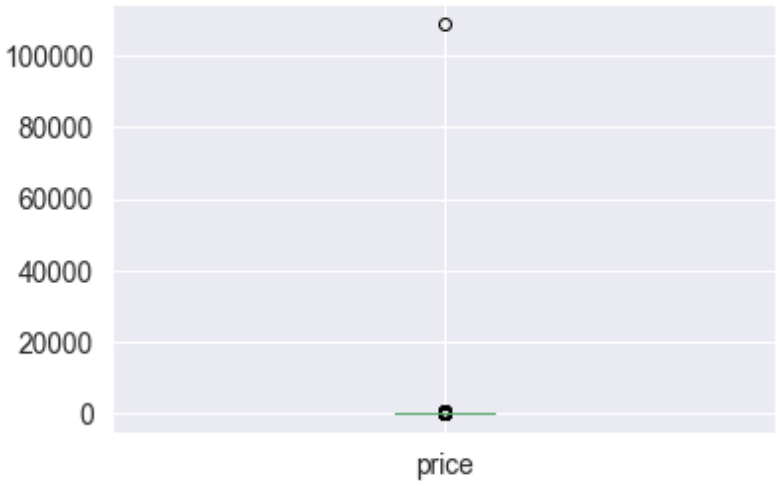


图 5.6 训练集 price 字段箱形图

去除了异常点后的 price 字段箱形图最大的 price 价格约为 700，虽然有部分数据超出箱形图的上边界，但是经对比发现新车价格 newprice 字段的值也有超过 100 数据，且 price 和 newprice 的值都比较高，因此认为超出箱形图的上边界数据并不是异常值。

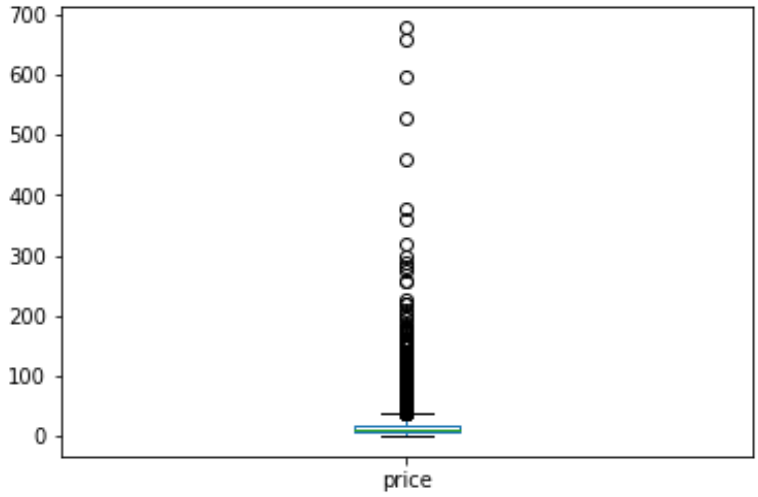


图 5.7 训练集 price 字段去除异常点箱形图

同时观察数据发现 price 价格比 newprice 价格大的数据有 180 个。根据现实情况，二手车的价格普遍低于新车价格，但是不排除极少数情况二手车价格可能大于新车价格，如新车买了之后未使用立即卖出，且该车的市场价格有所提升，因此二手车的价格可能不降反升。因此我们认为 price 大于等于 1.5 倍的 newprice 视为异常点，用 newprice 值替换 price 的方法处理。

5.1.5 删除与目标无关列和重复列

根据分析，carid 字段是唯一的，与预测值 price 无关，因此将其删除。同时 serial 和 country 的值是一一对应的，我们保留其中一个字段即可。

5.1.6 去掉可能影响预测的数据

比较训练集与测试集的分类特征，如下图 5.8 和 5.9 所示，发现 f11 和 settings 两个分类特征在训练集与测试集中的种类数不一致，并且这部分数据数量较少，为了提升模型的预测效果，需要考虑将训练集中 f11 和 seatings 这两列数据删去。

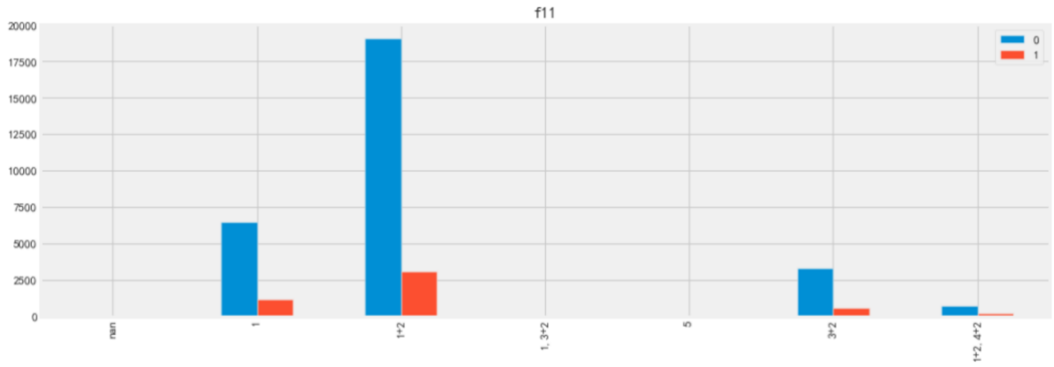


图 5.8 f11 分类特征

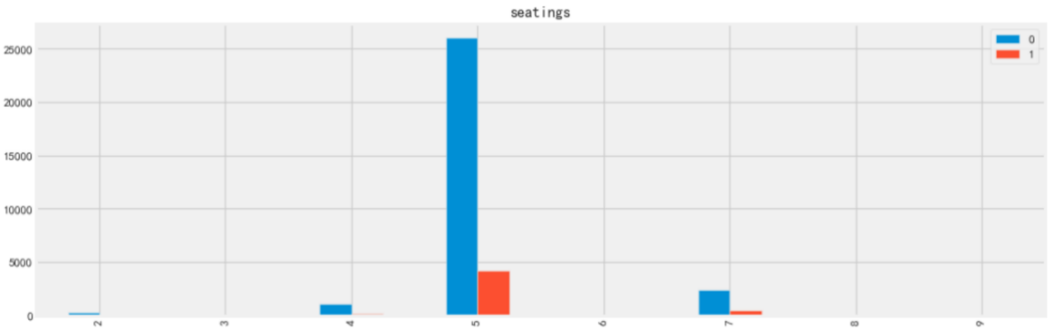


图 5.9 seatings 分类特征

5.2 特征工程

首先对训练集和预测集中的数据分布情况进行查看，查看是否需要对数据进行大量剔除或转换。如概率密度图所示，训练集和预测集中的连续值字段的分布都比较一致，不需要做额外的处理。其中 f12_1，f12_2 和 f12_3 分别为车辆的长宽高信息。

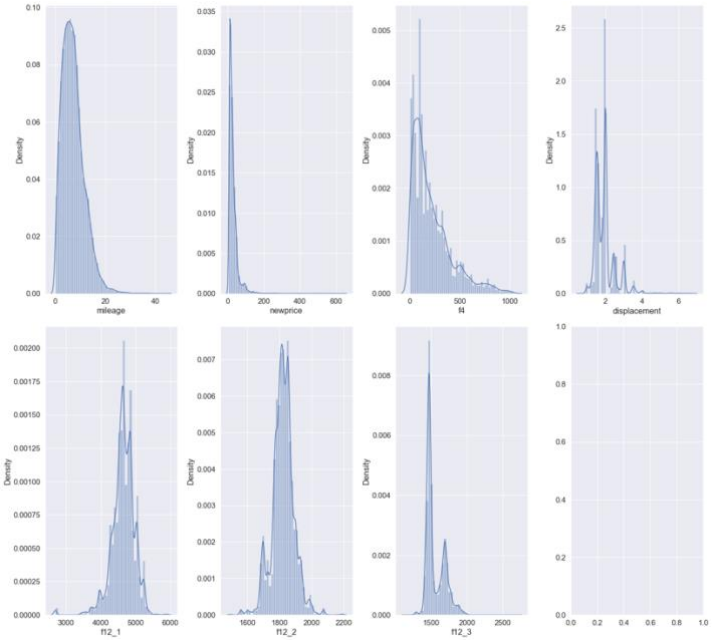


图 5.10 训练集连续值概率密度图

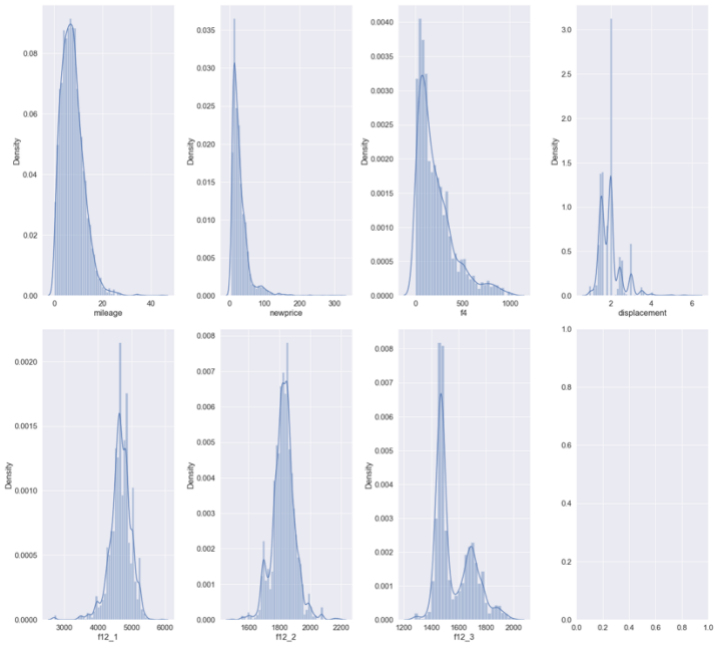


图 5.11 预测集连续值概率密度图

5.2.1 对 price 和 newprice 对数转换

因为大部分模型需要的数据要求符合正态分布，通过 python 发现字段 price 和 newprice 的分布情况为左偏，与正态分布差距较大，因此我们对其取对数，如下公式所示

$$y = log(x + 1)$$

其中x是原数据，y是变换后的数据，加 1 是保证转换后的数据为非负值。转换前后字段 price 和 newprice 的分布直方图如 5.12 所示。可以看到对数化后两个数据趋于正态分布。

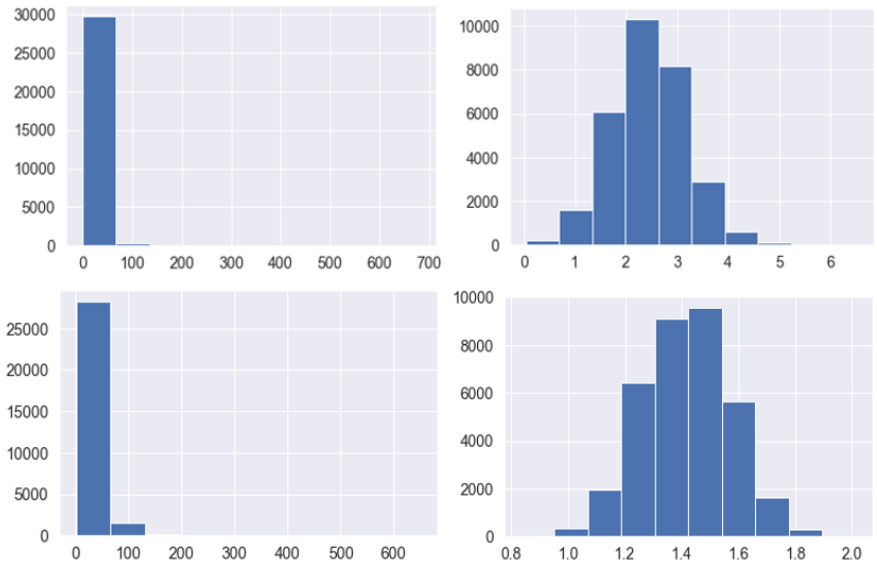


图 5.12 左边两张图分别为 price 和 newprice 原始数据直方图分布；右边两幅图为对应的对数化后的直方图

5.2.2 归一化

对于数据中的连续值特征，为了消除不同字段量纲对最终模型的影响，我们需要对数据进行归一化，如下公式所示：

$$X^{'} = \frac{x - min}{\max - min}$$

其中min和max分别是该字段中数据的最小值和最大值。

5.2.3 特征编码

对于数据中的分类特征，原始数据的值跨越较大且有多种形式，因为只有数字类型才能进行计算。因此，对于各种特殊的特征值，我们都需要对其进行相应的编码。在这里我们采用 Label encoding，将原始特征值编码为自定义的数字标签完成量化编码过程。

5.2.4 特征构造

为了对数据进行充分利用，增强模型的表达能力，我们需要对原始的数据进行特征构造，主要采取了以下几个步骤：

1. 对日期数据做差值

二手车的价格与二手车的使用时长有较大联系，一般来说，二手车的使用时间越长，价格相应越低。为了表征这一特性，我们对车辆的注册日期和出售日期做差值，得到新的字段车辆使用时长$days$。

$$days = date1 - date2$$

其中$date1$表示车辆出售日期，$date2$表示车辆注册日期。

2. 对 newprice 和其他连续特征字段做除法构造新特征

二手车的价格与新车价格有着密切的关系，也与汽车排量、已行驶里程、汽车转户次数、行驶天数等有关。为了探究他们间与最终出售价格的关系，我们对他们进行组合得到一些新的特征。分别是单位排量价格 newprice/displacement，采取 newprice 与汽车排量做除法的方法；单户行驶里程数 mileage/transferCount，单户行驶天数 days/transferCount。

3. 对匿名字段和其他重要特征字段做交叉

匿名字段的信息我们无法获取，因此难以通过分析直接构造有背景信息的特征。我们采取匿名连续特征和其他重要字段 newprice，displacement，ransferCount, mileage 两两做乘法的操作，做乘法加入了非线性表大的新特征，有利于提高模型的表达能力。

5.2.5 嵌入式特征选取

经过上面的构造新特征，我们得到了特征比较多，因此需要对特征进行选择，防止模型的过拟合。我们采取特征嵌入式选择的方法，其方法流程如图 5.13 所示。

嵌入式特征选择，结合了过滤式和包裹式的优点，就是通过一些特殊的模型拟合数据然后根据模型自身的某些对于特征的评价的属性来作为评价指标，最后再使用包裹式的特征选择方法来选择。在本文中，我们通过采取集成树模型 XGBoost，然后去拟合输入输出得到训练完毕的模型，输出特征的重要性。我们不需要额外的去做特征选择，因为模型训练的过程中自身已经完成了特征选择，得到了不同特征的评价得分，然后根据这些得分的大小就可得到不同特征针对对应的模型的特征的贡献率。

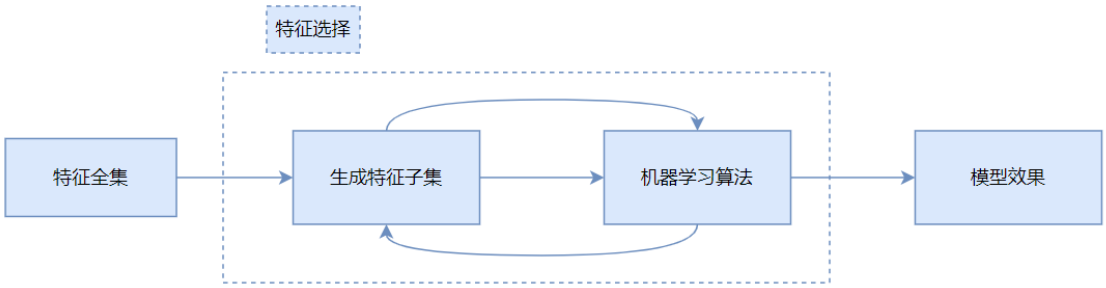


图 5.13 嵌入式特征选择

最终得到的重要性排名前十的特征如下图所示。

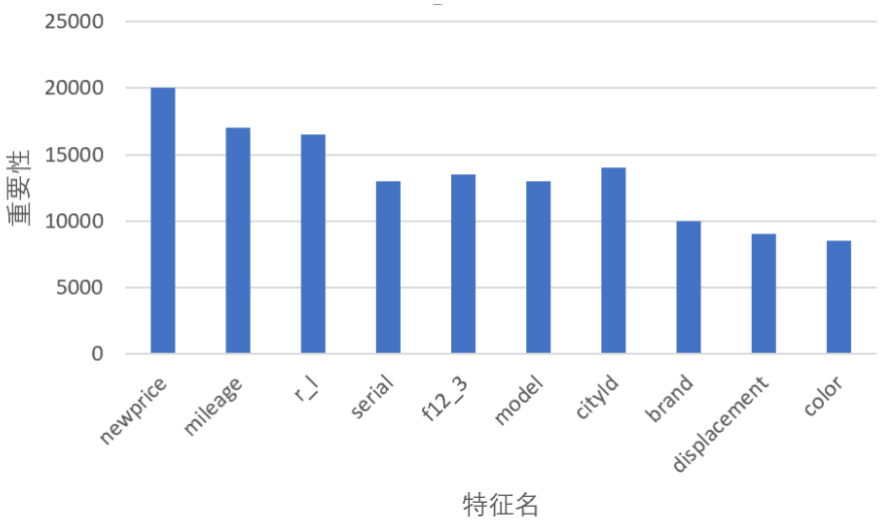


图 5.14 要性排名前十的特征

5. 3 模型的建立与求解

在对数据进行缺失值处理，异常值处理，特征工程步骤后，我们得到了一份新的数据。将该数据通过集成模型 LightGBM，XGboost 和随机森林算法采取五折交叉验证法对样本数据进行拟合，得到各特征与二手车价格的关系。随后，再采取模型融合的方法将 LightGBM，XGboost 和随机森林的结果赋予不同权重，结合它们的优点建立起最终预测二手车价格的模型。

5.3.1 随机森林模型的建立

随机森林属于一种集成学习模型，即通过构建多个学习器来共同完成学习任务，先产生一组基学习器，再用某种策略将这些学习器组合起来，而决策树常常被用做基学习器，因为其本身属于弱学习器，但是经过集成之后往往会有很强的预测效果，成为强学习器。随机森林就是其中一种决策树集成模型，它使用的是 CART 决策树，因其良好的预测效果和稳定性而被广泛应用。

以下将详细分析基于随机森林算法的二手车价格评估模型的建模步骤：

二手车价格评估的随机森林算法是由 B 棵树$\{T_1(X), T_2(X), T_3(X), \dots, T_B(X)\}$组成的集合，其中，$X = \{x_1, x_2, x_3, \dots, x_p\}$是二手车的 P 维特征向量。通过建树集合运算得出 B 个结果$\{\widehat{Y_1} = T_1(X), \widehat{Y_2} = T_2(X), \widehat{Y_3} = T_3(X), \dots, \widehat{Y_B} = T_B(X)\}$，其中$\{\widehat{Y_b}, b = 1,2,3, \dots, B\}$为第 b 为第 b 棵树对二手车价格的预测值。在回归问题分析中，$\hat{Y}$是每棵决策树的平均值[1]。在给定一系列特征变量的训练集样本数据进行训练时，二手车的特征变量用$D = \{(X_1, Y_1), \dots, (X_n, Y_n)\}, X_i(i = 1, \dots, n)$来表示，而$Y_i$指二手车的挂牌价格，随机森林回归算法的建模计算过程为：

(1)在原始的二手车样本数据集中,有 n 个二手车样本,在随机森林建模时，使用 bootstrap 抽取用于训练模型的样本集，因为该方法可以随机有放回的抽取样本。基于以上操作建立 B 棵随机森林的决策树，其中没有被 bootstrap 随机选中的样本，会被作为模型的测试集样本，用于建立好的随机森林模型的回归预测效果评估，这些数据被称为袋外数据（OOB)[2]；

(2)设原始的二手车样本数据集中有 P 个特征变量,在回归树的建立过程中，需要选择分枝节点中用于回归树的特征变量的个数，在模型中表现为参数 max_depth 大小的选择。在使用随机森林模型进行回归预测时，回归树可以不受限制的生长，不用对其进行剪枝操作。

(3)重复随机抽样和建立回归树的步骤，如果全部的回归树都已训练好，则代表基于随机森林算法的二手车估价模型已建立好。图 5.15 是具体的随机森林建模过程。

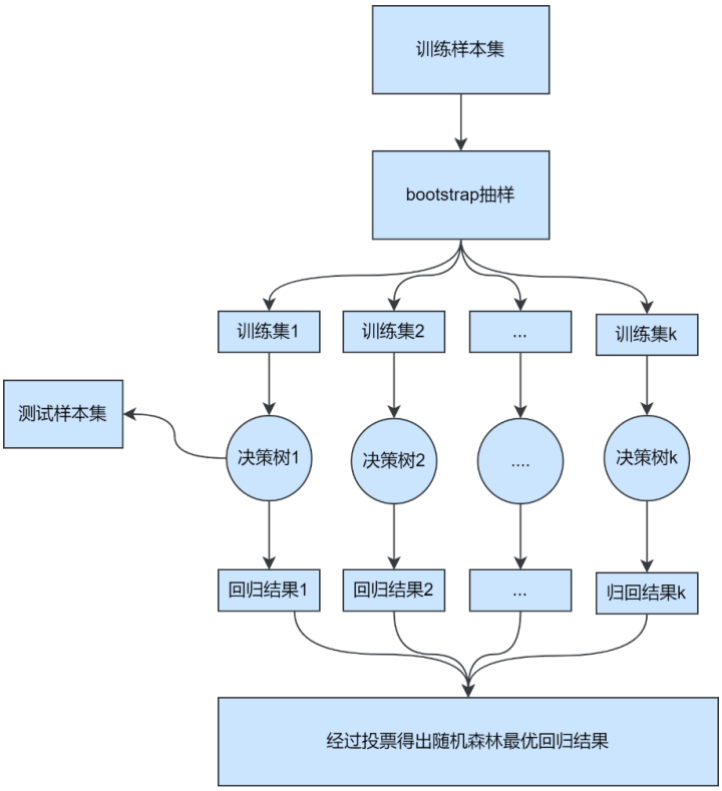


图 5.15 随机森林流程

5.3.2 随机森林模型的检验

建立基于随机森林算法的二手车估价模型主要目的是对二手车的各个影响因素进行回归分析，回归的最终目的是进行二手车价格的预测。所以我们需要对预测结果进行检验和评估，对结果的检验和评估我们采取题目所给的公式进行计算

$$score = 0.2 * (1 - \text{Mape}) + 0.8 * \text{Accuracy}_5$$

$$\text{Mape} = \frac{1}{m}\sum_{i=1}^{m} \text{Ape}_i$$

$$Ape = |\hat{y} - y|/y$$

其中，score 是我们的评估模型得分，其值在[0,1]区间内，越接近 1 越好，Accuracy_5为相对误差 Ape 在 5%以内的样本数量。

5.3.3 随机森林模型的参数调优

随机森林模型建立回归时主要需要优化的参数为：n_estimators 即随机森林最大的决策树个数；max_depth 即决策树在划分节点分支时所需要的特征变量的个数，用于限制决策树的最大深度；bootstrap 参数，决定是否有放回的抽样，使用什么数据建立每棵回归树。在应用 Python 建立基于随机森林算法的二手车估价模型时，需要对随机森林模型中的这三个参数进行优化，提高模型的回归预测效果。

在随机森林参数调优的过程中，选择 GridSearch 对参数进行优化，选 GridSearch 对模型进行调参工作，是因为该方法可以在输入模型的参数中，自动搜索由不同参数组成的不同模型，最终选择模型效果最优时的参数的组合输出，该方法可以有效的解决参数优化工作的成本高和效率低等问题。

第一步，在随机森林建模时按照每个参数的默认值运算，得出此时的模型评价指标值，其中 score 得分为 0.57。

第二步，对 n_estimators，max_depth，bootstrap 进行参数优化工作。其中 n_estimators 设置为 50-

2000，每次增加 50，因为默认值为 100，所以我们初始时设置为 50，有比 100 更小的值；max_depth 选择四个值分别为 5，10，20，深度过深容易造成过拟合，因此本文选择这三个值，用于优化参数；bootstrap 的取值有两个 True 和 False，决定是否有放回的抽样。先对 bootstrap 进行优化分析，使用网络搜索法优化参数，优化的次数为 160 次，根据训练结果当 bootstrap 设置为 True 时，随机森林模型有更低的误差、更高的拟合结果，所以在随机森林对二手车进行价格预测时，使用 bootstrap=True。

第三步，选择优化后的参数组合，即 bootstrap=True，n_estimators=80，max_depth=10。优化后模型 score 值为 0.61，与优化之前的模型对比，模型的拟合程度提高。

下表为未优化模型参数和优化模型参数的采取五折交叉方法训练集和测试集得分结果。

表 5.2 不同参数下随机森林模型的训练集和测试集得分

参数值			模型效果	
bootstrap	n_estimators	max_depth	训练集得分	测试集得分
默认值	默认值	默认值	0.695	0.571
True	800	10	0.748	0.613

5.3.4 LightGBM 模型的建立

LightGBM 是一个高速、分布式并且性能很高的梯度提升框架，它以决策树算法为基础，可用来完成排序、分类、回归和很多其他的机器学习任务。它在不降低精度的前提之下，将速度提高了十倍左右，使占用内存降低了三倍左右，具有高训练效率、低内存占用、高精度、支持并行以及 GPU 可以用来对大规模的数据进行处理等优点。LighGBM 算法的核心思想是：直方图算法、Leaf-wise 分裂策略、直接支持类别特征、基于直方图的特征优化[3][4]。

与随机森林算法步骤相同，调用 Python 库中 LightGBM 算法，先使用默认参数来对二手车价格进行拟合，随后再对 LightGBM 进行调参。LightGBM 模型的参数较多，但是调参规则和每一个基于决策树的模型是差不多的，先确定 0.1 为初始学习率，可以使模型有更快的收敛速度，然后通过网格搜索确定决策树数目和决策树最大深度，再确定最大叶子节点数，最后调节叶节点最小样本数防止模型过拟合。LightGBM 算法调参前后的效果如下表所示：

表 5.3 不同参数下随机森林模型的训练集和测试集得分

参数值				模型效果	
max_depth	n_estimators	min_samples_split	max_samples_split	训练集得分	测试集得分
默认值	默认值	默认值	默认值	0.697	0.583
8	1000	3	3	0.739	0.617

5.3.5 XGBoost 模型的建立

在训练模型的时候，XGBoost 算法[5]生成每棵树的方法是通过判断节点分裂前和节点分裂后是否产生了“增益”，进而明确这个节点是否分裂，同时通过参数来对树的深度进行控制。当一棵决策树生成结束之后，还需要对其进行剪枝，以防止过拟合的产生。在第 m 轮所产生的树会对真实值与第 m-1 轮所产生的预测值残差进行学习，以便使模型预测结果逐渐逼向真实值。

XGBoost 有以下几个好处：

(1)在目标函数当中添加了正则化项，降低了出现过拟合现象的可能性，不仅使用了一阶导数，还使用了二阶导数，使损失函数更加精确的同时还可以自定义损失。

(2）可以并行优化，并且 XGBoost 是在特征粒度上的并行。

(3）考虑了对稀疏值的处理，能给缺失值或指定值设置分支默认方向，极大提升了算法效率。

(4）允许列抽样，既可以抑制过拟合，又可以减少计算量。

我们首先调用 Python 封装好 XGBoost 对二手车价格进行拟合，然后再对 XGBoost 进行调参优化。在进行 XGboost 的参数调优时，我们主要步骤分为三步：

第一步：在构建 XGboost 模型的时候首先以各参数的默认值构建模型，计算得到初始模型的评价标准值。

第二步：对参数 learning_rate、n_estimators、max_depth 进行调整。其中 learning_rate 为学习率，默认为 0.3，在回归任务中，通过它来控制迭代速率，抑制过拟合现象的产生；n_estimators 为 boosting 的迭代次数（弱分类器的个数）；max_depth 为树的最大深度，它通常用来避免过拟合现场的产生。max_depth 越大，模型就会学到更加具体的样本，取值为非负数。正则化参数 lambda，alpha 的调优，这些参数可以降低模型的复杂度，从而提高模型的表现。

第三步：利用第二步中选取到的最优参数组合构建最优模型，计算得到优化后模型的评价标准值，与优化前的模型相比，优化后的模型的拟合程度明显提高。

表 5.3 优化后 XGBoost 的训练集和测试集得分

参数	值	训练集得分	测试集得分
learning_rate	0.01		
n_estimators	1000		
max_depth	8	0.776	0.624
lambda	0.3		
alpha	0.3		

5.3.6 模型融合

模型融合我们采取 stacking[6]的方法。stacking 就是用初始训练数据学习出若干个基学习器后，将这几个学习器的预测结果作为新的训练集，来学习一个新的学习器。本文已经训练好了三个基学习器随机森林，LightGBM 和 XGBoost，将这三个学习器的输出作为次集训练集给次级学习器。次学习器我们采取线性回归模型，因为我们的基学习器是强学习器，次级学习器选择简单的模型可以避免过拟合现象，因为结合了不同学习器的学习效果，使用 stacking 的方法可以使得最终融合的模型更加稳定，表现更好。stacking 融合的方法如下图所示：

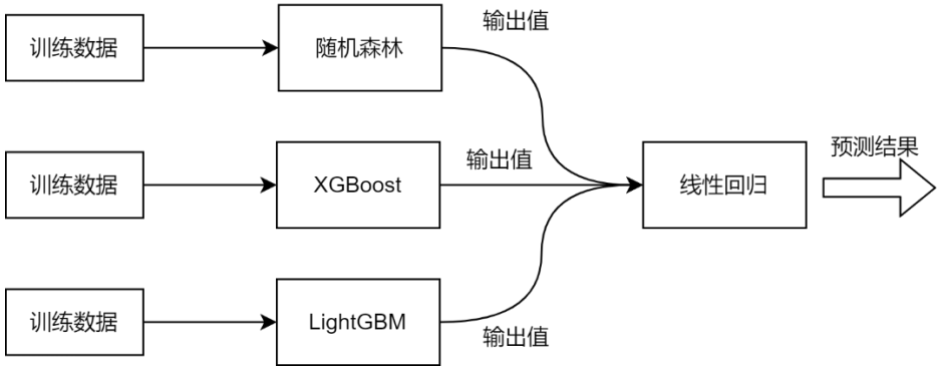


图 5.17 模型融合流程

从训练效果发现融合后的模型比单独的强学习器效果更好，随机森林，LightGBM 和 XGBoost 和三者的融合拟合效果如下表所示：

表 5.4 不同模型训练集与测试集得分比较

学习器	训练集得分	测试集得分
随机森林	0.748	0.613
LGBM	0.739	0.617
XGBoost	0.776	0.624
stacking 融合模型	0.793	0.636

6 问题二模型的建立与求解

6.1 数据的预处理

1. 处理未成交车辆的成交周期

分析数据，发现一万条数据中有八千条成交记录，两千条未成交车辆下架的记录。我们定义汽车的成交周期为成

$$tradeDays = withdrawDate - pushDate$$

其中$withdrawDate$为车辆的成交时间，而 pushDate 为车辆的上架时间。

对于两千条未成交车辆的成交周期认为其值为无限大，在本文我们将该值设为已经成交车辆中最大成交周期的两倍。

$$u_tradeDays = 2Max_{tradeDays}$$

其中$u_tradeDays$代表未成交车辆的成交周期天数，而$Max_{tradeDays}$代表已成交车辆的成交周期天数的最大值。

2. 构造车辆成交季节特征

影响汽车成交的因素有许多，包括汽车的销售价格，汽车的年份。销售的季节，如旺季和淡季也会对汽车成交产生影响等。因为原始数据中不含有汽车成交的季节。因此我们构造一个新的特征为“成交季节”表示汽车成交的季节，通过将$withdrawDate$中的月份数据映射到对应季节即可。

3. 提取车辆降价信息

通过源数据中的 updatePriceTimeJson 字段，我们可以提取得到车辆的降价次数“low_count"；我们可以得到车辆最后一次的降价价格“last_price”，构造车辆降价的幅度“low_price_rate”，公式如下：

$$low_price_rate = \frac{|last_price - pushPrice|}{pushPrice} \times 100\%$$

6.2 模型的建立

将问题二的表根据 cardId 与问题一所给的训练集的表连接成为一张新的大表。我们将车辆的成交周期作为标签，其他特征作为影响成交周期的因子，通过逻辑回归、LASSO 回归、SVM 模型、随机森林模型、LightGBM 模型、XGBoost 模型得到对重要的特征，通过投票机制得到最终影响成交周期的重要因素。

特征选择方法中的过滤法和包裹法，在特征选择过程与模型训练过程是独立进行的，而嵌入法则是综合考虑这两个过程，在学习的同时进行特征选择，因此，为了使结果更具有代表性，利于模型训练，本文使用以下两种嵌入法：

一是基于惩罚项的特征选择法，本文采用基于 SVM 模型、LASSO 模型、逻辑回归模型的惩罚项特征选择法来选择特征。用正则 L1 范数作为惩罚项。L1 范数不但可以降低过拟合风险，还可以使求得的 w 有较多分量为 0。所以当希望减少特征的维度以用于其他分类器时，可以选择不为 0 的系数所对应的特征。

二是树模型的特征选择法，这种方法能够用来计算特征的重要程度，因此可以用来去除不相关的特征。本文采用随机森林模型、LightGBM 模型的树模型特征选择法来选择特征。再根据特征重要性程度，设置一个阈值，得到每个算法排名靠前的特征，最后在五个模型选出的结果上采用投票法，筛选出大于等于 2 票的特征，作为影响该品牌销售主要因素。第一问中已经详细的描述了树模型的建立过程，下面就介绍基于惩罚项的特征选择法：

6.2.1 逻辑回归模型的建立

逻辑回归（logistic regression，LR）是一个强大的统计学方法，它可以用一个或多个解释变量来表示一个二项式结果。它通过使用逻辑函数来估计概率，从而衡量类别依赖变量和一个或多个独立变量之间的关系，后者服从累计逻辑分布。它的定义式如下：

$$h(z) = \frac{1}{1 + \exp(-z)}$$

这个函数的定义域为整个实数域，值域为(0,1)，并且是一个单调的增函数。根据对分布函数的要求，这个函数可以用来作为随机变量 x 的分布函数，即

$$p(x \le z) = h(z)$$

6.2.2 LASSO 回归模型的建立

LASSO 的全称是 Least absolute shrinkage and selection operator，是一种压缩估计，它通过构造一个惩罚函数得到一个较为精炼的模型，使得它压缩一些回归系数，即强制系数绝对值之和小于某个固定值，同时设定一些回归系数为零。因此保留了子集收缩的优点，是一种处理具有复共线性数据的有偏估计。LASSO 是在 RSS 最小化的计算中加入一个l_p范数作为惩罚约束。l_p范数的好处是当 λ 充分大时，可以把某些待估系数精确地收缩到零。通过交叉验证法：对 λ 的给定值，进行交叉验证，选取交叉验证误差最小的 λ 值，然后按照得到的 λ 值，用全部数据重新拟合模型即可。

$$\widehat{\beta_{\text{Lasso}}} = \arg\min_{\beta \in R^d} \left(|Y - X\beta|^2 + \lambda \sum_{j=1}^{d} |\beta_j| \right)$$

其中 t 与 λ 一一对应，为调节系数。

6.2.3 SVM 模型的建立

SVM 支持向量机主要针对二分类线性分类器，方法是确定一个超平面，使得数据点到超平面的距离最大，这是一个二次规划问题[7][8][9]。由于对任何数据集找到它合适的映射是困难的，因此通常会从常用核函数中选择[10]。常用的核函数有多项式核函数、高斯函数、线性函数等。分类超平面的约束为：

$$y_i(w^T x_i + b) \ge 1$$

目标函数是超平面离两类样本的距离要足够大，可以写成：

$$\frac{1}{2}|w|^2$$

6.3 模型的求解

6.3.1 关键影响因素的选取

表 6.1 基于惩罚项的嵌入法选取排名前 5 的特征

	逻辑回归	LASSO 回归	SVM
重要性排序	transferCount	transferCount	cityId
	cityId	cityId	成交季节
	pushPrice	成交季节	price
	成交季节	low_price_rate	tradeTime_year
	model	pushPrice	pushPrice

表 6.2 基于树模型的嵌入法选取的排名前 5 的特征

	随机森林	XGBoost	LightGBM
重要性排序(得分)	成交季节	cityId	cityId
	cityId	成交季节	成交季节
	transferCount	model	transferCount
	low_count	transferCount	pushPrice
	low_price_rate	pushPrice	low_price_rate

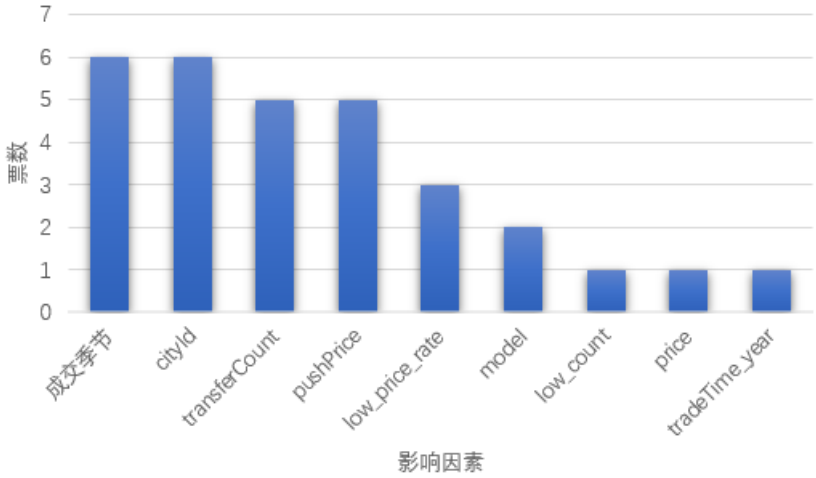


图 6.1 不同特征的重要性票数

根据以上 6 个模型的投票结果，我们可以选出 5 个对成交周期的影响较大的关键因素，分别车辆成交季节、cityId（车辆所在城市 Id）、transferCount（过户次数）、pushPrice（车辆上架价格）和 low_price_rate（车辆降价幅度）。下面将针对这些关键因素进行具体分析，提出的建议主要分为两类：门店销售策略类型的建议以及门店对二手车的收购标准的建议。

6.3.2 多元线性回归衡量预期效果

在提建议前，为了量化采取措施的具体效果，我们通过多元线性回归拟合以上五个因素与成交周期的关系，得到如下关系方程

$$y = 1.5x0 - 36.25x1 + 3.628x2 + 0.69x3 + 10.952x4 + 12.12$$

其中$x0$，$x1$，$x2$，$x3$，$x4$分别为车辆上架价格，车辆降价幅度，车辆成交季节，车辆所在城市，车辆过户次数。从方程可以看出车辆上架价格每变化 1 会改变 1.5 天的成交周期天数；车辆降价幅度每提高 100%，会降低成交周期天数 36.25 天，车辆过户次数每增加 1，会提高成交天数 10.952 天。

6.3.3 建议与预期效果

销售策略：对二手车所在城市因素的建议与预期效果

针对二手车所在城市这一特征：不同的城市二手车的成交周期有较大差别，如图 6.2 所示。考虑将二手车往热销城市输出，可以大大的增大其销售速度。若运输等相关费用成本能够接受，在部分城市销的不好的二手车，可以考虑将它们转往另一个热销城市的进行销售。比如一个门店在全国有连锁店，将淡销城市的二手车送往热销城市销售，销售速度自然也会加快。适用条件为商家在全国具有多家连锁店且二手车的运转费用成本能够接受。

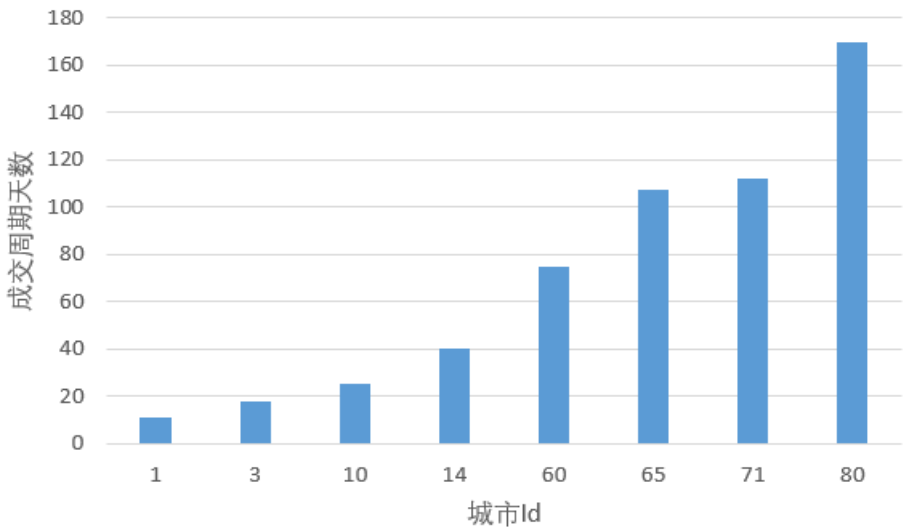


图 6.2 城市 Id 与成交周期天数的关系

预期效果为缩短的成交周期天数为两个城市汽车平均的成交周期天数之差。

销售策略：对季节因素的建议与预期效果

针对二手车成交季节这个关键因素，经统计售卖掉的二手车数量发现：汽车在冬季和春季的销售速度是要优越于夏季和秋季的，如图 6.3 所示，春冬季节的成交周期天数小于其他两个季节。为了提高销售速度，我们可以在淡季出售更多地车辆，采取的措施是只在淡季的时候让车辆价格相较于旺季降低，就能促进淡季的销量，因而能够缩短车辆成交周期。这一方法的适用条件是车辆额外降价的季节为淡季即秋冬季节。

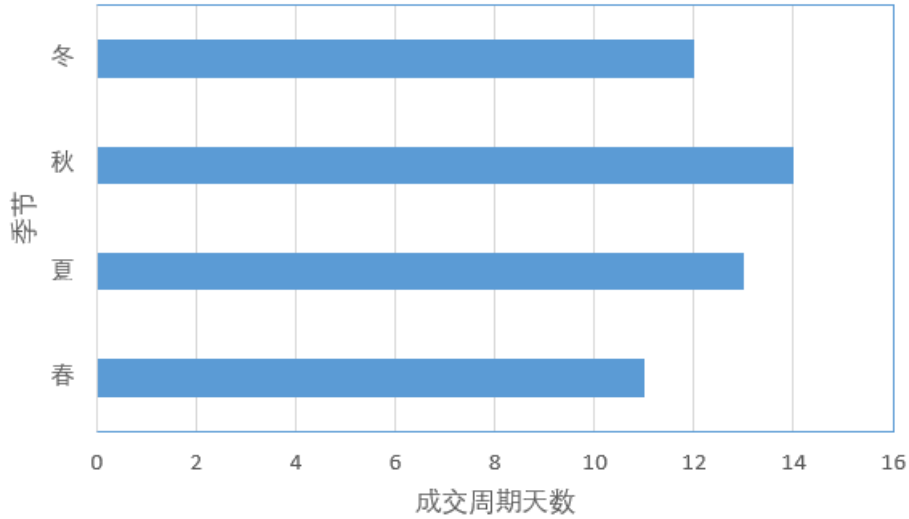


图 6.3 不同季节车辆出售的平均成交周期天数

预期效果我们通过多元线性回归拟合出得到的关系可知，车辆降价幅度每提高 100%，会降低成交周期天数 36.25 天。如果我们在淡季的时候选择降价，降价幅度为 10%，那么我们可以缩短成交周期天数约为 3.625 天。而商家可以根据库存和其他现实需求选择降价的比例。

销售策略：对二手车价格因素的建议与预期效果

针对二手车价格降价的幅度和上架价格的定价这两个因素，为了加快出售的速度，有两种方法。

1. 对于准备出售的二手车，将 pushPrice(上架价格)提高一些，后续进行价格调整，将降价的幅度提高。预期效果和降价的幅度成正比，根据多元线性回归效果，每降低 10%价格，成交周期天数缩短 3.625 天。
2. 考虑上架价格因素影响，将上架价格降低，每降低 1 个单位的上架价格将会缩短 1.5 天的

成交日期。

这两种方法是普遍适用的，需要商家根据个性需求来考虑具体降价的比例。

收购标准-对二手车转户次数因素的建议与预期效果

针对二手车转户次数这个关键因素，如果店内有使用时长较长的二手车，会导致二手车的成交周期延长，如图 6.4 所示。因此为了加快门店内二手车的销售速度，我们需要尽可能地以低价收购转户次数多的二手车，通过降低价格加快二手车的销售速度或者收购时增大转户次数少的二手车的收购比例。预期每降低一次转户次数二手车的收购，车辆的成交周期数会缩短 10.952 天。

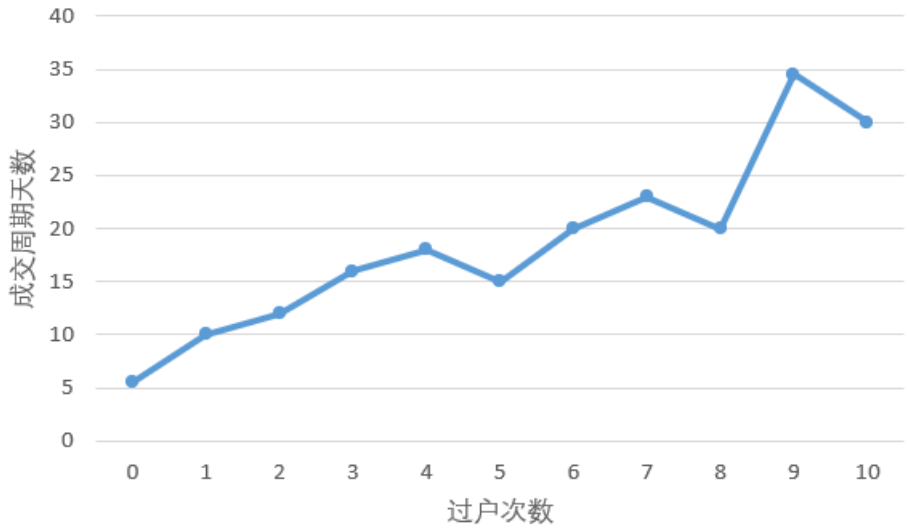


图 6.4 过户次数与成交周期天数的关系

7 问题三研究问题及求解思路

基于问题 3 分析中所列举出的值得研究的问题，给出其求解思路。

7. 1 季节因素对二手车交易价格的影响

7.1.1 按照月份划分季节

本文根据“估价训练数据”和“门店交易数据”获取每一辆二手车的成交时间和成交价格，再按照月份将成交时间划分为春夏秋冬四个季节，即 1-3 月对应春季、4-6 月对应夏季、7-9 月对应秋季，10-12 月对应冬季，对应一年的四个季度，再分别对四个季度的成交价格统计特征进行分析。

7.1.2 统计每个季度二手车交易价格的特征

由于原始交易价格数据存在异常值，如二手车交易价格比新车价格大很多，价格存在突出值等问题，因此在统计每个季度二手车交易价格的特征前，需要对价格的异常值进行处理。

采用问题 1 所使用的数据清洗方法，观察价格数据集的分别，去除异常值，得到一份新的数据集，再基于该数据集计算每个季节二手车交易价格的总和以及平均值，寻找季节因素对二手车成交价格产生的影响。

计算每个季节二手车交易价格的总和如下表所示。

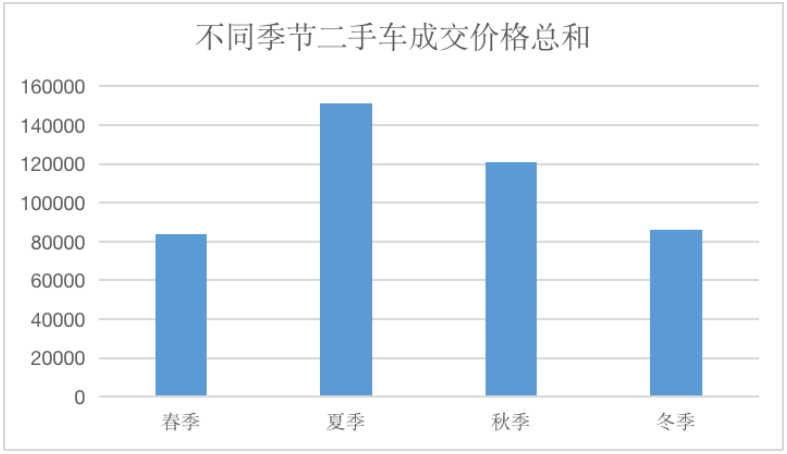


图 7.1 不同季节二手车成交价格总和

计算每个季节二手车交易价格的平均值如下表所示

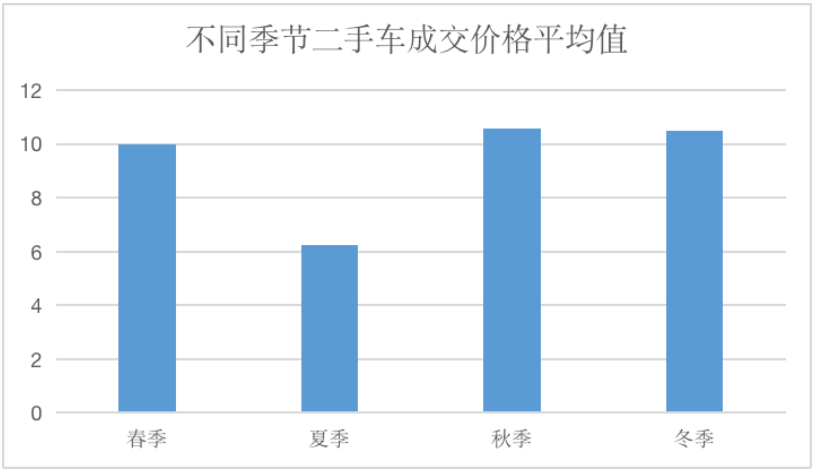


图 7.2 不同季节二手车成交价格均值

7.1.3 统计特征分析

从上图 7.1 可知，本文所给定的样本数据夏季和秋季成交额较多，这说明夏季和秋季是二手车成交的旺季，人们更倾向于在夏季和秋季购买二手车；而观察图 7.2 可知，夏季二手车成交价格的均值与其它季节相比最少，说明夏季虽然二手车成交额较多，但夏季多是中低端二手车占据主要市场。春季、秋季和冬季二手车交易价格的平均值较为稳定。

基于上述分析，季节因素对二手车的成交价格存在一定的影响，如夏季二手车成交总额较多，购车较为实惠，春季和冬季成交额较少。而季节因素对二手车价格的影响是多方面因素促成的，如国家在某个季节出台相应政策调控二手车价格、新车价格变化等。

二手车厂商可以在销售淡季制定合适的营销补贴策略，吸引更多的消费者前来购车，及时关注国家宏观政策调控，加快门店在库车辆的销售速度。

7.2 影响二手车保值率的关键因素

7.2.1 二手车保值率计算

二手车是保值率指某款车型在使用一段时期后，将其卖出的价格与先前购买价格的比值，它是衡量二手车价值的关键指标。本文依据“估价训练数据”中的新车价 newprice 和二手车交易价格 price，以及“门店交易训练数据”中的上架价格 pushPrice，计算二手车的保值率。

其中，定义二手车期望保值率 exp 如下：

$$exp = \frac{pushPrice}{newprice}$$

定义二手车实际保值率 act 如下：

$$act = \frac{price}{newprice}$$

取二手车期望保值率和实际保值率的平均值作为二手车的保值率 R：

$$R = \frac{exp + act}{2}$$

7.2.2 挖掘影响二手车保值率的因素

通过上述二手车保值率计算方法计算出每一辆车的保值率。与问题 2 中求解影响车辆成交周期的关键因素类似，用保值率作为标签，其他特征信息作为自变量特征，放入模型中进行训练。

影响二手车保值率的因素有许多，包括汽车的品牌、车系、车型、新车价格、二手车交易价格等因素，为提取更准确的影响因素，在模型训练之前需要对数据进行预处理，主要包括去除表中未成交车辆的信息，增加车辆成交的特征信息。

处理未成交车辆的保值率

对于合并后的表格数据，存在未成交车辆，无法得知其交易价格，故去除未成交车辆的信息。

构造车辆成交季节特征

原始数据表中不包含车辆的成交季节。因此构造一个新的特征为“成交季节”表示汽车成交的季节，通过将$withdrawDate$中的月份数据映射到对应季节即可。

寻找影响二手车保值率的因素

在对数据进行预处理后，将车辆的保值率作为标签，其他特征作为影响保值率的因子，通过问题 2 所使用的逻辑回归、LASSO 回归、SVM 模型、随机森林模型、LightGBM 模型的树模型、XGBoost 模型得到重要的特征，再投票机制得到最终影响成交周期的关键因素。

在特征的选择上，有过滤法、封装法和嵌入法。过滤法是指照发散性或者相关性对各个特征进行评分，设定阈值或者待选择阈值的个数，选择特征；封装法是指根据目标函数，通常为预测结果

评分，每次选择若干特征，或者排除若干特征；嵌入法是指首先使用某些机器学习的算法和模型进行训练，得到各个特征的权值系数，根据系数从大到小选择特征。

为了使结果更具有代表性，有利于模型训练，本文使用以下两种嵌入法进行特征选择，分别是基于惩罚性的特征选择法和树模型的特征选择法。对于基于惩罚项的特征选择法，本文采用基于 SVM 模型、LASSO 模型、逻辑回归模型的惩罚项特征选择法来选择特征；而树模型的特征选择法随机森林模型、LightGBM 模型的树模型特征选择法来选择特征。

在特征选择完成后，根据上述六种模型选出的结果采用投票法筛选出票数大于等于 2 的特征，作为影响二手车保值率的关键因素。模型的求解结果如下表 7.1 和 7.2 所示。

表 7.1 基于惩罚项的嵌入法选取排名前 5 的特征

	逻辑回归	LASSO 回归	SVM
重要性排序	newPrice	newPrice	newPrice
	price	price	price
	brand	brand	pushPrice
	pushPrice	serial	maketype
	serial	pushPrice	pushPrice

表 7.2 基于树模型的嵌入法选取的排名前 5 的特征

	随机森林	XGBoost	LightGBM
重要性排序(得分)	newPrice	newPrice	newPrice
	price	price	price
	brand	pushPrice	serial
	maketype	maketype	brand
	pushPrice	serial	pushPrice

根据以上 6 个模型的投票结果，可以选出 6 个对二手车保值率影响较大的关键因素，分别是 newPrice（新车价）、price（二手车交易价格）、pushPrice（上架价格）、brand（品牌 id）、serial（车系 id）、maketype（厂商类型）。

因本文采用新车价、上架价格和二手车交易价格计算车辆的保值率，故这三个因素对二手车价格的影响比较重要，即重要性排序靠前。品牌 id、车系 id 以及厂商类型同样对车辆的保值率的有着较为重要的影响，这与市面上影响汽车保值率的关键因素相符。

8 模型评价

8.1 模型的优点

1. 使用了多个回归模型与树模型对价格进行预测，比较多个模型优中择优，得到更好的拟合效果较好。
2. 采取了 stacking 模型融合的方法，将强学习器对数据的学习效果取长补短，提高模型的稳定性和表现。
3. 使用嵌入法进行特征选择，采用投票机制对重要性因素进行选择，筛选出来的关键因素可信度高，也更有说服力。
4. 构造了影响车辆成交周期的季节特征，降价特征，挖掘出了影响车辆成交周期的关键因素。对建议效果进行了量化。

8.2 模型的缺点及改进方向

1. 特征工程中的特征挖掘仍然有许多不足，模型效果不是很好，后续仍可以对特征工程进行更好的处理。
2. 各种树模型参数的调整粒度不够细致，受限于算力与时间，模型的参数还可以继续优化。
3. 特征选择采用机器学习模型，会使样本信息提取不完全导致部分信息丢失，后续可以多进行特征工程。

参考文献

[1] 王静娜. 基于随机森林算法的二手车估价模型研究[D]. 北京交通大学.

[2] 马骊. 随机森林算法的优化改进研究[D]. 暨南大学, 2016.

[3] 贾鹏翔. 基于 LightGBM 的二手车价格预测[D].山东师范大学,2021.

[4] KE, Guolin, et al. Lightgbm: A highly efficient gradient boosting decision tree. Advances in neural information processing systems, 2017, 30: 3146-3154.

[5] CHEN, Tianqi, et al. Xgboost: extreme gradient boosting. R package version 0.4-2, 2015, 1.4: 1-4.

[6] 史佳琪; 张建华. 基于多模型融合 Stacking 集成学习方式的负荷预测方法. 中国电机工程学报, 2019, 39.14: 4032-4041.

[7] 谢玲, 刘琼荪. 集成 Logistic 与 SVM 的二分类算法[J]. 计算机工程与应用,2011(29):149-150.

[8] 曲媛. 基于 SVM 的二分类不平衡数据问题研究[D]. 华南理工大学, 2009.

[9] 周涛丽. 基于支持向量机的多分类方法研究[D]. 电子科技大学.

[10] 丁世飞,齐丙娟, 谭红艳. 支持向量机理论与算法研究综述[J]. 电子科技大学学报, 2011,40(001):2-10.