队伍编号	MCB2200703
赛道	（B）

基于决策树模型对北京移动用户体验影响因素研究

摘要

随着移动通信技术的飞速发展，网络覆盖越来越完善，各个移动运营商越来越重视用户的网络使用与体验，从而进一步提升网络服务质量。

本文则是对北京移动用户体验影响因素的探究，通过分析影响用户体验的主要影响因素，并以此来为决策提供依据，进而提升客户的上网体验。本文基于附件中提供的打分项以及影响打分的各个因素建立了对于客户语音业务和上网业务的数学模型，最终得出量化分析结果，并对附件 3，附件 4 中的客户打分进行了预测。具体本文解决了以下问题。

针对问题一：首先进行数据清洗，根据附件五的描述字段对附件一二数据进行转换，针对特征缺失值的类型分别采用 K 近邻算法（KNN）以及均值填补将特征缺失值补全。之后进行特征工程，对部分类别特征数据进行标签化和独热编码，将附件一“用户描述”字段和附件二“用户备注”字段中的文本进行合并分词，并通过 tf(词频)绘制词云图量化分析，对影响用户打分的主要因素类型进行初步判断。为了对数据集有一个整体把握，我们对处理好的数据做了描述性统计进行分析，并给出了分析结果。之后，引入了 CART 决策树模型针对每项打分提取所有特征的重要性程度，并根据特征的重要性得出了影响客户语音业务满意度的主要因素为 GPRS 总流量（KB）、前 3 月 MOU、当月 ARPU、是否遇到过网络问题，影响客户上网业务满意度的主要因素为重定向次数、年龄、当月 GPRS 资源使用量（GB）、网络信号差/没有信号。然后给出了各因素对客户打分影响程度的量化分析和结果。

针对问题二：为了结合相关因素对用户打分进行一个更好的预测，需要对问题一处理好的数据再次进行特征工程，采用 PCA 主成分降维和特征重构的方式重新构造数据集，基于 CART 决策树模型设定阈值针对每项打分数据进行特征选取，并结合附件三和附件四中已有的特征筛选出主要特征，同时对附件 3 和附件 4 部分缺失特征进行众数填补和特征转换使其格式调整为与训练集相同的格式。之后划分数据集并进行模型训练，首先针对决策树的泛化性能进行后剪枝优化。随后引入了集成学习模型随机森林和 XGBoost，通过网格搜索和五折交叉验证的方式对 CART 决策树模型、随机森林、XGBoost 模型进行超参数优化，最后采取软投票融合机制对上述三个模型进行加权融合，得到最终预测模型，数据带入模型得到了最终用户打分预测结果，并对结果的合理性做出解释说明。

关键词：特征工程，CART 决策树，PCA 主成分降维，随机森林，XGBoost 模型，模型融合

目录

一、问题重述..... 1
1.1 问题背景..... 1
1.2 问题提出..... 1
二、问题分析..... 1
2.1 针对问题一的分析..... 1
2.2 针对问题二的分析..... 1
三、模型假设..... 2
四、符号说明..... 2
五、问题一模型的建立与求解..... 3
5.1 数据清洗..... 3
5.2 特征工程..... 6
5.3 基于决策树模型的特征重要性提取..... 7
5.3.1 特征选择..... 7
5.3.2 构建 CART 分类树模型..... 7
5.3.3 特征重要性..... 8
5.3.4 整体满意度打分主要因素分析..... 9
5.3.5 其余打分影响程度的量化分析..... 10
六、问题而模型的建立与求解..... 12
6.1 模型的选取和数据的优化..... 12
6.1.1 选取目标值和特征值..... 12
6.1.2 代价复杂度 CPP 决策树后剪枝..... 15
6.2 随机森林模型..... 18
6.3 XGBoost 模型..... 19
6.4 随机森林和 XGBoost 模型的超参数优化..... 20
6.5 模型融合..... 23
6.6 基于决策树模型的预测及结果合理性..... 24
七、模型评价..... 24
八、模型推广..... 25
参考文献..... 25
附录..... 26

一、问题重述

1.1.问题背景

随着移动通信技术的飞速发展，运营商们都非常重视客户的网络使用体验，从而进一步提升网络服务质量。在信息透明，产品同质化的今天，客户满意度的表现成为各大运营商市场运营状况的重要体现，客户满意才能推动商业决策的实行，从而进一步推动移动网络的高质量可持续发展。由于创痛的方法已经难以有效的提升客户的满意度，这次拟通过分析影响用户满意度的各种因素，从而更快、更全面的提升用户满意度。

1.2.问题提出

基于以上背景，要求我们通过数据分析与建模的方法帮助中国移动北京公司解决以下问题：

1.分别给出影响客户语音业务和上网业务满意度的主要因素，并且给出各个因素对于客户的满意度影响程度的量化分析和结果。

2.通过问题一的分析，创建客户语音业务和上网业务客户打分的相关影响因素的数学模型，并对附件 3，附件 4 中的客户打分进行预测。

二、问题分析

2.1 针对问题一的分析

首先对附件 1 和附件 2 的数据进行数据清洗，根据附件 5 的字段描述，将原始数据进行转换，针对特征缺失值的类型分别采用 K 近邻算法（KNN）以及均值填补将特征缺失值补全，然后进行特征工程，利用分类特征编码和 tf(词频)对数据集特征进行了量化。我们还对处理后的数据进行了描述性统计，以便方便后续的研究。之后建立 CART 决策树模型，对数据集进行分类并计算每个特征的重要性，最终得出影响客户打分项目的主要因素及量化分析结果。

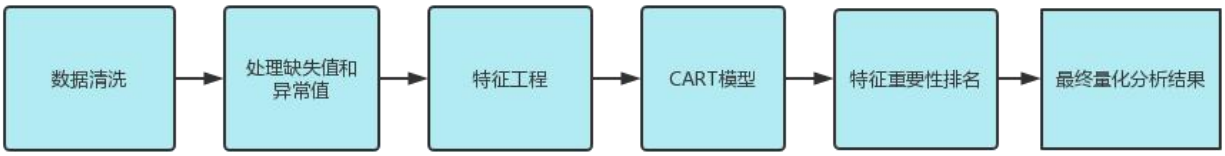


图 1.问题一思路流程图

2.2 针对问题二的分析

首先对数据集再进行特征工程，利用 PCA 主成分降维和特征重构重新选取，选取出重要性较大的特征。之后利用选取的特征建立 CART 决策树，随机森林，XGBoost 模型，并以 7：3 的比例划分训练集与测试集，然后利用网格搜索和五折交叉验证对模型调参寻取最优参数，之后对模型进行软投票加权法进行融合，从而达到进一步稳定预测的目的。随后，我们对附件 3，附件 4 中的数据进行了预处理，使之成为与训练集格式一样的数据，最终得到了预测结果，并解释了预测结果的合理性。

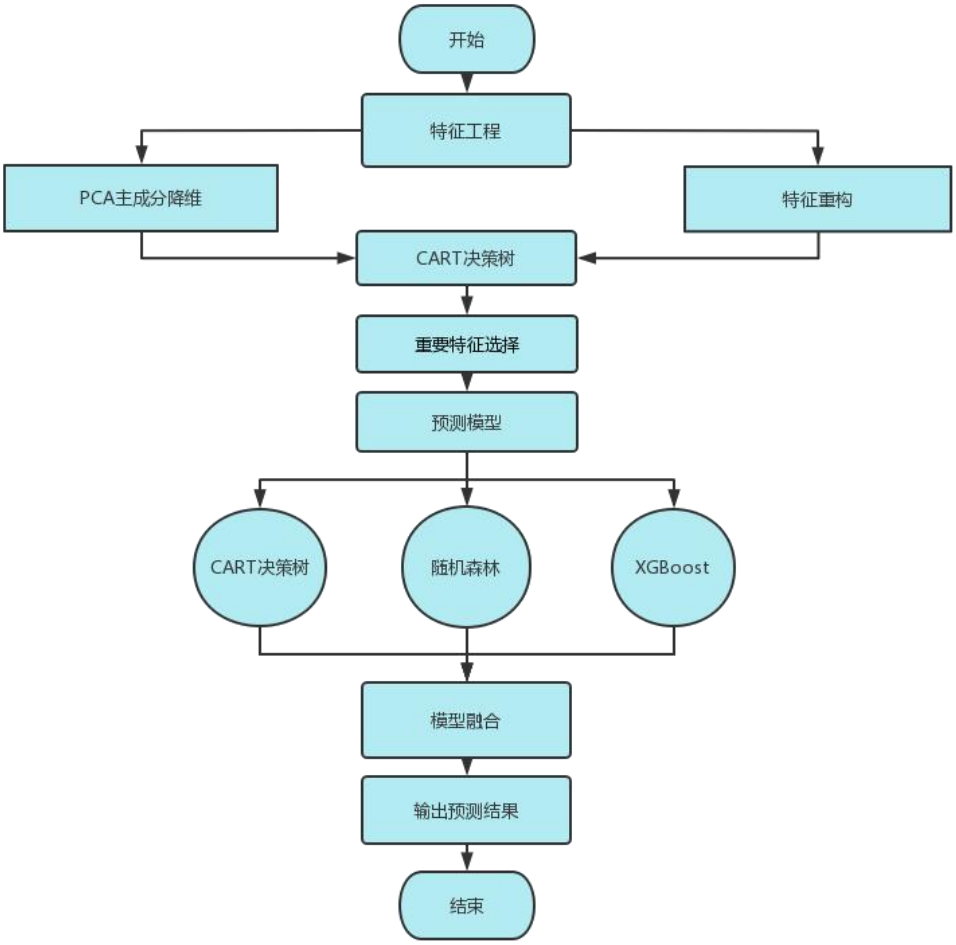


图 2 问题二思路流程图

三、模型假设

1. 假设题目中所给出的数据真实有效。
2. 假设客户对语音业务和上网业务的满意度不受除附件给出的其它因素影响。
3. 假设调查群体基本具有相同的特征。

四、符号说明

下表列出了一部分符号，文中出现的其它符号在相应位置给予解释

符号	符号说明
I	特征重要性
$Gini$	基尼系数
$Gini-index$	基尼指数
result	表示在分类时属于某类的概率

五、问题一　模型的建立与求解

5.1 数据清洗

附件 1、附件 2 给出的原始数据集中，介于给出的数据量非常庞大，信息复杂，涉及到的影响因素众多等，可能会导致原始数据集出现缺失值、异常值等现象，影响本文数据挖掘及分析的结果，因此本文先对原始数据集进行初步数据清洗。

1.对数据集进行初步转换

根据附件 5 给出的附件 1、附件 2 的字段说明，对数据进行一系列处理，根据描述字段的分析，对数据集进行以下转换，转换方式见**图 3**：

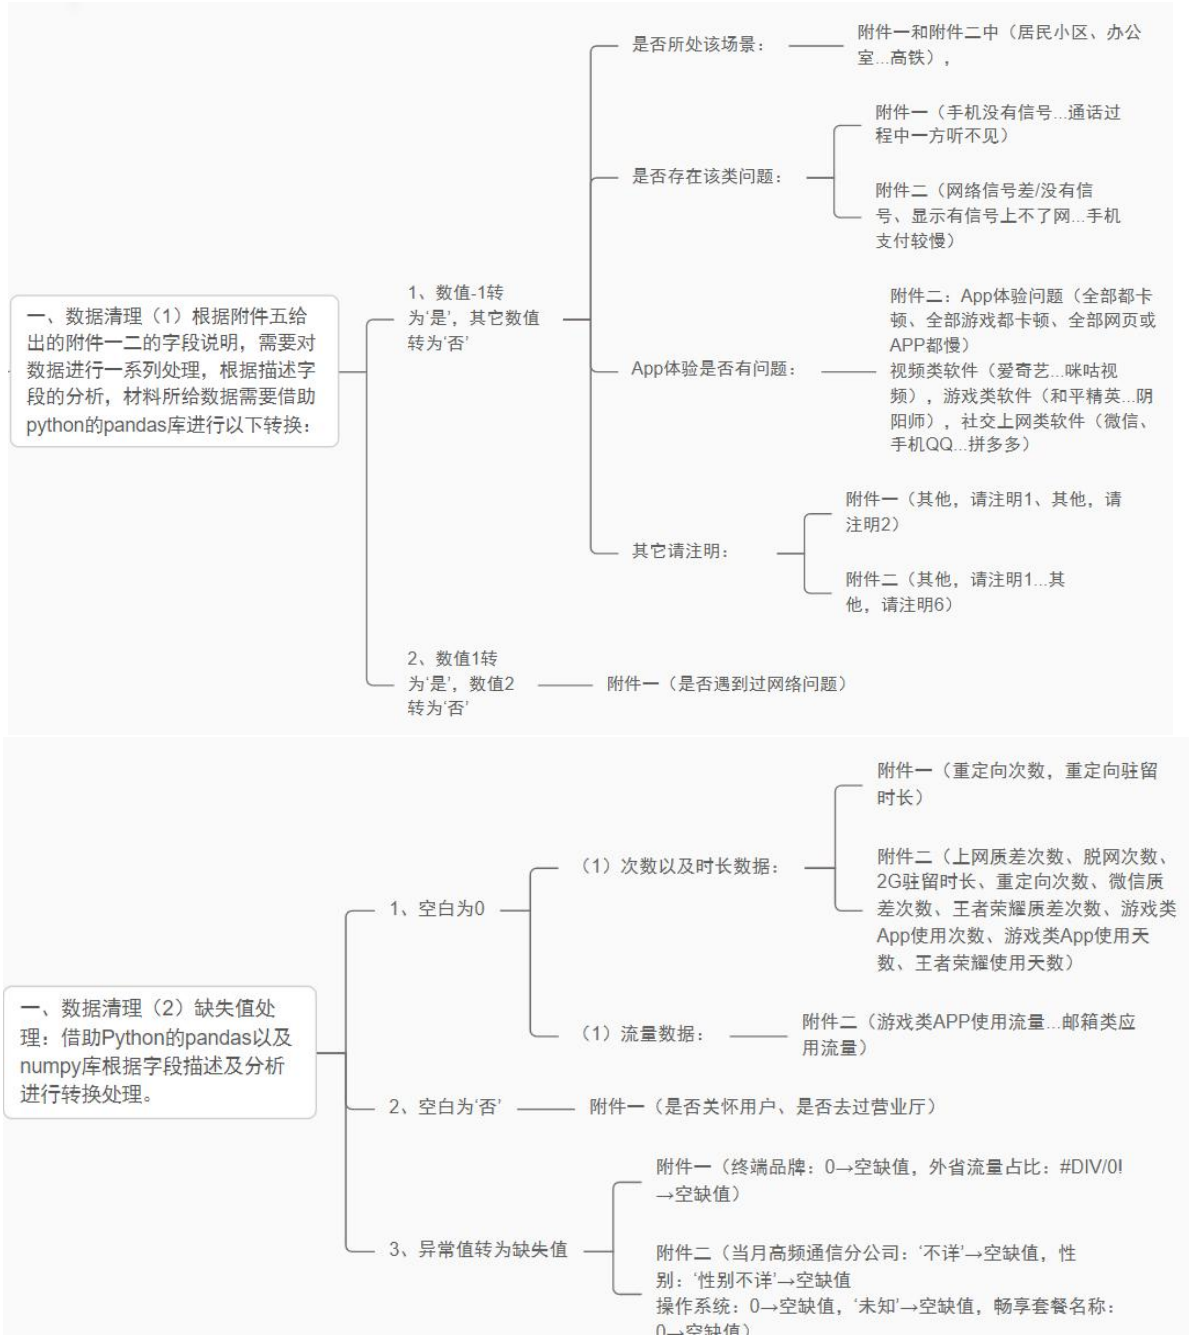


图 3 数据集转换详情图

经过以上处理之后，对附件 1 和附件 2 的数据列缺失值进行统计分析，结果见**图 4** 和**图 5**：

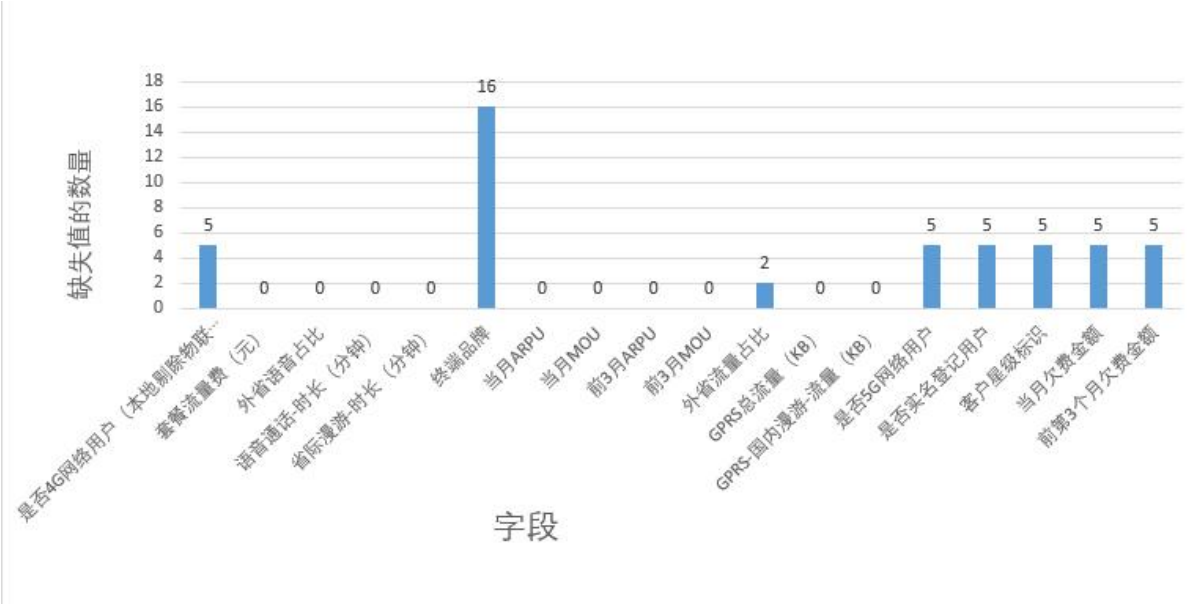


图 4 附件 1 缺失值统计

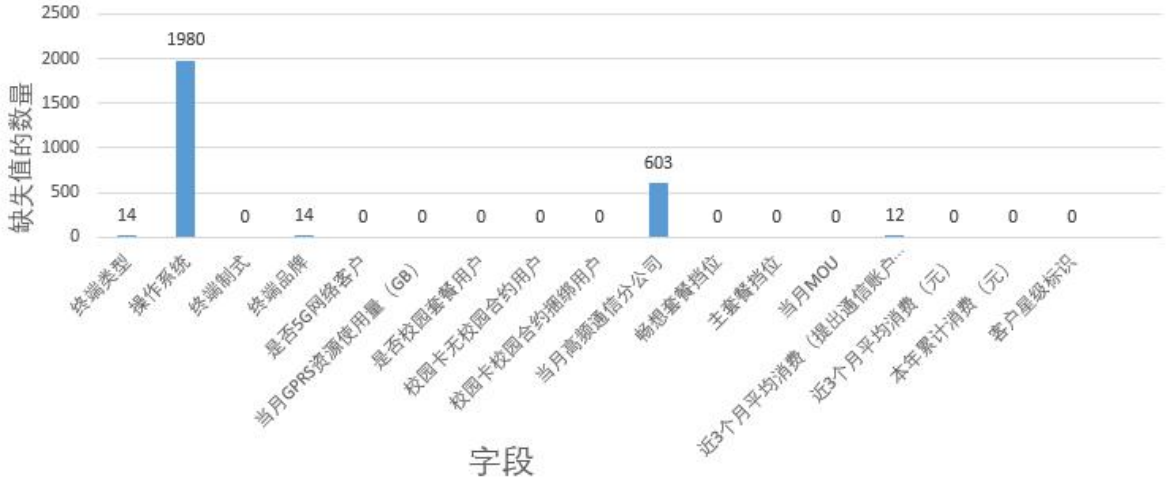


图 5 附件 2 缺失值统计

2. 删除缺失值过量的特征

数据集中“畅享套餐名称”、“码号资源-激活时间”、“码号资源-发卡时间”特征缺失值较多，超过 50%，缺失值占比见**图 6**：

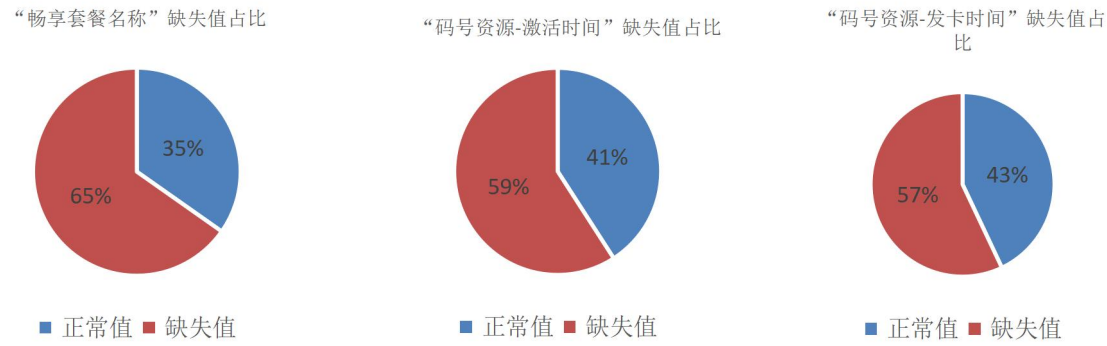


图 6　畅享套餐名称、码号资源-激活时间、码号资源-发卡时间特征缺失值占比

上述特征由于缺失值占比过高，强行填补会造成较大的偏差，因此将该类特征删除。

3. 缺失值填补

（1）连续型数据

附件 1 中“外省流量占比”、“当月欠费金额”、“前三个月欠费金额”

附件 2 中“近三个月平均消费（剔除通信账户支付）”均为连续型数据，采用平均值填补其缺失值。

（1）类别型缺失值

通过观察数据集，附件 1 中“是否 4G 网络客户（本地剔除物联网）”、“终端品牌”、“是否 5G 网络客户”、“是否实名登记用户”、“客户星级标识”和附件 2 中“终端类型”、“终端品牌类型”、“操作系统”、“终端品牌”、“当月高频通信分公司”、“性别”均为类别变量，因此本文采用 K 近邻（KNN）分类算法预测填补。

KNN 算法的主要思想就是待预测样本点与其它样本点距离进行计算，然后保存并排序，选出距离最近的 K 个样本点，若这 K 个样本大多数属于类别 M，则将该待预测样本归为 M。具体步骤如下：

1）选取特征

附件 1 中选取“语音通话整体满意度”、“语音通话清晰度”、“语音通话稳定性”、“网络覆盖与信号强度”这 4 个字段作为特征变量。

附件 2 中选取“手机上网整体满意度”、“网络覆盖与信号强度”、“手机上网速度”、“手机上网稳定性”这 4 个字段作为特征变量。

2）计算欧式距离

本文利用欧式距离公式计算待预测样本点和其它样本点的距离，即预测样本点与其他样本点的相似程度。本文假设待测样本点 A 的坐标为(A_1, A_2, A_3, A_4)，其它样本点 B 的坐标为(B_1, B_2, B_3, B_4)，那么 A、B 两点的欧式距离为：

$$|AB| = \sqrt{(A_1 - B_1)^2 + (A_2 - B_2)^2 + (A_3 - B_3)^2 + (A_4 - B_4)^2}$$

3）根据 K 值判定类别

计算得到待预测样本与所有样本的欧式距离后，根据距离的远近对其它样本进行升序排序。最终选取前 K 个其它样本并得到其中最多的类别（本文选取的 K 值为 9），实现待预测样本的归类，完成类别型缺失值的填补。

4.数据的整体分析

在完成上述数据预处理工作后，为了对数据有一个整体的把握，对处理好的数据和附件 3，附件 4 中的数据进行描述性统计，分别计算了样本量、最大值、最小值等统计量来研究定量数

据的基本情况。根据统计结果发现绝大部分数据的变异系数（CV）都大于 0.15，在这些数据基本上都存在异常值，即题目中给出的真实数据中每一项都存在异常值，这是由于打分数据太过于主观而导致的。在相同的因素下，不同的人的满意状况不相同，因此会造成很大的打分差距。**（总体描述结果见附录 1）**

5.2. 特征工程

完成数据清洗工作后，接下来是对数据集的特征工程。

1. tf（词频）

tf 是用以评估一字词对于一个文件的重要程度的一种统计方法。通过观察数据集，我们发现附件 1 中的“用户描述”和附件 2 中的场景备注数据、现象备注数据、APP 大类备注、APP 小类视频备注、APP 小类游戏备注、APP 小类上网备注等文本数据是主观评判数据，因此决定通 tf 来对这些数据进行处理。本文通过 Python 对每个用户的描述数据进行了合并，将所有词语合成在一个文件中，并通过 jieba 库进行分词，然后计算每一个词所对应的 tf 值。

tf 公式如下：

$$tf = \frac{n_i}{\sum_k n_k}$$

其中 n_i 表示所有用户评语中某词出现的次数，$\sum_k n_k$ 表示所有评语的总词数。

右图是根据**附件一和附件二**用户描述和备注字段词频绘制的词云图，可以看到，影响用户语音业务满意度和手机上网满意度的主要因素类型是网络信号和所处的地点。



图 7　词云图

2. 分类特征编码

（1）LabelEncoder 编码

本文中针对二分类特征对数据进行 LabelEncoder 编码，转换方式见**图 8**：

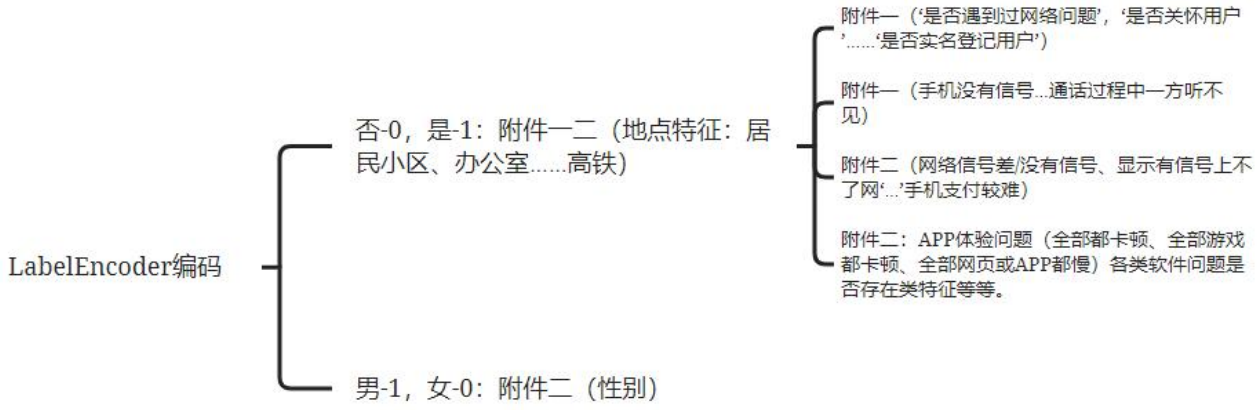


图 8　LabelEncoder 编码详情图

（2）独热编码（One-Hot Encoding）：

针对多分类特征（大于三个类别），并且类别之间不存在大小比较意义，因此，本文对多分类特征（大于三个类别）进行独热编码。

以附件 2“终端制式”样本为例：

终端制式	终端制式=4G终端	终端制式=5G终端	终端制式=2/3G终端
4G终端	1	0	0
5G终端	0	1	0
2/3G终端	0	0	1

图 9　“终端制式”样本独热编码

由于附件 1、附件 2 中的“终端品牌类型”种类过多（共 631 项），用独热编码会造成维度暴涨，所以对类别特征编码时排除该特征。

5.3 基于决策树模型的特征重要性提取

决策树（Decision Tree）是一种自上而下，对样本数据进行树形分类的过程。决策树由结点和有向边组成。每个内部结点表示一个特征或属性，叶节点表示类别。样本从从顶部的根节点开始划分，样本被分到不同的子节点中。再根据子节的特征进行进一步划分，直至所有样本都被归到某一叶结点中。

本文采用的是一种常见的决策树构造算法 CART 分类树。

5.3.1. 特征选择

CART 分类树中是利用基尼指数（Gini index）作为节点选取标准点的特征进一步划分，直至所有样本都被归到某一叶节点中。

设样本集合 D 中有 K 类样本，样本集合 D 中第 K 类样本所占的比例为 $p_k=(k=1,2,...,|K|)$，那么数据集 D 的基尼值定义为：

$$\mathrm{Gini}(D)=1-\sum_{k=1}^{|K|}p_k^2$$

基尼值反映的是两个样本类别标记不一致的概率，数据集的基尼值越小，纯度越高。

设离散属性 a 有 V 个可能的取值 $\{a_1,a_2,...,a_v\}$，用 a 来对样本集合进行划分会产生 V 个分支节点，其中，第 v 个分支节点包含了 D 中所有在属性 a 上取值为 V 的样本，记为 D_v。属性 D 的基尼指数为：

$$Gini-index(D,a)=\sum_{v=1}^{V}\frac{|D_v|}{|D|}Gini(D_v)$$

在构建决策树过程中，选取使划分后基尼指数最小的属性作为最优的划分属性，即 $a'=\arg\min_{a\in A} Gini-index(D,a)$

5.3.2. 构建 CART 分类树模型

在构建树的过程中，选择最优属性作为测试属性，将测试属性取值相同的样本划分到同一个样本子集中；如果该样本集类别中只有一个属性，则分支为叶子节点，否则对该样本集采用递归调用算法。模型具体建立过程见图 10：

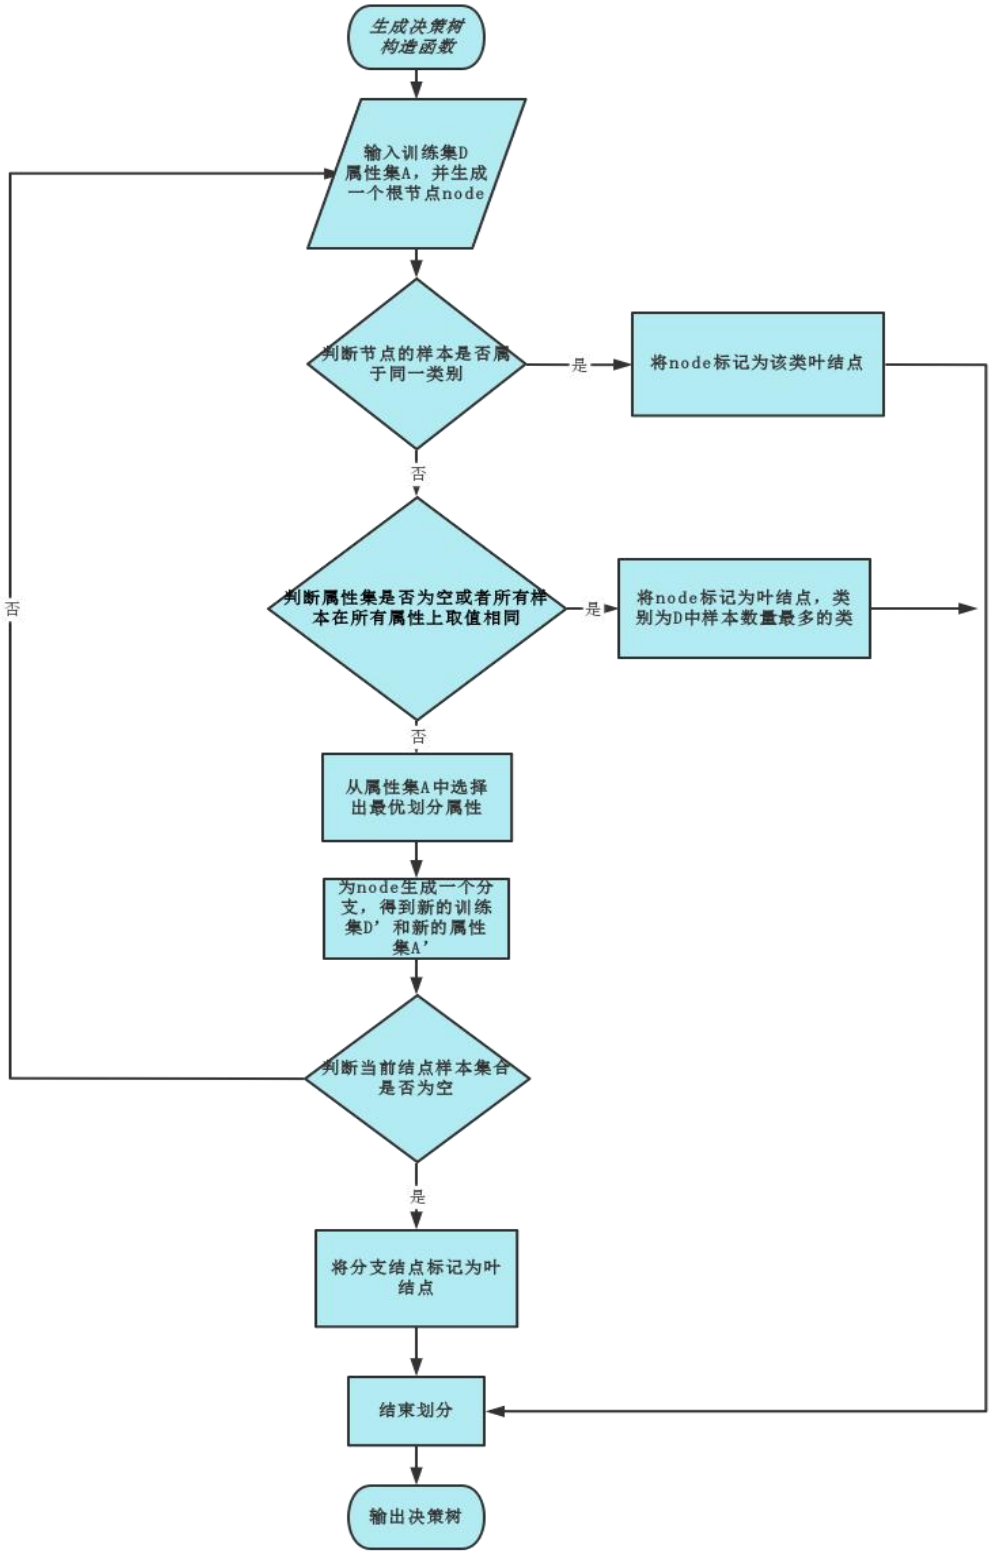


图 10　CART 模型构建具体流程

5.3.3.特征重要性

为了研究影响客户语音业务和上网业务满意度的主要因素，需要对决策树中的特征计算出特征的重要性。特征重要性越高，表示该特征对其满意度的影响越大。本文决定用特征重要性来评估对影响客户语音业务和上网业务满意度的主要因素。

CART 模型构造好后，对每一个特征计算其重要性，对每个特征计算它的基尼系数，特征重要性为基尼系数减少量的归一化值。

设在该数据集中的样本总数为 N， N_t 是决策树中某一结点的样本数目， L_t 是在这一结点处左孩子的样本数目，R_t 是在这一结点处右孩子的样本数目，该处结点的基尼系数为 $Gini(D)$，左孩子的基尼系数为 $Gini(L)$，右孩子的基尼系数为 $Gini(R)$；那么该结点处所对应的特征重要性为：

$$I = \frac{N_t}{N}\left(Gini(D) - \frac{R_t}{N_t}Gini(R) - \frac{L_t}{N_t}Gini(L) \right)$$

最后根据每个特征的特征重要性进行降序排序，并将数据汇总在 csv 文件，存放在支撑材料中。

5.3.4. 整体满意度打分主要因素分析

对于语音通话整体满意度和手机上网整体满意度的两个打分项目采用 5.3.1 中建立的模型，采用 5.3.3 中的公式计算出每个特征的重要性。由于篇幅有限，仅展示出特征重要性排名前十名结果，结果见**表 1** 和**表 2**：

表 1　语音通话整体满意度特征重要性前十名

GPRS 总流量（KB）	0.125644
前 3 月 MOU	0.105648
当月 ARPU	0.102283
是否遇到过网络问题	0.090247
当月 MOU	0.06138
语音通话时长（分钟）	0.058187
Mos 质差次数	0.049293
脱网次数	0.0352
未接通掉话次数	0.028615
重定向驻留时长	0.021474

从上表可以看到影响语音通话整体满意度的主要因素为:“GPRS 总流量(KB)”“前 3 月 MOU”、“当月 ARPU”、“是否遇到过网络问题”。

表 2　手机上网整体满意度特征重要性前十名

重定向次数	0.08170442
年龄	0.051158538
当月 GPRS 资源使用量（GB）	0.046827913
网络信号差/没有信号	0.039974137
通信类应用流量	0.033789474
当月 MOU	0.032047617
网页类应用流量	0.029131373
优酷视频使用流量	0.028134721
小视频系 APP 流量	0.026828634
阿里系 APP 流量	0.026439612

从上表可以看到影响手机上网整体满意度的主要因素为：“重定向次数”、“年龄”、“当月 GPRS 资源使用量（GB）”、“网络信号差/没有信号”。

5.3.5 其余打分影响程度的量化分析

由于附件 1 和附件 2 中两个满意度各存在三个打分项目，依然采用 5.3.1 中建立的模型，并采用 5.3.3 中的公式计算特征重要性，由于篇幅限制，仅展示特征重要性排名前十结果，结果见**表 3-表 8。（剩余特征的量化分析结果见附录 2）**

表 3　附件 1 网络覆盖与信号强度特征重要性前十名

GPRS 总流量（KB）	0.12798
当月 ARPU	0.10791
前 3 月 MOU	0.09952
是否遇到过网络问题	0.09703
Mos 质差次数	0.06102
当月 MOU	0.05995
语音通话-时长（分钟）	0.05946
未接通掉话次数	0.03023
脱网次数	0.02915
重定向驻留时长	0.02000

表 4　附件 1 语音通话清晰度特征重要性前十名

GPRS 总流量（KB）	0.11892
当月 ARPU	0.11012
前 3 月 MOU	0.09129
是否遇到过网络问题	0.09222
Mos 质差次数	0.06423
当月 MOU	0.05820
语音通话-时长（分钟）	0.05752
终端品牌-苹果	0.01882
脱网次数	0.03945
重定向驻留时长	0.02247

表 5　附件 1 语音通话稳定性特征重要性前十名

GPRS 总流量（KB）	0.11073
是否遇到过网络问题	0.10525
前 3 月 MOU	0.10456
当月 ARPU	0.086006
语音通话-时长（分钟）	0.06882
当月 MOU	0.06078
Mos 质差次数	0.05986
脱网次数	0.03810
未接通掉话次数	0.02198
重定向驻留时长	0.01767

表 6　附件 2 网络覆盖与信号强度特征重要性前十名

GPRS 总流量（KB）	0.12798
当月 ARPU	0.1079
前 3 月 MOU	0.0995
是否遇到过网络问题	0.0973
Mos 质差次数	0.06102
当月 MOU	0.0599
语音通话-时长（分钟）	0.05946
未接通掉话次数	0.0302
脱网次数	0.0291
重定向驻留时长	0.02000

表 7　附件 2 手机上网速度特征重要性前十名

重定向次数	0.07989
年龄	0.04123
通信类应用流量	0.03499
今日头条使用流量	0.0349
腾讯视频使用流量	0.03368
当月 MOU	0.03353
手机上网速度慢	0.03130
当月 GPRS 资源使用量	0.03062
上网过程中网络时断时续或时快时慢	0.02940
视频类应用流量	0.02817

表 8　附件 2 手机上网稳定性特征重要性前十名

重定向次数	0.07784
年龄	0.04307
当月 MOU	0.04271
通信类应用流量	0.0397
当月 GPRS 资源使用量（GB）	0.0373
上网过程中网络时断时续或时快时慢	0.03725
网络信号差/没有信号	0.03694
网页类应用流量	0.02841
今日头条使用流量	0.02712
本年累计消费（元）	0.02581

六、问题二　模型的建立与求解

在本问题中将要建立基于决策树模型的预测模型，并且引入集成学习模型，为了提高模型的预测效果，首先对问题一中已处理好的数据进一步优化处理，对降维后的数据进行特征重构和特征选择，同时对决策树模型进行剪枝以提高其泛化能力，随后建立了随机森林模型及 XGBoost 分类模型，对选取的数据集进行拟合，同时通过网格搜索和五折交叉验证对模型超参数进行优化，最后将三种模型通过软投票加权法进行融合，进一步提高模型预测的准确率。

6.1 模型的选取和数据的优化

在上述决策树模型中，由于对多分类特征进行了独热编码，使得原数据集维度扩张，在这种情况下，建立的树模型会出现过拟合的风险，降低模型泛化性能。因此，为了提高模型的预测效果，对整体数据集进行了特征降维重构，接着基于重构的特征带入 CART 决策分类树模型设定阈值对特征进行选择选取用来预测的特征值。

6.1.1 选取目标值和特征值

下文中模型的目标值分别为 8 个打分项目，即“语音通话整体满意度”、“网络覆盖与信号强度”、“语音通话清晰度”、“语音通话稳定性”、“手机上网整体满意度”、“网络覆盖与信号强度”、“手机上网速度”、“手机上网稳定性”。

接下来是对特征值的选取，在选取之前，需要对数据集进一步加工处理，本文采用 PCA 主成分降维及特征合并两种方式进行特征重构。

（1）PCA 主成分降维

主成分分析(Principal Component Analysis，PCA）是一种无监督学习的多元统计分析方法，主要思想是将 n 维特征映射到 k 维上，这 k 维特征被称为主成分，是在原有 n 维特征的基础上重新构造出来的 k 维特征，本文将降维的数据原有的 n 维特征全部降至一维。过程如下：

假设该类别的数据集中有 n 条 k 维数据，将数据按列组成 k 行 n 列矩阵 k

1）对数据样本中心化，即将矩阵 k 中样本数据均值为零，方差为一；

$$\sum_i x_i = 0$$

2）计算出协方差矩阵 $C = \frac{1}{m} XX^T$ 即：

$$C = \begin{pmatrix} cov(x_1,x_1) & cov(x_1,x_2) & \cdots & cov(x_1,x_m) \\ cov(x_2,x_1) & cov(x_2,x_2) & \cdots & cov(x_2,x_m) \\ \vdots & \vdots & \ddots & \vdots \\ cov(x_m,x_1) & cov(x_m,x_2) & \cdots & cov(x_m,x_m) \end{pmatrix}$$

其中 $cov(x,y)$ 为两个样本变量之间的协方差，$\bar{x}$ 、$\bar{y}$ 为两个样本变量的均值，即：

$$cov(x,y)=\frac{\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{n-1}$$

4）求出协方差矩阵的特征值及对应的特征向量，并将求出的特征向量按对应特征值大小排序，取第一行组成矩阵 P，最终求得 $Y=PX$ 即为数据降到一维后的数据。

对数据集中一部分数据进行 PCA 主成分降维，详情见图 11。

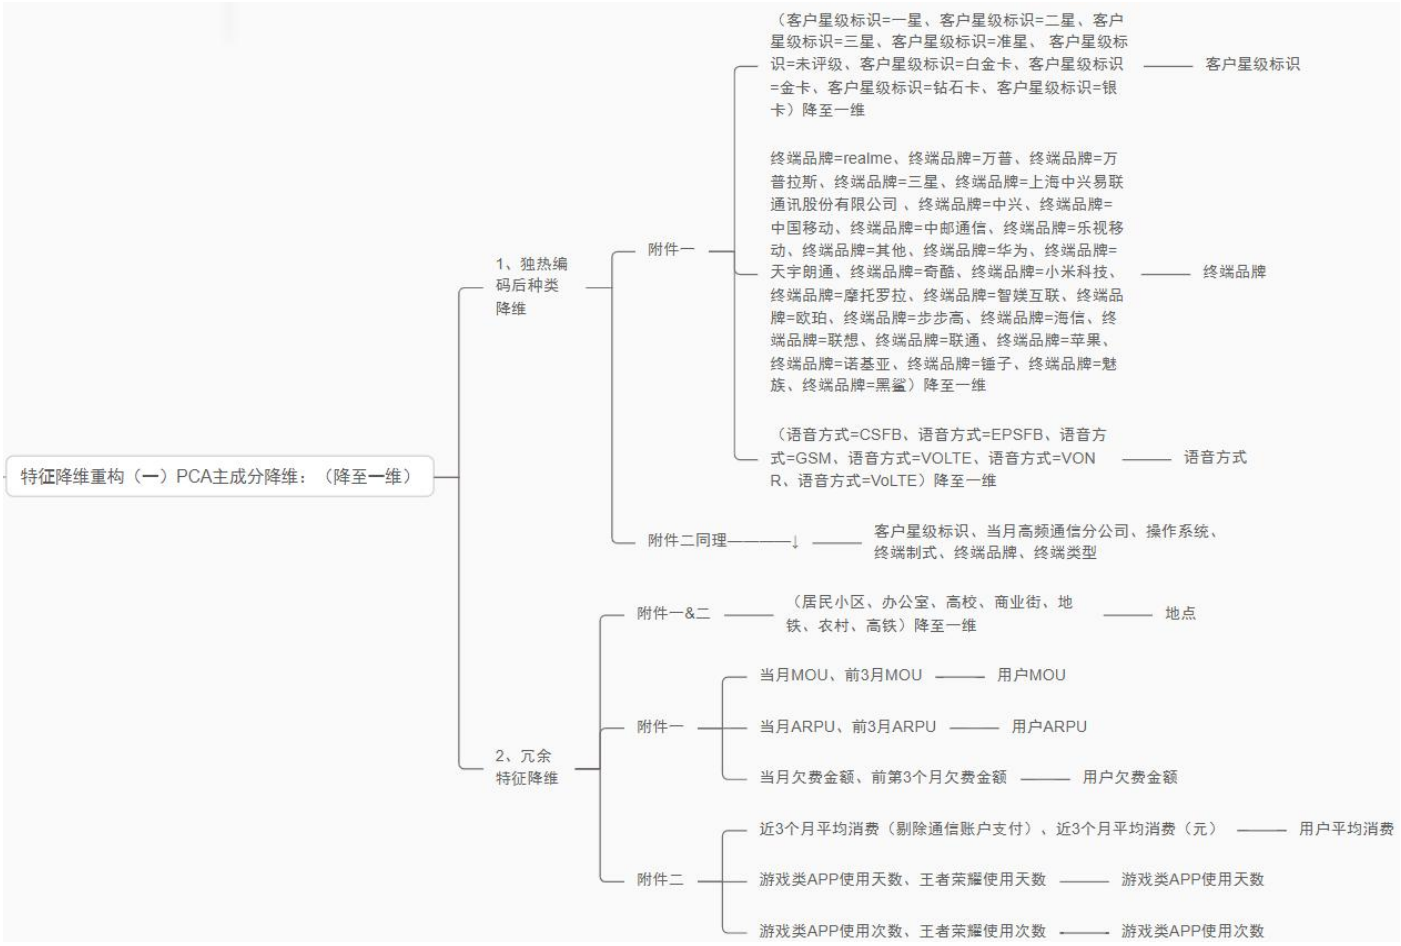


图 11　PCA 主成分降维详细情况

（2）特征合并

根据描述字段将一些相似特征进行相加合并归为一类特征。例如对附件 1 中（手机没有信号、有信号无法拨通、通话过程中突然中断、通话中有杂音、听不清、断断续续、串线、通话过程中一方听不见）这些特征进行相加变为新的特征“网络问题出现总个数”。

对数据集特征合并的详细处理方式见图 12：

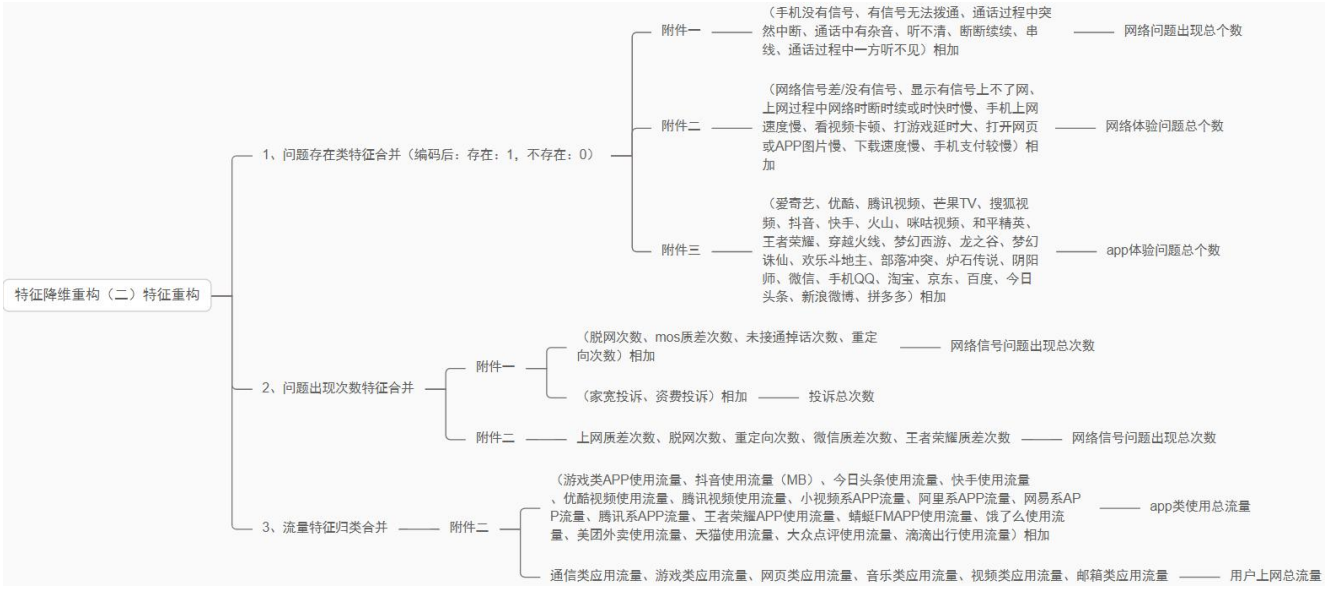


图 12　特征合并详情

（3）基于决策树模型的重要特征选择

1）附件 1 重要特征选择

将重构后的特征数据引入 CART 分类树模型中，得到了新的特征重要性结果（**附件 1 和附件 2 中特征重要性结果见附录 3**）。通过 sklearn 库中 SelectFromModel 方法设定特征选择的阈值为特征重要性均值进行特征选取，最终选择出特征重要性大于均值的特征作为用于模型训练的特征值，最终选取的特征见**表 9**：

表 9　附件 1 语音业务用户满意度特征选择结果

GPRS 总流量（KB）
用户 MOU
用户 ARPU
语音通话-时长（分钟）
网络信号问题出现总次数
是否遇到过网络问题
地点
网络问题出现总个数

2）附件 2 重要特征选择

采用与附件 1 重要特征选择一样的方法，先选取特征值大于均值的特征，考虑到附件 2 给出的数据中的部分特征在附件 4 中并未出现，附件 4 中给出的数据集与附件 2 中给出的数据集相差过大，为了使附件 2 与附件 4 数据集统一为相同的格式，排除了进行特征融合后在附件 2 中存在，但在附件 4 中缺失过多的部分特征，之后再选取特征重要性排名前十的特征，选取结果见表 10.

表 10　附件 2 上网业务用户满意度特征选择结果

网络体验问题总个数
当月 MOU
当月 GPRS 资源使用量（GB）
地点
网络信号问题出现总次数
性别
app 体验问题总个数
全部网页或 APP 都慢
全部游戏都卡顿
全部都卡顿

3）对附件 3 数据的处理

在预测之前，将附件 3 的数据处理成与附件 1 数据集相同的格式：将“重定向次数”采用众数进行填补，剩余数据采用与 5.1，5.2 中所描述的方式处理。然后选取和**表 9** 一样的特征作为预测时的特征。

4）对附件 4 数据的处理

在预测之前，将附件 4 的数据处理成与附件 2 中训练集相同的格式：将缺失特征“王者荣耀质差次数”、“重定向次数”根据附件二数据进行众数填补，附件四的‘GPRS 总流量（KB）’需要进行单位转换转转换为附件二中的‘当月 GPRS 资源使用量（GB）’剩余数据采用与 5.1，5.2 中所描述的方式处理。然后选取和**表 10** 一样的特征作为预测时的特征。

（4）划分数据集

借助 sklearn 库中 model_selection.train_test_split 方法设定随机种子和比例，可以很好地将原数据集中的目标值和特征值按 7：3 的比例划分为训练集和测试集用于后续模型的训练。

6.1.2 代价复杂度 CPP 决策树后剪枝（Cost Complexity Pruning）

为了进一步提高决策树的泛化能力，降低决策树的过度生长造成过拟合的风险，对决策树进行后剪枝处理。

后剪枝是先从训练集生成一棵完整决策树后，对树进行剪枝简化处理。CCP 代价复杂度则是通过下式损失函数的最小化为目标对决策树进行剪枝：

$$L=\sum_{i=1}^{T}\frac{N_i}{N}L_i+\alpha T$$

其中 T 是树中叶子结点的个数，N 是样本总个数，N_i 是第 i 个叶子结点上的样本数量，L_i 是第 i 个叶子结点的损失函数。

L_i 是待定系数，L_i 越大，表示叶节点的个数对损失函数的影响越大，剪枝后的决策树就更容易选择复杂度较小的树，即 T 较小。L_i 越小，表示叶节点的个数对损失函数的影响越小，此时剪枝后的决策树就更容易选择负责都较大的树，即 T 较大。因此，L_i 控制了预测误差与树的复杂度对剪枝的影响。

为了确定最优参数 L_i 的取值，首先通过绘制学习曲线选出较优的取值范围，采用 Python 编程，将测试样本与训练样本代入模型，绘制不同 L_i 取值下决策树在训练样本和测试样本上的精确度。以附件 1“语音通话整体满意度”和附件 2“手机上网整体满意度”两项打分项目为例，参数与模型训练集和测试集精度关系见**图 13** 和**图 14**。

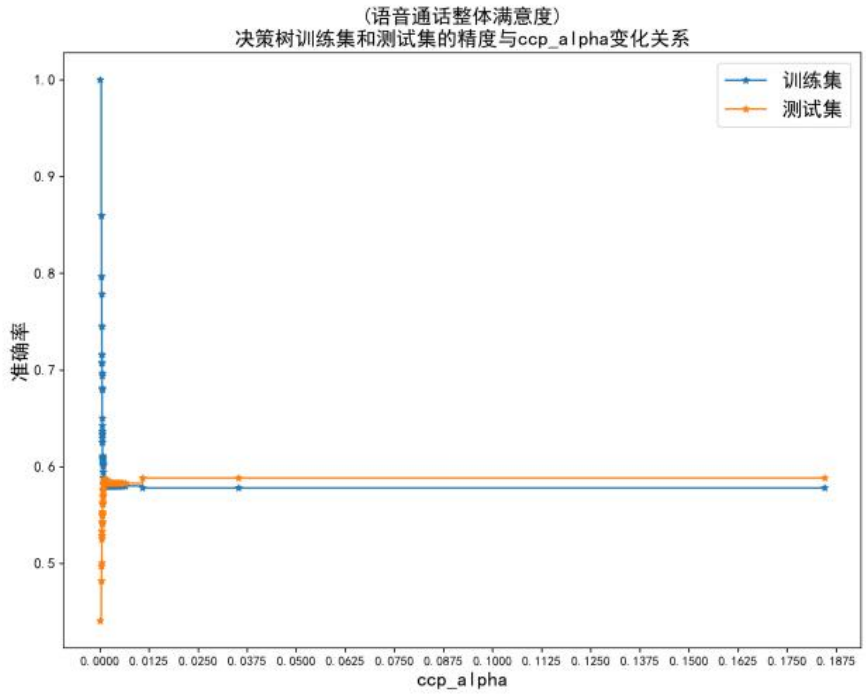


图 13 模型参数α与模型测试集、训练集精度变化关系（语音通话整体满意度）

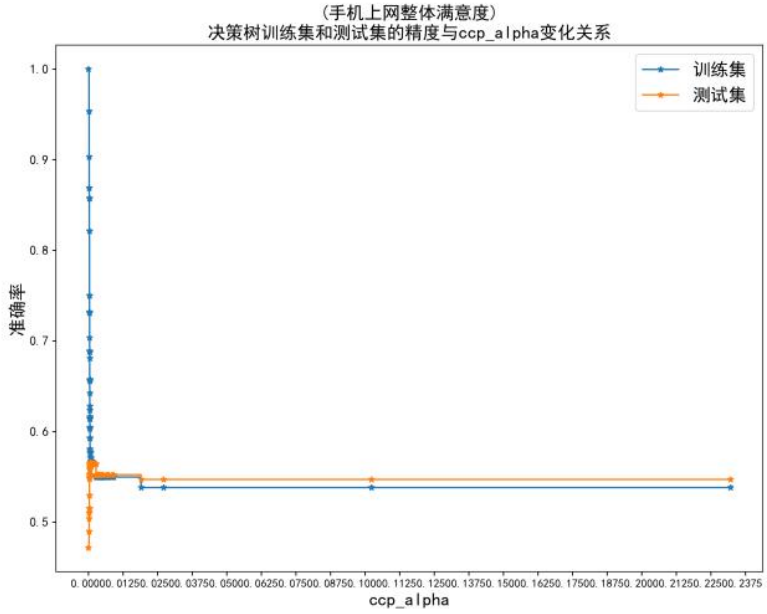


图 14 模型参数α与模型测试集、训练集精度变化关系（手机上网整体满意度）

可以看出最优精度区间都在[0.0000～0.0125]之间。为了提高模型的准确率，在后续超参数优化过程中会在最优区间内进行选择，本文采取网格搜索与交叉验证的方式进一步调参。

（1）网格搜索（Grid Search）

网格搜索是一种穷举方法，即在上述得出的最优精度区间内，将该区间内的参数依次代入模型中进行调试，最终选出较好的参数。随后进行交叉验证的处最优参数组合的得分。

（2）交叉验证（Cross Validation）

交叉验证是将数据集D划分为k个大小相似的互斥子集，然后用$k-1$个子集的并集作为训练集，余下的子集作为测试集，总共可以获得k组测试集和训练集，即进行k次训练及测试，最终返回k次测试结果的均值。这种方法被称为“k折交叉验证”。本文取$k-1$，即5折交叉验证。示意图见**图 15**：

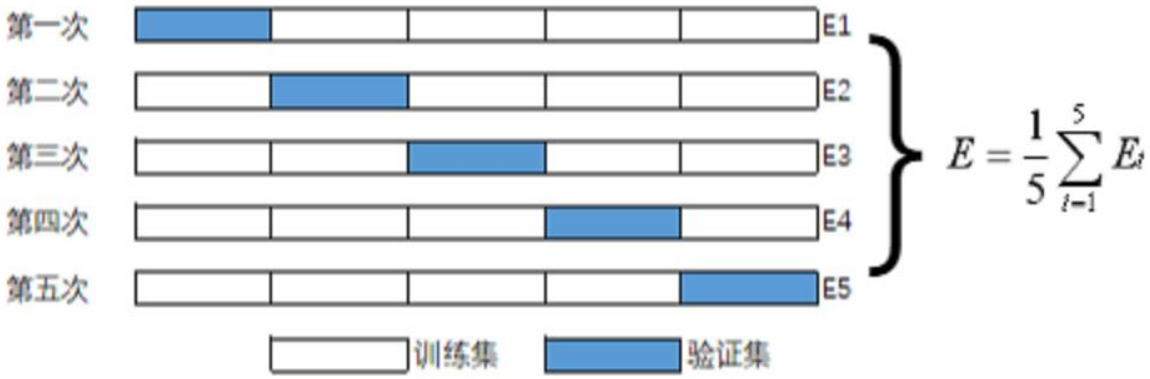


图 15　五折交叉验证示意图

经过网格搜索和5折交叉验证后选取了最优参数，并对CART决策树完成CCP剪枝操作，绘制出后剪枝可视化图，由于篇幅有限，此处展示针对语音通话整体满意度的后剪枝部分可视化，见**图 16**。

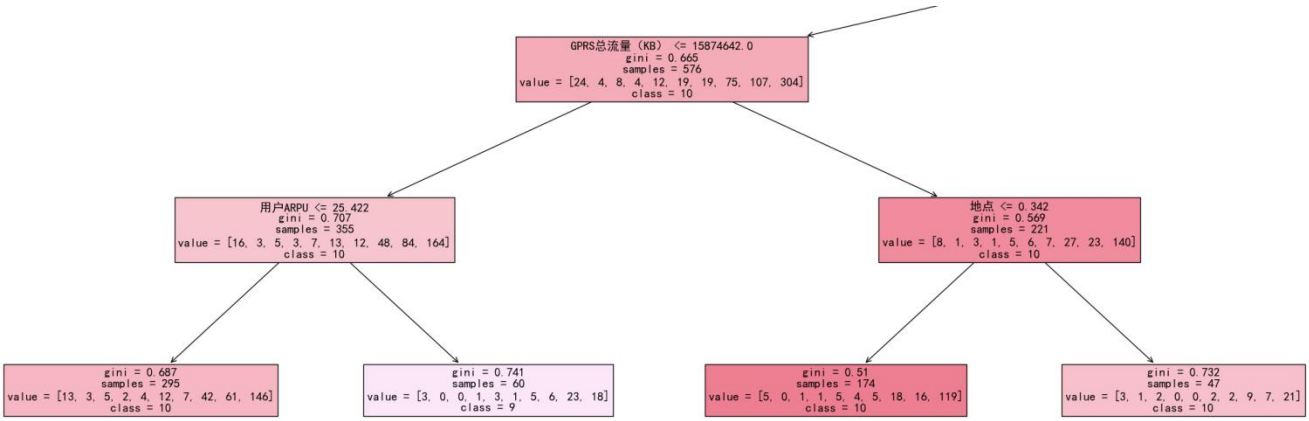


图 16　　CCP 后剪枝后 CART 决策树部分可视化图

本文对剪枝前与剪枝后的CART模型的精度做了对比，并绘制出剪枝前后模型的精度对比图，见**图 17** 和**图 18**。

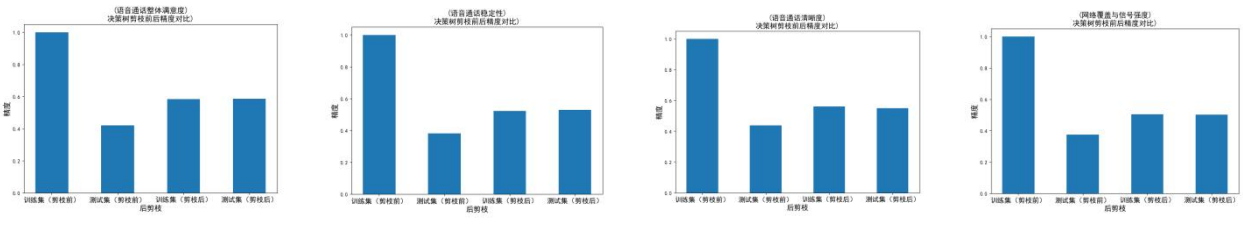


图 17　附件 1 各打分项目 CART 模型剪枝前后精度对比

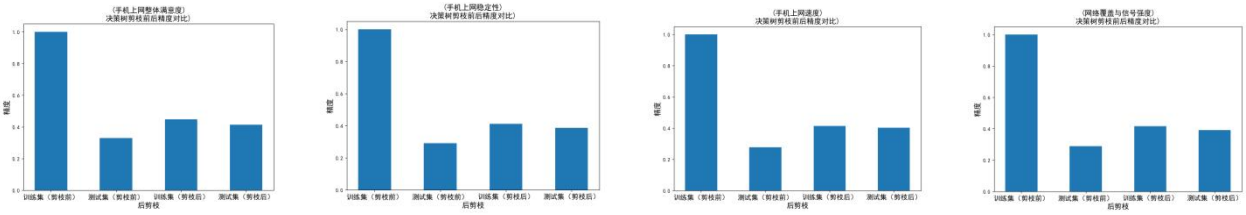


图 18　附件 2 各打分项目 CART 模型剪枝前后精度对比

从图中可以看出，剪枝后的测试集精度都得到了有效的提升，过拟合现象得到大幅缓解。

6.2 随机森林模型

随机森林（Random Forest）是一种集成学习模型，先产生一组基学习器，然后用某种策略将这些学习器组合起来，通常决策树被用做基学习器。决策树本身属于弱学习器，但经过集成之后会有很强的预测效果，成为强学习器。随机森林本质上是多棵决策树组合在一起的多数投票结果。

随机森林的算法步骤如下：

（1）使用训练数据训练模型，从数据样本集中抽取训练集，共进行 k 轮抽取，共得到 k 个相互独立的训练集。

（2）特征选取：根据上文所述的重要特征选择选取特征。

（3）每次使用一个训练集训练模型，共 k 个模型。

（4）输出结果：采用投票的方式得到分类结果

随机森林模型建立大致流程图见图 19：

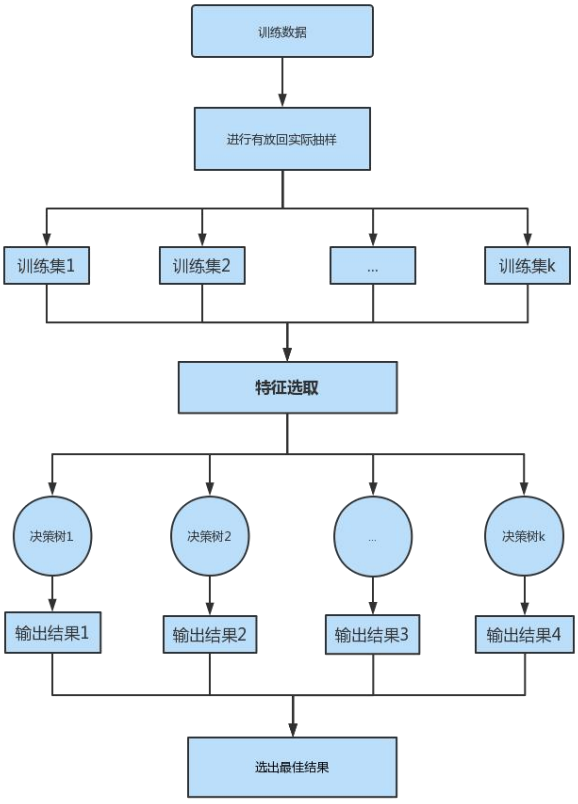


图 19　随机森林模型流程图

6.3 XGBoost 模型

XGBoost 模型是一种以 CART 决策树模型为基础的集成学习算法，可将弱学习器提升为强学习器，是基于梯度提升树 GBDT 的思想，对 GBDT 模型的优化。XGBoost 模型是一个加法模型，它串行的训练一组 CART 决策树，对预测结果进行加权求和，得到一个强学习器。模型常用的目标函数为：

$$Obj(\theta)=L(\theta)+\Omega(\theta)$$

其中 $Obj(\theta)$ 为目标函数；$L(\theta)$ 为模型训练损失，用以评估模型的优劣；$\Omega(\theta)$ 为正则化项；θ 为样本空间。

XGBoost 基于单一树模型进行线性加权集成，训练过程采用加法训练。其预测原理是：某时刻的预测值是前一时刻的预测值与此刻的函数之和，目标是选取最优的函数值。设训练数据集 $\{(x_1,y_1),(x_2,y_2)...(x_n,y_n)\}$，其目标函数的表达式为：

$$Obj^{(t)}=\sum_{i=1}^{n}l\left(y_i,\hat{y}_i^{(t)}\right)+\sum_{i=1}^{t}\Omega(f_i)$$

其中，$\hat{y}_i$ 表示第 i 个样本 x_i 的预测值；$\sum_{i=1}^{n}l\left(y,\hat{y}_i^{(t)}\right)$ 为损失函数，本文所使用的为 softmax 的损失函数，即 $L_i=-\log\left(\frac{e^{f_{y_i}}}{\sum_j e^{f_j}}\right)$；$\sum_{i=1}^{t}\Omega(f_i)$ 为正则化项，表示 i 棵树的复杂度。由于 GBDT 梯度提升树有 $y_i=\hat{y}_i^{(t-1)}+f_t(x_i)$，将其代入目标函数并对正则化项进行拆分，其目标函数变为：

$$\sum_{i=1}^{n}l\left(y_i,y_i^{(t-1)}+f_t(x_i)\right)+\Omega(f_t)$$

f_t 表示 t 时刻的函数。该原理就是通过寻找最优的 f_t 来使目标函数最小化。

运用泰勒公式对目标值进行展开，泰勒公式为：

$$f(x+\Delta x)\approx f(x)+f'(x)\Delta x+\frac{1}{2}f''(x)\Delta x^2$$

利用泰勒公式可将目标函数表示为：

$$\sum_{i=1}^{n}l\left(y_i,\hat{y}_i^{t-1}+f_t(x_i)\right)=\sum_{i=1}^{n}\left[l\left(y_i,\hat{y}_i^{t-1}\right)+l'\left(y_i,\hat{y}_i^{t-1}\right)f_t(x_i)+\frac{1}{2}l''\left(y_i,\hat{y}_i^{t-1}\right)f_t^2(x_i)\right]$$

用 g_i 记为第 i 个样本损失函数的一阶导数，h_i 记为第 i 个样本损失函数的二阶导数，即：

$$g_i=l'\left(y_i,\hat{y}_i^{t-1}\right)$$

$$h_i=l''\left(y_i,\hat{y}^{t-1}{}_i\right)$$

如此可以将目标函数表示成如下形式：

$$Obj^{(t)}=\sum_{i=1}^{n}\left[g_if_t(x_i)+\frac{1}{2}h_if_t^2(x_i)\right]+\Omega(f_t)$$

其中，树模型的复杂度定义为$\Omega(f)$，可以利用该复杂度的参数来更新目标函数。

6.4 随机森林和 XGBoost 模型的超参数优化

在构建随机森林和 XGBoost 模型时，首先以各参数的默认值构建模型，得到初始模型的评价标准值，然后对随机森林重要参数:
max_depth,n_estimators,min_samples_leaf,min_samples_split 以及 xgboost 重要参数：max_depth,n_estimators,learning_rate 等超参数进行调节。其中 n_estimators 为迭代次数，即弱分类器的个数；learning_rate 为学习率，其作用是用来控制迭代速率；max_depth 为树的最大深度，用来避免过拟合；min_samples_leaf 和 min_samples_split 分别为叶子节点需要的最小样本数和拆分内部节点所需的最少样本数，该参数可以限制模型的复杂程度，产生平滑模型的效果，减轻过拟合现象。

由于对不同参数组合进行网格搜索以及交叉验证需要耗费大量时间，为了提高参数优化效率，通过绘制学习曲线确定单个参数的最优精度区间，之后针对每个参数的最优区段通过网格搜索配合五折交叉验证得到最优参数组合。

以语音通话整体满意度和手机上网整体满意度两个打分数据为例：

1）首先需要控制基学习器单个树的深度 max_depth，由于分类树的拟合能力与其复杂程度成正比，一般而言，树的深度越大则表示其分支越多，更加具特性而失去通用性，所以限制最大深度可以有效避免过拟合现象，随机森林与 xgboost 训练集与测试集随深度误差变化见**图 20**。

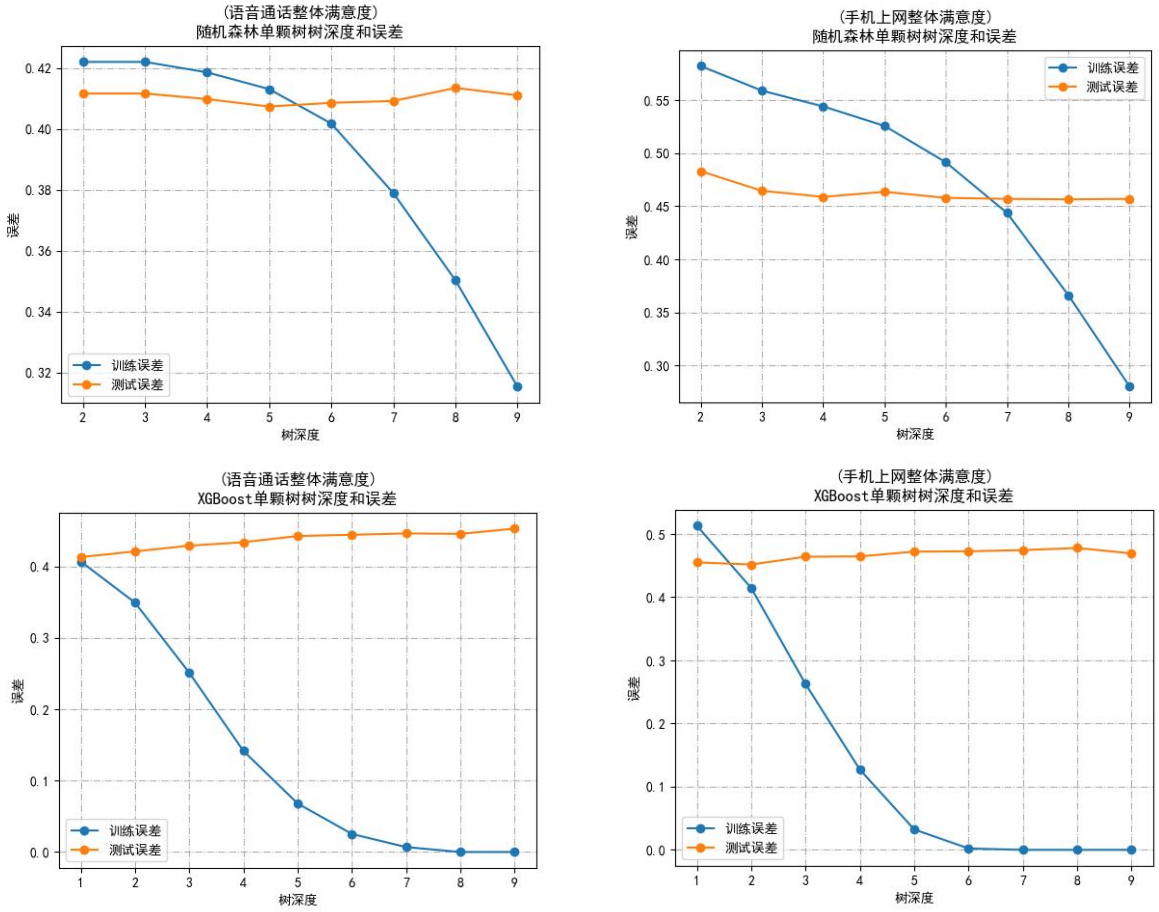


图 20　随机森林与 xgboost 训练集与测试集随深度误差变化

可以看出两类模型随着树深度的增加出现了严重的过拟合现象，针对语音通话整体满意度和手机上网整体满意度的预测误差分析得出：随机森林模型单个树的最大深度区段位于 5~7 之间时测试误差和训练误差会逐渐达到中和，之后随着深度的增加，过拟合程度会大幅加深；而

xgboost 模型针对两项打分数据测试误差和训练误差的中和深度区段则为 1~2，所以综合上述分析，针对随机森林和 xgboost 分别选定[5,7]、[1,2]为基于两项打分预测模型单个树深度的最优区段，接下来需要控制随机森林模型单个树叶子节点需要的最小样本数和拆分内部节点所需的最少样本数来进一步控制过拟合现象，最后通过网格搜索和五折交叉验证找到随机森林这三项参数的最佳组合。

2）同样，为了更好地确定 xgboost 模型的最佳迭代次数区段以及提高该模型的鲁棒性，我们需要对 xgboost 的学习率 learning_rate 进行调节，以便控制每次迭代更新权重的步长。xgboost 根据学习率误差变化曲线见**图 21**：

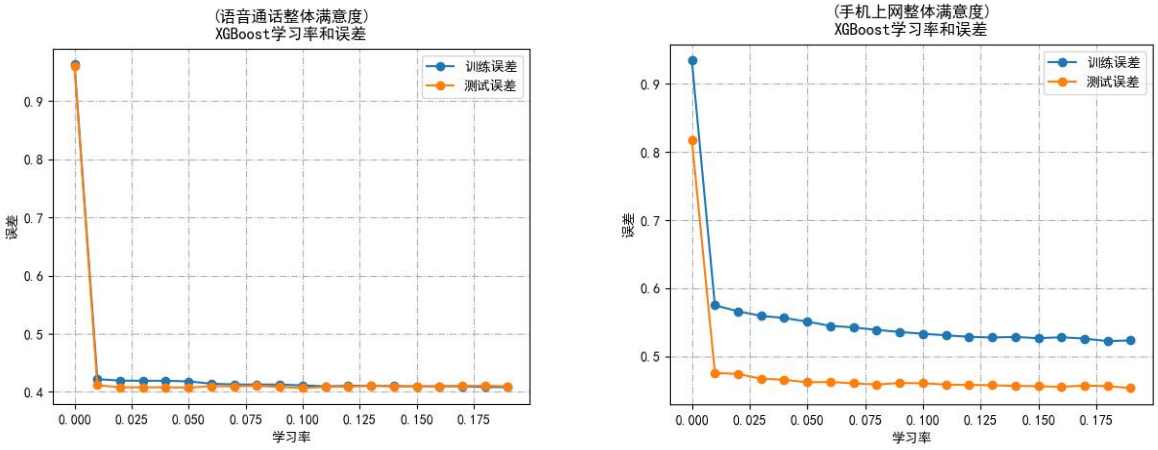


图 21　XGBoost 模型学习率误差变化曲线

由图可以看到初始学习率的增加对于测试集和训练集的误差带来极大的改善，泛化能力不断提升，针对两项打分数据最低误差区段集中在 0.1~0.175 之间，接下来需要控制每棵树随机采样比例参数 subsample，决定最小叶子节点样本权重和 min_child_weight 以及限制每棵树权重改变的最大步长 min_delta_step，同时引入权重的 L2 正则化项参数 reg_lambda 来进一步改善过拟合以及欠拟合现象，同样通过网格搜索找到最优参数组合。

3）接下来，我们需要控制两类集成模型中的基学习器的数量（迭代次数），找到每个模型在低误差下的收敛区间来达到一个较为理想的预测效果。误差变化曲线图见**图 22**：

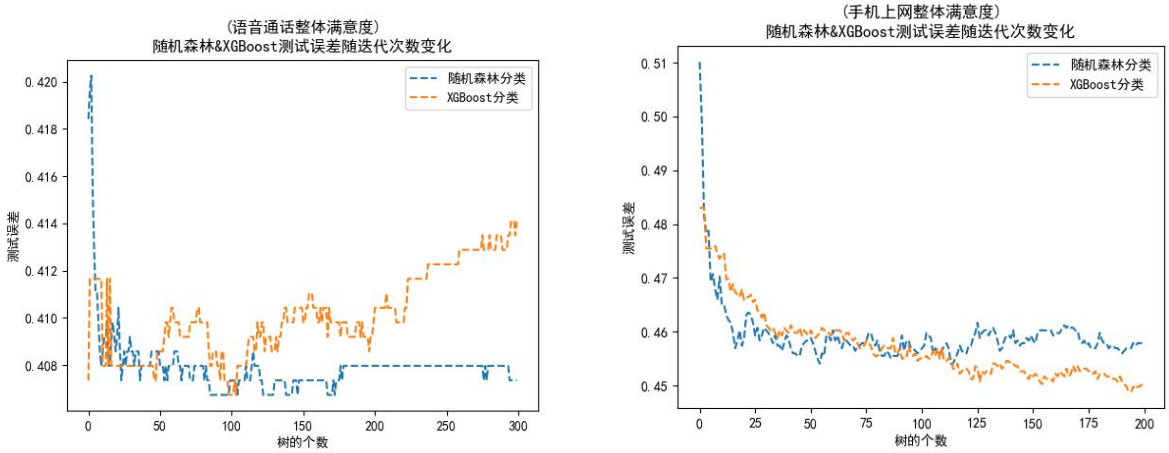


图 22　随机森林和 XGBoost 测试误差随迭代次数变化图

由图分析可以看出：对于语音通话和手机上网整体满意度数据的预测，随机森林的收敛速度较之 xgboost 会更快地达到一个较低的测试误差，其最低测试误差区段出现于 50 次迭代之后，而 xgboost 则位于 100~200 次之间，确定最佳迭代次数区段之后，对于两类模型迭代次数参数 n_estimators 通过网格搜索和五折交叉验证可找到对应打分数据预测的最佳参数值。

最后利用选取到的最优参数组合构建出最优的模型，并计算出调参前后各个模型的精度，具体的模型参数和调参前后模型的精度见**表 11-表 14**：（由于篇幅受限，本文只给出语音通话整体满意度和手机上网整体满意度两个打分项的详细数据，详细参数数据见附录问题二代码：模型训练&打分数据预测）：

表 11　随机森林模型参数与调参前后语音通话整体满意度的训练集和测试集精度

参数	值	调参前训练集精度	调参前测试集精度	调参后训练集精度	调参后测试集精度
max_depth	5				
n_estimators	86				
max_features	6	1	0.5583	0.5927	0.5896
min_samples_leaf	5				
min_samples_split	2				

表 12 随机森林模型参数与调参前后手机上网整体满意度的训练集和测试集精度

参数	值	调参前训练集精度	调参前测试集精度	调参后训练集精度	调参后测试集精度
max_depth	8				
n_estimators	55				
random_state	22	1	0.4998	0.6156	0.5413
max_features	10				
min_samples_leaf	1				
min_samples_split	8				

表 13　XGBoost 模型参数与调参前后语音通话整体满意度的训练集和测试集精度

参数	值	调参前训练集精度	调参前测试集精度	调参后训练集精度	调参后测试集精度
n_estimators	99				
max_depth	1				
eta	0.1				
objective	‘multi:softmax’				
random_state	22	0.9747	0.5662	0.5864	0.5906
subsample	0.7				
min_child_weight	14				
min_delta_step	0.9				
reg_lambda	0.4				

表 14　XGBoost 模型参数与调参前后手机上网整体满意度的训练集和测试集精度

参数	值	调参前训练集精度	调参前测试集精度	调参后训练集精度	调参后测试集精度
n_estimators	71				
max_depth	2				
eta	0.16				
objective	‘multi:softmax’				
random_state	22	0.9978	0.5074	0.5675	0.5422
subsample	0.4				
min_child_weight	14				
min_delta_step	0				
reg_lambda	0.4				

可以看出，经过模型超参数优化后，模型的测试集精度都得到了提高，模型的过拟合现象得到缓解，泛化性能得到了一定的提升。

6.5 模型融合

根据上述建立的三个模型，采用融合的方式将三个模型进行融合，采用软投票加权融合的方式。具体的模型结果如下：

$$result = \beta_1 \bullet result_1 + \beta_2 \bullet result_2 + \beta_3 \bullet result_3$$

其中，$\beta_1, \beta_2, \beta_3$ 为权重系数，$result$ 表示被分到该结果的概率，$result_1, result_2, result_3$ 分别表示在 CART 模型、随机森林、XGBoost 模型中被分到该结果的概率，经过不断调试，得到最好的权重组合为 $\beta_1 = 1$，$\beta_2 = 2$ $\beta_3 = 3$。然后将算出的 $result$ 进行归一化处理，得到了最终分类的概率。

之后计算出了 CART 模型、随机森林、XGBoost 模型、模型融合的测试误差，测试误差的可视化图见**图 23** 和**图 24**：

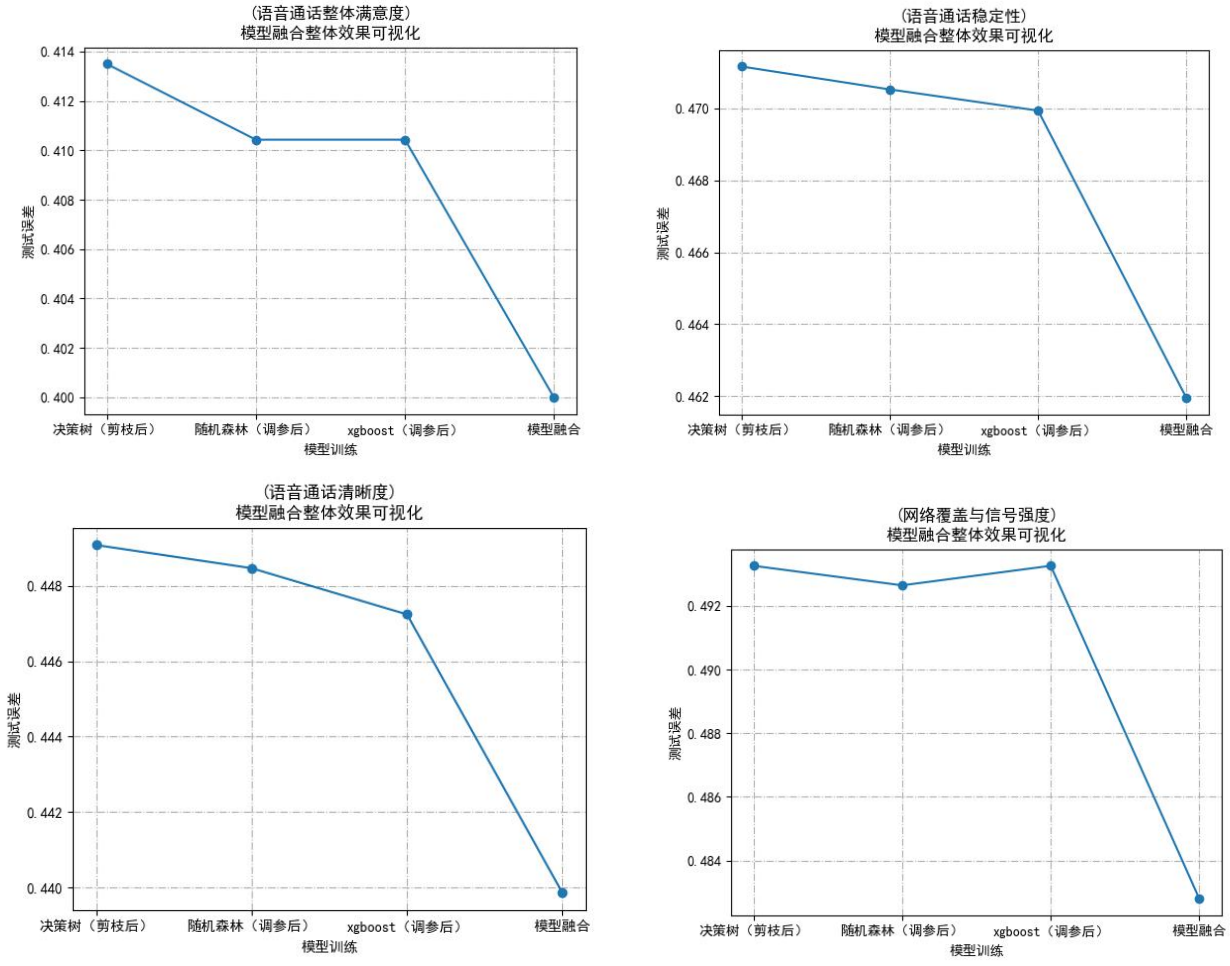


图 23　附件 1 中 4 个打分项目模型测试误差

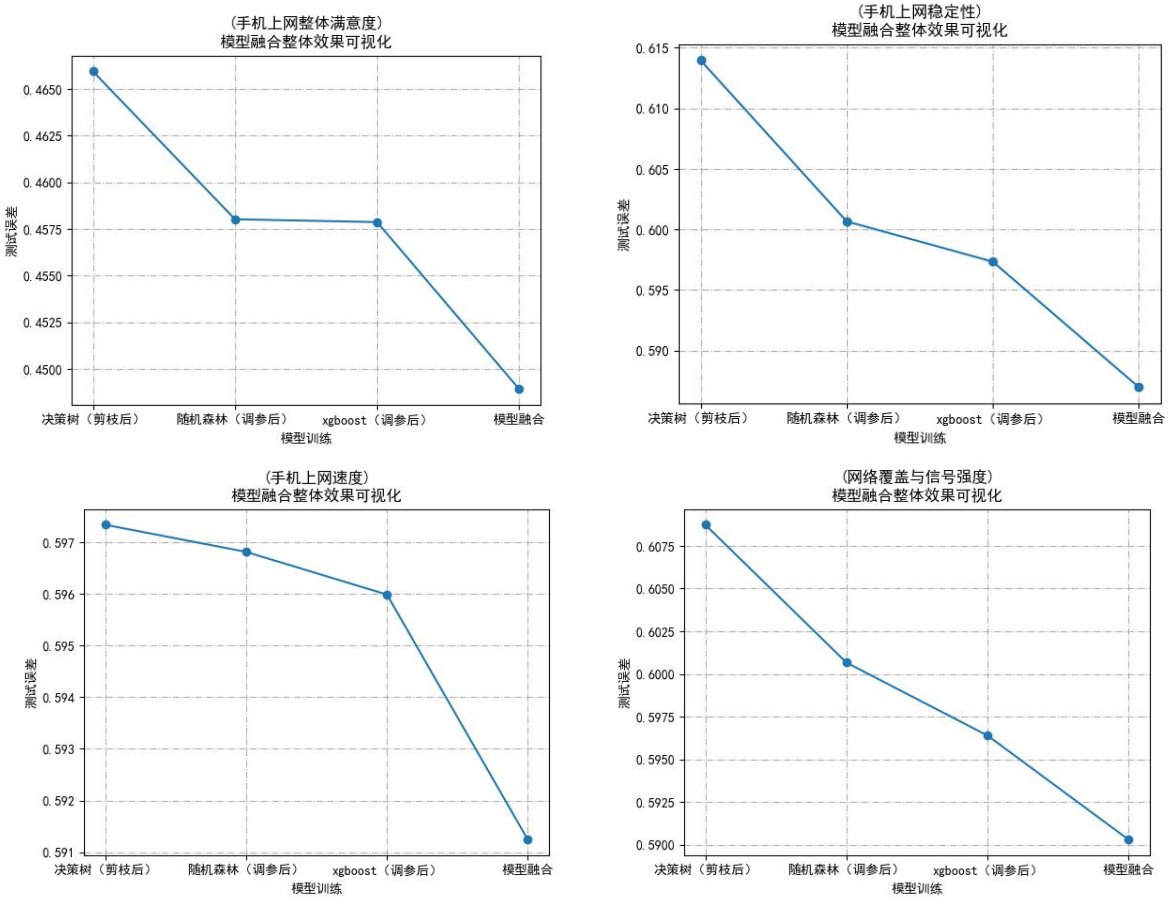


图 24　附件 2 中 4 个打分项目模型测试误差

可以看出，模型融合后测试误差降到了最低，即模型融合后的预测结果更准确

6.6 基于决策树模型的预测及结果合理性

将数据导入模型得到了预测结果，并保存在 result.xlsx 中。

上文的结果表明，模型最终的测试集精度在 0.4-0.6 之间，这个结果并不是很高，但结合问题一中对数据的描述性统计，发现数据中大部分指标存在异常值，即客户打分的主观性很强，在相同的因素下，由于不同的人需求不同，这也导致了打分存在不一致的情况。经过对模型不断的学习调试与融合，也确保了测试集的精度在不断提高。由此可知，最终的预测结果符合实际，是合理的。

七 、模型评价

1. 模型优点

（1）本文运用多个模型，对数据集使用充分，对数据集的处理比较完整。

（2）模型调参过程中使用了网格搜索和交叉验证，提高了模型的泛化能力。

（3）采用软投票加权融合的方法，提高了整体的预测能力。

2. 模型缺点

（1）特征工程的特征挖掘仍有不足，后续可以对特征工程更好的处理。

（2）由于数据存在异常值，加之客户打分十分主观，模型在测试集上的表现一般，但是预测出的打分结果与实际结果相差不大。

八、模型推广

本文所建立的模型，可以投入到现实生活中使用，可以针对其它地区移动用户满意度的判别提供参照，并且该模型可以推广到生活中更多场景的预测问题中。

参考文献

[1]周志华.（2016）.机器学习.清华大学出版社，北京
[2]武炜杰.随机森林的应用与优化方法研究[D].江南大学，2021
[3]吕晓令 宋捷.大数据挖掘与统计机器学习.中国人民大学出版社