队伍编号	MCB2201112
赛道	B

基于多模型调参优化的 Stacking 用户评分预测集成学习

摘　　要

随着移动通信技术的迅猛发展和网络工程的不断建设，在信息透明、产品同质化的今天，提升语音通话及网络服务的质量，满足用户对高质量语音通话、网络服务的需求显得尤为重要。本文旨在**建立一个基于多模型调参优化的 Stacking 集成学习，完善且合理地预测用户评分的普适性模型**，从已有数据中心获得有效信息，更高效地提升服务质量，从而完善业务服务体系。

针对问题一，主要需要对用户语音及上网业务评分影响因素的程度进行量化分析。本文首先对数据集进行统一处理，包括：**初步剔除相关列数据、学习数据与预测数据指标一致化、指标规范化、空缺值处理、标签编码、特征构造、数据标准化、学习数据与预测数据一致化、学习数据训练集与测试集划分**。之后在处理好的数据集上建立**熵权法、灰色关联度分析、随机森林分类**模型，多方面综合考虑，量化分析各影响因素对评分的影响程度，最终结果见表 2、表 3及表 4，并依此来确定影响用户两项业务满意度的主要因素。量化结果接近于实际生活，效果良好，且可为后续问题奠定基础。

针对问题二，主要需要根据已有影响因素对用户的评分进行预测，并解释预测的合理性。本文首先结合问题一量化结果以及建立**主成分分析**模型，对数据**累计方差**进行解释，确定特征个数；之后建立 **XGBoost 模型**，并得出各影响因素的重要性，与随机森林模型结合分析，确定特征的选择；再建立 **KNN、SVM、LightGBM** 以及**多分类逻辑回归模型**，对数据进行学习分析；随后，对各个模型进行**超参数调优**，模型准确率均有大幅度提升，如随机森林**较原先提升了 11.69%，最高提升较原先可达到 14.25%**，效果良好。再者，以模型的准确率、平均绝对误差、均方误差为标准，选择表现较优的模型作为 **Stacking 集成学习**的基模型，同时选择余下的一个模型作为第二层模型，在提升准确率的同时，避免过拟合。同时对其采用**五折交叉验证**，验证其**稳健性**。Stacking 集成学习结果符合预期效果，各评分预测模型效果见表 10，明显优于单一模型。在保证准确率的同时，预测的平均绝对误差、均方误差**均有一定优化**，同时本文还注重结果的可解释性及模型的现实意义。最后，本文进行**可视化分析**，绘制原始数据及预测数据评分人数**南丁格尔玫瑰图**，查看数据分布，绘制模型的**混淆矩阵热力图、分类报告、ROC/AUC 曲线**，多方面评估模型效果及解释模型的合理性。综合上述分析，可以确认模型效果良好，具有良好的稳健性、泛化能力。

最后，本文对所建立的模型的优缺点进行了中肯的评价、提出了模型的改进措施以及对模型进行了一定推广。

关键词：影响程度量化分析；特征工程；Stacking 集成学习；评分预测；可视化评估

目录

一、 问题的提出 1
1.1 问题背景 1
1.2 问题要求 1
二、 问题的分析 1
2.1 问题的整体分析 1
2.2 问题一的分析 2
2.3 问题二的分析 2
三、 符号说明 2
四、 模型的假设 3
五、 模型的建立与求解 3
5.1 数据的准备 3
5.2 问题一模型的建立与求解 6
5.2.1 模型的建立 6
5.2.2 语音业务求解 9
5.2.3 上网业务求解 13
5.3 问题二模型的建立与求解 16
5.3.1 累计解释方差 16
5.3.2 多种多分类模型的建立 17
5.3.3 Stacking 集成学习原理解释 20
5.3.4 模型的超参数调优 20
5.3.5 特征选择 22
5.3.6 模型的选择及集成 22
5.3.7 客户评分预测 24
5.3.8 模型预测结果合理性分析 24
六、 模型的评价与推广 30
6.1 模型的评价 30
6.2 模型的推广 31
参考文献 32
附　　录 33

一、问题的提出

1.1 问题背景

随着移动通信技术的迅猛发展和网络工程的不断建设，在信息透明、产品同质化的今天，提升语音通话及网络服务的质量，满足用户对高质量语音通话、网络服务的需求显得尤为重要。由于当今用户数量的不断增多、用户需求不断提高、运营商业务不断广泛化，因此点对点、传统方法解决问题逐渐困难化。而现在有来自移动通信集团北京分公司根据用户对语音业务及上网业务的满意度进行的评分及相关影响因素的数据，我们需要对其进行分析、建立相关数学模型，以便从数据中心获得有效信息，更高效地提升服务质量，为客户提供更好的服务。

1.2 问题要求

- **问题一**：研究并量化分析影响用户对语音及上网业务满意度的主要因素；
- **问题二**：建立基于影响用户评分影响因素的数学模型，并依据附件 3、4 中相关因素对其评分进行预测，并解释预测评分的合理性。

二、问题的分析

2.1 问题的整体分析

该题是一个关于移动用户对语音及上网业务体验评分的数据分析、预测类问题。

从分析目的看，本题需要分析用户对语音与上网业务的评分及各个影响因素，筛选出影响用户评分的主要因素，并量化结果。同时需要对用户的评分进行预测及研究，为运营商提供参考，从而提升用户语音及上网的优质体验。因此本题主要需完成两方面任务：**其一**，研究影响用户语音及上网业务满意度的主要因素，并对各因素进行量化分析；**其二**，根据上述的分析，建立合理模型，对用户的评分进行预测及研究，确保分类模型的准确性、稳健性、可靠性，并有一定的泛化能力，且能够包容用户真实评分的主观性。

从数据来源、特征看，本题的数据来源于北京移动用户的语音与上网业务评分数据，数据包括用户对语音业务下“语音通话整体满意度”“网络覆盖与信号强度”“语音通话清晰度”“语音通话稳定性”，上网业务下“手机上网整体满意度”“网络覆盖与信号强度”“手机上网速度”“手机上网稳定性”方面的评分，以及相关的影响评分的因素。评分数据具有主观性，影响因素数据具有高维、多样、标准体系不一致、量纲不一致等特点，且数据量较大。因此，本题数据相对特殊且复杂，需要对数据进行一定的预处理，以便于后续的分析。

从模型的选择看，本题数据量较大、维度较高，且分析目的是分析影响用户评分的主要因素，并对用户的评分进行预测及研究。本文将评分视为多分类，且评分具有一定主观性、分类种类多，因此，在模型的选择上，本文结合多种分类预测模型，构建集成学习模型，尽可能多地学习到用户评分特点，提升模型的准确性、稳健性及可泛化性能。

从软件的选择看，本题为数据类型，且需要进行大量的数据分析、预测等，因此我们选择 Python Jupyter 对问题进行求解，其交互式的编程范式，方便且高效。

2.2 问题一的分析

问题一的核心目的在于**研究并量化分析影响用户对语音及上网业务满意度的主要因素**。对于已给的数据集，数据在完整度、指标标准等方面存在一定缺陷。这导致在原数据上我们不可直接进行分析，需要对原数据集进行数据的预处理。此外附件数据集在语音及上网业务中，每一业务均有四项评分，因此我们需要对每一项评分进行分析，对各因素进行量化。结合数据来源、与特征方面，我们综合**皮尔逊相关系数、熵权法、灰色关联度分析、随机森林分类**，构建多元量化分析模型，尽可能准确挖掘到影响用户评分的因素，为构建后续预测模型提供优质依据。

2.3 问题二的分析

问题二的核心目的在于**建立基于影响用户评分影响因素的数学模型，并依据附件 3、4 中相关因素对用户评分进行预测，并解释模型预测的合理性**。但是在附件 1 与附件 2，附件 3 与附件 4 中，影响因素存在不配对的情况。这导致在给定用户评分的数据中，部分因素不可作为模型建立的基础特征数据，因此在数据预处理的同时，还需要对附件 1 与附件 2，附件 3 与附件 4 中的**影响因素列取交集**，使得学习数据与预测数据的特征数据一致。此外，在已给的存在用户评分的数据集中，用户对每一项的评分均为整数，不存在小数，且评分范围为 $[1,10]$。因此，我们在建立预测模型时，应尽量避免使用回归模型，而应使用**分类模型**，但部分分类模型需要分类标签量值从 0 开始，因此需要对所有评分进行标签编码，规范数据。同时分类种类较多，对于单一模型，其预测准确率较低，平均绝对误差较高、泛化能力较弱……因此，本文结合多种机器学习模型，构建**集成学习模型**，尽可能准确预测用户评分。最后，在此基础上，结合模型的**分类混淆矩阵热力图、分类报告、ROC/AUC 曲线**等对于预测结果进行解释，叙述模型的合理性，同时考虑集成学习模型对预测误差的包容性，对模型的泛化能力进行分析。

三、符号说明

符号	符号说明
μ	样本平均值
σ	样本方差
x_{standard}	经过标准化后的数据
$R(x)_{m\times n}$	经过某项处理后的数据特征集
ρ	皮尔逊相关系数
x'	经过某项处理后的数据
$Gini$	样本集合基尼系数
$\hat{y}$	预测值
$L^{(t)}$	目标函数
Ω	叶节点正则项惩罚系数
P	某事件发生的概率
ω	权重

四、模型的假设

- **假设一**：语音与上网业务的八项评分中，存在个别用户乱评、错评现象；
- **假设二**：除个别用户的部分评分外，其余所有数据真实且符合实际情况；
- **假设三**：用户评分还受到除附件中因素之外的因素的影响；
- **假设四**：给定的数据集可全面体现用户整体情况；
- **假设五**：对于同一业务，学习数据与预测数据的内在规律是一致的。

五、模型的建立与求解

模型的建立与求解[1]部分主要分为数据的准备，模型建立与求解、结果分析。[2]

- **数据的准备**：对于给定的数据集，对数据进行预处理。
- **模型的建立、求解、结果分析**：对于给定的数据集，建立相关模型，研究并量化分析影响用户对语音及上网业务满意度的主要因素。此外还需要建立基于影响用户评分影响因素的数学模型，并依据附件 3、4 中相关因素对其评分进行预测，并解释预测评分的合理性。



图 1　数据的准备主要过程

5.1 数据的准备

为方便、准确、高效解决问题，我们需要对数据进行预处理，其主要过程见图 1，包括：初步剔除相关列数据、学习数据与预测数据指标一致化、指标规范化、空缺值处理、标签编码、特征构造、标准化、学习数据与预测数据一致化、学习数据训练集与测试集划分。**本文后续的模型建立都在此基础之上**。

[1]本文中所有解决问题的源程序均可在附录 [D] 或支撑材料中查看

[2]本文中除词云图及南丁格尔玫瑰图示外，其余均为矢量图。由于数据较多，在 PDF 阅读时，表格、图示中字体可能较小，读者可适当放大进行查看，所有图表放大后，均可清晰查看。

Step1 初步剔除相关列数据

由于“用户 id”为连续编号，且与评分无任何关系，故本文将该列数据剔除；同时对于“用户描述”等文字性叙述指标，由于其均为文本，且描述特征难以提取，难以量化，本文将该列数据剔除，但为了获得客户相关描述，本文将绘制用户描述高频词汇云图；此外，对于“终端品牌类型”等多类别指标，由于其类别较多，量化后难以提取出有效信息，故也将其剔除，其余列暂时保留。

Step2 学习数据与预测数据指标一致化

附件 1 与附件 3 为用户语音业务数据，但两表数据影响的因素存在不一致的现象，需要对指标取交集，确保两者一致，附件 2 与附件 4 同理。这里我们利用 Python 中集合 set 容器元素唯一性特征及 pandas 库，筛选出相同因素。而对于可能重合的指标，我们在下文也会进行一定处理。这样即可确保在学习数据上建立的模型依据的指标存在于预测数据集上，避免两者指标不一的情况。

Step3 指标规范化

经过上述处理后，我们发现大部分影响因素为分类指标，其划分“是”“否”的字段不统一，故依据“附件 5 附件 1、2、3、4 的字段说明.xlsx”文件，本文对附件 1、2、3、4 中的分类指标进行规范化，记“是”类别为 1，“否”类别为 0，方便后续模型的建立。

Step4 空缺值处理

在给定数据集中，部分空缺值可以依据附件 5 的解释进行填充。经过一定处理后，附件 3 与附件 4 中无空缺值，故本文对附件 1 与附件 2 中的空缺值进行分析与处理：

- **对于附件 1**：据附件 5 解释进行填充后，还存在个别用户的空缺值，如图 2所示。空缺

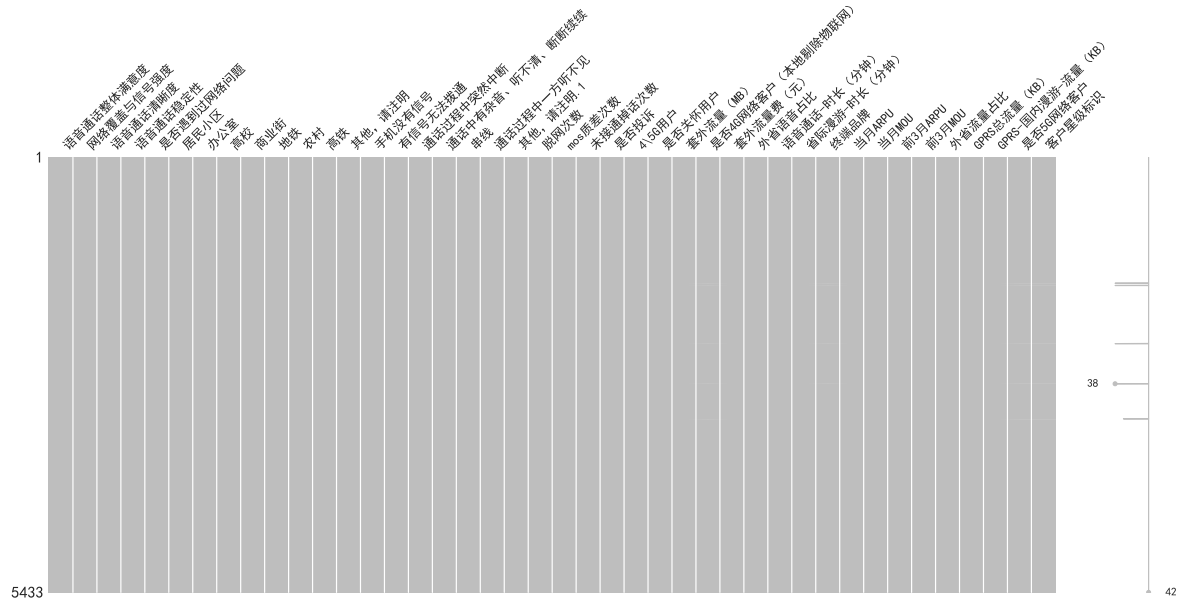


图 2　附件 1 初步处理后缺失值查看

值的列名为：“是否 4G 网络客户（本地剔除物联网）”“终端品牌”“是否 5G 网络客户”“客户星级标识”，且这些空缺值均在同一用户中出现，用户 id 分别为 1573、1601、2326、2827、3265。附件 1 的空缺值有集中、个数少的特点，存有空缺值的用户仅有 5 个，占整体用户的 0.0920%，对于模型的建立影响较小，因此我们将这 5 行用户剔除。

- **对于附件 2：**经过指标一致化后及初步数据空缺值的填补后，附件 2 中仅剩“终端品牌”列指标存在 14 个空缺值，根据该列数据其余特征，我们将这个 14 个空缺值以 0 填充。

Step5 **标签编码**

首先，对用户的评分进行编码，由于部分分类模型需要分类量值从 0 开始，因此，为方便后续集成学习等，本文将评分从 $[1,10]$ 映射至 $[0,9]$，且仍均为整数，即将评分减 1。其次，对“终端品牌”“4\5G 用户”指标利用 Python 的 sklearn 库中的 LabelEncoder 进行标签编码。此外，对于“客户星级标识”指标，我们依据移动公司对客户星级标识的划分进行编码，编码值对应见表 1。

表 1　客户星级标识编码对应表

未评级	准星	一星	二星	三星	银卡	金卡	白金卡	钻石卡
0	1	2	3	4	5	6	7	8

Step6 **特征构造**

观察并分析给定的数据，我们可以初步构造以下特征：

- **对于附件 1 与附件 3：**观察到附件 1 中有“家宽投诉”与“资费投诉”两项，而在附件 3 中有“是否投诉”一项，因此，我们在附件 1 中构造“是否投诉”一项。若“家宽投诉”与“资费投诉”均为 0，则“是否投诉”记为 0，否则记为 1。并同时删去“家宽投诉”与“资费投诉”。

- **对于附件 2 与附件 4：**观察数据，我们构造三项新指标，分别为“出现问题场所或应用总”“网络卡速度慢延时大上不了网总”“质差总”。其来源为对应列指标按行求和。

Step7 **数据标准化**

该处标准化处理为 **Z-score** 方法，仅用于后续机器学习模型的使用。而在问题一的熵权法、灰色关联度分析中我们采用 **Min-Max** 方法，该方法在后文模型中会具体说明。

对于某一列数据 $x=[x_1,x_2,\cdots,x_m]^{\mathrm{T}}$，其平均值为

$$\mu=\frac{1}{m}\sum_{i=1}^{m}x_i \tag{1}$$

标准差为

$$\sigma=\sqrt{\frac{1}{m}\sum_{i=1}^{m}(x_i-\mu)^2} \tag{2}$$

则标准化后的数据为

$$(x_{\text{standard}})_i = \frac{x_i - \mu}{\sigma} \tag{3}$$

利用上述计算公式，我们对非分类指标进行处理，使得原数据经过处理后，其值聚集于 0 附近，即均值为 0，标准差为 1。这样处理，利于机器学习模型的建立、学习与预测，加快模型的收敛速度，并在一定程度上提升模型的准确性。同时该标准化处理方法适合当代嘈杂的大数据场景[1]。因此对于大样本的数据，如出现部分异常值，使用该方法对最终结果影响较小。

Step8 学习数据与预测数据一致化

经过上述几项处理后，我们还需要将附件 1 与附件 3 数据集一致化，包括指标一致化以及数据字段、分布排列一致化，从而保证对于需要预测的数据集附件 3 利用在附件 1 中建立的模型所利用到的数据集的一致性，避免造成数据的不一致，导致预测错误。本文对附件 2 与附件 4 进行上述相同的操作。

Step9 学习数据训练集与测试集划分

为计算问题二中建立的模型的准确性等指标，需要在附件 1 与附件 2 中均划分训练集与测试集。对于语音业务划分训练集与测试集比例为 8:2；而对于上网业务，其比例设为 9:1。对于比例的设置，本文将在后文解释其合理性。且上述划分利用 sklearn 库中的 train_test_split 函数实现，且任意设定随机种子为 2022，确保多次调试结果的一致性。该函数可确保划分的随机性，确保训练集与测试集数据分布规律大致相同。

5.2 问题一模型的建立与求解

对于问题一，我们综合**皮尔逊相关系数**、**熵权法**、**灰色关联度分析法**，以及**随机森林分类模型**，构建多元量化分析模型，尽可能准确挖掘到影响用户评分的因素。

5.2.1 模型的建立

皮尔逊相关系数（Pearson Correlation Coefficient）可衡量两个变量之间的相似度，我们不妨用 $\rho(x, y)$ 表示，计算公式[2]如下

$$\rho(x, y) = \frac{\sum_{i=1}^{n} (x_i - \mu_x)(y_i - \mu_y)}{\sqrt{\sum_{i=1}^{n} (x_i - \mu_x)^2} \sqrt{\sum_{i=1}^{n} (y_i - \mu_y)^2}} \tag{4}$$

其中 μ 计算见(1) 式。

由该定义，显然 $\rho \in [-1, 1]$。当 $\rho > 0$ 时，上述两变量呈正相关；当 $\rho = 0$ 时，上述两变量不相关；当 $\rho < 0$ 时，上述两变量呈负相关。当 $|\rho|$ 越接近于 1 时，则上述两变量相关性就越强[3]。

熵权法（Entropy Weight Method, EWM）是一种指标客观影响程度的量化方法。当信息熵越大时，信息的无序程度越大，此时，信息价值越小，指标权重就越小[4]。其计算步骤如下：

- **Step1**，指标正向化。由于数据集构成的指标类别不一，部分指标可能数值越大越好，部分指标可能越小越好，而有的可能在某一点取值最优，为方便、高效评价，我们需要进行指标正向化处理[5]。其处理方法如下

  – **越大越优指标**

  $$x'_{ij} = x_{ij} \tag{5}$$

  – **越小越优指标**

  $$x'_{ij} = \max\left(x_{ij}\right) - x_{ij} \tag{6}$$

  – **在 β 处取值最优指标**

  $$x'_{ij} = 1 - \frac{|x_{ij} - \beta|}{\max\left(|x_{ij} - \beta|\right)} \tag{7}$$

- **Step2**，数据标准化。由于数据集构成的指标数据数量级存在差异、量纲不一，为消除上述情况对结果的影响，我们需要将各指标进行标准化处理，这里我们使用 Min-Max 方法。处理方法计算公式如下

$$r_{ij} = \frac{x'_{ij} - \min\left(x'_j\right)}{\max\left(x'_j\right) - \min\left(x'_j\right)} \tag{8}$$

- **Step3**，计算信息熵。进行上述处理后可得到由特征数据构成的矩阵 $R\left(r_{ij}\right)_{m\times n}$，对于某一项指标的数据 r_j，其信息熵为

$$E_j = -\frac{1}{\ln m} \cdot \sum_{i=1}^{m} p_{ij} \ln p_{ij} \tag{9}$$

  其中

$$p_{ij} = \frac{r_{ij}}{\sum\limits_{i=1}^{m} r_{ij}} \tag{10}$$

  观察到(10) 式中分母不可为 0，且(9) 式对数真数部分不能为 0，因此，我们在进行 **Step2** 时，标准化区间的最小值设为 0.002，可避免计算时的不合定义。

- **Step4**，计算指标权重。其计算公式如下

$$\omega_j = \frac{1 - E_j}{\sum\limits_{j=1}^{n} \left(1 - E_j\right)} \tag{11}$$

灰色关联度分析（Grey Relation Analysis, GRA）是通过指标之间的关联系数来判断指标对系统的影响程度[6]。其计算方法如下：

- **Step1**，指标无量纲化。这里指标无量纲化与熵权法的 **Step2** 中的数据标准化方法处理相同，此处不再赘述。
- **Step2**，计算每一项比较序列与参考序列绝对值差

$$\Delta i\left(k\right)=\left|R_0\left(k\right)-R_i\left(k\right)\right| \tag{12}$$

- **Step3**，确定二级最小差与二级最大差

$$\max_{i=1}^{n}\max_{k=1}^{m}\left|R_0\left(k\right)-R_i\left(k\right)\right| \qquad \min_{i=1}^{n}\min_{k=1}^{m}\left|R_0\left(k\right)-R_i\left(k\right)\right| \tag{13}$$

- **Step4**，计算关联系数，记分辨系数为 η，本文我们取 $\eta=0.5$

$$\xi_i\left(k\right)=\frac{\min\limits_{i}\min\limits_{k}\left|R_0\left(k\right)-R_i\left(k\right)\right|+\eta\cdot\max\limits_{i}\max\limits_{k}\left|R_0\left(k\right)-R_i\left(k\right)\right|}{\left|R_0\left(k\right)-R_i\left(k\right)\right|+\eta\cdot\max\limits_{i}\max\limits_{k}\left|R_0\left(k\right)-R_i\left(k\right)\right|} \tag{14}$$

- **Step5**，计算灰色关联度

$$\gamma_{0i}=\frac{1}{m}\sum_{k=1}^{m}\xi_i\left(k\right) \tag{15}$$

随机森林（Random Forest, RF）是由多棵决策树（Decision Tree）进行组合后对预测结果投票或取均值的一种算法[7]。其有分类和回归两种模型，对于本题，我们选择分类模型。其简要过程如图 3所示，算法伪代码如Algorithm1所示。

Algorithm 1: 随机森林（RF）

Data: 数据集 $\mathcal{D}$

function DTree($\mathcal{D}$)
if *Termination* **then**
  return base (g_t)
else
  learn $b\left(x\right)$ 并且依据 $b\left(x\right)$ 划分 $\mathcal{D}$ 为 $\mathcal{D}_C$
  build $G_C\leftarrow\mathrm{DTree}(\mathcal{D}_C)$
  return $G\left(x\right)=\sum\limits_{C=1}^{C}[\![b\left(x\right)=C]\!]G_C\left(x\right)$
end
function RandomForest($\mathcal{D}$)
for $t=1,2,3,\cdots,T$ **do**
  request 数据集 $\tilde{\mathcal{D}}_t\leftarrow\mathrm{BoostStrapping}(\mathcal{D})$
  obtain DTree $g_t\leftarrow\mathrm{DTree}\left(\tilde{\mathcal{D}}_t\right)$
  return $G=\mathrm{Uniform}(g_t)$
end

Result: 随机森林模型 $G=\mathrm{Uniform}\left(g_t\right)$

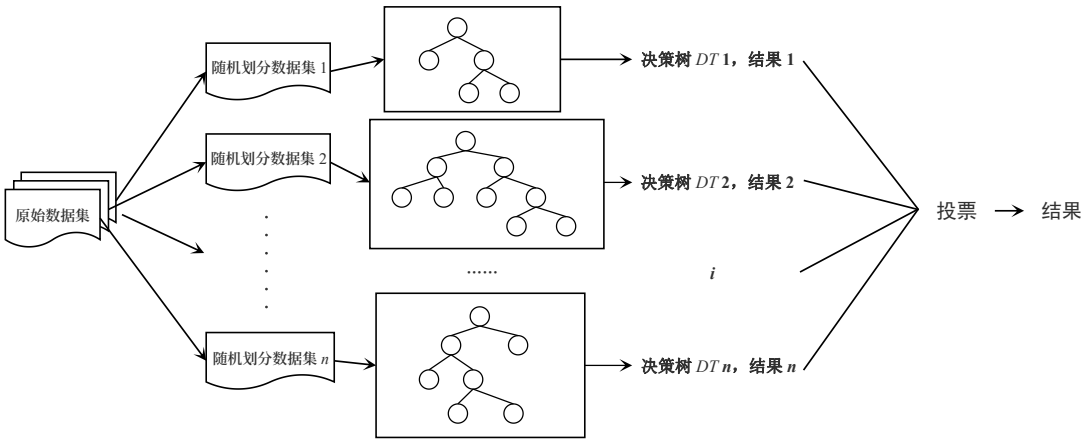


图 3　随机森林算法简图

对于单棵决策树而言，本文利用 **CART** 算法[7]构建。基尼系数是衡量样本集合纯度的指标，当该值越小时，其纯度也就越高。计算公式如下

$$Gini\left(R_i\right)=\sum_{k=1}^{K}\sum_{k\neq k'}P_kP_{k'}=1-\sum_{k=1}^{K}P_k^2 \tag{16}$$

其中，R 为选取出的特征（影响因素），K 表示在该特征中包含的类别数，P_k 表示该特征中第 k 类别的出现概率。

由上述分析可知，对于单棵决策树而言，其叶子节点的分裂特征为选择的所有特征中基尼系数最小的特征。

5.2.2 语音业务求解

首先我们绘制语音业务用户四项评分箱线图，如图 4所示（图中数据是原评分数据通过标签编码转化而来的）。之后依据(4) 式，可以计算出各影响因素与语音业务四项评分之间的皮尔逊相关系数，并通过 Python 绘制其热力图，如图 6所示，图中仅显示相关性排名前 10 的指标。 由图 6可以直观发现，用户对于语音业务的满意度影响较大排名在前的因素依次为

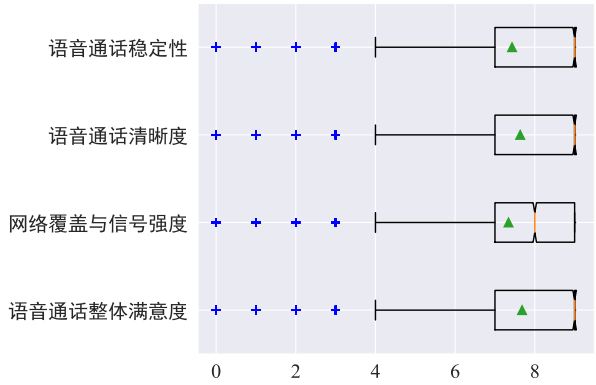


图 4　语音业务用户四项评分箱线图

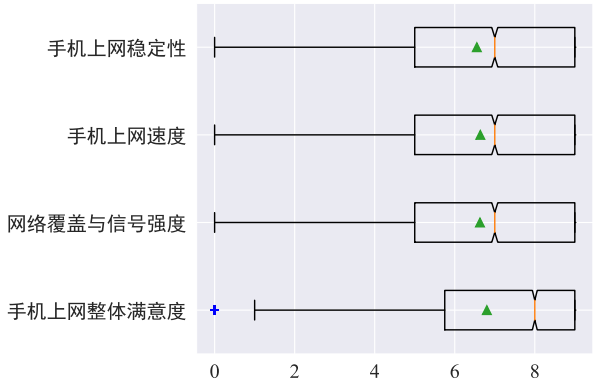


图 5　上网业务用户四项评分箱线图

“是否遇到过网络问题”、“居民小区”、“手机没有信号”、“有信号无法拨通”、“通话过程中突

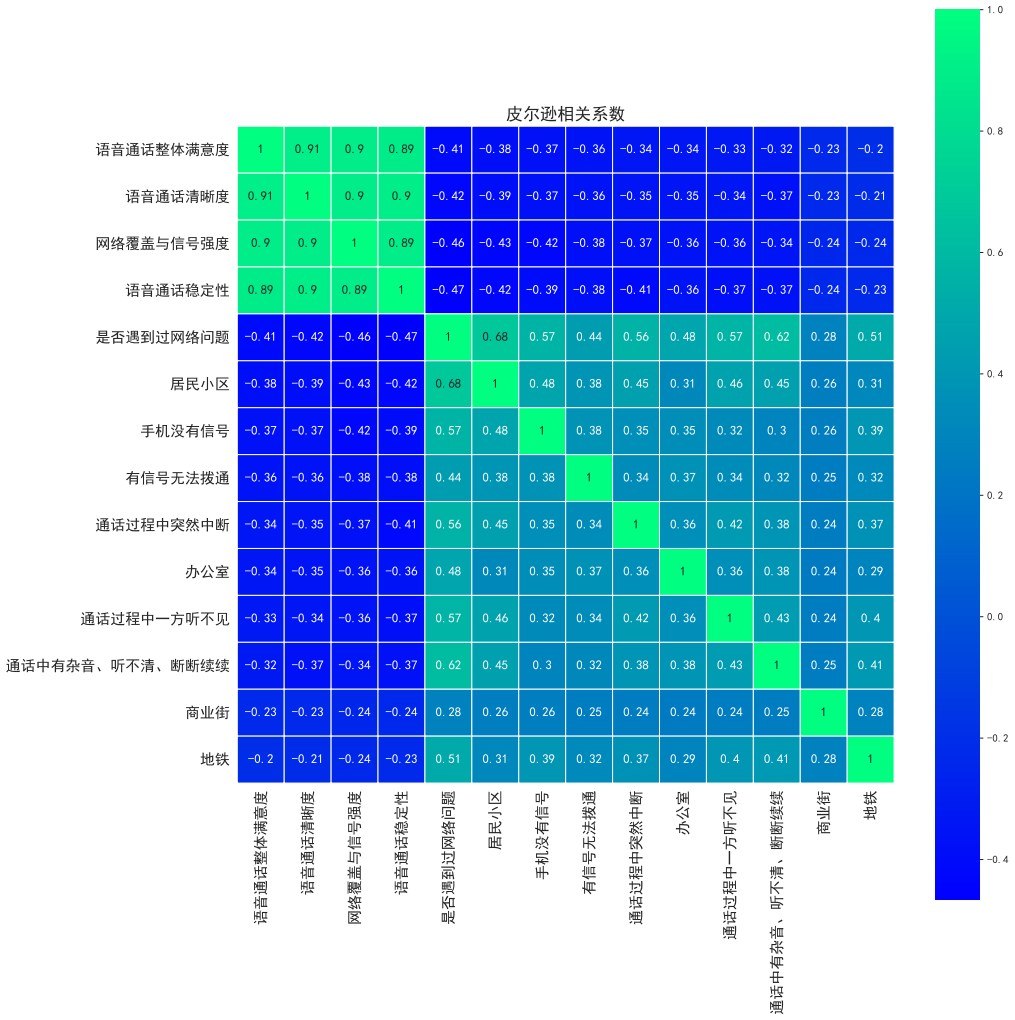


图 6　语音业务评分与其影响因素皮尔逊相关系数热力图

然中断”、“办公室”、“通话过程中一方听不见”、“通话中有杂音、听不清、断断续续”、“商业街”、“地铁”。为了更好地分析影响语音业务的因素，我们分别绘制出上述 10 个指标与语音业务四项评分之间的 RidViz 图，如图 7~图 10所示。由此我们可以发现，用户对于语音业务的四项评分，分布规律大致一致，且主要影响满意度的因素非常相似，同时噪声较小。因此我们在此分析基础上，建立熵权法、灰色关联度分析法、随机森林模型在整体上求得量化结果并得出主要因素。结果见表 12、表 13、图 11，其中图 11中数据见表 2最后一列。

通过分析上述图表，我们可以发现利用熵权法、灰色关联度分析法、随机森林模型得到的排序结果大致相同，主要影响因素有：“省际漫游-时长（分钟）”、“前 3 月 ARPU”、“套外流量（MB）”、“GPRS-总流量（KB）”、“套外流量费（元）”、“脱网次数”、“未接通掉话次数”、“mos 质差次数”、“其他，请注明.1”（该指标对应的是通话过程中遇到其他问题部分的注明）、“是否投诉”（特征构造出的因素）、“是否关怀用户”、“串线”、“其他，请注明”（该指标对应的是出现问题的场所部分的注明），以及在各场所遇到语音通话各个问题的情况。而在随机森林模型中，我们可以发现有部分因素量化值也排名较前，如“当月 ARPU”、“是否遇到过网络问题”、“前 3 月 MOU”、“语音通话-时长（分钟）”、“当月 MOU”、“客户星级标识”、“终端品牌”等因素。可以发现，随机森林模型可以给出更多的重要影响因素，避免了熵权法及灰色关联度分析的局限性，并且量化值可以用于后续模型的建立。

因此我们在此分析基础上，将语音业务的四项评分分别作为因变量，所有指标作为自变量（不包括评分），建立随机森林模型，绘制出其特征重要性图示，由于篇幅原因，读者可翻阅附录，见图 29~图 32。以及量化各影响因素影响程度，量化结果见表 2。

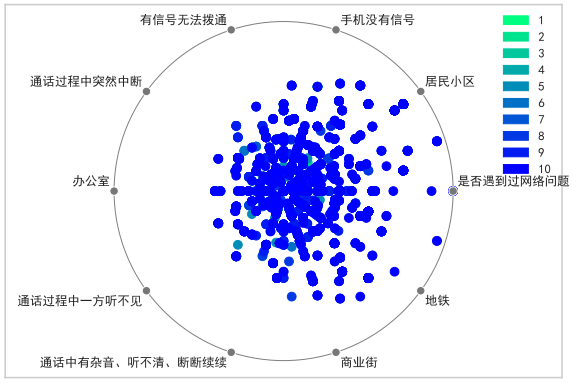


图 7　语音通话整体满意度与指标 RidViz

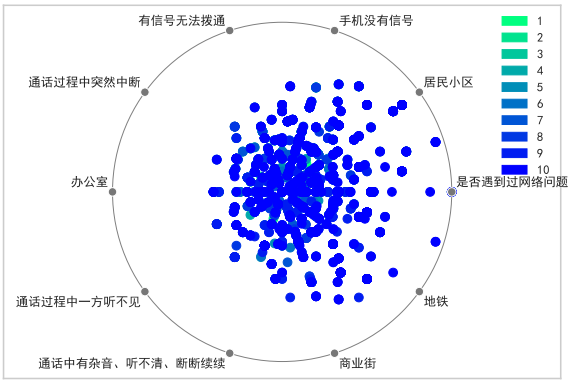


图 8　网络覆盖与信号强度与指标 RidViz

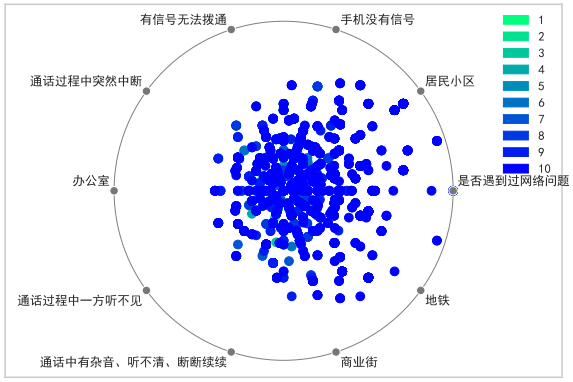


图 9　语音通话清晰度与指标 RidViz

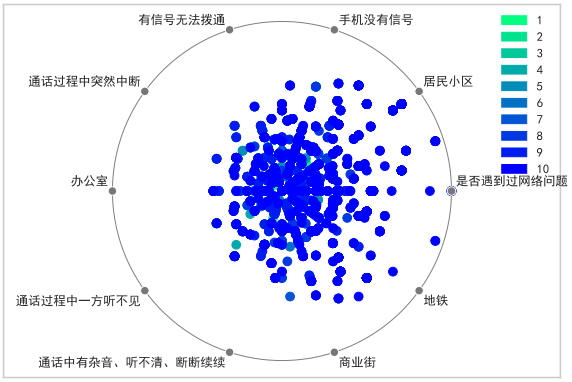


图 10　语音通话稳定性 RidViz

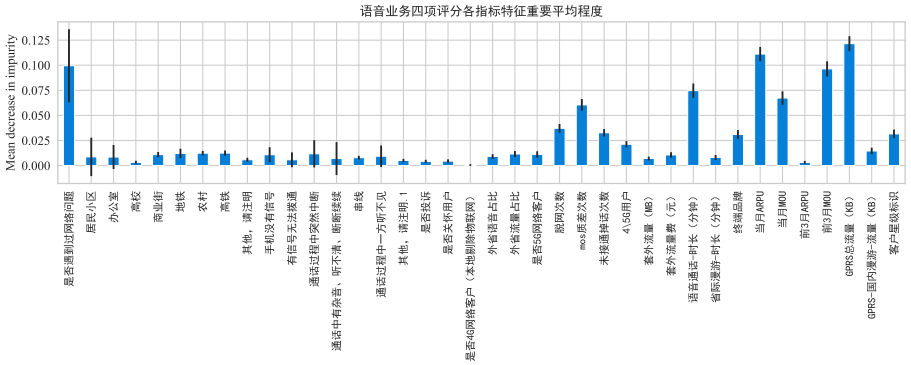


图 11　语音业务四项评分各指标特征重要平均程度

通过分析图 29~图 32以及表 2，我们可以得到以下结论：

- 对于**语音通话整体满意度**，影响客户满意度的主要因素有：“当月 ARPU”、“GPRS 总流量（KB）”、“语音通话-时长（分钟）”、“mos 质差次数”、“手机没有信号”、“未接通掉话次数”、“有信号无法拨通”、“通话中有杂音、听不清、断断续续”、“通话过程中突然中断”、“通话过程中一方听不见”，以及在各场所发生上述情况；

- 对于**网络覆盖与信号强度**，影响客户满意度的主要因素有：“GPRS 总流量（KB）”、“前 3 月 MOU”、“当月 ARPU”、“是否遇到过网络问题”、“mos 质差次数”、“脱网次

数”、“语音通话-时长（分钟）”、“手机没有信号”，以及在各场所发生上述情况；

- 对于**语音通话清晰度**，影响客户满意度的主要因素有：“GPRS 总流量（KB）”、“前 3 月 MOU”、“当月 ARPU”、“通话中有杂音、听不清、断断续续”、“mos 质差次数”、“语音通话-时长（分钟）”、“未接通掉话次数”，以及在各场所发生上述情况；

- 对于**语音通话稳定性**，影响客户满意度的主要因素有：“GPRS 总流量（KB）”、“当月 ARPU”、“语音通话-时长（分钟）”、“前 3 月 MOU”、“mos 质差次数”、“终端品牌”、“未接通掉话次数”、“客户星级标识”、“脱网次数”、“通话过程中突然中断”、“通话过程中一方听不见”、“手机没有信号”、“通话中有杂音、听不清、断断续续”、“有信号无法拨通”，以及在各场所发生上述情况；

- 对于**语音业务四项评分**，我们可以发现，影响客户满意度的主要因素大致相同，在不同的评分中，其量化出的影响程度不相同，但大致趋势一致。

通过上述模型的建立，我们得到了符合预期的效果。本文进行综合比较，可以更全面地分析出影响的主要因素，而对于量化值，我们以随机森林结果为准，这是由于该量化值更贴近于生活、可以更好地挖掘出其中隐含的因素，同时在后续模型的建立中，本文也会利用该结果进行分析，对于影响语音业务用户评分的因素量化最终结果见表 2。

表 2　语音业务总体以及四项评分各个指标影响程度量化结果

因素	语音通话整体满意度	网络覆盖与信号强度	语音通话清晰度	语音通话稳定性	语音业务总
GPRS 总流量（KB）	0.1266	0.1151	0.1181	0.1263	0.1215
当月 ARPU	0.1154	0.1116	0.1000	0.1032	0.1111
是否遇到过网络问题	0.0922	0.1015	0.0953	0.1080	0.0995
前 3 月 MOU	0.0996	0.1232	0.1028	0.0993	0.0964
语音通话-时长（分钟）	0.0726	0.0762	0.0754	0.0680	0.0747
当月 MOU	0.0671	0.0715	0.0722	0.0689	0.0673
mos 质差次数	0.0645	0.0512	0.0617	0.0670	0.0604
脱网次数	0.0388	0.0406	0.0361	0.0444	0.0372
未接通掉话次数	0.0334	0.0319	0.0328	0.0302	0.0327
客户星级标识	0.0315	0.0233	0.0259	0.0243	0.0316
终端品牌	0.0356	0.0297	0.0368	0.0382	0.0310
4\5G 用户	0.0114	0.0137	0.0177	0.0119	0.0212
GPRS-国内漫游-流量（KB）	0.0105	0.0112	0.0162	0.0136	0.0145
高铁	0.0107	0.0114	0.0141	0.0118	0.0124
农村	0.0117	0.0106	0.0105	0.0076	0.0124
地铁	0.0151	0.0126	0.0152	0.0129	0.0121
通话过程中突然中断	0.0081	0.0134	0.0096	0.0075	0.0117
外省流量占比	0.0133	0.0125	0.0110	0.0094	0.0115
是否 5G 网络客户	0.0116	0.0090	0.0128	0.0091	0.0112
商业街	0.0096	0.0080	0.0124	0.0071	0.0109
手机没有信号	0.0167	0.0076	0.0142	0.0177	0.0108
套外流量费（元）	0.0063	0.0077	0.0089	0.0102	0.0106
通话过程中一方听不见	0.0112	0.0121	0.0171	0.0085	0.0093
外省语音占比	0.0023	0.0069	0.0051	0.0066	0.0091
居民小区	0.0115	0.0112	0.0091	0.0148	0.0086
办公室	0.0073	0.0145	0.0117	0.0085	0.0085
省际漫游-时长（分钟）	0.0086	0.0114	0.0078	0.0060	0.0081
串线	0.0053	0.0036	0.0035	0.0057	0.0079
套外流量（MB）	0.0071	0.0070	0.0037	0.0070	0.0071
通话中有杂音、听不清、断断续续	0.0105	0.0078	0.0067	0.0106	0.0070
其他，请注明	0.0040	0.0052	0.0050	0.0065	0.0058
有信号无法拨通	0.0076	0.0051	0.0087	0.0088	0.0058
其他，请注明.1	0.0036	0.0065	0.0040	0.0048	0.0051
是否关怀用户	0.0070	0.0041	0.0055	0.0059	0.0044
是否投诉	0.0028	0.0029	0.0047	0.0032	0.0041
高校	0.0039	0.0038	0.0049	0.0033	0.0031
前 3 月 ARPU	0.0044	0.0037	0.0022	0.0030	0.0031
是否 4G 网络客户（本地剔除物联网）	0.0008	0.0005	0.0009	0.0004	0.0005

此外，为了更好地利用原数据集中用户描述文本数据，我们对其提取出高频词汇，并利用 Python 中 wordcloud 库绘制出语音业务用户描述高频词汇云图，见图 12。



图 12　语音业务用户描述高频词汇云图



图 13　上网业务用户描述高频词汇云图

根据图 12结果，我们可以发现，对于原数据集中尚未提及的因素，用户进行描述，语音方面更多的问题体现在：信号、网络、断断续续、突然中断等；场所更多地出现在：车库、小区、地下室、家里、山区、电梯、高速等。

5.2.3 上网业务求解

对于上网业务的分析，与语音业务求解类似。首先我们绘制上网业务用户四项评分箱线图，如图 5所示。再计算出皮尔逊相关系数，绘制其热力图，如图 27所示，图中仅显示相关度排名前 10 的指标。

由图 27可以直观发现，用户对于上网业务的满意度影响较大排名在前的因素依次为：“网络卡速度慢延时大上不了网总”、“出现问题场所或应用总”、“网络信号差/没有信号”、“手机上网速度慢”、“上网过程中网络时断时续或时快时慢”、“打开网页或 APP 图片慢”、“居民小区”、“显示有信号上不了网”、“办公室”、“看视频卡顿”。同时为了更好地分析影响上网业务的因素，我们与语音业务分析类似，绘制出上述 10 个指标与上网业务四项评分之间的 RidViz 图，由于篇幅原因，这里不再展示，读者可以在附件中查看，见图 33~图 36。

通过观察上述所得到的图，我们可以发现，用户对于上网业务的四项评分，分布规律也大致一致，且主要影响满意度的因素同样非常相似。因此，建立熵权法、灰色关联度分析法、随机森林模型在整体上得出主要因素并求得量化结果。结果见表 14、图 28。其中，图 28中数据见表 3最后一列及表 4最后一列。

结合分析结果，我们可以发现，利用 EWM 和灰色关联度分析，量化的结果大致相似，间接说明结果的准确性。对于上网业务，影响用户评分的主要因素有：“套外流量”、“其他，请注明.5”（该指标对应的是游戏部分的注明）、“火山”（视频）、“全部都卡”（特征构造出的因素）、“全部游戏都卡顿”、“看视频卡顿”、“性别”、“客户星级标识”、“上网过程中网络时断时续或时快时慢”、“下载速度慢”，“当月 MOU”，以及各种游戏、APP、视频的卡顿。这些因素在日常生活中也明显影响到用户对于上网体验的满意度，可以依此验证上述分析结果的准确性。对于随机森林量化出的结果，我们可以发现，影响到用户体验的主要因素有：“当有 MOU”（当月的通话时长），“网络卡速度慢延时大上不了网总”（特征构造出的因素）、“终端品牌”、“客户星级标识”、“出现问题场所或应用总”（特征构造出的因素）、“性别”、“脱网次数”、“质差总”（特征构造出的因素）、“是否 5G 网络客户”、“是否不限量套餐到达用户”、“显示有信号上不了网”、“上网过程中网络时断时续或时快时慢”，以及在各场所发生网络卡顿等问题。与 EWM 及灰色关联度分析比较，可以发现，有部分指标不一致，这可能是

由于在该模型中，部分因素对于模型的训练贡献较大，有部分潜在因素未被 EWM 及灰色关联度分析发现，但大致结果相同，符合预期效果。

其次，将语音业务的四项评分分别作为因变量，所有指标作为自变量，建立随机森林模型，绘制出其特征重要性图。由于图示与上文语音业务求解出的图为同一类型，且篇幅限制，读者可在附录中查看，见图 37~图 40。量化数据见表 3及表 4。通过分析上述图表，我们可以得出以下结论：

- 对于**手机上网整体满意度**，影响客户满意度的主要因素有：“当月 MOU”、“出现问题场所或应用总”（特征构造出的因素）、“终端品牌”、“脱网次数”、“网络卡速度慢延时大上不了网总”（特征构造出的因素）、“性别”、“客户星级标识”、“质差总”（特征构造出的因素）、“微信质差次数”、“居民小区”、“显示有信号上不了网”、“地铁”等；而类似于：“龙之谷”、“阴阳师”、“梦幻诛仙”等游戏或是 APP，影响度量化值趋近于 0，对于客户满意度影响较小；

- 对于**网络覆盖与信号强度**，影响客户满意度的主要因素有：“当月 MOU”、“网络卡速度慢延时大上不了网总”、“客户星级标识”、“终端品牌”、“出现问题场所或应用总”、“性别”、“是否 5G 网络客户”、“脱网次数”、“质差总”、“微信质差次数”、“套外流量费（元）”、“上网质差次数”、“农村”、“居民小区”等；而类似于：而类似于：“龙之谷”、“阴阳师”、“梦幻诛仙”等游戏或是 APP，影响度量化值趋近于 0，对于客户满意度影响较小；

- 对于**手机上网速度**，影响客户满意度的主要因素有：“当月 MOU”、“出现问题场所或应用总”、“终端品牌”、“客户星级标识”、“质差总”、“是否 5G 网络客户”、“网络卡速

表 3　上网业务总体以及四项评分各个指标影响程度量化结果 [续表见表 4]

因素	手机上网整体满意度	网络覆盖与信号强度	手机上网速度	手机上网稳定性	上网业务总
当月 MOU	0.1563	0.2447	0.2530	0.2436	0.2278
网络卡速度慢延时大上不了网总	0.0899	0.1259	0.0292	0.1295	0.1244
终端品牌	0.0332	0.0484	0.0643	0.0594	0.0551
客户星级标识	0.0223	0.0596	0.0531	0.0549	0.0522
出现问题场所或应用总	0.4678	0.0402	0.1258	0.0407	0.0394
性别	0.0242	0.0440	0.0286	0.0315	0.0387
脱网次数	0.0383	0.0282	0.0284	0.0323	0.0318
质差总	0.0107	0.0289	0.0334	0.0330	0.0317
是否 5G 网络客户	0.0092	0.0301	0.0350	0.0267	0.0296
微信质差次数	0.0104	0.0251	0.0205	0.0210	0.0233
是否不限量套餐到达用户	0.0078	0.0183	0.0189	0.0172	0.0226
套外流量费（元）	0.0089	0.0206	0.0249	0.0213	0.0221
上网质差次数	0.0058	0.0185	0.0208	0.0183	0.0215
农村	0.0067	0.0154	0.0150	0.0154	0.0163
显示有信号上不了网	0.0105	0.0131	0.0146	0.0150	0.0161
居民小区	0.0138	0.0185	0.0185	0.0170	0.0161
地铁	0.0100	0.0141	0.0145	0.0169	0.0151
高铁	0.0016	0.0138	0.0123	0.0123	0.0150
商业街	0.0090	0.0124	0.0127	0.0149	0.0139
上网过程中网络时断时续或时快时慢	0.0038	0.0102	0.0107	0.0103	0.0137
网络信号差/没有信号	0.0046	0.0109	0.0138	0.0139	0.0133
办公室	0.0091	0.0136	0.0156	0.0144	0.0120
套外流量（MB）	0.0029	0.0107	0.0089	0.0134	0.0119
手机支付较慢	0.0000	0.0073	0.0069	0.0058	0.0086
其他，请注明	0.0031	0.0123	0.0090	0.0100	0.0079
下载速度慢	0.0023	0.0073	0.0071	0.0067	0.0074
拼多多	0.0000	0.0035	0.0033	0.0038	0.0063
打游戏延时大	0.0094	0.0044	0.0033	0.0025	0.0063
抖音	0.0015	0.0081	0.0072	0.0051	0.0059
百度	0.0000	0.0064	0.0048	0.0061	0.0059
其他，请注明.1	0.0033	0.0041	0.0028	0.0056	0.0059
看视频卡顿	0.0020	0.0056	0.0054	0.0055	0.0056
微信	0.0012	0.0054	0.0042	0.0051	0.0052

表 4　上网业务总体以及四项评分各个指标影响程度量化结果 [表 3续表]

因素	手机上网整体满意度	网络覆盖与信号强度	手机上网速度	手机上网稳定性	上网业务总
高校	0.0000	0.0046	0.0063	0.0052	0.0051
腾讯视频	0.0022	0.0042	0.0044	0.0040	0.0049
打开网页或 APP 图片慢	0.0054	0.0042	0.0045	0.0042	0.0044
全部网页或 APP 都慢	0.0023	0.0031	0.0030	0.0028	0.0044
京东	0.0000	0.0064	0.0041	0.0060	0.0043
快手	0.0000	0.0026	0.0058	0.0042	0.0041
淘宝	0.0022	0.0044	0.0043	0.0054	0.0040
手机上网速度慢	0.0022	0.0031	0.0032	0.0034	0.0038
今日头条	0.0000	0.0047	0.0044	0.0048	0.0035
王者荣耀	0.0000	0.0030	0.0021	0.0020	0.0034
新浪微博	0.0000	0.0039	0.0033	0.0041	0.0029
爱奇艺	0.0016	0.0040	0.0049	0.0035	0.0027
优酷	0.0025	0.0021	0.0014	0.0026	0.0026
芒果 TV	0.0000	0.0014	0.0016	0.0026	0.0026
全部都卡顿	0.0020	0.0033	0.0040	0.0029	0.0026
手机 QQ	0.0000	0.0027	0.0040	0.0023	0.0026
其他，请注明.2	0.0000	0.0017	0.0017	0.0010	0.0019
搜狐视频	0.0000	0.0011	0.0006	0.0013	0.0018
咪咕视频	0.0000	0.0016	0.0009	0.0019	0.0017
其他，请注明.3	0.0000	0.0016	0.0030	0.0024	0.0015
其他，请注明.5	0.0000	0.0011	0.0016	0.0004	0.0013
全部游戏都卡顿	0.0000	0.0010	0.0006	0.0005	0.0013
火山	0.0000	0.0004	0.0003	0.0000	0.0011
和平精英	0.0000	0.0015	0.0014	0.0011	0.0008
欢乐斗地主	0.0000	0.0006	0.0003	0.0010	0.0008
其他，请注明.4	0.0000	0.0012	0.0002	0.0004	0.0007
梦幻西游	0.0000	0.0000	0.0009	0.0000	0.0003
穿越火线	0.0000	0.0005	0.0003	0.0004	0.0002
炉石传说	0.0000	0.0000	0.0007	0.0003	0.0001
部落冲突	0.0000	0.0004	0.0000	0.0002	0.0001
梦幻诛仙	0.0000	0.0000	0.0000	0.0000	0.0001
阴阳师	0.0000	0.0000	0.0000	0.0000	0.0000
龙之谷	0.0000	0.0000	0.0000	0.0000	0.0000

度慢延时大上不了网总”、“性别”、“脱网次数”、“套外流量费（元）”、“上网质差次数”等；而类似于：“龙之谷”、“阴阳师”、“梦幻诛仙”等游戏或是 APP，影响度量化值趋近于 0，对于客户满意度影响较小；

- 对于**手机上网稳定性**，影响客户满意度的主要因素有：“当月 MOU”、“网络卡速度慢延时大上不了网总”、“终端品牌”、“客户星级标识”、“出现问题场所或应用总”、“脱网次数”、“质差总”、“性别”等；而类似于：“龙之谷”、“阴阳师”、“梦幻诛仙”等游戏或是 APP，影响度量化值趋近于 0，对于客户满意度影响较小；

- 对于**上网业务四项评分**，我们可以发现，影响客户满意度的主要因素大致相同，在不同的评分中，其量化出的影响程度不相同，但大致趋势一致。

通过上述模型的建立，得到的效果符合预期。本文对 EWM、灰色关联度分析、随机森林的综合比较分析，可以更全面地分析出影响的主要因素。而对于量化值，我们以随机森林结果为准，这是由于，在上述的分析中，我们发现随机森林模型可以更好地解释主要影响因素，并且可以更好地利用数据挖掘出潜在信息，大大提高决策的高效性，准确性及可靠性，同时在后续模型的建立中，本文也会利用该结果进行分析，对于上网业务用户评分的因素量化最终结果见表 3及表 4。

此外，为了更好地分析影响语音业务的因素，我们对用户描述列提取出高频词汇，并绘制出上网业务用户描述高频词汇云图，见图 13。根据图 13结果，我们可以发现，对于原数据集中尚未提及的因素，用户进行描述，上网业务部分问题还体现在：信号、网络、流量、网速、经常没有、打不卡 APP、网页、在小区、电梯、医院、公交、家里等多个场所出现一系

列问题，提及的关键词还有：5G、速度、经常、断网、单位、微信、哔哩哔哩、小红书、突然、上网、信号不好等，这一系列关键词，都能有效反映出用户在实际体验中遇到的问题。

5.3 问题二模型的建立与求解

对于问题二，我们在问题一的基础上，对附件指标采用**主成分分析法**，对结果进行**累计方差解释**，绘制累计解释方差图，根据问题一结果及累计解释方差图。再建立多种用于**分类**的模型，包括**随机森林**、**XGBoost**、**KNN**、**SVM**、**LightGBM**、**改进的逻辑回归**。并对上述模型进行**超参数调优**，得到其最优模型。之后综合各个模型的表现，如准确率、平均绝对误差、均方误差等，有目的地进行合理组合，利用 **Stacking** 方法，进行集成学习，得到各评分预测模型，并且根据多方面指标对构建的集成学习进行评价分析，且解释预测的合理性。

5.3.1 累计解释方差

这里我们使用**主成分分析（Principal Component Analysis, PCA）**对附件 1 与附件 3 影响因素进行累计解释方差分析。其可对较高维度数据进行降维处理，并且保证原数据集信息丢失量最小化[11]，从而方便本文后续模型的建立。对于语音及上网业务，我们分别绘制出其各指标的累计解释方差图，如图 14、图 15所示。通过分析可知：

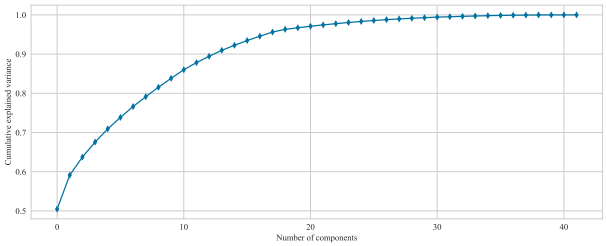


图 14　语音业务指标累计解释方差

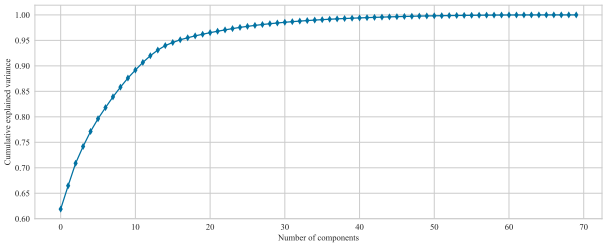


图 15　上网业务指标累计解释方差

- 对于**语音业务**：指标个数少于 20 个时，累计解释方差增幅较大，且约可累计解释 96% 以上方差，在 20 个指标后，增幅较小，当指标个数为 34 个时，可解释近于 100% 的方差。通过问题一的分析，我们可以将在其中量化结果中选择平均影响度量化值小于 0.0050 的进行特征剔除，包括：“是否关怀用户”、“是否投诉”、“高校”、“前 3 月 ARPU”、“是否 4G 网络客户（本地剔除物联网）”；

- 对于**上网业务**：指标个数少于 20 个时，累计解释方差增幅较大，且约可累计解释 96% 以上方差，在 20 个指标后，增幅较小，当指标个数为 50 个时，可解释近于 100% 的方差。通过问题一的分析，我们可以将在其中量化结果中选择平均影响度量化值小于 0.0010 的进行特征剔除，包括：“和平精英”、“欢乐斗地主”、“其他，请注明.4”（视频类 APP 的特殊注明列）、“梦幻西游”、“穿越火线”、“炉石传说”、“部落冲突”、“梦幻诛仙”、“阴阳师”、“龙之谷”；

- 对于**剔除的因素的合理性分析**：综合问题分析，我们发现：这些因素在业务上的解释性较弱，且在量化结果中的影响度较小，且在 PCA 分析中，这些因素的累计解释方差较

小，因此，我们认为这些因素对于业务的影响较小，故将其剔除分析。同时，我们对剔除前后的模型的准确率进行分析，发现，对于语音及上网业务的分析，模型准确率均有一定提升，介于 $1.24\% \sim 2.74\%$；

- 而对于下文**各个评分模型的建立**：我们会逐一分析，进行特征剔除，提升模型的准确性，以及模型的各项指标。上述的分析，首先在整体上确定合理方向。

5.3.2 多种多分类模型的建立

- **极端梯度提升（eXtreme Gradient Boosting, XGBoost）**。XGBoost 算法是一种基于树模型的优化模型，其将弱分类器组合，训练出一个较强的分类器。该算法通过多次迭代，生成一个新的树模型用于优化前一个树模型，随着迭代次数的增多，该模型的预测精度也会相应提高[8]。

  记通过数据处理后的数据集特征为 $R\left(x_{ij}\right)_{m\times n}$，表示其包含 m 个用户，n 个特征，在训练中形成的 CART 树的集合记为 $F=\left\{f\left(x\right)=w_{q(x)}, q:\mathbf{R}^{n}\rightarrow T, w\in\mathbf{R}^{T}\right\}$，其中 q 为树模型的叶节点决策规划，T 为某一树模型叶节点数量，w 为叶节点对应的得分[9]。对于预测的 y 值，其计算公式为

$$\hat{y}=\varphi\left(x_{i}\right)=\sum_{k=1}^{K}f_{k}\left(x_{i}\right) \tag{17}$$

  XGBoost 算法在每一次迭代过程中会保存前面所学习的模型，会将这些模型加入到新一轮迭代过程中，因此我们记第 i 个模型为预测结果为

$$\hat{y}_{i}^{(t)}=\hat{y}_{i}^{(t-1)}+f_{t}\left(x_{i}\right) \tag{18}$$

  XGBoost 算法的目标函数计算公式如下

$$L^{(t)}=\sum_{i=1}^{n}l\left(y_{i},\hat{y}_{i}^{(t-1)}+f_{t}\left(x_{i}\right)\right)+\gamma T+\frac{1}{2}\lambda\sum_{j=1}^{T}w_{j}^{2}+\text{const} \tag{19}$$

  上述公式中，l 为模型误差损失，描述在该模型下预测值与实际值之间的出差异损失，Ω 为模型叶节点的正则项惩罚系数，γ 与 λ 为模型的超参数[9]。通常情况下，我们难以用枚举法得到在模型中所训练出来的树结构，因此这里采用贪婪算法，从单叶子节点开始，通过迭代方法，将其加入到树结构中，从而得到最优解，其计算公式[10]如下

$$\mathcal{L}_{split}=\frac{1}{2}\left[\frac{\left(\sum_{i\in I_{L}}g_{i}\right)^{2}}{\sum_{i\in I_{L}}h_{i}+\lambda}+\frac{\left(\sum_{i\in I_{R}}g_{i}\right)^{2}}{\sum_{i\in I_{R}}h_{i}+\lambda}-\frac{\left(\sum_{i\in I}g_{i}\right)^{2}}{\sum_{i\in I}h_{i}+\lambda}\right]-\gamma \tag{20}$$

  其中 $I_{j}=\{i|q\left(x_{i}\right)=j\}$ 为叶节点 j 上的样本集合[9]，且有

$$g_{i}=\partial_{\hat{y}^{(t-1)}}l\left(y_{i},\hat{y}_{i}^{(t-1)}\right)\qquad h_{i}=\partial_{\hat{y}^{(t-1)}}^{2}l\left(y_{i},\hat{y}_{i}^{(t-1)}\right) \tag{21}$$

通过上述分析，我们可以得到 XGBoost 算法简图，如图 16所示。

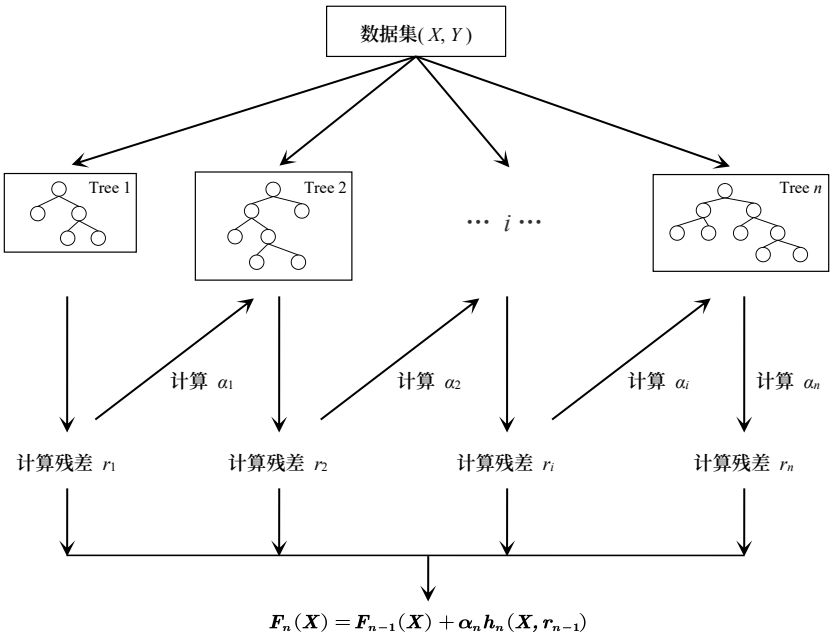


图 16　XGBoost 算法简图

- **K-近邻 (K Nearest Neighbor, KNN)**。KNN 算法的主要思想为：在出现新样本时从现有的训练数据中找到与其相对应的最接近的 K 个样本，并根据最相似的类别出现的样本进行分类。基于多数 K 个样本所属的类别来分辨待分类的数据集所属的类别[12]。接近度由两点之间的距离函数给出属性空间中的点决定。距离函数通常使用两个点之间的标准欧几里得距离。欧氏距离的计算公式如下

$$d(X,Y)=\sqrt{\sum_{i=1}^{n}(X_i-Y_i)^2} \tag{22}$$

其中 $X=(x_1,x_2,\cdots,x_m)^{\mathrm{T}}$ 和 $Y=(y_1,y_2,\cdots,y_m)^{\mathrm{T}}$ 表示两个样本列数据，m 为样本数量。

- **支持向量机（Support Vector Machine, SVM)**。SVM 建立在结构风险最小原理及 Vapnik-Chervonenkis 理论基础之上[13]，以有限的数据信息，在数据样本中找出合适区分类别的决策分界面，且保证边界点与分界面尽可能远，即需要再找出合适的边界分界面，该算法示意图如图 17所示。而由于 SVM 多应用于解决二分类问题，且我们需要建立多分类模型，因此需要对其进行相应的改进。本文采用 OVR（One Versus Rest）方法，将该问题改进为多个二分类问题[13]。在模型的训练时，任意将某一类别记为一类，其余类别记为另一类别，依次下去，建立出多分类的 SVM 模型。而对于核函数的选择，本文选择高斯核函数进行求解，其定义公式如下

$$K\left(x_i,x_j\right)=\exp\left(-\frac{\left\|x_i-x_j\right\|^2}{2\sigma^2}\right)=\exp\left(-\gamma\left\|x_i-x_j\right\|^2\right) \tag{23}$$

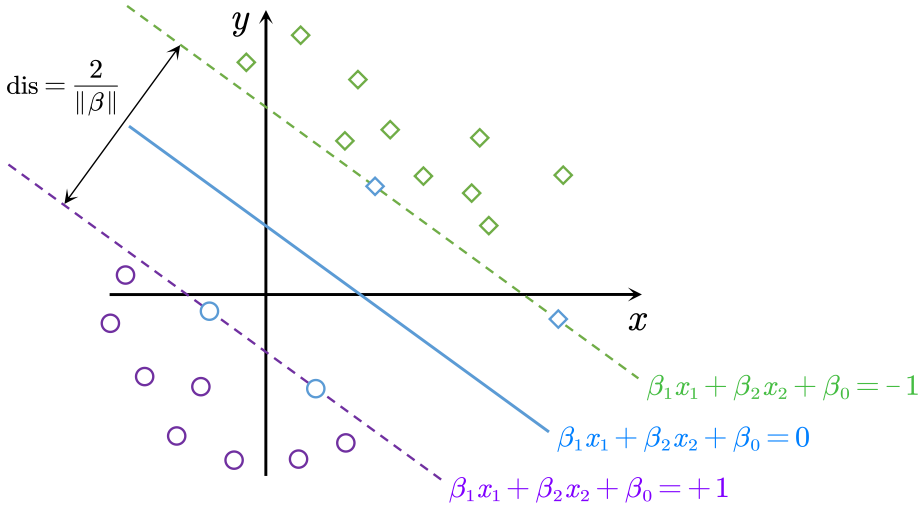


图 17　SVM 示意图

对于高斯核函数，其可以反映出样本两点之间的相似度大小。当 σ 确定后，若两点之间距离越小，则相似度趋近于 1；若距离越大，则相似度趋近于 0。

- **LightGBM（Light Gradient Boosting Machine）**。LightGBM 模型是基于决策树算法构建的一种高效的机器学习算法[14]。其为 XGBoost、直方图算法（Histogram）、基于梯度的单边采样（GOSS）算法以及互斥特征捆绑（EFB）算法的结合的一种算法。

- **多分类逻辑回归（Multinomial Logistic Regression）**。多分类逻辑回归是基于逻辑回归（Logistic Regression）进行学习的分类模型。对于逻辑回归模型，其属于分类模型，多用于二分类问题。若数据集为 $(\boldsymbol{A}, \boldsymbol{B}) = ((\boldsymbol{a}_1, b_1), (\boldsymbol{a}_2, b_2), \cdots, (\boldsymbol{a}_m, b_m))^{\mathrm{T}}$，其中 $\boldsymbol{a}_i = \left(a_i^1, a_i^2, \cdots, a_i^j\right)$，$a_i^j$ 为样本 $\boldsymbol{a}_i$ 的第 j 个特征，$\boldsymbol{B}$ 为因变量标签矩阵，该模型使用 Sigmoid 函数，同时构建样本 $\boldsymbol{a}_i$ 所属类别的概率，对于标签为 1 的结果，其概率可写为

$$P\left(b_i = 1 \mid \boldsymbol{a}_i, \boldsymbol{\omega}\right) = \frac{1}{1 + \mathrm{e}^{-\boldsymbol{a}_i b_i \boldsymbol{\omega}^{\mathrm{T}}}} \tag{24}$$

其中 $\boldsymbol{\omega} = (\omega^0, \omega^1, \cdots, \omega^n)^{\mathrm{T}}$ 为权重向量，即为优化模型的超参数。逻辑回归中利用损失函数来评估模型的预测结果与实际值之间的误差，其计算公式如下

$$L\left(\boldsymbol{A}, \boldsymbol{B}, \boldsymbol{\omega}\right) = \frac{1}{m} \sum_{i=1}^{m} \log\left(1 + \mathrm{e}^{-\boldsymbol{a}_i b_i \boldsymbol{\omega}^{\mathrm{T}}}\right) \tag{25}$$

而对于 $\boldsymbol{\omega}$，常采用梯度下降法来获得模型参数的最优解，其通过

$$\boldsymbol{\omega}^{\alpha+1} = \boldsymbol{\omega}^{\alpha} - \frac{\gamma}{m} \sum_{i=1}^{m} \left(\frac{1}{1 + \mathrm{e}^{-\boldsymbol{a}_i b_i \boldsymbol{\omega}^{\mathrm{T}}}} - 1\right) \boldsymbol{a}_i b_i \tag{26}$$

进行迭代更新，其中 γ 为模型的学习率，当 $|\boldsymbol{\omega}^{\alpha} - \boldsymbol{\omega}^{\alpha+1}| < \eta$ 或达到最大迭代次数时，停止训练，输出最终模型，其中 η 为人为给定的阈值[15]。

5.3.3 Stacking 集成学习原理解释

Stacking 集成学习是通过建立多个机器学习模型，将其有目的地进行合理组合，从各模型中学到优点，有利于模型的效果的提升。其基本过程为，首先将已经经过处理的原数据集划分成若干个子集数据，在第一层建立多个模型的融合模型，输入数据，并采用五折交叉验证，获得每个模型的对于因变量标签的预测结果；之后第一层的输出结果作为第二层较弱分类模型的输入数据，第二层单个模型进行训练学习，得到最终预测结果[16]。算法示意图如图 18所示，算法伪代码如Algorithm2所示。

Algorithm 2: Stacking 集成学习

Input: 训练集 $\mathcal{D}$

第一层学习模型 $\mathcal{F}_1$，$\mathcal{F}_2$，$\cdots$，$\mathcal{F}_n$

第二层学习模型 $\mathcal{S}$

for $t = 1, 2, 3, \cdots, n$ **do**

  $h_n = \mathcal{F}_n(\mathcal{D})$

end

$\mathcal{D}' = \varnothing$

for $i = 1, 2, \cdots, m$ **do**

  for $t = 1, 2, \cdots, n$ **do**

    $z_{in} = h_n(x_i)$

  end

  $\mathcal{D}' = \mathcal{D}' \cup ((z_{i1}, z_{i2}, \cdots, z_{in}), y_i)$

end

$h' = \mathcal{S}(D')$

Output: $\mathcal{H}(x) = h'(h_1(x), h_2(x), \cdots, h_n(x))$

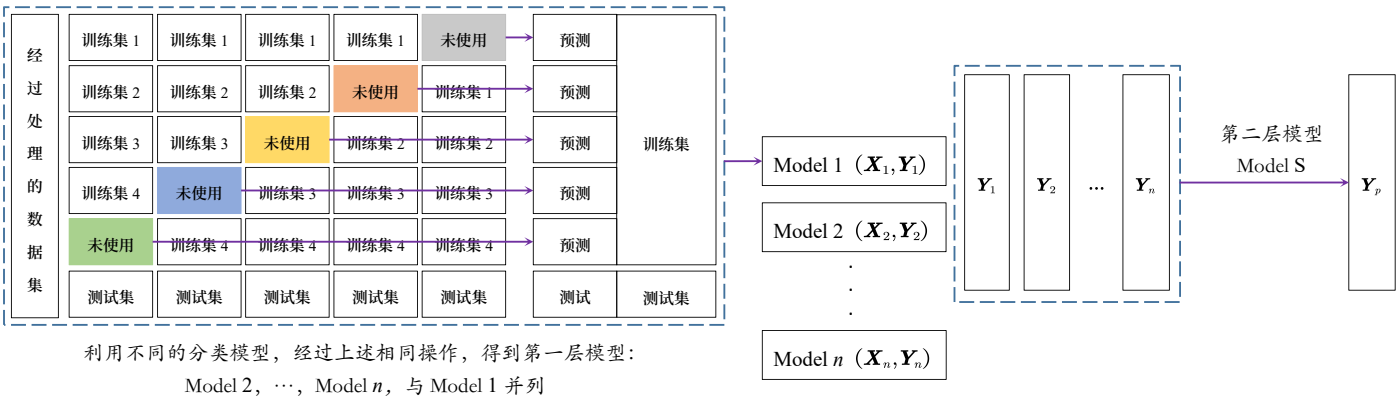


图 18 Stacking 集成学习示意图

5.3.4 模型的超参数调优

为了更好地预测用户评分，我们在建立上述模型的基础上，对模型进行超参数调优，以提高模型的预测准确性，减小平均绝对误差以及均方误差。

- **随机森林调优：**这边我们以语音业务中“网络覆盖与信号强度”评分为研究对象，进行调参，其他评分下建立的模型调参与此大致相同。随机森林最需要调节的参数为树的棵数（n_estimators），而森林深度、信息计算方法、叶节点等为辅助调参参数。首先我

们绘制模型“Acc-n_estimators”图像，见图 19，图像纵坐标为模型准确率，横坐标为 n_estimators 值。通过观察可以发现，该模型对于该数据在 n_estimators=161 附近时，

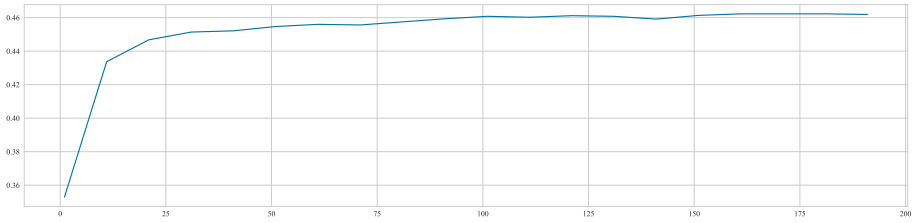


图 19　随机森林 n_estimators 调优图像，第一次

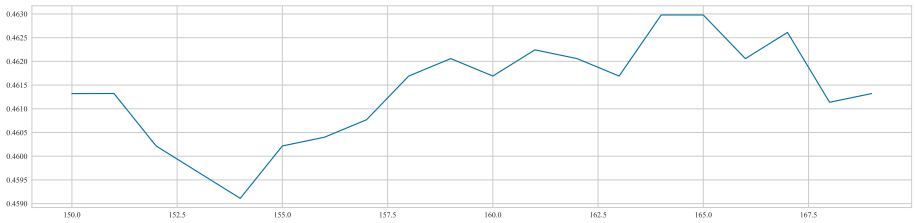


图 20　随机森林 n_estimators 调优图像，第二次

准确率最高，故我们选择 n_estimators=161 作为参数值。根据上述分析结果，进一步细化随机森林学习曲线，我们将在 150 ∼ 170 之间寻找最佳值。我们绘制出 n_estimators 在 150 ∼ 170 之间的学习曲线，见图 20。通过观察该图，我们发现对于该数据集，该模型的 n_estimators 最佳值为 164，故我们选择 n_estimators=164 作为参数值。

之后我们对参数 max_features，min_samples_leaf，criterion，max_depth 利用 Python 的 sklearn.model_selection 中的 GridSearchCV 模块进行调节，最终得到在该评分下，随机森林模型最优参数，结果见表 5。

表 5　语音业务-网络覆盖与信号强度评分下随机森林模型最优参数

参数	最优选取
n_estimators	164
max_features	log2
min_samples_leaf	8
criterion	gini
max_depth	19

通过计算，该模型调参前准确率为 45.67%，调节最优参数后，准确率上升至 51.01%，较原先提升了 11.69%，可以发现，调参效果良好。

- **XGBoost、KNN、SVM、LightGBM、多分类逻辑回归调优：**对于这些模型，我们采用网格搜索的方法进行调参，设置好需要调参的对象及范围，利用 Python 的 sklearn 库中的 model_selection.GridSearchCV 模块，进行调优。具体代码可以参看附录 [D]。通过分析，可以发现，各个模型在调参后，准确率均有一定提升，较原模型准确率的提升部分模型可以达到 14.25%，提升的百分点约为 6.28%，调参效果良好，符合预期效果。

5.3.5 特征选择

为了更好地预测用户评分，尽可能地提升模型的准确率、泛化能力，以及降低其预测的平均绝对误差、均方误差，我们在问题一的基础上，对特征进行了筛选，并且结合 XGBoost 模型的特种重要性可视化进行综合分析。对语言及上网业务共计八项评分，每一个进行了综合特征筛选。这里我们以语音业务-语音通话整体满意度评分为例，进行特征选择的分析。根据 XGBoost 模型，我们绘制出该评分下影响因素的重要性可视化图，如图 21所示。[3]

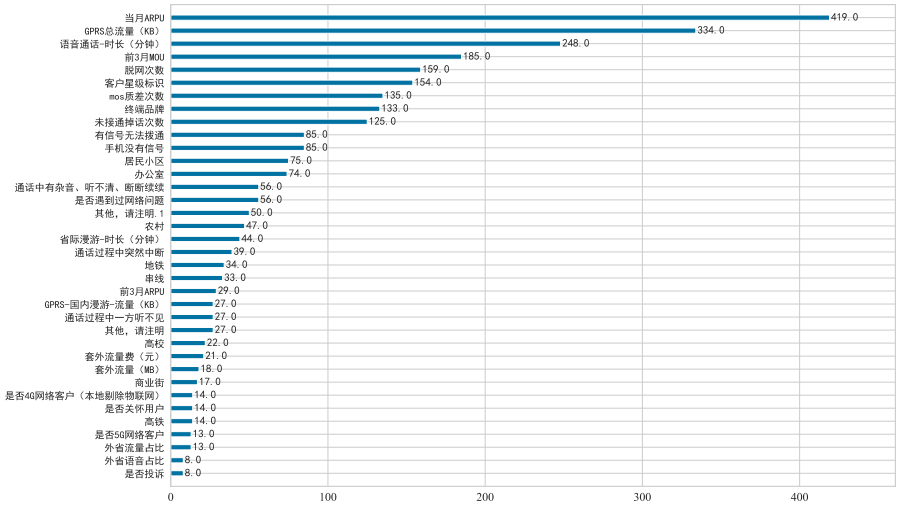


图 21　语音通话整体满意度各项指标重要程度，XGBoost

观察该图，我们可以发现，对于语音业务的语音通话整体满意度评分的影响因素，XGBoost 模型计算的结果与随机森林模型大致相似。我们综合表 2以及图 21结果，选择两个模型分析出的重要性高的特征，且剔除随机森林模型量化结果在 0.0010 以下，以及 XGBoost 模型量化结果在 10 以下的特征，它们为：“是否 4G 网络客户（本地剔除物联网）”、“外省语音占比”、“是否投诉”三项，并在这基础上建立后续模型，进行分析、预测。

而对于语音及上网业务的其余评分，思路与上述一致，由于篇幅原因，这里不再赘述。对于各评分的 XGBoost 特征重要性可视图，读者可以在附件中查看，见图 41~图 47。

5.3.6 模型的选择及集成

对八项评分，我们均建立**随机森林、XGBoost、KNN、SVM、LightGBM、多分类逻辑回归**模型，且进行参数调优，得到每一个最优模型。并且计算每一个模型的准确率（Accuracy）、平均绝对误差（Mean Absolute Error，MAE）、均方误差（Mean Square Error, MSE）。对于多分类模型，该三项指标，计算公式如下：

- **准确率**

$$\text{Accuracy} = \frac{N_{\text{TruePredict}}}{N_{\text{Sample}}} \tag{27}$$

其中，$N_{\text{TruePredict}}$ 为预测正确的样本数，N_{Sample} 为被预测的样本总数；

[3]其中由于上网业务的特征较多，对于其下的四项评分，我们仅选取了 20 个特征进行了可视化，但对评分特征选择的分析，本文是对所有特征进行选择的。

- **平均绝对误差**

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{28}$$

其中，y_i 为实际值，$\hat{y}_i$ 为预测值；

- **均方误差**

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \tag{29}$$

利用上述公式，我们可以计算出每个模型这三项指标，结果见表 6、表 7以及表 8。

表 6　随机森林、XGBoost 各评分三项指标结果

评分项目	随机森林			XGBoost		
	准确率	平均绝对误差	均方误差	准确率	平均绝对误差	均方误差
语音通话整体满意度	0.5829	1.2910	6.5378	0.5949	1.2320	6.0331
网络覆盖与信号强度	0.5101	1.5304	7.6077	0.4936	1.4926	7.0562
语音通话清晰度	0.5424	1.2864	6.0691	0.5331	1.3039	6.0976
语音通话稳定性	0.5184	1.3996	6.5433	0.5184	1.4282	6.7928
手机上网整体满意度	0.4459	1.7692	8.6752	0.4359	1.7222	8.2265
网络覆盖与信号强度	0.3903	1.7322	7.5214	0.3775	1.7863	7.8775
手机上网速度	0.3775	1.7892	7.7664	0.3533	1.7222	6.9587
手机上网稳定性	0.3803	1.8348	8.0912	0.3889	1.7792	7.8846

表 7　KNN、SVM 各评分三项指标结果

评分项目	KNN			SVM		
	准确率	平均绝对误差	均方误差	准确率	平均绝对误差	均方误差
语音通话整体满意度	0.5893	1.2680	6.5055	0.5884	1.3582	7.3103
网络覆盖与信号强度	0.5009	1.5506	7.6924	0.4991	1.5948	8.0571
语音通话清晰度	0.5543	1.3002	6.2063	0.5543	1.3932	7.1133
语音通话稳定性	0.5239	1.4162	6.7385	0.5267	1.4678	7.2652
手机上网整体满意度	0.4217	1.8148	8.6268	0.4330	1.8575	9.3846
网络覆盖与信号强度	0.3946	1.7792	8.0271	0.3960	1.8504	8.6966
手机上网速度	0.3818	1.7806	7.7094	0.3732	1.8519	8.5071
手机上网稳定性	0.3832	1.7977	8.1054	0.3818	1.9259	9.0057

表 8　LightGBM、多分类逻辑回归各评分三项指标结果

评分项目	LightGBM			多分类逻辑回归		
	准确率	平均绝对误差	均方误差	准确率	平均绝对误差	均方误差
语音通话整体满意度	0.5737	1.2366	5.8131	0.5829	1.2330	6.0230
网络覆盖与信号强度	0.4899	1.5037	7.1298	0.5000	1.4797	7.0101
语音通话清晰度	0.5396	1.2606	5.6860	0.5451	1.2845	5.9843
语音通话稳定性	0.5110	1.3517	6.1455	0.5285	1.3923	6.5727
手机上网整体满意度	0.4444	1.7123	8.1852	0.4302	1.7821	8.7365
网络覆盖与信号强度	0.3846	1.7393	7.4772	0.3718	1.8547	8.4530
手机上网速度	0.3704	1.7222	7.2464	0.3761	1.8219	8.0840
手机上网稳定性	0.3675	1.8433	8.1140	0.3818	1.8305	8.2550

通过分析上述表格，我们综合模型的准确率、平均绝对误差、均方误差的表现，对每一项评分选择基模型以及第二层模型，选择好的组合见表 9。

表 9　各个评分预测 Stacking 集成学习模型的建立

评分项目	基模型					第二层模型
语音通话整体满意度	XGBoost	KNN	SVM	LightGBM	LR	RF
网络覆盖与信号强度	RF	XGBoost	KNN	SVM	LR	LightGBM
语音通话清晰度	XGBoost	KNN	SVM	LightGBM	LR	RF
语音通话稳定性	RF	SVM	KNN	LightGBM	LR	XGBoost
手机上网整体满意度	RF	XGBoost	KNN	LightGBM	LR	SVM
网络覆盖与信号强度	RF	XGBoost	KNN	LightGBM	LR	SVM
手机上网速度	RF	XGBoost	KNN	LightGBM	LR	SVM
手机上网稳定性	RF	XGBoost	KNN	LightGBM	LR	SVM

依据表 9的融合组合，我们最终建立对于语音及上网业务每一项评分的用户评分预测模型，用于对附件 2 以及附件 4 中的用户评分进行预测。

5.3.7 客户评分预测

在“5.1 数据的准备”中，我们提到对学习数据与预测数据进行一致化，这是为了统一预测的自变量，避免不同的自变量的混乱，导致预测错误。经过对预测数据集的处理，利用上述已建立好的八个模型，对每一位用户的评分进行预测。这里我们需要注意的是：首先，要保证传入模型的变量要与训练时传入的指标一致；其次，在上文中我们提到我们选用多分类解决，而需要对评分进行标签编码，即将原评分 $y \in [1, 10]$ 映射至新评分标签 $y' \in [0, 9]$，即有关系式 $y' = y - 1$，而对于新数据的预测，我们要在模型的每个预测结果上加 1，避免预测结果出错。由于被预测用户过多，我们将不在论文中展示，而将以文件形式保存至“result.xlsx”。

5.3.8 模型预测结果合理性分析

本文对于数据集充分分析，多方面考虑，建立多模型调参融合的 Stacking 集成学习模型，且对模型训练采用五折交叉验证，保证模型的稳健性。对于语音业务数据的处理，我们将数据集划分训练集与测试集，比例为 8:2；对于上网业务数据的处理，我们将数据集划分训练集与测试集，比例为 9:1。对于两项业务这样处理有以下几点原因：

- 为验证模型的效果、分析模型的合理性、对模型参数进行调优、有监督地在数据上进行学习，更好地分析模型对于重要特征的选择，进行特征选择等，因此我们需要对数据集划分训练集与测试集；
- 对于语音业务，我们划分训练集与测试集比例为 8:2，这是由于我们观察到，语音业务的数据分布较优，且需要学习的特征相对于上网业务较少，若过分提高该比例，模型可能会产生过拟合的情况，无法对未知数据进行高效分析，泛化能力差；
- 对于上网业务，我们划分训练集与测试集比例为 9:1，这是由于我们观察到，上网业务需要学习的特征较多，若训练集样本过少，可能导致训练的模型发生欠拟合的情况，未能更好地学习到数据的内在规律，导致模型的多项指标为达到期望值。

此外，由于用户评分性质，我们选择多分类模型解决，为了更好地学习、预测，我们建立多个分类模型，且对各模型进行超参数的调节，在一定程度上提高模型的预测精度，分析

各个影响因素的特征重要性。此外利用 Stacking，对多模型进行集成学习，使得最终模型可以学习到各个模型的特性，且在一定程度上提升模型的泛化能力。

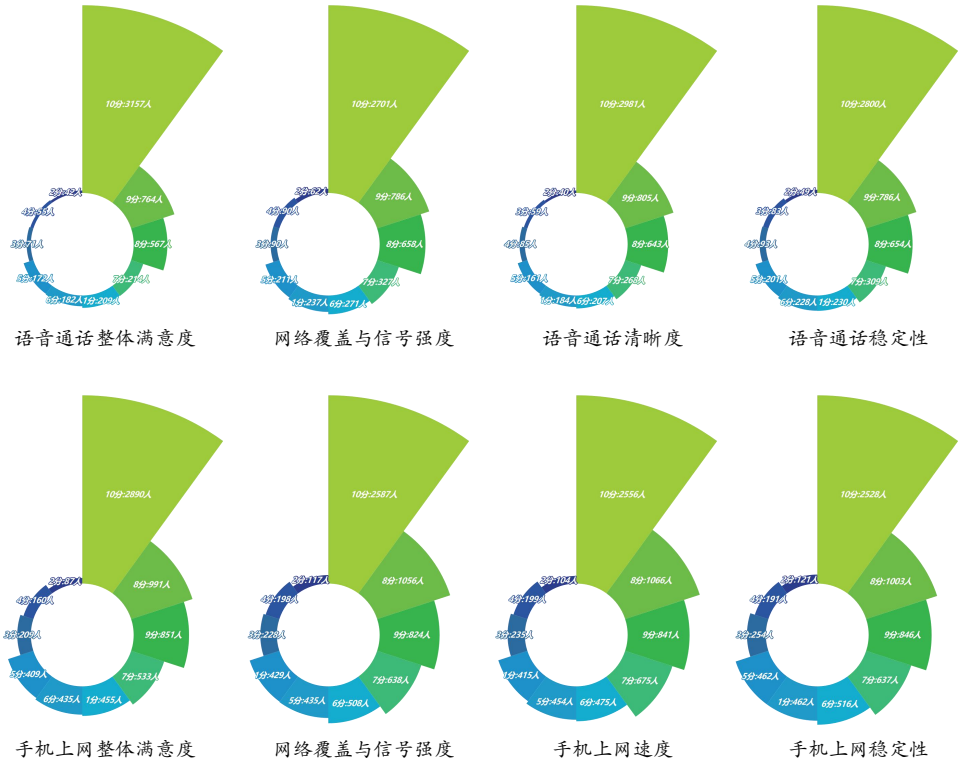


图 22　[附件 1、附件 2] 各类评分人数南丁格尔玫瑰图

同时我们计算出各个最终模型（即八个 Stacking 集成学习后的模型）的准确率。然而观察到，各评分的分类不平衡，即某些评分的样本量要远远大于某些评分，见图 22。因此，仅由准确率评估模型效果过于片面，且可能得到错误结论，因此我们还计算出各模型的平均绝对误差、均方误差，且准确率取五折交叉验证平均值，结果见表 10。

表 10　各评分预测模型效果

模型	五折交叉验证平均准确率	平均绝对误差	均方误差
模型一 [预测语音业务，语音通话整体满意度]	0.5773	1.2937	6.3877
模型二 [预测语音业务，网络覆盖与信号强度]	0.4880	1.5387	7.3416
模型三 [预测语音业务，语音通话清晰度]	0.5405	1.3527	6.4540
模型四 [预测语音业务，语音通话稳定性]	0.5212	1.3913	6.3748
模型五 [预测上网业务，手机上网整体满意度]	0.4359	1.7094	8.0684
模型六 [预测上网业务，网络覆盖与信号强度]	0.3803	1.7650	7.7764
模型七 [预测上网业务，手机上网速度]	0.3761	1.7208	7.3134
模型八 [预测上网业务，手机上网稳定性]	0.3875	1.8276	8.0897

我们将表 6、表 7、表 8与表 10进行对比分析，可以发现，Stacking 模型较其组成的模型各结果均有一定优化，且预测结果有良好的稳健性。Stacking 学习其组成模型的优势，更大范围地高效利用数据集间隐藏的关系，具有良好的预测效果。

为了更好地评估模型，对预测结果的合理性进行分析，我们绘制出各个模型的**混淆矩阵热力图**、**分类报告**、**ROC/AUC 曲线**。这里由于篇幅原因，我们仅展示“预测语音业务-语音通话整体满意度”三幅模型效果可视化图形，其余模型的分析与其一致。对于其余模型的可视化图形，读者可在附录中查看。其余七个模型的混淆矩阵热力图见图 48~图 54；分类报告见图 55~图 61；ROC/AUC 曲线见图 62~图 68。

- **混淆矩阵热力图**。该可视化图形的每一行表示样本标签的实际类别，在本题中表示用户评分的实际值[4]，而每一行表示样本标签的预测类别，在本题中表示用户评分的预测值。因此该图示的主对角线数据之和即为模型预测准确的样本数。对于多分类模型，我们可以随机指定一类为正类，而其余就为对应的负类。这里我们需要引入四项值，分别为 TP、FN、FP、TN，其中 T 为 True，F 为 False，这两个字母表示预测值与实际值是否相同；P 为 Positive，N 为 Negative，这两个字母表示预测出的是属于正类（阳性）还是负类（阴性）。而混淆矩阵热力图即为这些值组成，该图示可以直观地观察到预测准确与错误的情况，以及模型对于每一类别的区分程度。模型一的混淆矩阵热力图见图 23。

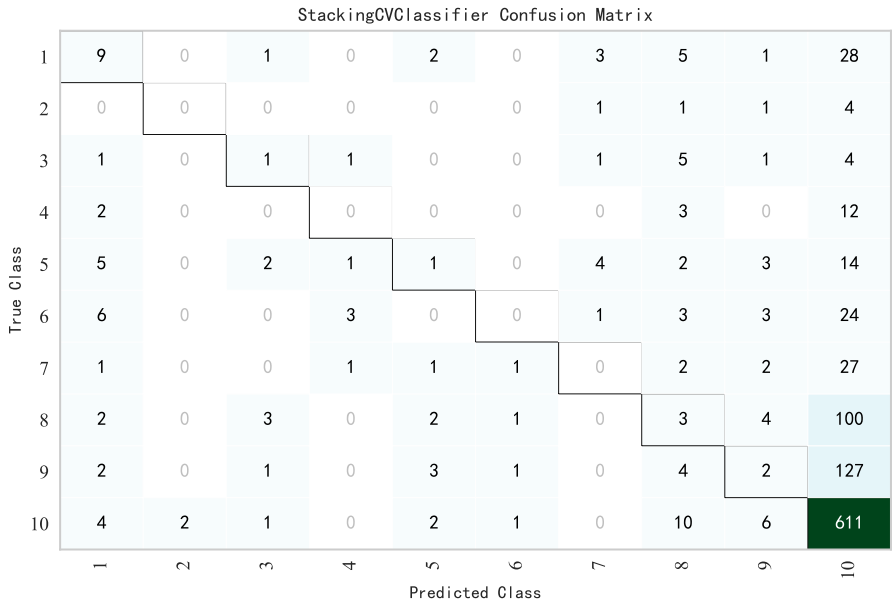


图 23　模型一混淆矩阵热力图 [语音业务-语音通话整体满意度]

观察该图，我们可以发现，该模型对于预测用户评分具有较好的效果，主对角线附近元素较多，说明模型预测正确的误差较小，预测得分与用户实际评分比较接近，可以较好预测用户评分。

- **分类报告**。分类报告图示可以直观得到模型各项参数，包括每一类别的精确率（Precision），召回率（Recall），F1 分数值（F1-Score）。对于这三项值，其计算公式如下：

  – **精确率**

$$\text{Precision} = \frac{TP}{TP + FP} \tag{30}$$

  – **召回率**

$$\text{Recall} = \frac{TP}{TP + FN} \tag{31}$$

  – **F1 分数值**

$$\text{F1} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{TP}{TP + \frac{1}{2}(FP + FN)} \tag{32}$$

[4]上文中提到我们对用户评分进行标签编码，从原来的 $[1, 10]$ 映射至新评分标签 $[0, 9]$，即在原评分基础上减 1，而在混淆矩阵热力图及分类报告图示中我们将标签编码已映射回原评分，对于模型的 ROC/AUC 曲线，我们未映射回原评分。

根据上述(30) 式、(31) 式、(32) 式，我们可以计算出每一个模型对于每一类别的三项指标值，并绘制分类报告图，对于模型一的分类报告，见图 24。此外我们还利用宏观（Macro）、微观（Micro）、权重（Weighted）三种方法计算模型的精确率、召回率以及 F1 分数值。宏观方法即取所有类别得出的值的平均值，不考虑样本的不平衡性；微观方法将所有样本视为整体；权重方法计算的是加权平均值。结果见表 11。

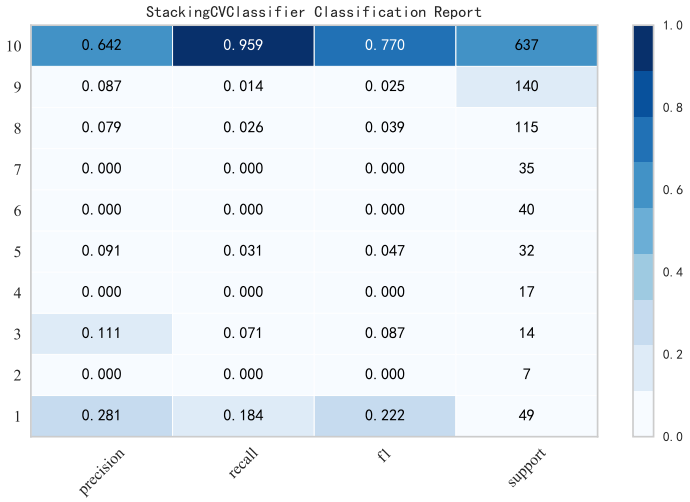


图 24　模型一分类报告 [语音业务-语音通话整体满意度]

表 11　模型一宏观、微观、权重计算准确率、召回率、F1 分数值

Method	Precision	Recall	F1-Score
Macro	0.1291	0.1285	0.1190
Micro	0.5773	0.5773	0.5773
Weighted	0.4373	0.5855	0.4841

根据上述图表，我们可以发现，对于不平衡的样本数据，若仅仅计算模型的准确率，显然不能很好体现模型的效果，同时我们也应该根据实际业务需求，对 Macro 及 Micro 方法进行综合分析。在样本类别的数目分布不均衡时，Macro 方法会同等对待每一种分类；而 Micro 方法较 Macro 方法更加趋向于客观结果的分析。此外，对于模型的精确率、召回率，我们可以根据定义发现，这两项值显然较大，模型效果较好。同时根据定义，我们可以发现模型的精确率、召回率在理想情况下是相差较小的，我们可以根据图表结果验证，符合预期效果。对于模型的 F1 分数值，其为精确率与召回率的调和平均数，因此当精确率与召回率均有较好表现时，F1 分数值会有较优秀表现。我们也可对(32) 式进行一定变换，可以得到

$$\mathrm{F1} = \frac{2}{\frac{1}{\mathrm{Precision}} + \frac{1}{\mathrm{Recall}}} \tag{33}$$

根据该式，我们可以得出上述结论。

- **ROC/AUC 曲线**。在分析特征曲线及曲线下面积（Receiver Operating Characteristic/Area Under the Curve, ROC/AUC）图之前，我们需要了解模型的相关参数，定义如下：

– **灵敏度（Sensitivity）**。灵敏度又被称为真阳性率，即 TP 率，定义为：

$$\text{Sensitivity} = TPR = \frac{TP}{TP + FN} \tag{34}$$

– **特异性（Specificity）**。特异性又被称为真阴性率，即 TN 率，定义为：

$$\text{Specificity} = TNR = \frac{TN}{TN + FP} \tag{35}$$

– **1-Specificity**。称为假阳性率（False Positive Rate, FPR），定义为：

$$FPR = 1 - \text{Specificity} = \frac{FP}{FP + TN} \tag{36}$$

– **1-Sensitivity**。称为假阴性率（False Negative Rate, FNR），定义为：

$$FNR = 1 - \text{Sensitivity} = \frac{FN}{FN + TP} \tag{37}$$

FPR 和 FNR 均对数据分布的变化不敏感[17]，因此这两个指标可以用于在不平衡的数据上建立的模型效果的评价。

对于 ROC/AUC 曲线，其以每一类别的 $1-\text{Specificity}$ 即 FPR 为横坐标，以 Sensitivity 即 TPR 为纵坐标，其可体现出模型的灵敏度与特异性之间的关系与差异。因此，该图的理想点位于左上角，即 $FPR = 0$ 且 $TPR = 1$，换言之，当曲线越靠近左上角，模型效果就越优。从而，我们可以得到另一项指标，即曲线下面积（Area Under the Curve, AUC），由上述分析可知，AUC 值越高，模型的整体效果也就越优。对于模型一的 ROC/AUC 曲线，见图 25。

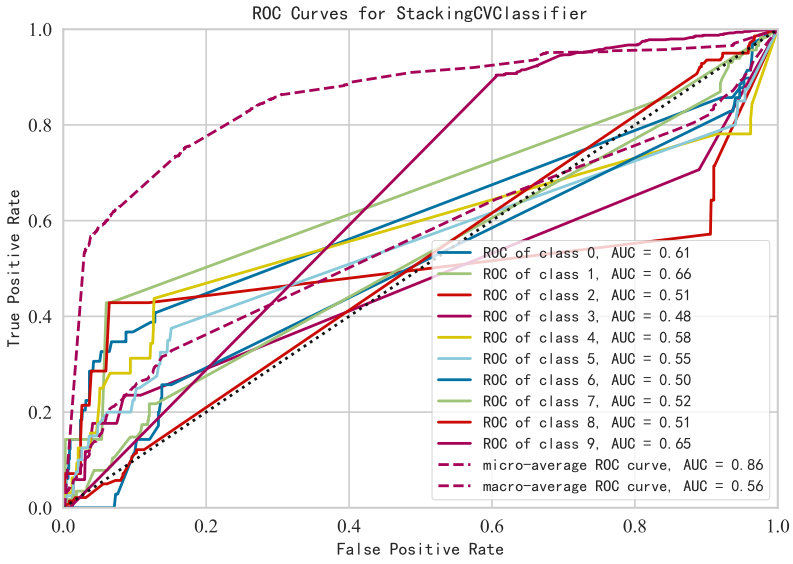


图 25　模型一 ROC/AUC 曲线 [语音业务-语音通话整体满意度]

根据上图结果，我们可以发现，模型一预测用户对于“语音业务-语音通话整体满意度”

的评分结果中，除对于类别 3（即实际评分为 4 分）的 AUC $<$ 0.50 之外，其余的 AUC $\geqslant$ 0.50，即以 $y = x$ 为分界线。同时，我们可以发现“macro-average ROC curve”指标，其是通过 Macro 方法求得，在上文中我们提到，该数据样本的标签分类是严重不平衡的，该方法能够平等对待每一项分类，在此方法下，我们可以对于小样本类别的准确率有一定把握，其曲线下面积 AUC = 0.56，位于分界线左上，预测效果良好；而对于“micro-average ROC curve”指标，其 AUC = 0.86，这指的是利用 Micro 方法求得曲线，曲线下面积为 0.86，曲线下面积较大，且曲线有向左上角最优点靠近的趋势，可以说明模型整体能力较优。

此外，为观察预测出的评分分布是否大体与已知评分数据集评分分布大致一致，我们再次绘制南丁格尔玫瑰图，见图 26。观察该图及图 22，我们可以发现预测出的评分分布与已知评分数据集评分分布大体一致，符合数据的一般性及内在规律。

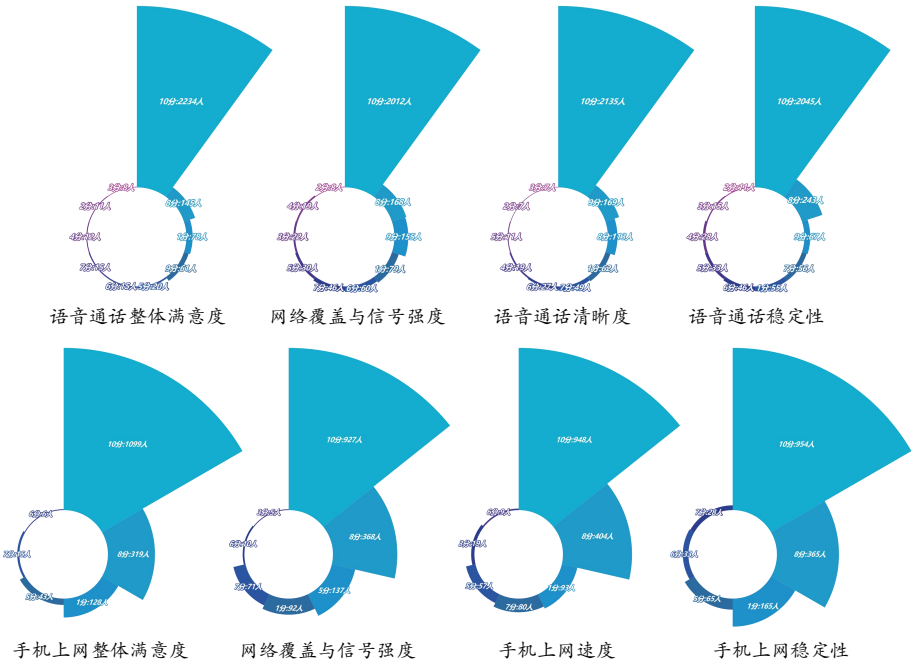


图 26　[附件 3、附件 4] 各类评分人数南丁格尔玫瑰图

对于模型一 [预测语音业务，语音通话整体满意度]，根据表 10，我们可以发现，其五折交叉验证平均准确率为 57.73%，平均绝对误差为 1.2937，均方误差为 6.3877，即平均每位用户评分预测误差控制在 1 分左右，易得均方根误差为 $\sqrt{6.3877} \approx 2.5274$，可以发现，预测值与准确值误差程度在可接受范围内，预测效果较好。而此外，我们知道，对于用户评分，其属于主观性评分，而该评分难以准确量化，给模型带来一定复杂性，即在相近的分数处，较难以区分。此外，对于部分用户，可能存在未详细阅读问卷，导致乱评、错评现象，这一类属于明显异常值，显然，该预测模型可以在一定程度上识别出异常值，且效果良好。同时，我们绘制模型的混淆矩阵热力图、分类报告、ROC/AUC 曲线，从上述分析中，我们有理由认为模型的预测效果较好，但同时也存在一定缺陷，如对小类样本的预测有一定难以区分的现象，而若我们要更多地分析研究小样本用户的情况，这会带来一定的局限性，我们也将在后文提及改进措施。

六、模型的评价与推广

6.1 模型的评价

- **模型的优点：**

1. 对数据进行综合处理，层次清晰，模型具有一定解释性；
2. 数据标准化，避免量纲不一造成的偏向学习影响的情况；
3. 特征筛选，减少不重要性因素占比，减少数据维度，提升模型学习效率，一定程度上避免数据噪声，适当降低模型复杂度，使模型高效化，防止过拟合；
4. 特征构造，由原数据构造出新数据特征，适当增多数据维度，防止欠拟合；
5. 综合熵权法、灰色关联度分析及随机森林量化影响程度，避免局部最优；
6. 对各模型进行参数调优，尽可能提高模型的多方面能力；
7. 加入正则化方法，一定程度上也可防止过拟合；
8. 交叉验证，更好地利用数据集，减少数据浪费，提高模型的泛化能力，验证模型的稳健性，防止过拟合情况的发生；
9. 模型设置任意随机种子，在保证划分训练集及测试集的一般性、随机性的同时，确保可重复性的结果，方便后续处理；
10. 通过主成分分析及随机森林进行特征选择，保证客观性；
11. 多模型 Stacking 集成学习，更好地利用已有数据，多方面学习数据中内在联系，结合多个模型优良方面，避免陷入局部最优，对数据有更好的把控能力，提升模型的泛化能力、提高预测准确率、提高模型稳健性、鲁棒性，同时减小预测误差，且对异常值有一定识别能力。

- **模型的缺点：**

1. 模型对于小样本分类的识别能力较差，难以对这些用户进行深入分析；
2. 模型对于预测主观性评分，难以提供完全一致的评分结果；
3. Stacking 在构造时，有一定复杂度，对基模型的要求较高；
4. 对于部分评分，特征构造出的因素有一定局限性；
5. 用户评分为主观性结果，本文大多模型选用客观性较强的模型进行解决，对数据利用有一定失真。

- **模型的改进：**

1. 在收集数据时，问卷设计需要更加合理化，多方面考虑其余未考虑到的影响因素对用户评分的影响；
2. 在允许条件下获得更多训练样本；
3. 对各模型可以选用非完全一致的特征，提升各模型的独特性，有目的地进行选择，减少学习的数据维度，加快模型收敛速度，使得模型学习高效化，结果准确化；
4. 适当增加或减少数据维度，建立复杂度适中的模型；
5. 对不平衡的多分类，可以采用“下采样”或“上采样”方法，使得分类平衡，但需要更多的数据集；
6. 可适当增加基模型个数，并提高对基模型的筛选要求；
7. 对主观性评分，可以建立主客观相结合的模型，从而优化模型各项指标。

6.2 模型的推广

机器学习可利用现有的数据集进行有目的的训练，在此基础上预测分类标签下人为难以确定的结果，极大方便了当今对复杂数据的处理；多种机器学习相互结合，利用 Stacking 集成学习的方法，可以有效提高模型各方面能力，减少判断错误的情况。针对小部分样本的学习，需要更容易区分类别的特征进行学习，以及利用特征工程等方法进行解决。对于机器学习模型，我们可以作出其可视化图像，观察到模型的各项指标不易发现的问题，如欠拟合、过拟合等情况，我们可以依据模型效果评估可视化来对模型进行一定的调优。本文是以移动用户对业务的评分为基础，我们运用了多种机器学习的模型，再结合 Stacking 进行集成学习，可以发现模型的效果较优，对主观性评分模型有较好把控能力。利用该模型，可以根据用户对某些影响因素的情况，预测用户对于这项业务的满意程度，再结合相关描述性信息，有的放矢地解决用户遇到的问题，提升客户的满意程度，提升产品的服务质量，从而为业务创造更多价值。该模型在一定程度上虽有一定欠缺，但不仅仅可用于该领域的评分，也可用于其余领域，如用户对于某一产品的评价预测，根据用户评价，改善产品质量，提升经济效益，实现双赢。

参考文献

[1] CSDN.【数据预处理】sklearn 实现数据预处理（归一化、标准化）[EB/OL]. https://blog.csdn.net/weixin_44109827/article/details/124786873.

[2] 肖杨, 李亚, 王海瑞, 常梦容. 基于皮尔逊相关系数的滚动轴承混合域特征选择方法 [J]. 化工自动化及仪表,2022,49(03):308-315.DOI:10.20030/j.cnki.1000-3932.202203009.

[3] 王殿武, 赵云斌, 尚丽英, 王凤刚, 张震. 皮尔逊相关系数算法在 B 油田优选化学防砂措施井的应用 [J]. 精细与专用化学品,2022,30(07):26-28.DOI:10.19482/j.cn11-3237.2022.07.07.

[4] 姚文宇, 李杰, 李岩峰, 高娜, 王涛. 基于熵权法的呼吸机质量综合评价研究 [C]//. 中国医学装备大会暨 2022 医学装备展览会论文汇编（下册）.[出版者不详],2022:162-167.DOI:10.26914/c.cnkihy.2022.042155.

[5] 谢赤, 钟赞. 熵权法在银行经营绩效综合评价中的应用 [J]. 中国软科学,2002(09):109-111+108.

[6] 张广海, 董跃蕾. 青岛市旅游业影响因素灰色关联度分析及其发展路径 [J]. 德州学院学报,2022,38(04):54-58.

[7] 饶雷, 冉军, 陶建权, 胡号朋, 吴沁, 熊圣新. 基于随机森林的海上风电机组发电机轴承异常状态监测方法 [J]. 船舶工程,2022,44(S2):27-31.DOI:10.13788/j.cnki.cbgc.2022.S2.06.

[8] 陈振宇, 刘金波, 李晨, 季晓慧, 李大鹏, 黄运豪, 狄方春, 高兴宇, 徐立中. 基于 LSTM 与 XGBoost 组合模型的超短期电力负荷预测 [J]. 电网技术,2020,44(02):614-620.DOI:10.13335/j.1000-3673.pst.2019.1566.

[9] 杨贵军, 徐雪, 赵富强. 基于 XGBoost 算法的用户评分预测模型及应用 [J]. 数据分析与知识发现,2019,3(01):118-126.

[10] Tianqi Chen and Carlos Guestrin. 2016. XGBoost: A Scalable Tree Boosting System. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16). Association for Computing Machinery, New York, NY, USA, 785–794. https://doi.org/10.1145/2939672.2939785.

[11] 傅湘, 纪昌明. 区域水资源承载能力综合评价——主成分分析法的应用 [J]. 长江流域资源与环境,1999(02):168-173.

[12] 张著英, 黄玉龙, 王翰虎. 一个高效的 KNN 分类算法 [J]. 计算机科学,2008(03):170-172.

[13] 汪海燕, 黎建辉, 杨风雷. 支持向量机理论及算法研究综述 [J]. 计算机应用研究,2014,31(05):1281-1286.

[14] 马晓君, 沙靖岚, 牛雪琪. 基于 LightGBM 算法的 P2P 项目信用评级模型的设计及应用 [J]. 数量经济技术经济研究,2018,35(05):144-160.DOI:10.13653/j.cnki.jqte.20180503.001.

[15] 唐敏, 张宇浩, 邓国强. 高效的非交互式隐私保护逻辑回归模型 [J/OL]. 计算机工程:1-11[2023-01-04].DOI:10.19678/j.issn.1000-3428.0065549.

[16] 史佳琪, 张建华. 基于多模型融合 Stacking 集成学习方式的负荷预测方法 [J]. 中国电机工程学报,2019,39(14):4032-4042.DOI:10.13334/j.0258-8013.pcsee.181510.

[17] A.Tharwat, Applied Computing and Informatics (2018). https://doi.org/10.1016/j.aci.2018.08.003.