队伍编号	MCB2201021
赛道	B

基于 SVR 的业务评分预测模型

摘 要

移动通信技术的快速发展为人们带来了便利，同时也使得网络覆盖越来越完善。为了提高客户的网络使用体验，各个移动运营商开始重视客户满意度。本文利用中国移动提供的数据对影响业务评分的主要因素进行了深入分析，并建立了业务评分的预测模型。

在数据预处理部分，我们首先对明显无关属性、重复属性与方差极小的属性进行了剔除处理。对于空值，类别变量我们将其填充为此列的众数；而连续型变量，根据附件 5 说明，我们将其填充为 0。针对类别变量，我们将其进行**标签编码**，以便之后的数据分析。此外，我们根据直觉构造出新的特征属性，如“遇到网络问题场景数”、“遇到网络问题类别数”、“视频网络问题数”等。

针对问题一，本文首先将特征属性分为了两个类：连续型属性和离散型属性。针对连续型属性，本文首先利用**最大信息系数（MIC）**来衡量特征属性与评分之间的线性与非线性相关性，发现所有属性与评分的最大信息系数均小于 0.1，无论是线性关系还是非线性关系均较弱。为了进一步探究，利用**灰色关联分析（GRA）**得到灰色关联系数，发现均小于 0.5。综合 MIC 和灰色关联系数，说明了连续型变量对于评分的影响可以忽略。针对离散型属性，本文首先利用 **Pearson 卡方检验**来衡量属性与评分之间的差异性，之后通过**效应量化分析**，计算 Phi 系数、克莱姆相关系数、列联系数与 Lambda 统计量，发现在语音业务中，有 7 个属性主要影响其评分（表 10），其中，“是否遇到网络问题”对四个评分的影响均为最大；在上网业务中，有 9 个属性主要影响其评分（表 16），“遇到网络问题场景数”和“遇到网络问题类别数”对四个评分的影响均排在前二位。

针对问题二，本文首先结合问题一的分析，将构造的新属性中对评分有主要影响的特征作为新特征加入到问题二的属性中。结合预测数据与现有数据，对属性取交集作为用于预测的特征。在特征工程方面，针对连续型变量，我们首先对它们进行**正态性检验**，计算**偏度**与**峰度**，取偏度绝对值大于 0.5 的属性进行 **box-cox 变换**，之后对所有的连续型属性进行**极差最大值变化**使其无量纲化；针对离散型变量，将无序离散型变量进行**独热编码**处理，而有序离散型变量不做处理。在模型的选择方面，利用 Python 中 sklearn 的便捷性，对线性回归、贝叶斯岭回归、LGBM、SVR、决策树回归、随机森林、XGBoost、GBDT、CatBoost 以及基于 Stacking 的集成模型分别进行了 **10 折交叉验证**，发现 **SVR** 的模型性能要远优于其他模型（表 18），因此本文选择 SVR 作为最后的模型。然后，本文利用**随机搜索**确定 SVR 超参数的最优范围，利用**网格搜索**确定超参数的最终取值。以 3：1 划分训练集和验证集，在验证集上，得到模型在语音业务评分中的 MAE 分别为 1.035、1.163、1.015 和 1.115，在上网业务中的 MAE 分别为 1.433、1.453、1.427 和 1.449。最后，对附件 3、4 的数据进行预测，计算预测评分分布与附件 1、2 中评分分布的 **JS 散度**，得到它们均在 0.03 左右，说明预测分布与真实数据分布相似，预测结果合理。

关键词：中国移动　支持向量回归　相关性分析

目录

一、问题重述.....1
1.1 问题背景.....1
1.2 数据分析.....1
1.3 问题提出.....1
二、问题分析.....1
2.1 问题一的分析.....1
2.2 问题二的分析.....1
三、符号说明.....2
四、数据预处理.....2
4.1 语音业务数据预处理.....2
4.2 上网业务数据预处理.....3
五、问题一模型的建立与求解.....4
5.1 语音业务满意度的主要影响因素.....4
5.2 上网业务满意度的主要影响因素.....10
六、问题二模型的建立与求解.....12
6.1 特征选择与转换.....12
6.2 数据的编码与无量纲化.....14
6.3 模型选择.....15
6.4 支持向量机.....15
6.4 评分预测.....16
6.5 结果合理性分析.....17
七、模型评价.....19
八、参考文献.....20
九、附录.....21

一、 问题重述

1.1 问题背景

移动通信技术的快速发展为人们带来了便利，同时也使得网络覆盖越来越完善。为了提高客户的网络使用体验，各个移动运营商开始重视客户满意度。在信息透明和产品同质化的今天，客户满意度成为运营商市场运营情况的重要体现。为了推动移动网络的高质量可持续发展，各大运营商应该运用数字经济的管理理念和技术手段建立客户体验生态的全方位系统性测评体系，以实现客户满意度的数字化转型，使客户体验成为商业决策的动力。

1.2 数据分析

本题给出了四个附件数据：

附件一提供了语音业务用户满意度数据，附件二提供了上网业务用户满意度数据，附件三是我们需要预测的语音业务用户满意度数据，附件四是我们需要预测的上网业务用户满意度数据。

1.3 问题提出

基于问题背景和附件数据，解决以下问题

问题 1：根据附件一和附件二数据，分别研究影响客户语音业务和上网业务满意度的主要因素，并给出各因素对客户打分影响程度的量化分析和结果。

问题 2：结合问题 1 的分析，对于客户语音业务和上网业务分别建立客户打分基于相关影响因素的数学模型，并对附件三和附件四的数据进行预测并说明预测的合理性。

二、 问题分析

2.1 问题一的分析

问题一要求分别研究影响语音业务和上网业务满意度的主要因素。我们首先根据直觉创建出一些可能对评分有影响的新的属性，比如遇到网络问题场景数、遇到网络问题类别数、视频 app 问题数、生活 app 问题数等等。

然后，将这些数据中的属性分为两个部分：连续型属性和离散型属性。

针对连续型属性，我们可以使用最大信息系数来衡量二者的相关性，不仅可以检测线性关系，也可以检测非线性关系。除此之外，我们利用灰色关联分析更进一步分析属性对评分的影响。综合二者，给出连续型变量中对评分有影响的属性。

针对离散型属性，我们考虑使用 Pearson 卡方检验来衡量二者的差异性。若差异性明显，我们则对它们进行效应量化分析，通过计算 Phi、克莱姆相关系数、列联系数和 Lambda 统计量来挖掘它们具体的关系，从而给出影响评分的主要因素。

2.2 问题二的分析

问题二要求我们结合问题一的分析，对新的数据进行预测。首先我们需要对比现有数据和新数据，对它们的属性取交集，这样才可以运用共有的属性进行预测。

结合问题一构造的新属性，如果它们是影响评分的主要因素，则我们将其加入问题二中用于预测。

在特征工程方面，我们对连续型变量先进行正态性检验，对偏度和峰度绝对值较大的属性进行 boxcox 变换，然后将他们无量纲化处理；对于离散型变量，我们将有序的离散型变量保持

原样，将无序的离散型变量进行编码，使得特征具有稀疏性。

在模型训练方面，可以尝试多个模型，使用交叉验证，根据平均损失和平均损失的方差选择最优模型，之后根据模型的不同，在网格搜索、随机搜索和贝叶斯优化中选择合适的方法对最优模型进行超参数优化，使用优化后的超参数在训练集上训练，最后进行预测。

分析预测结果的合理性可以从两方面着手，一是模型的泛化能力，若模型在验证集上的表现优异，说明模型泛化能力良好，预测结果合理。二是从预测数据分布与现有数据分布的差异着手，可以通过 JS 散度计算预测数据的分布和现有数据的分布，若 JS 散度很小，说明预测结果合理。

三、 符号说明

符号	说明
$mic(x;y)$	随机变量 x 与 y 的最大信息系数
ϵ	支持向量机的容忍偏差
C	支持向量机的惩罚系数
γ	核函数的系数
$KL(P\|\|Q)$	随机变量 P 和 Q 的 KL 散度
$JS(P\|\|Q)$	随机变量 P 和 Q 的 JS 散度

四、 数据预处理

4.1 语音业务数据预处理

4.1.1 剔除明显无关属性

在语音业务数据中，有明显与用户语音通话满意度无关的属性，我们将这些属性直接剔除掉。它们是“是否去过营业厅”、“ARPU”、“当月 ARPU”、“套外流量”、“套外流量费”、“是否实名等级用户”、“客户星级标识”、“当月欠费金额”、“前第 3 个月欠费金额”、“GPRS 总流量”、“GPRS 国内漫游流量”。

4.1.2 剔除重复的属性

数据中，有多组重复属性，如“语音通话时长”、“当月 MOU”和“前 3 月 MOU”这三个属性的数据中，“语音通话时长”与“当月 MOU”数据一样，而与“前 3 月 MOU”数据相关度极高，因此我们只保留“当月 MOU”属性；“终端品牌”和“终端品牌类型”数据所衡量的指标一样，因此只保留“终端品牌”；“4\5G”与“是否 4G 网络客户”与“是否 5G 网络客户”为重复属性，因此只保留“4\5G”属性。

4.1.3 剔除方差极小的属性

数据中，“资费投诉”的只有 2 人，“家宽投诉”的只有 123 人，类别不同比例在整个数据中小于 0.1%，因此剔除这两个属性。

4.1.4 空值处理

剔除以上属性之后，对空值进行填充。根据附件 5 说明，对于“重定向次数”、“重定向驻留时长”、“外省流量占比”这三列属性的空值，填充为 0。“是否关怀用户”的空值填充为“否”。此外，我们剔除用户描述项。

4.1.5 类别数据的转换

我们将“是否遇到网络问题”、“居民小区”、“办公室”、“高校”、“商业街”、“地铁”、“农村”、“高铁”、“其他，请注明”这几列合并为“是否遇到网络问题”一列，其取值方法为：若没有遇到网络问题，则取值为0，若遇到网络问题，则取值为遇到网络问题的地方有多少处。例如只在居民小区、办公室和高校遇到过网络问题，则“是否遇到网络问题”的值为3。

对于“4\5G用户”，我们记2G为0，4G为1，5G为2；对于“终端品牌”，我们记安卓客户端为0，IOS（即苹果）客户端为1；对于语音方式，记“CSFB”为0，“EPSFB”为1，“GSM”为2，“VOLTE”为3，“VONR”为4。其中，在数据文件中，有少量“VOLTE”异常值，记成了“VoLTE”，我们将其修改成了“VOLTE”；对于“是否关怀用户”，记“否”为0，“是”为1。

4.2 上网业务数据预处理

4.2.1 剔除明显无关属性

在上网业务数据中，与评分明显无关的属性有“性别”、“当月MOU”、“近3个月平均消费（剔除通信账户支付）”、“近3个月平均消费（元）”、“本年累计消费（元）”、“码号资源-激活时间”、“码号资源-发卡时间”和“客户星级标识”，对于这些属性列，我们直接剔除。

4.2.2 剔除重复的属性

数据中，明显重复的属性为“操作系统”、“终端品牌”和“终端品牌类型”，在此，我们只保留“终端品牌”；“终端制式”和“是否5G网络客户”为相似属性，我们保留“终端制式”。“畅享套餐档位”和“畅享套餐名称”为相似属性，保留“畅享套餐档位”；“王者荣耀使用次数”、“王者荣耀使用天数”、“游戏类APP使用次数”、“游戏类APP使用天数”为相似属性，仅保留“游戏类APP使用次数”。

4.2.3 剔除方差极小的属性

“终端类型”中，只有17人不是手机，且这17人中有14人为空白，因此，删除此列属性数据。

4.2.4 空值处理

根据附件5的说明，我们将“上网质差次数”、“脱网次数”、“重定向次数”、“2G驻留时长”、“微信质差次数”、“王者荣耀质差次数”的空值全部填充为0。“当月高频通信分公司”属性中，相当大一部分为“不详”和空白，十分影响数据的分析与判断，因此剔除此列属性。

4.2.5 类别数据的转换

对于遇到网络问题的场景，与语音业务数据预处理一样，我们新增一列属性“遇到网络问题场景数”，其值为在“居民小区”、“办公室”、“高校”、“商业街”、“地铁”、“农村”、“高铁”、“其他，请注明”遇到网络问题的场景数量。

对于网络问题总体衡量，我们新增一列属性“遇到网络问题类别数”，其值为在“看视频卡顿”、“打游戏延时大”、“打开网页或APP图片慢”、“下载速度慢”、“手机支付较慢”、“其他，请注明”这些问题中，遇到了几个问题。

对于视频app，我们也新增一列属性“视频网络问题”，表示在多少视频app中遇到过网络问题。其值为0-11，11表示全部视频app都卡顿那一列为99，而其他数字代表在多少视频app中卡顿。

对于游戏app，我们新增一列属性“游戏网络问题”，表示在多少游戏app中遇到过网络问

题。其值为 0-12，12 表示全部游戏 app 都卡顿那一列为 99，其他数字代表在多少游戏 app 中卡顿。

对于生活应用 app，新增属性“生活 app 网络问题”，表示在多少生活应用 app 中遇到过网络问题。其值为 0-10，10 表示全部生活应用 app 都卡顿那一列为 99，其他数字代表在多少生活应用 app 中卡顿。

对于所有的是否类别变量，我们将否设为 0，是设为 1。

对于终端制式，2/3G 终端设为 0，4G 终端设为 1，5G 终端设为 2；对于终端品牌，安卓客户端设为 0，IOS 客户端设为 1。

4.2.6 流量属性的合并

数据中，一共有 22 个属性来表示各种 app 的流量使用情况。在本文中，我们将所有 app 使用流量的情况合并为一列，命名为“使用总流量”，其值为所有 app 使用流量的和。

五、 问题一模型的建立与求解

5.1 语音业务满意度的主要影响因素

5.1.1 连续型属性变量的分析

（1）最大信息系数

最大信息系数（Maximal Information Coefficient）[1]是一种用于衡量两个变量 X 和 Y 之间的关联程度的非参数性探索。相比于 Pearson 相关系数，它不仅适用于线性数据，也能够探索非线性的关联，且对随机变量的先验分布没有要求，具有普适性。此外，它能够在不同类型的噪声下给出相近的系数，鲁棒性强。在本题中，由于不确定各个属性的先验分布，且各个属性与业务满意度的关系不一定是线性的。因此，使用 MIC 来衡量属性与业务满意度的相关性。

步骤一：给定 i、j，对 X、Y 构成的散点图进行 i 列 j 行网格化，并求出最大的互信息值。互信息的计算公式如下：

$$I(x;y)=\int p(x,y)log_2\frac{p(x,y)}{p(x)p(y)}dxdy$$

其中，$p(x,y)$为变量 x 和 y 之间的联合概率分布。

步骤二：对最大的互信息值进行归一化。归一化公式为：

$$I(x;y)=\frac{I(x;y)}{log\big(min(x,y)\big)}$$

步骤三：选择不同尺度下互信息的最大值作为 MIC 值。因此，MIC 计算公式可表示为

$$mic(x;y)=\underset{ab<B}{max}\frac{I(x;y)}{log\big(min(a,b)\big)}$$

其中，a 和 b 是在 x 和 y 方向上划分格子的个数，B 是变量，一般大小设为数据量的 0.6 次方左右。

（2）灰色关联度分析

灰色关联分析是灰色关联度分析（Grey Relation Analysis，GRA），是一种多因素统计分析方法[2]。其基本思想是将评价指标原始观测数进行无量纲化处理，计算关联系数、关联度以及根据关联度的大小对待评指标进行排序。

步骤一：确定比较序列和参考序列。

在本问题中，参考序列为语音通话整体满意度、网络覆盖与信号强度、语音通话清晰度和

语音通话稳定性四列，而比较序列为连续型属性脱网次数、mos 质差次数、未接通掉话次数、重定向次数、重定向驻留时长、外省语音占比、语音通话-时长（分钟）、省际漫游-时长（分钟）和外省流量占比。

步骤二：对指标数据进行量纲一化。为了真实地反映实际情况，排除由于各个指标单位的不同及其数值数量级间的悬殊差别带来的影响，避免不合理现象的发生，需要对指标进行量纲一化处理。在本文中，我们使用极差最大值变换，其公式如下所示：

$$f\big(x(k)\big)=\frac{x(k)-\min\limits_{k}x(k)}{\max\limits_{k}x(k)-\min\limits_{k}x(k)}=y(k)$$

步骤三：计算关联系数，其公式为：

$$\zeta_i(k)=\frac{min_i min_k|x_0(k)-x_i(k)|+\rho\cdot max_i max_k|x_0(k)-x_i(k)|}{|x_0(k)-x_i(k)|+\rho\cdot max_i max_k|x_0(k)-x_i(k)|}$$

其中，ρ为分辨系数，在[0, 1]间取值，分辨系数越小，区分能力越强。

步骤四：计算灰色关联度。分别计算其各个指标与参考序列对应元素的关联系数的加权平均值，以反映各操纵装置对象与参考序列间的关联关系，并称其为关联度，公式为

$$r'_{0i}=\frac{1}{m}\sum_{k=1}^{m}W_k\cdot\zeta_i(k)\,(k=1,\cdots,m)$$

其中W_k为各指标权重。

步骤五：根据灰色关联度的大小，对各个评价对象进行排序，关联度越大评价结果越好。

（3）最大信息系数和灰色关联度的求解与分析

使用 python 求解 MIC 和灰色关联度，得到结果如表 1、2、3、4 所示。

表 1 连续变量属性对语音通话整体满意度的影响

属性	灰色关联度	MIC	属性	灰色关联度	MIC
外省流量占比	0.385	0.044	未接通掉话次数	0.383	0.013
外省语音占比	0.385	0.040	省际漫游-时长（分钟）	0.383	0.042
mos 质差次数	0.384	0.017	脱网次数	0.383	0.029
重定向次数	0.384	0.054	重定向驻留时长	0.383	0.062
语音通话-时长（分钟）	0.383	0.064			

表 2 连续变量属性对网络覆盖与信号强度评分的影响

属性	灰色关联度	MIC	属性	灰色关联度	MIC
外省流量占比	0.397	0.047	未接通掉话次数	0.396	0.013
外省语音占比	0.397	0.038	省际漫游-时长（分钟）	0.396	0.039
mos 质差次数	0.397	0.016	脱网次数	0.395	0.026
重定向次数	0.396	0.056	重定向驻留时长	0.395	0.062
语音通话-时长（分钟）	0.396	0.058			

表 3 连续变量属性对语音通话清晰度评分的影响

属性	灰色关联度	MIC	属性	灰色关联度	MIC
外省流量占比	0.385	0.047	未接通掉话次数	0.383	0.011
外省语音占比	0.385	0.039	省际漫游-时长（分钟）	0.383	0.045
mos 质差次数	0.384	0.016	脱网次数	0.383	0.026
重定向次数	0.384	0.056	重定向驻留时长	0.383	0.062
语音通话-时长（分钟）	0.383	0.059			

表 4 连续变量属性对语音通话稳定性评分的影响

属性	灰色关联度	MIC	属性	灰色关联度	MIC
外省流量占比	0.394	0.047	未接通掉话次数	0.392	0.013
外省语音占比	0.394	0.040	省际漫游-时长（分钟）	0.392	0.036
mos 质差次数	0.393	0.016	脱网次数	0.392	0.028
重定向次数	0.393	0.056	重定向驻留时长	0.392	0.061
语音通话-时长（分钟）	0.392	0.060			

从表 1、2、3、4 可以看出，这些连续变量属性的灰色关联度均小于 0.4，最大信息系数均小于 0.1，说明评分与这些属性基本无关，因此可以认为这些因素对客户语音业务的评分没有影响。

5.1.2 类别属性变量的分析

（1）Pearson 卡方检验

卡方独立性检验[2]是一用途十分广的假设检验（先假设，再推翻假设），常用于检验两个分类变量的相关性。其原理就是统计样本的实际观测值与期望值之间的偏离程度，实际值与期望值的偏离程度决定了卡方值的大小，如果卡方值越大，二者偏差程度越大；反之，二者偏差越小。在本文中，业务评分数据为 1-10 的整数，因此可以看作是 10 分类变量，可以使用 Pearson 卡方分布进行检验。

卡方检验统计量χ^2计算公式为

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{c}\frac{\left(o_{ij}-e_{ij}\right)^2}{e_{ij}}$$

χ^2统计值的自由度为

$$dof = (c-1)*(r-1)$$

其中，r 为行，c 为列，o_i为观察值，e_i为期望值。

我们使用 SPSS 进行 Pearson 卡方检验，得到结果（部分）如表 5 所示。

表 5 语音通话整体满意度卡方检验结果（部分）

属性	类别	语音通话整体满意度										总计	χ^2	P
		1	2	3	4	5	6	7	8	9	10			
是否遇	0	15	3	3	0	14	12	27	122	270	2107	2573		
到过网	1	67	12	21	19	51	66	46	148	190	508	1128		

络问题	2	42	10	15	11	48	33	67	129	172	281	808		
	3	31	7	20	10	27	40	43	93	84	177	532		
	4	17	7	9	8	19	21	20	49	28	62	240		
	5	10	3	1	1	8	5	8	18	12	11	77	1773.119	0.000***
	6	6	0	1	5	3	2	1	7	5	5	35		
	7	14	0	1	1	2	2	2	1	3	5	31		
	8	7	0	0	0	0	1	0	0	0	1	9		
合计		209	42	71	55	172	182	214	567	764	3157	5433		
手机没	-1	65	18	21	24	71	86	109	335	560	2701	3990		
有信号	1	144	24	50	31	101	96	105	232	204	456	1443	815.571	0.000***
合计		209	42	71	55	172	182	214	567	764	3157	5433		

注：***代表 1%的显著性水平

通过卡方检验，得到结论语音通话整体满意度与各个分类属性间均有显著性差异，网络覆盖与信号强度与各个分类属性间均有显著性差异，语音通话清晰度与各个分类属性间均有显著性差异，语音通话稳定性与各个属性间均有显著性差异。

（2）效应量化分析

通过卡方检验，我们发现各个分类属性均与 4 个评分值有显著性差异。为了深入了解业务评分的与分类属性之间的相关联程度，我们进行了效应量指标的计算。

通过卡方检验统计量，我们可以用以下效应量指标来量化分析业务评分与分类属性之间的相关联程度。

- **Phi 系数**

phi 相关系数的大小，表示两样本之间的关联程度。当 phi 系数小于 0.3 时，表示相关较弱；当 phi 系数大于 0.6 时，表示相关较强。计算公式为

$$Phi = \sqrt{\frac{\chi^2}{n}}$$

其中，n 代表样本量。

- **Cramer's V（克莱姆相关系数）**

双变量相关分析的一种方法，专门用于衡量分类数据与分类数据之间相关程度。 该系数取值范围为 0 到 1，0 表示两个变量无关，1 表示完全相关。与 phi 系数作用相似，但 Cramer's V 系数的作用范围较广。计算公式为

$$V = \sqrt{\frac{\chi^2}{mn}}$$

其中，n 代表样本量，m 代表两个变量自由度(r-1)或(c-1)中更小的值。

- **列联系数**

简称 c 系数，主要用于大于 2×2 列联表的情况。当列联表中的两个变量相互独立时，系数 c=0，但它不可能大于 1。c 系数的特点是，其可能的最大值依赖于列联表的行数和列数，且随着 R 和 C 的增大而增大。计算公式为

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

其中，n 代表样本量。

➢ **Lambda 统计量**

一种相关性测量，它反映使用自变量的值来预测因变量的值时，误差成比例缩小。值为 1 表示自变量能完全预测因变量。值等于 0 时表示自变量对于预测因变量不起任何作用。计算公式为

$$\lambda = \frac{\text{每列最高频次之和} - Y\text{边缘和中最高频次}}{n - Y\text{边缘和中最高频次}}$$

其中n为样本量。

本文使用 SPSSPRO 进行效应量化分析，得到结果如表 6、7、8、9 所示。

表 6 语音通话整体满意度与分类变量的效应量化分析结果

属性	Phi	Cramer's V	列联系数	Lambda
是否遇到过网络问题	0.571	0.202	0.496	0.089
手机没有信号	0.387	0.387	0.361	0.112
有信号无法拨通	0.377	0.377	0.353	0.012
通话过程中突然中断	0.378	0.378	0.354	0.075
通话中有杂音、听不清、断断续续	0.391	0.391	0.365	0.111
串线	0.18	0.18	0.177	0.000
通话过程中一方听不见	0.37	0.37	0.347	0.089
其他，请注明.1	0.183	0.183	0.18	0.000
4\5G 用户	0.094	0.067	0.094	0.000
语音方式	0.119	0.06	0.118	0.001
是否关怀用户	0.057	0.057	0.057	0.000
终端品牌	0.208	0.208	0.204	0.071

表 7 网络覆盖与信号强度与分类变量的效应量化分析结果

属性	Phi	Cramer's V	列联系数	Lambda
是否遇到过网络问题	0.614	0.217	0.523	0.089
手机没有信号	0.438	0.438	0.402	0.148
有信号无法拨通	0.388	0.388	0.362	0.018
通话过程中突然中断	0.4	0.4	0.372	0.074
通话中有杂音、听不清、断断续续	0.404	0.404	0.375	0.095
串线	0.184	0.184	0.181	0.000
通话过程中一方听不见	0.402	0.402	0.373	0.066
其他，请注明.1	0.193	0.193	0.189	0.000
4\5G 用户	0.075	0.053	0.075	0.000
语音方式	0.1	0.05	0.099	0.002
是否关怀用户	0.063	0.063	0.063	0.000
终端品牌	0.228	0.228	0.222	0.088

表 8 语音通话清晰度与分类变量的效应量化分析结果

属性	Phi	Cramer's V	列联系数	Lambda
是否遇到过网络问题	0.586	0.207	0.505	0.085
手机没有信号	0.392	0.392	0.365	0.098
有信号无法拨通	0.372	0.372	0.349	0.017

通话过程中突然中断	0.38	0.38	0.355	0.058
通话中有杂音、听不清、断断续续	0.425	0.425	0.391	0.146
串线	0.182	0.182	0.179	0.000
通话过程中一方听不见	0.378	0.378	0.354	0.069
其他，请注明.1	0.191	0.191	0.187	0.000
4\5G 用户	0.091	0.064	0.091	0.000
语音方式	0.116	0.058	0.116	0.001
是否关怀用户	0.051	0.051	0.051	0.000
终端品牌	0.2	0.2	0.196	0.07

表 9 语音通话稳定性与分类变量的效应量化分析结果

属性	Phi	Cramer's V	列联系数	Lambda
是否遇到过网络问题	0.629	0.222	0.532	0.107
手机没有信号	0.41	0.41	0.379	0.122
有信号无法拨通	0.385	0.385	0.36	0.027
通话过程中突然中断	0.443	0.443	0.405	0.125
通话中有杂音、听不清、断断续续	0.424	0.424	0.39	0.132
串线	0.183	0.183	0.18	0.000
通话过程中一方听不见	0.421	0.421	0.388	0.087
其他，请注明.1	0.204	0.204	0.2	0.000
4\5G 用户	0.078	0.055	0.078	0.000
语音方式	0.113	0.056	0.112	0.004
是否关怀用户	0.057	0.057	0.057	0.000
终端品牌	0.2	0.2	0.196	0.074

当 phi 系数小于 0.3 时，表明相关较弱；而 phi 系数大于 0.6 时，表示相关较强。结合克莱姆相关系数、列联系数和 Lambda 系数，可以得出：

对于语音通话整体满意度，主要影响因素从高到低为“是否遇到网络问题”、“通话中有杂音、听不清、断断续续”、“手机没有信号”、“通话过程中突然中断”、“通话过程中一方听不见”、“有信号无法拨通”和“终端品牌”。

对于网络覆盖与信号强度评分，主要影响因素从高到低为“是否遇到网络问题”、“手机没有信号”、“通话中有杂音、听不清、断断续续”、“通话过程中突然中断”、“通话过程中一方听不见”、“有信号无法拨通”和“终端品牌”。

对于语音通话清晰度评分，主要影响因素从高到低为“是否遇到网络问题”、“通话中有杂音、听不清、断断续续”、“手机没有信号”、“通话过程中突然中断”、“通话过程中一方听不见”、“有信号无法拨通”和“终端品牌”。

对于语音通话稳定性评分，主要影响因素从高到低为“是否遇到网络问题”、“通话过程中突然中断”、“通话中有杂音、听不清、断断续续”、“手机没有信号”、 “通话过程中一方听不见”、“有信号无法拨通”和“终端品牌”。

5.1.3 语音业务满意度主要影响因素总结

通过对连续型变量和离散型变量属性与四个评分的相关度量化分析，得到连续型变量中，所有属性与评分基本无关，而在类别属性中，有 7 个属性与评分有一定关联。最终可以得到如表 10 所示的结果。

表 10 语音业务满意度主要影响因素

影响度排名	语音通话整体满意度	网络覆盖与信号强度	语音通话清晰度	语音通话稳定性
1	是否遇到网络问题	是否遇到网络问题	是否遇到网络问题	是否遇到网络问题
2	通话中有杂音、听不清、断断续续	手机没有信号	通话中有杂音、听不清、断断续续	通话过程中突然中断
3	手机没有信号	通话中有杂音、听不清、断断续续	手机没有信号	通话中有杂音、听不清、断断续续
4	通话过程中突然中断	通话过程中突然中断	通话过程中突然中断	手机没有信号
5	通话过程中一方听不见	通话过程中一方听不见	通话过程中一方听不见	通话过程中一方听不见
6	有信号无法拨通	有信号无法拨通	有信号无法拨通	有信号无法拨通
7	终端品牌	终端品牌	终端品牌	终端品牌

5.2 上网业务满意度主要影响因素

5.2.1 连续型属性变量的分析

与语音业务一样，我们仍然采用最大信息系数和灰色关联度来衡量上网业务评分与连续性属性变量之间的关联度。得到的结果如表 10、11、12、13 所示。

表 11 连续变量属性对手机上网整体满意度的影响

属性	灰色关联度	MIC	属性	灰色关联度	MIC
年龄	0.437	0.061	王者荣耀质差次数	0.419	0.012
当月 GPRS 资源使用量（GB）	0.42	0.077	2G 驻留时长	0.418	0.166
畅享套餐档位	0.42	0.011	脱网次数	0.418	0.053
重定向次数	0.418	0.164	上网质差次数	0.418	0.008
使用总流量（分钟）	0.419	0.071	游戏类 APP 使用次数	0.418	0.054
套外流量费（元）	0.418	0.027	微信质差次数	0.418	0.001
套外流量（MB）	0.418	0.037	主套餐档位	0.422	0.021

表 12 连续变量属性对网络覆盖与信号强度评分的影响

属性	灰色关联度	MIC	属性	灰色关联度	MIC
年龄	0.442	0.061	王者荣耀质差次数	0.424	0.012
当月 GPRS 资源使用量（GB）	0.426	0.077	2G 驻留时长	0.424	0.159
畅享套餐档位	0.425	0.012	脱网次数	0.423	0.061
重定向次数	0.424	0.178	上网质差次数	0.423	0.008
使用总流量（分钟）	0.424	0.065	游戏类 APP 使用次数	0.424	0.055
套外流量费（元）	0.423	0.027	微信质差次数	0.423	0.011
套外流量（MB）	0.423	0.037	主套餐档位	0.428	0.020

表 13 连续变量属性对手机上网速度评分的影响

属性	灰色关联度	MIC	属性	灰色关联度	MIC
年龄	0.441	0.051	王者荣耀质差次数	0.423	0.012
当月 GPRS 资源使用量（GB）	0.425	0.073	2G 驻留时长	0.423	0.174
畅享套餐档位	0.424	0.013	脱网次数	0.422	0.059
重定向次数	0.423	0.192	上网质差次数	0.422	0.008
使用总流量（分钟）	0.423	0.066	游戏类 APP 使用次数	0.423	0.054

套外流量费（元）	0.423	0.029	微信质差次数	0.422	0.009
套外流量（MB）	0.422	0.038	主套餐档位	0.427	0.021

表 14 连续变量属性对手机上网稳定性评分的影响

属性	灰色关联度	MIC	属性	灰色关联度	MIC
年龄	0.447	0.062	王者荣耀质差次数	0.428	0.015
当月 GPRS 资源使用量（GB）	0.43	0.074	2G 驻留时长	0.428	0.159
畅享套餐档位	0.429	0.013	脱网次数	0.427	0.057
重定向次数	0.427	0.179	上网质差次数	0.427	0.008
使用总流量（分钟）	0.428	0.070	游戏类 APP 使用次数	0.428	0.055
套外流量费（元）	0.427	0.029	微信质差次数	0.427	0.009
套外流量（MB）	0.427	0.038	主套餐档位	0.432	0.022

通过上面四张表可以看出，灰色关联度均小于 0.5，可以认为关联度很小，再结合最大信息系数，所有属性均小于 0.2，说明不管是线性还是非线性关联程度，这些属性对评分的影响都可以忽略不计。

5.2.2 类别属性变量的分析

与语音业务数据分析类似，我们进行卡方检验，再进行效应量化分析。得到结果如表 15 所示。这里仅展示手机上网整体满意度的结果表格，其余三个评分的效应量化分析见附录。卡方检验结果的表格也见附录。

表 15 手机上网整体满意度与分类变量的效应量化分析结果

属性	Phi	Cramer’s V	列联系数	Lambda
遇到网络问题场景数	0.603	0.213	0.516	0.122
遇到网络问题类别数	0.481	0.197	0.434	0.000
视频网络问题	0.403	0.134	0.374	0.000
游戏网络问题	0.327	0.109	0.311	0.000
生活 app 网络问题	0.438	0.146	0.401	0.000
网络信号差/没有信号	0.445	0.445	0.406	0.338
显示有信号上不了网	0.38	0.38	0.355	0.081
上网过程中网络时断时续或时快时慢	0.412	0.412	0.381	0.225
手机上网速度慢	0.417	0.417	0.385	0.171
其他，请注明.1	0.119	0.119	0.118	0.000
终端制式	0.048	0.034	0.048	0.000
终端品牌	0.197	0.197	0.193	0.029
是否校园套餐用户	0.067	0.067	0.066	0.000
校园卡无校园合约用户	0.049	0.049	0.049	0.000
校园卡校园合约捆绑用户	0.06	0.06	0.059	0.000
高单价超套客户（集团）	0.074	0.074	0.074	0.000
高频高额超套客户（集团）	0.037	0.037	0.037	0.000
是否全月漫游用户	0.098	0.098	0.098	0.000
是否不限量套餐到达用户	0.062	0.062	0.061	0.000

Phi 小于 0.3 表示相关度较弱，大于 0.6 表示相关度较强。因此我们保留所有 phi 大于 0.3 的属性，并根据克莱姆相关系数、列联系数与 Lambda 统计量，得到如下结果：

对于手机上网整体满意度，主要影响因素由高到低排序为遇到网络问题场景数、遇到网络问题类别数、网络信号差/没有信号、生活 app 网络问题、手机上网速度慢、上网过程中网络时断时续或时快时慢、视频网络问题、显示有信号上不了网、游戏网络问题。

对于网络覆盖与信号强度评分，主要因素由高到低排序为遇到网络问题场景数、遇到网络问题类别数、网络信号差/没有信号、生活 app 网络问题、手机上网速度慢、上网过程中网络时断时续或时快时慢、视频网络问题、显示有信号上不了网、游戏网络问题。

对于手机上网速度评分，主要因素由高到低排序为遇到网络问题场景数、遇到网络问题类别数、生活 app 网络问题、网络信号差/没有信号、手机上网速度慢、视频网络问题、上网过程中网络时断时续或时快时慢、显示有信号上不了网、游戏网络问题。

对于手机上网稳定性评分，主要因素由高到低排序为遇到网络问题场景数、遇到网络问题类别数、网络信号差/没有信号、上网过程中网络时断时续或时快时慢、生活 app 网络问题、手机上网速度慢、视频网络问题、显示有信号上不了网、游戏网络问题。

5.2.3 上网业务满意度主要影响因素总结

通过对连续型变量和离散型变量属性与四个评分的相关度量化分析，得到连续型变量中，所有属性与评分基本无关，而在类别属性中，有 9 个属性与评分有一定关联。最终可以得到如表 16 所示的结果。

表 16 上网业务满意度主要影响因素

影响度排名	手机上网整体满意度	网络覆盖与信号强度	手机上网速度	手机上网稳定性
1	遇到网络问题场景数	遇到网络问题场景数	遇到网络问题场景数	遇到网络问题场景数
2	遇到网络问题类别数	遇到网络问题类别数	遇到网络问题类别数	遇到网络问题类别数
3	网络信号差/没有信号	网络信号差/没有信号	生活 app 网络问题	网络信号差/没有信号
4	生活 app 网络问题	生活 app 网络问题	网络信号差/没有信号	上网过程中网络时断时续或时快时慢
5	手机上网速度慢	手机上网速度慢	手机上网速度慢	生活 app 网络问题
6	上网过程中网络时断时续或时快时慢	上网过程中网络时断时续或时快时慢	视频网络问题	手机上网速度慢
7	视频网络问题	视频网络问题	上网过程中网络时断时续或时快时慢	视频网络问题
8	显示有信号上不了网	显示有信号上不了网	显示有信号上不了网	显示有信号上不了网
9	游戏网络问题	游戏网络问题	游戏网络问题	游戏网络问题

六、 问题二模型的建立与求解

6.1 特征选择与转换

6.1.1 基本特征选择

在对比了有标签数据和预测数据后，我们首先选取了两者共有的特征作为基本特征。由于机器学习模型强大的非线性拟合能力，以及 python 中 sklearn 库调用的方便，本文在进行初步模型训练时不会进行特征的删除，为了更好的效果，会将所有的特征都保留。

6.1.2 构造新的特征

除了数据集中本有的特征，本文结合了问题一中的分析，构造出了新特征。在语音业务数据中，新特征为“遇到网络问题场景数”，在上网业务中，构造出了“遇到网络问题场景数”、“遇到网络问题类别数”、“视频网络问题”、“游戏网络问题”、“生活 app 网络问题”。

6.1.3 连续型特征的转换

（1）正态性检测

在机器学习中，尤其是回归预测中，模型学习涉及到联合分布概率与参数距离的概念。当数据越接近正态分布，训练效果也会越好。因此我们利用偏度和峰度来衡量一个随机变量的正态性。

- **偏度[5]**

偏度是统计数据分布偏斜方向和程度的度量，是统计数据分布非对称程度的数字特征。正态分布的偏度为 0，两侧尾部长度对称。偏度小于 0 称分布具有负偏离，也称左偏态，此时数据位于均值左边的比位于右边的少，直观表现为左边的尾部相对于与右边的尾部要长；偏度大于 0 称分布具有正偏离，也称右偏态，此时数据位于均值右边的比位于左边的少。计算公式为

$$S(X) = E\left[\left(\frac{X-\mu}{\sigma}\right)^3\right]$$

- **峰度[6]**

峰度与偏度类似，是描述总体中所有取值分布形态陡缓程度的统计量。这个统计量需要与正态分布相比较，峰度为 0 表示该总体数据分布与正态分布的陡缓程度相同；峰度大于 0 表示该总体数据分布与正态分布相比较为陡峭，为尖顶峰；峰度小于 0 表示该总体数据分布与正态分布相比较为平坦，为平顶峰。峰度的绝对值数值越大表示其分布形态的陡缓程度与正态分布的差异程度越大。计算公式为

$$K(X) = E\left[\left(\frac{X-\mu}{\sigma}\right)^4\right]$$

我们对连续型变量进行偏度峰度检测，得到结果（部分）如表 17 所示。

表 17 部分属性的峰度和偏度检测

属性	偏度	峰度
GPRS 总流量（KB）	36.507477	2062.604848
前 3 月 MOU	22.327473	1012.864424
套外流量（MB）	18.941265	442.899061
语音通话-时长（分钟）	18.444620	722.913492
当月 MOU	18.444620	722.913492
脱网次数	16.142124	442.146047

（2）box-cox 变换

Box-Cox 变换是 Box 和 Cox 在 1964 年提出的一种广义幂变换方法[3]，是统计建模中常用的一种数据变换，用于连续的响应变量不满足正态分布的情况。Box-Cox 变换之后，可以一定程度上减小不可观测的误差和预测变量的相关性。其公式为

$$y=\begin{cases}\dfrac{y^{\lambda}-1}{\lambda},\lambda\neq 0\\ log(y),\lambda=0\end{cases}$$

我们利用 python 中的 boxcox_normmax 寻找最佳变化参数λ，boxcox1p 完成 box-cox 变换。图 1 展示了属性“前三月 MOU”变化前后的 q-q 图和概率分布图。

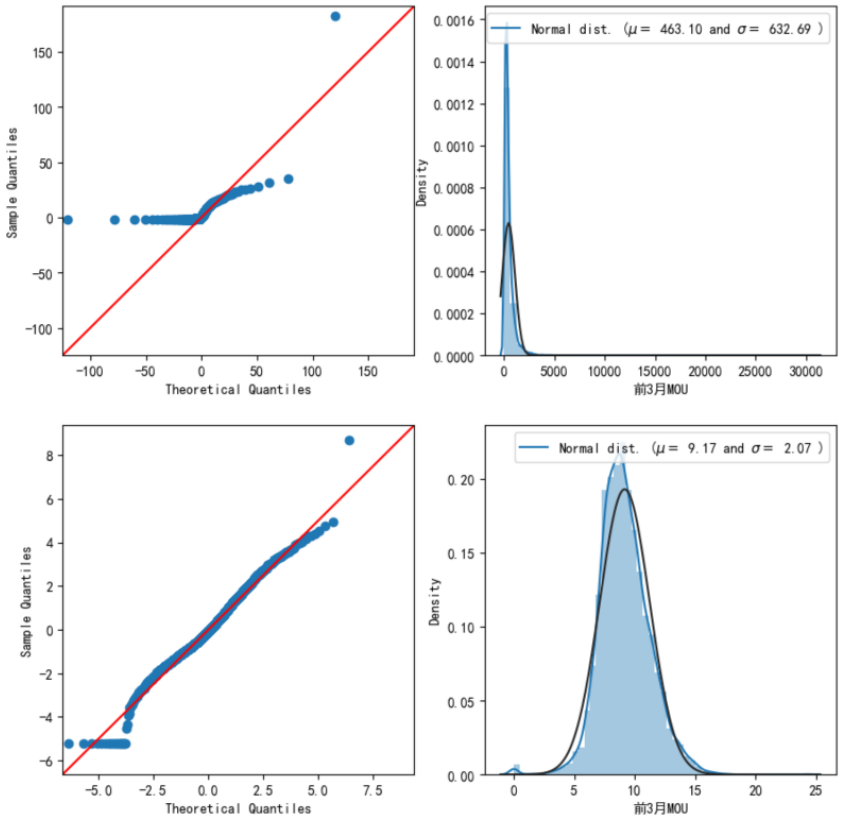


图 1 属性“前三月 MOU”boxcox 变换前后变化

6.2 数据的编码与无量纲化

6.2.1 类别数据编码

我们利用在问题一中得到的主要影响因素对评分进行预测。在回归、分类等问题中，特征之间的距离计算是非常重要的。使用独热编码（One-Hot Encoding），将离散特征的取值扩展到了欧式空间，离散特征的某个取值就对应欧式空间的某个点。将离散型特征使用独热编码，会让特征之间的距离计算更加合理。

独热编码的方法是使用 N 位状态寄存器来对 N 个状态进行编码，每个状态都有它独立的寄存器位，并且在任意时候，其中只有一位有效。即只有一位是 1，其余都是零值。

在本问题中，我们将无序类别变量进行独热编码。语音业务中，需要进行独热编码的属性有“通话中有杂音、听不清、断断续续”、“手机没有信号”、“通话过程中突然中断”、“通话过程中一方听不见”、“有信号无法拨通”和“终端品牌”，而“是否遇到网络问题”则不需要进行独热编码，因为它是有序变量，进行独热编码会丢失顺序信息。在上网业务中，需要进行独热编码属性有“网络信号差/没有信号”、“手机上网慢”、“上网过程中网络时断时续或时快时慢”、“显示有信号上不了网”，同样，“遇到网络问题场景数”、“遇到网络问题类别数”、“生活 app 网络问题”、“视频网络问题”和“游戏网络问题”不需要进行独热编码。

6.2.2 连续型数据无量纲化

我们对所有连续型变量进行如下变化：

$$f\big(x(k)\big)=\frac{x(k)-\min\limits_{k}x(k)}{\max\limits_{k}x(k)-\min\limits_{k}x(k)}$$

6.3 模型确定

由于 Python 中 sklearn 库的方便性，为了使得结果更加精准，我们尝试了多了个模型。每个模型进行 10 折交叉验证，以平均绝对误差为标准，衡量模型对数据的拟合能力。得到结果如表 18 所示（仅展示了语音业务中语音业务总体满意度的拟合情况）

表 18 语音业务总体满意度不同模型性能

算法模型	平均 MAE	MAE 标准差
Linear Regression	1.226187	0.082170
Bayesian Ridge Regression	1.224447	0.080963
LGBM	1.260875	0.075859
SVR	1.105737	0.094664
Decision Tree	1.605327	0.125768
Random Forest	1.296966	0.070631
XGBoost	1.325997	0.066610
GBDT	1.233793	0.068325
CatBoost	1.245236	0.066935
Stacked	1.353874	0.066644

从表格中容易看出，SVR 的性能好远远好于其他模型（对于其他评分的结果也是最优的）。因此本文选择 SVR 模型进行最终的训练与拟合。

6.4 支持向量回归

支持向量回归(Support Vector Regression, SVR)是一种基于支持向量机的回归算法[2]。SVR 的基本思想是在数据的边界处建立一个最大间隔的平面，使得数据点到平面的距离最小。

对于 SVR 预测函数

$$f(x)=\omega^{T}x+b$$

则我们要最小化数据点到平面的距离，SVR 的问题可以转换为

$$\min_{\omega,b}\frac{1}{2}\big|\big|\omega\big|\big|^{2}+C\sum_{i=1}^{m}l_{\epsilon}\big(f(x_i),y_i\big)$$

其中，C 为正则化常数，l_{ϵ}为ϵ-不敏感损失函数，表达式为

$$l_{\epsilon}=\begin{cases}0\quad, & |z|<\epsilon\\ |z|-\epsilon, & |z|\geq\epsilon\end{cases}$$

更进一步，引入松弛变量ξ_i和η_i容忍误差，这样就可以解决非线性和异常值问题。则新的优化问题为

$$\min_{\omega,b,\xi_i,\eta_i}\frac{1}{2}\big|\big|\omega\big|\big|^{2}+C\sum_{i=1}^{m}(\xi_i+\eta_i)$$

$$s.t\begin{cases} f(x_i)-y_i \le \epsilon+\xi_i, \\ y_i-f(x_i) \le \epsilon+\eta_i, \\ \xi_i \ge 0, \eta_i \ge 0, \quad i=1,2,\dots,N \end{cases}$$

我们通过拉格朗日乘子法来将上述有约束的优化问题变成无约束问题，拉格朗日函数为 $L(\omega,b,\alpha,\beta,\xi,\eta,\mu,\nu)$

$$=\frac{1}{2}||\omega||^2+C\sum_{i=2}^{N}(\xi_i+\eta_i)-\sum_{i=1}^{N}\mu_i\xi_i-\sum_{i=1}^{N}\nu_i\eta_i+\sum_{i=1}^{N}\alpha_i(f(y_i)-x_i-\epsilon-\xi_i)$$

$$+\sum_{i=1}^{N}\beta_i(f(y_i)-x_i-\epsilon-\eta_i)$$

令$L(\omega,b,\alpha,\beta,\xi,\eta,\mu,\nu)$对$\omega,b,\xi,\eta$的偏导数为 0，可以得到

$$\omega^*=\sum_{i=1}^{N}(\beta_i^*-\alpha_i^*)x_i$$

则 SVR 的解形如

$$f(x)=\sum_{i=1}^{N}(\beta_i^*-\alpha_i^*)x_i^Tx+b$$

在本问题中，我们考虑使用核函数，将样本映射到更高维空间，使得线性可分。我们选择高斯核函数，其形式为

$$k(x_i,x_j)=e^{-\frac{||x_i-x_j||^2}{2\sigma^2}}$$

所以最终 SVR 的表达式为

$$f(x)=\sum_{i=1}^{N}(\beta_i^*-\alpha_i^*)k(x_i^Tx)+b$$

6.5 评分预测

6.5.1 超参数优化

由于支持向量回归的超参数比较少，因此本文选择简单的网格搜索和随机搜索进行超参数的优化。本文首先利用随机搜索确定超参数的大致范围，之后利用网格搜索对超参数进行进一步的优化。

我们优化的参数有三个：C，即支持向量回归中的惩罚系数；ϵ，容忍偏差；γ，核函数的系数。

利用 Python 中 sklearn 的库函数 GridSearchCV 和 RandomSearchCV，使用交叉验证，得到最终参数，我们得到的结果如表所示。

表 19 超参数选择结果

预测变量	ϵ	C	γ
语音通话整体满意度	0.3	2.1	0.1
网络覆盖与信号强度（语音业务）	0.4	1.5	0.1
语音通话清晰度	0.4	1.5	0.1
语音通话稳定性	0.2	1.5	0.11

手机上网整体满意度	0.1	1	0.01
网络覆盖与信号强度（上网业务）	0.1	2.1	0.009
手机上网速度	0.2	1	0.01
手机上网稳定性	0.4	2.2	0.01

6.5.2 预测结果

我们将数据集以 3：1 的比例划分为训练集和验证集，利用 Python 中的 sklearn 库中的 SVR 对数据进行拟合。预测结果（部分）如表展示。完整数据见结果文件 result.xlsx。

表 20 语音业务预测结果（部分）

用户 id	语音通话整体满意度	网络覆盖与信号强度	语音通话清晰度	语音通话稳定性
1	10	10	10	10
2	10	10	9	10
3	10	9	10	10
4	9	9	9	9
5	8	7	8	8
6	6	5	6	6

表 21 上网业务预测结果（部分）

用户 id	手机上网整体满意度	网络覆盖与信号强度	手机上网速度	手机上网稳定性
1	8	8	7	7
2	9	9	9	9
3	10	10	10	10
4	10	10	10	9
5	6	6	6	6
6	10	10	10	10

6.6 结果合理性分析

6.6.1 模型泛化能力

本文以平均绝对误差来衡量模型的能力，其公式如下：

$$loss = \frac{1}{n}\sum_{i=1}^{n} \left|y_{pred} - y_{true}\right|$$

在验证集中，我们得到的结果如表 22 所示。

表 22 模型在验证集的表现

语音业务	MAE	上网业务	MAE
语音通话整体满意度	1.035	手机上网整体满意度	1.433
网络覆盖与信号强度	1.163	网络覆盖与信号强度	1.453
语音通话清晰度	1.015	手机上网速度	1.427
语音通话稳定性	1.115	手机上网稳定性	1.449

通过表 22 得到，语音业务预测评分平均绝对误差在 1.05 附近，上网业务预测评分平均绝对误差在 1.42 左右。说明预测结果可信。

6.6.2 有标签数据分布与预测数据分布的相似性

如果预测出来的数据是合理的，那么预测结果所服从的分布一定会与有标签数据的分布是类似的。因此，为了说明预测结果的合理性，我们使用 JS 散度[4]来衡量它们是否相似。

JS 散度度量了两个概率分布的相似度，基于 KL 散度的变体，解决了 KL 散度非对称的问题。一般地，JS 散度是对称的，其取值是 0 到 1 之间。其中 KL 散度的计算公式为

$$KL(P||Q) = \sum p_i(x)\, log \frac{p_i(x)}{q_i(x)}$$

由于 KL 散度是不对称的，即$KL(P||Q)$与$KL(Q||P)$结果不一定相同，因此我们使用了对称的 JS 散度来衡量相似性，其计算公式为

$$JS(P_1||P_2) = \frac{1}{2}KL\left(P_1||\frac{P_1+P_2}{2}\right) + \frac{1}{2}KL\left(P_2||\frac{P_1+P_2}{2}\right)$$

我们计算了有标签数据和预测数据的 JS 散度，得到的结果如图 2、3 所示。

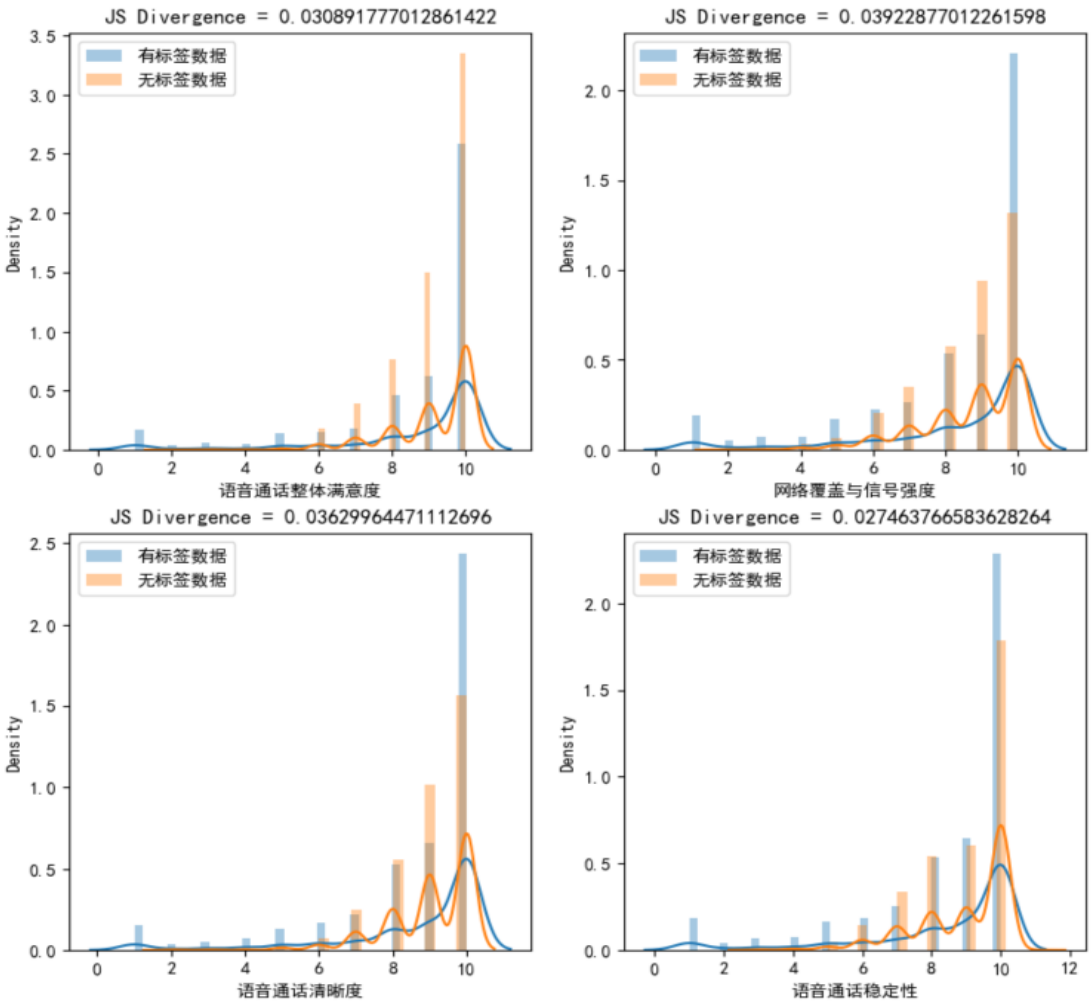


图 2 语音业务分布相似度

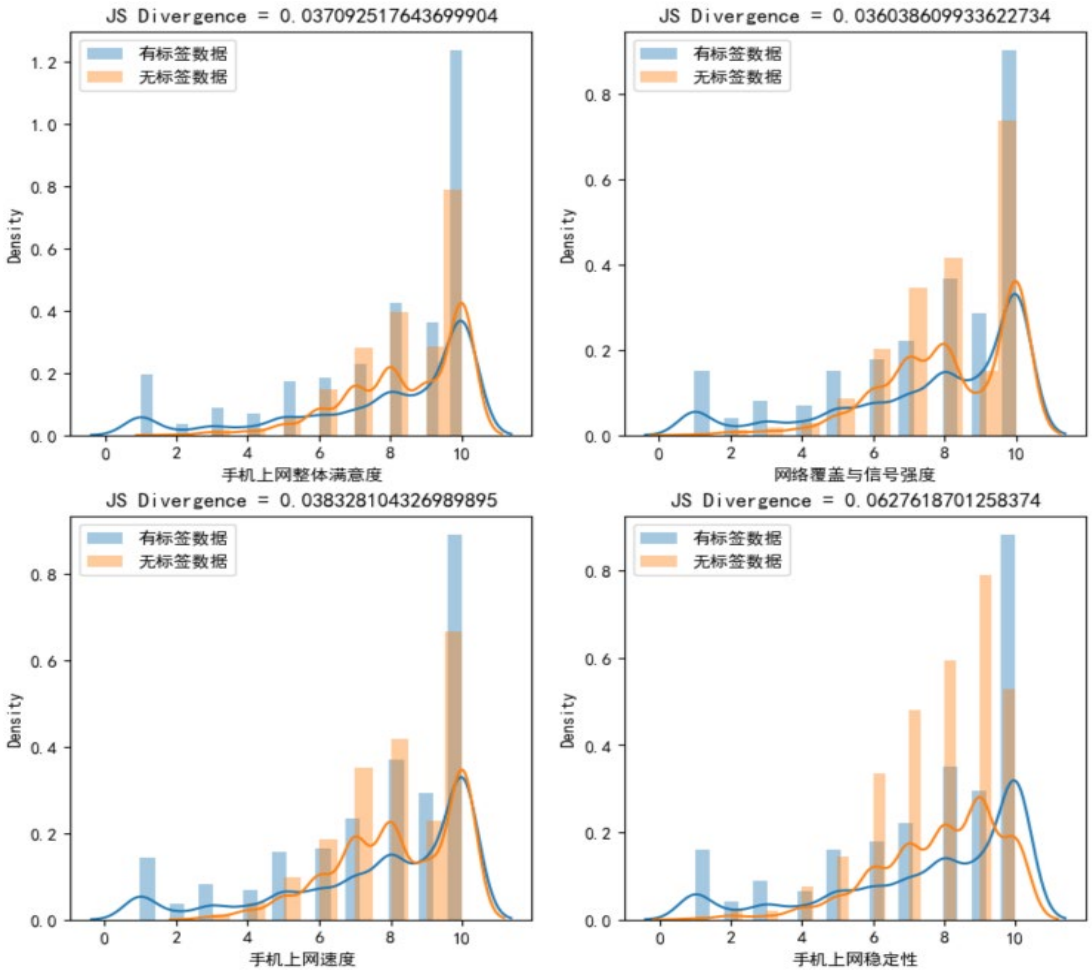


图 3 语音业务分布相似度

通过图 2、3 看出，JS 散度都很小，这表明了预测的分布与有标签的数据分布近似，说明了我们结果具有一定的合理性。

七、 模型评价

7.1 模型优点

- 通过多种指标对评分的主要影响因素进行衡量，既考虑了线性因素，也考虑了非线性因素。
- 通过对特征的变换以及构造新的特征增强了模型的泛化能力。

7.2 模型缺点

- 对评分为 1 的数据预测表现较差。

7.3 模型推广

- 适用于任何特征特别多的回归任务。
- 可以针对每个变量做出更细致的分析。

八、 参考文献

[1] Reshef, D. N.; Reshef, Y. A.; Finucane, H. K.; Grossman, S. R.; McVean, G.; Turnbaugh, P. J.; Lander, E. S.; Mitzenmacher, M.; Sabeti, P. C. (2011). "Detecting novel associations in large data sets". Science. 334 (6062): 1518–1524.

[2]司守奎，Python 数学实验与建模，北京：科学出版社，2020：146，268，524-526.

[3] Box, George E. P.; Cox, D. R. (1964). "An analysis of transformations". Journal of the Royal Statistical Society, Series B. 26 (2): 211–252.

[4] Frank Nielsen (2021). "On a variational definition for the Jensen-Shannon symmetrization of distances based on the information radius". Entropy. MDPI. 23 (4): 464.

[5] Illowsky, Barbara; Dean, Susan (27 March 2020). "2.6 Skewness and the Mean, Median, and Mode - Statistics". OpenStax. Retrieved 21 December 2022.

[6] Westfall, Peter H. (2014), "Kurtosis as Peakedness, 1905 - 2014. R.I.P.", The American Statistician, 68 (3): 191–195.