队伍编号	MCB2202628
赛道	B

基于机器学习的北京移动用户满意度分析

摘 要

本文基于北京移动用户数据进行用户满意度分析，主要研究两方面的问题，一是量化分析用户满意度影响因素的重要性，寻找重要影响因素；二是在考虑变量重要性基础上建立预测模型，对用户满意度评分进行预测。

文章主要包含三大部分。**第一部分主要为数据预处理和探索性分析**，首先对数据进行变量筛选和剔除、缺失值和异常值处理、类别变量编码等，在尽量不损失信息的前提下简化特征；其次，在此基础上进行数据探索性分析，通过统计用户评分分布情况以及相关性分析等初步探究数据特征。

第二部分为影响因素重要性量化分析，采用随机森林进行特征重要性评估。结果显示，对语音业务四个方面打分而言，最重要的前三个变量均为：GPRS 总流量（>11%）、前三个月 MOU（>10%）、当月 ARPU（>10%）；而同一变量对上网数据四个方面打分影响程度略有不同，但从总体来看，重要变量为：年龄、当月 GPRS 资源使用量（GB）、当月 MOU，重要性均>6%。在此基础上，我们对重要性排序靠前的部分变量进行了深入分析，通过直方图直观对比不同评分下该变量的分布情况，并基于此对北京移动公司提出建议。

第三部分为用户满意度预测，首先进行特征选取，对于语音业务数据在考虑变量重要性的基础上，仅将预处理后的附件 1 和附件 3 共同含有的变量作为模型学习的特征，对上网业务数据做相同的处理；其次，针对两个数据集共 8 个方面的评分分别构建预测模型，选取决策树、随机森林、Light-GBM 三个机器学习模型，采用 10 折交叉验证法划分训练集和测试集，并通过网格搜索寻找最优参数，基于附件 1 和附件 2 数据训练模型并测试模型性能；最后，考虑满意度评分为定比数据，以 MSE 为模型评价指标，选取最优模型进行附件 2 和附件 4 的预测，并输出结果文件。

本文最后，综合所有分析结果，对北京移动公司就如何提升用户满意度提出部分建议，竭力提升北京移动的用户满意度，让企业在 5G 时代下争取到更多市场份额。

关键词：用户分析；机器学习；满意度预测；网格搜索寻优

目录

第一章 问题重述 1

1.1 问题背景 1

1.2 研究问题 1

第二章 问题分析 2

2.1 针对问题一的分析 2

2.2 针对问题二的分析 2

第三章 数据探索性分析 3

3.1 数据预处理 3

3.1.1 变量的筛选与剔除 3

3.1.2 缺失值、异常值处理 4

3.1.3 类别变量编码 5

3.1.4 小结 5

3.2 用户满意度评分分布情况 6

3.3 变量相关性分析 8

第四章 用户分析之满意度影响因素分析 13

4.1 特征选择方法简介——随机森林 13

4.2 语音业务满意度影响因素分析 14

4.2.1 变量重要性量化分析 14

4.2.2 部分重要变量分析 15

4.3 上网业务满意度影响因素分析 17

4.3.1 变量重要性量化分析 17

4.3.2 部分重要变量分析 18

第五章 用户分析之满意度预测 21

5.1 分类方法简介 21

5.1.1 决策树 21

5.1.2 随机森林 21

5.1.3 Light-GBM 22

5.1.4 交叉验证 22

5.1.5 网格搜索 23

5.2 建立预测模型 23

5.3 结果分析与模型评价 24

5.3.1 评价指标 24

5.3.2 模型评价和结果展示 24

5.3.3 结果的比较性分析 25

第六章 建议 27

参考文献 29

附录 30

第一章 问题重述

1.1 问题背景

移动通信技术迅猛发展，网络覆盖愈加完善，人们越来越离不开移动通信技术带来的各种便捷。移动运营商越来越重视客户的网络使用体验，以此提升网络服务质量。客户满意度即客户对运营商产品服务的满意程度，反映了客户期望与实际感知的产品服务之间的差异，是各大运营商市场运营状况的重要体现。

根据客户投诉，对影响用户体验的问题逐点解决，是传统提升客户满意度的方法。但随着用户数量的大幅增加，移动产品的种类越来越丰富，客户的需求越来越高，传统的方法已经难以有效提升客户的满意度。数字经济时代，各大运营商需要运用数字经济的管理理念和技术手段，建立客户体验生态的全方位系统性测评体系，实现客户满意度评测的数字化转型，让客户体验赋能商业决策，让商业决策真正服务客户，共同推动移动网络高质量可持续发展。

中国移动通信集团北京公司，让客户根据自身在网络覆盖与信号强度、语音通话清晰度和语音通话稳定性三个方面的体验进行打分，同时还让客户根据语音通话的整体体验进行语音通话整体满意度的打分，并统计整理影响客户语音业务体验的因素，以此分析客户语音业务满意度的主要影响因素，并提升客户语音业务满意度。同时，对于上网数据业务，中国移动北京公司让客户根据自身在网络覆盖与信号强度、手机上网速度、手机上网稳定性三个方面的体验进行打分，同时还让客户根据手机上网的整体体验进行手机上网整体满意度的打分，并统计整理影响客户上网体验的因素，以此分析影响客户上网业务体验的主要因素，并提升客户的上网体验。本研究拟通过分析影响用户满意度的各种因素，为决策提供依据，从而实现更早、更全面提升用户满意度。

1.2 研究问题

基于以上研究背景以及所给的数据集，本文解决如下两个问题：

问题 1：研究影响客户语音业务和上网业务满意度的主要因素，并给出各因素对客户打分影响程度的量化分析和结果。

问题 2：结合问题 1 的分析，对于客户语音业务和上网业务分别建立客户打分基于相关影响因素的数学模型，并据此对客户打分进行预测研究。

第二章 问题分析

2.1 针对问题一的分析

问题一主要为影响因素重要性分析，不仅要对影响因素进行重要性排序，还需对重要性程度进行量化分析。首先需要进行数据预处理，清洗数据简化特征；其次进行包含相关性分析在内的数据探索性分析，初步探究变量相关性和重要性。对于问题一，注重考虑机器学习模型特征重要性评估方法，此种方法不仅可以给出重要性排序，还可以量化重要性程度，具有较好的效果。

2.2 针对问题二的分析

问题二为用户满意度预测，主要考虑采用机器学习模型，将 1-10 共 10 个打分数据视作 10 个类别，由此将满意度评分预测转化为类别预测。这一部分需要着重考虑两个方面的问题：一是如何选取有效的特征，需要综合问题一的结果，同时也要考虑原始数据集（附件 1、附件 2）和预测数据集（附件 3、附件 4）所含变量的不同，在训练模型时需特别注意选取附件 1 和附件 3 同时包含的变量作为机器学习模型的特征，附件 2 和附件 4 做相同处理；二是模型评价指标的选取，满意评分属于定比尺度，在建立模型时将评分视作 10 个类别将会将数据划分为定类尺度，此时采用准确率等指标进行模型评估有失偏颇，需要寻找更加符合数据的评价指标。

第三章 数据探索性分析

3.1 数据预处理

3.1.1 变量的筛选与剔除

本文包含两份原始数据集，一份为语音业务用户满意度数据集（附件 1），共含有 5433 个用户的 54 个相关信息变量（包含四个打分数据），另一份则为上网业务用户满意度数据集（附件 2），共含有 7020 个用户的 124 个信息（包含四个打分数据）。观察数据可发现，两份数据集数据量适中，但变量均较多，尤其是上网业务用户满意度数据集，且数据呈现形式多样、非规范的特点。一方面，较多的数据信息有助于挖掘更多的信息，但另一方面，变量过于冗杂则会影响分析的效果。故首先对数据进行简单分析，根据常识剔除无关变量、合并相关变量，在尽量不损失信息的情况下简化数据集。

针对语音业务用户满意度数据集，首先，两个用户描述变量为文本数据，且该变量是作为一种补充信息对满意度分析影响不大，可以删除；其次，终端品牌类型、是否实名登记用户、当月欠费金额、前第 3 个月欠费金额这 4 个变量为无关变量，故而可以剔除；此外，关于用户是否为 5G 用户这一信息，有三个相关变量，分别为：4\5G 用户、是否 4G 网络客户（本地剔除物联网）、是否 5G 网络客户，这三个变量信息重复，故仅保留一个，考虑到信息的完整性，在此保留“4\5G 用户”这一变量；最后，经过简单的数据分析发现“是否遇到过网络问题”这一变量涵盖了包括居民小区、办公室...手机没有信号等 16 个变量信息，即这 16 个变量为“是否遇到过网络问题”，以及在何处、遇到了何种网络问题的具体描述，具体而言，若 16 个变量均为“否”，则变量“是否遇到过网络问题”记为“否”，其他情况均记为“是”，在对语音业务进行满意度分析时，我们不再对具体问题进行区分，故将 16 各变量统称为“是否遇到过网络问题”。综上，经过初步变量剔除、合并后共得到 5433 个用户的 31 个相关信息（包含四个打分数据）。

针对上网业务用户满意度数据集，首先，三个用户描述变量为文本数据作为种补充信息对满意度分析影响不大，可以删除，操作系统、终端品牌、终端品牌类型、畅享套餐名称为无关变量，可以直接剔除；其次，王者荣耀使用次数、游戏类 APP 使用次数、王者荣耀使用天数以及游戏类 APP 使用天数含有重复信息，考虑到次数更具代表性，故仅保留次数相关信息，同理，终端制式和是否为 5G 网络用户仅保留终端制式，码号资源-激活时间与码号资源-发卡时间选择激活时间，另外，综合是否校园套餐用户、以及是否为校园卡绑定合约用户为一个变量——校园卡套餐情况（1：非校园卡套餐用户，

2：校园卡套餐未绑定合约，3：校园卡套餐并绑定合约）；此外，与语音业务用户满意度数据集存在同样的情况，上网业务用户满意度数据集存在多个变量信息包含的情况，采用同样的方法，剔除具体描述变量，保留整体描述变量。此步骤完成后，共得到 7020 个用户的 51 个相关信息（包含四个打分数据）。

3.1.2 缺失值、异常值处理

在数据预处理的环节中，缺失值的处理是十份重要与关键的，缺失值的存在可能对研究分析会产生较大的影响。且导致模型难以运行，一般会采用空缺值填充或者删除的方式对缺失值进行处理。而异常值指在数据集中不合理的值，又称离群点，异常值会影响模型分析的效果，甚至导致模型失败，常见的异常值处理办法是删除法、替代法（连续变量均值替代、离散变量用众数以及中位数替代）、插补法（回归插补、多重插补）等，此外，可以先把异常值变成缺失值，然后进行后续缺失值补齐等。在本文的数据中，由于用户差异较大，较多变量存在离群值数据，这里异常值仅设定为错误数据。

分别对语音业务用户满意度数据集和上网业务用户满意度数据集进行空缺值和异常值检验。根据表 3-1 所示的结果，语音业务用户满意度数据集未检测出异常值，共有 5 个变量含有缺失值。经分析，外省流量占比空缺的原因是该用户总流量为 0，故该变量缺失值用 0 填充；终端品牌和客户星级标识缺失值数量不多，且缺失这两个变量信息的用户相同，故删除这 5 个用户；重定向次数与重定向驻留时长含有较多缺失值，且无法进行替代或插补，采用删除法进行处理。经过此步骤后，语音业务数据集共包含 5428 个用户的 29 个相关信息.

表 3-1 语音业务数据集缺失值、异常值检测结果

类别	空缺值					异常值
变量	外省流量占比	终端品牌	客户星级	重定向次数	重定向驻留时长	/
数量	2971	4	5	4260	4260	/

同理，对上网业务用户数据集进行空缺值处理和异常值检验。结果显示（详见表 3-2），码号资源-激活时间、王者荣耀使用次数、高频通讯分公司、其他游戏类 APP 使用次数以及终端类型存在缺失值，其中，码号资源-激活时间缺失值较多，无法替补，删除这一变量；有 16 位用户缺失高频通讯分公司这一信息，将这 16 个样本删除，并将高频通讯分公司进行整合将城区一分公司、城区二分公司、城区三分公司统称为城区，剩余类型分公司统称为其他（最终，城区：4203，其他：2801）；有 14 位用户缺少终端类型这

一信息，进一步统计发现 7020 位用户中有 7002 位用户（约 99.7%）终端类型为手机，这一变量在分析中失去意义，可剔除；最后是对王者荣耀使用次数和其他游戏类 APP 使用次数的处理，这两类变量缺失值较多，考虑到已经保留游戏类应用使用流量这一变量，故剔除王者荣耀使用次数和其他游戏类 APP 使用次数这两个变量。

此外，在对上网业务用户数据集中发现异常值，有 18 位用户年龄信息为 0，显然错误，删除这 18 位用户。

经过此步骤后，上网业务数据集共包含 6986 位用户的 49 个相关信息。

表 3-2 上网业务数据集缺失值、异常值检测结果

类别	空缺值					异常值
变量	码号资源-激活时间	王者荣耀使用次数	高频通讯分公司	其他游戏类 APP 使用次数	终端类型	年龄
数量	4150	414	16	414	14	18

3.1.3 类别变量编码

在很多机器学习任务中，特征不全是连续值，而有可能是分类值，而机器学习一般仅对数字特征友好，无法直接利用类别特征进行学习，我们在将数据输入算法进行训练前需要对类别特征进行编码处理，将其转换成数字特征。一是转换后可以提高模型运算效率，二是对于一些模型，比如逻辑回归或计算距离时，无法对分类值直接进行计算。然而，直接转换为数字也会带来一些问题，如转换为数字后，默认为连续变量，违背最初设计，影响效率；转换后的值会影响同一特征在样本中的权重。因此，需要更好的编码方式对特征进行转换。

目前最常用的编码方式有 One-Hot Encoding、Label Encoding、Ordinal Encoding 等。One-hot 编码是类别变量编码中较为常用的一种编码方式，One-hot 方法会创建出对应的 N 列特征，其中每列代表该样本是否为该特征的某一种取值。每个类别映射到一个包含 1 和 0 的矢量，表示该特征的存在与否，向量的数量取决于特征类别的数量。但由于附件 1、2 中如客户星级标识、终端品牌等离散特征的特征值过多，导致生成特征的数量太多且过于稀疏，大大降低运行速度和效率。考虑到多数类别间为无序关系，故本文最终采用 Ordinal Encoding 序列编码，把所有的相同类别的特征编码成同一个值，对特征进行随机排序，减少人为误差和影响。

3.1.4 小结

综上，前两部分数据预处理主要为变量的筛选和缺失值、异常值处理，变量筛选部

分遵循两个原则，一是去重原则，筛选出具有重复信息的变量，保留其中含有信息最全面、缺失值最少的变量；二是去繁留简原则，剔除具体描述性的变量，仅保留概括性信息变量。缺失值、异常值处理部分主要采用删除法，若某个变量缺失值过多，考虑剔除该变量；若某个变量缺失值较少，考虑剔除相应的用户（样本）。第三部分预处理则是为模型做准备。

整个数据预处理过程大致如下：

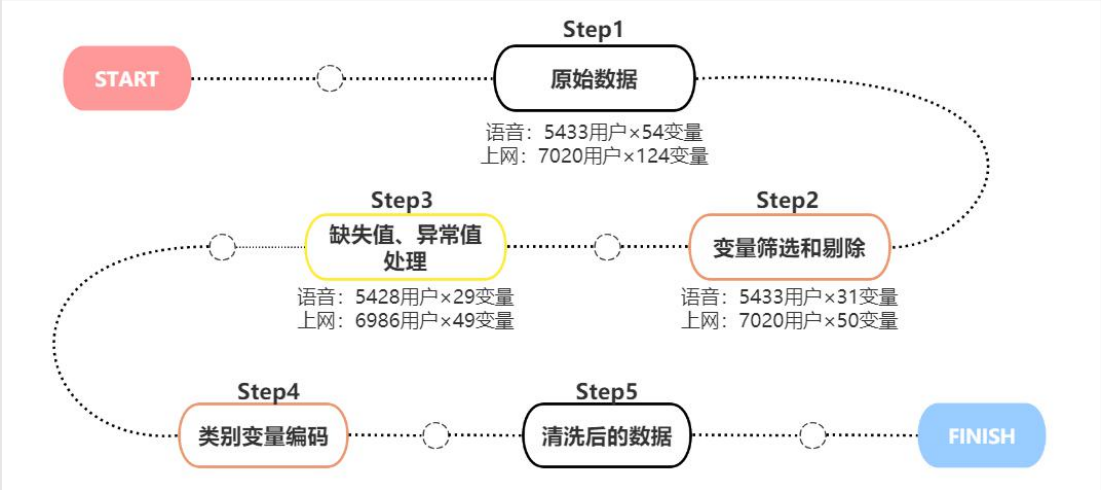


图 3-1 数据预处理过程

3.2 用户满意度评分分布情况

如图 3-2 所示，作出语音通话整体满意度、网络覆盖与信号强度、语音通话清晰度、语音通话稳定性四项指标的个数柱状图。该图描述出语音业务客户 1—10 打分的频繁程度，四项指标分布近似，10 分均占比最大，占总评分人数的 50%以上，10-2 分所占人数呈现阶梯式递减现象，在 2 分处出现转折，1 分人数相比于 2—4 分处较多。由此，可以看出，一半以上的客户对中国移动北京公司的语音业务非常满意，多数客户对语音业务较为满意，少部分客户对其语音业务不满意，不满意的客户中，1 分占比最大。

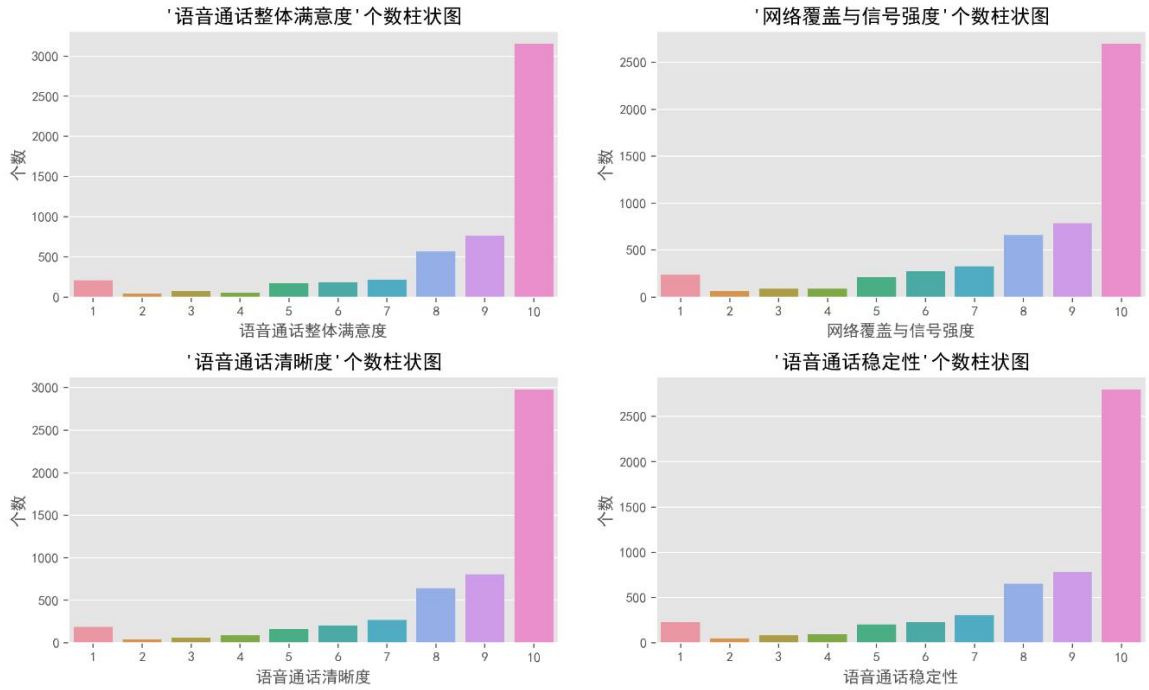


图 3-2 “语音业务”客户打分的分布情况

同理，作出手机上网整体满意度、网络覆盖与信号强度、手机上网速度、手机上网稳定性四项指标的个数柱状图（见如下图 3-3）。与语音业务客户打分情况相类似，上网业务打分情况中，10 分占比最多，超出 50%，其次打分最多的是 8 分，9 分的数量位于 8 分后，7-4 分递减，3 分的数量相比于 4 分回升，2 分处骤减，1 分大幅度增加。可以看出，上网业务的整体满意度不如语音业务，1 分非常不满意的比例有明显提升，较为满意的比例有所下降。

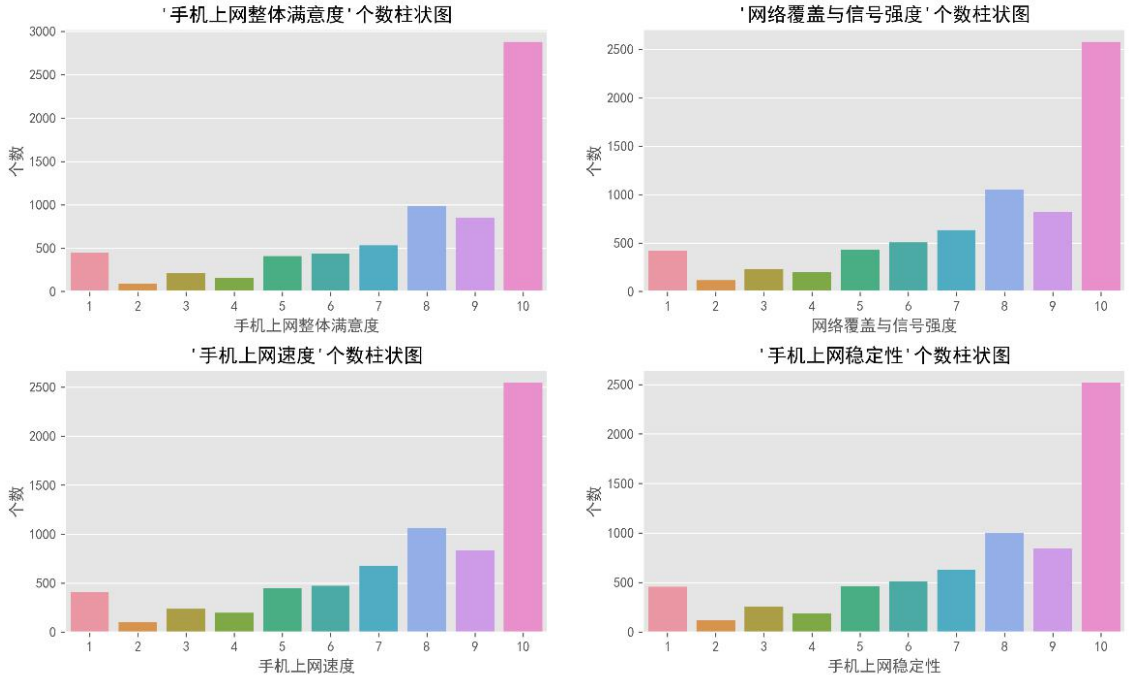


图 3-3 “上网业务”客户打分的分布情况

综上，我们对客户在语音业务、上网业务两方面的分布进行特征分析，可以初步得到客户的满意度趋势。中国移动北京公司在提升两方面满意度时，应略微侧重提升上网业务，其上升空间更大，效果会更加显著。中国移动北京公司在保证其非常满意的忠诚客户利益的同时，要更加重视那些对某些业务存在不满但对公司的总体满意度较高的用户，重视其不满和建议，以免失去该部分客户。

3.3 变量相关性分析

相关性分析是指对两个或多个具备相关性的变量元素进行分析，从而衡量两个变量因素的相关密切程度，我们常用的是皮尔森相关系数和斯皮尔曼相关系数。其中，皮尔森相关系数（Pearson correlation coefficient, PCC）是衡量两个连续型变量的线性相关关系；Spearman 相关用于计算等级数据之间的关系，这类数据的特点是数据有先后等级之分，但连续两个等级之间的具体分数差异却未必都是相等的。即 Pearson 处理变量的数据原始值，而 Spearman 处理数据排序值。

基于上述变量相关性的基础知识，我们将语音业务、上网业务用户满意度数据中各影响因素分别划分为数值型数据和类别型数据，见表 3-3。数值型数据求出 Pearson 相关系数，类别型数据求出 Spearman 相关系数，并做出对应的相关系数热力图。

表 3-3 语音、上网业务数据集字段的划分

语音业务影响因素		上网业务影响因素	
数值型字段	**类别型字段**	**数值型字段**	**类别型字段**
mos质差次数	是否遇到过网络问题	年龄	居民小区
未接通掉话次数	是否去过营业厅	王者荣耀使用次数	办公室
家宽投诉	4\5G用户	游戏类APP使用次数-->改为其他	高校
资费投诉	语音方式	通信类应用流量	商业街
ARPU（家庭宽带）	终端品牌	游戏类应用流量	地铁
套外流量（MB）	是否关怀用户	网页类应用流量	农村
套外流量费（元）	客户星级标识	音乐类应用流量	高铁
外省语音占比		视频类应用流量	其他场景
语音通话-时长（分钟）		邮箱类应用流量	网络信号差/没有信号
省际漫游-时长（分钟）		当月GPRS资源使用量（GB）	显示有信号上不了网
当月ARPU		畅享套餐档位	上网过程中网络时断时续或时快时慢
当月MOU		主套餐档位	手机上网速度慢
前3月ARPU		当月MOU	其他网络问题
前3月MOU		近3个月平均消费	看视频卡顿
外省流量占比		本年累计消费	打游戏延时大
GPRS总流量（KB）		套外流量（MB）	打开网页或APP图片慢
GPRS-国内漫游-流量（KB）		套外流量费（元）	下载速度慢
			手机支付较慢
			其他APP通用问题
			高单价超套客户（集团）
			高频高额超套客户（集团）
			客户星级标识
			性别
			是否全月漫游用户
			是否不限量套餐到达用户
			终端制式
			当月高频通信分公司
			校园卡用户

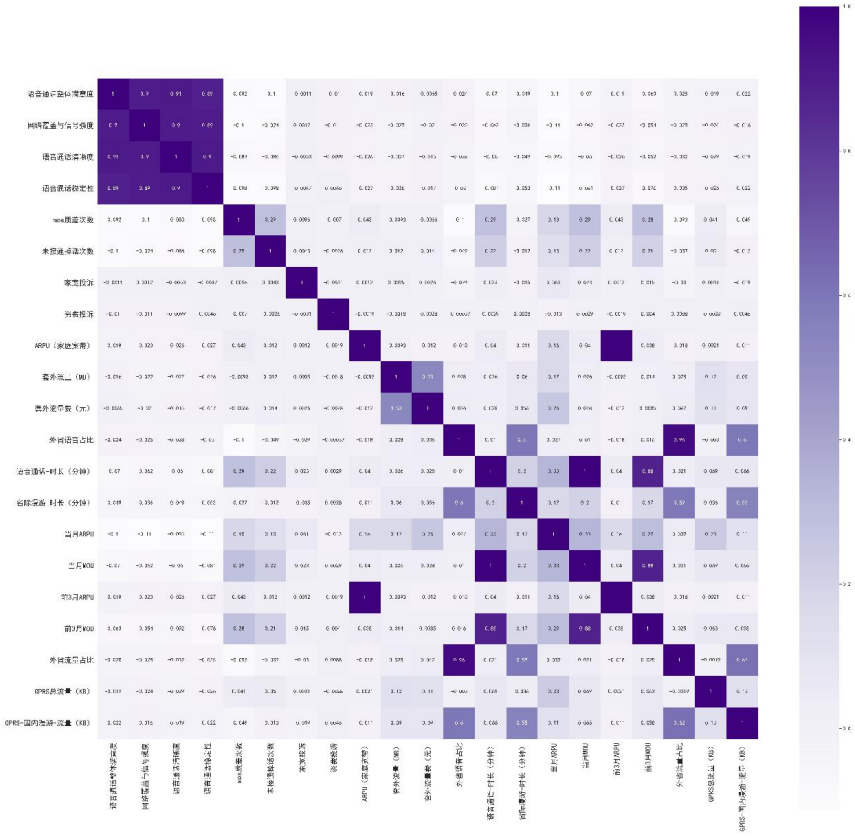


图 3-4 “语音业务”数值型指标相关系数热力图

在影响语音通话整体满意度的数值型指标中，我们可以看到，其 Pearson 相关系数的值均较低，网络覆盖与信号强度、语音通话清晰度、语音通话稳定性三者与语音通话整体满意度有很强的正相关性，均约为 0.9，但具体的影响因素指标与语音通话整体满意度的相关性均较低，其中当月 ARPU、未接通掉话次数与语音通话整体满意度的相关系数相比于其他指标较大，但仅为-0.1，有一定的负相关性，其余数值型指标影响较为微弱。

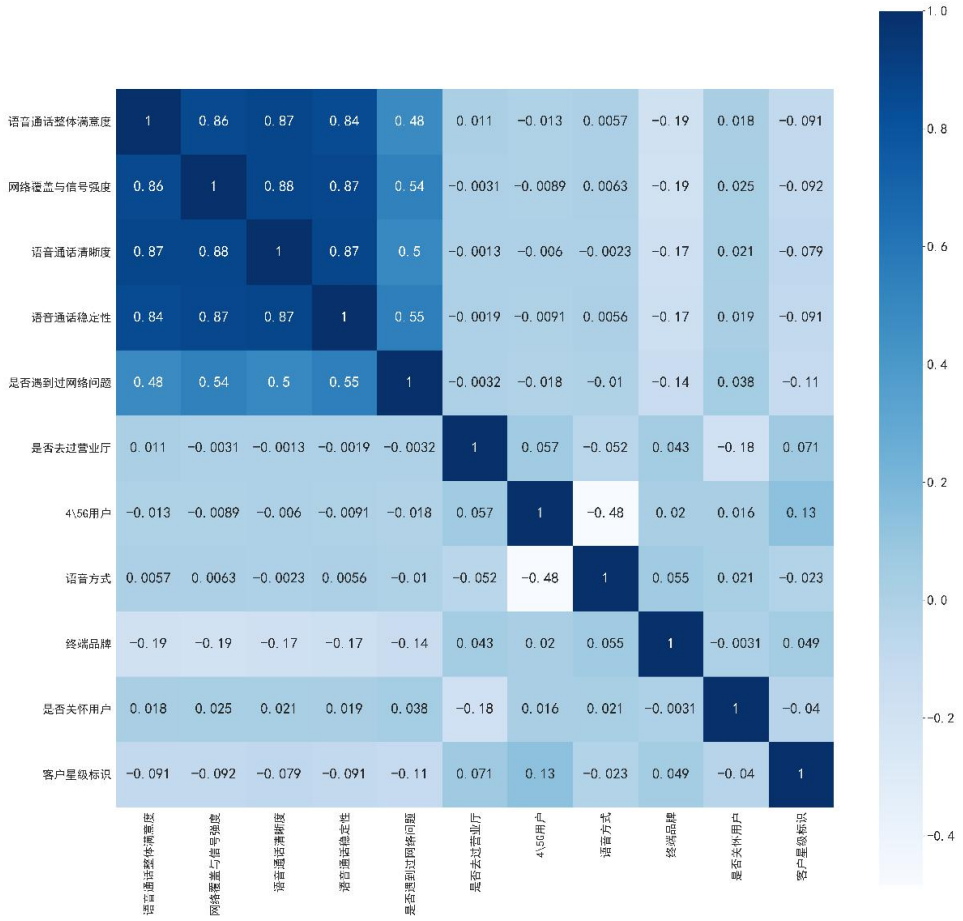


图 3-5 “语音业务”类别型指标相关系数热力图

在影响语音通话整体满意度的类别型指标中，我们可以看到，网络覆盖与信号强度、语音通话清晰度、语音通话稳定性三者与语音通话整体满意度的 Spearman 相关系数较高，有很强的正相关性，但具体的影响因素指标中，是否遇到过网络问题与语音通话整体满意度的相关系数为 0.48，说明其对语音通话整体满意度的影响较大。这里要注意说的是，数据预处理中，将类别变量随机编码，针对是否遇到过网络问题这一指标，python 随机用 0 表示是，1 表示否，故该相关系数为正值。此外，与其他剩余指标相比，终端品牌与语音通话整体满意度的相关系数为-0.19，认为如华为、苹果、小米等终端品牌对语音通话整体满意度有一定影响，其余指标的影响较为微弱。

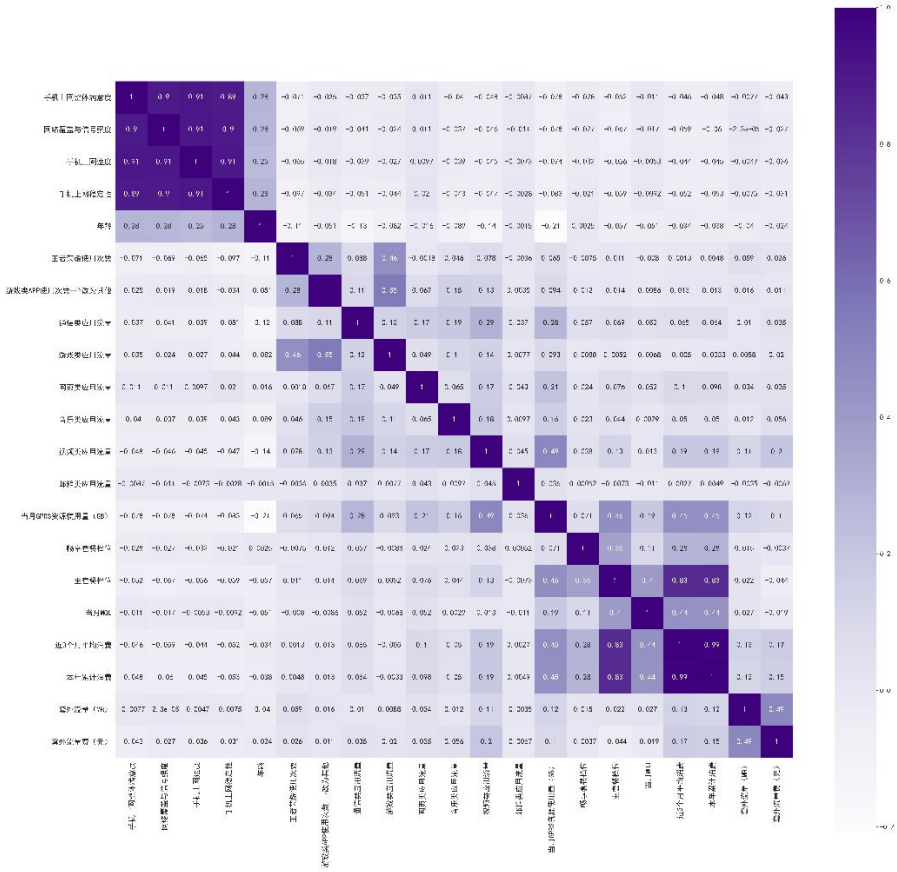


图 3-6 “上网业务”数值型指标相关系数热力图

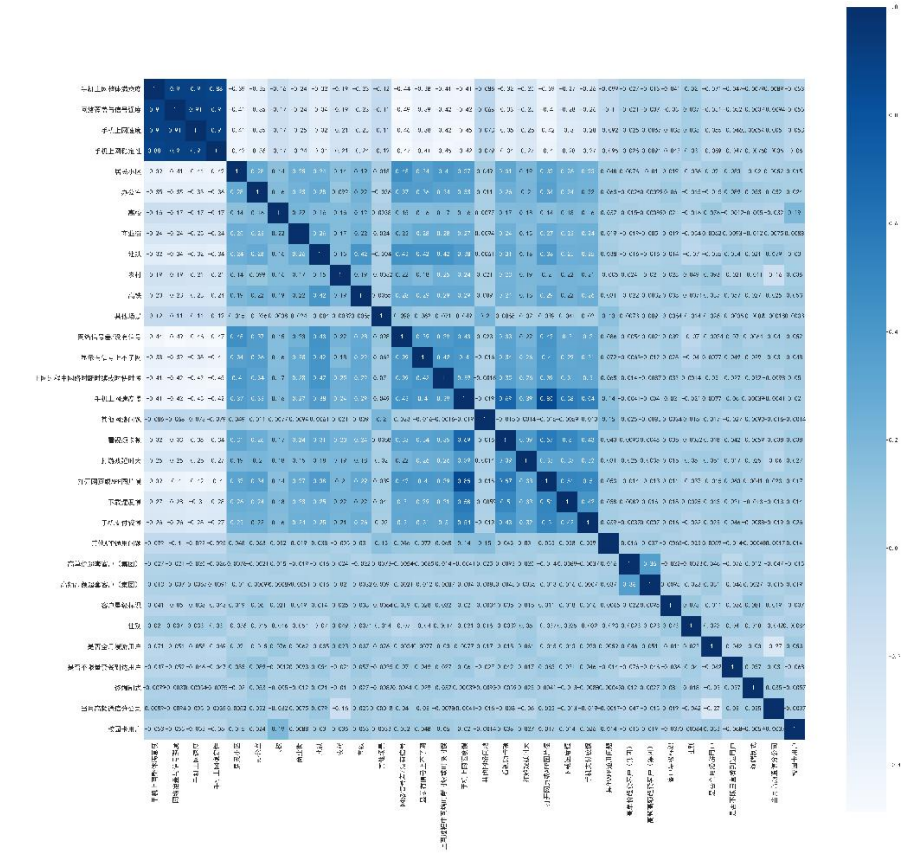


图 3-7 “上网业务”类别型指标相关系数热力图

同理，做出上网业务数值型、类别型指标的相关系数热力图（分别见图 3-6、图 3-7），可以看出，在数值型指标中手机上网整体满意度与年龄、当月 GPRS 资源使用量（KB）的相关系数分别为 0.28 和-0.078，相比于其他指标具有明显的相关性；类别型指标中我们发现手机上网整体满意度与网络信号差/没有信号、上网过程中网络时断时续或时快时慢、手机上网速度慢、打开网页或 APP 图片慢、居民小区、显示有信号上不了网的相关系数分别为-0.44、-0.41、-0.41、-0.39、-0.39、-0.38，存在多项负相关性较强的指标。

综上，我们先对预处理过的数据进行相关系分析，初步挖掘各指标变量之间的相关关系、大致了解影响用户在语音、上网两方面满意度的因素，为后面具体的满意度影响因素分析打下基础。

第四章 用户分析之满意度影响因素分析

4.1 特征选择方法简介——随机森林

当一个数据集具有充足数量的特征时，如何筛选出对结果影响最大的特征，即缩减建立模型时的特征数是尤为关键的。有效而准确的筛选特征不仅可以提高模型的效率同时也可以提升模型的准确度。用于特征选择的方法有很多，如多元分析方法主成分分析、因子分析等，基于正则化的变量筛选方法 lasso、Adaptive Lasso 等。除此之外，有很多机器学习方法在分类的过程中可以进行特征选择。其中，随机森林算法是最常用的一种特征选择方法。随机森林是以决策树为基础学习器的集成学习算法，在分类和回归上均具有很强的性能，也被誉为“代表集成学习技术水平的方法”。他的基本原理是，从原数据集中有放回的采样获得若干个子集，基于每个子集训练出不同的基分类器，再通过基分类器的投票获得最终的分类结果。

随机森林进行特征重要性评估方法主要两种，分别为 Decrease GINI 和 Decrease Accuracy[1]。

（1） Decrease GINI

对于分类问题，以 Gini 值作为评判标准，定义 Gini 值为：

$$Gini=1-\sum(P(i)*P(i)) \qquad （式 4-1）$$

其中，P(i)为当前节点上数据集中第 i 类样本的比例。一般来说，类别分布越平均，Gini 值越大，类分布越不均匀，Gini 值越小。在寻找最佳的分类特征和阈值时，寻找最佳的特征 f 和阈值 th，使得当前节点的 Gini 值减去左子节点的 Gini 和右子节点的 Gini 值最大。即评判标准为：

$$argmax(Gini-GiniLeft-GiniRight) \qquad （式 4-2）$$

对于回归问题，则更加简单，以 argmax(Var-VarLeft-VarRight)作为评判标准，即当前节点训练集的方差 Var 减去减去左子节点的方差 VarLeft 和右子节点的方差 VarRight 值最大。

（2） Decrease Accuracy

Decrease Accuracy 的基本思想为：如果一个变量 j 足够重要，那么改变它会极大的增加测试误差；反之，如果改变某一变量并没有引起测试误差增大，则说明该变量不是重要变量。

具体而言，对于一棵树 Tb(x)，采用 OOB 样本得到测试误差 1；然后随机改变 OOB 样本的第 j 列：保持其他列不变，对第 j 列进行随机的上下置换，得到测试误差 2。至此，可以用测试误差 1 与测试误差 2 的差值来刻画变量 j 的重要性。

4.2 语音业务满意度影响因素分析

4.2.1 变量重要性量化分析

在数据预处理基础上用随机森林方法对语音业务数据进行特征重要性评估。语音业务数据共含有用户 4 个方面的打分数据，分别为语音通话整体满意度、网络覆盖与信号强度、语音通话清晰度以及语音通话稳定性，每项打分区间为 1-10。经过数据预处理后，语音业务数据集含有 29 个变量，这里仅展示前 25 个变量重要性排序情况（详见图 4-1）。

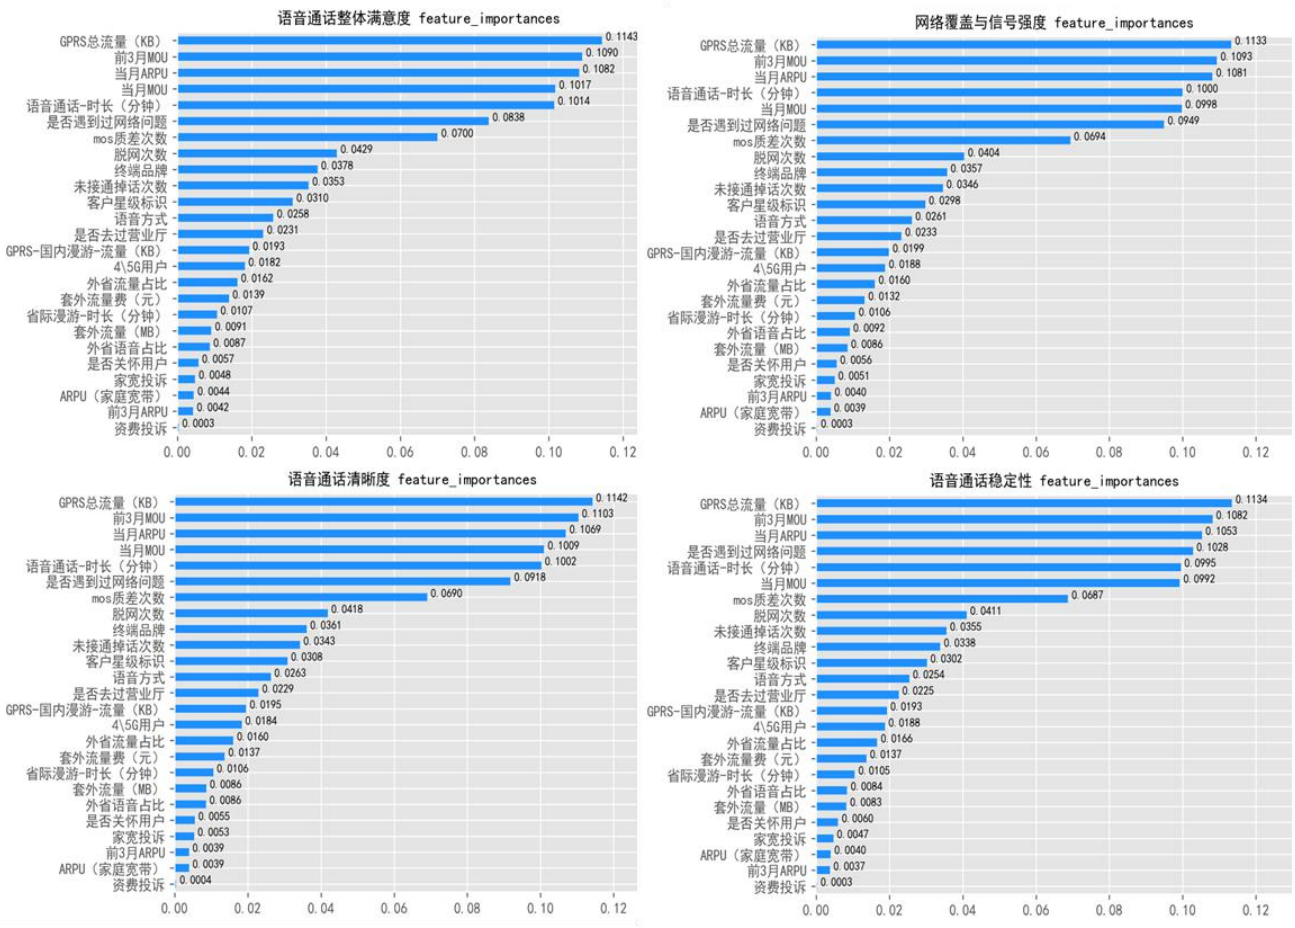


图 4-1 “语音业务”变量重要性排序

基于变量重要性排序结果图，可以得到以下分析结果：

（1）25 个变量对 4 项打分的重要性排序大致相同，即说明 4 个方面的打分基本受到相同变量的影响，这也导致了 4 各方面的打分呈现较强的相关性。

（2）最重要的三个变量为：GPRS 总流量、前三个月 MOU（前三个月语音通话时长）、当月 ARPU（家庭宽带）费用，这三个变量在 4 项打分重要性排序中均位于前三名，重要程度均大于 10%，在后期的分类预测中可能发挥很大作用；最不重要变量为资费投诉，这一变量对打分预测而言为无关变量。

（3）比较重要的变量为：是否遇到过与网络问题、语音通话时长、当月 MOU，这三个变量重要性程度为 10%左右，其次是质差次数、脱网次数，重要程度在 5%左右,这些变量对打分有很强的影响，可以作为打分预测的重要特征。

（4）不太重要的变量还有：ARPU (家庭宽带)套餐费用、前三个月 ARPU 费用、家宽投诉次数、是否为关怀用户等，这些变量对打分影响不大，在进行打分预测时可以剔除。

4.2.2 部分重要变量分析

选取语音通话整体满意度、网络覆盖与信号强度、语音通话清晰度、语音通话稳定性四项打分重要性最强的几个因素，同时将打分分成低（1-4 分）、中（5-7）、高（8-10）三个等级，进行排序分组，绘制直方图，进行重要变量重要性分析，最终选取对得分影响最为显著的因素前 3 月 MOU 即当月前面三个 3 月的通话时长进行展示和分析。

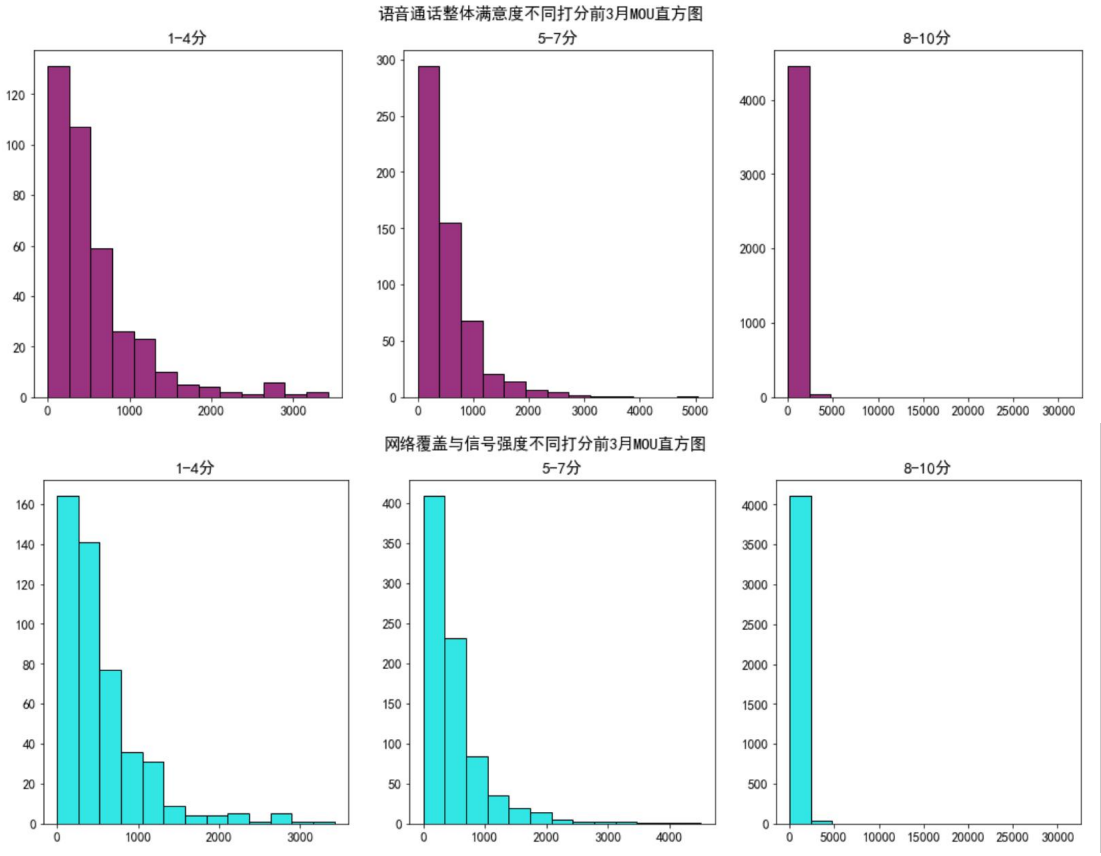


图 4-2 语音通话整体满意度、网络覆盖与信号强度前 3 月 MOU 直方图

通过图 4-2 我们可以看出，语音通话整体满意度、网络覆盖与信号强度前 3 月 MOU 的分布趋势较为一致，打分在 1-4 分、5-7 分、8-10 分之间的用户，其前 3 月 MOU 分别主要分布在 0-800 分钟、客户 0-1200 分钟、0-2500 分钟，三个等级的人数越来越高、前 3 月 MOU 逐渐增加。由此可以推断出，前 3 月 MOU 对用户在语音通话整体满意度、网络覆盖与信号强度的打分有显著影响，前 3 月 MOU 越大的用户，越偏向于较高的打分。

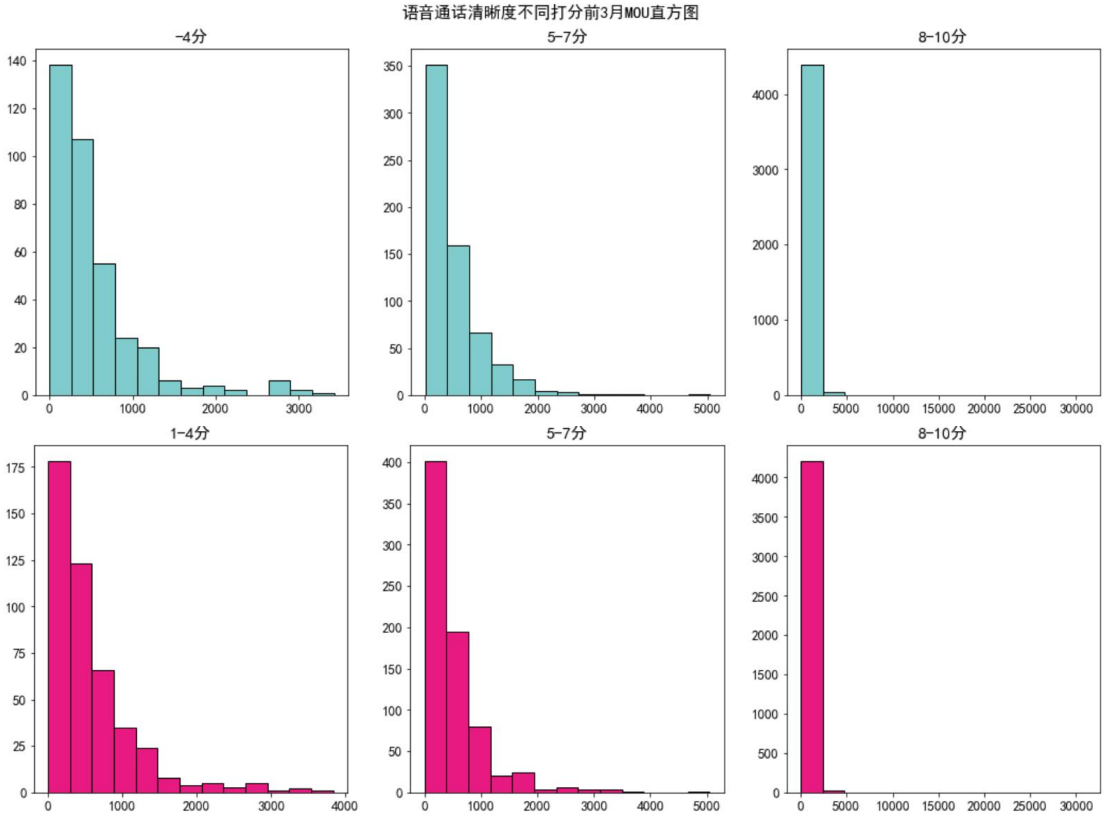


图 4-3 语音通话清晰度、语音通话稳定性前 3 月 MOU 直方图

同理，语音通话清晰度、语音通话稳定性前 3 月 MOU 的分布也是如此，同样认为前 3 月 MOU 对用户在语音通话清晰度、语音通话稳定性的打分有显著影响，前 3 月 MOU 越大的用户，越偏向于较高的打分。

通过上述分析，可以看出中国移动北京公司的语音通话体系较为完善，网络覆盖与信号强度、语音通话清晰度、语音通话稳定性较好，可以满足通话时间长的用户满意，从而获得该类客户的满意与支持。

4.3 上网业务满意度影响因素分析

4.3.1 变量重要性量化分析

在数据预处理基础上用随机森林方法对上网业务数据进行特征重要性评估。上网业务数据共含有用户 4 个方面的打分数据，分别为手机上网整体满意度、网络覆盖与信号强度、手机上网速度以及手机上网稳定性，每项打分区间为 1-10。经过数据预处理后，上网业务数据含有 49 个变量，这里同样仅展示前 25 个变量重要性排序情况（详见图 4-4）。

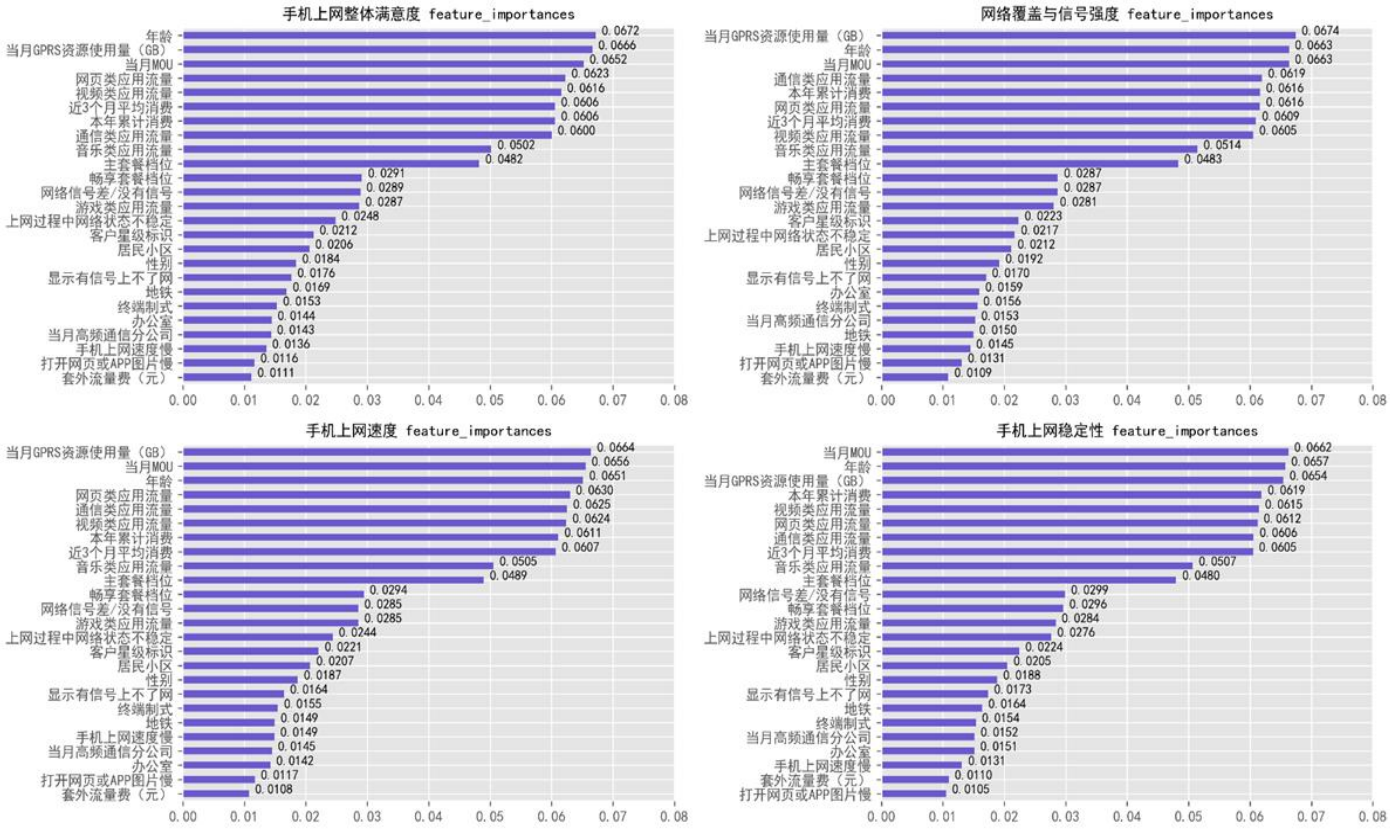


图 4-4 “上网业务”变量重要性排序

基于变量重要性排序结果图，可以得到以下分析结果：

（1）对上网业务 4 项打分而言，前 25 个最重要的变量大致相同，但变量重要性排序有所不同，

（2）对上网整体满意度而言，最重要的前十个变量依次是：年龄、当月 GPRS 资源使用量（GB）、当月 MOU、网页类应用流量、视频类应用流量、近 3 个月平均消费、本年累计消费、通信类应用流量、音乐类应用流量以及主套餐档位，这十个变量的重要程度均超过 4%，前八个变量重要程度超过 6%，这些变量对于手机上网整体满意度预测有很重要的影响；相对而言，不太重要的变量为：套外流量费、打开网络或 APP 图片慢、手机上网速度慢、当月高频通讯公司、是否在办公室遇见网络问题以及终端制式等，

这些变量重要程度小于 1.5%，对整体满意度影响较小。

（3）对网络覆盖与信号强度满意度而言，最重要的前十个变量依次是：当月 GPRS 资源使用量（GB）、年龄、通信类应用流量、本年累计消费、网页类应用流量、近 3 个月平均消费、视频类应用流量、音乐类应用流量以及主套餐档位，这十个变量的重要程度均超过 4%，前八个变量重要程度超过 6%，这些变量对网络覆盖与信号强度满意度预测有很重要的影响；相对而言，不太重要的变量为：套外流量费、打开网络或 APP 图片慢、手机上网速度慢、是否在地铁遇见网络问题、当月高频通讯公司以及终端制式等，这些变量重要程度小于 1.7%，小于平均水平，对整体网络覆盖与信号强度满意度影响较小。

（4）对手机上网速度满意度而言，最重要的前十个变量依次是：当月 GPRS 资源使用量（GB）、当月 MOU、年龄、网页类应用流量、通信类应用流量、视频类应用流量、本年累计消费、近 3 个月平均消费、音乐类应用流量以及主套餐档位，这十个变量的重要程度均超过 4%，前八个变量重要程度超过 6%，这些变量对手机上网速度满意度预测有很重要的影响；相对而言，不太重要的变量为：套外流量费、打开网络或 APP 图片慢、是否在办公室遇见网络问题、当月高频通讯公司等，这些变量重要程度小于 1.5%，小于平均水平，对手机上网速度满意度影响较小。

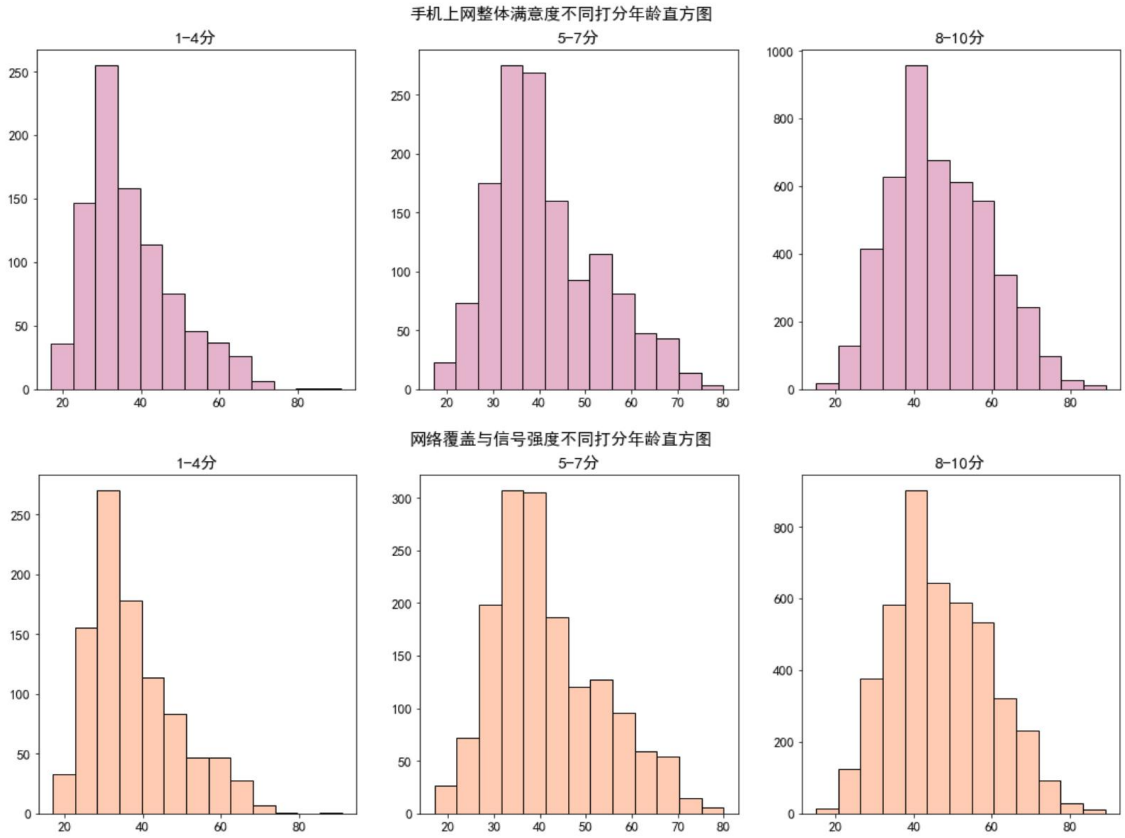
（5）对手机上网稳定性满意度而言，最重要的前十个变量依次是：当月 MOU、年龄、当月 GPRS 资源使用量（GB）、本年累计消费、视频类应用流量、网页类应用流量、通信类应用流量、近 3 个月平均消费、音乐类应用流量以及主套餐档位，这十个变量的重要程度均超过 4%，前八个变量重要程度超过 6%，这些变量对手机上网稳定性预测有很重要的影响；相对而言，不太重要的变量为：打开网络或 APP 图片慢、套外流量费、手机上网速度慢、是否在办公室遇见网络问题、当月高频通讯公司等，这些变量重要程度小于 1.5%，小于平均水平，对手机上网稳定性满意度影响较小。

4.3.2 部分重要变量分析

选取手机上网整体满意度、网络覆盖与信号强度、手机上网速度以及手机上网稳定性四项打分重要性最强的几个因素，同样将打分分成低（1-4 分）、中（5-7）、高（8-10）三个等级，进行排序分组，绘制直方图，进行重要变量重要性分析，最终选取对得分影响最为显著的因素年龄进行展示和分析。

通过手机上网整体满意度、网络覆盖与信号强度、手机上网速度以及手机上网稳定性的年龄直方图（下图 4-5）,我们可以看出，手机上网整体满意度、网络覆盖与信号强

度、手机上网速度以及手机上网稳定性年龄的分布趋势较为一致，打分在 1-4 分、5-7 分、8-10 分之间的用户，其年龄分别主要分布在 22-38 岁、32-42 岁、38-60 岁，低分的群体中，青年人的比例较高，高分群体中，中老年人比例较高。由此可以推断出，年龄对用户在手机上网整体满意度、网络覆盖与信号强度的打分有显著影响，年龄越大的用户，越偏向于较高的打分。



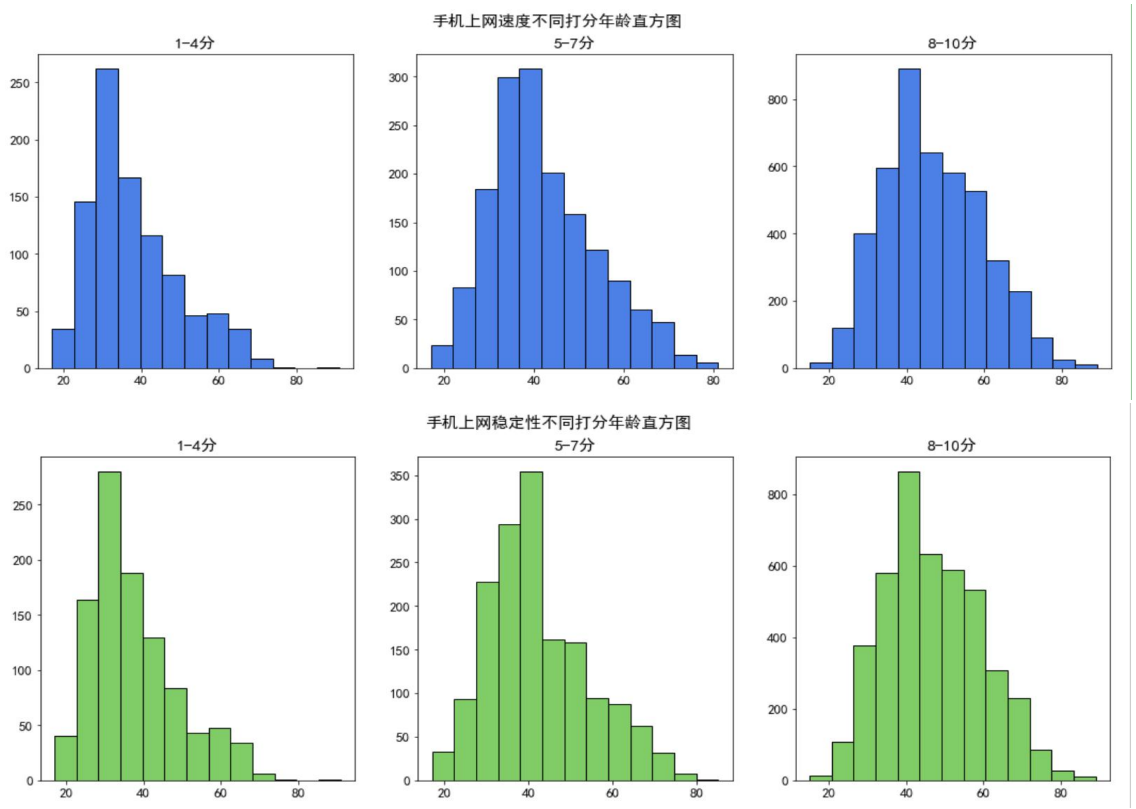


图 4-5 上网打分的年龄直方图

通过上述分析，可以看出相比于语音通话体系，中国移动北京公司的网络体系略有不足，青年群体的在手机上网整体满意度、网络覆盖与信号强度、手机上网速度以及手机上网稳定性的打分普遍低于中老年人。造成该现象的原因主要有，相较于中老年人，年轻人的上网时长更多、使用的 APP 数量更多更复杂、网络出现问题的概率更高，这会大大降低用户对手机上网的体验感，故青年人在低分中占比较大。

第五章 用户分析之满意度预测

5.1 分类方法简介

5.1.1 决策树

决策树是一个树结构。其每个非叶节点表示一个特征属性上的测试，每个分支代表这个特征属性在某个值域上的输出，而每个叶节点存放一个类别。使用决策树进行决策的过程就是从根节点开始，测试待分类项中相应的特征属性，并按照其值选择输出分支，直到到达叶子节点，将叶子节点存放的类别作为决策结果[2]。

一棵决策树的生成过程主要分为以下 3 个部分：

（1）特征选择：特征选择是指从训练数据中众多的特征中选择一个特征作为当前节点的分裂标准，如何选择特征有着很多不同量化评估标准标准，从而衍生出不同的决策树算法。

（2）决策树生成： 根据选择的特征评估标准，从上至下递归地生成子节点，直到数据集不可分则停止决策树停止生长。 树结构来说，递归结构是最容易理解的方式。

（3）剪枝：决策树容易过拟合，一般来需要剪枝，缩小树结构规模、缓解过拟合。剪枝技术有预剪枝和后剪枝两种。

决策树适用于数值型和标称型（离散型数据，变量的结果只在有限目标集中取值），能够读取数据集合，提取一些列数据中蕴含的规则。在分类问题中使用决策树模型有很多的优点，决策树计算复杂度不高、便于使用、而且高效，决策树可处理具有不相关特征的数据、可很容易地构造出易于理解的规则，而规则通常易于解释和理解。

5.1.2 随机森林

随机森林是一种基于决策树的集成学习算法，它由多棵决策树组成，每棵决策树具有一个投票权，随机森林最后的分类结果就取决于这些决策树的投票结果。随机森林中每棵决策树的生成方式如下[2]:

（1）从训练集中用有放回抽样法随机抽取一定数量的样本组成新训练集;

（2）在特征集中随机选择一定数量的特征;

（3）利用建立决策树的方法，依次计算最优的特征作为当前节点进行建树。

上述过程重复执行 n 次，每次抽取的样本数量、特征数量都固定不变，建立的 n 棵树就组成了随机森林。由于每次对样本和特征都是随机抽取，就会构造出许多不同的决

策树。因此，随机森林中的所有决策树对同一个样本进行分类，会得到许多分类结果，每棵决策树对其分类结果进行一次投票，通常取被投次数最多的类作为该样本所属的类。

由于随机森林选取训练样本和特征的随机性，以及多次对测试样本进行分类的特性，应用此算法进行分类可以较好地解决单棵决策树泛化能力弱的问题，一定程度上弥补了决策树容易出现过拟合的缺陷。

5.1.3 Light-GBM

Light-GBM（Light Gradient Boosting Machine）是一款基于决策树算法的分布式梯度提升框架，可以实现 GBDT(Gradient Boosting Decision Tree)算法，是一种可以进行快速高效、低内存占用、高准确度、支持并行和快速处理海量数据处理的数据科学工具[3]。GBDT 的主要思想是利用弱分类器迭代训练以得到最优模型，该模型具有训练效果好、不易过拟合等优点。GBDT 不仅在工业界应用广泛，通常被用于多分类、点击率预测、搜索排序等任务。

然而 GBDT 在每一次迭代时，都需要遍历整个训练数据多次。若将整个训练数据装进内存，则会限制训练数据的大小；不装进内存，反复地读写训练数据又会消耗非常大的时间。在 Light-GBM 提出之前，XGBoost 是 GBDT 的有利工具，它是基于预排序方法的决策树算法。但其存在空间消耗大、在遍历每一个分割点的时候，都需要进行分裂增益的计算，消耗的代价大、对 cache 优化不友好等缺点。因此，Light-GBM 提出的主要原因就是为了解决 GBDT 在海量数据遇到的问题，让 GBDT 可以更好更快地用于工业实践。它的设计思路主要为：

（1）减小数据对内存的使用，保证单个机器在不牺牲速度的情况下，尽可能地用上更多的数据。

（2）减小通信的代价，提升多机并行时的效率，实现在计算上的线性加速。

5.1.4 交叉验证

交叉验证的基本思想是将原始数据进行分组，一部分做为训练集来训练模型，另一部分做为测试集来评价模型。k 折交叉验证一般步骤为将数据集分成 k 份，轮流将其中 k-1 份作为训练数据，1 份作为测试数据，进行试验。每次试验都会得出相应的正确率（或差错率）。k 次的结果的正确率（或差错率）的平均值作为对算法精度的估计，一般还需要进行多次交叉验证，再求其均值，作为对算法准确性的估计[4]。

相比较一般划分训练集和测试集的方法，交叉验证的优点表现在：

（1）交叉验证用于评估模型的预测性能，尤其是训练好的模型在新数据上的表现，可以在一定程度上减小过拟合。

（2）可以从有限的数据中获取尽可能多的有效信息。

5.1.5 网格搜索

为了最大化模型性能，了解如何优化超参数至关重要。人为手动调参依赖大量的经验，耗时且性能未必最佳，因此发展出了许多自动化超参数优化方法。网格化寻优（Grid Search）网格化寻优可以说是最基本的超参数优化方法，它是指定参数值的一种穷举搜索方法，通过将估计函数的参数通过交叉验证的方法进行优化来得到最优的学习算法。即将各个参数可能的取值进行排列组合，列出所有可能的组合结果生成“网格”。使用这种技术，只需为所有超参数的可能构建独立的模型，评估每个模型的性能，并选择产生最佳结果的模型和超参数。

5.2 建立预测模型

现共有语音业务和上网业务两个数据集，每个数据集有四个方面的打分情况需要预测，则共需要预测 8 个指标。按照 5.1 方法简介，针对每个预测指标建立 3 个分类预测模型，最终选取预测效果最好的模型对附件 3 和附件 4 进行预测。

建立模型的过程可以概括为以下几个步骤：

（1）处理附件 1 和附件 3 两个文件，仅保留附件 1 和附件 3 共同含有的变量，处理后每个数据集含有 36 个特征；对附件 2 和附件 4 进行同样的操作，处理后附件 2 和附件 4 每个数据集含有 26 个特征。

（2）采用 10 折交叉验证法分别对附件 1 和附件 2 划分训练集和测试集，用训练集训练分类预测模型，并通过测试集模型测试模型性能，同时采用网格搜索法寻找最优参数。

（3）对比模型预测效果，选取预测效果最佳的模型对附件 3、附件 4 进行预测并输出预测结果文件

满意度预测技术路线图下：

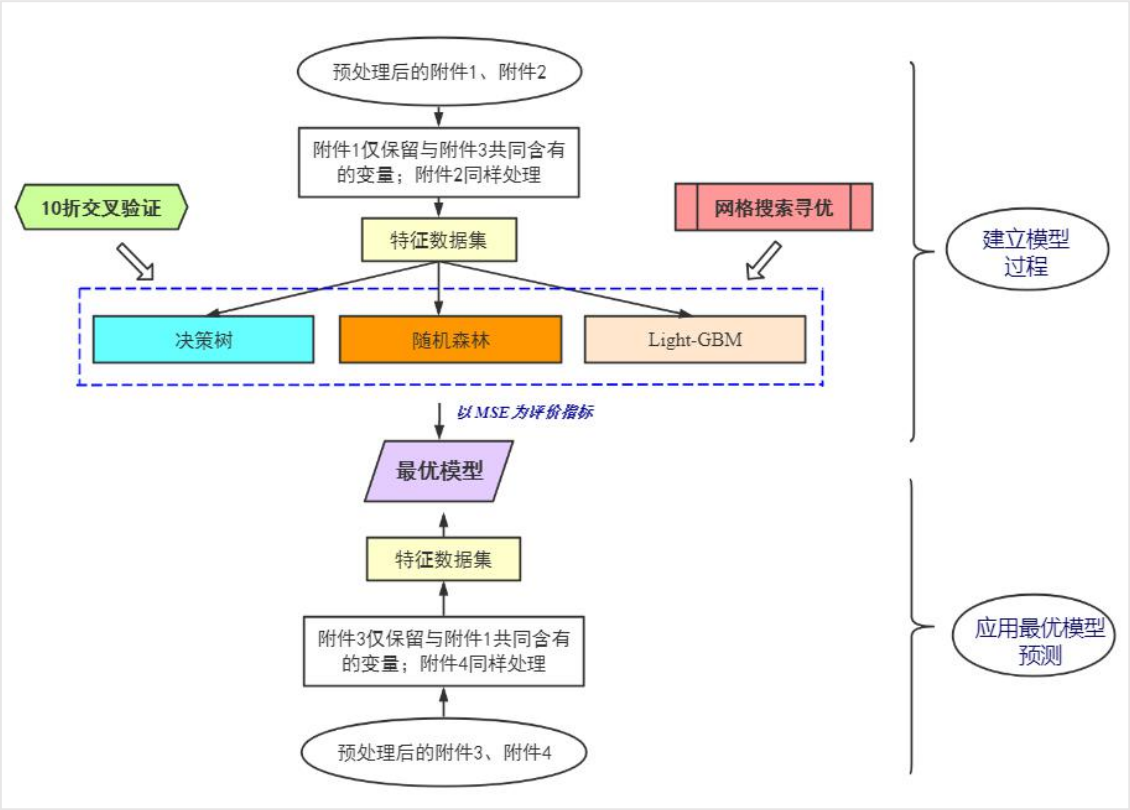


图 5-1 满意度预测技术路线

5.3 结果分析与模型评价

5.3.1 评价指标

对于一个分类预测模型，通常通过混淆矩阵观测预测结果，并计算准确率等指标来评估模型性能，但对于本数据而言，预测指标为满意度评分，在分类预测中，虽然我们将 1-10 评分视为 10 个类别，但是这 10 个类别并不是并列的关系，一般我们认为若将真实评分为 1 错误预测为 10，要比将真实评分为 1 错误预测为 4 更加严重，若采用准确率作为评价指标有失偏颇，故，我们采用均方误差（Mean Squared Error, MSE）作为模型评价指标，定义 MSE 为：

$$\text{MSE}= \frac{1}{n}\sum_{1}^{n}(y_{pred}-y_{test})^2 \qquad \text{（式 5-1）}$$

其中，n 为测试集样本量，y_{pred}为预测评分结果，y_{test}为真实评分结果。

5.3.2 模型评价和结果展示

对于语音业务和上网业务数据集，共 8 个满意度指标，每个指标分别建立决策树，随机森林以及 light-GBM 预测模型，统计模型结果可以得知（详见表 5-1），对于语音

数据集而言，4 个指标预测效果最好的模型均为决策树模型，对于语音整体满意度而言，随机森林 MSE 为 5.945；对于网络覆盖与信号强度，随机森林 MSE 为 6.340；对于语音通话清晰度，随机森林 MSE 为 5.515；最后，对语音通话稳定性预测中，随机森林 MSE 为 6.512，以上随机森林模型最优参数 n_estimators 均为 50。

表 5-1　语音业务数据各模型 MSE

模型	语音通话整体满意度	网络覆盖与信号强度	语音通话清晰度	语音通话稳定性
决策树	6.839	9.347	6.733	6.557
随机森林	**5.945**	**6.340**	**5.515**	**6.512**
Light-GBM	6.492	7.492	6.508	6.887

上网数据模型结果显示，对于手机上网整体满意度而言，决策树的 MSE 最小，为 8.613，最优参数设置为：max_dept= 3, min_samples_leaf= 2, min_samples_split= 2；对于网络覆盖与信号强度，仍然是决策树 MSE 最小（7.543）,最优参数为：max_dept= 4, min_samples_leaf= 2, min_samples_split= 2；对于语音通话清晰度，随机森林 MSE 为 8.491，为三个模型中中的最小值，n_estimators=50；最后，针对手机上网稳定性预测，Light-GBM 效果最好，MSE 为 8.743。

表 5-2　上网业务数据各模型 MSE

模型	手机上网整体满意度	网络覆盖与信号强度	手机上网速度	手机上网稳定性
决策树	**8.613**	**7.543**	9.249	9.556
随机森林	9.195	8.529	**8.491**	8.927
Light-GBM	12.088	8.856	9.421	**8.743**

5.3.3 结果的比较性分析

将 MSE 作为模型评价指标，上述已经对 3 个模型性能进行了比较分析，分别得出 8 个预测指标最佳分类预测模型，比较 8 个指标在各自最佳预测模型下的预测效果（详见图 5-2）。



图 5-2 语音业务和上网业务最优预测效果对比

对比分析结果主要有以下几点：

（1）语音业务数据集的预测整体效果优于上网数据；

（2）针对语音业务数据，预测效果排序依次是：语音通话清晰度 > 语音通话整体满意度 > 网络覆盖与信号强度 > 语音通话稳定性;

（3）针对上网业务数据，预测效果排序依次是：网络覆盖与信号强度 > 手机上网速度 > 手机上网整体满意度 > 手机上网稳定性。

究其原因，可能是因为语音业务数据集选取的特征更好地保留了用户特征，而上网业务数据保留的特征损失掉了部分样本信息，导致预测效果略差于语音数据。

第六章　建议

基于上述对影响用户语音、上网业务满意度因素的分析，本章提出针对性的整改措施，正确处理语音、上网业务短板问题，竭力提升北京移动用户满意度，让企业在在 5G 时代下争取到更市场份额。

（1）注重客户基础通信需求的满足

客户对现阶段语音、网络质量的满意度存在一定不足，用户在日常使用过程中，无论是固网宽带还是移动网，如果出现上网卡看视频加载时间久、拨打电话掉线、有杂音等都是网络质量不好的体现，网量的好与坏会影响到客户对网络甚至运营商的选择，故而需要保证语音信号与上网信号在覆盖过程中具有稳定性与全面性，保证室外信号在客户使用过程中稳定，提高上网速度，提升上网感知。

中国移动通信集团北京公司应在成功构建网络运行体系的必要前提下，持续性进行工作流程的优化，完善工作内容，促进基站整体服务质量实现新提升。工程建设中心应依据城市内及周边县郊区域的人口和网络需求进行尽可能泛的基础网络设施建设，为中国移动实现更广泛更强的信号覆盖而努力。与此同时，还需针对性的对投诉较多的区域进行集中区域信号质量改善，如居民小区、办公室、高校等人口集中区域，把控好网络运行质量，推进网络信号治理，打消消费者对移动网络是否流畅稳定的疑虑，促使消费效果向着最优化方向转变。对客户联网需求和网络故障投诉予以最高效最有效地满足，减少投诉情况的发生，一步步树立好移动网络优质的相关口碑，从而稳定移动存量用户。

（2） 提高投诉处理能力

对客户语音、联网需求和故障投诉予以最高效最有效地满足，减少投诉情况的发生，一步步树立好中国移动通信集团北京公司语音、网络优质的相关口碑，从而稳定移动存量用户。服务端服务工作也会影响客户满意度，警如:网络质量投诉受理等待过程的长短。开展室分测试优化相关工作，通过定期主动走访活动了解重要单位及小区出现的室分系统问题，做到问题及时发现，及时处理,积极推进维护优化工作落实。实施网络优化测试，做好不同线路网络信号监测工作，保证所有基站在运行过程中符合要求，其倾角与方位角都为正确定，进一步提升网络质量，具体措施有:频点调整、下倾角调整、方位角调整及相关设备维护和升级等。

（3） 提升产品类型适配度

首先，基于大数据展开客户使用习惯的深化分析，提高产品开发与客户使用习惯的匹配度,通过引导帮助客户选择更符合自身需求的资费方式，实现公众客户满意度提高。

实践发现客户在产品与资费的选择过程中更倾向于简洁明了的，这个更好的降低双方交易成本，有助于增强客户的使用感受。

其次，为特定人群制定专属产品。现阶段中国老龄化问题较为突出，该类人群常常只需要基础通讯，故而日常产生的资费较低，与此同时，00 后消费正在快速崛起，该类人群会对宽带及流量有较高的需求。教育行业应受到疫情的影响出了更多的线上教育产品，出现了通讯服务需求。通讯公司可以做好人群细分工作，进行特殊产品的针对性制推动企业差异化营销策略，从不同层面进行客户满意度的提升。

参考文献

[1] https://blog.csdn.net/csdn_lzw/article/details/80159735

[2] https://blog.csdn.net/weixin_40449129/article/details/102970339

[3] https://www.jianshu.com/p/104c3e0622d3

[4] https://blog.csdn.net/m0_37805255/article/details/97106652

[5] 张蓓蓓,胡敏.基于网格搜索改进随机森林的顾客满意度预测[J].北京信息科技大学学报(自然科学版),2021,36(04):50-53+58.DOI:10.16508/j.cnki.11-5866/n.2021.04.010.

[6] 蒲峥屹,李云飞.基于网格搜索支持向量机的个人信用等级评分预测[J].市场研究,2020,No.491(03):33-36.DOI:10.13999/j.cnki.scyj.2020.03.011.

[7] 朱晓晨,尹奇志,赵福芹,钱巍文,赵奎奎.基于 LightGBM 的船舶航速预测模型研究[J/OL].大连海事大学学报:1-9[2023-01-19].

[8] 王维虎,刘艳超,杨雷,纪慎思.基于决策树的家庭垃圾分类模型的研究[J].湖北工程学院学报,2022,42(06):68-71.

[9] 胡玉红,张明辉,鲍晓青,孙炜,鲍勇,郭丽君.基于有序 Logistic 回归与决策树的上海市中医家庭康复满意度调查及影响因素分析[J].中国康复理论与实践,2022,28(10):1159-1168.

[7] 颜佳,黄一,王晓娜.基于交叉验证梯度提升决策树的管道腐蚀速率预测[J].腐蚀与防护,2021,42(11):68-74.

[8] 吴菲菲. 中国移动石河子分公司顾客满意度提升策略研究[D].石河子大学,2022.DOI:10.27332/d.cnki.gshzu.2022.001202.

[9] 徐知彬. 基于客户满意度的 H 市联通公司服务质量提升策略研究[D].石家庄铁道大学,2022.DOI:10.27334/d.cnki.gstdy.2022.000466.

[10] 唐忠川. 中国移动 T 市公司客户满意度提升策略研究[D].电子科技大学,2021.DOI:10.27005/d.cnki.gdzku.2021.005255.