队伍编号	MCB2201818
赛道	B

北京移动用户体验影响因素研究

摘 要

针对问题一，题目要求我们研究出语音业务和上网业务客户满意度的主要因素，并将各因素对客户打分影响程度进行量化分析。首先对所给**数据进行预处理**，因为个别缺省值过多的指标的数据缺失占比达到**70%以上**，所以将这些指标丢弃。其次对部分缺省值非常少的指标数据直接丢弃。根据附件五的字段说明，再根据指标的数据特征，将部分具有共性的指标进行**整合**。再者，我们利用**stata软件创建虚拟变量**，将对定性的指标编码采用**one-hot编码**，用于多元线性回归模型；同时我们也采用**Label encoding的方法**将某些定性的指标编码为自定义的数字标签完成量化编码，将离散的指标数据转化为连续的指标数据处理并用于Lasso回归模型。我们对于问题一的进一步求解**建立了多元线性回归模型和Lasso回归模型**。在多元线性回归模型中，我们首先进行了指标和客户满意度打分的相关性的分析，得到了相关系数矩阵图，发现部分指标与客户满意度具有较强的相关性，于是建立多元线性回归模型。其次因为发现多个指标具有**多重共线性问题**，因此**采用逐步回归法**进行变量选择，最终得到**“最优”多元线性回归模型**。在Lasso回归模型中，运用Lasso回归进行变量选择，检验经过筛选处理后变量的**显著性**，最终确定对满意度打分有显著影响的因素。然后**对两个模型的结果综合筛选分析整合**，最终得到**语音整体满意度得分等8个指标的主要影响因素和对应权重分布**。

针对问题二，题目要求我们根据问题一的分析分别建立客户语音业务、上网业务客户打分的相关影响因素的数学模型，且根据附件进行预测并说明预测的合理性。首先，我们根据问题一的结果分析，对附件 3、4 进行类似的**数据预处理**，其次基于问题一筛选后得到的语音整体满意度等八个指标的所有的主要影响因素，再分别建立对客户语音业务和上网业务客户打分的影响因素**随机森林模型**。再者，根据随机森林模型和附件 3、4 的相关数据进行**预测**。最终我们对其测试集的数据进行 RMS **均方根误差分析和精度大小分析**来验证预测的合理性。

关键词：数据预处理、多元线性回归模型、Lasso 回归模型、逐步回归法、随机森林模型、RMS 均方根误差分析和精度大小分析

目录

目录 2
一、问题重述 1
1.1 问题背景 1
1.2 问题重述 1
二、问题分析 1
2.1 问题一的分析 1
2.2 问题二的分析 2
三、模型假设与符号说明 3
3.1 模型假设 3
3.2 符号说明 3
四、问题一的求解 3
4.1 数据预处理 3
4.1.1 附件一的数据预处理 3
4.1.2 附件二的数据预处理 5
4.2 多元线性回归模型和 Lasso 回归模型的建立和求解 6
4.2.1 逐步回归模型 6
4.2.2 相关性分析 7
4.2.3 初步建立多元线性回归模型 9
4.2.4 Lasso 回归模型 12
4.2.5 结果分析整合 13
五、问题二的求解 20
5.1 数据预处理 20
5.1.1 附件三的数据预处理 20
5.1.2 附件四的数据预处理 21
5.2 随机森林模型的建立和求解 22
5.2.1 建立随机森林模型 22
5.2.3 模型求解 24
六、模型的评价 26
6.1 模型的评价 26
6.1.1 模型的优点 26
6.1.2 模型的缺点 27
七、参考文献 27
附录 28
问题一的代码 30
问题二的代码 38

一、问题重述

1.1 问题背景

移动通信技术飞速发展，给人们带来了极大便利，人们也越来越离不开移动通信技术带来的各种便捷。各个移动运营商，越来越重视客户的网络使用体验，从而进一步提升网络服务质量。客户满意度是客户对运营商产品服务的满意程度，反映了客户期望与实际感知的产品服务之间的差异。在信息快速发展的今天，客户满意度成为各大运营商市场运营情况的重要体现。各大运营商运用数字经济的管理理念和技术手段，建立客户体验生态的全方位系统给测评体系，传统方法难以有效提升客户的满意度，于是想通过研究分析影响客户满意度的各种因素，为决策提供依据，从而实现更全面地提升客户满意度。

1.2 问题重述

针对问题一：根据附件1研究影响客户语音业务，根据附件2研究上网业务满意度的主要因素，整理分析后给出各因素对客户打分影响程度的量化分析和结果。

针对问题二：根据问题1的分析，分别建立对于客户语音业务、上网业务客户打分的相关影响因素的数学模型，并根据模型对附件3、4中的客户打分进行预测分析，将预测结果分别填写在result.xlsx的Sheet1“语音”和Sheet2“上网”两个工作表中，且说明分析预测的合理性。

二、问题分析

2.1 问题一的分析

对于问题一，题目要求我们研究出语音业务和上网业务客户满意度的主要因素，并将各因素对客户打分影响程度进行量化分析。首先对所给数据进行预处理，在这一阶段，首先，因为个别缺省值过多的指标的数据缺失占比达到70%以上，所以将这些指标丢弃。然后对部分缺省值非常少（只有几个）的指标，并且发现这些缺失是多个指标的公共缺失，对这几个用户的所有指标数据直接丢弃。其次根据附件五的字段说明，

再根据指标的数据特征，将部分具有共性的指标进行整合。再者，采用Label encoding的方法将某些定性的指标编码为自定义的数字标签完成量化编码，将离散的指标数据转化为连续的指标数据处理，（用于Lasso回归方法）；也需要对定性的指标编码（例如类别特征等）采用one-hot编码（用于多元线性回归模型），当然其实这一过程是利用Stata软件创建虚拟变量过程中进行处理的。然后分别采用逐步回归方法和Lasso研究语音业务和上网业务客户满意度的主要影响因素，并进行量化分析。在多元线性回归模型中，首先我们进行了指标和客户满意度打分的相关性的分析，得到了相关系数矩阵图（因为部分的指标数据是定序数据，不满足使用pearson相关系数的条件，因此我们使用spearman相关系数），发现部分指标与客户满意度具有较强的相关性，于是我们建立多元线性回归模型。其次因为发现多个指标具有多重共线性问题，因此采用逐步回归法进行变量选择，最终得到“最优”多元线性回归模型。在Lasso回归模型中，运用Lasso回归进行变量选择，检验经过筛选处理后变量的显著性，最终确定对满意度打分有显著影响的因素。然后对结果综合筛选分析整合，最终得到语音整体满意度得分等8个指标的主要影响因素和对应权重分布。对于结果的量化分析，由于通过标准回归系数可以直接比较各影响因素的重要程度，于是可用每个影响因素标准回归系数的绝对值除以方程式中所有影响因素标准回归系数绝对值之和，得出各自变量的影响权重。

2.2 问题二的分析

问题二主要需要我们根据问题一的分析分别建立客户语音业务、上网业务客户打分的相关影响因素的数学模型，且根据模型对附件 3，4 中客户打分进行预测并说明预测的合理性。首先，我们根据问题一的分析，对附件 3、4 进行类似的数据预处理，然后基于问题一分析得到的语音整体满意度等八个指标的所有主要影响因素，不是只取第一题的最终每个得分的前四个影响因素，而是取用所有的影响因素（权重分布图重展示的），再分别建立对客户语音业务和上网业务客户打分的影响因素随机森林模型。再者，根据随机森林模型和附件 3、4 的相关数据进行预测。最终我们需要对其测试集的数据进行 RMS 均方根误差分析和精度大小分析来验证预测的合理性。

三、模型假设与符号说明

3.1 模型假设

1、假设客户打分的偏好短期内不会变化

2、假设数据预处理之后的数据均为准确数据

3、假设问题一中spearman相关系数能代表其影响因素对于因变量的影响程度

4.假设问题二中的使用的问题一的结果是可靠的

3.2 符号说明

符号	意义
y_i	第i个因变量
β_i	第i个回归系数
x_i	第i个自变量
δ_i	第i个虚拟变量相对回归系数

注: 未列出符号及重复的符号以出现处为准

四、问题一的求解

4.1 数据预处理

4.1.1 附件一的数据预处理

根据附件一的数据，可以发现用户描述里有很多个不同的地点且没有共同性，于是选择将用户描述这一栏指标给剔除；重定向次数和重定向时长都分别有 4260 的空白且附件五没有说明空白为 0 即为缺失值，所以我们将这两个指标给剔除；终端类型指标的数据没有共同性，所以我们也选择将这一栏给剔除；我们再发现终端类型为空白的用户 id 中，是否 4G 网络客户（本地剔除物联网）、终端品牌、是否 5G 网络客户、是否实名登记用户、客户星级标识、当月欠费金额、前第 3 个月欠费金额都为空白，且附件五说明了原数据表中除上述特别说明外，其余的有空格的都是情况未知，即数据缺失，且一共有 5433 个用户，5 个用户 id 的占比极小，所以我们选择将这 5 个用户 id 给舍去；再者，根据附件五的字段说明，再根据指标的数据特征，将部分指标进行整合，如下表：

进行整合的指标	整合后的指标
居民小区；办公室；高校；商业街；农村；高铁；其他，请注明	**用户所在场景种类个数**
手机没有信号；有信号无法拨通；通话过程中突然中断；通话中有杂音。听不清、断断续续；串线；通话过程中一方听不见；其他，请注明	**用户通话过程中的网络问题个数**

表 4-1-1

然后我们将是否关怀用户、是否去过营业厅的空白为否补齐；我们采用 Label encoding 的方法将定性的指标例如：是否遇到过网络问题、4\5G 用户、语音方式、是否关怀用户、是否去过营业厅、是否 4G 网络客户（本地剔除物联网）、是否 5G 网络客户、是否实名登记用户、终端品牌客户星级标识的数据编码为自定义的数字标签完成量化编码，部分具体的数据量化过程如下表，详细见附录，

原始数据	量化之后的编码
是	1
否	0
2G	1
4G	2

表 4-1-2

描述统计	N统计	最小值	最大值	均值	标准 错误	标准 偏差	方差	偏度	峰度
语音通话整体满意度	5426	1	10	8.68	0.031	2.259	5.104	-2.102	3.801
网络覆盖与信号强度	5426	1	10	8.34	0.033	2.418	5.847	-1.692	2.107
语音通话清晰度	5426	1	10	8.64	0.03	2.201	4.845	-2.025	3.656
语音通话稳定性	5426	1	10	8.43	0.032	2.372	5.628	-1.79	2.494
用户所在场景种类个数	5426	0	8	1.14	0.02	1.438	2.067	1.45	2.199
用户通话过程中的网络问题个数	5426	0	7	1.33	0.022	1.593	2.538	1.015	0.064
脱网次数	5426	0	1275	7.74	0.46	33.904	1149.454	16.137	441.614
mos质差次数	5426	0	110	4.76	0.102	7.526	56.641	4.167	30.759
未接通掉话次数	5426	0	86	0.86	0.035	2.589	6.701	11.738	271.379
家宽投诉	5426	0	2	0.03	0.003	0.2	0.04	6.938	52.475
ARPU（家庭宽带）	5426	0	199	0.619	0.08539	6.28974	39.561	15.998	325.666
套外流量（MB）	5426	0	7607.34	24.328	3.45241	254.30951	64673.328	18.934	442.326
套外流量费（元）	5426	0	500	2.3644	0.21846	16.09191	258.95	14.203	286.339
外省语音占比	5426	0	1	0.05317593	0.00285	0.20965763	0.044	4.031	14.742
语音通话-时长（分钟）	5426	0	29493	463.73	8.926	657.516	432327.075	18.453	722.841
省际漫游-时长（分钟）	5426	0	3477	26.1	2.163	159.352	25392.965	11.836	185.912
当月ARPU	5426	0	892.72	85.1627	0.92962	68.4774	4689.154	2.37	11.915
当月MOU	5426	0	29493	463.73	8.926	657.516	432327.075	18.453	722.841
前3月ARPU	5426	0	199	0.619	0.08539	6.28974	39.561	15.998	325.666
前3月MOU	5426	0	31066	463.59	8.593	632.981	400665.41	22.336	1012.62
外省流量占比	5426	0	1	0.05464224	0.00289	0.21259103	0.045	3.974	14.278
GPRS总流量（KB）	5426	0	1892486521	18073389.5	440335	32435719.7	1.05208E+15	36.514	2061.49
GPRS-国内漫游-流量（KB）	5426	0	174541422	974416.31	81992.7	6039695.43	3.64779E+13	12.137	221.404
当月欠费金额	5426	0	400	3.7217	0.32658	24.05603	578.693	8.897	98.044
前第3个月欠费金额	5426	0	848.99	3.8856	0.35469	26.12679	682.609	13.12	289.546
是否遇到过网络问题	5426	0	1	0.53	0.007	0.499	0.249	-0.106	-1.99
4\3用户	5426	1	3	2.38	0.007	0.497	0.247	0.36	-1.514
语音方式	5426	1	5	2.84	0.016	1.182	1.397	-0.156	-1.587
是否关怀用户	5426	0	1	0.04	0.003	0.188	0.036	4.917	22.19
是否去过营业厅	5426	0	1	0.45	0.007	0.498	0.248	0.19	-1.965
是否4G网络客户（本地剔除物联网）	5426	0	1	0.99	0.001	0.077	0.006	-12.91	164.721
是否5G网络客户	5426	0	1	0.38	0.007	0.486	0.237	0.477	-1.773
是否实名登记用户	5426	0	1	0.09	0.004	0.293	0.086	2.772	5.688
终端品牌	5426	1	27	11.89	0.075	5.538	30.673	0.365	-0.657
客户星级标识	5426	1	9	5.15	0.013	0.946	0.896	-0.532	4.402

表 4-1-3 描述性统计

4.1.2 附件二的数据预处理

根据附件二的数据，可以发现年龄为 0 的 id 用户有 18 个，年龄为 0 明显不符合实际，因此我们将这 18 个用户给舍去；我们也发现指标王者荣耀使用天数和王者荣耀使用次数分别隶属于指标游戏类 APP 使用天数和游戏类 APP 使用次数，因此我们将指标王者荣耀使用天数和王者荣耀使用次数删掉；再者，根据附件五的字段说明，再根据指标的数据特征，将部分指标进行整合，如下表：

进行整合的指标	整合后的指标
居民小区；办公室；高校；商业街；农村；高铁；其他，请注明；场景数据备注	**用户所在场景种类个数**
网络信号差/没有信号；显示有信号上不了网；上网过程中网络时断时续或时快时慢；手机上网速度慢；其他，请注明；现象备注数据	**用户上网过程中的网络问题种类个数**
看视频卡顿；打游戏延时大；打开网页或 APP 图片慢；下载速度慢；手机支付较慢；其他，请注明；APP 大类备注	**用户上网过程中的体验问题种类个数**
爱奇艺；优酷；腾讯视频；芒果 TV；搜狐视频；抖音；快手；火山；咪咕视频；其他，请注明；APP 小类备注	**用户上网过程中视频 APP 的体验问题种类个数**
和平精英；王者荣耀；穿越火线；梦幻西游；龙之谷；梦幻诛仙；欢乐斗地主；部落冲突；炉石传说；阴阳师；其他，请注明；APP 小类游戏备注，全部游戏都卡顿	**用户上网过程中游戏 app 的体验问题种类个数**
微信；手机 QQ；淘宝；京东；百度；近日头条；新浪微博；拼多多；其他，请注明；APP 小类上网备注；全部网页或 APP 都慢	**生活类问题种类个数**

表4-1-4

我们采用 Label encoding 的方法将定性的指标例如：是否全月漫游用户、是否不限量套餐到达用户、性别、是否 5G 网络客户、是否校园套餐用户、校园卡无校园合约用户、校园卡校园合约捆绑用户、高单价超套客户（集团）、高频高额超套客户（集团）、当月高频通信分公司、是否全部都卡顿、是否全部游戏都卡顿、是否全部网页或 APP 都慢、终端制式、终端品牌、客户星级标识的数据编码为自定义的数字标签完成量化编码，部分具体的数据量化过程如下表，详细见附录，

原始数据	量化之后的编码
是	1
否	0
一星	1
二星	2

表4-1-5

描述统计	N	最小值	最大值	均值	标准 错误	标准 偏差	方差	偏度	峰度
手机上网整体满意度	7002	1	10	7.8	0.032	2.705	7.318	-1.237	0.507
网络覆盖与信号强度	7002	1	10	7.63	0.032	2.694	7.259	-1.105	0.234
手机上网速度	7002	1	10	7.64	0.032	2.669	7.125	-1.109	0.268
手机上网稳定性	7002	1	10	7.55	0.033	2.745	7.533	-1.055	0.074
用户所在场景种类个数	7002	0	7	1.05	0.015	1.287	1.657	1.417	2.107
用户上网过程中的网络问题种类个数	7002	0	5	1.29	0.016	1.352	1.827	0.629	-0.9
用户上网过程中的体验问题种类个数	7002	0	6	0.85	0.015	1.259	1.586	1.488	1.374
户上网过程中视频app的体验问题种类个	7002	0	9	0.36	0.013	1.064	1.132	3.908	17.905
户上网过程中游戏app的体验问题种类个	7002	0	10	0.1	0.007	0.553	0.306	10.427	149.751
生活类问题种类个数	7002	0	9	0.59	0.017	1.409	1.985	2.707	7.354
上网质差次数	7002	0	106	0.45	0.035	2.913	8.484	17.853	448.159
脱网次数	7002	0	1744	5.45	0.471	39.373	1550.236	24.99	877.973
重定向次数	7002	0	23422	141.4	5.873	491.468	241540.4	18.817	751.342
2G驻留时长	7002	0	71837440	677105.16	27330.3	2286944.24	5.23011E+12	9.369	182.28
微信质差次数	7002	0	224	0.78	0.048	4.036	16.289	28.697	1397.18
王者荣耀质差次数	7002	0	37	0.41	0.029	2.409	5.801	7.292	58.395
套外流量（MB）	7002	0	16126.02	34.442	4.47145	374.16155	139996.867	22.696	700.711
套外流量费（元）	7002	0	500	3.0732	0.19321	16.16732	261.382	12.317	242.382
年龄	7002	15	91	44.52	0.152	12.73	162.048	0.455	-0.359
游戏类APP使用天数	7002	0	30	4.19	0.071	5.931	35.181	2.219	5.092
游戏类APP使用次数	7002	0	37874	413.68	22.395	1873.991	3511841.918	10.533	144.525
APP使用流量	7002	0	52056909.7	922337.204	43920.6	92233.7204	1.3507E+13	5.305	38.363
当月GPRS资源使用量（GB）	7002	0	344.7775	21.110331	0.30156	25.2338927	636.749	3.255	18.588
畅享套餐档位	7002	0	489	21.45	0.543	45.406	2061.714	3.392	17.907
主套餐档位	7002	0	598	64.92	0.814	68.107	4638.527	1.923	6.692
当月MOU	7002	0	5017	275.61	4.601	385.018	148238.521	3.639	20.614
近3个月平均消费（元）	7002	0	724.03	76.7307	0.76093	63.67321	4054.278	2.522	11.908
本年累计消费（元）	7002	0	2652.1	307.9836	3.01296	252.11844	63563.705	2.457	10.947
是否全月漫游用户	7002	0	1	0.05	0.003	0.213	0.045	4.245	16.026
是否不限量套餐到达用户	7002	0	1	0.14	0.004	0.346	0.12	2.085	2.346
性别	7002	1	3	1.44	0.007	0.601	0.361	1.026	0.031
是否5G网络客户	7002	0	1	0.45	0.006	0.498	0.248	0.193	-1.963
是否校园套餐用户	7002	0	1	0.05	0.003	0.21	0.044	4.328	16.739
校园卡无校园合约用户	7002	0	1	0	0.001	0.048	0.002	20.852	432.937
校园卡校园合约捆绑用户	7002	0	1	0.04	0.002	0.205	0.042	4.457	17.867
高单价超套客户（集团）	7002	0	1	0.07	0.003	0.249	0.062	3.493	10.202
高频高额超套客户（集团）	7002	0	1	0.01	0.001	0.12	0.014	8.105	63.708
当月高频通信分公司	6986	0	12	3.93	0.036	3.031	9.184	1.16	0.535
是否全部都卡顿	7002	0	1	0.05	0.003	0.209	0.044	4.336	16.806
是否全部游戏都卡顿	7002	0	1	0.02	0.002	0.133	0.018	7.253	50.627
是否全部网页或APP都慢	7002	0	1	0.07	0.003	0.252	0.064	3.424	9.73
终端制式	7002	1	3	2.55	0.006	0.504	0.254	-0.259	-1.745
终端品牌	7002	1	34	12.43	0.071	5.924	35.099	0.296	-0.741
客户星级标识	7002	1	9	4.99	0.012	1.001	1.001	-0.546	3.225

表4-1-6 描述性统计

4.2 多元线性回归模型和 Lasso 回归模型的建立和求解

4.2.1逐步回归模型

逐步回归[1]是一种按解释变量对被解释变量影响的显著程度，逐个的将变量引入（或剔除）回归方程的分析方法，是在多变量的情况下筛选重要变量，使用逐步回归分析的方法能较好避免解释变量之间产生多重共线性，且抛去了繁重的变量筛选过程。

考虑含有K个解释变量的线性总体回归模型式(1)和普通最小二乘法下的样本回归模型式(2):

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \ldots + \beta_k x_{ki} + \mu_i \qquad (1)$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + ... + \hat{\beta}_k x_{ki} + \hat{\mu}_i \quad (2)$$

有总离差平方和TSS、残差平方和ESS、回归平方和RSS:

$$TSS = \sum_{i=1}^{n} (y_i - \overline{y})^2$$

$$ESS = \sum_{i=1}^{n} \left(\hat{y}_i - \overline{y}\right)^2$$

$$RSS = \sum_{i=1}^{n} \left(y_i - \hat{y}\right)^2$$

其中$\hat{y}_i = y_i - \hat{\mu}_i$为样本拟合值，$\overline{y}$为样本均值，n为样本容量。则不含$x_k$的样本回归模型为：

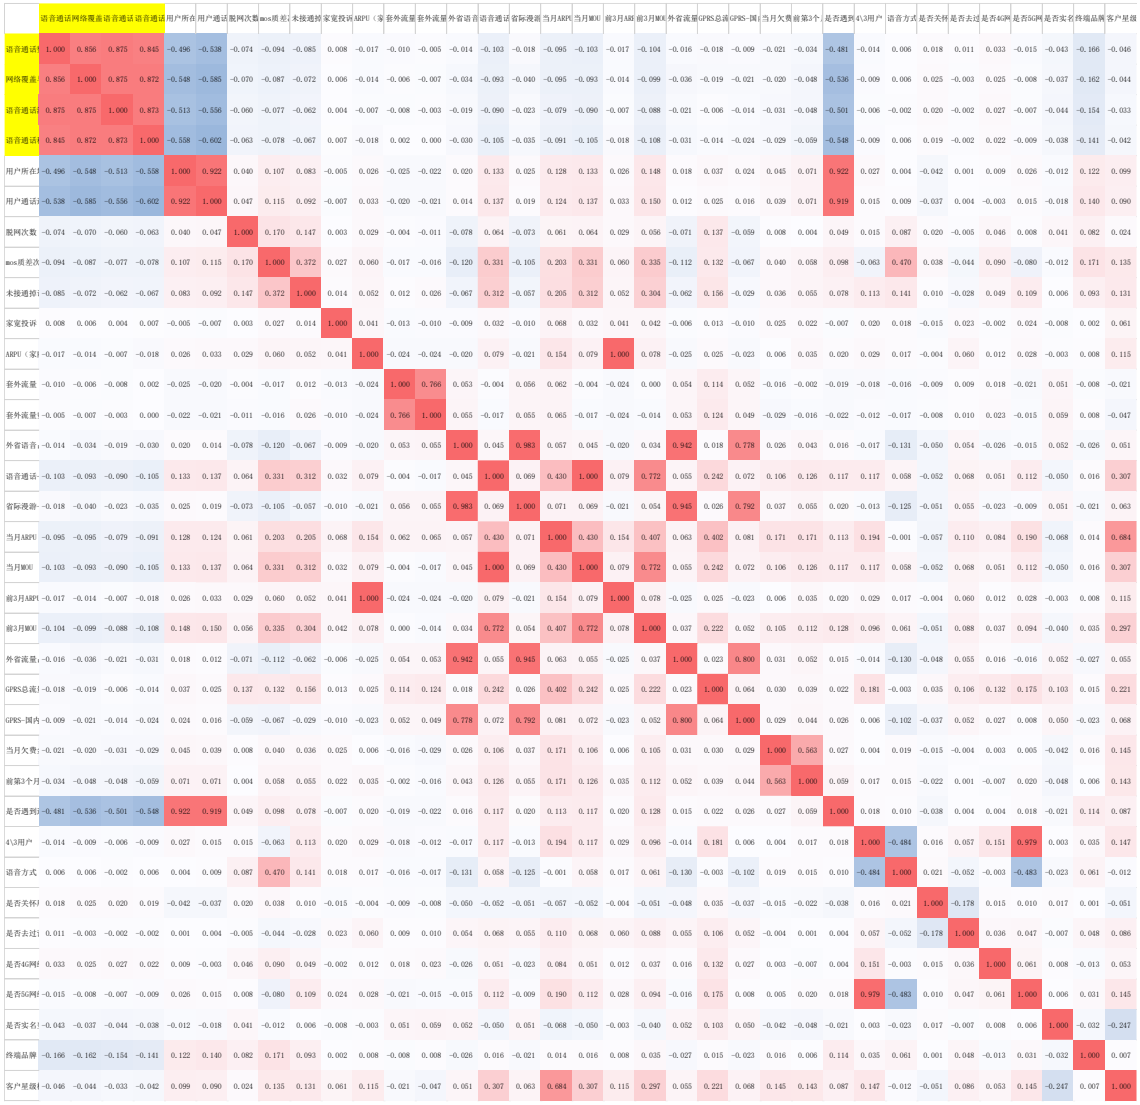
$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + ... + \hat{\beta}_{k-1} x_{(k-1)i} + \hat{\mu}_i \quad (i = 1, ..., n)$$

假设上式的残差平方和为ESS^*,回归平方和为RSS^*,则x_k的偏回归平方和为：$ESSP_k = ESS - ESS^*$.同理可定义其他解释变量的偏回归平方和，可得$RSSP_k = RSS - RSS^*$。逐步回归方法是以偏回归平方和最大（最小）的准则来引入（剔除）自变量的。在引入（剔除）步骤中，假设模型已含有k-1(k)个全部显著的解释变量，在引入第k个（剔除某个）解释变量后，原模型和引入（剔除)变量之后的样本模型则可表示为式(1)和式(2)。通过F检验以判断解释变量是否该引入回归模型中。由x_k的偏回归平方和$ESSP_k$得到的F统计量为：

$$F = \frac{ESSP_k}{RSS/(n-k-1)} = \frac{ESS - ESS^*}{RSS/(n-k-1)} \sim F(1, n-k-1) \quad (3)$$

4.2.2相关性分析

相关分析是进行回归分析的基础，对多变量进行回归分析之前需要对因变量与各个自变量之间进行相关关系分析，因为部分的指标数据是定序数据，不满足使用pearson 相关系数的条件，于是我们选择使用 spearman 相关系数，在统计学中，通常用相关系数描述两个变量之间的相关程度，它是研究变量之间线性相关程度的量，当相关系数0时通常认为两变量之间不存在线性关系，但并不能排除其是否存在其他关系。相关系数矩阵图如下：



	语音通话网络覆盖	语音通话	语音通话	用户所在	用户通话	脱网次数	mos质差次	未接通掉	家宽投诉	ARPU（家	套外流量	套外流量	外省语音	语音通话	省际漫游	当月ARPU	当月MOU	前3月ARP	前3月MOU	外省流量	GPRS总流	GPRS-国内	当月欠费	前第3个	是否遇到	4\3用户	语音方式	是否关怀	是否去过	是否4G网	是否5G网	是否实名	终端品牌	客户星级
语音通话网络覆盖	1.000	0.856	0.875	0.845	-0.496	-0.538	-0.074	-0.094	-0.085	0.008	-0.017	-0.010	-0.005	-0.014	-0.103	-0.018	-0.095	-0.103	-0.017	-0.104	-0.016	-0.018	-0.009	-0.021	-0.034	-0.481	-0.014	0.006	0.018	0.011	0.033	-0.015	-0.043	-0.166	-0.046
网络覆盖	0.856	1.000	0.875	0.872	-0.548	-0.585	-0.070	-0.087	-0.072	0.006	-0.014	-0.006	-0.007	-0.034	-0.093	-0.040	-0.095	-0.093	-0.014	-0.099	-0.036	-0.019	-0.021	-0.020	-0.048	-0.536	-0.009	0.006	0.025	-0.003	0.025	-0.008	-0.037	-0.162	-0.044
语音通话	0.875	0.875	1.000	0.873	-0.513	-0.556	-0.060	-0.077	-0.062	0.004	-0.007	-0.008	-0.003	-0.019	-0.090	-0.023	-0.079	-0.090	-0.007	-0.088	-0.021	-0.006	-0.014	-0.031	-0.048	-0.501	-0.006	-0.002	0.020	-0.002	0.027	-0.007	-0.044	-0.154	-0.033
语音通话	0.845	0.872	0.873	1.000	-0.558	-0.602	-0.063	-0.078	-0.067	0.007	-0.018	0.002	0.000	-0.030	-0.105	-0.035	-0.091	-0.105	-0.018	-0.108	-0.031	-0.014	-0.024	-0.029	-0.059	-0.548	-0.009	0.006	0.019	-0.002	0.022	-0.009	-0.038	-0.141	-0.042
用户所在	-0.496	-0.548	-0.513	-0.558	1.000	0.922	0.040	0.107	0.083	-0.005	0.026	-0.025	-0.022	0.020	0.133	0.025	0.128	0.133	0.026	0.148	0.018	0.037	0.024	0.045	0.071	0.922	0.027	0.004	-0.042	0.001	0.009	0.026	-0.012	0.122	0.099
用户通话	-0.538	-0.585	-0.556	-0.602	0.922	1.000	0.047	0.115	0.092	-0.007	0.033	-0.020	-0.021	0.014	0.137	0.019	0.124	0.137	0.033	0.150	0.012	0.025	0.016	0.039	0.071	0.919	0.015	0.009	-0.037	0.004	-0.003	0.015	-0.018	0.140	0.090
脱网次数	-0.074	-0.070	-0.060	-0.063	0.040	0.047	1.000	0.170	0.147	0.003	0.029	-0.004	-0.011	-0.078	0.064	-0.073	0.061	0.064	0.029	0.056	-0.071	0.137	-0.059	0.008	0.004	0.049	0.015	0.087	0.020	-0.005	0.046	0.008	0.041	0.082	0.024
mos质差次	-0.094	-0.087	-0.077	-0.078	0.107	0.115	0.170	1.000	0.372	0.027	0.060	-0.017	-0.016	-0.120	0.331	-0.105	0.203	0.331	0.060	0.335	-0.112	0.132	-0.067	0.040	0.068	0.098	-0.063	0.470	0.038	-0.044	0.090	-0.080	-0.012	0.171	0.135
未接通掉	-0.085	-0.072	-0.062	-0.067	0.083	0.092	0.147	0.372	1.000	0.014	0.052	0.012	0.026	-0.067	0.312	-0.057	0.205	0.312	0.052	0.304	-0.062	0.156	-0.029	0.036	0.055	0.078	0.113	0.141	0.010	-0.028	0.049	0.109	0.006	0.093	0.131
家宽投诉	0.008	0.006	0.004	0.007	-0.005	-0.007	0.003	0.027	0.014	1.000	0.041	-0.013	-0.010	-0.009	0.032	-0.010	0.068	0.032	0.041	0.042	-0.006	0.013	-0.010	0.025	0.022	-0.007	0.020	0.018	-0.015	0.023	-0.002	0.024	-0.008	0.002	0.061
ARPU（家	-0.017	-0.014	-0.007	-0.018	0.026	0.033	0.029	0.060	0.052	0.041	1.000	-0.024	-0.024	-0.020	0.079	-0.021	0.154	0.079	1.000	0.078	-0.025	0.025	-0.023	0.006	0.035	0.020	0.029	0.017	-0.004	0.060	0.012	0.028	-0.003	0.008	0.115
套外流量	-0.010	-0.006	-0.008	0.002	-0.025	-0.020	-0.004	-0.017	0.012	-0.013	-0.024	1.000	0.766	0.053	-0.004	0.056	0.062	-0.004	-0.024	0.000	0.054	0.114	0.052	-0.016	-0.002	-0.019	-0.018	-0.016	-0.009	0.009	0.018	-0.021	0.051	-0.008	-0.021
套外流量	-0.005	-0.007	-0.003	0.000	-0.022	-0.021	-0.011	-0.016	0.026	-0.010	-0.024	0.766	1.000	0.055	-0.017	0.055	0.065	-0.017	-0.024	-0.014	0.053	0.124	0.049	-0.029	-0.016	-0.022	-0.012	-0.017	-0.008	0.010	0.023	-0.015	0.059	0.008	-0.047
外省语音	-0.014	-0.034	-0.019	-0.030	0.020	0.014	-0.078	-0.120	-0.067	-0.009	-0.020	0.053	0.055	1.000	0.045	0.983	0.057	0.045	-0.020	0.034	0.942	0.018	0.778	0.026	0.043	0.016	-0.017	-0.131	-0.050	0.054	-0.026	-0.015	0.052	-0.026	0.051
语音通话	-0.103	-0.093	-0.090	-0.105	0.133	0.137	0.064	0.331	0.312	0.032	0.079	-0.004	-0.017	0.045	1.000	0.069	0.430	1.000	0.079	0.772	0.055	0.242	0.072	0.106	0.126	0.117	0.117	0.058	-0.052	0.068	0.051	0.112	-0.050	0.016	0.307
省际漫游	-0.018	-0.040	-0.023	-0.035	0.025	0.019	-0.073	-0.105	-0.057	-0.010	-0.021	0.056	0.055	0.983	0.069	1.000	0.071	0.069	-0.021	0.054	0.945	0.026	0.792	0.037	0.055	0.020	-0.013	-0.125	-0.051	0.055	-0.023	-0.009	0.051	-0.021	0.063
当月ARPU	-0.095	-0.095	-0.079	-0.091	0.128	0.124	0.061	0.203	0.205	0.068	0.154	0.062	0.065	0.057	0.430	0.071	1.000	0.430	0.154	0.407	0.063	0.402	0.081	0.171	0.171	0.113	0.194	-0.001	-0.057	0.110	0.084	0.190	-0.068	0.014	0.684
当月MOU	-0.103	-0.093	-0.090	-0.105	0.133	0.137	0.064	0.331	0.312	0.032	0.079	-0.004	-0.017	0.045	1.000	0.069	0.430	1.000	0.079	0.772	0.055	0.242	0.072	0.106	0.126	0.117	0.117	0.058	-0.052	0.068	0.051	0.112	-0.050	0.016	0.307
前3月ARPU	-0.017	-0.014	-0.007	-0.018	0.026	0.033	0.029	0.060	0.052	0.041	1.000	-0.024	-0.024	-0.020	0.079	-0.021	0.154	0.079	1.000	0.078	-0.025	0.025	-0.023	0.006	0.035	0.020	0.029	0.017	-0.004	0.060	0.012	0.028	-0.003	0.008	0.115
前3月MOU	-0.104	-0.099	-0.088	-0.108	0.148	0.150	0.056	0.335	0.304	0.042	0.078	0.000	-0.014	0.034	0.772	0.054	0.407	0.772	0.078	1.000	0.037	0.222	0.052	0.105	0.112	0.128	0.096	0.061	-0.051	0.088	0.037	0.094	-0.040	0.035	0.297
外省流量	-0.016	-0.036	-0.021	-0.031	0.018	0.012	-0.071	-0.112	-0.062	-0.006	-0.025	0.054	0.053	0.942	0.055	0.945	0.063	0.055	-0.025	0.037	1.000	0.023	0.800	0.031	0.052	0.015	-0.014	-0.130	-0.048	0.055	0.016	-0.016	0.052	-0.027	0.055
GPRS总流	-0.018	-0.019	-0.006	-0.014	0.037	0.025	0.137	0.132	0.156	0.013	0.025	0.114	0.124	0.018	0.242	0.026	0.402	0.242	0.025	0.222	0.023	1.000	0.064	0.030	0.039	0.022	0.181	-0.003	0.035	0.106	0.132	0.175	0.103	0.015	0.221
GPRS-国内	-0.009	-0.021	-0.014	-0.024	0.024	0.016	-0.059	-0.067	-0.029	-0.010	-0.023	0.052	0.049	0.778	0.072	0.792	0.081	0.072	-0.023	0.052	0.800	0.064	1.000	0.029	0.044	0.026	0.006	-0.102	-0.037	0.052	0.027	0.008	0.050	-0.023	0.068
当月欠费	-0.021	-0.020	-0.031	-0.029	0.045	0.039	0.008	0.040	0.036	0.025	0.006	-0.016	-0.029	0.026	0.106	0.037	0.171	0.106	0.006	0.105	0.031	0.030	0.029	1.000	0.563	0.027	0.004	0.019	-0.015	-0.004	0.003	0.005	-0.042	0.016	0.145
前第3个月	-0.034	-0.048	-0.048	-0.059	0.071	0.071	0.004	0.058	0.055	0.022	0.035	-0.002	-0.016	0.043	0.126	0.055	0.171	0.126	0.035	0.112	0.052	0.039	0.044	0.563	1.000	0.059	0.017	0.015	-0.022	0.001	-0.007	0.020	-0.048	0.006	0.143
是否遇到	-0.481	-0.536	-0.501	-0.548	0.922	0.919	0.049	0.098	0.078	-0.007	0.020	-0.019	-0.022	0.016	0.117	0.020	0.113	0.117	0.020	0.128	0.015	0.022	0.026	0.027	0.059	1.000	0.018	0.010	-0.038	0.004	0.004	0.018	-0.021	0.114	0.087
4\3用户	-0.014	-0.009	-0.006	-0.009	0.027	0.015	0.015	-0.063	0.113	0.020	0.029	-0.018	-0.012	-0.017	0.117	-0.013	0.194	0.117	0.029	0.096	-0.014	0.181	0.006	0.004	0.017	0.018	1.000	-0.484	0.016	0.057	0.151	0.979	0.003	0.035	0.147
语音方式	0.006	0.006	-0.002	0.006	0.004	0.009	0.087	0.470	0.141	0.018	0.017	-0.016	-0.017	-0.131	0.058	-0.125	-0.001	0.058	0.017	0.061	-0.130	-0.003	-0.102	0.019	0.015	0.010	-0.484	1.000	0.021	-0.052	-0.003	-0.483	-0.023	0.061	-0.012
是否关怀	0.018	0.025	0.020	0.019	-0.042	-0.037	0.020	0.038	0.010	-0.015	-0.004	-0.009	-0.008	-0.050	-0.052	-0.051	-0.057	-0.052	-0.004	-0.051	-0.048	0.035	-0.037	-0.015	-0.022	-0.038	0.016	0.021	1.000	-0.178	0.015	0.010	0.017	0.001	-0.051
是否去过	0.011	-0.003	-0.002	-0.002	0.001	0.004	-0.005	-0.044	-0.028	0.023	0.060	0.009	0.010	0.054	0.068	0.055	0.110	0.068	0.060	0.088	0.055	0.106	0.052	-0.004	0.001	0.004	0.057	-0.052	-0.178	1.000	0.036	0.047	-0.007	0.048	0.086
是否4G网	0.033	0.025	0.027	0.022	0.009	-0.003	0.046	0.090	0.049	-0.002	0.012	0.018	0.023	-0.026	0.051	-0.023	0.084	0.051	0.012	0.037	0.016	0.132	0.027	0.003	-0.007	0.004	0.151	-0.003	0.015	0.036	1.000	0.061	0.008	-0.013	0.053
是否5G网	-0.015	-0.008	-0.007	-0.009	0.026	0.015	0.008	-0.080	0.109	0.024	0.028	-0.021	-0.015	-0.015	0.112	-0.009	0.190	0.112	0.028	0.094	-0.016	0.175	0.008	0.005	0.020	0.018	0.979	-0.483	0.010	0.047	0.061	1.000	0.006	0.031	0.145
是否实名	-0.043	-0.037	-0.044	-0.038	-0.012	-0.018	0.041	-0.012	0.006	-0.008	-0.003	0.051	0.059	0.052	-0.050	0.051	-0.068	-0.050	-0.003	-0.040	0.052	0.103	0.050	-0.042	-0.048	-0.021	0.003	-0.023	0.017	-0.007	0.008	0.006	1.000	-0.032	-0.247
终端品牌	-0.166	-0.162	-0.154	-0.141	0.122	0.140	0.082	0.171	0.093	0.002	0.008	-0.008	0.008	-0.026	0.016	-0.021	0.014	0.016	0.008	0.035	-0.027	0.015	-0.023	0.016	0.006	0.114	0.035	0.061	0.001	0.048	-0.013	0.031	-0.032	1.000	0.007
客户星级	-0.046	-0.044	-0.033	-0.042	0.099	0.090	0.024	0.135	0.131	0.061	0.115	-0.021	-0.047	0.051	0.307	0.063	0.684	0.307	0.115	0.297	0.055	0.221	0.068	0.145	0.143	0.087	0.147	-0.012	-0.051	0.086	0.053	0.145	-0.247	0.007	1.000

图4-2-1

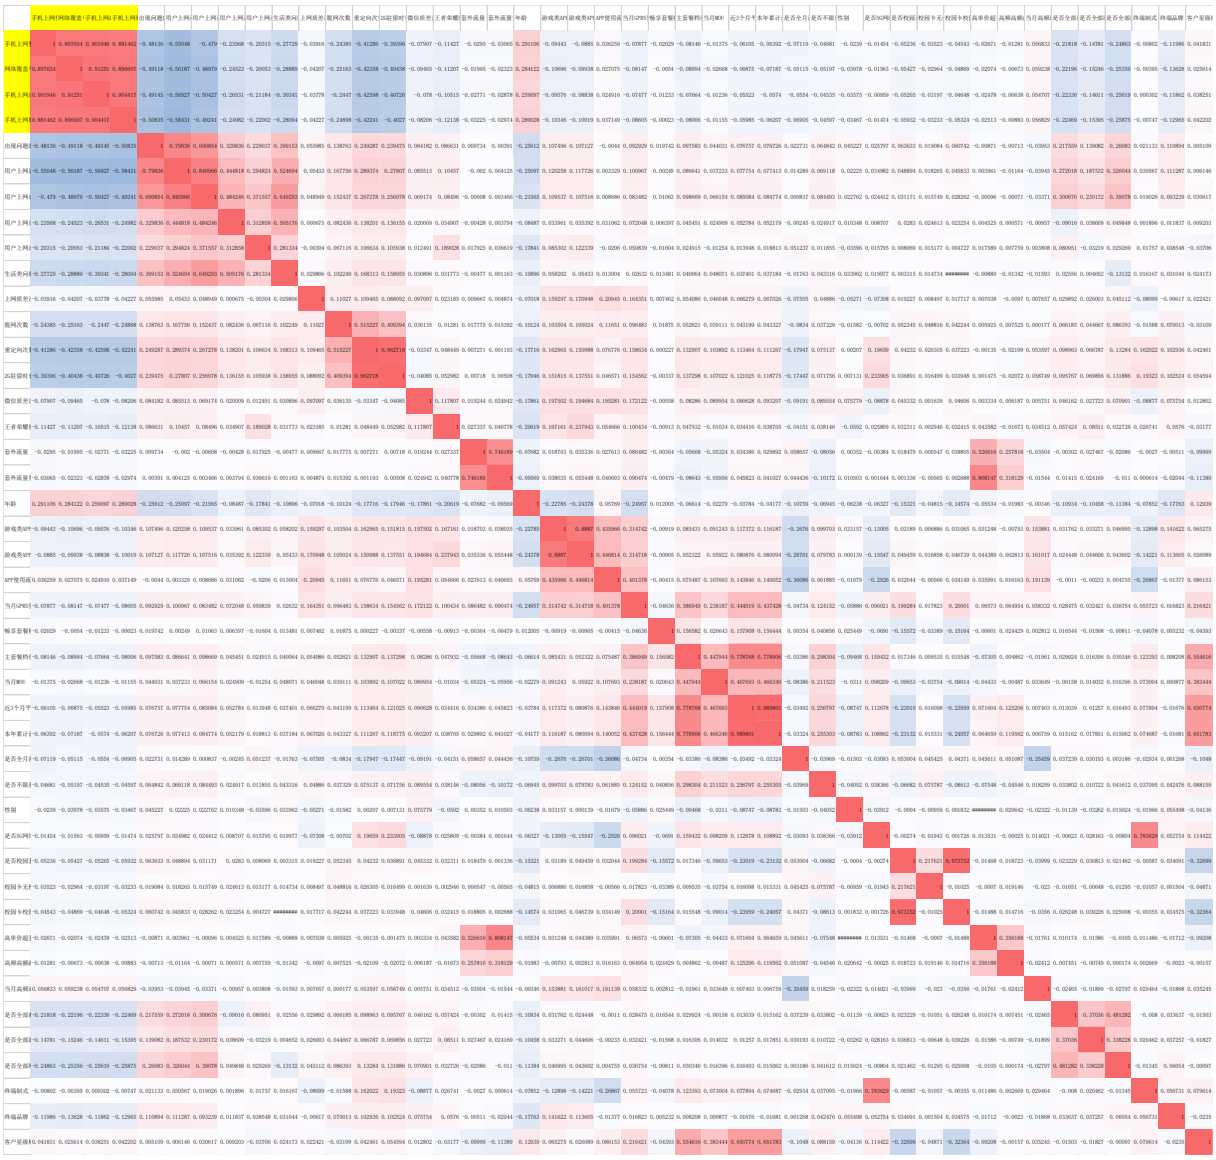


图 4-2-2

上两张图标黄的是因变量，其余都是自变量。从图4-2-1中可以看出语音通话整体满意度与用户所在场景种类个数、用户通话过程中的网络问题个数、是否遇到过网络问题有较强的相关性。从图4-2-2中可以看出上网整体满意度与出现问题的场景次数、用户上网过程中的网络问题种类个数、用户上网过程中的网络问题种类个数、重定向次数、2G驻留时长有较强的相关性，于是可以用多元线性回归分析本题。

4.2.3初步建立多元线性回归模型

1）**以语音通话整体满意度为因变量为例（其余七个因变量网络覆盖与信号强度、语音通话清晰度、语音通话稳定性、手机上网整体满意度、网络覆盖与信号强度、手机上网速度、手机上网稳定性同理处理）**，初步建立多元线性回归[2]方程，

$$y_i = \beta_0 + \delta_0 internet_problem_true_i + \delta_1 total_hold\ up_true_i ... + \beta_1 x_{1i} + \beta_2 x_{2i} + ... + \beta_k x_{ki} + \mu_i \quad (4)$$

$internet_problem_true_i$=1表示第i个样本为是有网络问题，$internet_problem_true_i$=0表示第i个样本为没有网络问题；$total_hold\ up_true_i$=1表示第i个样本为是全部都卡顿，$total_hold\ up_true_i$=0表示第i个样本为没有全部都卡顿，同理依次将其他定性变量转化为虚拟变量。

2）标准化回归系数

在多元线性回归中，通常各自变量取值的单位及其离散程度是不同的，所以量纲不同的各回归系数之间不能直接比较大小。为此，可先对所有的自变量和因变量进行标准化转换，之后估计标准化回归系数。标准化回归系数可以代表各自变量对因变量的重要程度，并用以比较各自变量对因变量的贡献大小。为了更为精准的研究影响满意度的重要因素（去除量纲的影响），我们可考虑使用标准化回归系数。标准化系数的绝对值越大，说明对因变量的影响就越大（只关注显著的回归系数）。

3）异方差检验

如图4-2-4所示，发现语音通话整体满意度分布非常不均匀，集中分布在9-10分之间，

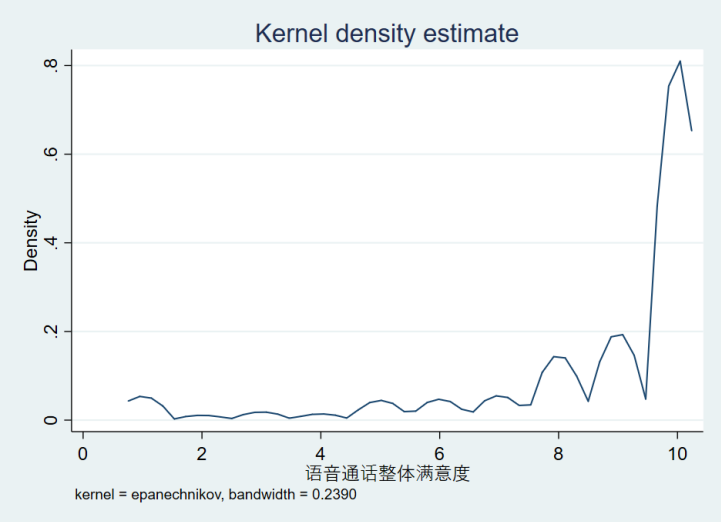


图4-2-3

利用**stata软件**使用进行异方差BP检验，发现其扰动项存在异方差，如图4-2-4所示，因此我们采用使用OLS + 稳健的标准误，消除异方差的影响。

```
. estat hettest ,rhs iid

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity
        Ho: Constant variance
        Variables: 用户所在场景种类个数 用户通话过程中的网络问题个数 脱网次数 mos质差次数 未接通掉话次数 家宽投诉 ARPU家庭宽带
                   套外流量MB 套外流量费元 外省语音占比 语音通话时长分钟 省际漫游时长分钟 当月ARPU 前3月MOU 外省流量占比
                   GPRS总流量KB GPRS国内漫游流量KB 当月欠费金额 前第3个月欠费金额 A1 C1 C2 C4 C5 D1 E1 F1 G1 H2 I1 I2 I3 I4 I5
                   I6 I7 I8 I9 I10 I11 I12 I13 I14 I15 I16 I17 I18 I19 I21 I22 I23 I24 I25 I26 I27 M1 M2 M3 M4 M5 M6 M7 M8

        chi2(63)     =   620.76
        Prob > chi2  =   0.0000
```

图4-2-4

所建立模型显著性检验的P值显著为0,说明该回归模型显著；但是各个系数的P值均比较大，并未能通过显著性检验，说明该回归方程可能具有多重共线性，于是对其进行VIF检验结果如图4-2-5所示（注：对应的字母是虚拟变量，虚拟变量对应的指标已在图右上侧标明）

Variable	VIF	Variable	VIF
I15	1308.92	M2	4.32
I7	1306.75	I16	4.05
C2	477.92	I11	4.02
C4	475.81	I6	4.02
I23	456.73	用户通话-数	3.68
I3	264.10	当月ARPU	3.57
I14	224.86	用户所在-数	3.14
C1	223.09	I24	3.04
M5	163.34	I10	3.03
M6	116.22	I5	3.02
M4	53.25	A1	3.00
I18	37.04	I19	2.06
G1	30.42	I12	2.01
M3	22.22	I13	2.01
I2	19.10	I17	2.01
M7	16.25	I8	2.01
C5	15.89	省际漫游-钟	1.91
外省流量占比	14.76	GPRS国内漫-B	1.85
外省语音占比	14.42	套外流量费元	1.68
I1	13.06	前第3个月-额	1.66
I22	12.07	当月欠费金额	1.57
F1	10.81	套外流量MB	1.42
M8	10.58	mos质差次数	1.33
I4	8.05	H2	1.26
M1	7.11	未接通掉-数	1.14
I27	7.06	GPRS总流量KB	1.12
I9	7.05	D1	1.07
I21	7.03	E1	1.07
I26	5.03	ARPU家庭宽带	1.06
I25	5.03	脱网次数	1.02
语音通话-钟	4.60	家宽投诉	1.01
前3月MOU	4.40		

是否遇到过	A
用户	B
语音方式	C
是否关怀月	D
否去过意义	E
是否4G网络	F
否5G网络套	G
是否实名登	H
终端品牌	I
客户星级标	M

图4-2-5

发现多个指标具有多重共线性问题，因此采用逐步回归方法，得到如下表所示结果。

变量名称	标准化回归系数
是否关怀用户	0.4809
否去过意业厅	-0.4635
未接通掉话次数	0.1472
是否实名登记用户	-0.1183
终端品牌	-0.0551
客户星级标识	-0.0520
用户通话过程中的网络问题个数	-0.0261
语音方式	-0.0225

表4-2-6

4.2.4 Lasso回归模型

Lasso回归[3]方法通过构造一个惩罚函数得到一个较为精炼的模型，达到压缩回归系数的目的，是一种处理具有复共线性数据的有偏估计。

岭回归无法降低模型复杂度，而Lasso回归是在岭回归基础上的优化，可以直接将系数惩罚压缩至零，达到降低模型复杂度的目的。Lasso回归的目标函数可以表示为：

$$L(b)=\sum(y-Xb)^2+\lambda||b||_1=\sum(y-Xb)^2+\sum\lambda|b| \qquad (5)$$

其中：$\lambda||b||_1$为函数的惩罚项，λ为惩罚系数；$||b||_1$为回归系数b的正则，表示所有回归系数绝对值的和。

以语音通话整体满意度为因变量为例（其余七个因变量网络覆盖与信号强度、语音通话清晰度、语音通话稳定性、手机上网整体满意度、网络覆盖与信号强度、手机上网速度、手机上网稳定性同理处理），使用Lasso回归对语音整体满意度的影响指标进行筛选处理后得到个影响因素的回归系数。

变量名称	回归系数
用户通话过程中的网络问题个数	-0.4156
用户所在场景种类个数	-0.0278
未接通掉话次数	-0.0017
是否4G网络客户（本地剔除物联网）	0.0992
是否实名登记用户	-0.0494
终端品牌	-0.0043

表4-2-7

从31个自变量中筛选得到6个符合要求的自变量，分别是用户通话过程中的网络问题个数、用户所在场景种类个数、未接通掉话次数、是否4G网络客户本地剔除物联网、是否实名登记用户、终端品牌，对应的回归系数见表5-2-7，另外25个变量对应的系数值为0，说明这25个变量对语音通话整体满意度指数没有显著意义。故可以将Lasso回归模型表达为：

$$Y = 9.6643 - 0.4156X_1 - 0.0278X_2 - 0.0017X_3 + 0.0992X_4 - 0.0494X_3 - 0.0043X_6$$

对经过筛选处理的变量参数进行检验，结果见表4-2-8

变量名称	参数估计	标准误.	t值	P值
用户通话过程中的网络问题个数	-0.6024	0.0399621	-15.0800	0
用户所在场景种类个数	-0.0914	0.0442351	-2.0700	0.039
未接通掉话次数	-0.0477	0.0206405	-2.3100	0.021
是否4G网络客户本地剔除物联网.	-2.1086	0.5619648	-3.7500	0
是否实名登记用户	-0.5974	0.1122457	-5.3200	0
终端品牌	-0.2938	0.0477303	-6.1500	0

表4-2-8

由表5-2-8可知，6个符合要求的自变量P值都小于了0.05，都通过了t检验，得到了最优模型，其中包含的影响因素为用户通话过程中的网络问题个数、用户所在场景种类个数、未接通掉话次数、是否4G网络客户本地剔除物联网、是否实名登记用户、终端品牌。

4.2.5 结果分析整合

以语音通话整体满意度为例，表4-2-9是运用逐步回归后得到的影响因素，表4-2-10是运用Lasso回归后得到的影响因素，

变量名称
是否关怀用户
否去过意业厅
未接通掉话次数
是否实名登记用户
终端品牌
客户星级标识
用户通话过程中的网络问题个数
语音方式

表4-2-9

变量名称
用户通话过程中的网络问题个数
用户所在场景种类个数
未接通掉话次数
是否4G网络客户本地剔除物联网.
是否实名登记用户
终端品牌

表4-2-10

将这两个表格进行整合，取其共同的影响因素，分别是用户通话过程中的网络问题个数、终端品牌、是否实名登记用户、未接通掉话次数这四个影响因素，再进行一

次回归分析，由于通过标准回归系数可以直接比较各影响因素的重要程度，于是可用每个影响因素标准回归系数的绝对值除以方程式中所有影响因素标准回归系数绝对值之和，得出各自变量的影响权重[4]，结果如表4-2-11所示。

语音通话整体满意度	标准化回归系	权重值
用户通话过程中的网络问题个数	-0.4435837	0.674611179
终端品牌	-0.0834859	0.126967067
是否实名登记用户	-0.0778913	0.118458685
未接通掉话次数	-0.0525789	0.079963068

表 4-2-11

于是我们也将其余 7 个因变量网络覆盖与信号强度、语音通话清晰度、语音通话稳定性、手机上网整体满意度、网络覆盖与信号强度、手机上网速度、手机上网稳定性的，分别运用逐步回归和 Lasso 回归进行分析，分别得到其影响因素，再进行对比整合，取其相同的影响因素，然后又进行一次回归分析，图 4-2-12 和图 4-2-13 是八个因变量逐步回归法和 Lasso 分别得出的影响因素的对比整合取相同因素的过程图，

逐步回归			Lasso回归	
语音通话整体满意度			语音通话整体满意度	
语音方式	0.3521		用户通话过程中的网络问题个数	0.566353233
用户通话过程中的网络问题个数	0.3394		用户所在场景种类个数	0.077504271
客户星级标识	0.1078		未接通掉话次数	0.072913287
终端品牌	0.0867		是否4G网络客户本地剔除物联网，	0.095280953
是否实名登记用户	0.0403		是否实名登记用户	0.10315803
未接通掉话次数	0.0381		客户星级标识	0.084790227
否去过营业厅	0.0191			
是否关怀用户	0.0165			
网络覆盖与信号强度			网络覆盖与信号强度	
用户通话过程中的网络问题个数	0.3882		用户通话过程中的网络问题个数	0.4194
否5G网络客户	0.169		终端品牌	0.1884
终端品牌	0.1228		用户所在场景种类个数	0.0639
语音方式	0.0904		是否遇到过网络问题	0.0637
是否遇到过网络问题	0.0627			
用户所在场景种类个数	0.0561			
是否实名登记用户	0.0526			
客户星级标识	0.0398			
是否关怀用户	0.0184			
客户星级标识	0.0398			
是否关怀用户	0.0184			
语音通话清晰度			语音通话清晰度	
用户通话过程中的网络问题个数	0.4981		用户通话过程中的网络问题个数	
语音方式	0.224			
终端品牌	0.1145			
客户星级标识	0.0922			
是否实名登记用户	0.055			
是否关怀用户	0.0163			
语音通话稳定性			语音通话稳定性	
用户通话过程中的网络问题个数	0.5296		是否遇到过网络问题	0.0912
终端品牌	0.1062		用户通话过程中的网络问题个数	0.9088
客户星级标识	0.089			
语音方式	0.0737			
是否遇到过网络问题	0.0718			
是否实名登记用户	0.0505			
未接通掉话次数	0.0485			
省际漫游时长分钟	0.0307			

图 4-2-12

逐步回归			Lasso回归	
手机上网整体满意度			手机上网整体满意度	
用户上网过程中的网络问题种类个数	0.2486		用户上网过程中的网络问题种类个数	0.3153
客户星级标识	0.1299		客户星级标识	0.2433
年龄	0.0884		年龄	0.1174
出现问题的场景次数	0.0713		出现问题的场景次数	0.0905
G驻留时长	0.0694		是否全部都卡顿	0.0695
是否全部都卡顿	0.0498		是否全部网页或APP都慢	0.058
终端品牌	0.045		是否全月漫游用户	0.0543
当月高频通信分公司	0.0445		G驻留时长	0.0519
是否全部网页或APP都慢	0.0439			
本年累计消费元	0.0433			
是否5G网络用户	0.0366			
用户上网过程中游戏app的体验问题种类个数	0.0331			
套外流量费元	0.0299			
是否全部游戏都卡顿	0.024			
校园卡校园合约捆绑用户	0.0223			
套外流量MB	0.0202			
网络覆盖与信号强度			网络覆盖与信号强度	
终端品牌	0.3306		用户上网过程中的网络问题种类个数	0.3131
用户上网过程中的网络问题种类个数	0.1733		客户星级标识	0.197
客户星级标识	0.0773		年龄	0.111
G驻留时长	0.0509		出现问题的场景次数	0.0905
年龄	0.0499		是否全部网页或APP都慢	0.0662
出现问题的场景次数	0.0497		是否全部都卡顿	0.059
是否全部网页或APP都慢	0.0448		G驻留时长	0.0557
近3个月平均消费元	0.0363		是否全月漫游用户	0.0398
是否全部都卡顿	0.0328		用户上网过程中游戏app的体验问题种类个数	0.0359
当月高频通信分公司	0.0277		王者荣耀质差次数	0.0318
是否5G网络用户	0.0218			
用户上网过程中游戏app的体验问题种类个数	0.0211			
生活类问题种类个数	0.0211			
是否全部游戏都卡顿	0.0162			
王者荣耀质差次数	0.015			
当月MOU	0.0125			
终端制式	0.01			
微信质差次数	0.0092			
手机上网速度			手机上网速度	
用户上网过程中的网络问题种类个数	0.2316		用户上网过程中的网络问题种类个数	0.2769
客户星级标识	0.1122		客户星级标识	0.1963
出现问题的场景次数	0.0708		年龄	0.08636
年龄	0.0655		出现问题的场景次数	0.0822
G驻留时长	0.0653		是否全部都卡顿	0.0721
用户上网过程中的体验问题种类个数	0.0581		用户上网过程中的体验问题种类个数	0.067
是否全部都卡顿	0.058		是否全部网页或APP都慢	0.0578
终端品牌	0.0556		用户上网过程中视频app的体验问题种类个数	0.0492
是否全部网页或APP都慢	0.0487		G驻留时长	0.0451
当月高频通信分公司	0.0433		是否全月漫游用户	0.0405
主套餐档位	0.0426		当月MOU	0.0265
用户上网过程中视频app的体验问题种类个数	0.0405			
终端制式	0.0352			
套外流量费元	0.0243			
校园卡校园合约捆绑用户	0.0197			
当月MOU	0.0175			
微信质差次数	0.0111			
手机上网稳定性			手机上网稳定性	
用户上网过程中的网络问题种类个数	0.2614		用户上网过程中的网络问题种类个数	0.2904
客户星级标识	0.1231		客户星级标识	0.2226
年龄	0.0683		年龄	0.0797
出现问题的场景次数	0.0655		出现问题的场景次数	0.0709
G驻留时长	0.0636		近3个月平均消费元	0.0533
近3个月平均消费元	0.056		是否全部网页或APP都慢	0.052
终端品牌	0.0544		G驻留时长	0.0511
是否全部网页或APP都慢	0.0455		是否全部都卡顿	0.0444
是否全部都卡顿	0.0403		用户上网过程中游戏app的体验问题种类个数	0.0402
用户上网过程中游戏app的体验问题种类个数	0.0355		是否全月漫游用户	0.039
是否全月漫游用户	0.0333		王者荣耀质差次数	0.0353
终端制式	0.0325		是否全部游戏都卡顿	0.021
是否5G网络用户	0.0325			
王者荣耀质差次数	0.0317			
是否全部游戏都卡顿	0.0205			
当月MOU	0.0188			
当月高频通信分公司	0.0172			

图 4-2-13

其中因变量语音通话清晰度和语音通话稳定性的 Lasso 回归模型得出的影响因素只有一个值，因此对于这两个因变量我们就取逐步回归法得到的影响因素即可。

由于通过标准回归系数可以直接比较各影响因素的重要程度，于是可用每个影响因素标准回归系数的绝对值除以方程式中所有影响因素标准回归系数绝对值之和，得出各自变量的影响权重。如下图表所示。

语音通话整体满意度	权重值
用户上网过程中的网络问题种类个数	0.6746
终端品牌	0.1270
是否实名登记用户	0.1185
未接通掉话次数	0.0800

表 4-2-14 语音通话整体满意度权重值

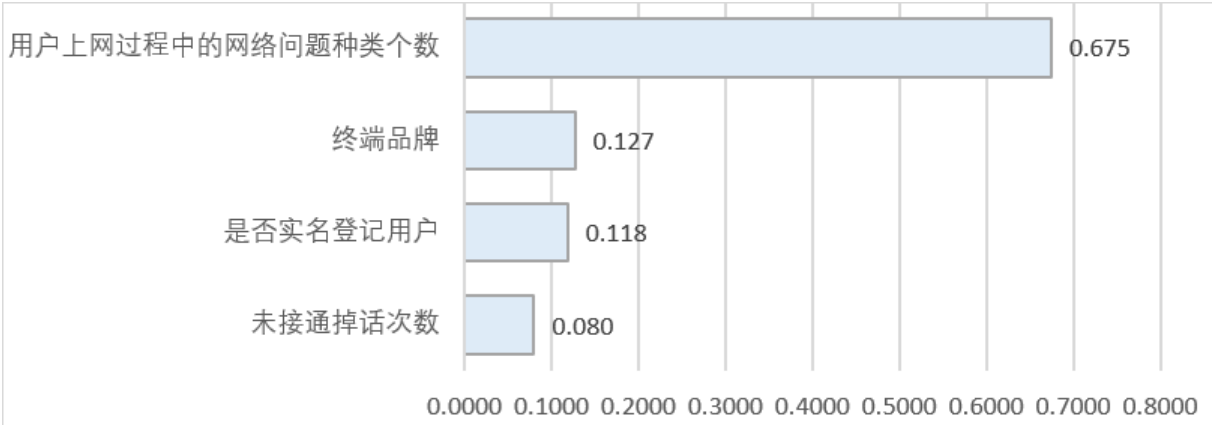


图 4-2-14 语音通话整体满意度权重值柱状图

网络覆盖与信号强度	权重值
是否遇到过网络问题	0.4194
用户所在场景种类个数	0.1884
终端品牌	0.0639
用户上网过程中的网络问题种类个数	0.0637

表 4-2-15 网络覆盖与信号强度权重值

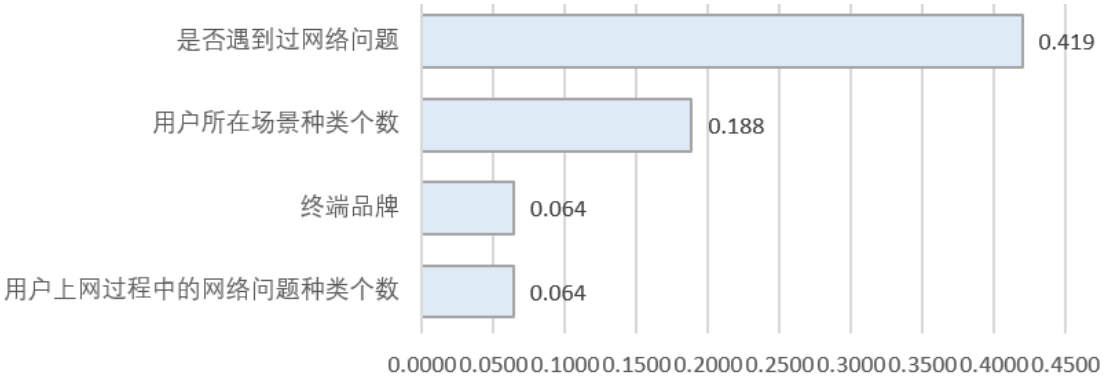


图 4-2-15 网络覆盖与信号强度权重值柱状图

语音通话清晰度	权重值
用户上网过程中的网络问题种类个数	0.4981
语音方式	0.2240
终端品牌	0.1145
客户星级标识	0.0922
是否实名登记用户	0.055
是否关怀用户	0.0163

表 4-2-16 语音通话清晰度权重值

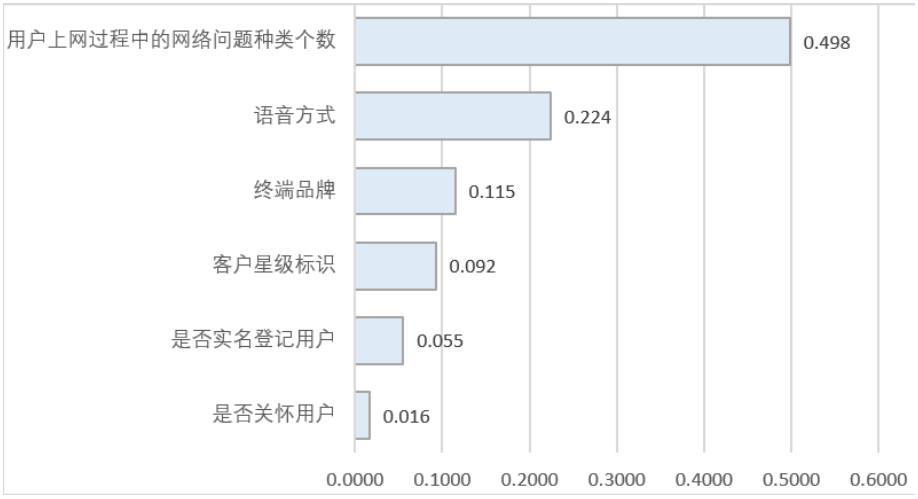


图 4-2-17 语音通话清晰度权重值柱状图

语音通话稳定性	权重值
用户上网过程中的网络问题种类个数	0.5296
终端品牌	0.1062
客户星级标识	0.0890
语音方式	0.0737
是否遇到过网络问题	0.0718
是否实名登记用户	0.0505
未接通掉话次数	0.0485
省际漫游时长分钟	0.0307

表 4-2-18 语音通话稳定性权重值

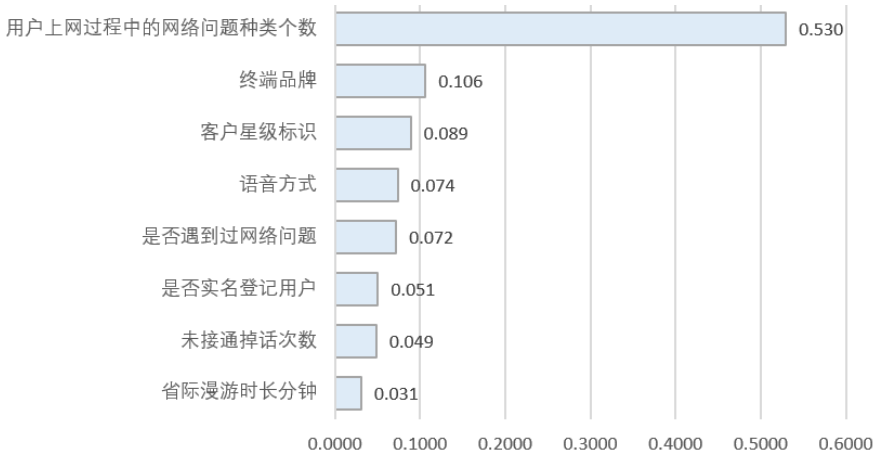


图 4-2-19 语音通话稳定性权重值柱状图

手机上网整体满意度	权重值
用户上网过程中的网络问题种类个数	0.3474
客户星级标识	0.2173
年龄	0.1356
出现问题的场景次数	0.1025
是否全部都卡顿	0.0794
是否全部网页或APP都慢	0.0630
G驻留时长	0.0549

表 4-2-20 手机上网整体满意度权重值

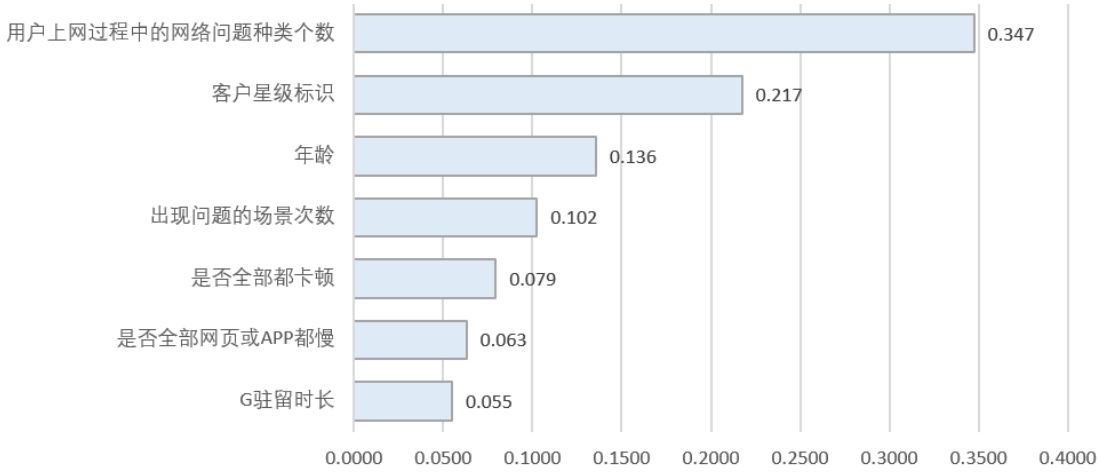


图 4-2-21 手机上网整体满意度权重值柱状图

手机上网速度	权重值
用户上网过程中的网络问题种类个数	0.2975
客户星级标识	0.2182
年龄	0.0973
出现问题的场景次数	0.0903
是否全部都卡顿	0.0798
用户上网过程中的体验问题种类个数	0.0720
是否全部网页或APP都慢	0.0614
用户上网过程中视频app的体验问题种类个数	0.0535
当月MOU	0.0300

表 4-2-22 手机上网速度权重值

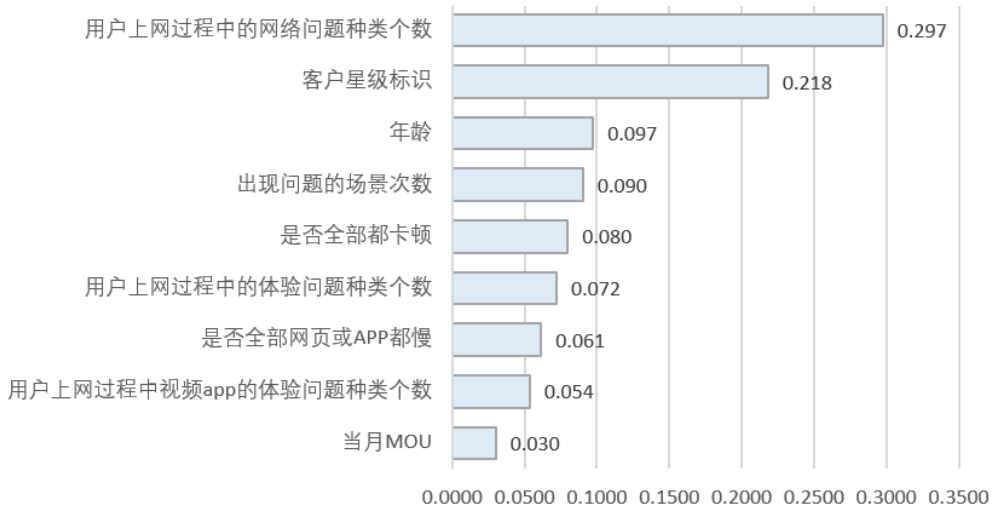


图 4-2-23 手机上网速度权重值柱状图

网络覆盖与信号强度	权重值
用户上网过程中的网络问题种类个数	0.3226
客户星级标识	0.2099
年龄	0.1185
出现问题的场景次数	0.0947
是否全部网页或APP都慢	0.0674
是否全部都卡顿	0.0625
G驻留时长	0.0552
用户上网过程中游戏app的体验问题种类个数	0.0387
王者荣耀质差次数	0.0305

表 4-2-24 网络覆盖与信号强度权重值

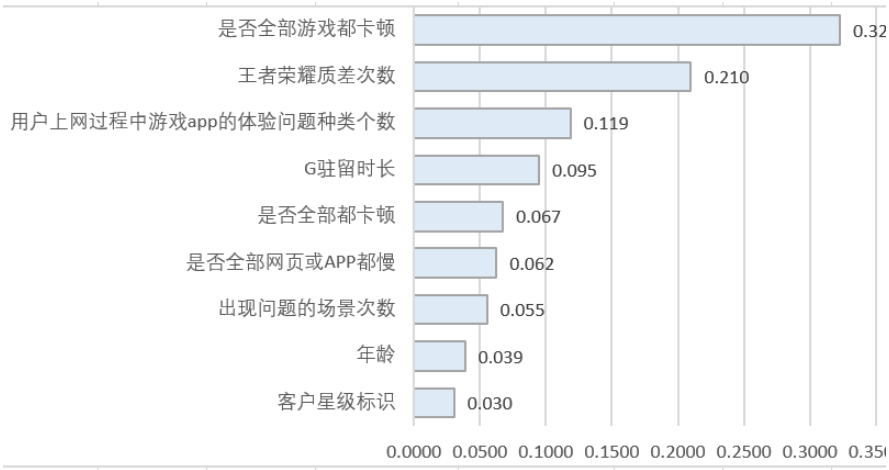


图 4-2-25 网络覆盖与信号强度权重值柱状图

手机上网稳定性	权重值
用户上网过程中的网络问题种类个数	0.2904
客户星级标识	0.2226
年龄	0.0797
出现问题的场景次数	0.0709
近3个月平均消费元	0.0533
是否全部网页或APP都慢	0.0520
G驻留时长	0.0511
是否全部都卡顿	0.0444
用户上网过程中游戏app的体验问题种类个数	0.0402
是否全月漫游用户	0.0390
王者荣耀质差次数	0.0353
是否全部游戏都卡顿	0.0210

表 4-2-26 手机上网稳定性权重值

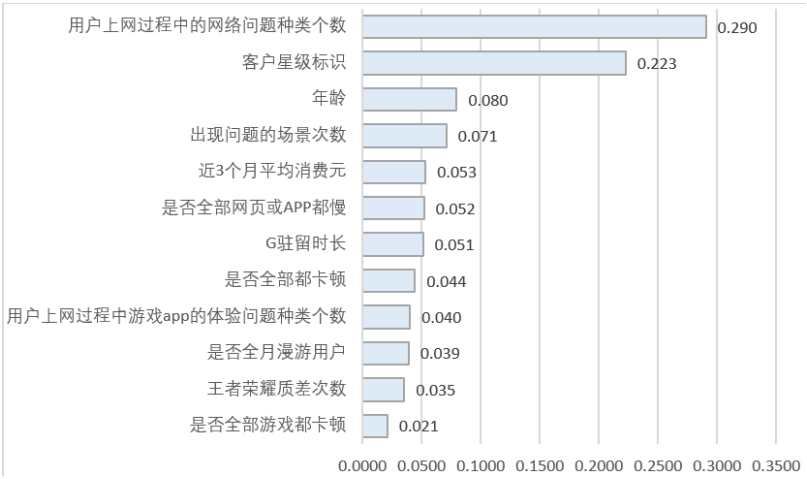


图 4-2-27 手机上网稳定性权重值柱状图

将每个因变量的权重占比最大的前四个作为主要影响因素，得到如下两个表格，

因变量	影响因素	权重值
语音通话整体满意度	用户上网过程中的网络问题种类个数	0.6746
	终端品牌	0.1270
	是否实名登记用户	0.1185
	未接通掉话次数	0.0800
网络覆盖与信号强度	是否遇到过网络问题	0.4194
	用户所在场景种类个数	0.1884
	终端品牌	0.0639
	用户上网过程中的网络问题种类个数	0.0637
语音通话清晰度	用户上网过程中的网络问题种类个数	0.4981
	语音方式	0.2240
	终端品牌	0.1145
	客户星级标识	0.0922
语音通话稳定性	用户上网过程中的网络问题种类个数	0.5296
	终端品牌	0.1062
	客户星级标识	0.0890
	语音方式	0.0737

表4-2-28

因变量	影响因素	权重值
手机上网整体满意度	用户上网过程中的网络问题种类个数	0.3474
	客户星级标识	0.2173
	年龄	0.1356
	出现问题的场景次数	0.1025
网络覆盖与信号强度	用户上网过程中的网络问题种类个数	0.3144
	客户星级标识	0.2045
	年龄	0.1155
	出现问题的场景次数	0.0923
手机上网速度	用户上网过程中的网络问题种类个数	0.2975
	客户星级标识	0.2182
	年龄	0.0973
	出现问题的场景次数	0.0903
手机上网稳定性	用户上网过程中的网络问题种类个数	0.2904
	客户星级标识	0.2226
	年龄	0.0797
	出现问题的场景次数	0.0709

表4-2-29

五、问题二的求解

5.1 数据预处理

5.1.1 附件三的数据预处理

根据附件三的数据，可以发现用户描述里有很多个不同的地点且没有共同性，于是选择将用户描述这一栏指标给剔除；终端类型指标的数据没有共同性，所以我们也选择将这一栏给剔除；再者，根据附件五的字段说明，再根据指标的数据特征，将部分指标进行整合，如下表：

进行整合的指标	整合后的指标

居民小区；办公室；高校；商业街；农村；高铁；其他，请注明	**用户所在场景种类个数**
手机没有信号；有信号无法拨通；通话过程中突然中断；通话中有杂音。听不清、断断续续；串线；通话过程中一方听不见；其他，请注明	**用户通话过程中的网络问题个数**

表5-1-1

然后我们采用Label encoding的方法将定性的指标例如： 4\5G用户、是否关怀用户、是否4G网络客户（本地剔除物联网）、是否5G网络客户、终端品牌、客户星级标识的数据编码为自定义的数字标签完成量化编码，部分具体的数据量化过程如下表，详细见附录

原始数据	量化之后的编码
是	1
否	0
4G	2
5G	3

表5-1-2

虽然我们处理某些异常值之后，预测的精度提高了很多，但是因为客户打分具有很强的主观性，我们预测的结果也是一个主观的结果，因此我们不处理某些异常值。

5.1.2附件四的数据预处理

根据附件四的数据，发现学习强国这个指标在附件二中并没有，而附件四是根据附件二来分析预测，所以将这个指标删去；再者，根据附件五的字段说明，再根据指标的数据特征，将部分指标进行整合，如下表：

进行整合的指标	整合后的指标
居民小区；办公室；高校；商业街；农村；高铁；其他，请注明；场景数据备注	**用户所在场景种类个数**
网络信号差/没有信号；显示有信号上不了网；上网过程中网络时断时续或时快时慢；手机上网速度慢；其他，请注明；现象备注数据	**用户上网过程中的网络问题种类个数**
看视频卡顿；打游戏延时大；打开网页或 APP 图片慢；下载速度慢；手机支付较慢；其他，请注明；APP 大类备注	**用户上网过程中的体验问题种类个数**

爱奇艺；优酷；腾讯视频；芒果 TV；搜狐视频；抖音；快手；火山；咪咕视频；其他，请注明；APP 小类备注	**用户上网过程中视频 APP 的体验问题种类个数**
和平精英；王者荣耀；穿越火线；梦幻西游；龙之谷；梦幻诛仙；欢乐斗地主；部落冲突；炉石传说；阴阳师；其他，请注明；APP 小类游戏备注，全部游戏都卡顿	**用户上网过程中游戏 app 的体验问题种类个数**
微信；手机 QQ；淘宝；京东；百度；近日头条；新浪微博；拼多多；其他，请注明；APP 小类上网备注；全部网页或 APP 都慢	**生活类问题种类个数**

表5-1-3

我们采用 Label encoding 的方法将定性的指标例如：是否不限量套餐到达用户、性别、是否 4G 网络客户（本地剔除物联网）、是否全部都卡顿、是否全部游戏都卡顿、是否全部网页或 APP 都慢、4\5G 用户、终端品牌、客户星级标识的数据编码为自定义的数字标签完成量化编码，部分具体的数据量化过程如下表，详细见附录，

原始数据	量化之后的编码
是	1
否	0
银卡	6
金卡	7

表5-1-4

对异常值的处理同5.1.1。

5.2 随机森林模型的建立和求解

5.2.1 建立随机森林模型

随机森林算法对大规模数据具有良好性能，核心思想是结合随机特征子空间方法形成性能较弱的多个分类回归决策树，经过一定规则组成森林，最终结果由森林中所有的决策树投票得出。

随机森林[5]算法流程主要包括 3 个步骤：对训练数据集进行随机抽取获得训练子集、随机选取特征子集形成决策树、并行训练每个决策树获得对应结果：

设 X 是一个包含 m 个特征的输入向量，Y 是输出值，S_n是一个包含 n 个观测值(X_i,Y_i)的训练集，其中

$$S_n = \{(X_1, Y_1), ..., (X_n, Y_n)\}, X \in R^m, Y \in R. \quad (6)$$

特征选择目前比较流行的方法是信息增益、增益率、基尼系数和卡方检验。这里主要介绍基于基尼系数（GINI）的特征选择，因为随机森林采用的 CART 决策树就是基于基尼系数选择特征的。

基尼系数的选择的标准就是每个子节点达到最高的纯度，即落在子节点中的所有观察都属于同一个分类，此时基尼系数最小，纯度最高，不确定度最小。

对于一般的决策树，假如总共有 K 类，样本属于第 k 类的概率为：pk，则该概率分布的基尼指数为:

$$Gini(p) = \sum_{k=1}^{K} p_k(1 - p_k) = 1 - \sum_{k=1}^{K} p_k^2 \quad (7)$$

基尼指数越大，说明不确定性就越大；基尼系数越小，不确定性越小，数据分割越彻底，越干净。

对于 CART 树而言，由于是二叉树，可以通过下面的表示：

$$Gini(p) = 2p(1 - p) \quad (8)$$

在我们遍历每个特征的每个分割点时，当使用特征 A=a，将 D 划分为两部分，即 D1（满足 A=a 的样本集合），D2（不满足 A=a 的样本集合）。则在特征 A=a 的条件下 D 的基尼指数为：

$$Gini(D, A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2) \quad (9)$$

Gini(D)：表示集合 D 的不确定性。Gini(A,D)：表示经过 A=a 分割后的集合 D 的不确定性。

随机森林中的每棵 CART 决策树都是通过不断遍历这棵树的特征子集的所有可能的分割点，寻找 Gini 系数最小的特征的分割点，将数据集分成两个子集，直至满足停止条件为止。

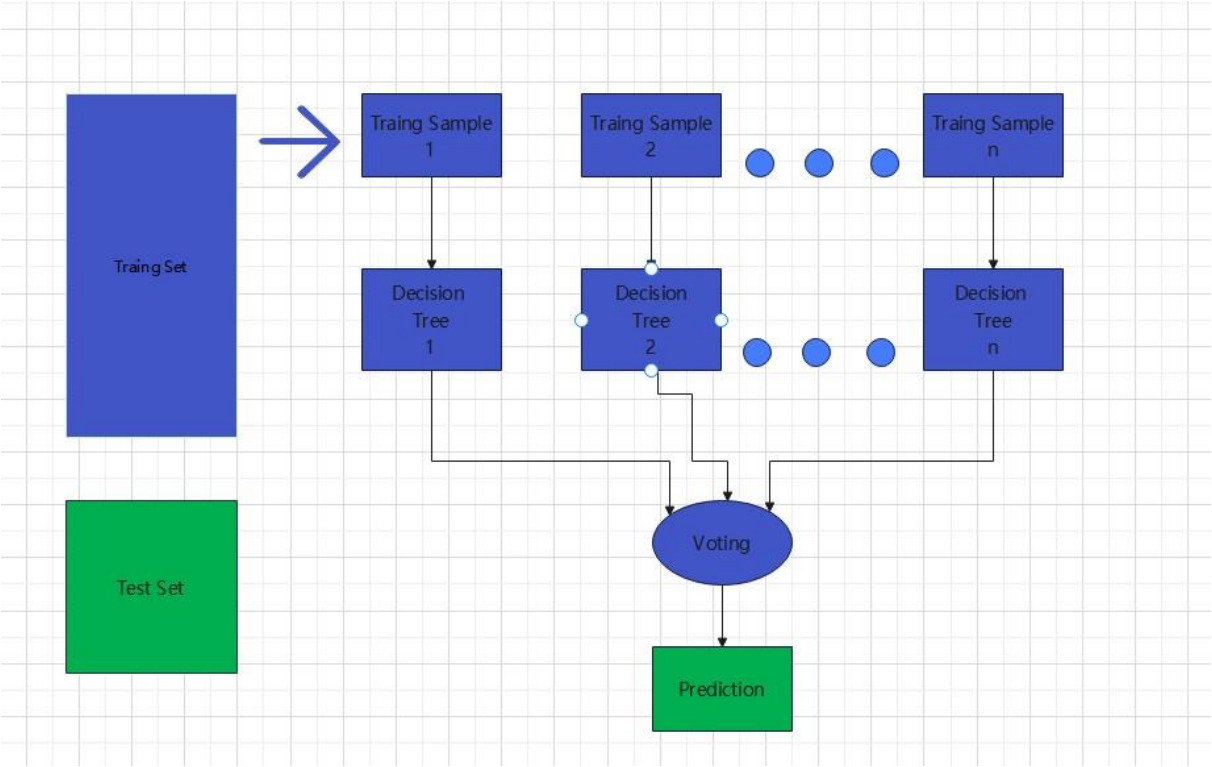


图 5-1-2 随机森林算法流程图

6.2.2 RMS 均方根误差分析和精度大小分析

均方根误差也称之为标准误差，是均方误差的算术平方根。引入均方根误差与引入标准差（均方查）的原因是完全一致的，即均方误差的量纲与数据量纲不同，不能直观反映离散程度，故在均方误差上开平方根，得到均方根误差：

$$RMS = \sqrt{\frac{1}{N}\sum_{t=1}^{N}(observed_t - predict_t)^2} \qquad (10)$$

同样的，均方根误差 RMS 和标准差的计算公式也是高度近似的：标准差是用来衡量一组数自身的离散程度，而均方根误差是用来衡量观测值（真值）与预测值之间的偏差。

在测试集中，预测的数据与原始数据进行比较，误差在正负范围 1 内，我们都认为预测正确，（注：例如 8 分和 9 分我们认为这是区分不大的好坏程度，其次预测数据是小数，选择误差在正负范围 1 内更精确）从而进行精确度分析。

5.2.3 模型求解

通过随机森林算法，基于问题一的结果分析，将得到的每个因变量的主要影响因素作为随机森林的输入量，得分作为输出量。以手机上网整体满意度为例，将用户上网过程中的网络问题种类个数、客户星级标识、年龄、出现问题的场景次数、是否全部都卡顿、是否全部网页或 APP 都慢、2G 驻留时长全部作为输入量，上网整体满意度

作为输出量，前六千个数据作为训练集，后一千多个数据作为测试集，得出随机森林回归模型，可得到误差随决策数目的变化

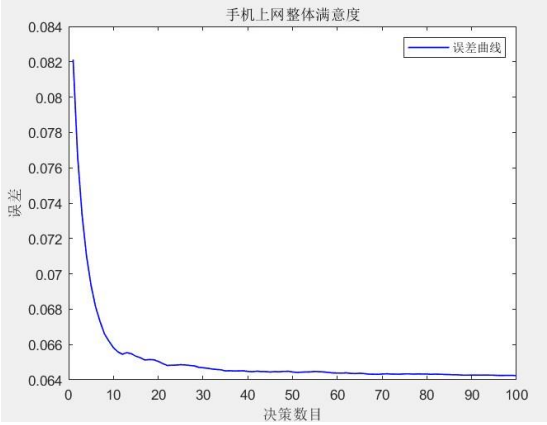


图 5-1-3

然后我们将模型进行 RMS 均方根误差分析和精度分析，其中 RMS 均方根误差大小为 2.2312，精度大小为 0.6028，我们能够发现该模型合理性较强，再利用随机森林回归模型对附件 4 的上网整体满意度进行预测[6]，并将相关数据记录于 result 附件中，其余七个问题一的因变量同理分析即可，误差随决策数目的变化如下图所示。

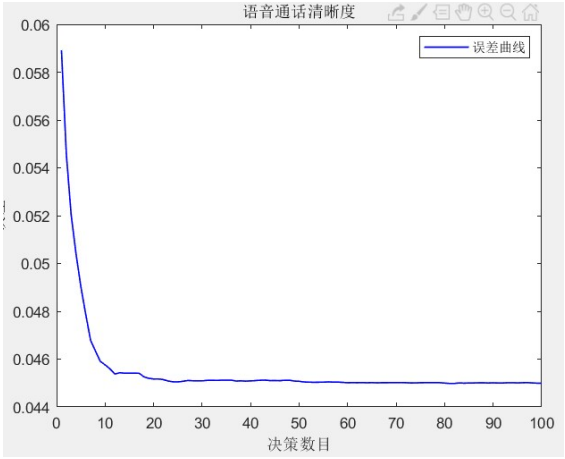


图 5-1-4

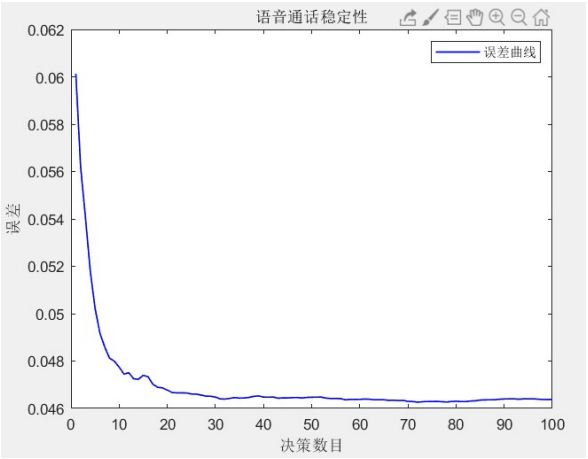


图 5-1-5

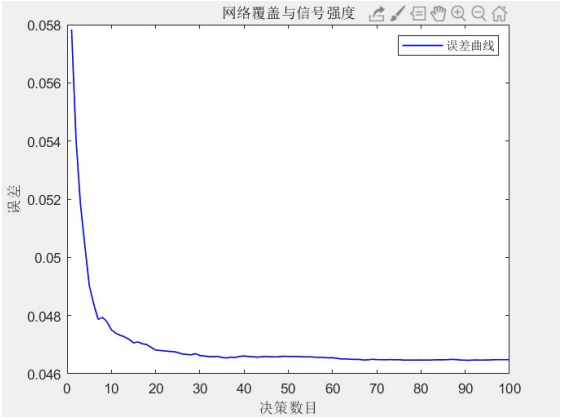


图5-1-6

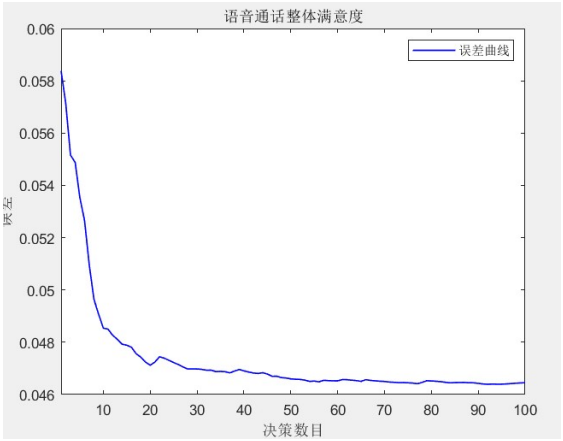


图5-1-7

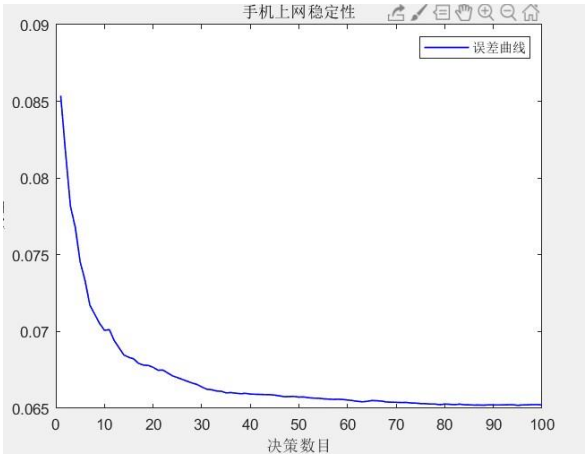


图5-1-8

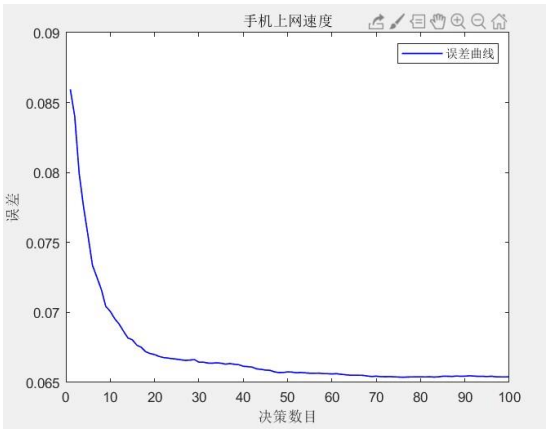


图5-1-9

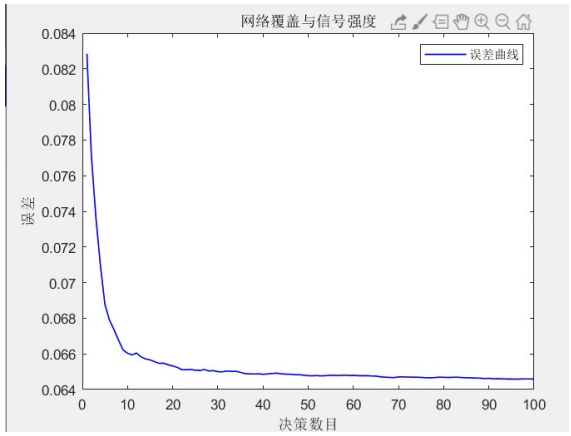


图5-1-10

RMS均方根误差大小和精度大小如下表所示，

语音业务	语音通话整体满意度	网络覆盖与信号强度	语音通话清晰度	语音通话稳定性
精度	0.7397	0.7333	0.7376	0.7149
RMS	1.9878	1.9136	2.0065	1.9026
上网业务	手机上网整体满意度	网络覆盖与信号强度	手机上网速度	手机上网稳定性
精度	0.6028	0.6158	0.6238	0.6078
RMS	2.2312	2.1887	2.2494	2.2501

图5-1-11

其余的预测结果记录了result.xlsx表中。

六、模型的评价

6.1 模型的评价

6.1.1 模型的优点

1、本文分别利用逐步回归与 Lasso 回归研究主要影响因素，然后综合筛选分析整

合，增加了我们研究影响客户语音业务和上网业务满意度的主要因素的可信度，使分析结果更加具有说服力。

2、随机森林模型抗过拟合能力比较强，既能处理离散型数据，也能处理连续型数据，且不需要进行归一化处理，并且对于多变量预测，精确度比较高

6.1.2 模型的缺点

1、随机森林在解决回归问题时，并没有像它在分类中表现的那么好，这是因为它并不能给出一个连续的输出。当进行回归时，随机森林不能够做出超越训练集数据范围的预测，这可能导致在某些特定噪声的数据进行建模时出现过度拟合。

2、随机森林执行数据虽然比 boosting 等快（随机森林属于 bagging），但比单只决策树慢

七、参考文献

[1]梁翠香.基于逐步回归方法的福建省 CPI 影响因素分析[J].市场周刊,2022,3

[2]周辰,唐文霞.基于多元回归分析的课程满意度影响模型构建[J].江苏建筑职业技术学院学报,2022,22(01):73-78+109.

[3]李学泱,邵喜高.基于多元线性回归和 Lasso 回归的高校生源质量影响因素研究[J].鲁东大学学报(自然科学版),2022,38(04):350-356.

[2]周辰,唐文霞.基于多元回归分析的课程满意度影响模型构建[J].江苏建筑职业技术学院学报,2022,22(01):73-78+109.

[4]谢双霜,柴文文,王亮.基于多元线性回归的海洋工程海上作业综合工效权重分析[J].中国集体经济,2022,(11):80-82.

[5]张蓓蓓,胡敏.基于网格搜索改进随机森林的顾客满意度预测[J].北京信息科技大学学报(自然科学版),2021,36(04):50-53+58.

[6]郑胜洁,徐余明,胡祖翰,刘留.基于随机森林的城市轨道交通桥梁故障预测模型[J].北京交通大学学报,2022,46(05):9-18.