队伍编号	2201644
赛道	B

基于 SMOTEBAG 模型的用户满意度预测研究

摘要

移动网络用户的满意度是运营商经营质量水平的一个重要评价标准，高水平的用户满意度评分是提升存量用户忠诚度的重要保障。随着移网用户数量不断增长，提升用户满意度水平对运营商高质量发展具有重要意义。

本文首先对数据进行预处理，由于语音业务、上网业务原始训练数据存在不规范性，首先进行数据清洗，统计和处理空白值和异常值，在此基础上对数据进行特征工程处理，其中包括训练数据和预测数据特征取交集、标签统一工作、文本数据处理、连续变量 KMeans 分箱、连续变量 RankGaussian 归一化、分类变量 LabelEncode 和 CountEncode、删除类别严重单一化的分类变量和预测目标无关列，在对数据清洗、特征处理后，两种业务根据训练集：验证集=9:1 分层抽样划分，在验证集和测试集特征整体数据探索、利用 KDE 分布图进行分布一致性探索及绘制自变量间 Spearman 相关系数热力图进行冗余变量删除，最后语音业务得到 26 个输入特征、上网业务得到 34 个输入特征。

针对问题一：本文首先建立及对比分析 KNN、RondomForest、LightGBM、XGBoost 和 SMOTEABAG 模型性能，得到参数为默认值时 SMOTEABAG 模型表现最好，后以 SMOTEABAG 的基决策树使用每个特征时的 Gini 系数作为特征重要性的依据，得到基决策树的分类结构图和以 LOFO 特征选择方法选择的影响两种业务打分的关键因素，其中语音业务中语音通话整体满意度前三个重要性特征为**是否遇到网络问题、终端品牌类型_CountEncode、终端品牌_CountEncode**，上网业务中手机上网整体满意度特征排序前三为**当月 MOU_RankGaussian、终端品牌类型_CountEncode、是否不限量套餐达到用户**。

针对问题二：本文选用留出法评价该多分类且类别不均衡问题，以 CKS 和 MAE 为评价指标，基于 SMOTEABAG 的默认参数得到的结果，利用 Optuna 对 SMOTEABAG 模型 6 个超参数寻优，得到语音业务中在验证集上最优时语音通话整体满意度：CKS 为 0.69、MAE 为 0.44，网络覆盖与信号强度：CKS 为 0.83、MAE 为 0.17，语音通话清晰度：CKS 为 0.84、MAE 为 0.16，语音通话稳定性：CKS 为 0.83、MAE 为 0.17，上网业务中在验证集上最优时手机上网整体满意度：CKS 为 0.66、MAE 为 0.76，网络覆盖与信号强度：CKS 为 0.67、MAE 为 0.73，手机上网速度 CKS 为 0.64、MAE 为 0.75，手机上网稳定性：CKS 为 0.64、MAE 为 0.77。利用 KDE 核密度图检验得到训练集真实满意度和测试集预测满意度分布具有一致性，以此说明预测模型的合理性。

最后，本文对模型优缺点进行了客观评价和模型改进，最终对生物信息学、机器故障诊断等存在不均衡多分类问题的领域进行了应用与推广。

关键词：KMeans 分箱　RankGaussian 归一化　SMOTEABAG　LOFO 特征选择　Optuna 超参数优化

目录

一、问题的背景和重述 1
1.1 问题的背景 1
1.2 问题的重述 1
1.3 名词解释 1
1.4 原始数据集介绍 1
二、问题的分析 2
2.1 数据预处理分析 2
2.2 问题 1 的分析 2
2.3 问题 2 的分析 3
三、模型假设 3
四、符号定义与说明 3
五、数据预处理 3
5.1 语音业务数据清洗 3
5.1.1 语音业务查找缺失值并计算占比 4
5.1.2 语音业务空白值处理 4
5.1.3 语音业务异常值处理 4
5.2 语音业务的特征工程 4
5.2.1 语音业务特征交集处理 4
5.2.2 语音业务统一编号处理 4
5.2.3 语音业务 4/5G LabelEncode 5
5.2.4 语音业务 CountEncode 5
5.2.5 语音业务删除类别严重单一化的分类变量 5
5.2.6 语音业务连续变量 KMeans 分箱 5
5.2.7 语音业务连续变量 RankGaussian 归一化 6
5.2.8 语音业务文本数据处理[3] 6
5.3 语音业务的数据探索 7
5.3.1 语音业务整体数据探索 7
5.3.2 语音业务自变量相关性探索 8
5.3.3 语音业务验证集和测试集特征分布一致性探索 9
5.4 语音业务预处理的总结 10
5.5 上网业务的数据清洗 10
5.5.1 上网业务查找缺失值并计算占比 10
5.5.2 上网数据空白值处理 11
5.5.3 上网业务异常值处理 11
5.6 上网业务的特征工程 11
5.6.1 上网业务特征取交集 11
5.6.3 上网业务文本数据处理 12
5.6.4 上网业务分类变量 LabelEncode 12
5.6.5 上网业务分类变量 CountEncode 12
5.6.6 删除类别严重单一化的分类变量 13
5.6.7 上网业务连续变量 KMeans 聚类分箱 13
5.6.8 上网业务连续变量 RankGaussian 归一化 13

5.7 上网业务数据探索 13
5.7.1 上网业务整体数据探索 13
5.7.2 上网业务自变量相关性探索 14
5.7.3 上网业务验证集和测试集特征分布一致性探索 14
5.8 上网业务预处理的总结 15
六、模型的建立和求解 16
6.1 问题一的建模和求解 16
6.1.1 多模型性能的探索 16
6.1.2 模型的评价指标和评价方式 18
6.1.3 语音业务多模型性能探索的求解 19
6.1.4 基于 SMOTEABAG 的语音业务影响程度的量化分析 20
6.1.5 上网业务多模型性能探索的求解 22
6.1.6 基于 SMOTEABAG 的上网业务影响程度的量化分析 22
6.2 问题 2 的建模和求解 24
6.2.1SMOTEABAG 模型参数寻优 24
6.2.2SMOTEABAG 语音业务分类模型的求解 25
6.2.3SMOTEABAG 上网业务分类模型的求解 26
6.2.4 语音业务预测合理性说明 27
6.2.5 上网业务预测合理性说明 28
七、模型的评价和改进 28
8.1 模型的优点 28
8.2 模型的缺点 28
8.3 模型的改进 29
八、模型的应用和推广 29
九、参考文献 29
附录 30

一、问题的背景和重述

1.1 问题的背景

随着全业务运营时代的到来，中国电信领域竞争格局发生深刻变化，移动通信业务同质化趋势明显。移动运营企业为了预防用户流失，实现市场份额扩大和利润提升，需要不断提高用户满意度，增强用户黏性，凸显竞争优势。

中国电信市场范围和层次逐渐增加以及人们在通信方面的需求量增多的背景之下,通信行业竞争程度也日渐加剧。我国通信重组后交易运营局势,让通讯市场构成中国移动、中国联通和中国电信鼎立的情况。随着商品和技术的日趋相同,通信企业形成了自己全新的服务理念—“服务营销”、“提升满意度”。为了能够在越来越激烈、越来越同质化的运营商市场竞争中始终保持领先、保持主导地位,必须通过服务,来实现差异化内容供给,实现可持续发展[1]。

我国的客户满意度工作起始于 1999 年，首先在大中型企业进行探索，实施提升客户满意度的措施。众多研究客户满意度的学者对其定义各有侧重，美国营销大师菲利普.科特勒在其经典著作中指出，客户满意度是客户通过对产品或服务进行感知，将感知的结果与其预期的感受进行比较，预期与感受的差异使顾客感到心情愉悦或是失望。营销学者奥利弗指出，客户满意度是客户消费产品或服务后是否得到满足的心理反应。亨利.阿塞而认为，当客户消费产品达到预期感受时就会产生满意情绪，否则将会产生不满。尽管上述定义存在差别，但基本内涵是一致的，都是期望与感知效果对比进行定义。主要的观点是：当感知效果低于期望值时，客户就会产生失望不满的情绪。当感知效果与客户期望相近时，客户就会产生一定程度的满意和愉悦。当感知效果远远超过客户期望时，客户会对产品或服务产生高度的满意和一定程度的忠诚[2]。

1.2 问题的重述

问题 1：根据附件 1 语音业务用户满意度数据和附件 2 上网业务用户满意度数据，分别研究影响客户语音业务和上网业务满意度的主要因素，并给出各因素对客户打分影响程度的量化分析和结果。

问题 2：基于问题 1 的研究，对于客户语音业务和上网业务分别建立客户打分基于相关影响因素的数学模型，并据此对附件 3 语音业务、附件 4 上网业务中的客户打分进行预测研究，并说明你们预测的合理性。

1.3 名词解释

- 当月 ARPU：AverageRevenuePerUser，指的是一个月内电信运营企业平均每个用户贡献的通信业务收入，其单位为元/户，是衡量用户价值的重要指标。
- 前 3 月 ARPU：指的是三个月内电信运营企业平均每个用户贡献的通信业务收入
- 当月 MOU：Minutes of Usage，每用户每月平均通话时间。
- 前 3 月 MOU：每用户三个月平均通话时间
- GPRS 总流量（KB）：GPRS 是一种移动数据通信业务，在移动用户和数据网络之间提供连接，给移动用户提供高速无线 IP 服务。

1.4 原始数据集介绍

题中所给的原始数据集来源于用户对语音业务和上网业务 4 种满意度和相关影响因素。

1、附件 1 语音业务用户满意度数据（5433×55）
2、附件 2 上网业务用户满意度数据（7020×125）
3、附件 3 语音业务用户满意度预测数据（2599×44）
4、附件 4 上网业务用户满意度预测数据（1610×87）
5、附件 5 附件 1、2、3、4 的字段说明

二、问题的分析

本文首先拟对附件 1、2 中客户满意度打分数据的进行数据预处理和分析，建立分类模型对附件 3、4 进行预测和对语音业务、上网业务特征影响程度的量化分析，下面我们对此逐一进行讨论分析。

2.1 数据预处理分析

由于数据集繁多，存在数据异常和空白现象，本文首先对附件 1 与附件 2 的数据集进行预处理即进行数据清洗、特征工程、数据探索工作。数据清洗包括对异常值修正、删除工作，对空白值填补、删除工作。其次进行特征工程构建，应该对相关数据进行特征转换分箱、进行编码、数据归一化，以利于模型的学习。考虑到本题部分分类变量所含类别较多，拟用 LabelEncode 和 CountEncode 进行编码，减少模型的复杂程度。对于连续变量，拟用 KMeans 分箱和 RankGaussian 归一化操作进行处理。去除 id 列和类别严重单一化的贡献度较小特征后划分训练集、验证集，进行整体数据探索，分布一致检验，去除剔除相关程度过高的特征。

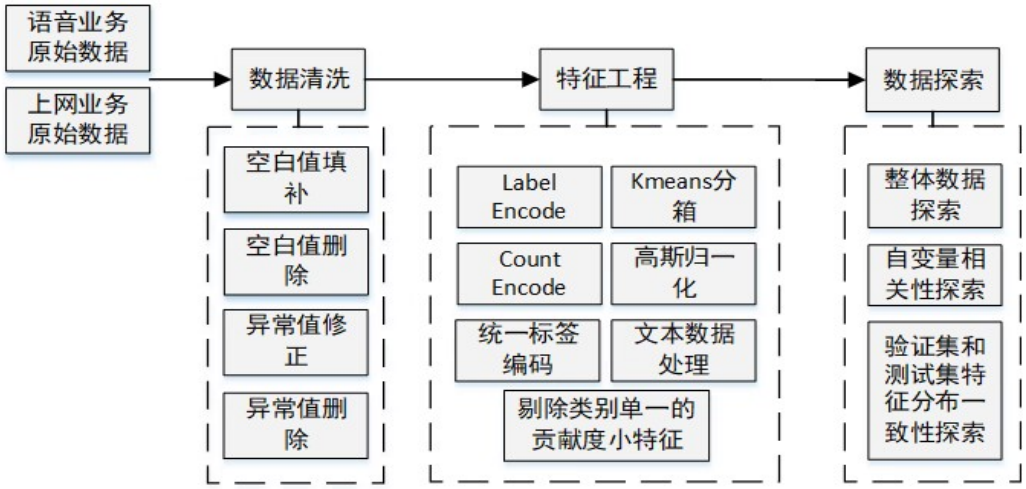


图 1 预处理思路流程图

2.2 问题 1 的分析

在预处理的基础上，对于多分类不均衡问题，本文首先对满意度分类模型进行探索拟建立多个模型 KNN、RondomForest、LightGBM、XGBoost、SMOTEABAG 模型，选取默认参数下表现最好的模型进行初步分类预测和关键因素量化分析，其中可以得到基决策树的分类结构图进行白箱分类的说明和影响两种业务打分的关键因素的重要性排序。思路流程图如下：

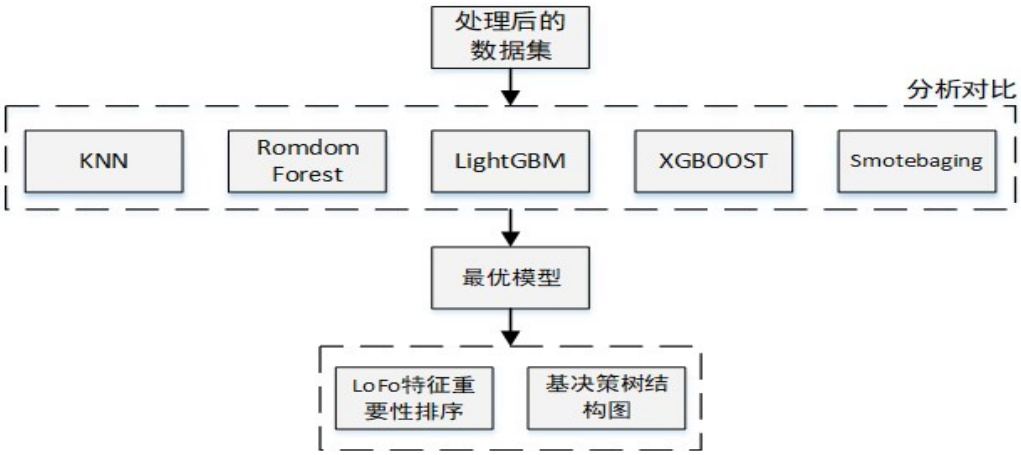


图 2 问题 1 的思路流程图

2.3 问题 2 的分析

经模型性能探索后得出对于此问题的性能最优模型，本文选用留出法评价该多分类且类别不均衡的问题，以 CKS 和 MAE 为评价指标利用 Optuna 进行超参数优化，后对验证集数据进行性能测试和对附件 3 和 4 进行预测分类。其中 Optuna 是一个十分常用的超参数调优框架，具有操作简单、嵌入式强和动态调整参数空间等优点。思路流程图如下：

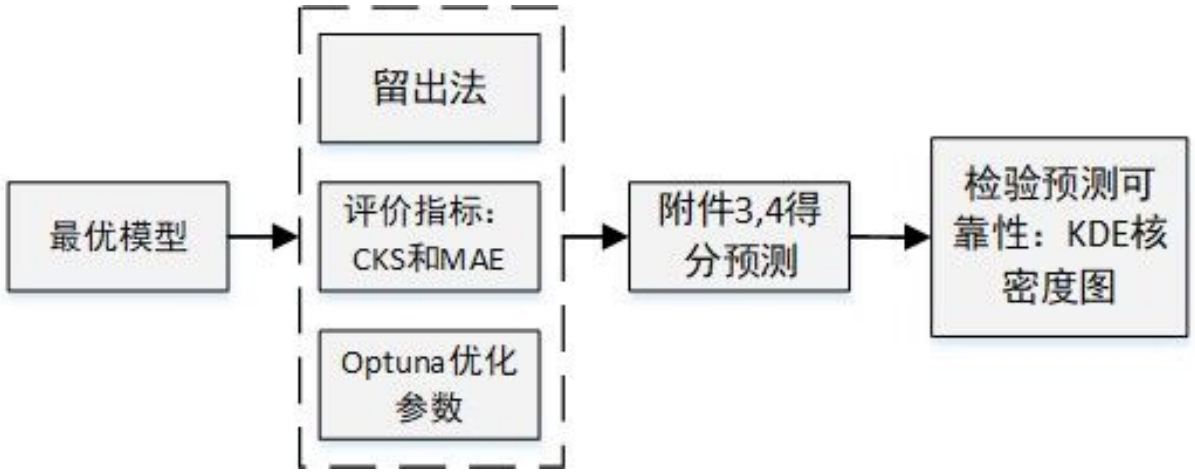


图 3 问题 2 思路流程图

三、模型假设

1、假设影响用户打分的因素仅在官方数据集中；
2、假设用户打分在短期内不会变化；
3、假设所调查的用户打分及相关影响因素数据数据都比较准确；
4、假设未在给出数据集内的其他因素对用户满意度预测无显著影响。

四、符号定义与说明

符号	符号含义
r_s	斯皮尔曼相关系数
p_i	表示第 i 类指标占比
l	损失函数
$\delta(f_t)$	正则项
$Constant$	常数项
C_k	基分类器
n	总样本个数
S	训练集
T	测试集
$GINI$	基尼系数

五、数据预处理

5.1 语音业务数据清洗

在原始数据集中，由于用户数量过多、分布广，加之各种不可控因素，导致所采集

的数据会存在重复值、缺失值和异常值，无法直接进行数据挖掘。为了改善数据质量、提高后续模型预测结果的可靠性，因此本文将先对附件 1 语音业务用户满意度数据进行初步的数据清洗。

5.1.1 语音业务查找缺失值并计算占比

首先，本文进行缺失值可视化分析，其中空白值越多代表缺失情况越严重。

在语音业务中两个用户描述、是否关怀用户、重定向次数、重定向驻留时长、空白值较多，是否去过营业厅存在半数缺失值的情况，其他特征缺失值较少。为进一步定量处理缺失问题，本文分别查找计算原始数据集的各字段缺失值情况，如下表所示：

表 1 语音业务和上网业务缺失值表

字段名	缺失数量	缺失占比	终端品牌	4	0.000736
用户描述	5158	0.949383	终端品牌类型	5	0.00092
用户描述.1	5324	0.979937	外省流量占比	2	0.000368
重定向次数	4260	0.784097	是否 5G 网络客户	5	0.00092
重定向驻留时长	4260	0.784097	是否实名登记用户	5	0.00092
是否关怀用户	5233	0.963188	客户星级标识	5	0.00092
是否去过营业厅	2971	0.546843	当月欠费金额	5	0.00092
是否 4G 网络客户	5	0.00092	前第 3 个月欠费金额	5	0.00092

5.1.2 语音业务空白值处理

- **语音业务空白值删除**

基于对附件 1 进行空白值统计得到，终端品牌类型中 5 个空白值删去，其中 4 个 0 认为是 0 号品牌为有效数据不删去。外省流量占比中 2 个空白值删去。

- **语音业务空白值填充**

按附件 5 中所给字段说明将是否关怀用户、是否去过营业厅中空白值填充为否，并将是否 5G 网络客户编码为 0/1。

表 2 编码示意表

是否关怀用户、是否去过营业厅		
原数据	否	是
现数据	0(否)	1（是）

5.1.3 语音业务异常值处理

将外省流量占比中 2 个#DIV/0!数据删除。

5.2 语音业务的特征工程

5.2.1 语音业务特征交集处理

对附件 1 和附件 3 的语音业务用户满意度数据即预测数据数据特征进行观察可知附件 1 中的重定向次数、重定向驻留时长、家宽投诉、资费投诉、语音方式、是否去过营业厅、ARPU（家庭宽带）、是否实名登记用户、当月欠费金额、前第 3 个月欠费金额，共 10 个特征，附件 3 中没有，所以本文将其删除。附件 3 删除变量：是否投诉、性别、是否不限量套餐到达用户。

5.2.2 语音业务统一编号处理

为使其拥有统一的标准，本文进行统一编号处理：

表 3 编号示意表

居民小区、办公室、高校、商业街、地铁、农村、高铁、其他，请注明		
原数据	-1（否）	1/2/3/4/5/6/7/98（是）
现数据	0（否）	1（是）

表 4 编号示意表

手机没有信号、有信号无法拨通、通话过程中突然中断、通话中有杂音、听不清、断断续续、串线、通话过程中一方听不见、其他，请注明		
原数据	-1（否）	1/2/3/4/5/6/98（是）
现数据	0（否）	1(是)

表 5 编号示意表

是否遇到网络问题		
原数据	2（否）	1（是）
现数据	0（否）	1（是）

5.2.3 语音业务 4/5G LabelEncode

由于 4/5G 为不连续的有等级区别的文本变量，本文利用 LabelEncoder 对 4/5G 特征值进行编码转换成 0 到 N−1 之间的数。

表 6 4/5G 用户编码示意表

原数据	2G	4G	5G
现数据	0	1	2

5.2.4 语音业务 CountEncode

CountEncode，即频数编码使用频次替换类别，由于客户星级标识、终端品牌、终端品牌类型各个类别的频数不同，其中终端品牌类型为高基数特征，所含类别过多，故对客户星级标识、终端品牌、终端品牌类型进行频数编码以更好利用数据信息，编码示意表如下：

表 7 客户星级标识编码示意表

客户星级标识	一星	...	三星	二星
频数	172	...	3202	455
编码	172	...	3202	455

表 8 终端品牌编码示意表

终端品牌	realme	...	万普	万普拉斯
频数	18	...	6	11
编码	18	...	6	11

表 9 终端品牌类型编码示意表

终端品牌类型	2015561	...	21091116C	ANA-TN00
频数	1	...	2	2
编码	1	...	2	2

5.2.5 语音业务删除类别严重单一化的分类变量

下表为是否关怀用户、是否 4G 网络客户（本地剔除物联网）的标签类型及占比表，由表可知标签类别过于单一，本文将这两个指标进行删除。

表 10 标签类型及占比表

是否关怀用户	1（0.03812）	是否 4G 网络客户	1（0.99908）
	0（0.963188）		0（0.00092）

5.2.6 语音业务连续变量 KMeans 分箱

脱网次数、未接通掉话次数、套外流量（MB）、套外流量费（元）、省际漫游-时长（分钟）、前 3 月 ARPU、外省流量占比、GPRS-国内漫游-流量（KB）共 8 个特征属于连续变量，本文利用 KMeans 分箱将其连续数据离散化使其更加简洁清晰地呈现特征信息，并且能够极大程度减少异常值的影响，同时也能够消除不同特征量纲差异的影响。由于满意度有 10 个等级，本文 K 取 10，对上述数据进行分箱。下图为 KMeans 分箱的

流程图：

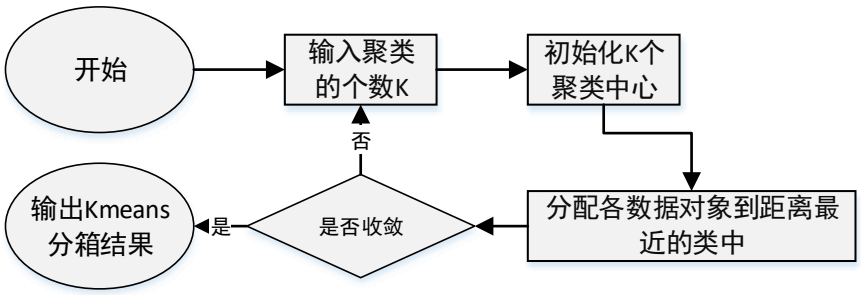


图 4 KMeans 分箱的流程图

5.2.7 语音业务连续变量 RankGaussian 归一化

对输入特征进行归一化能使模型更容易训练，故本文使用 RankGaussian 算法对语音通话-时长（分钟）、当月 ARPU、当月 MOU、前 3 月 MOU、GPRS 总流量（KB）进行归一化。

Step1:对数据进行从大到小的排序，记录排序信息

Step2:将排序信息转换尺度到[-1,1]

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \tag{2}$$

Step3:调整x'极端值得到x_1

Step4:x_1带入 erfinv 函数即 errorfunction 的反函数进行计算，得到最终 RankGaussian 归一化结果。下图为 erfinv 函数示意图：

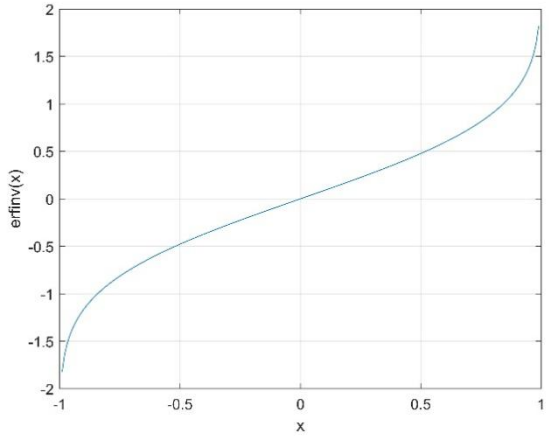


图 5 erfinv 函数

5.2.8 语音业务文本数据处理[3]

对于两个用户描述的文本数据，本文首先将其中的空白填写成一般，“一般”的情感极性为较中性，然后利用 SnowNLP 库对其进行文本情感分析处理进行文本分析，得出两列用户描述的情感得分后取平均值，代替两列用户描述的特征。

Step1:利用 jieba 分词进行中文切词，即将一个汉字序列切分成一个一个单独的词，将连续的字序列按照一定的规范重新组合成词序列的过程。如：

[地铁和高铁信号太差了] → [地铁|和|高铁|信号|太|差|了]

Step2:词性标注

Step3:情感分析

基于情感词典实现的，其简单的将文本分为两类，积极和消极，返回值为情绪的概率，越接近 1 为积极，接近 0 为消极。

预测过程使用的公式为

$$P(c_1 \mid w_1,\cdots,w_n)=\frac{P(w_1,\cdots,w_n \mid c_1)\cdot P(c_1)}{P(w_1,\cdots,w_n \mid c_1)\cdot P(c_1)+P(w_1,\cdots,w_n \mid c_2)\cdot P(c_2)} \quad (3)$$

Step4:两者得分合并取平均

得到的两个用户描述的文本数据的情感得分取平均得到如下示意图

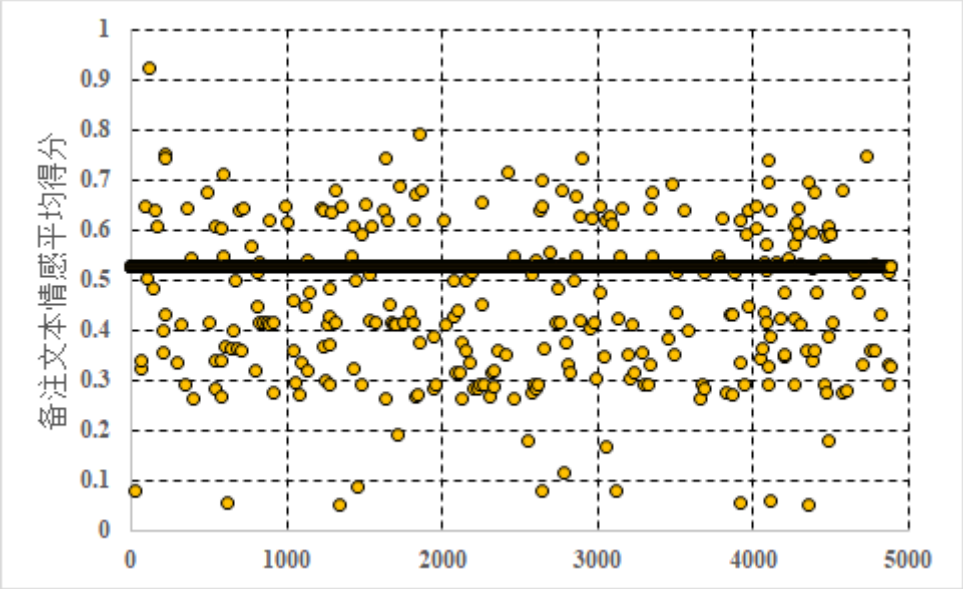


图 6 语音业务用户描述文本情感平均得分折线图

5.3 语音业务的数据探索

5.3.1 语音业务整体数据探索

在数据清洗和特征工程的基础上，为模型建立提供基础，本文对其进行统计性描述，下图为语音业务的用户 4 种打分即语音通话整体满意度、网络覆盖与信号强度、语音通话清晰度和语音通话稳定性的体验打分分布图。

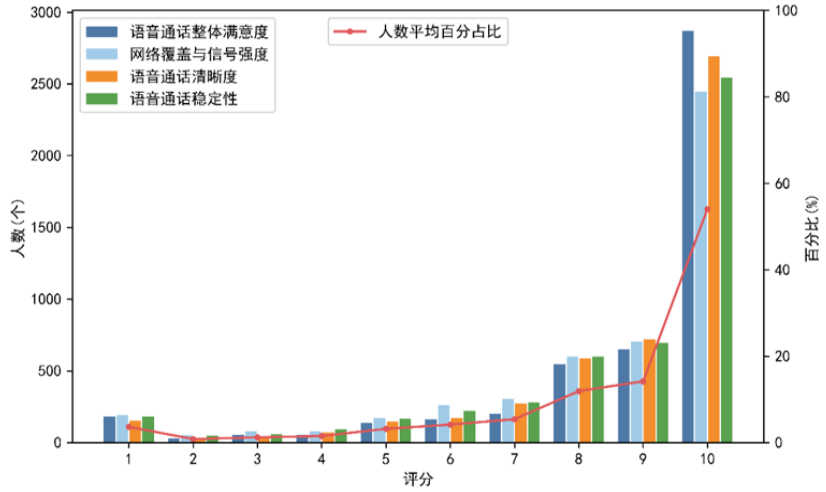


图 7 语音业务的用户 4 种打分分布图

由图 5 可知，用户评分主要集中在 8、9 和 10 分，处于 1、2 和 3 等低分段相对较少，呈现偏态分布[4]，即分布不均衡。四项评价指标中 10 分人数最多，占到总用户数的 58.2%，其次 9 分占到 13.31%，8 分占到 11.16%，由此可见用户的体验大多数是良好的。

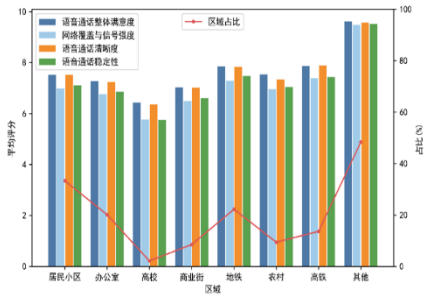


图 8 用户自身分布图

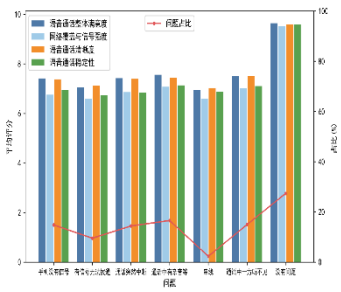


图 9 用户问题分布与得分统计图

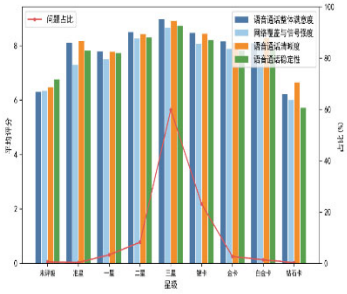


图 10 客户星级标识分布图

由图 8 可知，用户自身所在高校场景下占比最少为 1.35%，四项评价指标的评分整体也偏低，需要加强高校业务的服务。在地铁、高铁、农村这三种通信可能受区域影响的场景中的评分与居民小区场景相差不大，说明通信服务覆盖得相当完善。由图 9 可知，问题分布较为平均，在通话中，发生串线问题发生的最少为 2.32%，发生最多的问题是通话中有杂音，27.3%用户通话中没有问题。可以看出通话中的问题对于降低用户的平均评分影响大致相同，没有通话问题的平均评分远高于有问题的平均评分。在图 10 中，客户星级标识是由未评级、准星、一星、二星、三星、银卡、金卡、白金卡和钻石卡从高到低依次排列。由图可知，用户在星级分布上呈现出“中间高、两边低”，三星级用户最多为 59.90%、金卡 2.66%、白金卡 1.39%、钻石卡 0.29%，其中钻石卡用户的四项指标的平均评分在其中是最低，最高的是三星级户。

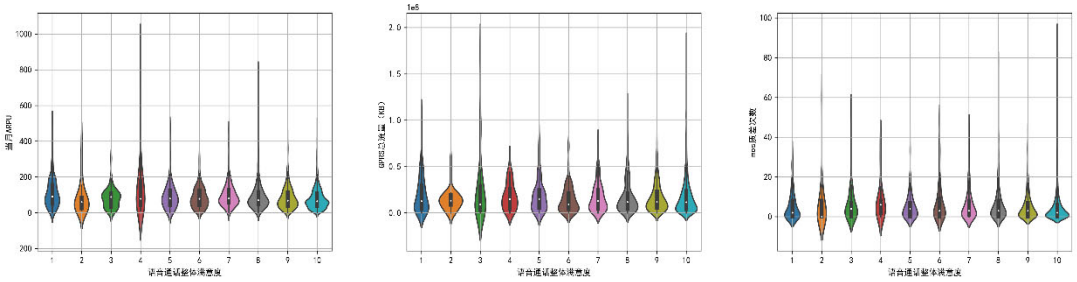


图 11 当月 ARPU、GPRS 总流量、mos 质差次数的小提琴图

小提琴图是箱线图与核密度图的结合，箱线图展示分位数的位置，核密度图则展示任意位置的密度，通过小提琴图可以大致了解数据的整体分布情况。由图 9 可知，各个评分下 mos 质差次数分布大致相同，均存在较明显的离散值。对 GPRS 总流量来说，语音通话整体满意度 1 分、3 分的 GPRS 总流量相较于 10 分更多。对当月 ARPU 而言，语音通话整体满意度 1、4 分的当月 ARPU 相较于 8、9、10 分更多。

5.3.2 语音业务自变量相关性探索

由于数据特征大多呈现非正态分布且含有定序特征，故采用 Spearman 相关系数判断变量间的相关性。其中如果相关系数 r 的绝对值一般在 0.8 以上可认为 A 和 B 具有强相关性，0.3 到 0.8 之间可认为具有弱相关性，0.3 以下可认为几乎无相关性。本文发现然后 4\5G 用户和是否 5G 网络客户的相关性为 0.98，为强相关性，存在冗余信息，剔除相关程度过高的特征以减少模型的复杂程度，故本文删除是否 5G 网络客户数据。由于用户 id 属于无关特征，本文也将其删除。

定义：X 和 Y 为两组数据，其斯皮尔曼（等级）相关系数计算公式如下：

$$r_s = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2-1)} \tag{4}$$

其中:d_i^2 表示第 i 个数据对的位次值之差，n 表示总的观测样本数

下图为语音业务自变量相关系数热力图:

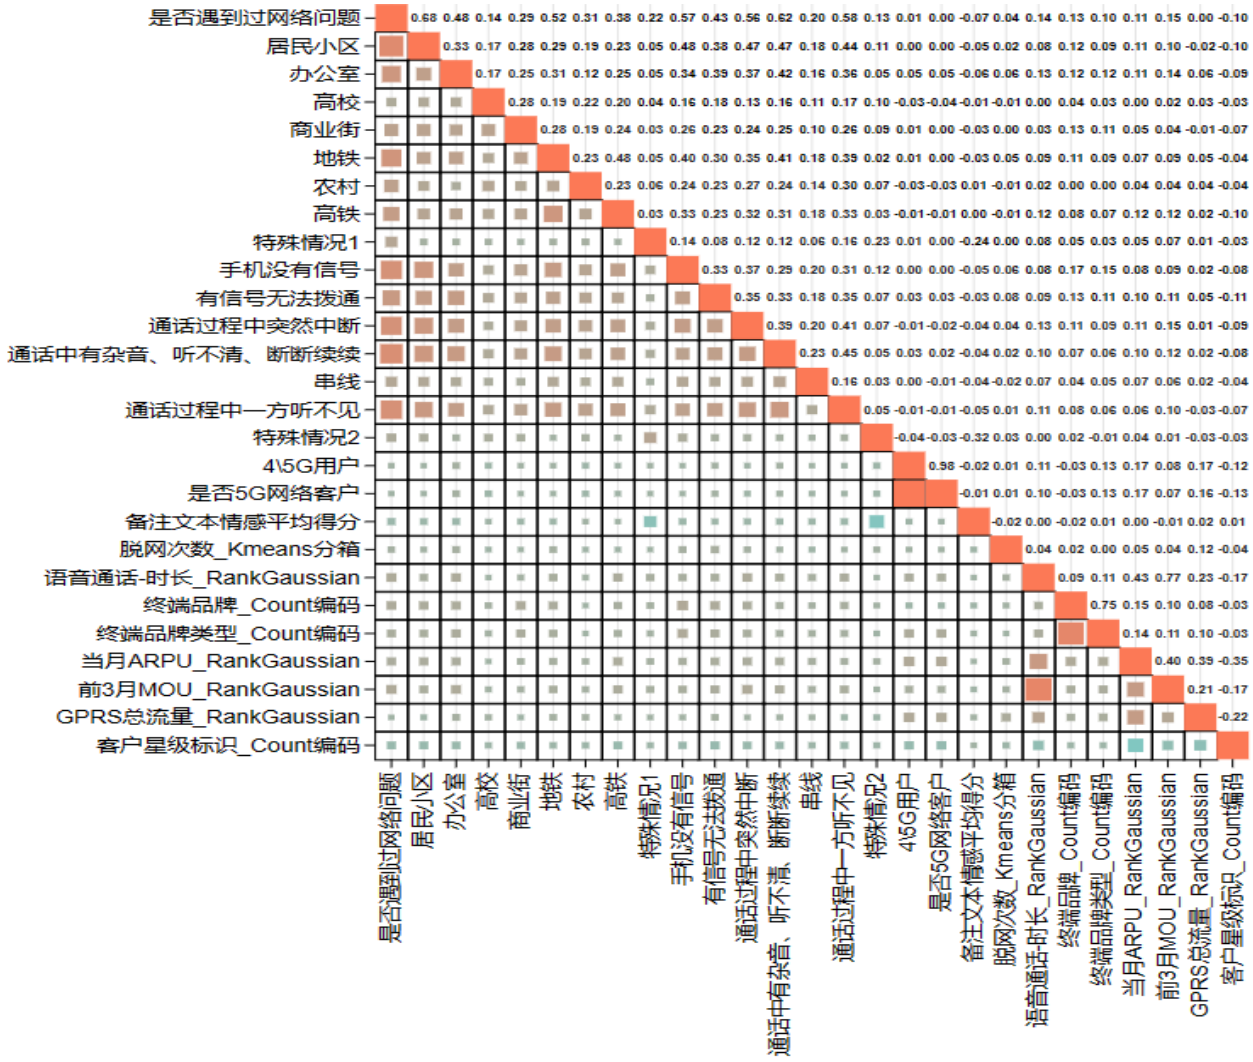


图 12 语音业务自变量相关系数热力图

5.3.3 语音业务验证集和测试集特征分布一致性探索

在上述处理后，本文根据训练集:验证集=9:1 分层抽样划分得到：训练集 4883×26 和验证集 543×26。为了防止训练集和测试集分布不一致导致模型过拟合训练集，以提高模型分类准确度，本文使用核密度估计图对比训练集和测试集的分布。如下图可知，预处理后的接通掉话次数_KMeans 分箱、mos 质差次数_RankGaussian、套外流量_KMeans 分箱、套外流量费_KMeans 分箱、外省流量占比_KMeans 分箱、省际漫游-时长_KMeans 分箱、前 3 月 ARPU_KMeans 分箱、GPRS-国内漫游-流量_KMeans 分箱共 8 个特征存在协变量偏移即独立变量的偏移，为模型在测试集上表现较好，本文将其删除。

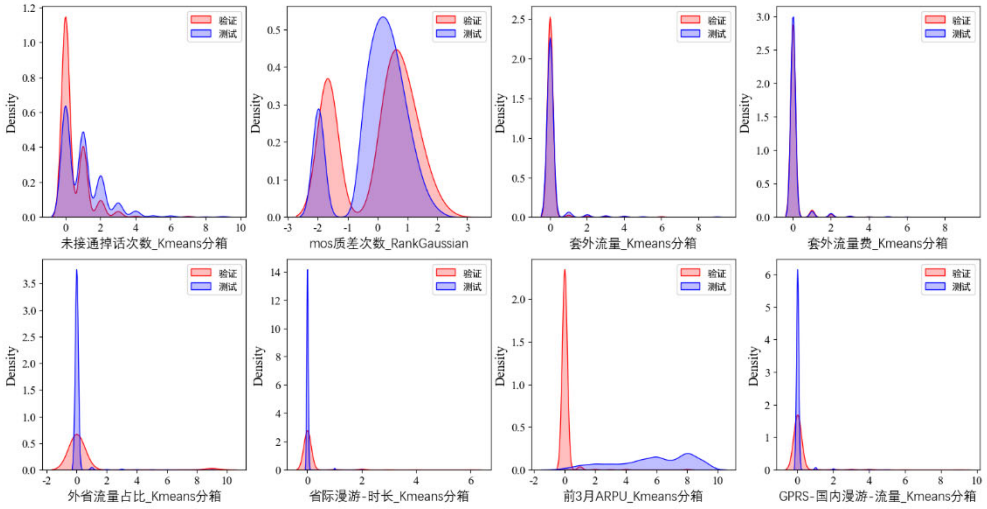


图 13 删除变量的核密度估计图

5.4 语音业务预处理的总结

综上所述，经数据清洗和特征工程后得到的语音业务构建的特征向量组成如下表所示，共 26 个输入特征，验证集和测试集作如上相同处理。

表 11 语音业务的特征向量

是否遇到过网络问题	居民小区
办公室	高校
商业街	地铁
农村	高铁
特殊情况 1	手机没有信号
有信号无法拨通	通话过程中突然中断
通话中有杂音、听不清、断断续续	串线
通话过程中一方听不见	特殊情况 2
4\5G 用户	备注文本情感平均得分
脱网次数_Kmeans 分箱	语音通话-时长_RankGaussian
终端品牌_Count 编码	终端品牌类型_Count 编码
当月 ARPU_RankGaussian	前 3 月 MOU_RankGaussian
GPRS 总流量_RankGaussian	客户星级标识_Count 编码

5.5 上网业务的数据清洗

5.5.1 上网业务查找缺失值并计算占比

同语音业务，本文首先对上网业务缺失值进行可视化分析，其中空白值越多表示缺失情况越严重。

由表十三可知备注类数据的缺失值占比均大于 90%，王者荣耀质差次数缺失占比达到 95.1%，上网质差次数缺失 6134 个，微信质差次数缺失 5708 个。

表 12 上网业务的缺失值数据缺失值和占比表

字段名	缺失数量	缺失占比	脱网次数	5924	0.843875
场景备注数据	6651	0.947436	重定向次数	3804	0.54188
现象备注数据	6881	0.980199	2G 驻留时长	3804	0.54188
APP 大类备注	6953	0.990456	微信质差次数	5708	0.813105

APP 小类视频备注	6910	0.98433	王者荣耀质差次数	6679	0.951425
APP 小类游戏备注	6977	0.993875	王者荣耀使用次数	414	0.058974
APP 小类上网备注	6949	0.989886	游戏类 APP 使用天数	414	0.058974
上网质差次数	6134	0.873789	游戏类 APP 使用次数	414	0.058974
脱网次数	5924	0.843875	脱网次数	5924	0.843875

5.5.2 上网数据空白值处理

按附件 5 中的上网打分数据字段说明进行对以下特征进行空白值为 0 填补。上网质差次数、脱网次数、重定向次数、2G 驻留时长、微信质差次数、王者荣耀质差次数共 6 个特征。

5.5.3 上网业务异常值处理

1、对于性别变量存在性别不详的异常情况，性别不详统计得到共 402 个，性别不详数据量较大，本文使用众数对异常值进行修正，即用“男”做异常值进行修正。

表 13 性别标签示意表

性别	个数	占比
男	4340	61.82%
性别不详	402	5.73%
女	2278	32.45%

2、终端品牌、终端品牌类型中将 0 当作分类变量的一种，不删除。

5.6 上网业务的特征工程

5.6.1 上网业务特征取交集

由于训练集和预测集的特征不同，本文将附件 2 和附件 4 中特征取交集操作。经对比分析得到：

1、附件 2 删除变量：重定向次数、2G 驻留时长、王者荣耀质差次数、高单价超套客户（集团）、高频高额超套客户（集团）、是否全月漫游用户、年龄、王者荣耀使用次数、游戏类 APP 使用天数、游戏类 APP 使用次数、王者荣耀使用天数、游戏类 APP 使用流量、抖音使用流量（MB）、今日头条使用流量、快手使用流量、优酷视频使用流量、腾讯视频使用流量、小视频系 APP 流量、阿里系 APP 流量、网易系 APP 流量、腾讯系 APP 流量、王者荣耀 APP 使用流量、蜻蜓 FMAPP 使用流量、饿了么使用流量、美团外卖使用流量、天猫使用流量、大众点评使用流量、滴滴出行使用流量、通信类应用流量、游戏类应用流量、网页类应用流量、音乐类应用流量、视频类应用流量、邮箱类应用流量、终端类型、操作系统、终端制式、当月 GPRS 资源使用量（GB）、是否校园套餐用户、校园卡无校园合约用户、校园卡校园合约捆绑用户、当月高频通信分公司、畅享套餐档位、畅享套餐名称、主套餐档位、近 3 个月平均消费（剔除通信账户支付）、近 3 个月平均消费（元）、本年累计消费（元）、码号资源-激活时间、码号资源-发卡时间。共 54 个特征。

2、附件 4 删除变量：是否遇到网络问题、学习强国、是否投诉、4\5G 用户、是否关怀用户、是否 4G 网络客户（本地剔除物联网）、外省语音占比、语音通话-时长（分钟）、省际漫游-时长（分钟）、当月 ARPU、前 3 月 ARPU、前 3 月 MOU、外省流量占比、GPRS 总流量（KB）、GPRS-国内漫游-流量（KB）共 15 个特征。

3、数值统一：-1 更换为 0，其他数字更换为 1

5.6.2 上网业务特征统一编号处理

为使其拥有统一的标准，本文进行统一编号处理：

表 14 编号示意表

居民小区、办公室、高校、商业街、地铁、农村、高铁、其他，请注明
看视频卡顿、打游戏延时大、打开网页或 APP 图片慢、下载速度慢、手机支付较慢、其

他，请注明
网络信号差、没有信号、显示有信号上不了网、上网过程中网络时断时续或时快时慢、手机上网速度慢、其他，请注明
爱奇艺、优酷、腾讯视频、芒果 TV、搜狐视频、抖音、快手、火山、咪咕视频、其他，请注明、全部都卡顿
和平精英、王者荣耀、穿越火线、梦幻西游、龙之谷、梦幻诛仙、欢乐斗地主、部落冲突、炉石传说、阴阳师、其他，请注明、全部游戏都卡顿
微信、QQ、淘宝、京东、百度、今日头条、新浪微博、拼多多、其他，请注明、全部网页或 APP 都慢

原数据	-1（否）	其他数字（是）
现数据	0（否）	1（是）

5.6.3 上网业务文本数据处理

同语音业务文本数据处理，对上网业务中场景备注数据、现象备注数据、APP 大类备注、APP 小类视频备注、APP 小类游戏备注、APP 小类上网备注共六种用户描述情感分析，将空白处填补中性词：一般，调用 jieba 库对文本进行分词，调用 SnowNLP 库进行文本情感分析得到情感分数，最后将六种用户描述情感分数取平均值得到上网业务的文本情感平均得分。

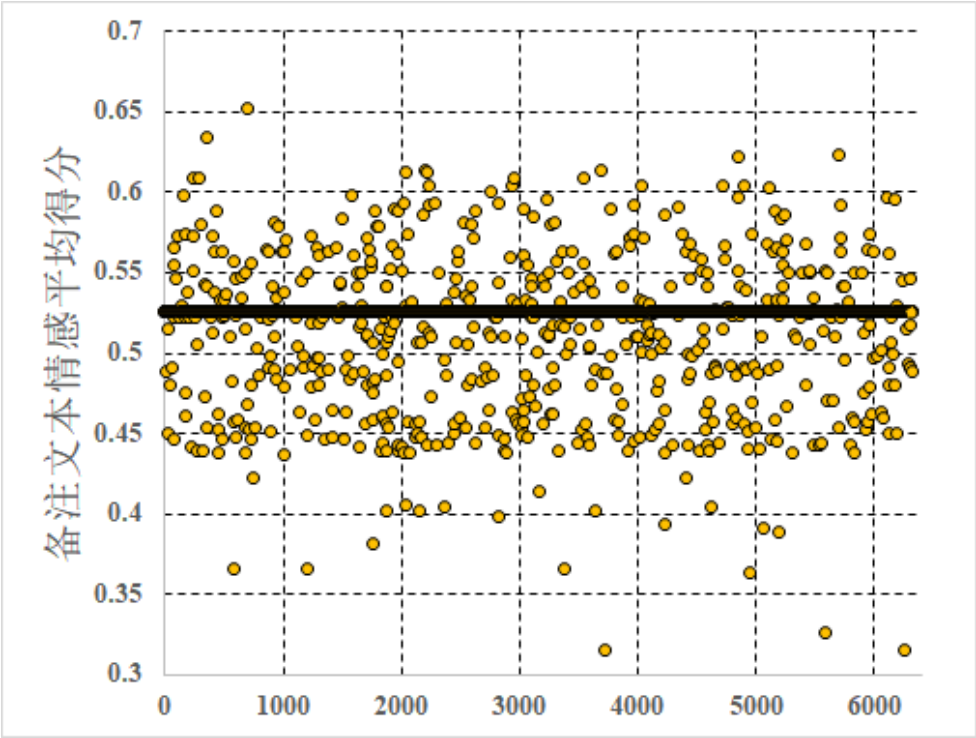


图 14 上网业务的文本情感平均得分图

5.6.4 上网业务分类变量 LabelEncode

由于各个类别之间相互独立，本文利用 LabelEncode 对性别、是否 5G 网络客户、是否不限量套餐到达用户进行编码。

1、对性别进行编码，男/性别不详：0，女：1

2、对是否 5G 网络客户进行编码，否：0，是：1

3、对是否不限量套餐到达用户进行编码，否：0，是：1

5.6.5 上网业务分类变量 CountEncode

终端品牌、终端品牌类型、客户星级标识的类别分别为：33、702 和 9，本文利用

CountEncode 对其进行编码，下表为上网业务部分编码示意表：

表 15 上网业务终端品牌编码示意表

终端品牌	频数	编码
小米科技	909	909
…	…	…
华为	2447	2447

5.6.6 删除类别严重单一化的分类变量

观察到部分特征标签严重单一化，此情况会添加数据的噪声使得模型分类可靠性下降，故本文将其删除。高校、特殊情况 2、特殊情况 3、优酷、芒果 TV、搜狐视频、快手、火山、咪咕视频、特殊情况 4、和平精英、王者荣耀、穿越火线、梦幻西游、龙之谷、梦幻诛仙、欢乐斗地主、部落冲突、炉石传说、阴阳师、特殊情况 5、全部游戏都卡顿、手机 QQ、新浪微博、拼多多、特殊情况 6 共 26 个特征存在严重单一化情况。其中部落冲突特征的数据频数占比如下表，其他特征类似。

表 16 部落冲突标签示意表

	标签	占比
部落冲突	0	96.2963%
	1	3.7037

5.6.7 上网业务连续变量 KMeans 聚类分箱

由 10 种满意度等级出发从而进行聚类数目 K=10 的 KMeans 分箱，对上网质差次数、脱网次数、微信质差次数、套外流量（MB）、套外流量费（元）进行分箱，下表为套外流量（MB）分箱后的结果：

表 17 套外流量（MB）KMeans 聚类分箱示意表

	标签	样本个数
套外流量（MB）	0	1523
	1	255
	…	…
	7	1

5.6.8 上网业务连续变量 RankGaussian 归一化

同理，对当月 MOU 进行 RankGaussian 归一化。

5.7 上网业务数据探索

5.7.1 上网业务整体数据探索

下图为各种场景下四项指标的雷达图和各个场景下指标所占百分比饼图

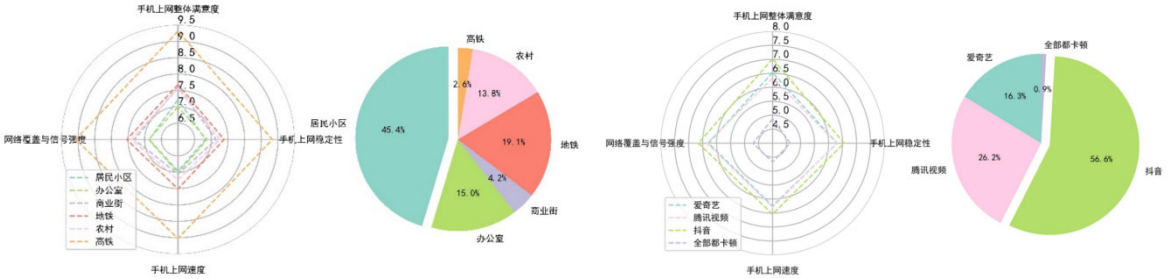


图 15 各种场景下四项指标的雷达图和各个场景下指标所占百分比饼图

由图 14 可知在高铁上、地铁上的四项指标平均分在所有场景中排名前二，办公室、居民小区场景下四项评分类似，剩下的场景评分趋近相同。全部视频 APP 都卡顿的四项平均分是最低的，爱奇艺和腾讯视频卡顿评分趋近相同，而抖音卡顿的四项评分最高，抖音属于短视频平台，因此可能说明短视频网络卡顿对于用户体验影响较小。

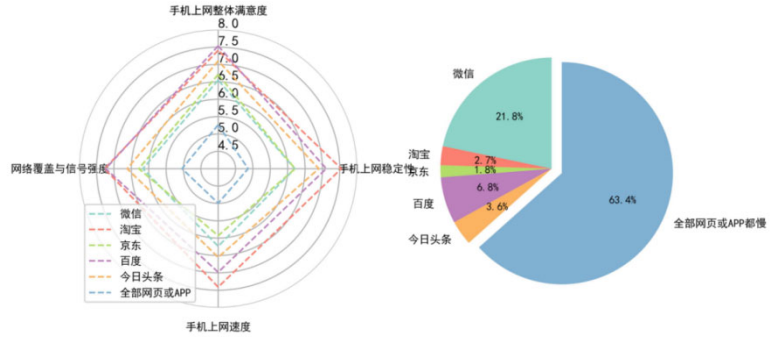


图 16 各种场景下四项指标的雷达图和各个场景下指标所占百分比饼图

由图 15 可知，百度卡顿的用户手机上网整体满意度是最高的，全部网页或 APP 卡顿的用户、微信卡顿的用户用户手机上网整体满意度排名倒数，微信作为一个日常生活几乎必备的 APP，它的卡顿对于用户上网满意度的影响确实很大。

5.7.2 上网业务自变量相关性探索

考虑到选择对上网业务数据进行正态分布检验后，发现存在非正态现象，绘制自变量间 Spearman 相关系数热力图。其中强相关性的相关系数大于 0.8。相关性最大的为套外流量费_KMeans 分箱与终端品牌_Count 编码为 0.72，发现所有特征变量无较强相关性。

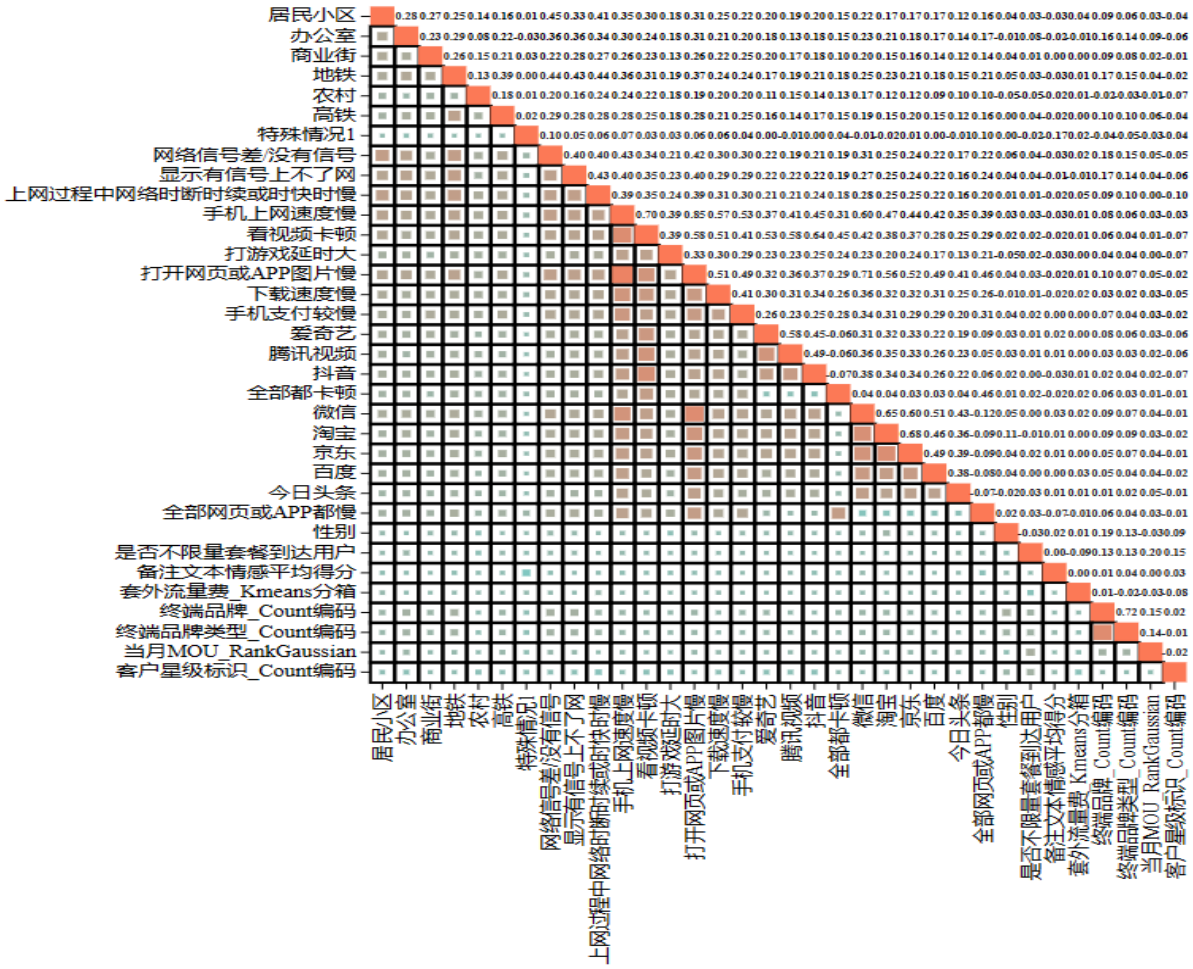


图 17 上网业务自变量相关系数图

5.7.3 上网业务验证集和测试集特征分布一致性探索

删除用户 id 后验证集和测试集作如上相同处理。且根据训练集:验证集=9:1 分层抽样划分得到：训练集 6318×75、验证集 702×75。绘制特征 KDE(核密度估计)分布图后发现：下列变量在验证集和测试集上分布不一致，予以删除是否 5G 网络客户、上网质

差次数_KMeans 分箱、脱网次数_KMeans 分箱、微信质差次数_KMeans 分箱、套外流量_KMeans 分箱。

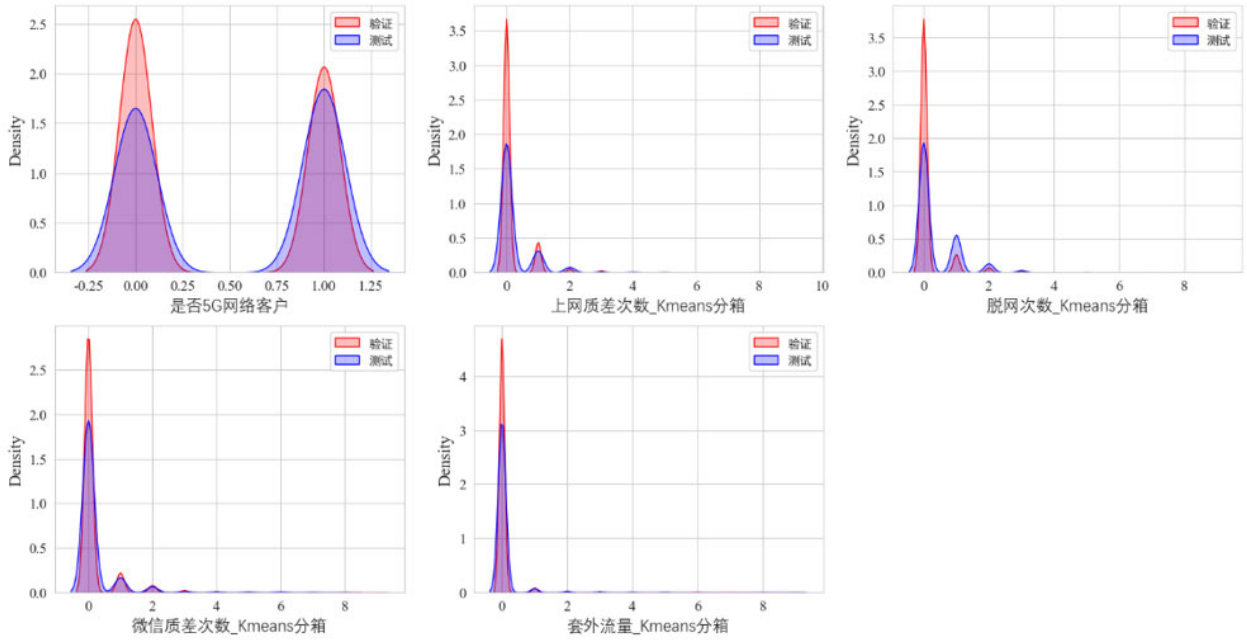


图 18 部分特征的 KDE 分布图

5.8 上网业务预处理的总结

综上所述，经过上述处理后得到如下 34 个输入特征：

表 18 语音业务的特征向量

居民小区	办公室
商业街	地铁
农村	高铁
特殊情况 1	网络信号差/没有信号
显示有信号上不了网	上网过程中网络时断时续或时快时慢
手机上网速度慢	看视频卡顿
打游戏延时大	打开网页或 APP 图片慢
下载速度慢	手机支付较慢
爱奇艺	腾讯视频
抖音	全部都卡顿
微信	淘宝
京东	百度
今日头条	全部网页或 APP 都慢
性别	是否不限量套餐到达用户
备注文本情感平均得分	套外流量费_Kmeans 分箱
终端品牌_Count 编码	终端品牌类型_Count 编码
当月 MOU_RankGaussian	客户星级标识_Count 编码

六、模型的建立和求解

6.1 问题一的建模和求解

本文首先进行模型性能探索工作，建立了 KNN、RondomForest、LightGBM、XGBoost、SMOTEABAG 模型，以 CKS 和 MAE 为评价指标，得出 SMOTEABAG 模型在该问题上性能表现最好，以 SMOTEABAG 模型为主模型，根据给出的 4 种得分的分类的基决策树示意图和特征重要性排序，得出各因素对客户打分影响程度的量化分析和结果。

6.1.1 多模型性能的探索

为探究影响客户语音业务和上网业务满意度的主要因素，基于第 5 节数据预处理得到的 26 个语音业务特征和 34 个上网业务特征，并对特征自相关性进行分析。

- **SMOTEABAG 模型**[5]

算法思想：SMOTEABAG 随机森林模型是有多个决策树加权集合构成的，采用多个决策树的投票机制来改善决策树且为了克服不平衡问题，融合了过采样。即多数类首先进行欠采样并分成 N 个组，其中每个组具有相同的大小，我们从多数类和一个增强少数类中获过 N 个新的数据集。少数类和多数类中的每一组将形成一个新的训练集，因此我们得到 N 个新的训练集。使用新生成的数据集，我们训练 N 个决策树。给定一个新的测试示例，通过融合来自 N 个决策树的输出来获得预测结果。

表 19 SMOTEABAG 算法伪代码

输入:训练集 S,测试集 T,Bag 数目 M
输出:对测试集 T 中每个样本所属类别的预测结果
For k=1~M
用 Bootstrap 方法从训练集 S 中抽取样本，构成 S。其中 $\|S_k\|=\|S\|$
在 S_k 的基础上使用 SMOTE 方法生成新的少类样本，直到各类样本数量相等，构成 S_k。
以 S_k 为训练集，训练基分类器 C_k
基分类器 C_k 至 C_k 采用多数投票的方式得到测试集 T 中每个样本所属类别

决策树分类打分：决策树可以通过对已知案例进行分类，建立一个树状结构，并归纳出案例的一些规则，也可根据这些规则，用于样本外的预测和对分类指标进行自学习的特征重要性排序，本文利用此进行对客户语音业务和上网业务满意度的主要因素的量化分析。其基本流程如下图所示：

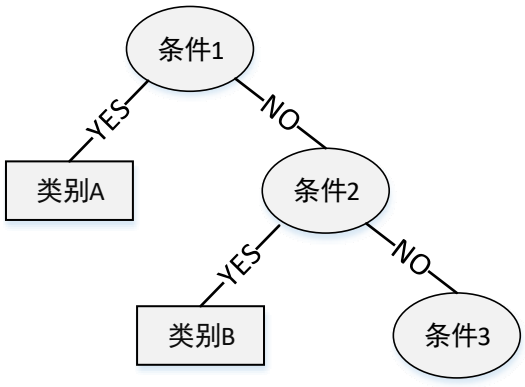


图 19 决策树分类机制示意图

此处利用 GINI 系数作为节点选择的度量，即采用 CART 算法构造决策树。

Step1：节点分割

设 p_i 表示第 i 类指标占比，则 GINI 值的计算公式为：

$$GINI=1-\sum_{i=1}^{n}p_i^2 \quad (4)$$

通过选择使子节点的 GINI 值最小的属性，来找到最佳分割点，将节点分成两部分。

Step2:叶节点类别的确定

叶节点属于哪一个类别的确定是由该节点中的样本点所决定的，也就是能使该叶节点中所有样本点的误分类代价最小的类别就是该叶节点的最终类别。

Step3:剪枝

为了防止决策树分支过多，出现过拟合的情况，我们需要对决策树进行后剪枝。即先构建完整的一颗树，然后根据错误率删除分支，最后未删除的分支节点变为叶节点。

Step4:利用 SMOTEABAG 算法集成多个决策树

基于上述算法流程，我们得到基于 GINI 系数为跟节点选择的 SMOTEABAG 随机森林构建流程如下：

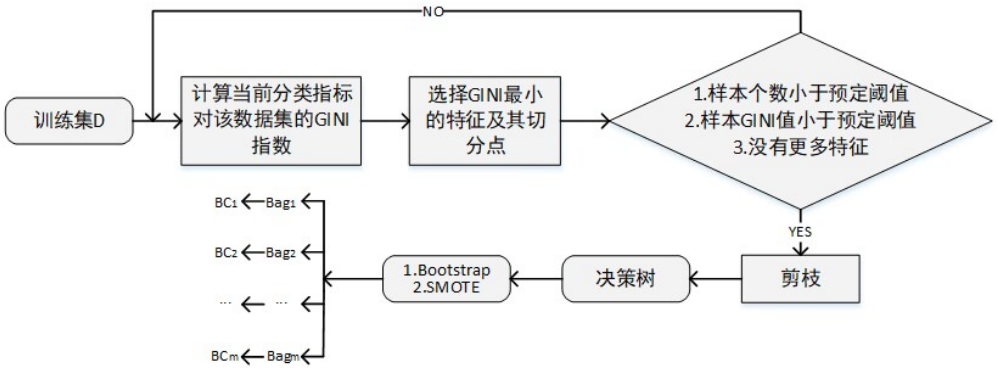


图 20 SMOTEABAG 随机森林构建流程

- **K 近邻(KNN)模型**

K 近邻(KNN)分类器是有监督学习中普遍使用的分类器之一，将观察值的分类判定为离它最近的 k 个观察值中所占比例最大的分类。

- **随机森林模型**

随机森林分类在生成众多决策树的过程中，是通过对建模数据集的样本观测和特征变量分别进行随机抽样，每次抽样结果均为一棵树，且每棵树都会生成符合自身属性的规则和分类结果，而森林最终集成所有决策树的规则和分类结果，实现随机森林算法的分类。

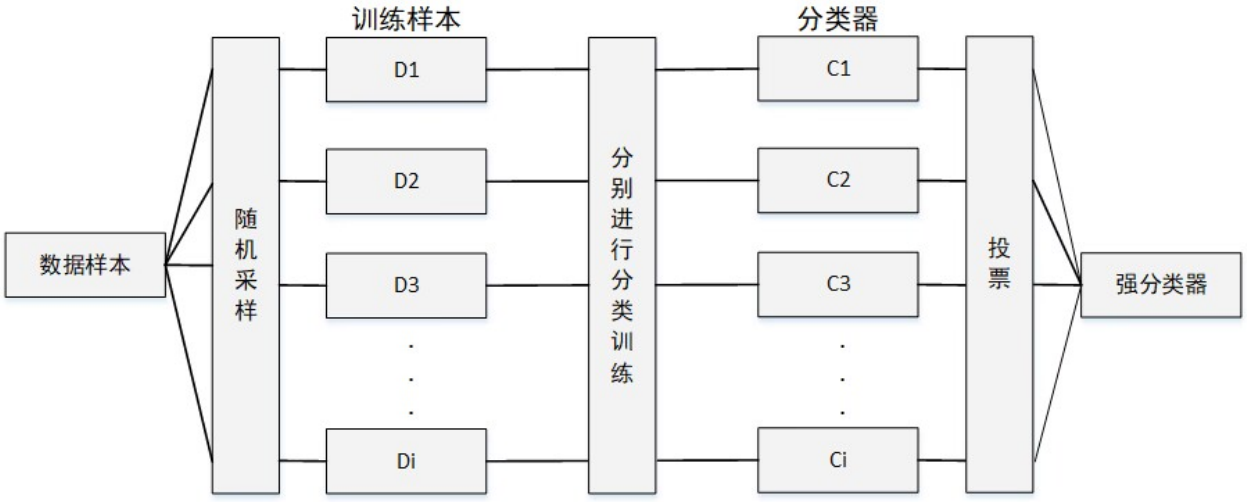


图 21 随机森林算法示意图

- **XGBoost 模型**

算法思想：不断地添加树，不断地进行特征分裂来生长一棵树，每次添加一个树，其实是学习一个新函数，去拟合上次预测的残差。当我们训练完成得到 k 棵树，我们要

预测一个样本的分数，其实就是根据这个样本的特征，在每棵树中会落到对应的一个叶子节点，每个叶子节点就对应一个分数，最后只需要将每棵树对应的分数加起来就是该样本的预测值。

其优化函数可以表示为:

$$R_j = \varphi(\boldsymbol{x}_1, \boldsymbol{x}_2, \boldsymbol{x}_3 ... \boldsymbol{x}_{21}) = \sum_{i=1}^{n} \boldsymbol{l}\left(\boldsymbol{y}_i, \hat{\boldsymbol{y}}_i^{(t-1)} + \boldsymbol{f}_t(\boldsymbol{x}_i)\right) + \boldsymbol{\delta}(\boldsymbol{f}_t) + \ constant \quad (5)$$

其中 l 为损失函数，$\delta(f_t)$ 为正则项，$constant$ 为常数项。

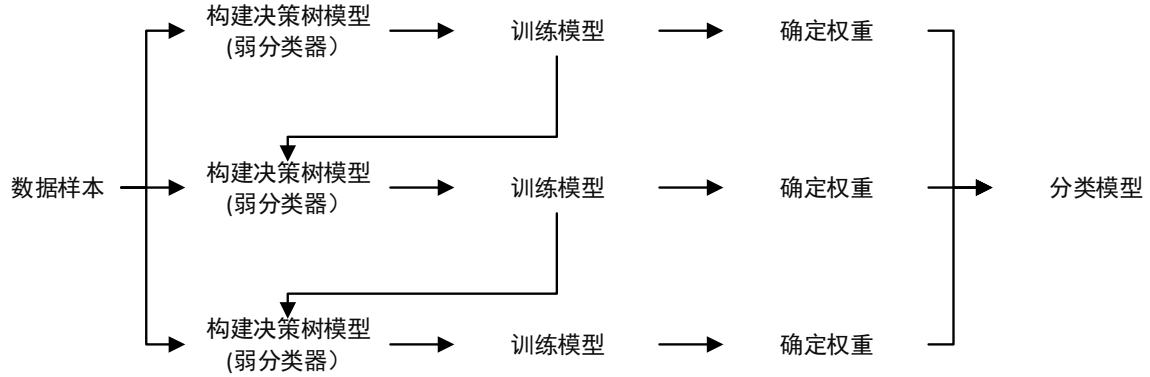


图 22 XGBoost 模型示意图

- **LightGBM 模型**

LightGBM 模型是一种根据直方图的离散值来遍历数据以寻找最优分割点的决策树算法。LightGBM 的特点之一是采用基于 Histogram 的决策树算法，它首先将连续型的特征值离散成 k 个值，然后生成一个宽为 k 的直方图。当遍历样本时，将经过离散的值当作索引。在经过一次遍历后，直方图累积了需要的统计量，然后通过直方图的离散值，遍历寻找最优分割点。采用这种方式既能显著降低减小储存成本和计算成本，又可降低时间复杂。

6.1.2 模型的评价指标和评价方式

- **评价方式：留出法（Hold-Out Method）**

由于留出法可以得到在得到一个在未见数据集或未来数据集上能够更好地泛化的模型，本文使用留出法进行评估，且留出法需要训练/测试集的划分要尽可能保持数据分布的一致性，避免因数据划分过程引入额外的偏差而对最终结果产生影响。

Step1：将数据集分为训练集和测试集两部分

Step2：在训练集上训练模型，在训练之前要选择固定的一些模型超参数设置。

Step3：把训练好的模型在测试集上评估

下图为本模型用 Hold-Out Method 的整个训练的过程示意图：

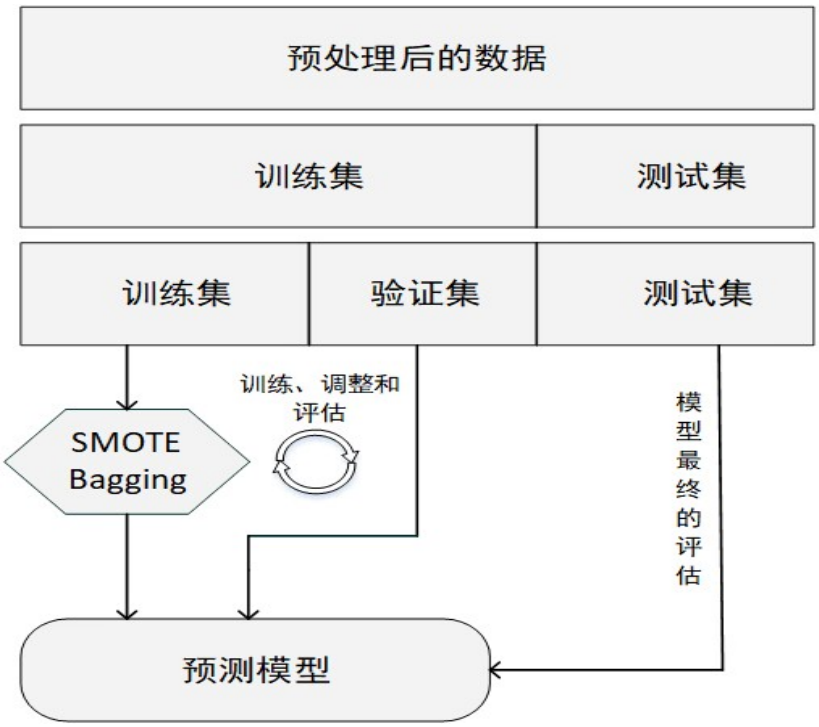


图 23 留出法训练过程示意图

- **评价指标：MAE 和 CKS**

1、MAE：平均绝对值误差，用于评估预测结果和真实数据集的接近程度，其值越小说明拟合效果越好，可以更好地反映预测值误差的实际情况。其公式如下：

$$MAE=\frac{\sum_{i=1}^{N}|Y-Y_{predict}|}{N} \tag{6}$$

2、CKS：Cohen's Kappa Score 指标是专门针对多分类问题中类别不均衡的问题设计的，用来替代简单的 accuracy 指标的，该指标考虑了模型偶然预测准确某一个类别的可能性，可以一定程度上防止模型因为数据集类别不均衡而导致的偏见，是一种更加鲁棒、有效的度量方式，其值越大说明拟合效果越好。计算公式如下：

$$CKS=1-\frac{1-\text{ accuracy}}{1-p_e} \tag{7}$$

其中 $\text{accuracy}=\frac{TP+TN}{TP+FN+FP+TN}$，$p_e=a_1\times b_1+a_2\times b_2+...+a_c\times b_c/n\times n$

假设每一类的真实样本个数分别为$a_1,a_2,...,a_c$而预测出来的每一类的样本个数分别为$b_1,b_2,...,b_c$，总样本个数为n。

6.1.3 语音业务多模型性能探索的求解

语音业务数据集划分:以分层采样对数据集进行划分，训练集和验证集比例为 9:1，即训练集 4883×26 和验证集 543×26，对应输出为 4 种用户打分。

所有分类器都是模型默认超参数时，利用 Python 编程得到，得到如下图，在语音业务中 SMOTEABAG 模型在四种满意度打分的性能最好，所以本文以 SMOTEABAG 模型为主要模型，使用 SMOTEABAG 模型对语音业务各特征的客户打分影响程度的进行量化分析。

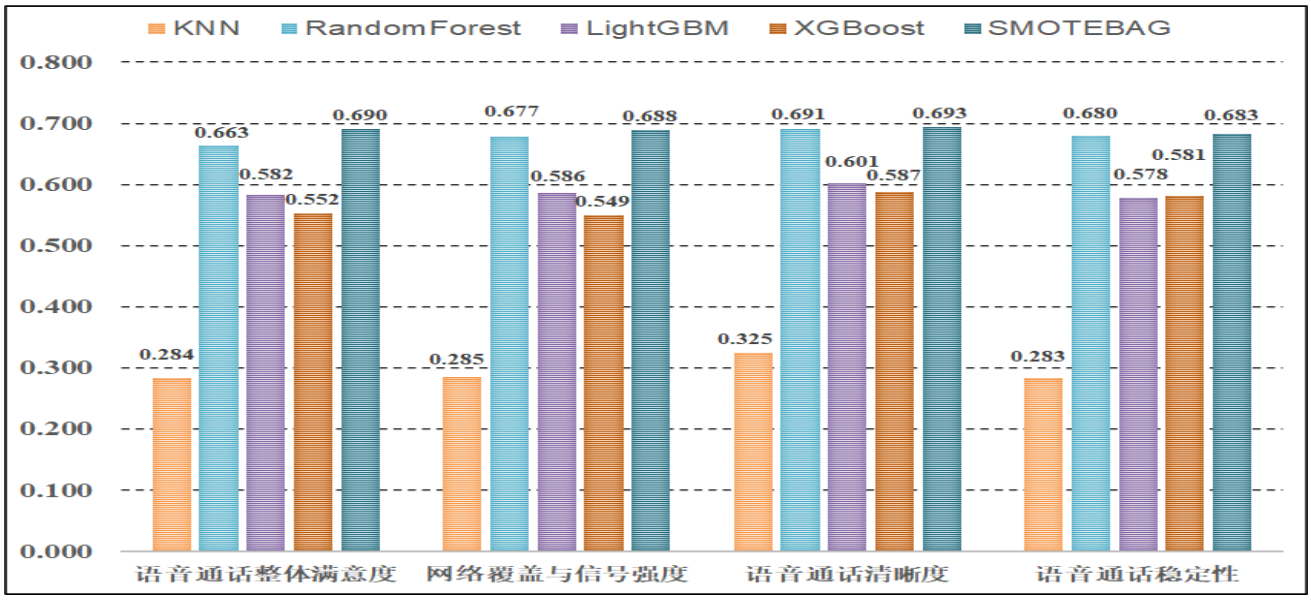


图 24 语音业务 CKS 多模型比较图

6.1.4 基于 SMOTEABAG 的语音业务影响程度的量化分析

- **SMOTEABAG 的基决策树结构图分析**

SMOTEABAG 基于 4 种语音业务特征进行样本分类的一颗决策树分类示意图如下：(由于篇幅限制，只展示三层)

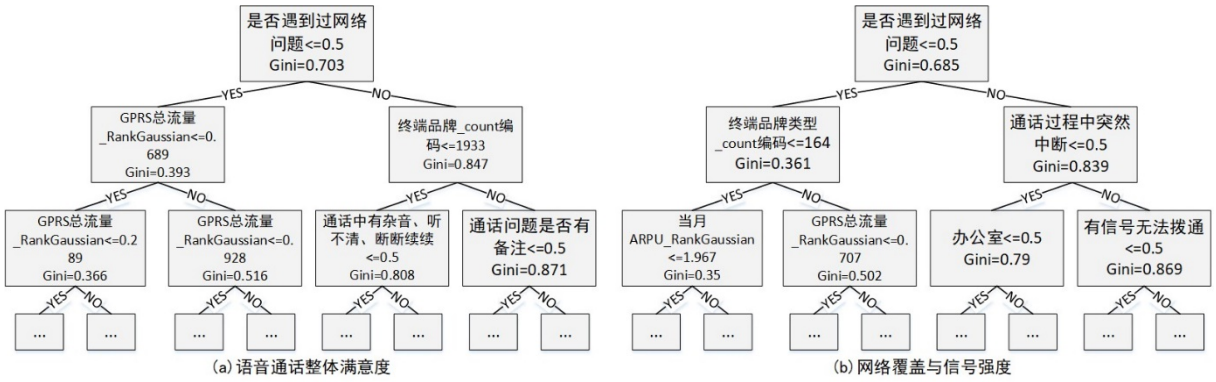


图 25 语音通话整体满意度和网络覆盖与信号强度的决策树结构.

a. 对于语音通话整体满意度，由上图可知，在根节点上，样本特征中的是否遇到网络问题<=0.5 节点处所计算得到基不纯度最高，达到 0.703，因此 SMOTEABAG 分类器选择在此进行分叉，为父亲节点和分类的主要依据。在第一层节点 GPRS 总流量_RankGaussian 和终端品牌_Count 编码的基尼不纯度最高，两个节点基尼不纯度分别达到 0.393 和 0.366 因此在此层上根据 GPRS 总流量_RankGaussian<=0.689 和终端品牌_count 编码<=1933 进行分层为次分类依据，在第二层节点上，GPRS 总流量_RankGaussian 和通话中有杂音、听不清、断断续续和特殊情况 2（通话问题是否备注）。

b. 对于网络覆盖与信号强度，由对应决策树结构可知影响因素为是否遇到网络问题、GPRS 总流量_RankGaussian、终端品牌_Count 编码、当月 ARPU_RankGaussian、办公室、通话中有杂音、听不清、断断续续为 26 个特征中较为关键的分类特征。

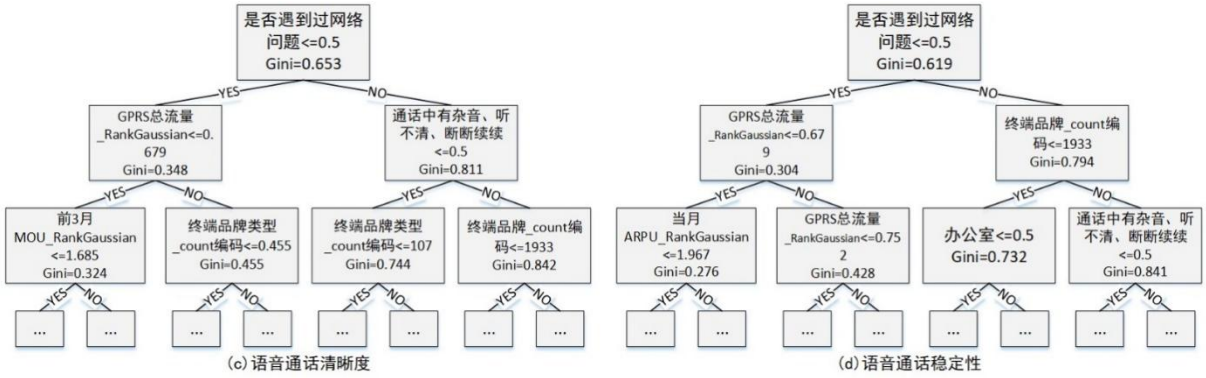


图 26 语音通话清晰度和语音通话稳定性的决策树结构.

c. 对于语音通话清晰度，是否遇到网络问题<=0.5 为主要分类依据，其次按照 GPRS 总流量_RankGaussian<=0.679 和通话中有杂音、听不清、断断续续<=0.5 进行分类，第三层分类依据为前 3 月 Mou_RankGaussian<=1.685,、终端品牌类型_Count 编码<=0.455、终端品牌类型_count 编码<=107、终端品牌类型_count 编码<=1933。

d. 对于语音通话稳定性决策树结构，父亲节点为是否遇到网络问题为主要分类依据，其次的分类依据为 GPRS 总流量_RankGaussian<=0.679、终端品牌_Count 编码<=1933，第三层是当月 ARPU_RankGaussian、GPRS 总流量_RankGaussian、办公室、通话中有杂音、听不清、断断续续。

- **基于 SMOTEABAG 的语音业务特征重要性排序**

特征选择一般可分为过滤式(Filter)和封装式(Wrapper)法[6]。本文的特征重要性排序通过 LOFO 特征选择方法来完成的，相较于其它的特征重要性方法，其特点在于：它可以较好地泛化到未知的测试集、它可以对特征进行分组。特别适用于高维特征，且可以它可以自动对高度相关的特征进行分组，以防止低估其重要性。

LOFO 算法思想：迭代地从特征集合中删除一个特征，并基于选择的度量，使用选择的验证方案评估模型的性能来计算一组集合特征的重要性。

基本步骤

Step1：输入所有的特征，LOFO 基于所有的特征评估包含全部特性的模型的效果;

Step2：一次迭代删除一个特性，重新训练模型,并在验证集上评估其效果;

Step3：记录每个特征重要性的平均值和标准偏差。

由指标得分为合适的分类指标的标准，利用 Python 求解得到结果，4 个的用户得分的特征重要性排序如下图。

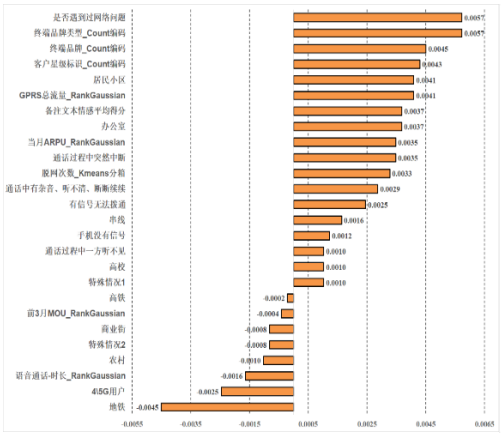


图 27 语音通话整体满意度的特征排序

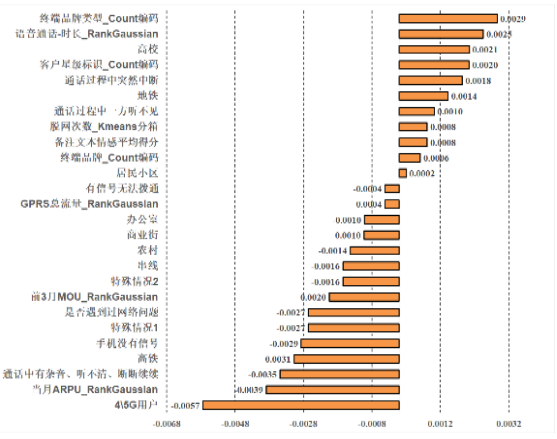


图 28 语音通话稳定性的特征排序

上图左图展示 SMOTEABAG 模型得出的语音通话整体满意度重要性排序图，对语

音业务中语音通话整体满意度影响较大的关键因素有**是否遇到网络问题、终端品牌类型_Count Encode、终端品牌_Count Encode、地铁、客户星级标_Count Encode、居民小区、GRPS 总流量_ RankGaussian**。上图右图展示语音通话稳定性重要性排序图，前 5 个分别是 **4/5G 用户、当月 ARPU_RankGaussian、高铁、手机没有信号、终端品牌类型_CountEncode 和通话中有杂音、听不清、断断续续**。

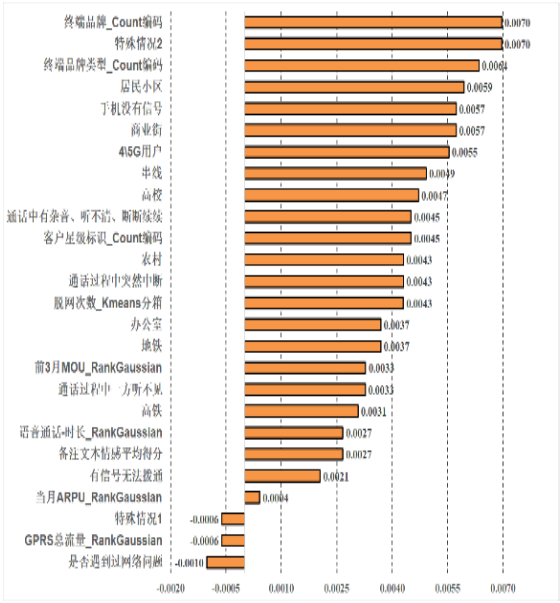


图 29 网络覆盖与信号强度特征重要性排序图

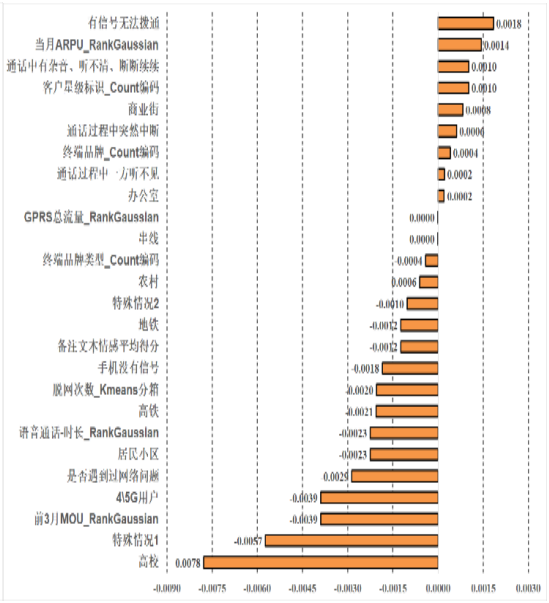


图 30 语音通话清晰度特征重要性排序图

由上图左图可知，影响网络覆盖与信号强度的关键特征为**终端品牌_CountEncode、通话问题是否备注、居民小区、手机没有信号、商业街**。由上图右图可知，语音通话清晰度特征重要性前五为**高校、特殊情况 1、前 3 月 MOU_RankGaussian、4/5G 用户、是否遇到网络问题**。

6.1.5 上网业务多模型性能探索的求解

上网业务根据训练集：验证集=9:1 分层抽样划分得到：训练集 6318×36 和验证集 702×36。本文对比分析 KNN、RondomForest、LightGBM、Xgboost 和 SMOTEABAG 模型，当参数都为默认参数时，得到图 24 多分类的 CKS 比较图。其中模型 4 种满意度分类效果最好的依旧是 SMOTEABAG 模型。本文以 SMOTEABAG 模型为主模型，对上网业务的 4 种满意度进行分类和主要影响因素进行研究。

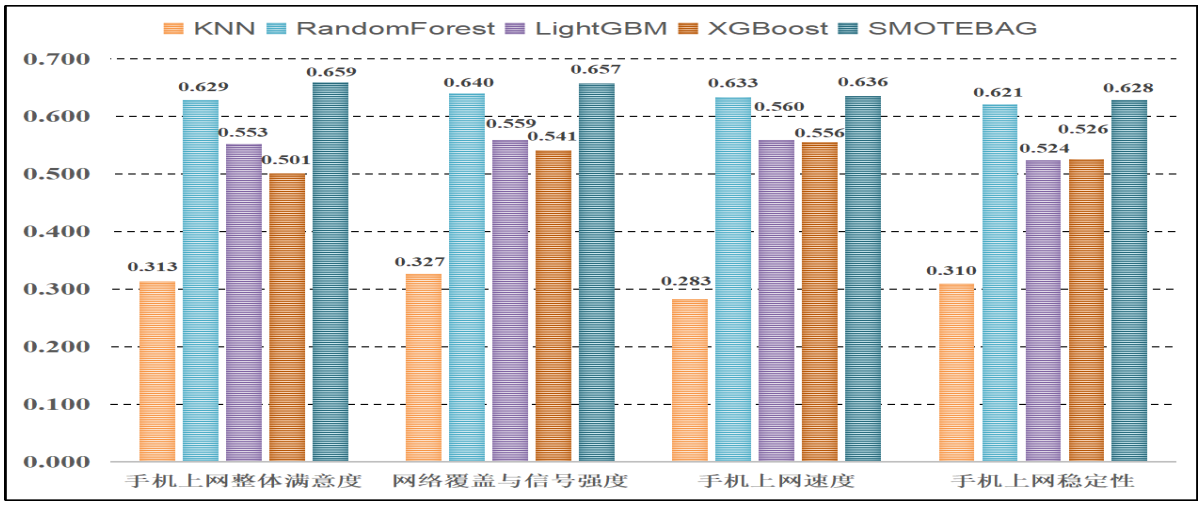


图 31 上网业务多模型的 CKS 比较图

6.1.6 基于 SMOTEABAG 的上网业务影响程度的量化分析

- **SMOTEABAG 的上网业务决策树结构图分析**

下面给出 SMOTEABAG 随机森林基于特征进行样本分类的 4 种上网业务的一颗决策树分类示意图如下(由于篇幅限制，只展示三层)：

a. 由图可知，网络覆盖与信号强度主分类依据是网络信号差/没有信号、次分类依据是上网过程中网络时断时续或时快时慢、打游戏延时大，第三层是上网速度慢，终端品牌，全部网页或 APP 都慢

b. 对于手机上网速度，由网络信号差/没有信号<=0.5 节点处所计算得到基不纯度最高，达到 0.703。在第一层节点 GPRS 总流量_RankGaussian 和终端品牌_Count 编码的基尼不纯度最高，两个节点基尼不纯度分别达到 0.393 和 0.366 因此在此层上根据上网过程中网络时断时续或时快时慢<=0.5 和手机上网速度慢<=0.5 进行分层为次分类依据，在第二层节点上，由手机上网速度慢<=0.5、网络时断时续或时快时慢<=0.5、打游戏延时大<=0.5 继续分类。

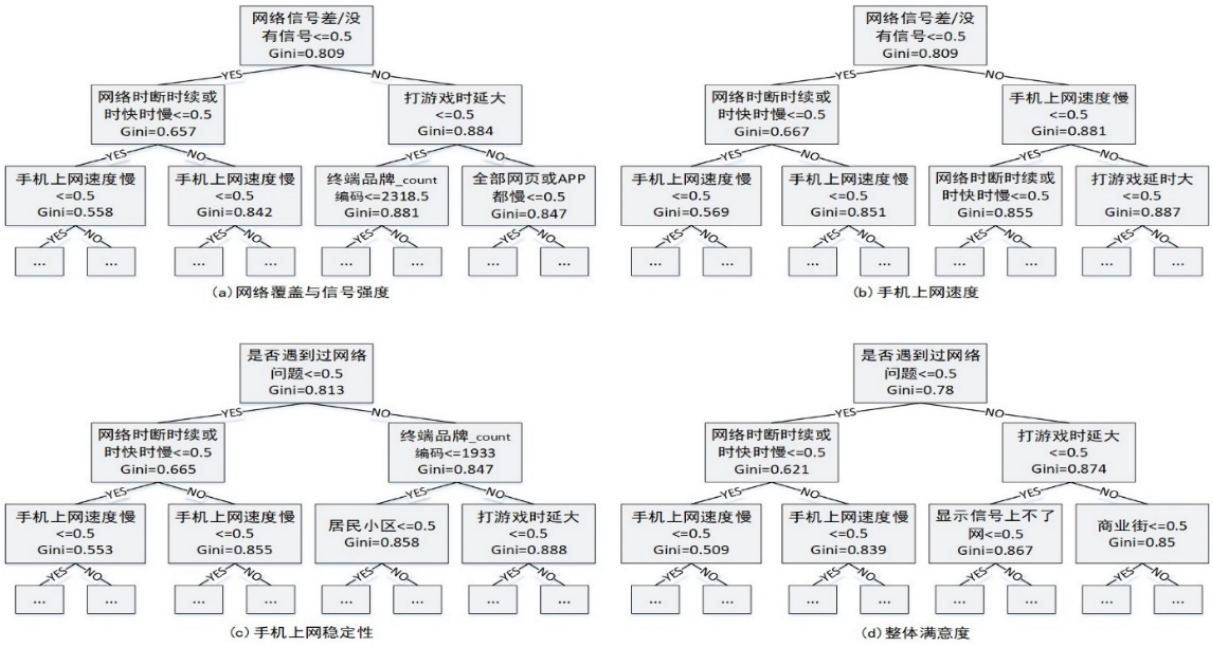


图 32 上网业务四种打分的决策树结构图

c. 手机上网稳定性的主分类依据是网络信号差/没有信号，第一层分类依据是上网过程中网络时断时续或时快时慢<=0.5、第二层分类依据是手机上网速度慢<=0.5、居民小区<=0.5、打游戏延时大<=0.5。

d. 手机上网业务整体满意度由网络信号差/没有信号<=0.5 开始分层，此时的基尼系数为 0.78，第二层分类依据是上网过程中网络时断时续或时快时慢<=0.5 和打游戏延时大<=0.5。第三层节点是上网速度慢、显示有信号上不了网、商业街。

- **基于 SMOTEABAG 的上网业务特征重要性排序**

同理，上网业务通过 LOFO 特征选择得到手机上网整体满意度、手机上网速度、手机上网稳定性、网络覆盖与信号强度的特征重要性排序。由下图左图可知**当月 MOU_RankGaussian、终端品牌类型_CountEncode、是否不限量套餐达到用户**为手机上网整体满意度的主要影响因素。由下图右图可知，对于手机上网稳定性，主要影响因素为**当月 MOU_RankGaussian、终端品牌类型_CountEncode、终端品牌_CountEncode**。

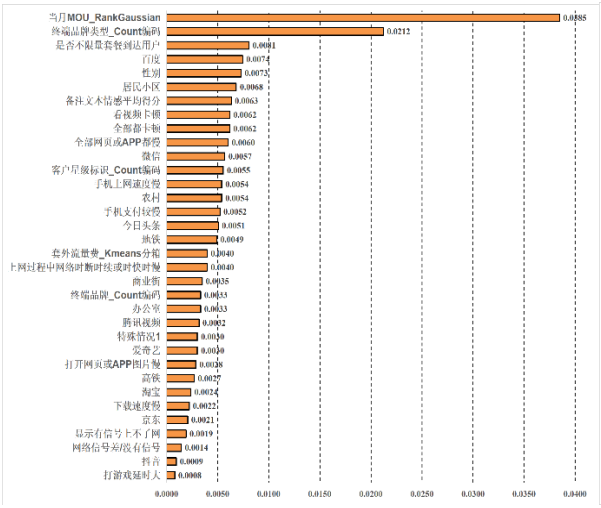


图 33 手机上网整体满意度

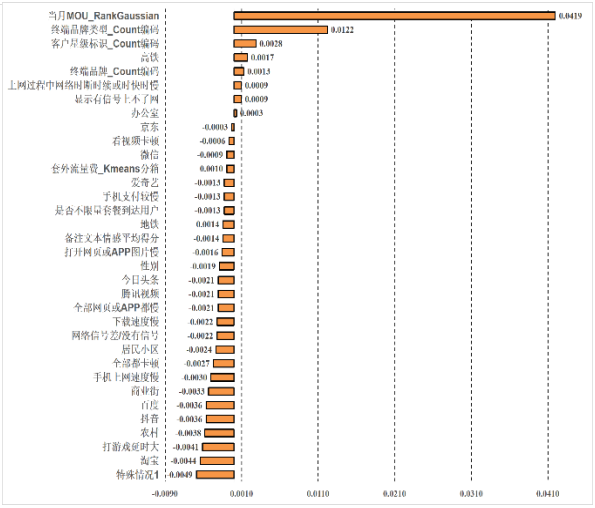


图 34 手机上网速度

由下图左图可知手机上网稳定性的关键影响因素为**当月 MOU_RankGaussian、终端品牌类型_CountEncode、终端品牌_CountEncode**。由下图右图可知对于网络覆盖与信号强度，特征重要性排序前三的分别是**当月 MOU_RankGaussian、终端品牌类型_CountEncode、客户星级标识_CountEncode**。

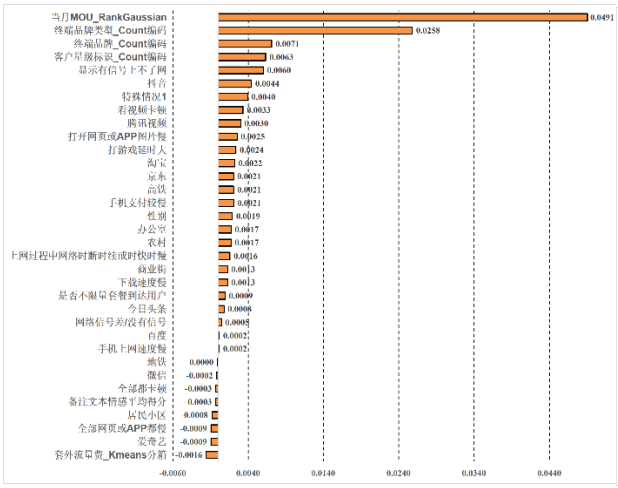


图 35 手机上网稳定性

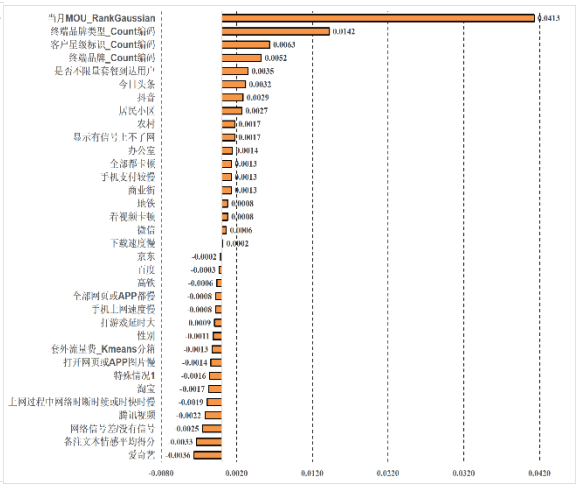


图 36 网络覆盖与信号强度

6.2 问题 2 的建模和求解

基于问题 1 中的性能最优的 SMOTEABAG 模型，本文使用 Optuna 对 SMOTEABAG 进行参数寻优，同样以留出法和 CKS、MAE 作为评价方式和指标，对附件 3、4 数据进行分类预测，得出最优的 CKS、MAE 值。

6.2.1SMOTEABAG 模型参数寻优

SMOTEABAG 随机森林模型建立分类时主要需要优化的参数为：n_estimators 即 SMOTEABAG 最大的决策树个数；bootstrap 参数决定是否有放回的抽样，使用何种数据建立每棵分类树，选取的特征子集中特征的个数通过 max_features 参数来控制；对于单棵用采样集训练完成的决策树 Ti，用袋外数据运行后会产生一个 oob_score；“max_samples”定义将从每个基估计器的训练集中抽取的样本数，查询使用的邻居数：k_neighbors。

Step1：按照每个参数的默认值运算

Optuna 是一个超参数的优化工具，对基于树的超参数搜索进行了优化，它使用被称为 TPESampler“Tree-structuredParzenEstimator”的方法，这种方法依靠贝叶斯概率来确定哪些超参数选择是最有希望的并迭代调整搜索

Step2：本文利用 Optuna 对 SMOTEABAG 随机森林模型 6 个参数寻优

Step3：选择优化后的参数组合

6.2.2SMOTEABAG 语音业务分类模型的求解

1、样本数量划分:以分层采样对数据集进行划分，训练集和验证集比例为 9:1，即训练集 4883×26 和验证集 543×26。

2、SMOTEABAG 语音业务分类模型经 Optuna 调参后的最佳参数设定如下表：

语音通话整体满意度：此时 **CKS：0.6918720445062587，MAE：0.4438305709023941**

表 20 语音业务四种满意度的 SMOTEABAG 参数设定表

max_samples	max_features	bootstrap	oob_score	n_estimators	k_neighbors
0.9	1	True	False	177	4

网络覆盖与信号强度：此时 **CKS：0.8334285080536691，MAE：0.17495395948434622**

max_samples	max_features	bootstrap	oob_score	n_estimators	k_neighbors
1	0.7	True	False	70	6

语音通话清晰度：此时 **CKS：0.8441085513392632，MAE：0.16206261510128914**

max_samples	max_features	bootstrap	oob_score	n_estimators	k_neighbors
0.9	0.7	True	False	243	2

语音通话稳定性：此时 **CKS：0.8365832919325868，MAE：0.1731123388581952**

max_samples	max_features	bootstrap	oob_score	n_estimators	k_neighbors
1	1	True	False	129	5

下图为四种用户打分的混淆矩阵，对于语音通话整体满意度，得分 1 共有 21 个样本，被正确分类的有 17 个，对于得分 2、4 存在 1 个样本误判，其他得分的分类效果较好。对于语音通话稳定性，得分 2 分类正确率 100%，得分 5 存在 1 个样本误判，其他得分分类效果也较优。

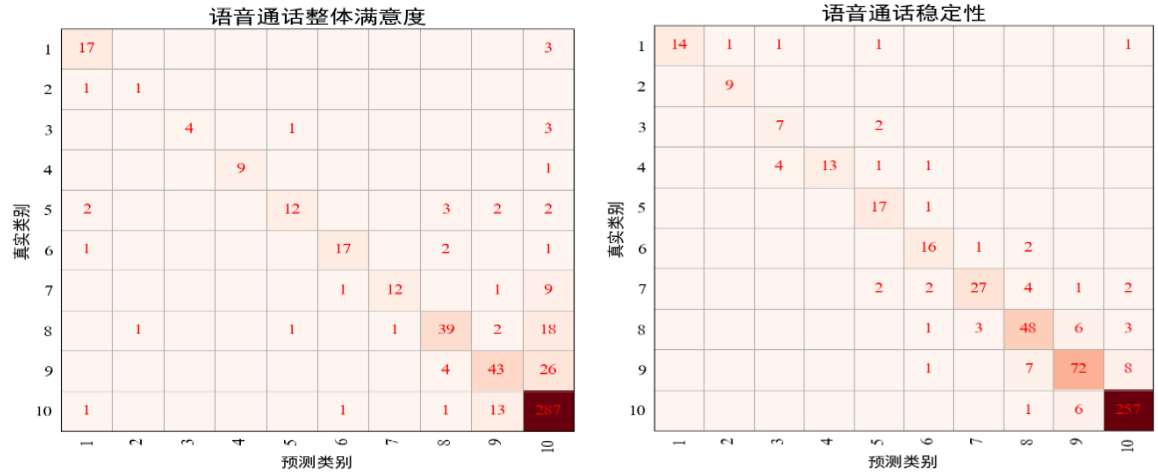


图 7 语音通话整体满意度和语音通话稳定性的混淆矩阵

对于语音通话清晰度，得分 1 实现精准预测为 100%，得分 2 实现 1 个样本被判为得分 6，其他的得分误判的个数也较小，对于网络覆盖与信号强度混淆矩阵，得分 1、2 实现 1 个样本误判，得分 3、4 实现两个样本误判，得分 6 实现 3 个样本误判，其他得分误判率较低。综上所述，SMOTEABAG 分类模型分类效果较优。

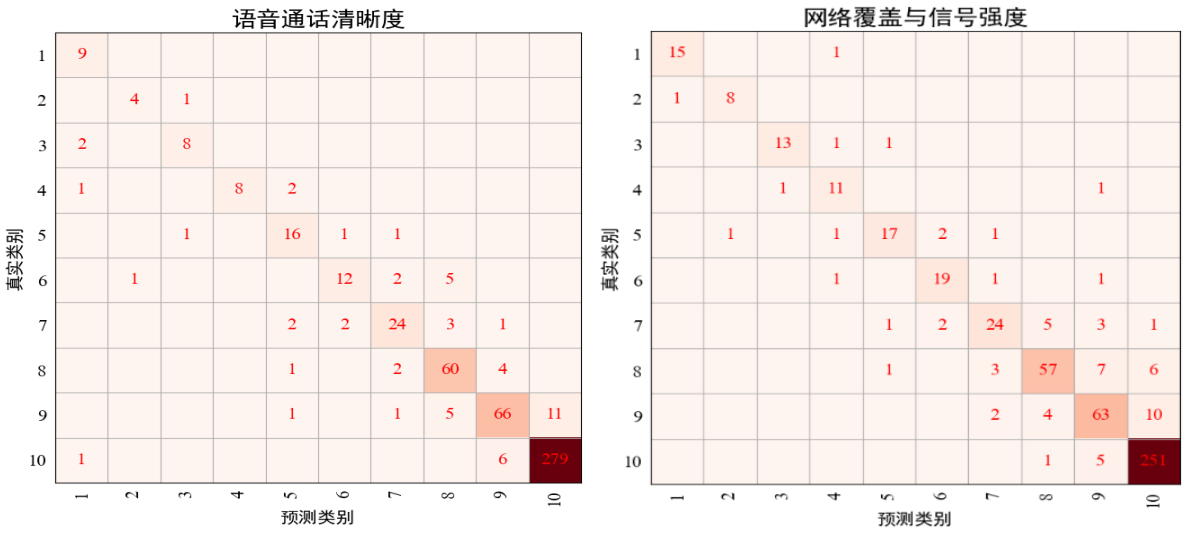


图 38 语音通话清晰度和网络覆盖与信号强度混淆矩阵

6.2.3SMOTEABAG 上网业务分类模型的求解

1.根据训练集：验证集=9:1 分层抽样划分得到：训练集 6318×36 和验证集 702×36

2.本文调用 Python 库中 SMOTEABAG 算法，先使用默认参数来对上网业务的 4 种满意度进行分类，随后再利用 Optuna 对 SMOTEABAG 进行调参，确定 SMOTEABAG 最大的决策树个数、SMOTEABAG 中决策树的最大深度、选取的特征子集中特征的个数、从每个基估计器的训练集中抽取的样本数、查询使用的邻居数且由于样本数量大，本文设置 n_jobs=-1,此时 SMOTEABAG 会使用 CPU 的全部内核，训练速度极大提升。

SMOTEABAG 算法调参后的效果和参数设定如下表所示：

1.手机上网整体满意度最优为 **CKS：0.655528026256516、MAE：0.7649572649572649**

表 21 上网业务四种满意度的 SMOTEABAG 参数设定表

max_samples	max_features	bootstrap	oob_score	n_estimators	k_neighbors
1.0	0.8	True	False	155	8

2.网络覆盖与信号强度最优为 **CKS：0.665204644071772、MAE：0.7293447293447294**

max_samples	max_features	bootstrap	oob_score	n_estimators	k_neighbors
1.0	0.8	True	False	57	8

3.手机上网速度最优为 **CKS：0.6431680855833546、MAE：0.7549857549857549**

max_samples	max_features	bootstrap	oob_score	n_estimators	k_neighbors
1.0	0.9	True	False	71	5

4.手机上网稳定性最优为 **CKS：0.6434319843791876、MAE：0.7735042735042735**

max_samples	max_features	bootstrap	oob_score	n_estimators	k_neighbors
1.0	0.8	True	False	48	6

下图为手机上网整体满意度、手机上网速度的混淆矩阵。对于手机上网整体满意度，对于得分 2 共 4 被正确分类的有 3 个，对于得分 4 实现 80%正确率，其他得分的分类效果较好。对于手机上网速度，得分 4 实现 78.5%的精度，其他得分也能很好地分类

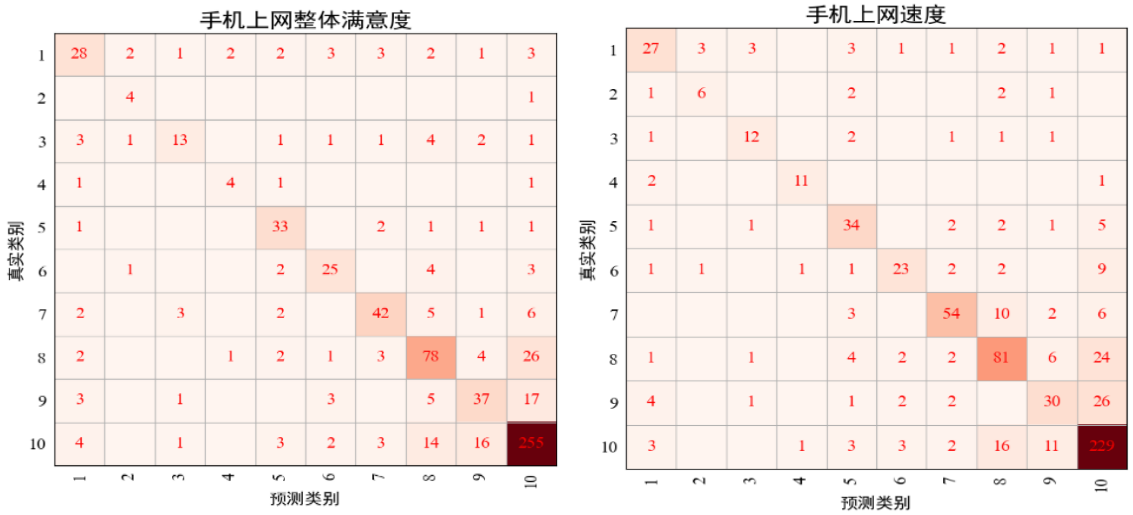


图 39 手机上网整体满意度、手机上网速度的混淆矩阵

下图为网络覆盖与信号强度、手机上网稳定性的混淆矩阵，对于网络覆盖与信号强度，得分 4 实现 93.8%的正确分类，对于手机上网稳定性，得分 10 实现 86.3%正确分类，其他得分类似。

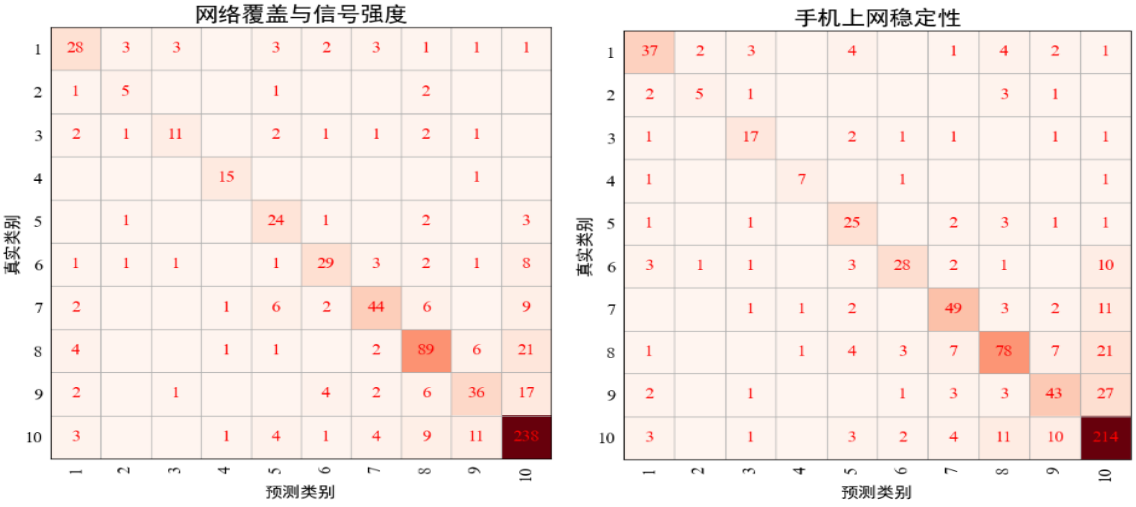


图 40 网络覆盖与信号强度、手机上网稳定性的混淆矩阵

6.2.4 语音业务预测合理性说明

核密度估计是在概率论中用来估计未知的密度函数，属于非参数检验方法之一，通过核密度估计图可以比较直观的看出数据样本本身的分布特征。下图为语音业务的 4 种得分的训练集真实满意度和测试集预测满意度的 KDE 分布图，由图可知，真实满意度和预测满意度分布基本一致，由此可认为本文建立的 SMOTEBAG 语音业务分类模型用训练集训练后进行对测试集的预测具有可靠依据。

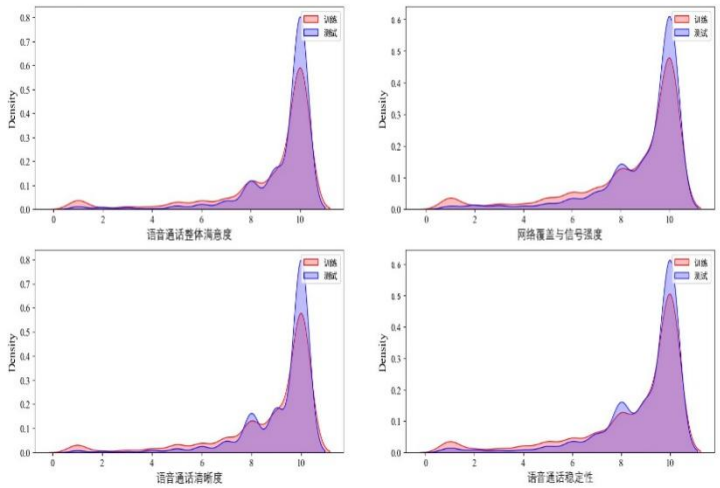


图 41 语音业务的 4 种得分的 KDE 分布图

6.2.5 上网业务预测合理性说明

下图为上网业务的 4 种得分的训练集真实满意度和测试集预测满意度的 KDE 分布图，由图可知，真实满意度和预测满意度分布基本一致，由此可认为本文建立的 SMOTEBAG 上网业务分类模型用训练集训练后进行对测试集的预测具有可靠依据。

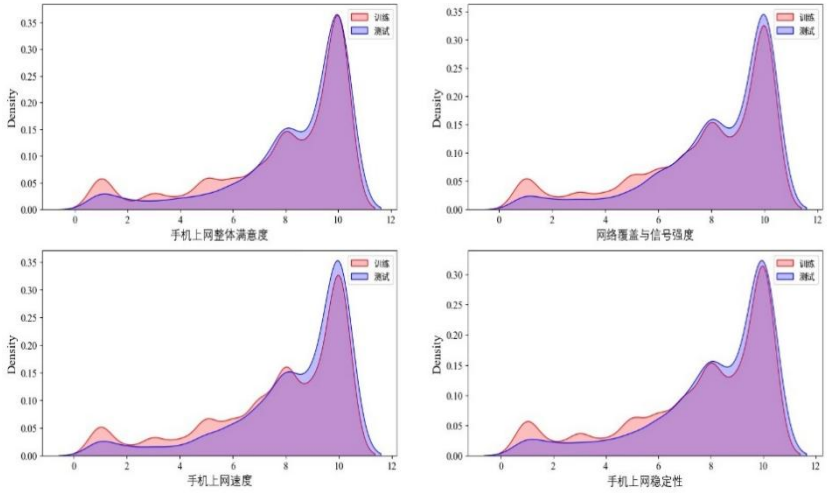


图 42 上网业务的 4 种得分的 KDE 分布图

七、模型的评价和改进

8.1 模型的优点

1、SMOTEABAG 模型有更好的基分类器多样性和更高对少类样本的预测准确率，预测速度较快。

2、本文建立并比较了多个模型性能，选出最优模型进行对客户打分的分类预测，避免了大量的集成学习方法并行使用，节约了后续预测的时间和算力，降低模型复杂度。

3、利用 LOFO 算法来对模型超参数调优，大大提高模型的准确性。

4、对用户备注信息进行了文本情感分析，为用户满意度预测中重要的评测指标。

8.2 模型的缺点

1、本题提供的用户满意度低分类样本数据量较小，导致模型的精度不能继续提高，因此需要有更多的低分类样本量进行模型的训练，进一步发挥 SMOTEABAG 模型的长处。

8.3 模型的改进

1、受限于时间，SMOTEABAG 模型的参数还可以继续优化。

八、模型的应用和推广

当每个类的实例数量之间的差异较大时，机器学习系统就很难学习到与少数类别相关的概念影响机器学习系统创建的分类器的性能。不平衡问题存在于大多数现实世界中，一般情况下，不平衡的数据会使分类器倾向于过拟合，从而降低分类器在少数类上的性能。为了克服这一问题，本文采用了一种不平衡数据分类的新技术 SMOTEABAG 模型。该模型可以通过重新平衡不平衡的数据来缓解这一问题，保持高特异性的同时提高了灵敏度。另一方面，结果表明，再平衡技术比集成分类器更有效地提高了精度。

SMOTEABAG 模型也可以应用到生物信息学的其他领域，因为在许多生物数据集中都存在不平衡问题。我们的方法在预测蛋白质-蛋白质相互作用方面表现良好，仅需要更多额外的研究就可以处理基因微阵列数据，因为基因微阵列数据更高维和不平衡[7]，以及机器故障诊断领域，存在多数正常类和少数故障类也能使用 SMOTEABAG 模型进行分类预测。

九、参考文献

[1]刘雪姣.基于用户满意度的移动运营企业促销能力提升研究[D].北京邮电大学,2012.

[2]李睿.杭州移动通信用户满意度及提升研究[D].江西财经大学,2016.

[3]赵妍妍,秦兵,刘挺.文本情感分析[J].软件学报,2010,21(08):1834-1848.

[4]古平,杨炀.面向不均衡数据集中少数类细分的过采样算法[J].计算机工程,2017,43(02):241-247.

[5]LertampaipornSupatcha,ThammarongthamChinae,NukoolkitChakarida,KaewkamnerdpongBoonserm,RuengjitchatchawalyaMarasri.Heterogeneousensembleapproachwithdiscriminativefeaturesandmodified-SMOTEABAGforpre-miRNAclassification.[J].Nucleicacidsresearch,2013,41(1).

[6]姚旭,王晓丹,张玉玺,权文.特征选择方法综述[J].控制与决策,2012,27(02):161-166+192.DOI:10.13195/j.cd.2012.02.4.yaox.013.

[7]曹鹏.不均衡数据分类方法的研究[D].东北大学,2014.

[8]https://www.chiplot.online/