队伍编号	MCB2401996
赛道	A

基于机器学习算法的洪水发生聚类预测模型

摘要

洪水无论对生态环境还是对人民生活都产生着巨大的危害，因此我们要预防洪水对我们生活的危害，保护我们的健康。本文针对洪水发生的分类和预测问题，采用了**随机森林分类模型、BP 神经网络模型**等机器学习算法，建立了洪水发生的聚类模型和预测模型。

针对问题一，我们首先对 train.csv 中的数据进行预处理，对附件 20 个指标进行编号并以**概率不小于 0.6** 为条件选出洪水概率较高的事件；然后以**分值不小于 9** 为条件选出每个事件当中指标数值较高的指标，表示这些指标与事件中洪水的发生有着较强的关联；接着我们将每个事件的指标编号形成数组后，通过 **FP-Growth 关联分析法**计算得到与洪水发生具有较强关联的指标 **6 个**，其中前两个的指标名称和关联值分别为**基础设施恶化 0.190151808** 和**季风强度 0.189258592，**同时得到与洪水发生不具有关联的指标 4 个，其中前两个的指标名称和关联值分别为**规划不足 0.180800061** 和**排水系统 0.178970528**。最后针对问题的结果给出原因和建议。

针对问题二前半小问，我们主要采用 **K-mean 均值法**对事件的洪水发生概率进行聚类分析，分为高、中、低三类风险洪水事件，同时发现**每个指标平均分值的大小排列为：高> 中>低，并且三类风险洪水事件的总指标分值方差近似相等。**针对后半小问，我们采用**随机森林分类模型**对附件数据进行学习，计算出每个指标的重要性权重，排名前两名的指标名称和权重分别为**地形排水 5.9655%**和**基础设施恶化 5.8961%**。通过上述结果我们选出权重较大的 **6 个指标**对洪水发生概率进行预测，再通过随机森林分类模型建立发生洪水不同风险的预警评价模型，其**训练数据预测准确率为 93.244%**。对于灵敏度的分析，我们分别去除**地形排水指标**和**河流管理指标**后再将模型代入到随机森林分类模型中进行分类学习，发现**模型的准确率均出现大幅度下降**，进而验证模型的灵敏性。

针对问题三，我们根据问题一的结果，运用**BP 神经网络模型**，分别在六个强关联指标和五个强关联指标的情况下建立洪水发生概率的预测模型。**这两个模型的均方误差分别为 0.059 和 0.0614，都具有极高的准确性**。

针对问题四，我们将 test.csv 里的数据代入到问题二所建立的洪水发生概率预测模型，计算得到相应的洪水概率结果并将其写入 submit.csv 文件中。同时我们绘制出了洪水概率结果的直方图和折线图，并通过 **KS 检验法**对该洪水概率分布是否满足正态分布。经过计算我们算出 **H=1**，从而得出**该洪水概率结果分布不符合正态分布**。

关键字：FP-Growth 关联分析法；K-mean 均值法；随机森林分类模型；BP 神经网络模型；KS 检验法

一、问题重述

1.1 问题背景

洪水是暴雨、急剧融冰化雪、风暴潮等自然因素引起的江河湖泊水量迅速增加，或者水位迅猛上涨的一种自然现象，是自然灾害。洪水又称大水，是河流、海洋、湖泊等水体上涨超过一定水位，威胁有关地区的安全，甚至造成灾害的水流。2023 年，全球洪水等造成了数十亿美元的经济损失。

洪水的频率和严重程度与人口增长趋势相当一致。迅猛的人口增长，扩大耕地，围湖造田，乱砍滥伐等人为破坏不断地改变着地表状态，改变了汇流条件，加剧了洪灾程度。在降水多的年份，洪水是否造成灾害，以及洪水灾害的大小，也离不开人为因素，长期以来人为的森林破坏是其重要原因。对森林的肆意砍伐不仅危害自己，而且祸及子孙后代，世界上许多地方，如美索不达米亚、小亚细亚、阿尔卑斯山南坡等由于过度砍伐森林，最后都变成了不毛之地。

1.2 已知条件

- 附件 train.csv 中提供了超过 100 万的洪水数据，其中包含洪水事件的 id、季风强度、地形排水、河流管理、森林砍伐、城市化、气候变化、大坝质量、淤积、农业实践、侵蚀、无效防灾、排水系统、海岸脆弱性、滑坡、流域、基础设施恶化、人口得分、湿地损失、规划不足、政策因素和发生洪水的概率。
- 附件 test.csv 中包含了超过 70 万的洪水数据，其中包含洪水事件的 id 和上述 20 个指标得分，缺少发生洪水的概率。
- 附件 submit.csv 中包含 test.csv 中的洪水事件的 id，缺少发生洪水的概率。

1.3 题目任务

- 分析并可视化附件 train.csv 中与洪水发生有着密切关联的指标和没有密切关联的指标，分析可能的原因；针对洪水的提前预防，提出你们合理的建议和措施。
- 将附件train.csv 中洪水发生的概率聚类成不同类别，分析具有高、中、低风险的洪水事件的指标特征。选取合适的指标，计算不同指标的权重，建立发生洪水不同风险的预警评价模型，最后进行模型的灵敏度分析。
- 基于问题 1 中指标分析的结果建立洪水发生概率的预测模型，从20 个指标中选取合适指标，预测洪水发生的概率，并验证你们预测模型的准确性。如果仅用 5 个关键指标，调整改进洪水发生概率的预测模型。
- 基于问题2中建立的洪水发生概率的预测模型，预测附件 test.csv 中所有事件发生洪水的概率并将预测结果填入附件 submit.csv 中。绘制这74 多万件发生洪水的概率的直方图和折线图，分析此结果的分布是否服从正态分布。

二、题目分析

2.1 问题一的分析

问题一主要让我们分析附件train.csv 中与洪水发生具有密切关联和不具有密切关联的指标并分析原因，给出建议。对于这一题我们主要采用FP-Growth 关联分析算法来计算得到相关的指标：首先我们对 train.csv 中的数据进行处理，对这些指标进行编号并选出洪水概率较高的事件；然后选出每个事件当中指标数值较高的指标，表示这些指标与事件中洪水的发生有着较强的关联；接着对每个事件选出来的指标编号形成数组，并将

所有事件的数组带入到 FP-Growt 的 MATLAB 编程里，计算得到与洪水发生具有较强关联的指标，最后针对问题的结果给出原因和建议。

2.2 问题二的分析

问题二主要要求我们对洪水发生概率进行聚类，分为具有高、中、低风险的洪水三类，并且选取合适的指标，计算指标的权重，建立发生洪水不同风险的预警评价模型，最后进行模型的灵敏度分析。针对问题二的前半小问，我们主要采用K-mean 均值分类法对事件的洪水发生概率进行聚类分析，并分析具有高、中、低风险的洪水事件的指标特征；针对问题二的后半小问，我们主要采用随机森林分类模型对附件数据进行学习，并通过这种方法计算出每个指标的重要程度，进而通过重要程度比例计算出每个指标的权重。通过上述结果我们选出权重较大的指标对洪水发生概率进行预测，再通过随机森林分类模型建立发生洪水不同风险的预警评价模型。对于灵敏度的分析，我们分别去除不同的指标后再将模型代入到随机森林分类模型中进行分类学习，计算并比较预测的正确率，从而对灵敏度进行分析。

2.3 问题三的分析

问题三主要要求我们根据问题一的分析结果选取合适的指标建立洪水发生的预测模型并验证准确性，并且在此基础上建立仅用五个关键指标的风水发生的预测模型。对于这一题，我们主要通过 BP 神经网络预测模型来建立洪水发生的预测模型的。首先确定问题一选出的与洪水发生具有较强关系的重要指标，然后将这些指标和洪水概率的数据代入到 BP 神经网络预测模型的 MATLAB 代码中进行建模，进而验证模型的准确性。对于仅用五个指标的情况，我们只保留5 个与洪水发生具有最强相关性的指标，再将这些指标的数据代入到 BP 神经网络中进行建模。

2.4 问题四的分析

问题四主要要求我们根据问题二所建立的模型来预测 test.csv 文件中的洪水概率并将结果写进 submit.csv 文件中，同时绘制其直方图和折线图并判断其分布是否符合正态分布。针对这一题，我们主要将 test.csv 文件中的数据代入到问题二所建立的随机森林分类学习预测模型中得到预测结果并画出直方图和折线图，同时通过 KS 检验法来判断预测结果的分布是否符合正态分布。

下面是本篇文章的总的解题思维导图：

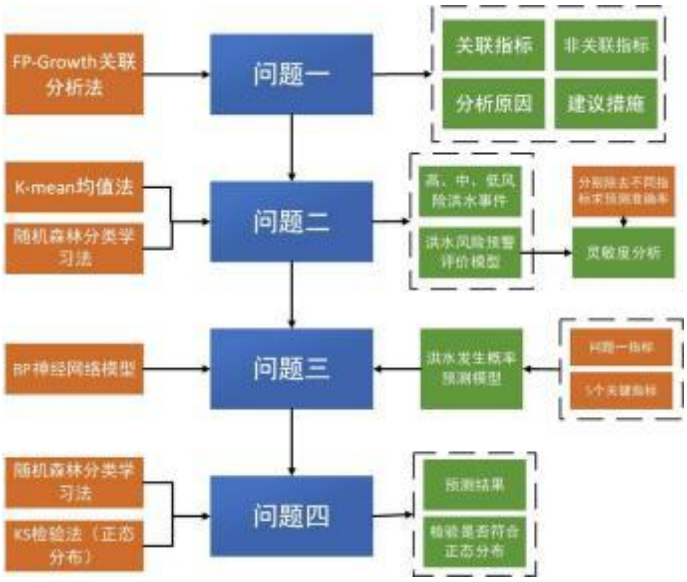


图 1　总思维导图

三、模型假设

- 假设影响洪水发生概率的因素仅限于附件提供的 20 项指标，与其他因素无关。
- 假设附件 train.csv 中数据情况分布均匀和随机，不存在长段数据描述情况相似或相同的情况。
- 假设附件所提供的每一项指标地位相等。
- 假设附件数据没有严重错误，且数据记录属实，无造假情况。

四、符号说明

表 1　模型符号说明表

符号	解释说明	备注
i	指标编号	——
max(i)	第 i 项指标的最大值	——
min(i)	第 i 项指标的最小值	——
x_i'	第 i 项指标的归一化数值	——
x_i	第 i 项指标的原式数据	——

五、数据预处理

为了方便计算求解，我们需要对附件数据进行预处理。而对数据的预处理主要分为三步：指标编号、数据缩减和数据归一化。

5.1 指标编号

为方便题目计算求解，我们需要对附件所提供的指标进行编号处理，我们对附件提供的指标从左到右依次进行编号处理，编号结果如下：

表 2　附件数据指标编号表

指标	季风强度	地形排水	河流管理	森林砍伐
编号	1	2	3	4
指标	城市化	气候变化	大坝质量	淤积
编号	5	6	7	8
指标	农业实践	侵蚀	无效防灾	排水系统
编号	9	10	11	12
指标	海岸脆弱性	滑坡	流域	基础设施恶化
编号	13	14	15	16
指标	人口得分	湿地损失	规划不足	政策因素
编号	17	18	19	20
指标	洪水概率			
编号	21			

5.2 数据缩减

由于附件数据量过大，如果对附件所有训练数据代入计算机中进行计算，那就不仅会造成计算机运算时间过长，还会造成因计算机储存不足导致结果计算失败。因此为缩短计算时间，提高计算效率，我们需要对数据进行缩减处理。对数据进行缩减处理的方式如下：

我们主要对数据的数量进行 1:25 比例的缩减处理，这样我们可以仅通过训练数据中的 1/25 代入计算来求出结果。我们将附件训练数据分为每 25 个数据一组的多组数据，每组数据分别随机抽出一组数据，下表是选中数据的样式：

表 3　选中数据样式表

数据组别	id
1	24
3	66
4	89

5.3 数据归一化

由附件数据可以知道，训练数据的 20 个指标与洪水发生概率的量纲不一致，因此为了方便问题的计算和比较，我们需要再对数据进行归一化处理。归一化处理的步骤为首先我们需要找到相同指标数据的最大值max (i)和最小值 min (i)，这样我们可以求得该指标下每一个数据的归一化数据表达式为：

$$x_i' = \frac{x_i - \max(i)}{\max(i) - \min(i)} \tag{1}$$

其中，i 表示第 i 项指标。

六、问题一的建模与求解

问题一主要让我们分析附件train.csv 中与洪水发生具有密切关联和不具有密切关联的指标并分析原因，给出建议。对于这一题我们主要采用FP-Growth 关联分析算法来计算得到相关的指标：首先我们对 train.csv 中的数据进行处理，对这些指标进行编号并选出洪水概率较高的事件；然后选出每个事件当中指标数值较高的指标，表示这些指标与事件中洪水的发生有着较强的关联；接着对每个事件选出来的指标编号形成数组，并将所有事件的数组带入到 FP-Growt 的 MATLAB 编程里，计算得到与洪水发生具有较强关联的指标：基础设施恶化、季风强度、大坝质量、地形排水、河流管理、淤积。最后针对问题的结果给出原因和建议。

6.1 FP-Growth 关联分析法的介绍

FP-Growth 算法是韩嘉炜等人 2000 年提出的关联分析算法，它采取如下分治策略：将提供频繁项集的数据库压缩到一棵频繁模式树（FP-tree），但仍保留项集关联信息。在算法中使用了一种称为频繁模式树（Frequent Pattern Tree）的数据结构。FP-tree 是一种特殊的前缀树，由频繁项头表和项前缀树构成。FP-Growth 算法基于以上的结构加快整个挖掘过程[1-2]。

相比于 Apriori 算法，FP-Growth 算法具有遍历数据量大大缩短，计算效率高等特点，从而大大缩短计算时间[3]。

FP-Growth 算法的基本思路是不断地迭代 FP-tree 的构造和投影过程。算法描述如下：

- 对于每个频繁项，构造它的条件投影数据库和投影 FP-tree。
- 对每个新构建的 FP-tree 重复这个过程，直到构造的新 FP-tree 为空，或者只包含一条路径。
- 当构造的 FP-tree 为空时，其前缀即为频繁模式；当只包含一条路径时，通过枚举所有可能组合并与此树的前缀连接即可得到频繁模式。

图 2 是 FP-tree 构建的算法流程图：

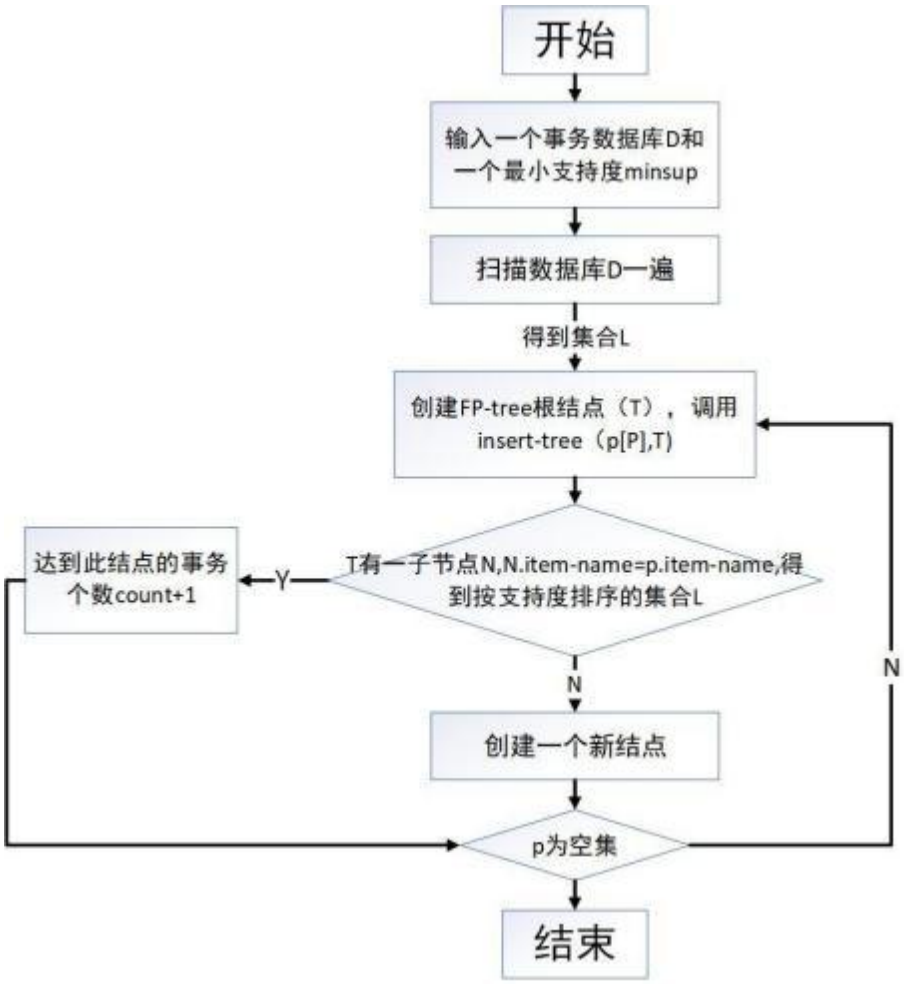


图 2　FP-tree 构建的算法流程图

6.2 训练数据的处理及结果计算

由于数据量过大，我们将训练数据进行 1：25 的缩减处理。将数据进行缩减处理后，为了方便计算，我们又对缩减数据进行进一步的处理。

首先我们需要筛选洪水发生概率较高的事件，我们规定洪水发生概率大于等于 0.6 的事件为洪水发生概率较高事件。

然后对筛选出来的事件我们需要对其相关指标进行筛选：我们规定每个事件中数值大于等于 9 的指标为强关联指标，这些指标也是我们需要进行筛选的指标。

最后我们将对筛选的数据进行预处理，保证它们的量纲相同。

经过上述标准筛选，我们总共在缩减数据中筛选出了 1281 组数据，具体数据数组样例如下表所示:

表 4　筛选数组样例表

数据组别	编号内容
1	1、8、21
3	2、15、21
4	4、6、10、12、21

接下来我们将这些数据代入到 FP-Growth 关联算法模型中进行计算求解，得到了指标编号之间的相关联关系，进而通过计算得到各个指标与洪水概率（编号为21）之间的关联系数如下表所示：

表 5 各指标关联系数结果表

指标编号	16	1	7	2
关联系数	0.190151808	0.189258592	0.187675559	0.187642909
指标编号	3	8	17	6
关联系数	0.187202109	0.186914432	0.186285207	0.185311044
指标编号	14	4	18	9
关联系数	0.184925724	0.184419518	0.183471775	0.183365239
指标编号	11	20	15	5
关联系数	0.182846814	0.182247544	0.181806352	0.181315905
指标编号	19	12	10	13
关联系数	0.180800061	0.178970528	0.178583198	0.177824992

其中，与洪水概率关联性最大的指标是基础设施恶化，其值为 0.190151808。而与洪水概率关联性最大的前六个指标分别为基础设施恶化、季风强度、大坝质量、地形排水、河流管理、淤积。相反，与洪水概率关联性最小的前四项指标分别为规划不足、排水系统、侵蚀、海岸脆弱性，其值分别为 0.180800061、0.178970528、0.178583198、0.177824992。

为了进一步验证相关指标与洪水概率的关联性，我们分别对相关指标（强相关指标取前四个，弱相关指标取后两个）与洪水概率的数据进行绘制趋势折线图，进行可视化分析。由于数据量较大，我们只取其中的 100 个数据进行绘制折线图，绘制图表如下所示：

（下面四张图为强相关指标趋势图）

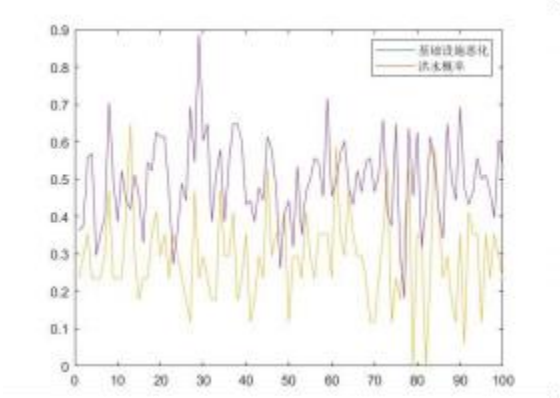


图 3 基础设施恶化趋势图

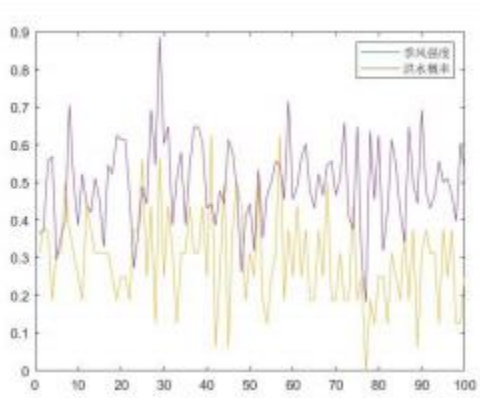


图 4 季风强度趋势图

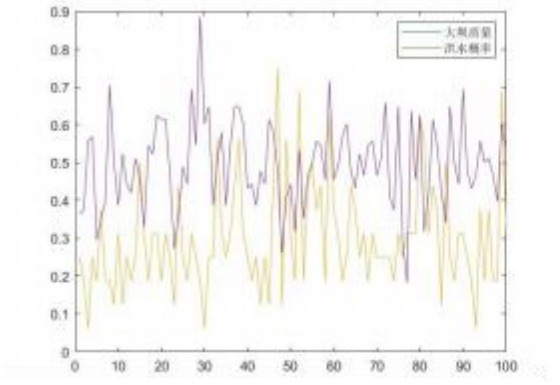


图 5 大坝质量恶化趋势图

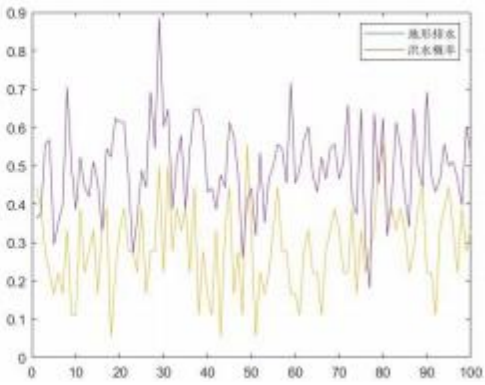


图 6 地形排水恶化趋势图

（下面两张图为弱相关指标趋势图）

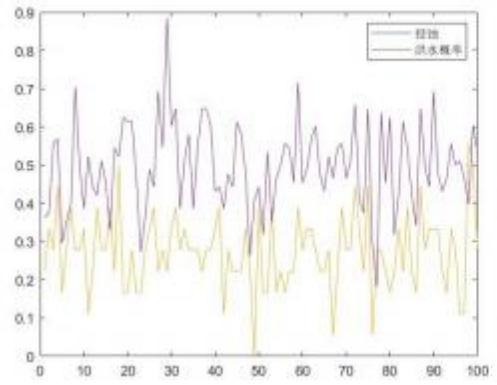


图 7　侵蚀趋势图

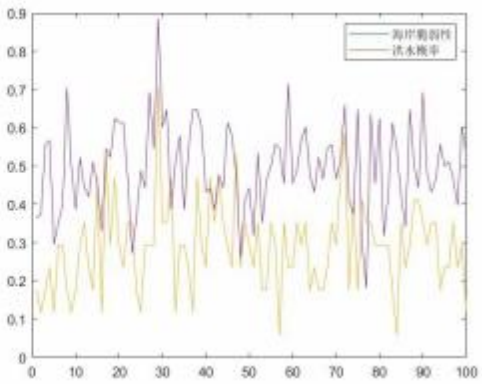


图 8　海岸脆弱性趋势图

由上面六张趋势图可以看出，这六项指标的趋势与洪水概率的趋势差别近似相同。主要是因为强相关指标系数的值和弱相关指标系数的值相差并不大，因此区别不太明显。

6.3 原因分析与建设建议

由上述结果我们可以知道，基础设施恶化、季风强度、大坝质量、地形排水、河流管理、淤积这六项指标与洪水发生的关联性较强，规划不足、排水系统、侵蚀、海岸脆弱性这六项指标与洪水发生的关联性较弱。其主要原因有以下几点：

- 基础设施是一个城市的物质基础，基础设施的弱化通过影响排水系统、防洪设施、土地利用和气候适应能力等多个方面，增加了洪水发生的可能性。
- 季风强度的增强通过增加降水总量、改变降水分布、增加洪水频率和持续时间、影响地形和地理条件、影响城市化和土地利用，以及通过气候变化的综合影响，促进洪水的发生。
- 大坝质量如果下降，其结构稳定性、泄洪能力、维护情况、监测系统等功能将会受到损害，从而增加洪水发生的可能性。
- 地形排水通过影响地形坡度、集水区大小、地形排水系统、地形结构、地下水位、植被覆盖等多方面来影响洪水发生的可能性。
- 河流管理如果不到位，则河流流量可能会大大增加，进而比较直接地导致洪水的发生可能性增加。
- 淤积可能会导致河流过水断面减小、行洪能力下降、洪水演进速度加快、洪水频率增加等负面影响，进而增加了洪水发生的可能性。
- 规划不足、排水系统、侵蚀和海岸脆弱性这四项指标虽然对洪水的发生可能性产生一定的影响，但相比于上面六项指标其影响的方面相对较少，因此与洪水发生的关联性较弱。

针对以上情况，我们提出以下建议：

- 加强基础设施建设和维护，以及合理规划土地利用和提升气候适应能力。
- 加强对季风活动的检测，采取相应防洪措施。
- 确保大坝质量，包括设计、施工、维护和监测的各个环节。
- 设计和维护地形排水系统、合理利用土地、加强植被保护。
- 加强河道疏浚、植被恢复、水土保持，合理规划土地使用。
- 加强对河道的管理，控制河流流量。

6.4 小结

问题一主要通过 FP-Growth 关联分析法对训练数据进行分析，找出强相关性指标和

弱相关性指标并进行可视化分析。通过计算结果我们给出相关原因并提出相关建议和措施。

八、问题二的建模与求解

问题二主要要求我们对洪水发生概率进行聚类，分为具有高、中、低风险的洪水三类，并且选取合适的指标，计算指标的权重，建立发生洪水不同风险的预警评价模型，最后进行模型的灵敏度分析。针对问题二的前半小问，我们主要采用K-mean 均值分类法对事件的洪水发生概率进行聚类分析，并分析具有高、中、低风险的洪水事件的指标特征；针对问题二的后半小问，我们主要采用随机森林分类模型对附件数据进行学习，并通过这种方法计算出每个指标的重要程度，进而通过重要程度比例计算出每个指标的权重。通过上述结果我们选出权重较大的指标对洪水发生概率进行预测，再通过随机森林分类模型建立发生洪水不同风险的预警评价模型。对于灵敏度的分析，我们分别去除不同的指标后再将模型代入到随机森林分类模型中进行分类学习，计算并比较预测的正确率，从而对灵敏度进行分析。

图 9 是问题二的相关思路的思维导图：

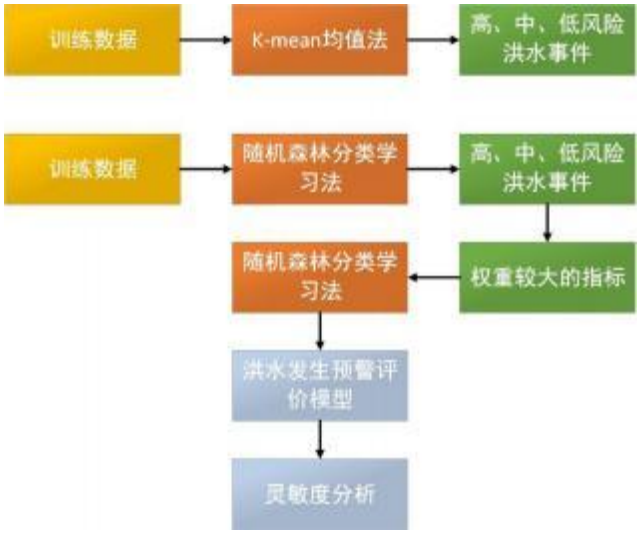


图 9　问题二思维导图

7.1 K-mean 均值法的介绍

对于问题二的上半问，我们主要通过 K-mean 均值法根据洪水概率对训练数据进行聚类，从而将训练数据分为高、中、低三类洪水风险事件。接下来我们来介绍 K-mean 均值法的基本内容[4-5]：

K-means 算法是很典型的基于距离的聚类算法，采用距离作为相似性的评价指标，即认为两个对象的距离越近，其相似度就越大。该算法认为簇是由距离靠近的对象组成的，因此把得到紧凑且独立的簇作为最终目标。

算法工作原理：输入聚类个数 k 以及包含 n 个数据对象的数据库，在输出上满足方差最小的 k 个聚类。

算法步骤：（1）从 N 个文档随机选取 K 个文档作为质心；（2）对剩余的每个文档测量其到每个质心的距离，并把它归到最近的质心的类；（3）重新计算已经得到的各个类的质心；（4）迭代 2~3 步直至新的质心与原质心相等或小于指定阈值，算法结束。

L-mean 均值法的核心公式为：

$$V = \sum_{i=1}^{k} \sum_{x_j \in S_i} (x_j - u_i)^2 \tag{2}$$

其中，V 表示总方差，Si 表示集合，ui 表示第 i 个聚类点，k、i、j 表示序号。

图 10 是 K-mean 均值法的流程思维导图：

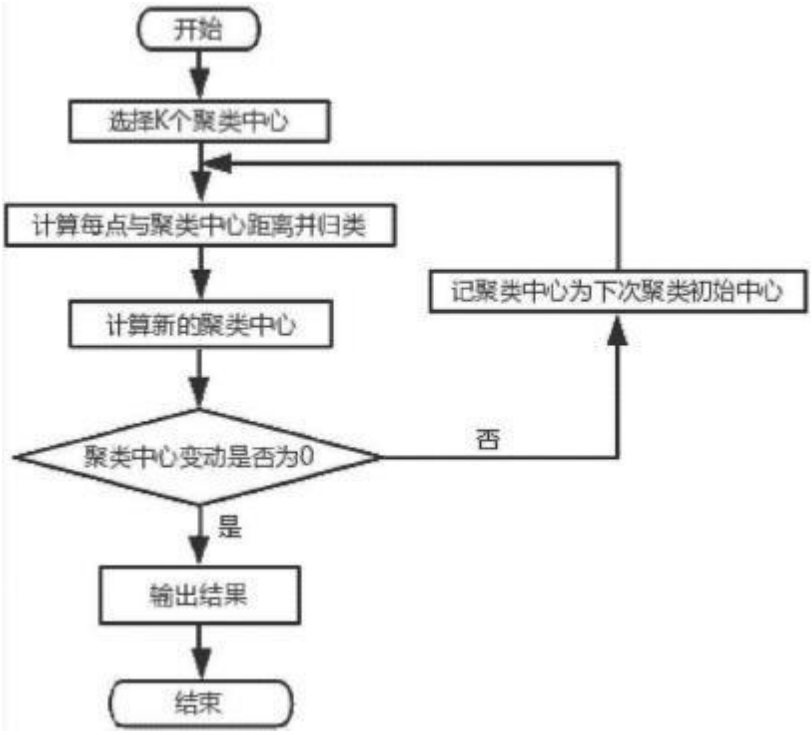


图 10　K-mean 均值法流程图

7.2 模型的计算与求解

我们将缩减后的训练数据代入到 K-mean 均值法的 MATLAB 程序中进行计算。根据题意我们将聚类个数定为 3 个，通过计算我们得到了训练数据的聚类结果，聚类结果由数字 1、2、3 表示，其中聚类 1 表示低风险洪水事件；聚类 2 表示中风险洪水事件；聚类 3 表示高风险洪水事件。表 6 和表 7 分别显示了聚类阈值和部分聚类结果样式：

表 6　聚类阈值

聚类类别	编号内容	聚类中心
1	0.285—0.465	0.4428
2	0.470—0.530	0.5020
3	0.535—0.725	0.5640

表 7　聚类结果的部分样式

事件 id	聚类结果
1	2
2	2
3	3

图 11 和图 12 分别展示训练数据的聚类散点图和聚类数量饼状图：

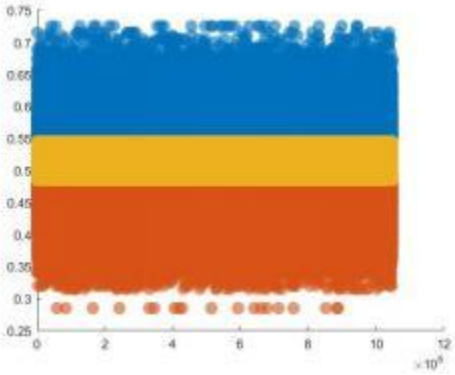


图 11　训练数据聚类散点图

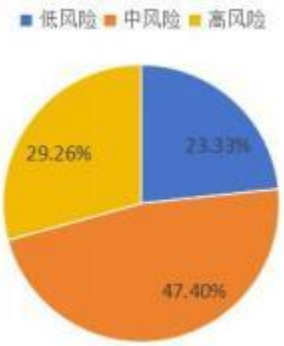


图 12　不同聚类类型数量比例

由图表我们可以分析出，在训练数据事件当中，聚类中心比较集中；在训练数据事件中，中风险洪水事件数量占比最大，其次为高风险洪水事件和低风险洪水事件。这说明在训练数据事件中，中风险洪水事件占最多数，而低风险洪水事件占最少数；由此我们可以推测在整个附件数据事件中，中风险洪水事件占最多数，低风险洪水事件占最少数，高风险洪水事件居中。

7.3 高、中、低风险洪水事件的特征分析

根据上述计算结果，我们以训练数据为基础对三类洪水事件进行指标分析。我们分别绘制出三类洪水事件的指标平均值的柱状图，结果如下所示：

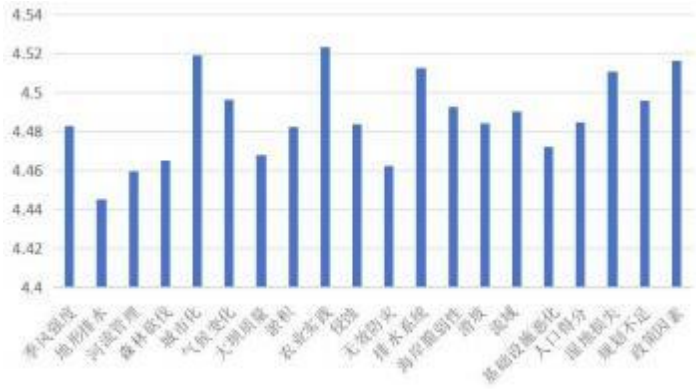


图 13　低风险洪水事件指标平均值柱状图

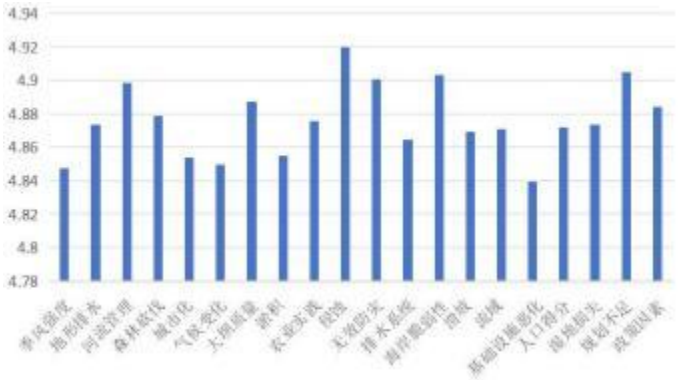


图 14　中风险洪水事件指标平均值柱状图

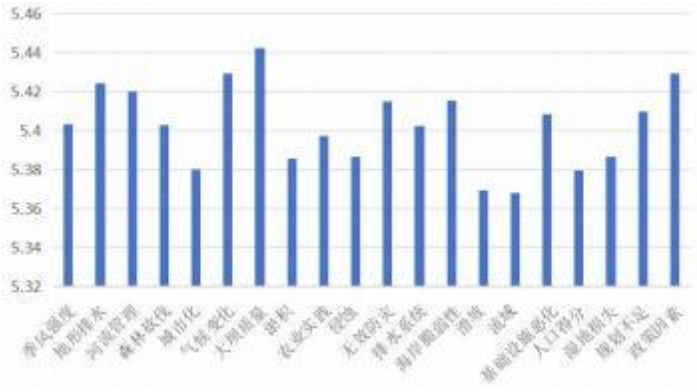


图 15　高风险洪水事件指标平均值柱状图

由三个柱状图我们可以看出：在总体上，高风险洪水事件每个指标平均值要普遍大于中风险洪水事件，而中风险洪水事件每个指标平均值要普遍大于低风险洪水事件。这三类洪水事件的总指标分值方差近似相等。

对于低风险洪水事件来说，农业实践、城市化、排水系统、湿地损失和政策因素这 5 个指标的分值最高，在 4.5—4.52 之间；而地形排水指标的分值最低，约为 4.44。对于中风险洪水事件来说，侵蚀指标分值最高，约为 4.92；基础设施恶化和季风强度的指标分值最低，约为 4.85。对于低风险洪水事件来说，大坝质量、气候变化和政策因素这三个指标的分值最高，在 5.42—5.44 之间；而流域和滑坡这两个指标的分值最低，约为 5.37.

7.4 随机森林分类模型的介绍

对于问题二的后半问，我们主要采用随机森林分类模型来进行进行求解。接下来我们对随机森林分类模型进行简要的介绍。

随机森林是一种集成学习方法，通过建立多个决策树进行分类或回归任务。每棵树是从数据集中随机抽样生成的，在训练时选择部分特征进行分裂，最终结果是通过集成所有树的预测来确定的[6-7]。

构建随机森林的主要步骤如下：

（1）数据清洗；（2）划分训练集和测试集；（3）Bagging 抽样；（4）随机选择特征；（5）构建决策树；（6）集成预测；（7）模型评估、调优、部署。

图13是随机森林模型的主要原理步骤图：

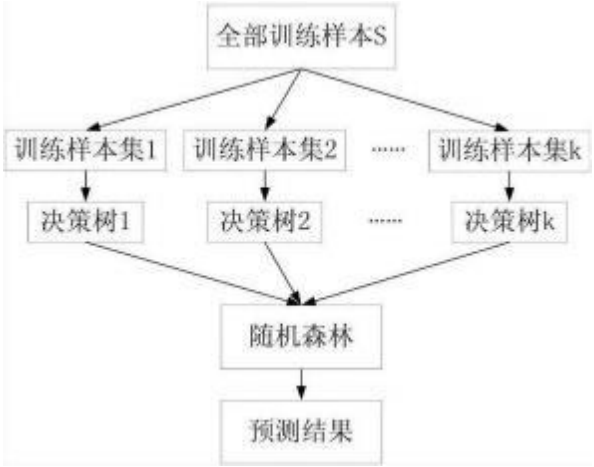


图16　随机森林模型主要原理步骤图

在本问当中，我们主要通过随机森林分类学习算法来完成三件事：特征重要性评估、建立发生洪水不同风险的预警评价模型和灵敏度分析。

7.4.1 特征重要性评估

在随机森林中，指标重要性是通过计算每个指标对模型性能提升的贡献来确定的。指标重要性的计算步骤如下：

（1）计算节点分裂的重要性：

在每棵树的构建过程中，数据集中的每个指标用于分裂节点。对于每个节点，根据选择该指标后带来的信息增益（如基尼指数或熵的减少）来衡量该指标的重要性。信息增益越大，表明该指标越能有效地将数据分开，因此该指标的重要性越高。

（2）聚合树的重要性：

对于每棵树，记录该树中每个指标的重要性。将所有树中某个特征的重要性进行平均，得到该指标在整个随机森林模型中的重要性。

（3）归一化处理：

将所有指标的重要性进行归一化，使得它们的总和为 1。这样可以直观地比较各个指标的重要性。

7.4.2 指标重要性权重计算结果

我们将训练数据按训练集与测试集比例 9:1 划分，代入到随机森林分类模型的 MATLAB 程序中计算得到指标重要性权重结果（模型基本数据：决策树数量为 50，最小叶子数为 1），用柱状图形式表示结果如下：

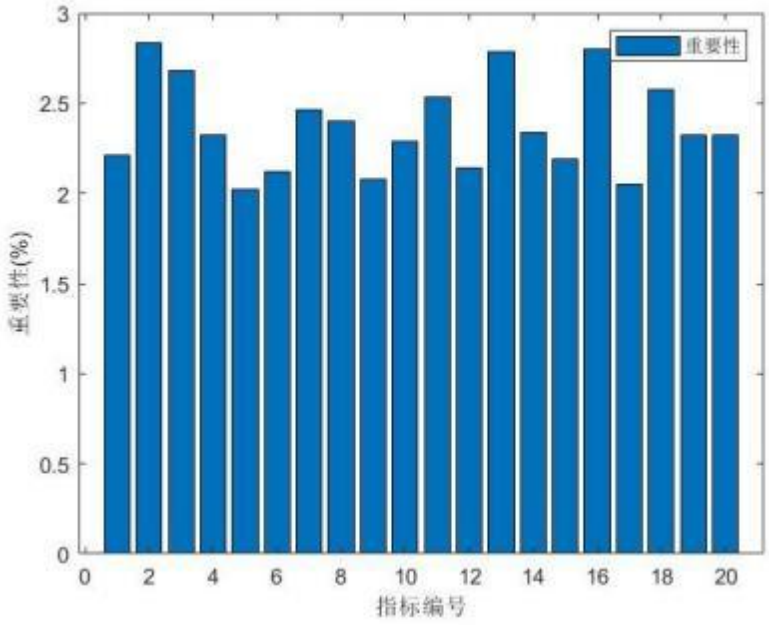


图17　指标重要性权重图

通过计算可以得出，指标重要性权重最大的前六个指标编号分别为 2、16、13、3、18、11，其权重分别为 5.9655%、5.8961%、5.8638%、5.6510%、5.4180%、5.3379%。

7.4.3 发生洪水不同风险的预警评价模型的建立

通过指标重要性权重分析与计算求解，我们算出了各个指标的权重比例。因此根据题意，我们选取权重比最大的6 个指标来建立发生洪水不同风险的预警评价模型。

首先我们将六个指标筛选出来，与聚类结果一起构成新的数据集，然后将数据集按照训练集与测试集9:1进行划分，将决策树数量设为50，将最小叶子数的数量设为1。并将新的数据集代入到随机森林模型中计算得到相关结果如下：

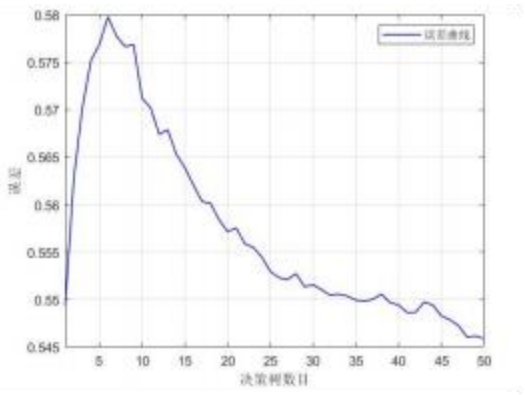


图18　模型误差趋势图

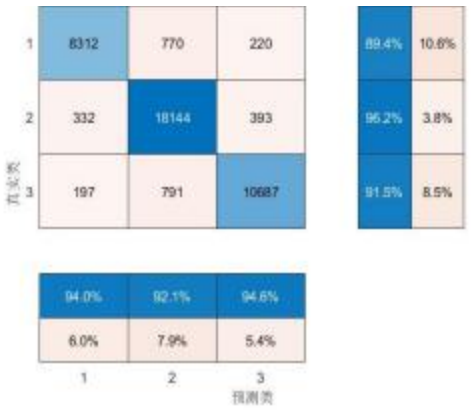


图19　训练数据混淆矩阵

下表展示的是通过随机森林进行预测的部分结果：

表 8　部分预测结果显示表

真实值	预测值	误差
1	1	0
3	3	0
1	2	1

通过计算，模型训练结果的准确性为 93.244%。

通过上述数据我们可以我们可以分析，随着决策树数量的增加，计算误差逐渐减小。然而相比于采用全部指标分类而言，由于各个指标的重要性权重相差不大，采用主要指标进行分类学习得到的结果准确性要明显小于前者。由于随机森林模型的随机性，随机森林模型计算得到的结果准确性会减小，这是随机森林模型的一个缺点。

7.5 随机森林模型的灵敏性分析

对于该模型的灵敏性分析，我们主要采用以下方法：将原模型的六个指标中去掉任意一项指标，再将剩下五个指标和聚类结果一起组成新的训练数据集并将其代入到模型中进行训练，比较去掉指标前后的训练结果的准确性。

我们将地形排水这一指标的相关数据进行踢除后得到的训练准确性结果如下：

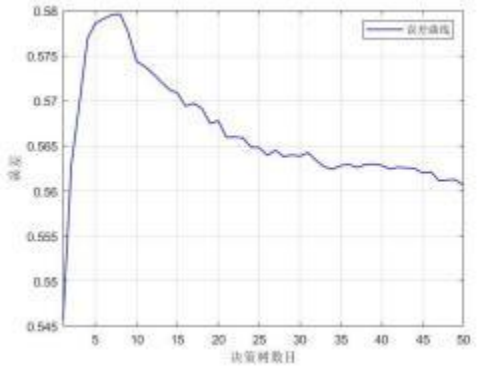


图 20　去除地形排水后误差趋势图

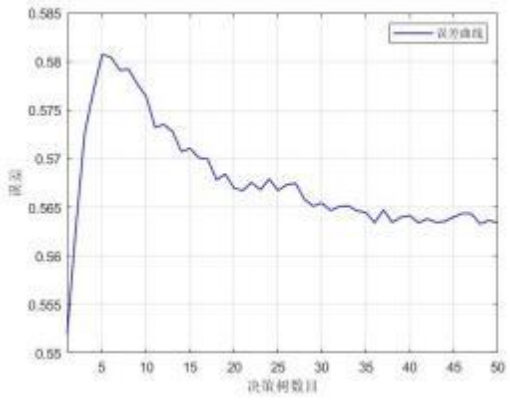


图 21　去除地形排水后训练数据混淆矩阵

经过计算得出，训练数据预测的结果为 77.408%。

通过结果我们可以知道当去除地形排水这一指标的数据后，误差从 0.545 上升到 0.56，准确率由 93.244%下降到 77.408%。由此我们可以知道地形排水这一指标对模型预测结果具有显著影响。

我们将河流管理这一指标的相关数据进行踢除后得到的训练准确性结果如下：



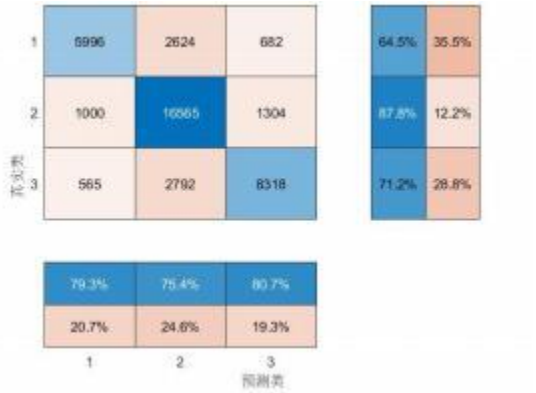


图 22　去除河流管理后误差趋势图　　**图 23　去除地形排水后训练数据混淆矩阵**

经过计算得出，训练数据预测的结果为77.496%。

通过结果我们可以知道当去除河流管理这一指标的数据后，误差从 0.545 上升到 0.5625，准确率由 93.244%下降到 77.496%。由此我们可以知道河流管理这一指标对模型预测结果具有显著影响。

通过上述结果我们可以看出，当去掉地形排水指标或河流管理指标时，误差和训练数据准确率结果都会发生显著的变化，说明该模型对指标和数据的灵敏度很强，从而验证了发生洪水不同风险的预警评价模型的灵敏度。

7.6 小结

针对问题二，我们主要通过 K-mean 均值法对训练数据集进行聚类，得到高、中、低风险的洪水事件聚类；同时我们通过随机森林分类模型对训练数据集进行学习计算，得到各个指标的重要性权重值，并选取权重值最大的六个指标建立发生洪水不同风险的预警评价模型。最后我们对所建立的模型进行灵敏度分析。但由于随机森林模型的不确定性，其预测结果准确性一般较低，这也是该模型的缺点。

九、问题三的建模与求解

问题三主要要求我们根据问题一的分析结果选取合适的指标建立洪水发生的预测模型并验证准确性，并且在此基础上建立仅用五个关键指标的风水发生的预测模型。对于这一题，我们主要通过 BP 神经网络预测模型来建立洪水发生的预测模型的。首先确定问题一选出的与洪水发生具有较强关系的重要指标，然后将这些指标和洪水概率的数据代入到 BP 神经网络预测模型的 MATLAB 代码中进行建模，进而验证模型的准确性。对于仅用五个指标的情况，我们只保留5 个与洪水发生具有最强相关性的指标，再将这些指标的数据代入到 BP 神经网络中进行建模。

9.1 BP 神经网络预测模型的介绍

BP 神经网络模型是一种基于误差反向传播算法训练的多层前馈神经网络。它通过模拟人脑神经系统的工作方式，实现对复杂问题的建模和求解。BP 神经网络以其强大的学习能力和泛化能力，在多个领域取得了显著的应用成果[8-9]。

9.1.1 BP神经网络模型结构

BP 神经网络模型是一种有向图模型，由多个神经元组成，通常包括输入层、隐藏层和输出层。下面我们来对输入层、隐藏层和输出层分别进行介绍：

输入层：接收外部输入信号。

隐藏层：对输入信号进行非线性变换，提取特征信息。隐藏层可以有多层，以增强网络的非线性拟合能力。

输出层：输出网络的处理结果。

图 21 展示的是 BP 神经网络的结构图：

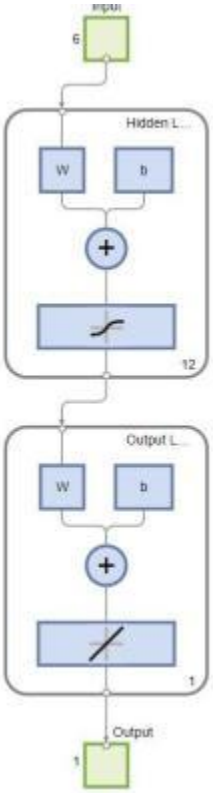


图24　BP神经网络的结构图

9.1.2 BP 神经网络学习过程

BP 神经网络的学习过程主要包括前向传播、计算误差、反向传播和参数更新四个步骤。下面我们对这些步骤进行介绍：

（1）前向传播：将输入样本通过神经网络，逐层计算神经元的输出。对于每个神经元，将前一层神经元的输出与对应的权重相乘，并将结果进行求和，然后通过激活函数得到当前神经元的输出。

（2）计算误差：将神经网络的输出与实际标签进行比较，计算误差值。常用的误差函数包括均方误差和交叉熵损失等。

（3）反向传播：根据误差值，通过链式法则计算每个权重的梯度，并利用梯度下降算法更新权重和偏置。目标是使误差沿梯度方向下降，经过反复学习训练，确定与最小误差相对应的网络参数。

（4）参数更新：根据反向传播计算得到的梯度，更新神经网络的权重和偏置，使网络对训练数据的拟合能力逐渐增强。

9.2 模型的建立与求解

接下来我们需要对模型进行分析与求解，由题目一我们选取季风强度、大坝质量、地形排水、河流管理、淤积、基础设施恶化这六个指标进行建模。

首先我们选取训练数据集的六个指标数据与洪水概率数据一起组成新的数据训练集。然后确定好 BP 神经网络模型的基本数据指标，其中数据训练集中训练集与测试集数据数量比例为 9:1，训练次数为 1000 次，学习速率为 0.01，训练目标最小误差为 0.000001。接着我们将数据训练集代入到BP 神经网络模型的MATLAB 代码中进行计算，得到如下结果：

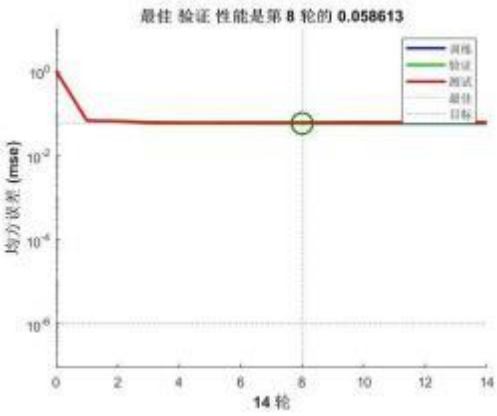


图 25　BP 神经网络性能图

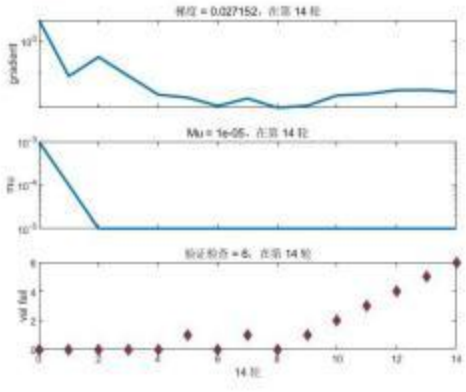


图 26　BP 神经网络训练状态图

下表是 BP 神经网络模型的训练进度表和部分预测结果显示表：

表 9　BP 神经网络模型训练进度表

单位	初始值	停止值	目标值
轮	0	15	1000
历时	-	00.00.00	-
性能	0.167	0.059	1e-06
梯度	0.514	0.0148	1e-07
Mu	0.001	1e-05	1e+10
验证检查	0	6	6

表 10　部分预测结果显示表

实际值	预测值	误差
0.455	0.483642791	0.028642791
0.47	0.463245366	0.006754634
0.565	0.511601887	0.053398113

由于洪水概率值大不相同，我们模型预测出来洪水概率的完全吻合的准确性极低，但我们可以缩短预测的结果与实际值之间的误差，因此我们可以用均方误差这一指标来表达预测模型的准确性。

由上述结果可以知道，BP 神经网络的均方误差约为 0.059，说明该模型的准确性极高，同时运算速率较快，效率较高。

9.3 仅用五个指标时模型的建立与求解

当指标个数限定为 5 个的时候，根据问题一的指标关联值，我们在上一个模型的基础上将淤积这项指标去除掉，保留季风强度、大坝质量、地形排水、河流管理、基础设施恶化这五个关联值最高的指标。并将这五个指标的数值与与洪水概率数据一起组成新的数据训练集。将 BP 神经网络模型的基本数据指标设置成和上一个模型相同的数值后，我们将数据训练集代入到 BP 神经网络模型的 MATLAB 代码中进行计算，得到如下结果：

表 11　BP 神经网络模型训练进度表

单位	初始值	停止值	目标值
轮	0	10	1000
历时	-	00.00.00	-
性能	6.04	0.0614	1e-06
梯度	13	0.00751	1e-07

Mu	0.001	1e-05	1e+10
验证检查	0	6	6

表 12　部分预测结果显示表

实际值	预测值	误差
0.455	0.46250316	0.00750316
0.47	0.473439534	0.003439534
0.565	0.509437895	0.055562105

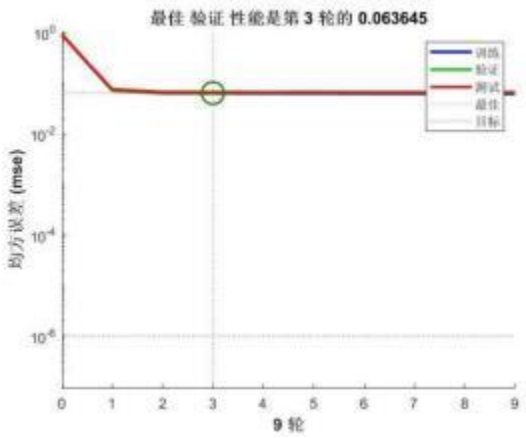


图 27　BP 神经网络性能图

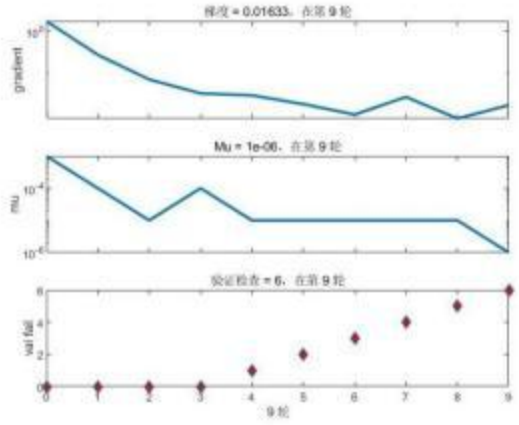


图 28　BP 神经网络训练状态图

由上述结果可以知道，BP 神经网络的均方误差约为 0.0614，说明该模型仍然具有较高的准确性，运算速率较快，效率较高。但相比于前一个 BP 神经网络模型而言，该模型的准确性稍微偏低。

9.4 小结

本问题主要根据问题一的情况，运用BP 神经网络模型，分别在六个强关联指标和五个强关联指标的情况下建立洪水发生概率的预测模型。由结果可以知道，两个模型的准确性都较高，但第二个模型的准确性相比于第一个准确性而言稍微偏低。

十、问题四的建模与求解

问题四要求我们基于问题 2 中建立的洪水发生概率的预测模型，预测附件 test.csv 中所有事件发生洪水的概率，并将预测结果填入附件 submit.csv 中。然后绘制这 74 多万件发生洪水的概率的直方图和折线图，分析此结果的分布是否服从正态分布。因此，我们将数据集带入模型，得出预测结果，针对所得数据不清楚其分布情况，采用非参数检验 KS 检验方法，得出不符合正态分布。

10.1 发生概率的预测

我们将 test.csv 中的数据带入第二问建立的随机森林模型并计算得到相应结果，部分预测结表 13 所示：

表 13　部分洪水概率表

id	洪水概率	id	洪水概率
1117961	0.505%	1118135	0.5%
1117985	0.535%	1118189	0.52%

1117997	0.47%	1437913	0.625%
1118043	0.49%	1840766	0.655%
1118066	0.49%	1234265	0.69%

10.2 检测数据分布

10.2.1 检测方法的确定

为了确定预测结果分布规律是否符合正态分布，我们引入了KS 检测。

KS 检测法是比较一个频率分布与理论分布或者两个观测值分布的检验方法。其基本操作方法如下所示：

原假设 H0:两个数据分布一致或者数据符合理论分布。

判断公式：

$$D = \max[f(x) - g(x)] \quad (3)$$

其中$f(x)$ 是频率分布函数，$g(x)$ 是理论分布函数。

当实际观测值$D > D(n, a)$ 时，则拒绝 H0，否则则接受 H0 假设。

KS 检验的基本思想是:根据经验分布函数与期望分布函数的累计分布的差值，可以构造一个服从 Kolmogorov 分布的统计量，进而进行检验。该检验被归为非参数检验。KS 检验 Q 与t-检验之类的其他方法不同是 KS 检验不需要知道数据的分布情况，可以算是一种非参数检验方法。当然这样方便的代价就是当检验的数据分布符合特定的分布事，KS 检验的灵敏度没有相应的检验来的高。在样本量比较小的时候，KS 检验最为非参数检验在分析两组数据之间是否不同时相当常用。

10.2.2 测试相关数据的准确性

我们将通过计算得到的概率结果数据代入到 MATLAB 中绘制直方图和折线图，结果如下所示.

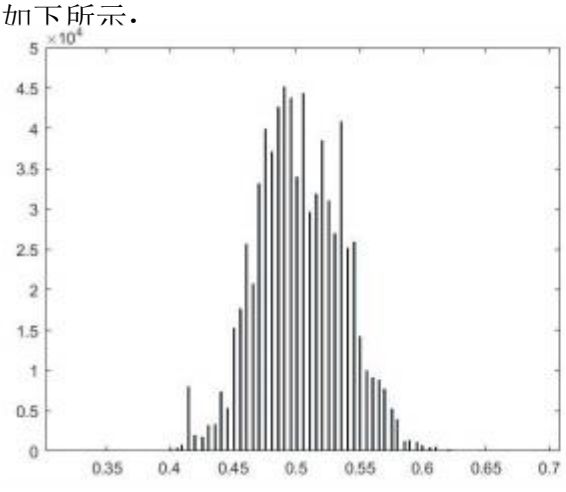


图 29　洪水概率直方图

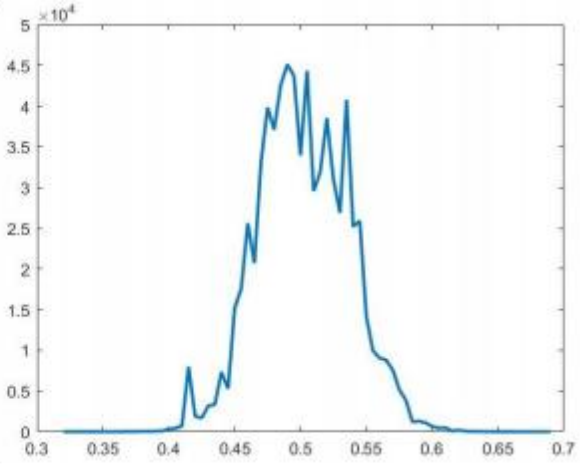


图 30　洪水概率折线图

正态分布的显著性水平一般为 0.05，但通过计算预测结果为 h=1，拒绝原假设，不符合正态分布。

10.3 小结

问题四我们主要将附件 test.csv 中的数据带入到问题二的随机森林分类模型中计算洪水概率结果，并将计算结果写入 submit.csv 文件中。同时画出洪水发生概率直方图和

直线图。最后我们通过 KS 检验法检验得出在显著条件为 0.05 的情况下洪水概率数据分布不符合正态分布。

十一、模型评价与推广

11.1 模型评价

模型优点：

- 该模型运用了FP-Growth 关联分析法来分析指标与洪水发生之间的关联性，相比于 Apriori 关联分析法来说，该模型能减少候选集的生成以及内存使用更少，从而更适合频繁项集的发现，因此效率更高。
- 本模型在使用附件数据时，采取随机选取数据的方法对大批量数据进行缩减，这样不仅依然能够反映附件数据的真实情况，还能减少数据运算量，提高效率，避免电脑内存不够而导致结果运算失败的情况。
- 该模型运用BP 神经网络模型来对数据训练集进行学习，同时对洪水发生概率进行预测。BP 神经网络模型具有准确性高，效率高，易操作等特点，这大大提高了预测结果的可能性。

模型缺点：

- 该模型所使用的随机森林分类模型由于其随机性，其运算得到的结果往往准确率低下，同时伴随计算结果不唯一的问题。应该将其他能够克制随机性的算法与随机森林分类模型一起使用，从而可以大大提高计算结果准确性。
- 该模型在解决问题一时只考虑了洪水发生概率高的事件与高数值指标之间的强关联情况，没有充分考虑洪水发生概率低的事件与指标之间的关联情况，考虑纬度有待提高。

11.2 模型推广

- 该模型可以运用于对某个地区洪水发生风险和发生概率的预测方面来。
- 处理预测洪水之外，该模型还可以运用于根据某地的相关指标情况来预测该地段发生某件事情的概率和风险情况。

参考文献

[1] 梁树杰.基于 FP-growth 算法的高维混合属性数据挖掘方法[J].计算技术与 自动化,2024,43(02):88-92.DOI:10. 16339/j.cnki.jsjsyzdh.202402015.

[2] 刘永涛,张慧臣,袁诗泉,等.基于 FP-growth 的老年行人交通事故损伤致因研究[J].中国安全生产科学技术,2024,20(06):176-182.

[3] 马晓平,曹少中,李旸.基于优化 Apriori 算法的印刷检测数据关联分析[J].北京印刷学院学报,2024,32(06):22-26.DOI:10.19461/j.cnki.1004-8626.2024.06.003.

[4] 高山行,王慧,杨张博.生成式人工智能领先企业专利布局分析——基于复杂网络分析与 K 均值聚类算法[J/OL].科技进步与对策,1-12[2024-07-08].http://kns.cnki.net/kcms/detail/42.1224.G3.20240328.1641.006.html.

[5] 李金, 李素, 王祖荣, 等. 融合混沌灰狼优化算法的 K-均值聚类算法[J]. 计算机仿真,2024,41(05):343-347+358.

[6] 王克忠,谢添,李梅,等.基于数值样本和随机森林分类器的岩爆风险快速预测代理模型[J].清华大学学报(自然科学版),2024,64(07):1203-1214.DOI:10. 16511/j.cnki.qhdxxb.2024.26.027.

[7] 高若楠,施佳子,樊红,等.基于随机森林的三江平原地区作物分类研究[J].武汉大学学报(工学版),2024,57(04):519-527.DOI:10.14188/j.1671-8844.2024-04-015.

[8] 嵇晶晶,佘冬立,阿力木·阿布来提,等.基于优化 BP 神经网络的盐渍化农田排水沟水体溶存 N_(2)O 浓度预测[J/OL].中国环境科学,1-10[2024-07-08].https://doi.org/10.19674/j.cnki.issn1000-6923.20240705.001.

[9]陈懂娟.基于 BP 神经网络的公共建筑工程造价预测研究[J].科技创新与应用,2024,14(18):153-156.DOI:10.19981/j.CN23-1581/G3.2024.18.035.

附录

（以下主要是 MATLAB 代码）

问题一代码：

```
a=readmatrix("原始数据 .csv");
A=zeros(41943,21);
z=1;
for i =1:1048575
if(i==25*z)
A(z,:)=a(i,:);
z=z+1;
end
end
H=A(:,21);
xlswrite("洪水概率 .xlsx",H);

B=zeros(41943,21);
y=1;
for i =1:41943
if(A(i,21)>=0.6)
B(y,:)=A(i,1:21);
y=y+1;
end
end

qq=zeros(41943,21);
for i =1:41943
k=1;
for j =1:20
if(B(i,j)>=9)
qq(i,k)=j;
k=k+1;
end
end
qq(i,k)=21;
end

qqq=zeros(41943,21);
h=1;
for i =1:41943
if(qq(i,2)~=0)
qqq(h,:)=qq(i,:);
h=h+1;
end
```

```
end
zz=qqq(1:h-1,:);
xlswrite("相关联性 .xlsx",zz);


X=readmatrix("原始数据 .csv");
AA=X(:,2:21);
A=zeros(1048575,20);
for i = 1:20
maxx=max(AA(:,i));
minx=min(AA(:,i));
for j = 1:1048575
A(j,i)=(AA(j,i)-minx)/(maxx-minx);
end
end
a1=A(:,1);
a2=A(:,2);
a3=A(:,3);
a4=A(:,4);
a5=A(:,5);
a6=A(:,6);
a7=A(:,7);
a8=A(:,8);
a9=A(:,9);
a10=A(:,10);
a11=A(:,11);
a12=A(:,12);
a13=A(:,13);
a14=A(:,14);
a15=A(:,15);
a16=A(:,16);
a17=A(:,17);
a18=A(:,18);
a19=A(:,19);
a20=A(:,20);
B=X(:,22);
b=zeros(1048575,1);
maxxx=max(B);
minxx=min(B);
for j = 1:1048575
b(j,1)=(B(j,1)-minxx)/(maxxx-minxx);
end
c=zeros(1,20);
c1=corrcoef(a1,b);
c2=corrcoef(a2,b);
```

```
c3=corrcoef(a3,b);
c4=corrcoef(a4,b);
c5=corrcoef(a5,b);
c6=corrcoef(a6,b);
c7=corrcoef(a7,b);
c8=corrcoef(a8,b);
c9=corrcoef(a9,b);
c10=corrcoef(a10,b);
c11=corrcoef(a11,b);
c12=corrcoef(a12,b);
c13=corrcoef(a13,b);
c14=corrcoef(a14,b);
c15=corrcoef(a15,b);
c16=corrcoef(a16,b);
c17=corrcoef(a17,b);
c18=corrcoef(a18,b);
c19=corrcoef(a19,b);
c20=corrcoef(a20,b);
c(1,1)=c1(1,2);
c(1,2)=c2(1,2);
c(1,3)=c3(1,2);
c(1,4)=c4(1,2);
c(1,5)=c5(1,2);
c(1,6)=c6(1,2);
c(1,7)=c7(1,2);
c(1,8)=c8(1,2);
c(1,9)=c9(1,2);
c(1,10)=c10(1,2);
c(1,11)=c11(1,2);
c(1,12)=c12(1,2);
c(1,13)=c13(1,2);
c(1,14)=c14(1,2);
c(1,15)=c15(1,2);
c(1,16)=c16(1,2);
c(1,17)=c17(1,2);
c(1,18)=c18(1,2);
c(1,19)=c19(1,2);
c(1,20)=c20(1,2);
[ind1,ind2]=sort(c,"descend");
ind1
ind2
c
xx=zeros(2,20);
xx(1,:)=ind2;
xx(2,:)=ind1;
```

```
xlswrite("指标相关联系数 .xlsx",xx);
d16=a16(1:100,1);
d1=a1(1:100,1);
d7=a7(1:100,1);
d2=a2(1:100,1);
d10=a10(1:100,1);
d13=a13(1:100,1);
d21=b(1:100,1);
X=1:100;
figure(1)
plot(X,d16)
hold on
plot(X,d21)
legend("基础设施恶化","洪水概率")
figure(2)
plot(X,d1)
hold on
plot(X,d21)
legend("季风强度","洪水概率")
figure(3)
plot(X,d7)
hold on
plot(X,d21)
legend("大坝质量","洪水概率")
figure(4)
plot(X,d2)
hold on
plot(X,d21)
legend("地形排水","洪水概率")
figure(5)
plot(X,d10)
hold on
plot(X,d21)
legend("侵蚀","洪水概率")
figure(6)
plot(X,d13)
hold on
plot(X,d21)
legend("海岸脆弱性","洪水概率")
```

问题二代码：

```
HS=readmatrix("洪水概率 .xlsx");
data(:,1)=HS(:,1);
data(:,2)=HS(:,2);
data(:,3)=HS(:,2);
```

```
figure(1)
scatter(data(:,1),data(:,2), 'LineWidth',2)
data1=data(:,2:3);
data2=data(:,2);
title("原始数据散点图")
cluster_num=3;
[index_cluster,cluster] = kmeans_func(data1,cluster_num);
index_cluster;
cluster
index_cluster=index_cluster';
xlswrite("洪水概率.xlsx",index_cluster,"sheet1","C2:C41944");
%% 画出聚类效果
figure(2)
% subplot(2,1,1)
a=unique(index_cluster);%找出分类出的个数
C=cell(1,length(a));
for i=1:length(a)
C(1,i)={find(index_cluster==a(i))};
end
for j=1:cluster_num
data_get=data(C{1,j},:);
scatter(data_get(:,1),data_get(:,2),100, 'filled', 'MarkerFaceAlpha',.6, 'MarkerEdgeAlpha',.9);
hold on
end
hold on
sc_t=mean(silhouette(data,index_cluster'));
title_str=['原理推导 K 均值聚类', ' 聚类数为: ',num2str(cluster_num), ' SC 轮廓系数:',num2str(sc_t)];
title(title_str);

function [index_cluster,cluster] = kmeans_func(data,cluster_num)
%% 原理推导 Kmeans 聚类算法
[m,n]=size(data);
cluster=data(randperm(m,cluster_num),:);%从 m 个点中随机选择 cluster_num 个点作为初始聚类中心点
epoch_max=1000;%最大次数
therad_lim=0.001;%中心变化阈值
epoch_num=0;
while(epoch_num<epoch_max)
epoch_num=epoch_num+1;
% distance1 存储每个点到各聚类中心的欧氏距离
for i=1:cluster_num
distance=(data-repmat(cluster(i,:),m,1)).^2;
distance1(:,i)=sqrt(sum(distance'));
```

```
    end
    [~,index_cluster]=min(distance1 ');%index_cluster 取值范围 1~cluster_num
    % cluster_new 存储新的聚类中心
    for j=1:cluster_num
    cluster_new(j,:)=mean(data(find(index_cluster==j),:));
    end
    %如果新的聚类中心和上一轮的聚类中心距离和大于 therad_lim，更新聚类中心，否则算法结束
    if (sqrt(sum((cluster_new-cluster).^2))>therad_lim)
    cluster=cluster_new;
    else
    break;
    end
    end
    end

    %************************************************************************
************************************************************************************
************************************************
    %% 清空环境变量
    warning off % 关闭报警信息
    close all % 关闭开启的图窗
    clear % 清空变量
    clc % 清空命令行
    %************************************************************************
************************************************************************************
************************************************
    %% 导入数据
    res = xlsread('训练.xlsx');
    %************************************************************************
************************************************************************************
************************************************
    %% 划分训练集和测试集
    %************************************************************************
************************************************************************************
************************************************
    P_train = res(1:39846, 1:6)';
    T_train = res(1:39846, 7)';
    M = size(P_train, 2);
    %************************************************************************
************************************************************************************
************************************************
    P_test = res(39847:41943, 1:6)';
    T_test = res(39847:41943, 7)';
    N = size(P_test, 2);
```

```
    %%************************************************************************
************************************************************************************
************************************************
    %% 数据归一化
    [p_train, ps_input] = mapminmax(P_train, 0, 1);
    p_test = mapminmax('apply ', P_test, ps_input );
    t_train = T_train;
    t_test = T_test ;
    %%************************************************************************
************************************************************************************
************************************************
    %% 转置以适应模型
    p_train = p_train '; p_test = p_test ';
    t_train = t_train '; t_test = t_test ';
    %%************************************************************************
************************************************************************************
************************************************
    %% 训练模型
    trees = 50; % 决策树数目
    leaf = 1; % 最小叶子数
    OOBPrediction = 'on '; % 打开误差图
    OOBPredictorImportance = 'on '; % 计算特征重要性
    Method = 'classification '; % 分类还是回归
    net = TreeBagger(trees, p_train, t_train, 'OOBPredictorImportance ',
OOBPredictorImportance, ...
    'Method ', Method, 'OOBPrediction ', OOBPrediction, 'minleaf ', leaf);
    importance = net.OOBPermutedPredictorDeltaError;% 重要性
    %%************************************************************************
************************************************************************************
************************************************
    %% 仿真测试
    t_sim1 = predict(net, p_train);
    t_sim2 = predict(net, p_test );
    %%************************************************************************
************************************************************************************
************************************************
    %% 格式转换
    T_sim1=cellfun(@str2num,t_sim1);
    T_sim2=cellfun(@str2num,t_sim2);
    %%************************************************************************
************************************************************************************
************************************************
    %% 性能评价
    error1 = sum((T_sim1 ' == T_train)) / M * 100 ;
    error2 = sum((T_sim2 ' == T_test )) / N * 100 ;
```

```
    %*************************************************************************
*************************************************************************
*************************************************
    %% 绘制误差曲线
    figure
    plot(1  : trees, oobError(net),  'b- ',  'LineWidth ', 1)
    legend('误差曲线')
    xlabel('决策树数目')
    ylabel('误差 ')
    xlim([1, trees])
    grid
    %*************************************************************************
*************************************************************************
*************************************************
    %% 绘制特征重要性
    % figure
    % bar(importance)
    % legend('重要性')
    % xlabel('指标编号')
    % ylabel('重要性(%) ')
    %*************************************************************************
*************************************************************************
*************************************************
    %% 数据排序
    [T_train, index_1] = sort(T_train);
    [T_test , index_2] = sort(T_test );
    %*************************************************************************
*************************************************************************
*************************************************
    T_sim1 = T_sim1(index_1);
    T_sim2 = T_sim2(index_2);
    %*************************************************************************
*************************************************************************
*************************************************
    %% 绘图
    figure
    plot(1: M, T_train,  'r-* ', 1: M, T_sim1,  'b-o ',  'LineWidth ', 1)
    legend('真实值 ',  '预测值')
    xlabel('预测样本')
    ylabel('预测结果')
    string = {'训练集预测结果对比 '; [ '准确率= '  num2str(error1)  '%']};
    title(string)
    grid
    xlswrite("真实值与预测值 .xlsx",T_train,"A1:A39846");
```

```
    xlswrite("真实值与预测值.xlsx",T_sim1,"B1:B39846");
    %%%%
```

```
input=data(:,1:end-1); %第 1 列至倒数第 2 列为输入
output=data(:,end); %最后 1 列为输出

N=length(output); %计算样本数量
testNum=37749; %设定测试集样本数量，从数据集后面选取
trainNum=N-testNum; %设定训练集样本数量
%% 3.设置训练集和测试集
input_train = input(1:trainNum,:) '; % 训练集输入
output_train =output(1:trainNum) '; % 训练集输出
input_test =input(trainNum+1:trainNum+testNum,:) '; % 测试集输入
output_test =output(trainNum+1:trainNum+testNum) '; % 测试集输出
%% 4.数据归一化
[inputn,inputps]=mapminmax(input_train,0,1); % 训练集输入归一化到[0,1]之间
[outputn,outputps]=mapminmax(output_train); % 训练集输出归一化到默认区间[-1, 1]
inputn_test=mapminmax('apply ',input_test,inputps); % 测试集输入采用和训练集输入相同的归一化方式
%% 5.求解最佳隐含层
inputnum=size(input,2); %size 用来求取矩阵的行数和列数，1 代表行数，2 代表列数
outputnum=size(output,2);
disp(['输入层节点数： ',num2str(inputnum), ', 输出层节点数： ',num2str(outputnum)]);
disp(['隐含层节点数范围为 ',num2str(fix(sqrt(inputnum+outputnum))+1), ' 至 ',num2str(fix(sqrt(inputnum+outputnum))+10)]);
disp(' ');
disp('最佳隐含层节点的确定 ... ');
%根据 hiddennum=sqrt(m+n)+a，m 为输入层节点数，n 为输出层节点数，a 取值[1,10]之间的整数
MSE=1e+5; %误差初始化
transform_func={'tansig ', 'purelin '}; %激活函数采用 tan-sigmoid 和 purelin
train_func= 'trainlm '; %训练算法
for hiddennum=fix(sqrt(inputnum+outputnum))+1:fix(sqrt(inputnum+outputnum))+10
net=newff(inputn,outputn,hiddennum,transform_func,train_func); %构建 BP 网络
% 设置网络参数
net.trainParam.epochs=1000; % 设置训练次数
net.trainParam.lr=0.01; % 设置学习速率
net.trainParam.goal=0.000001; % 设置训练目标最小误差
% 进行网络训练
net=train(net,inputn,outputn);
an0=sim(net,inputn); %仿真结果
mse0=mse(outputn,an0); %仿真的均方误差
disp(['当隐含层节点数为 ',num2str(hiddennum), '时，训练集均方误差为： ',num2str(mse0)])
%不断更新最佳隐含层节点
if mse0<MSE
MSE=mse0;
hiddennum_best=hiddennum;
end
```

```
    end
    disp(['最佳隐含层节点数为：',num2str(hiddennum_best),'，均方误差为：',num2str(MSE)])
    %% 6.构建最佳隐含层的 BP 神经网络
    net=newff(inputn,outputn,hiddennum_best,transform_func,train_func);

    % 网络参数
    net.trainParam.epochs=1000; % 训练次数
    net.trainParam.lr=0.01; % 学习速率
    net.trainParam.goal=0.000001; % 训练目标最小误差
    %% 7.网络训练
    net=train(net,inputn,outputn); % train 函数用于训练神经网络，调用蓝色仿真界面
    %% 8.网络测试
    an=sim(net,inputn_test); % 训练完成的模型进行仿真测试
    test_simu=mapminmax('reverse',an,outputps); % 测试结果反归一化
    error=test_simu-output_test; % 测试值和真实值的误差

    % 权值阈值
    W1 = net.iw{1, 1}; %输入层到中间层的权值
    B1 = net.b{1}; %中间各层神经元阈值
    W2 = net.lw{2,1}; %中间层到输出层的权值
    B2 = net.b{2}; %输出层各神经元阈值
    %% 9.结果输出
    % BP 预测值和实际值的对比图
    figure
    plot(output_test,'bo-','linewidth',1.5)
    hold on
    plot(test_simu,'rs-','linewidth',1.5)
    legend('实际值','预测值')
    xlabel('测试样本'),ylabel('指标值')
    title('BP 预测值和实际值的对比')
    set(gca,'fontsize',12)
    xlswrite("实际值与预测值.xlsx",output_test','A1:A37749');
    xlswrite("实际值与预测值.xlsx",test_simu','B1:B37749');
    % BP 测试集的预测误差图
    figure
    plot(error,'bo-','linewidth',1.5)
    xlabel('测试样本'),ylabel('预测误差')
    title('BP 神经网络测试集的预测误差')
    set(gca,'fontsize',12)

    %计算各项误差参数
    [~,len]=size(output_test); % len 获取测试样本个数，数值等于 testNum，用于求各指标平均值
    SSE1=sum(error.^2); % 误差平方和
```

```
MAE1=sum(abs(error))/len; % 平均绝对误差
MSE1=error*error'/len; % 均方误差
RMSE1=MSE1^(1/2); % 均方根误差
MAPE1=mean(abs(error./output_test)); % 平均百分比误差
r=corrcoef(output_test,test_simu); % corrcoef 计算相关系数矩阵，包括自相关和互相关系数
R1=r(1,2);

% 显示各指标结果
disp(' ')
disp('各项误差指标结果： ')
disp(['误差平方和 SSE： ',num2str(SSE1)])
disp(['平均绝对误差 MAE： ',num2str(MAE1)])
disp(['均方误差 MSE： ',num2str(MSE1)])
disp(['均方根误差 RMSE： ',num2str(RMSE1)])
disp(['平均百分比误差 MAPE： ',num2str(MAPE1*100),'%'])
disp(['预测准确率为： ',num2str(100-MAPE1*100),'%'])
disp(['相关系数 R： ',num2str(R1)])

%显示测试集结果
disp(' ')
disp('测试集结果： ')
disp(' 编号 实际值 BP 预测值 误差')
for i=1:len
disp([i,output_test(i),test_simu(i),error(i)]) % 显示顺序： 样本编号，实际值，预测值，误差
end
```

问题四代码：

```
%*************************************************************************
*************************************************************************
************************************************
%% 清空环境变量
warning off % 关闭报警信息
close all % 关闭开启的图窗
clear % 清空变量
clc % 清空命令行
%*************************************************************************
*************************************************************************
************************************************
%% 导入数据
res = readmatrix('训练 .xlsx ');
res1= readmatrix('test.csv ');
```

```
    %%%%
```

```
    %%%%
```

```
    %*************************************************************************
*************************************************************************
*********************************************
    % T_sim1 = T_sim1(index_1);
    % T_sim2 = T_sim2(index_2);
    %*************************************************************************
*************************************************************************
*********************************************
    %% 绘图
    % figure
    % plot(1: M, T_train, 'r-*', 1: M, T_sim1, 'b-o', 'LineWidth', 1)
    % legend('真实值', '预测值')
    % xlabel('预测样本')
    % ylabel('预测结果')
    % string = {'训练集预测结果对比'; ['准确率=' num2str(error1) '%']};
    % title(string)
    % grid
    %*************************************************************************
*************************************************************************
*********************************************
    % figure
    % plot(1: N, T_test, 'r-*', 1: N, T_sim2, 'b-o', 'LineWidth', 1)
    % legend('真实值', '预测值')
    % xlabel('预测样本')
    % ylabel('预测结果')
    % string = {'测试集预测结果对比'; ['准确率=' num2str(error2) '%']};
    % title(string)
    % grid
    %*************************************************************************
*************************************************************************
*********************************************
    %% 混淆矩阵
    % figure
    % cm = confusionchart(T_train, T_sim1);
    % cm.Title = 'Confusion Matrix for Train Data';
    % cm.ColumnSummary = 'column-normalized';
    % cm.RowSummary = 'row-normalized';
    %*************************************************************************
*************************************************************************
*********************************************
    % figure
    % cm = confusionchart(T_test, T_sim2);
    % cm.Title = 'Confusion Matrix for Test Data';
    % cm.ColumnSummary = 'column-normalized';
    % cm.RowSummary = 'row-normalized';
```

```
%*************************************************************************
*************************************************************************
*************************************************
```

```
a=xlsread("submit.xlsx");
A=a(:,3);
A1=a(:,1);
figure(1)
histogram(A1)
B=xlsread("wenti4 折线图 .xlsx");
C=randn(68,1);
D=zeros(68,2);
x=B(:,1);
y=B(:,2);
D(:,1)=x;
D(:,2)=C;
figure(2)
plot(x,y,"LineWidth",2);
h = kstest(y)
```